

Computational Mathematics for Learning and Data Analysis

Fondamenti Computazionali, Algebra Lineare Numerica e
Ottimizzazione

Anno Accademico 2026/2027

Indice

I	Algebra Lineare Numerica e Analisi dei Dati	1
1	Richiami di Algebra Lineare: Vettori, Norme, Basi e Trasformazioni	2
1.1	Introduzione al Calcolo Numerico e Motivazioni Applicative . . .	2
1.2	Vettori, Spazi Vettoriali e Rappresentazione Geometrica	4
1.2.1	Notazione e Convenzioni	4
1.2.2	Interpretazione Geometrica: Punti, Frecce e Regola del Parallelogramma	4
1.2.3	Il Problema della Misura della “Grandezza” di un Vettore	5
1.3	Norme Vettoriali e Spazi Normati	6
1.3.1	Famiglia delle ℓ_p -Norme su $\mathbb{R}^n$	6
1.3.2	Risoluzione Rigorosa del Confronto tra i Vettori $\mathbf{v}$ e $\mathbf{w}$	7
1.4	Prodotto Scalare Standard (Inner Product)	8
1.4.1	Notazione Matriciale e Dimensione del Risultato	8
1.5	Basi di Spazi Vettoriali e Indipendenza Lineare	9
1.5.1	Esempi Notabili di Basi	9
1.5.2	Indipendenza Lineare e Criteri di Cardinalità	10
1.6	Esercitazione Guidata: Sfere Unitarie e Geometria delle Norme	11
1.6.1	Esercizio 1: Calcolo Comparativo delle Norme in $\mathbb{R}^3$	11
1.6.2	Esercizio 2: Tracciamento delle Sfere Unitarie nel Piano $\mathbb{R}^2$	12
1.6.3	Esercizio 3: Verifica di Base in $\mathbb{R}^3$	13
1.7	Tre Visioni del Prodotto Matrice-Vettore	14
1.7.1	Definizione e Compatibilità Dimensionale	14
1.7.2	Le Tre Visioni Equivalenti del Prodotto	14
1.8	Matrici come Trasformazioni Lineari nel Piano	16
1.8.1	Esempi Geometrici Fondamentali	16
1.9	Introduzione alla Complessità Computazionale e Flops	17
1.9.1	Conteggio delle Operazioni per il Prodotto Scalare	17
1.9.2	Modello di Scaling Temporale Lineare	17

1.10	Quadro Sinottico dei Concetti Fondamentali	19
2	Prodotto tra Matrici, Complessità Computazionale e Matrici Ortogonali	20
2.1	Moltiplicazione Matrice-Matrice	20
2.1.1	Condizione di Compatibilità Dimensionale	20
2.1.2	Definizione per Componenti	21
2.1.3	Esempio Numerico Passo-Passo	21
2.2	Complessità Computazionale e Legge di Scaling	22
2.2.1	Conteggio Rigoroso dei FLOPs	22
2.2.2	Legge di Scalabilità Temporale Cubica	23
2.2.3	Quadro Comparativo delle Operazioni Fondamentali	23
2.3	Proprietà Fondamentali: Rango, Spazi Fondamentali e Invertibilità	24
2.3.1	Definizioni degli Spazi Associati a una Matrice	24
2.3.2	Invertibilità di Matrici Quadrate	25
2.3.3	Esempio Guidato: Calcolo di Rango, Nucleo e Immagine	26
2.4	Ortogonalità e Ortonormalità Vettoriale	27
2.4.1	Definizioni Fondamentali	27
2.4.2	Esercizi Costruttivi di Normalizzazione in $\mathbb{R}^2$	27
2.5	Matrici Ortogonali	28
2.5.1	Definizione e Proprietà della Trasposta	28
2.5.2	Caratterizzazione per Colonne e per Righe	28
2.5.3	Esempio Notevole: Rotazione nel Piano	29
2.5.4	Chiusura del Prodotto di Matrici Ortogonali	30
2.6	I Quattro Quesiti Notabili sulle Matrici Ortogonali	30
2.6.1	Quesito 1: Limite Superiore sulle Singole Entrate	30
2.6.2	Quesito 2: Matrici Diagonali Ortogonali	31
2.6.3	Quesito 3: Matrici Triangolari Superiori Ortogonali	31
2.6.4	Quesito 4: Isometria Euclidea e Preservazione delle Norme	32
2.7	Formulario di Sintesi del Capitolo	34
3	Matrici Ortonormali, Autovalori e Forme Quadratiche	35
3.1	Richiamo sulle Matrici Ortogonali Quadrate e Isometria	35
3.2	Matrici Rettangolari a Colonne Ortonormali	36
3.2.1	Definizione e Vincolo sulla Dimensionalità	37
3.2.2	Il Prodotto $V^T V$ (Gramiano delle Colonne)	37
3.2.3	Il Prodotto Inverso $V V^T$ (Proiettore Ortogonale)	38
3.3	Isometria Parziale per Matrici Rettangolari Ortonormali	39

3.3.1	Quesito (a): Conservazione della Norma per Vettori in $\mathbb{R}^k$	39
3.3.2	Quesito (b): Conservazione della Norma per Vettori in $\mathbb{R}^n$ sotto V^T	40
3.4	Autovalori e Autovettori: Fondamenti ed Esempio Guida	41
3.4.1	Definizioni Fondamentali	41
3.4.2	Esempio Guidato Passo-Passo	41
3.5	Diagonalizzazione ed Espansione Diadica	42
3.5.1	Matrici Diagonalizzabili	42
3.5.2	Espansione Diadica (Outer Product Expansion)	43
3.5.3	Casi Patologici di Mancata Diagonalizzabilità	43
3.6	Esercizi Guidati sugli Autovalori (Q1 – Q4)	45
3.6.1	Esercizio Q1: Autocoppie di una Matrice Diagonale	45
3.6.2	Esercizio Q2: Autocoppie della Matrice Identità	46
3.6.3	Esercizio Q3: Somma e Prodotto di Matrici con Autovalore Comune	46
3.6.4	Esercizio Q4: Autocoppie della Potenza di una Matrice	47
3.7	Matrici Simmetriche e il Teorema Spettrale	48
3.8	Forme Quadratiche e Disuguaglianza di Rayleigh	49
3.8.1	Definizione di Forma Quadratica	49
3.8.2	Teorema dei Limiti Spettrali (Disuguaglianza di Rayleigh)	49
3.8.3	Condizioni di Uguaglianza e Quoziente di Rayleigh	50
3.9	Matrici Simmetriche Definite e Semidefinite Positive	51
3.9.1	Definizioni Assiomatiche	51
3.9.2	Caratterizzazione Spettrale Equivalente	52
3.9.3	Gerarchia e Inclusione delle Classi Matriciali	52
3.9.4	Esempi Notevoli in $\mathbb{R}^{2 \times 2}$	53
3.10	Generazione Naturale di Matrici SPSPD	54
3.11	Formulario di Sintesi del Capitolo	56

II Ottimizzazione Continua e Machine Learning 57

Parte I

Algebra Lineare Numerica e Analisi dei Dati

Capitolo 1

Richiami di Algebra Lineare: Vettori, Norme, Basi e Trasformazioni

1.1 Introduzione al Calcolo Numerico e Motivazioni Applicative

Il corso affronta la risoluzione computazionale ed efficiente dei problemi tipici dell'algebra lineare su calcolatori elettronici [1, 2]. Nella matematica applicata, nella scienza dei dati e nel machine learning, la formulazione generale di un problema decisionale assume la forma di un'ottimizzazione:

$$\min_{\mathbf{x} \in S} f(\mathbf{x}), \quad (1.1)$$

dove $f : \mathbb{R}^n \rightarrow \mathbb{R}$ denota la funzione obiettivo e $S \subseteq \mathbb{R}^n$ definisce l'insieme ammissibile dei vincoli.

Nell'ambito dell'algebra lineare numerica (*Numerical Linear Algebra*), tale formulazione generale viene frequentemente ricondotta o approssimata tramite il problema lineare ai minimi quadrati (*least squares problem*):

$$\min_{\mathbf{x} \in \mathbb{R}^n} \|A\mathbf{x} - \mathbf{b}\|_2^2, \quad (1.2)$$

dove $A \in \mathbb{R}^{m \times n}$ rappresenta la matrice del modello o dei dati, $\mathbf{b} \in \mathbb{R}^m$ il vettore dei termini noti (o target osservati) e $\mathbf{x} \in \mathbb{R}^n$ l'incognita da stimare.

Perché Focalizzarsi sui Problemi Lineari?

I motivi cardine che rendono lo studio dei problemi lineari insostituibile nel calcolo scientifico moderno sono molteplici:

1. **Trattabilità teorica e chiarezza analitica:** I problemi lineari godono di una struttura algebrica pulita e ben compresa; ciò consente di formulare garanzie a priori sull'esistenza, unicità e convergenza delle soluzioni.
2. **Efficienza e precisione di macchina:** È possibile progettare algoritmi diretti o iterativi in grado di determinare la soluzione numerica fino alla precisione limite dell'aritmetica di macchina (standard IEEE 754 a virgola mobile, $\epsilon_{\text{mach}} \approx 10^{-16}$ in doppia precisione).
3. **Sfruttamento di strutture matriciali speciali:** Matrici reali caratterizzate da proprietà specifiche (simmetriche, definite positive, ortogonali, a bande, di Toeplitz o fortemente sparse) ammettono algoritmi dedicati con complessità temporale e spaziale drasticamente ridotta rispetto ai metodi generici.
4. **Blocco costitutivo di algoritmi non lineari:** La quasi totalità dei metodi numerici avanzati per problemi non lineari complessi (metodi di Newton, Quasi-Newton come BFGS, algoritmi di ottimizzazione vincolata e discretizzazione di equazioni differenziali) richiede la risoluzione di uno o più sistemi lineari a ogni singola iterazione.
5. **Stabilità e controllo dell'errore:** Nel calcolo applicato è essenziale prevenire fenomeni di propagazione incontrollata degli errori di arrotondamento, instabilità algoritmica o cancellazione numerica distruttiva.

1.2 Vettori, Spazi Vettoriali e Rappresentazione Geometrica

1.2.1 Notazione e Convenzioni

Salvo diversa indicazione esplicita, **tutti i vettori sono considerati vettori colonna**. Un vettore $\mathbf{x} \in \mathbb{R}^n$ si denota:

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}, \quad \mathbf{x}^T = \begin{bmatrix} x_1 & x_2 & \dots & x_n \end{bmatrix}. \quad (1.3)$$

Consideriamo, a titolo esemplificativo in $\mathbb{R}^2$, i vettori:

$$\mathbf{x} = \begin{bmatrix} 2 \\ 4 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}. \quad (1.4)$$

L'operazione fondamentale che definisce la struttura di spazio vettoriale è la somma componente per componente:

$$\mathbf{x} + \mathbf{y} = \begin{bmatrix} 2 \\ 4 \end{bmatrix} + \begin{bmatrix} 2 \\ 1 \end{bmatrix} = \begin{bmatrix} 2+2 \\ 4+1 \end{bmatrix} = \begin{bmatrix} 4 \\ 5 \end{bmatrix}. \quad (1.5)$$

1.2.2 Interpretazione Geometrica: Punti, Frecce e Regola del Parallelogramma

Un vettore $\mathbf{x} = [x_1, x_2]^T \in \mathbb{R}^2$ ammette una duplice interpretazione geometrica:

- come **punto** nel piano cartesiano con coordinate (x_1, x_2) rispetto all'origine;
- come **freccia orientata** (segmento orientato) avente punto di applicazione nell'origine $(0, 0)$ e vertice in (x_1, x_2) .

La somma vettoriale $\mathbf{x} + \mathbf{y}$ corrisponde alla classica **regola del parallelogramma**: traslando l'origine di $\mathbf{y}$ sulla punta di $\mathbf{x}$, il vettore risultante connette l'origine con il vertice opposto del parallelogramma individuato dai due vettori, terminando nel punto $(4, 5)$. Tale nozione si estende inalterata agli spazi euclidei di dimensione $n \geq 3$.




Figura 1.1: Interpretazione geometrica della somma vettoriale in $\mathbb{R}^2$ tramite la regola del parallelogramma.

1.2.3 Il Problema della Misura della “Grandezza” di un Vettore

Si consideri la seguente domanda apparentemente elementare:

Dati i vettori $\mathbf{v}, \mathbf{w} \in \mathbb{R}^4$:

$$\mathbf{v} = \begin{bmatrix} 2 \\ 2 \\ 2 \\ 2 \end{bmatrix}, \quad \mathbf{w} = \begin{bmatrix} 4 \\ 0 \\ 0 \\ 0 \end{bmatrix}, \quad (1.6)$$

quale tra questi due vettori è il “più grande”?

La risposta non è univoca, poiché la nozione di “grandezza” dipende criticamente dal criterio matematico adottato:

- In base al **valore massimo delle coordinate**, $\mathbf{w}$ presenta un elemento pari a 4, mentre gli elementi di $\mathbf{v}$ non superano 2.
- In base alla **somma assoluta delle coordinate**, $\mathbf{v}$ totalizza $2 + 2 + 2 + 2 = 8$, mentre $\mathbf{w}$ raggiunge appena 4.
- In base alla **lunghezza geometrica euclidea**, entrambi misurano $\sqrt{16} = 4$.

Per rendere quantitativo e inequivocabile questo confronto occorre formalizzare la nozione di **norma vettoriale**.

1.3 Norme Vettoriali e Spazi Normati

Definizione 1.3.1 (Norma Vettoriale). Sia V uno spazio vettoriale su $\mathbb{R}$ (o $\mathbb{C}$). Una funzione $\|\cdot\| : V \rightarrow \mathbb{R}$ è detta **norma vettoriale** se e solo se soddisfa i seguenti tre assiomi per ogni $\mathbf{v}, \mathbf{w} \in V$ e ogni scalare $\lambda \in \mathbb{R}$:

1. **Non-negatività e positività stretta (separazione):**

$$\|\mathbf{v}\| \geq 0 \quad \forall \mathbf{v} \in V, \quad \|\mathbf{v}\| = 0 \iff \mathbf{v} = \mathbf{0}_V. \quad (1.7)$$

2. **Omogeneità assoluta:**

$$\|\lambda \mathbf{v}\| = |\lambda| \cdot \|\mathbf{v}\| \quad \forall \lambda \in \mathbb{R}, \forall \mathbf{v} \in V. \quad (1.8)$$

3. **Disuguaglianza triangolare (sub-additività):**

$$\|\mathbf{v} + \mathbf{w}\| \leq \|\mathbf{v}\| + \|\mathbf{w}\| \quad \forall \mathbf{v}, \mathbf{w} \in V. \quad (1.9)$$

Uno spazio vettoriale V equipaggiato con una norma $\|\cdot\|$ prende il nome di **spazio normato**.

1.3.1 Famiglia delle ℓ_p -Norme su $\mathbb{R}^n$

Sia $\mathbf{v} = [v_1, v_2, \dots, v_n]^T \in \mathbb{R}^n$. Le norme più frequentemente utilizzate nell'analisi numerica e nei modelli di apprendimento appartengono alla classe delle ℓ_p -norme:

$$\|\mathbf{v}\|_p = \left(\sum_{i=1}^n |v_i|^p \right)^{1/p} \quad (p \geq 1). \quad (1.10)$$

I tre casi d'uso canonici corrispondono a:

1. **Norma Euclidea (ℓ_2).** Rappresenta la naturale lunghezza euclidea del segmento nello spazio affine:

$$\|\mathbf{v}\|_2 = \sqrt{\sum_{i=1}^n v_i^2} = \sqrt{\mathbf{v}^T \mathbf{v}}. \quad (1.11)$$

2. **Norma di Manhattan (ℓ_1 o Taxi-cab).** Calcola la somma dei moduli delle singole coordinate:

$$\|\mathbf{v}\|_1 = \sum_{i=1}^n |v_i|. \quad (1.12)$$

3. Norma del Massimo (ℓ_∞ o Norma di Chebyshev). Rileva la massima magnitudine assoluta tra tutte le componenti:

$$\|\mathbf{v}\|_\infty = \lim_{p \rightarrow \infty} \|\mathbf{v}\|_p = \max_{1 \leq i \leq n} |v_i|. \quad (1.13)$$

1.3.2 Risoluzione Rigorosa del Confronto tra i Vettori $\mathbf{v}$ e $\mathbf{w}$

Riprendiamo i vettori $\mathbf{v} = [2, 2, 2, 2]^T$ e $\mathbf{w} = [4, 0, 0, 0]^T \in \mathbb{R}^4$:

Esempio 1.3.1 (Valutazione Comparativa nelle Tre Norme).

- **In norma euclidea ℓ_2 :**

$$\|\mathbf{v}\|_2 = \sqrt{2^2 + 2^2 + 2^2 + 2^2} = \sqrt{4 + 4 + 4 + 4} = \sqrt{16} = 4, \quad (1.14)$$

$$\|\mathbf{w}\|_2 = \sqrt{4^2 + 0^2 + 0^2 + 0^2} = \sqrt{16 + 0 + 0 + 0} = \sqrt{16} = 4. \quad (1.15)$$

I due vettori possiedono esattamente la **stessa lunghezza euclidea**:
 $\|\mathbf{v}\|_2 = \|\mathbf{w}\|_2 = 4$.

- **In norma ℓ_1 :**

$$\|\mathbf{v}\|_1 = |2| + |2| + |2| + |2| = 8, \quad (1.16)$$

$$\|\mathbf{w}\|_1 = |4| + |0| + |0| + |0| = 4. \quad (1.17)$$

In norma ℓ_1 , risulta $\|\mathbf{v}\|_1 = 8 > 4 = \|\mathbf{w}\|_1$.

- **In norma ℓ_∞ :**

$$\|\mathbf{v}\|_\infty = \max\{|2|, |2|, |2|, |2|\} = 2, \quad (1.18)$$

$$\|\mathbf{w}\|_\infty = \max\{|4|, |0|, |0|, |0|\} = 4. \quad (1.19)$$

In norma infinito, l'ordinamento si inverte: $\|\mathbf{v}\|_\infty = 2 < 4 = \|\mathbf{w}\|_\infty$.

Criteri di Selezione della Norma nei Problemi Reali

La scelta della norma non è una mera preferenza formale, ma governa le proprietà matematiche del modello:

- **Trattabilità analitica e differenziabilità:** La norma euclidea quadra $\|\cdot\|_2^2$ è ovunque liscia e differenziabile, e la sua minimizzazione conduce a sistemi di equazioni lineari chiusi (equazioni normali).
- **Sparsità delle soluzioni:** La norma ℓ_1 non è differenziabile nell'origine ed induce soluzioni a supporto compatto (vettori sparsi), risultando fondamentale in statistica (Lasso) e nell'elaborazione di segnali (*compressed sensing*).
- **Limitazione del picco d'errore:** La norma ℓ_∞ trova impiego nell'approssimazione minimax e nel controllo ottimo, dove conta garantire un limite assoluto sul peggior scostamento possibile.

1.4 Prodotto Scalare Standard (Inner Product)

Definizione 1.4.1 (Prodotto Scalare in $\mathbb{R}^n$). Dati due vettori colonna $\mathbf{v}, \mathbf{w} \in \mathbb{R}^n$, il **prodotto scalare standard** (o *inner product*) è l'applicazione bilineare definita da:

$$\langle \mathbf{v}, \mathbf{w} \rangle = \mathbf{v}^T \mathbf{w} = \sum_{i=1}^n v_i w_i = v_1 w_1 + v_2 w_2 + \cdots + v_n w_n. \quad (1.20)$$

1.4.1 Notazione Matriciale e Dimensione del Risultato

Poiché $\mathbf{v}, \mathbf{w} \in \mathbb{R}^{n \times 1}$, la trasposta $\mathbf{v}^T$ è una matrice riga di tipo $1 \times n$:

$$\mathbf{v}^T = \begin{bmatrix} v_1 & v_2 & \cdots & v_n \end{bmatrix}, \quad \mathbf{w} = \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_n \end{bmatrix}. \quad (1.21)$$

Il prodotto riga per colonna $\mathbf{v}^T \mathbf{w}$ produce formalmente una matrice scalare 1×1 :

$$\mathbf{v}^T \mathbf{w} = \begin{bmatrix} v_1 & v_2 & \dots & v_n \end{bmatrix} \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_n \end{bmatrix} = \sum_{i=1}^n v_i w_i \in \mathbb{R}. \quad (1.22)$$

Proprietà 1.4.1 (Legame Diretto con la Norma Euclidea). *Il prodotto scalare di un vettore con se stesso restituisce il quadrato della sua norma euclidea:*

$$\langle \mathbf{v}, \mathbf{v} \rangle = \mathbf{v}^T \mathbf{v} = \sum_{i=1}^n v_i^2 = \|\mathbf{v}\|_2^2 \implies \|\mathbf{v}\|_2 = \sqrt{\langle \mathbf{v}, \mathbf{v} \rangle} = \sqrt{\mathbf{v}^T \mathbf{v}}. \quad (1.23)$$

Inoltre, due vettori non nulli si dicono **ortogonali** se e solo se $\langle \mathbf{v}, \mathbf{w} \rangle = 0$.

1.5 Basi di Spazi Vettoriali e Indipendenza Lineare

Definizione 1.5.1 (Combinazione Lineare). Dato un insieme ordinato di vettori $\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k\} \subseteq V$ e un insieme di scalari $\alpha_1, \alpha_2, \dots, \alpha_k \in \mathbb{R}$, la **combinazione lineare** associata è il vettore:

$$\mathbf{v} = \sum_{i=1}^k \alpha_i \mathbf{v}_i = \alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \dots + \alpha_k \mathbf{v}_k. \quad (1.24)$$

Definizione 1.5.2 (Base di uno Spazio Vettoriale). Un sottoinsieme ordinato $\mathcal{B} = \{\mathbf{v}_1, \dots, \mathbf{v}_k\} \subseteq V$ costituisce una **base** di V se ogni elemento $\mathbf{v} \in V$ può essere espresso come combinazione lineare dei vettori di $\mathcal{B}$ in **modo unico**.

1.5.1 Esempi Notabili di Basi

1. Base Canonica (Standard). In $\mathbb{R}^n$, i vettori della base canonica $\mathbf{e}_1, \dots, \mathbf{e}_n$ presentano valore 1 nella posizione corrispondente all'indice e 0 altrove:

$$\mathbf{e}_1 = \begin{bmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix}, \quad \mathbf{e}_2 = \begin{bmatrix} 0 \\ 1 \\ \vdots \\ 0 \end{bmatrix}, \quad \dots, \quad \mathbf{e}_n = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 1 \end{bmatrix}. \quad (1.25)$$

Ogni vettore $\mathbf{x} = [x_1, \dots, x_n]^T$ ammette l'espansione canonica immediata $\mathbf{x} = \sum_{i=1}^n x_i \mathbf{e}_i$.

2. Base Non Canonica in $\mathbb{R}^2$. Si consideri la coppia di vettori in $\mathbb{R}^2$:

$$\mathcal{B} = \left\{ \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ -1 \end{bmatrix} \right\}. \quad (1.26)$$

Per verificare che $\mathcal{B}$ sia una base, mostriamo che per ogni $[x, y]^T \in \mathbb{R}^2$ esistono unici scalari $\alpha_1, \alpha_2 \in \mathbb{R}$ tali che:

$$\begin{bmatrix} x \\ y \end{bmatrix} = \alpha_1 \begin{bmatrix} 1 \\ 0 \end{bmatrix} + \alpha_2 \begin{bmatrix} 1 \\ -1 \end{bmatrix} = \begin{bmatrix} \alpha_1 + \alpha_2 \\ -\alpha_2 \end{bmatrix}. \quad (1.27)$$

Il sistema lineare triangolare risultante:

$$\begin{cases} \alpha_1 + \alpha_2 = x \\ -\alpha_2 = y \end{cases} \implies \begin{cases} \alpha_2 = -y \\ \alpha_1 = x + y \end{cases} \quad (1.28)$$

ammette soluzione unica per qualsiasi scelta di (x, y) . I coefficienti cercati sono univocamente $(\alpha_1, \alpha_2) = (x + y, -y)$, dimostrando che $\mathcal{B}$ è una base valida.

1.5.2 Indipendenza Lineare e Criteri di Cardinalità

Definizione 1.5.3 (Indipendenza Lineare). Un insieme di vettori $\{\mathbf{v}_1, \dots, \mathbf{v}_k\}$ si dice **linearmente indipendente** se l'unica combinazione lineare che genera il vettore nullo è quella banale:

$$\sum_{i=1}^k \alpha_i \mathbf{v}_i = \mathbf{0}_V \implies \alpha_1 = \alpha_2 = \dots = \alpha_k = 0. \quad (1.29)$$

Se esistono coefficienti non tutti nulli per cui la somma si annulla, i vettori sono detti **linearmente dipendenti**.

Esempio 1.5.1 (Quesiti di Verifica dell'Indipendenza Lineare). Illustriamo mediante due quesiti pratici la verifica dell'indipendenza lineare e della nozione di base:

1. **Tre vettori in $\mathbb{R}^2$.** Sia dato l'insieme:

$$\mathcal{S} = \{[1, 0]^T, [2, 1]^T, [1, 1]^T\} \subset \mathbb{R}^2.$$

Determinare se $\mathcal{S}$ costituisce una base.

Risposta: NO.

- *Vincolo di dimensione:* La dimensione di $\mathbb{R}^2$ è 2. Qualsiasi base di $\mathbb{R}^2$ deve contenere esattamente due vettori. Tre o più vettori in $\mathbb{R}^2$ sono necessariamente linearmente dipendenti.
- *Dipendenza esplicita:* Poiché $[1, 1]^T = -[1, 0]^T + [2, 1]^T$, vale la combinazione non banale:

$$1 \begin{bmatrix} 1 \\ 0 \end{bmatrix} - 1 \begin{bmatrix} 2 \\ 1 \end{bmatrix} + 1 \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}. \quad (1.30)$$

2. **Due vettori collineari in $\mathbb{R}^2$.** Sia dato l'insieme:

$$\mathcal{S}' = \{[2, 1]^T, [-4, -2]^T\} \subset \mathbb{R}^2.$$

Determinare se $\mathcal{S}'$ costituisce una base.

Risposta: NO.

I due vettori sono collineari (proporzionali):

$$\begin{bmatrix} -4 \\ -2 \end{bmatrix} = -2 \begin{bmatrix} 2 \\ 1 \end{bmatrix} \implies 2 \begin{bmatrix} 2 \\ 1 \end{bmatrix} + \begin{bmatrix} -4 \\ -2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}. \quad (1.31)$$

Il loro span genera esclusivamente la retta $y = \frac{1}{2}x$ e non l'intero piano $\mathbb{R}^2$.

1.6 Esercitazione GUIDATA: Sfere Unitarie e Geometria delle Norme

1.6.1 Esercizio 1: Calcolo Comparativo delle Norme in $\mathbb{R}^3$

Dato il vettore $\mathbf{v} = [1, 2, -3]^T \in \mathbb{R}^3$, calcoliamo le tre norme fondamentali:

1. **Norma ℓ_1 :**

$$\|\mathbf{v}\|_1 = |1| + |2| + |-3| = 1 + 2 + 3 = 6. \quad (1.32)$$

2. **Norma ℓ_2 :**

$$\|\mathbf{v}\|_2 = \sqrt{1^2 + 2^2 + (-3)^2} = \sqrt{1 + 4 + 9} = \sqrt{14} \approx 3.742. \quad (1.33)$$

3. **Norma ℓ_∞ :**

$$\|\mathbf{v}\|_\infty = \max\{|1|, |2|, |-3|\} = \max\{1, 2, 3\} = 3. \quad (1.34)$$

1.6.2 Esercizio 2: Tracciamento delle Sfere Unitarie nel Piano $\mathbb{R}^2$

Si consideri il luogo geometrico dei vettori di norma unitaria al variare della metrica, per $\mathbf{v} = [x, y]^T \in \mathbb{R}^2$:

1. Sfera Euclidea $S_2 = \{\mathbf{v} \in \mathbb{R}^2 : \|\mathbf{v}\|_2 = 1\}$. L'equazione coincide con $\sqrt{x^2 + y^2} = 1 \iff x^2 + y^2 = 1$. È la **circonferenza unitaria** centrata nell'origine con raggio $R = 1$.

2. Sfera di Manhattan $S_1 = \{\mathbf{v} \in \mathbb{R}^2 : \|\mathbf{v}\|_1 = 1\}$. L'equazione $|x| + |y| = 1$ definisce, per interpolazione lineare nei quattro quadranti cartesiani:

$$\begin{cases} x + y = 1 \implies y = 1 - x & (x \geq 0, y \geq 0), \\ -x + y = 1 \implies y = 1 + x & (x \leq 0, y \geq 0), \\ -x - y = 1 \implies y = -1 - x & (x \leq 0, y \leq 0), \\ x - y = 1 \implies y = x - 1 & (x \geq 0, y \leq 0). \end{cases} \quad (1.35)$$

Geometricamente è un **quadrato ruotato di 45°** (losanga o *diamond*) con vertici nei punti cardinali $(\pm 1, 0)$ e $(0, \pm 1)$.

3. Sfera del Massimo $S_\infty = \{\mathbf{v} \in \mathbb{R}^2 : \|\mathbf{v}\|_\infty = 1\}$. La condizione $\max\{|x|, |y|\} = 1$ impone che almeno una coordinata abbia modulo pari a 1 mentre l'altra rimanga confinata in $[-1, 1]$. Geometricamente corrisponde al perimetro di un **quadrato con lati paralleli agli assi**, avente lato di lunghezza 2 e vertici nei punti $(\pm 1, \pm 1)$.




Figura 1.2: Confronto geometrico delle sfere unitarie S_1 (verde), S_2 (blu) e S_∞ (arancione tratteggiato) in $\mathbb{R}^2$. I quattro punti rossi indicano l'intersezione $S_1 \cap S_2 \cap S_\infty = \{\pm \mathbf{e}_1, \pm \mathbf{e}_2\}$.

Proprietà 1.6.1 (Intersezione Comune delle Sfere Unitarie). *L'intersezione dei tre luoghi geometrici è data esattamente dall'insieme dei vettori della base canonica e dai rispettivi opposti:*

$$S_1 \cap S_2 \cap S_\infty = \left\{ \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \end{bmatrix}, \begin{bmatrix} -1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ -1 \end{bmatrix} \right\} = \{\pm \mathbf{e}_1, \pm \mathbf{e}_2\}. \quad (1.36)$$

Solo per questi specifici quattro vettori, tutte e tre le norme assumono simultaneamente valore unitario $\|\mathbf{v}\|_1 = \|\mathbf{v}\|_2 = \|\mathbf{v}\|_\infty = 1$.

1.6.3 Esercizio 3: Verifica di Base in $\mathbb{R}^3$

Si considerino i tre vettori in $\mathbb{R}^3$:

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 0 \\ 2 \end{bmatrix}, \quad \mathbf{v}_2 = \begin{bmatrix} 2 \\ 2 \\ 0 \end{bmatrix}, \quad \mathbf{v}_3 = \begin{bmatrix} -3 \\ -4 \\ 2 \end{bmatrix}. \quad (1.37)$$

Verifichiamo se $\mathbf{v}_3$ sia esprimibile come combinazione lineare di $\mathbf{v}_1$ e $\mathbf{v}_2$:

$$\alpha \mathbf{v}_1 + \beta \mathbf{v}_2 = \mathbf{v}_3 \iff \begin{cases} \alpha + 2\beta = -3 & (\text{componente 1}), \\ 2\beta = -4 & (\text{componente 2}), \\ 2\alpha = 2 & (\text{componente 3}). \end{cases} \quad (1.38)$$

Dalla terza equazione si ricava $\alpha = 1$, mentre dalla seconda si ottiene $\beta = -2$. Sostituendo nella prima equazione:

$$\alpha + 2\beta = 1 + 2(-2) = 1 - 4 = -3, \quad (1.39)$$

il sistema risulta consistente e confermato. Abbiamo ottenuto la relazione di dipendenza lineare non banale:

$$\mathbf{v}_1 - 2\mathbf{v}_2 - \mathbf{v}_3 = \mathbf{0}_{\mathbb{R}^3}. \quad (1.40)$$

I tre vettori sono linearmente dipendenti; il vettore $\mathbf{v}_3$ appartiene al sottospazio piano $\text{span}(\mathbf{v}_1, \mathbf{v}_2)$ e dunque l'insieme $\{\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3\}$ **non costituisce una base di $\mathbb{R}^3$** .

1.7 Tre Visioni del Prodotto Matrice-Vettore

1.7.1 Definizione e Compatibilità Dimensionale

Una matrice $A \in \mathbb{R}^{n \times m}$ è una tabella rettangolare ordinata formata da n righe ed m colonne:

$$A = \begin{bmatrix} A_{11} & A_{12} & \cdots & A_{1m} \\ A_{21} & A_{22} & \cdots & A_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ A_{n1} & A_{n2} & \cdots & A_{nm} \end{bmatrix}. \quad (1.41)$$

Nel prodotto matrice-vettore $\mathbf{c} = A\mathbf{b}$, la compatibilità algebrica impone:

$$A \in \mathbb{R}^{n \times m}, \quad \mathbf{b} \in \mathbb{R}^{m \times 1} \implies \mathbf{c} = A\mathbf{b} \in \mathbb{R}^{n \times 1}. \quad (1.42)$$

Il numero di colonne di A deve coincidere esattamente con il numero di righe di $\mathbf{b}$.

1.7.2 Le Tre Visioni Equivalenti del Prodotto

Si consideri l'esempio numerico concreto:

$$A = \begin{bmatrix} 2 & 0 & 1 \\ 3 & -1 & 0 \end{bmatrix} \in \mathbb{R}^{2 \times 3}, \quad \mathbf{b} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} \in \mathbb{R}^3. \quad (1.43)$$

L'algebra lineare computazionale interpreta questo calcolo attraverso tre prospettive complementari:

Visione 1: Formula Scalare per Componenti. Ogni elemento c_i del vettore di output si ottiene accumulando i prodotti lungo riga e colonna:

$$c_i = \sum_{j=1}^m A_{ij} b_j \quad (i = 1, \dots, n). \quad (1.44)$$

Nel nostro esempio:

$$c_1 = 2 \cdot 1 + 0 \cdot 2 + 1 \cdot 3 = 2 + 0 + 3 = 5, \quad (1.45)$$

$$c_2 = 3 \cdot 1 + (-1) \cdot 2 + 0 \cdot 3 = 3 - 2 + 0 = 1 \implies \mathbf{c} = \begin{bmatrix} 5 \\ 1 \end{bmatrix}. \quad (1.46)$$

Visione 2: Prospettiva per Righe (Prodotto Scalare). Rappresentando la matrice A per righe orizzontali $\mathbf{u}_1^T, \dots, \mathbf{u}_n^T$ con $\mathbf{u}_i \in \mathbb{R}^m$:

$$A = \begin{bmatrix} - & \mathbf{u}_1^T & - \\ - & \mathbf{u}_2^T & - \\ & \vdots & \\ - & \mathbf{u}_n^T & - \end{bmatrix} \implies c_i = \langle \mathbf{u}_i, \mathbf{b} \rangle = \mathbf{u}_i^T \mathbf{b}. \quad (1.47)$$

Ogni elemento dell'output è il prodotto scalare euclideo tra la riga corrispondente di A e il vettore $\mathbf{b}$.

Visione 3: Prospettiva per Colonne (Combinazione Lineare delle Colonne). Rappresentando A tramite le sue m colonne verticali $\mathbf{w}_1, \dots, \mathbf{w}_m \in \mathbb{R}^n$:

$$A = \begin{bmatrix} | & | & & | \\ \mathbf{w}_1 & \mathbf{w}_2 & \dots & \mathbf{w}_m \\ | & | & & | \end{bmatrix} \implies \mathbf{c} = A\mathbf{b} = \sum_{j=1}^m b_j \mathbf{w}_j. \quad (1.48)$$

Il vettore risultante $\mathbf{c}$ è la **combinazione lineare delle colonne di A** pesata dai coefficienti scalari forniti dal vettore $\mathbf{b}$:

$$\mathbf{c} = 1 \begin{bmatrix} 2 \\ 3 \end{bmatrix} + 2 \begin{bmatrix} 0 \\ -1 \end{bmatrix} + 3 \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 2 + 0 + 3 \\ 3 - 2 + 0 \end{bmatrix} = \begin{bmatrix} 5 \\ 1 \end{bmatrix}. \quad (1.49)$$

Rilevanza della Visione per Colonne

La prospettiva per colonne è cruciale in tutto il corso: essa mostra immediatamente che il sottospazio di tutti i possibili vettori generabili da $A\mathbf{b}$ al variare di $\mathbf{b}$ è lo **spazio delle colonne** $\text{range}(A) = \text{span}(\mathbf{w}_1, \dots, \mathbf{w}_m)$. Risolvere un sistema $A\mathbf{x} = \mathbf{b}$ equivale a ricercare i pesi $\mathbf{x}$ con cui combinare le colonne di A per ricostruire $\mathbf{b}$.

1.8 Matrici come Trasformazioni Lineari nel Piano

Una matrice quadrata $A \in \mathbb{R}^{2 \times 2}$ agisce sui vettori del piano euclideo definendo una trasformazione lineare $T_A : \mathbb{R}^2 \rightarrow \mathbb{R}^2$, con $T_A(\mathbf{v}) = A\mathbf{v}$. L'effetto geometrico complessivo di A è interamente governato dalle immagini dei vettori della base canonica:

$$A\mathbf{e}_1 = \text{prima colonna di } A, \quad A\mathbf{e}_2 = \text{seconda colonna di } A. \quad (1.50)$$

1.8.1 Esempi Geometrici Fondamentali

1. Rotazione Oraria di 90° . Si consideri la matrice:

$$A_{\text{rot}} = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix}. \quad (1.51)$$

L'azione sui vettori canonici vale:

$$A_{\text{rot}}\mathbf{e}_1 = \begin{bmatrix} 0 \\ -1 \end{bmatrix} = -\mathbf{e}_2, \quad A_{\text{rot}}\mathbf{e}_2 = \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \mathbf{e}_1. \quad (1.52)$$

Il vettore orizzontale $\mathbf{e}_1$ viene ruotato verso il basso ($-\mathbf{e}_2$), mentre il vettore verticale $\mathbf{e}_2$ viene ruotato verso destra ($\mathbf{e}_1$). Applicato a un vettore generico $\mathbf{v} = [v_1, v_2]^T$, restituisce $[v_2, -v_1]^T$, ruotando l'intero piano di 90° in senso orario.

2. Scorrimento Orizzontale (*Shear Mapping*). Si consideri la matrice triangolare:

$$A_{\text{shear}} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}. \quad (1.53)$$

L'azione sulla base canonica restituisce:

$$A_{\text{shear}}\mathbf{e}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \mathbf{e}_1, \quad A_{\text{shear}}\mathbf{e}_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \mathbf{e}_1 + \mathbf{e}_2. \quad (1.54)$$

L'asse delle ascisse rimane immobile, mentre la coordinata orizzontale di ogni punto subisce una traslazione proporzionale alla sua ordinata ($x \mapsto x + y$, $y \mapsto y$). Tale trasformazione muta i quadrati in parallelogrammi preservandone l'area ($\det A_{\text{shear}} = 1$).

3. Omotetia Uniforme e Riflessione.

- $A = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} = 2I$: scala uniformemente ogni vettore dello spazio di un fattore 2 ($A\mathbf{v} = 2\mathbf{v}$), conservando direzioni e angoli.
- $A = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$: scambia tra loro le coordinate ($x \mapsto y, y \mapsto x$), realizzando la riflessione speculare rispetto alla retta bisettrice $y = x$.

1.9 Introduzione alla Complessità Computazionale e Flops

Nell'algebra lineare numerica non basta verificare teoricamente la risolubilità di un'equazione: è indispensabile quantificare il numero di operazioni elementari in virgola mobile (**flops**, *floating-point operations* — addizioni, sottrazioni, moltiplicazioni, divisioni) richieste per eseguirla al calcolatore.

1.9.1 Conteggio delle Operazioni per il Prodotto Scalare

Siano $\mathbf{v}, \mathbf{w} \in \mathbb{R}^n$. Il calcolo di $\langle \mathbf{v}, \mathbf{w} \rangle = \sum_{i=1}^n v_i w_i$ richiede:

1. n moltiplicazioni elementari ($v_1 w_1, v_2 w_2, \dots, v_n w_n$);
2. $n - 1$ addizioni per accumulare i prodotti parziali.

Il costo computazionale esatto ammonta a:

$$\text{Flops}(n) = n + (n - 1) = 2n - 1 \implies \mathcal{O}(n). \quad (1.55)$$

1.9.2 Modello di Scaling Temporale Lineare

Si assuma che il tempo di esecuzione su un'architettura hardware sia proporzionale al numero di operazioni. Se il calcolo del prodotto scalare per vettori di dimensione $n = 10^7$ (10 milioni di elementi) impiega 3 secondi, per vettori di dimensione triplicata $n' = 3 \cdot 10^7$:

$$\text{Tempo stimato} = 3 \times (\text{tempo base}) = 3 \times 3 \text{ s} = 9 \text{ s}. \quad (1.56)$$

La complessità lineare $\mathcal{O}(n)$ assicura che il tempo di computazione scali proporzionalmente al fattore di ingrandimento dei dati.

Nota 1.9.1 (Quesito Aperto: Il Costo del Prodotto Matrice-Vettore). Data una matrice quadrata $A \in \mathbb{R}^{n \times n}$ e un vettore $\mathbf{b} \in \mathbb{R}^n$:

- Il calcolo di $A\mathbf{b}$ equivale a calcolare n prodotti scalari indipendenti, ciascuno di costo $2n - 1$:

$$\text{Flops}_{\text{mat-vec}}(n) = n(2n - 1) = 2n^2 - n \implies \mathcal{O}(n^2). \quad (1.57)$$

- Se per $n = 1\,000$ l'operazione impiega 3 secondi, raddoppiando la dimensione a $n' = 2\,000$, la crescita quadratica $\mathcal{O}(n^2)$ comporta un incremento per un fattore $(2)^2 = 4$, portando il tempo atteso a circa $4 \times 3\text{ s} = 12\text{ s}$.

1.10 Quadro Sinottico dei Concetti Fondamentali

Oggetto / Concetto	Definizione Matematica	Proprietà Chiave / Complessità
Norma ℓ_1	$\ \mathbf{v}\ _1 = \sum_{i=1}^n v_i $	Sfera unitaria a rombo (45°), induce sparsità nei modelli.
Norma ℓ_2	$\ \mathbf{v}\ _2 = \sqrt{\sum_{i=1}^n v_i^2} = \sqrt{\mathbf{v}^T \mathbf{v}}$	Lunghezza euclidea invariante per rotazioni, liscia e differenziabile.
Norma ℓ_∞	$\ \mathbf{v}\ _\infty = \max_{1 \leq i \leq n} v_i $	Sfera unitaria a quadrato parallelo agli assi cartesiani.
Prodotto Scalare	$\langle \mathbf{v}, \mathbf{w} \rangle = \mathbf{v}^T \mathbf{w} = \sum_{i=1}^n v_i w_i$	Operazioni aritmetiche: $2n - 1 \implies \mathcal{O}(n)$.
Base	Insieme lin. indep. con $\text{span} = V$	Rappresentazione unica delle coordinate di ogni vettore.
Prodotto $A\mathbf{b}$ (Righe)	$c_i = \mathbf{u}_i^T \mathbf{b}$	n prodotti scalari tra le righe di A e il vettore $\mathbf{b}$.
Prodotto $A\mathbf{b}$ (Colonne)	$\mathbf{c} = \sum_{j=1}^m b_j \mathbf{w}_j$	Combinazione lineare delle colonne pesata da $\mathbf{b}$; descrive $\text{range}(A)$.
Rotazione 90° Oraria	$A = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix}$	Mappa $\mathbf{e}_1 \mapsto -\mathbf{e}_2$ e $\mathbf{e}_2 \mapsto \mathbf{e}_1$.
Riflessione su $y = x$	$A = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$	Mappa $\mathbf{e}_1 \mapsto \mathbf{e}_2$ e $\mathbf{e}_2 \mapsto \mathbf{e}_1$, invertendo le coordinate.

Tabella 1.1: Sintesi dei concetti algebrici, geometrici e computazionali trattati nel Capitolo 1.

Capitolo 2

Prodotto tra Matrici, Complessità Computazionale e Matrici Ortogonali

Il presente capitolo approfondisce le operazioni algebriche di livello superiore tra matrici, analizzando la moltiplicazione matrice-matrice, il relativo profilo di complessità computazionale e le proprietà strutturali degli spazi fondamentali associati a una matrice. Vengono quindi introdotte l'ortogonalità vettoriale e le matrici ortogonali, componenti basilari per la progettazione di algoritmi stabili e per le fattorizzazioni matriciali dell'algebra lineare numerica [1].

2.1 Moltiplicazione Matrice-Matrice

2.1.1 Condizione di Compatibilità Dimensionale

Siano date due matrici a entrate reali A e B . L'operazione di moltiplicazione matriciale $C = AB$ è lecita ed algebricamente definita **se e solo se** il numero di colonne del primo fattore A coincide con il numero di righe del secondo fattore B .

Definizione 2.1.1 (Compatibilità del Prodotto Matriciale). Dati $n, m, p \in \mathbb{N}$, siano $A \in \mathbb{R}^{n \times m}$ e $B \in \mathbb{R}^{m \times p}$. Il prodotto matrice-matrice restituisce la matrice $C = AB \in \mathbb{R}^{n \times p}$ la cui dimensione è data dal numero di righe del primo fattore per il numero di colonne del secondo:

$$A \in \mathbb{R}^{n \times m}, \quad B \in \mathbb{R}^{m \times p} \implies C = AB \in \mathbb{R}^{n \times p}. \quad (2.1)$$

Se il numero di colonne di A differisce dal numero di righe di B , il prodotto non è definito. In generale, anche per matrici quadrate ($n = m = p$), la

moltiplicazione non gode della proprietà commutativa:

$$AB \neq BA \quad (\text{in generale}). \quad (2.2)$$




Figura 2.1: Compatibilità dimensionale nel prodotto matriciale: l'elemento generico C_{ij} nasce dall'intersezione tra la riga $\mathbf{u}_i^T$ di A e la colonna $\mathbf{w}_j$ di B .

2.1.2 Definizione per Componenti

Ciascun elemento C_{ij} posizionato all'intersezione tra la riga i ($1 \leq i \leq n$) e la colonna j ($1 \leq j \leq p$) della matrice risultante è generato dal prodotto scalare euclideo tra la riga i -esima di A e la colonna j -esima di B :

Definizione 2.1.2 (Formula per Componenti del Prodotto). Dati $A \in \mathbb{R}^{n \times m}$ e $B \in \mathbb{R}^{m \times p}$, la voce (i, j) del prodotto $C = AB$ è pari a:

$$C_{ij} = \sum_{k=1}^m A_{ik} B_{kj} = A_{i1} B_{1j} + A_{i2} B_{2j} + \cdots + A_{im} B_{mj}. \quad (2.3)$$

In forma vettoriale, indicando con $\mathbf{u}_i^T$ la i -esima riga di A e con $\mathbf{w}_j$ la j -esima colonna di B :

$$C_{ij} = \langle \mathbf{u}_i, \mathbf{w}_j \rangle = \mathbf{u}_i^T \mathbf{w}_j. \quad (2.4)$$

2.1.3 Esempio Numerico Passo-Passo

Esempio 2.1.1 (Calcolo Dettagliato del Prodotto Rettangolare). Siano assegnate le matrici:

$$A = \begin{bmatrix} 1 & 2 \\ 0 & 3 \end{bmatrix} \in \mathbb{R}^{2 \times 2}, \quad B = \begin{bmatrix} 0 & 1 & -1 \\ 1 & 0 & 2 \end{bmatrix} \in \mathbb{R}^{2 \times 3}. \quad (2.5)$$

Poiché le colonne di A ($m = 2$) eguagliano le righe di B ($m = 2$), la matrice prodotto $C = AB$ è ben definita ed ha dimensione 2×3 . Calcoliamo analiticamente le sue sei componenti:

Prima riga di C (prodotto della riga 1 di A con le colonne di B):

$$C_{11} = A_{11}B_{11} + A_{12}B_{21} = 1 \cdot 0 + 2 \cdot 1 = 0 + 2 = 2, \quad (2.6)$$

$$C_{12} = A_{11}B_{12} + A_{12}B_{22} = 1 \cdot 1 + 2 \cdot 0 = 1 + 0 = 1, \quad (2.7)$$

$$C_{13} = A_{11}B_{13} + A_{12}B_{23} = 1 \cdot (-1) + 2 \cdot 2 = -1 + 4 = 3. \quad (2.8)$$

Seconda riga di C (prodotto della riga 2 di A con le colonne di B):

$$C_{21} = A_{21}B_{11} + A_{22}B_{21} = 0 \cdot 0 + 3 \cdot 1 = 0 + 3 = 3, \quad (2.9)$$

$$C_{22} = A_{21}B_{12} + A_{22}B_{22} = 0 \cdot 1 + 3 \cdot 0 = 0 + 0 = 0, \quad (2.10)$$

$$C_{23} = A_{21}B_{13} + A_{22}B_{23} = 0 \cdot (-1) + 3 \cdot 2 = 0 + 6 = 6. \quad (2.11)$$

Ricomponendo i valori calcolati nella tabella matriciale:

$$C = AB = \begin{bmatrix} 2 & 1 & 3 \\ 3 & 0 & 6 \end{bmatrix} \in \mathbb{R}^{2 \times 3}. \quad (2.12)$$

2.2 Complessità Computazionale e Legge di Scaling

2.2.1 Conteggio Rigoroso dei FLOPs

La valutazione del tempo di esecuzione di un algoritmo numerico richiede la stima analitica delle operazioni in virgola mobile (*FLOPs*, floating-point operations).

Proprietà 2.2.1 (Costo Computazionale del Prodotto Matrice-Matrice).

1. **Costo di una singola entrata:** La valutazione di $C_{ij} = \sum_{k=1}^m A_{ik}B_{kj}$ richiede m moltiplicazioni tra scalari ed $m - 1$ addizioni, per un totale di:

$$FLOPs \text{ per entrata} = m + (m - 1) = 2m - 1 \implies \mathcal{O}(m). \quad (2.13)$$

2. **Costo del caso rettangolare generale** ($A \in \mathbb{R}^{n \times m}, B \in \mathbb{R}^{m \times p}$): Dovendo calcolare $n \cdot p$ elementi indipendenti:

$$FLOPs \text{ Totali} = n \cdot p \cdot (2m - 1) = 2nmp - np \implies \mathcal{O}(nmp). \quad (2.14)$$

3. **Costo del caso quadrato** ($n = m = p$): Se entrambe le matrici appartengono a $\mathbb{R}^{n \times n}$, la matrice C contiene n^2 elementi:

$$FLOPs \text{ Totali}(n) = n^2 \cdot (2n - 1) = 2n^3 - n^2 \implies \mathcal{O}(n^3). \quad (2.15)$$

Il termine dominante $2n^3$ impone una crescita cubica al crescere della taglia n .

2.2.2 Legge di Scalabilità Temporale Cubica

Sia $T(n) \approx \gamma n^3$ il tempo di calcolo su un'architettura hardware fissata, dove la costante $\gamma > 0$ racchiude l'efficienza della cache, la frequenza di clock della CPU e il fattore di conversione del compilatore.

Esempio 2.2.1 (Previsione dei Tempi con Raddoppio della Dimensione). Supponiamo che il prodotto tra due matrici quadrate dense di dimensione $n = 1000$ richieda 3 secondi di CPU:

$$T(1000) \approx \gamma \cdot (1000)^3 = 3 \text{ s.} \quad (2.16)$$

Se raddoppiamo la dimensione portandola a $n' = 2000$, la legge cubica stabilisce:

$$T(2000) \approx \gamma \cdot (2000)^3 = \gamma \cdot (2 \cdot 1000)^3 = 8 \cdot (\gamma \cdot 1000^3) = 8 \cdot T(1000). \quad (2.17)$$

Il tempo di esecuzione scala di un fattore 8:

$$T(2000) \approx 8 \cdot 3 \text{ s} = 24 \text{ secondi.} \quad (2.18)$$

2.2.3 Quadro Comparativo delle Operazioni Fondamentali

La tabella 2.1 illustra come le tre operazioni cardine dell'algebra lineare numerica scalino in risposta a un incremento di un fattore 10 della dimensione lineare n (passaggio da $n = 10^3$ a $n = 10^4$).

Operazione	Dati Coinvolti	Formula FLOPs	Costo	Fattore ($10\times$)
Prodotto Scalare	$\mathbf{v}, \mathbf{w} \in \mathbb{R}^n$	$2n - 1$	$\mathcal{O}(n)$	$10^1 = 10$
Matrice-Vettore	$A \in \mathbb{R}^{n \times n}, \mathbf{b} \in \mathbb{R}^n$	$2n^2 - n$	$\mathcal{O}(n^2)$	$10^2 = 100$
Matrice-Matrice	$A, B \in \mathbb{R}^{n \times n}$	$2n^3 - n^2$	$\mathcal{O}(n^3)$	$10^3 = 1000$

Tabella 2.1: Confronto di complessità computazionale e fattore di scaling per una dilatazione di ordine di grandezza dei dati.

Se un'operazione matrice-matrice con $n = 1000$ impiega 1 secondo, la medesima operazione con $n = 10\,000$ richiederà 1000 secondi (≈ 16.6 minuti).

2.3 Proprietà Fondamentali: Rango, Spazi Fondamentali e Invertibilità

2.3.1 Definizioni degli Spazi Associati a una Matrice

Sia $A \in \mathbb{R}^{n \times m}$ interpretata come operatore lineare $T_A : \mathbb{R}^m \rightarrow \mathbb{R}^n$ tale che $T_A(\mathbf{x}) = A\mathbf{x}$.

Definizione 2.3.1 (Rango di una Matrice). Il **rango** di A , denotato con $\text{rank}(A)$, è la dimensione dello spazio generato dalle sue colonne. Vale il teorema fondamentale per cui il rango per colonne coincide sempre con il rango per righe:

$$\text{rank}(A) = \dim(\text{col}(A)) = \dim(\text{row}(A)) \leq \min(n, m). \quad (2.19)$$

Se $\text{rank}(A) = \min(n, m)$, la matrice si dice a **rango pieno** (*full rank*).

Definizione 2.3.2 (Spazio Nullo o Kernel). Il **nucleo** (*kernel* o *nullspace*) di A è il sottospazio di $\mathbb{R}^m$ costituito da tutti i vettori che vengono mappati nel vettore nullo di $\mathbb{R}^n$:

$$\ker(A) = \{\mathbf{x} \in \mathbb{R}^m : A\mathbf{x} = \mathbf{0}_{\mathbb{R}^n}\} \subseteq \mathbb{R}^m. \quad (2.20)$$

Definizione 2.3.3 (Immagine o Range). L'**immagine** (*image* o *range*) di A è il sottospazio di $\mathbb{R}^n$ generato da tutte le combinazioni lineari delle colonne di A :

$$\text{Im}(A) = \text{span}(\text{colonne di } A) = \{A\mathbf{x} : \mathbf{x} \in \mathbb{R}^m\} \subseteq \mathbb{R}^n. \quad (2.21)$$

Vale $\dim(\text{Im}(A)) = \text{rank}(A)$.

Teorema 2.3.1 (Teorema del Rango-Nullità). *Per ogni matrice $A \in \mathbb{R}^{n \times m}$ avente m colonne, la somma della dimensione dell'immagine e della dimensione del nucleo eguaglia la dimensione dello spazio di partenza:*

$$\dim(\text{Im}(A)) + \dim(\ker(A)) = m. \quad (2.22)$$




Figura 2.2: Rappresentazione geometrica dei sottospazi fondamentali e del Teorema del Rango-Nullità: $\dim(\ker(A)) + \dim(\text{Im}(A)) = m$. La restrizione di A al sottospazio ortogonale $(\ker(A))^\perp$ mappa biunivocamente su $\text{Im}(A)$.

2.3.2 Invertibilità di Matrici Quadrate

Nel contesto di matrici quadrate $A \in \mathbb{R}^{n \times n}$, le nozioni di rango, nucleo e invertibilità si fondono in un unico teorema di equivalenza.

Definizione 2.3.4 (Matrice Invertibile o Non Singolare). Una matrice $A \in \mathbb{R}^{n \times n}$ si dice **invertibile** se esiste un'unica matrice $A^{-1} \in \mathbb{R}^{n \times n}$ tale che:

$$AA^{-1} = I_n \quad \text{e} \quad A^{-1}A = I_n. \quad (2.23)$$

Teorema 2.3.2 (Caratterizzazioni Equivalenti di Invertibilità). Sia $A \in \mathbb{R}^{n \times n}$. Le seguenti affermazioni sono equivalenti:

1. A è invertibile.
2. $\text{rank}(A) = n$ (A ha rango massimo).
3. $\det(A) \neq 0$.
4. $\ker(A) = \{\mathbf{0}_{\mathbb{R}^n}\}$ (il nucleo contiene esclusivamente il vettore nullo).
5. Le colonne di A formano una base di $\mathbb{R}^n$.
6. Il sistema lineare $A\mathbf{x} = \mathbf{b}$ ammette una e una sola soluzione $\mathbf{x} = A^{-1}\mathbf{b}$ per ogni $\mathbf{b} \in \mathbb{R}^n$.

2.3.3 Esempio Guidato: Calcolo di Rango, Nucleo e Immagine

Esempio 2.3.1 (Analisi Completa di una Matrice 3×3 Singolare). Consideriamo la matrice:

$$A = \begin{bmatrix} 1 & 2 & 0 \\ 2 & 4 & 0 \\ 0 & 0 & 1 \end{bmatrix} \in \mathbb{R}^{3 \times 3}. \quad (2.24)$$

1. Calcolo del Rango via Eliminazione Gaussiana: Applichiamo l'operazione elementare per righe $R_2 \leftarrow R_2 - 2R_1$:

$$\begin{bmatrix} 1 & 2 & 0 \\ 2 & 4 & 0 \\ 0 & 0 & 1 \end{bmatrix} \xrightarrow{R_2 \rightarrow R_2 - 2R_1} \begin{bmatrix} 1 & 2 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix} \xrightarrow{R_2 \leftrightarrow R_3} \begin{bmatrix} 1 & 2 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 0 \end{bmatrix}. \quad (2.25)$$

La matrice ridotta a gradini presenta 2 pivot non nulli. Di conseguenza:

$$\text{rank}(A) = 2. \quad (2.26)$$

Poiché $\text{rank}(A) = 2 < 3$, la matrice A **non è invertibile** ($\det(A) = 0$).

2. Determinazione dell'Immagine $\text{Im}(A)$: Osservando le colonne di A :

$$\mathbf{a}_1 = \begin{bmatrix} 1 \\ 2 \\ 0 \end{bmatrix}, \quad \mathbf{a}_2 = \begin{bmatrix} 2 \\ 4 \\ 0 \end{bmatrix} = 2\mathbf{a}_1, \quad \mathbf{a}_3 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}. \quad (2.27)$$

La seconda colonna è collineare alla prima ed è dunque ridondante. Le colonne $\mathbf{a}_1$ e $\mathbf{a}_3$ sono linearmente indipendenti e costituiscono una base dell'immagine:

$$\text{Im}(A) = \text{span} \left\{ \begin{bmatrix} 1 \\ 2 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} \right\}, \quad \dim(\text{Im}(A)) = 2. \quad (2.28)$$

3. Determinazione del Nucleo $\ker(A)$: Risolviamo il sistema omogeneo $A\mathbf{x} = \mathbf{0}_{\mathbb{R}^3}$ per $\mathbf{x} = [x_1, x_2, x_3]^T$:

$$\begin{bmatrix} 1 & 2 & 0 \\ 2 & 4 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} \implies \begin{cases} x_1 + 2x_2 = 0 \\ x_3 = 0 \end{cases} \implies \begin{cases} x_1 = -2x_2 \\ x_3 = 0 \end{cases}. \quad (2.29)$$

Assegnando alla variabile libera x_2 il parametro $t \in \mathbb{R}$:

$$\mathbf{x} = \begin{bmatrix} -2t \\ t \\ 0 \end{bmatrix} = t \begin{bmatrix} -2 \\ 1 \\ 0 \end{bmatrix} \implies \ker(A) = \text{span} \left\{ \begin{bmatrix} -2 \\ 1 \\ 0 \end{bmatrix} \right\}. \quad (2.30)$$

La dimensione del nucleo è $\dim(\ker(A)) = 1$. Verifichiamo il Teorema del Rango-Nullità:

$$\dim(\text{Im}(A)) + \dim(\ker(A)) = 2 + 1 = 3 = m. \quad (2.31)$$

2.4 Ortogonalità e Ortonormalità Vettoriale

2.4.1 Definizioni Fondamentali

Definizione 2.4.1 (Vettori Ortogonali). Due vettori $\mathbf{v}, \mathbf{w} \in \mathbb{R}^n$ si dicono **ortogonali** ($\mathbf{v} \perp \mathbf{w}$) se e solo se il loro prodotto scalare standard è nullo:

$$\langle \mathbf{v}, \mathbf{w} \rangle = \mathbf{v}^T \mathbf{w} = 0. \quad (2.32)$$

Definizione 2.4.2 (Insieme Ortogonale ed Ortonormale). Un insieme di vettori $\{\mathbf{v}_1, \dots, \mathbf{v}_k\} \subset \mathbb{R}^n$ è detto:

1. **Ortogonale** se i vettori sono a due a due ortogonali:

$$\langle \mathbf{v}_i, \mathbf{v}_j \rangle = 0 \quad \forall i \neq j. \quad (2.33)$$

2. **Ortonormale** se è ortogonale e ciascun vettore possiede norma euclidea unitaria:

$$\langle \mathbf{v}_i, \mathbf{v}_j \rangle = \delta_{ij} = \begin{cases} 1 & \text{se } i = j, \\ 0 & \text{se } i \neq j, \end{cases} \quad (2.34)$$

dove δ_{ij} denota la delta di Kronecker.

2.4.2 Esercizi Costruttivi di Normalizzazione in $\mathbb{R}^2$

Esempio 2.4.1 (Costruzione e Normalizzazione di una Coppia Ortogonale).

1. **Ricerca di un vettore ortogonale:** Sia assegnato il vettore $\mathbf{v}_1 = [2, 1]^T \in \mathbb{R}^2$. Cerchiamo un vettore non nullo $\mathbf{v}_2 = [x, y]^T$ tale che $\langle \mathbf{v}_1, \mathbf{v}_2 \rangle = 0$:

$$2x + y = 0 \implies y = -2x. \quad (2.35)$$

Scegliendo $x = 1$, otteniamo $y = -2$, da cui la coppia ortogonale:

$$\mathbf{v}_1 = \begin{bmatrix} 2 \\ 1 \end{bmatrix}, \quad \mathbf{v}_2 = \begin{bmatrix} 1 \\ -2 \end{bmatrix}, \quad \langle \mathbf{v}_1, \mathbf{v}_2 \rangle = 2(1) + 1(-2) = 0. \quad (2.36)$$

2. **Normalizzazione euclidea (Ortonormalizzazione):** Dividiamo ciascun vettore per la rispettiva norma euclidea ℓ_2 :

$$\|\mathbf{v}_1\|_2 = \sqrt{2^2 + 1^2} = \sqrt{5} \implies \mathbf{u}_1 = \frac{\mathbf{v}_1}{\|\mathbf{v}_1\|_2} = \begin{bmatrix} 2/\sqrt{5} \\ 1/\sqrt{5} \end{bmatrix}, \quad (2.37)$$

$$\|\mathbf{v}_2\|_2 = \sqrt{1^2 + (-2)^2} = \sqrt{5} \implies \mathbf{u}_2 = \frac{\mathbf{v}_2}{\|\mathbf{v}_2\|_2} = \begin{bmatrix} 1/\sqrt{5} \\ -2/\sqrt{5} \end{bmatrix}. \quad (2.38)$$

Verifichiamo le proprietà di ortonormalità:

$$\|\mathbf{u}_1\|_2 = 1, \quad \|\mathbf{u}_2\|_2 = 1, \quad (2.39)$$

$$\langle \mathbf{u}_1, \mathbf{u}_2 \rangle = \frac{2}{\sqrt{5}} \frac{1}{\sqrt{5}} + \frac{1}{\sqrt{5}} \left(-\frac{2}{\sqrt{5}} \right) = \frac{2}{5} - \frac{2}{5} = 0. \quad (2.40)$$

L'insieme $\{\mathbf{u}_1, \mathbf{u}_2\}$ costituisce una base ortonormale di $\mathbb{R}^2$.

2.5 Matrici Ortogonali

2.5.1 Definizione e Proprietà della Trasposta

Richiamiamo che per una generica matrice rettangolare $A \in \mathbb{R}^{n \times m}$, la matrice trasposta $A^T \in \mathbb{R}^{m \times n}$ ha elementi $(A^T)_{ij} = A_{ji}$. Per qualsiasi coppia di matrici compatibili, vale l'inversione dell'ordine nella trasposizione:

$$(AB)^T = B^T A^T. \quad (2.41)$$

Definizione 2.5.1 (Matrice Ortogonale). Una matrice quadrata $U \in \mathbb{R}^{n \times n}$ è definita **ortogonale** se e solo se la sua trasposta coincide con la sua inversa:

$$U^T U = U U^T = I_n \iff U^{-1} = U^T. \quad (2.42)$$

2.5.2 Caratterizzazione per Colonne e per Righe

Teorema 2.5.1 (Ortonormalità delle Colonne e delle Righe). *Una matrice quadrata $U \in \mathbb{R}^{n \times n}$ è ortogonale se e solo se le sue colonne formano una base ortonormale di $\mathbb{R}^n$. Equivalentemente, U è ortogonale se e solo se le sue righe formano una base ortonormale di $\mathbb{R}^n$.*

Dimostrazione. Partizioniamo U per vettori colonna $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_n \in \mathbb{R}^n$:

$$U = \begin{bmatrix} \mathbf{u}_1 & \mathbf{u}_2 & \dots & \mathbf{u}_n \end{bmatrix}. \quad (2.43)$$

La trasposta U^T si esprime mediante le medesime partizioni come matrice a blocchi per righe:

$$U^T = \begin{bmatrix} \mathbf{u}_1^T \\ \mathbf{u}_2^T \\ \vdots \\ \mathbf{u}_n^T \end{bmatrix}. \quad (2.44)$$

Eseguiamo la moltiplicazione a blocchi $U^T U$:

$$\begin{aligned} U^T U &= \begin{bmatrix} \mathbf{u}_1^T \\ \mathbf{u}_2^T \\ \vdots \\ \mathbf{u}_n^T \end{bmatrix} \begin{bmatrix} \mathbf{u}_1 & \mathbf{u}_2 & \dots & \mathbf{u}_n \end{bmatrix} \\ &= \begin{bmatrix} \mathbf{u}_1^T \mathbf{u}_1 & \mathbf{u}_1^T \mathbf{u}_2 & \dots & \mathbf{u}_1^T \mathbf{u}_n \\ \mathbf{u}_2^T \mathbf{u}_1 & \mathbf{u}_2^T \mathbf{u}_2 & \dots & \mathbf{u}_2^T \mathbf{u}_n \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{u}_n^T \mathbf{u}_1 & \mathbf{u}_n^T \mathbf{u}_2 & \dots & \mathbf{u}_n^T \mathbf{u}_n \end{bmatrix} = [\langle \mathbf{u}_i, \mathbf{u}_j \rangle]_{i,j=1}^n. \end{aligned} \quad (2.45)$$

Affinché il prodotto coincida con la matrice identità I_n , deve risultare:

$$\langle \mathbf{u}_i, \mathbf{u}_j \rangle = \delta_{ij} \quad \forall i, j \in \{1, \dots, n\}. \quad (2.46)$$

Questo dimostra in modo costruttivo che le colonne sono mutuamente ortogonali e a norma euclidea unitaria. Lo stesso argomento applicato a $UU^T = I_n$ prova l'ortonormalità delle righe. $\square$

2.5.3 Esempio Notevole: Rotazione nel Piano

Esempio 2.5.1 (Matrice di Rotazione Piana). Sia $\theta \in \mathbb{R}$. Consideriamo la matrice di rotazione:

$$U = \begin{bmatrix} \cos \theta & \sin \theta \\ -\sin \theta & \cos \theta \end{bmatrix}. \quad (2.47)$$

Verifichiamo la condizione $U^T U = I_2$:

$$\begin{aligned} U^T U &= \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix} \begin{bmatrix} \cos \theta & \sin \theta \\ -\sin \theta & \cos \theta \end{bmatrix} \\ &= \begin{bmatrix} \cos^2 \theta + \sin^2 \theta & \cos \theta \sin \theta - \sin \theta \cos \theta \\ \sin \theta \cos \theta - \cos \theta \sin \theta & \sin^2 \theta + \cos^2 \theta \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = I_2. \end{aligned} \quad (2.48)$$

La matrice U è ortogonale per qualunque valore dell'angolo θ .

2.5.4 Chiusura del Prodotto di Matrici Ortogonali

Proposizione 2.5.1 (Gruppo Ortogonale e Chiusura rispetto al Prodotto).
Se $U, V \in \mathbb{R}^{n \times n}$ sono matrici ortogonali, il loro prodotto $Q = UV$ è anch'esso una matrice ortogonale.

Dimostrazione. Calcoliamo QQ^T sfruttando la regola di inversione della trasposta $(UV)^T = V^T U^T$:

$$QQ^T = (UV)(UV)^T = (UV)(V^T U^T). \quad (2.49)$$

Per la proprietà associativa del prodotto matriciale:

$$QQ^T = U(VV^T)U^T. \quad (2.50)$$

Poiché V è ortogonale, $VV^T = I_n$:

$$QQ^T = UI_n U^T = UU^T = I_n. \quad (2.51)$$

In modo del tutto analogo si verifica che $Q^T Q = V^T (U^T U) V = V^T I_n V = I_n$.
Pertanto $Q = UV$ è ortogonale. $\square$

2.6 I Quattro Quesiti Notabili sulle Matrici Ortogonali

2.6.1 Quesito 1: Limite Superiore sulle Singole Entrate

Esempio 2.6.1 (Gli Elementi di una Matrice Ortogonale Possono Superare 1?). **Domanda:** È possibile che una matrice ortogonale $U \in \mathbb{R}^{n \times n}$ contenga un elemento $U_{ij} > 1$?

Risposta: NO.

Dimostrazione: Sia $\mathbf{u}_j$ la j -esima colonna di U . Poiché U è ortogonale, $\mathbf{u}_j$ ha norma euclidea unitaria:

$$\|\mathbf{u}_j\|_2^2 = \sum_{k=1}^n U_{kj}^2 = 1. \quad (2.52)$$

Poiché ogni quadrato $U_{kj}^2 \geq 0$, ogni singolo termine della sommatoria è limitato superiormente dalla somma complessiva:

$$U_{ij}^2 \leq \sum_{k=1}^n U_{kj}^2 = 1 \implies |U_{ij}| \leq 1 \implies -1 \leq U_{ij} \leq 1. \quad (2.53)$$

Nessuna componente di una matrice ortogonale può superare 1 in valore assoluto.

2.6.2 Quesito 2: Matrici Diagonali Ortogonali

Esempio 2.6.2 (Caratterizzazione delle Matrici Diagonali Ortogonali). **Domanda:** A quali condizioni una matrice diagonale $D \in \mathbb{R}^{n \times n}$ risulta ortogonale?

Risoluzione: Sia $D = \text{diag}(d_1, d_2, \dots, d_n)$. Essendo diagonale, essa coincide con la propria trasposta: $D^T = D$. Calcoliamo $D^T D$:

$$D^T D = D^2 = \text{diag}(d_1^2, d_2^2, \dots, d_n^2). \quad (2.54)$$

Affinché $D^T D = I_n$, occorre che:

$$d_i^2 = 1 \iff d_i = \pm 1 \quad \forall i = 1, \dots, n. \quad (2.55)$$

Conclusione: Una matrice diagonale è ortogonale se e solo se tutte le entrate diagonali sono pari a $+1$ o -1 . Esistono esattamente 2^n matrici diagonali ortogonali distinte in $\mathbb{R}^{n \times n}$.

2.6.3 Quesito 3: Matrici Triangolari Superiori Ortogonali

Esempio 2.6.3 (Caratterizzazione delle Matrici Triangolari Ortogonali). **Domanda:** Quando una matrice triangolare superiore $R \in \mathbb{R}^{n \times n}$ è ortogonale?

Dimostrazione per induzione sulle colonne: Sia R triangolare superiore ($R_{ij} = 0$ per ogni $i > j$):

$$R = \begin{bmatrix} r_{11} & r_{12} & r_{13} & \cdots & r_{1n} \\ 0 & r_{22} & r_{23} & \cdots & r_{2n} \\ 0 & 0 & r_{33} & \cdots & r_{3n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & r_{nn} \end{bmatrix}. \quad (2.56)$$

Poiché R è ortogonale, le sue colonne $\mathbf{r}_1, \dots, \mathbf{r}_n$ devono formare una base ortonormale:

1. **Prima colonna** $\mathbf{r}_1 = [r_{11}, 0, \dots, 0]^T$: La norma unitaria impone $r_{11}^2 = 1 \implies r_{11} = \pm 1$.
2. **Seconda colonna** $\mathbf{r}_2 = [r_{12}, r_{22}, 0, \dots, 0]^T$: L'ortogonalità rispetto a $\mathbf{r}_1$ impone:

$$\langle \mathbf{r}_1, \mathbf{r}_2 \rangle = r_{11} r_{12} = 0 \implies r_{12} = 0 \quad (\text{poiché } r_{11} = \pm 1 \neq 0). \quad (2.57)$$

Dalla norma unitaria: $\|\mathbf{r}_2\|_2^2 = r_{12}^2 + r_{22}^2 = 0 + r_{22}^2 = 1 \implies r_{22} = \pm 1$.

3. **Terza colonna** $\mathbf{r}_3 = [r_{13}, r_{23}, r_{33}, 0, \dots, 0]^T$: L'ortogonalità verso $\mathbf{r}_1$ e $\mathbf{r}_2$ impone $r_{11}r_{13} = 0 \implies r_{13} = 0$ e $r_{22}r_{23} = 0 \implies r_{23} = 0$. Segue $r_{33} = \pm 1$.
4. **Passo induttivo generale**: Per ogni colonna j , tutti gli elementi fuori diagonale si annullano ($r_{ij} = 0$ per ogni $i < j$), mentre gli elementi diagonali valgono $r_{jj} = \pm 1$.

Conclusione: Una matrice triangolare superiore è ortogonale se e solo se è diagonale con entrate ± 1 .

2.6.4 Quesito 4: Isometria Euclidea e Preservazione delle Norme

Teorema 2.6.1 (Proprietà di Isometria delle Matrici Ortogonali). *Le matrici ortogonali preservano rigidamente la norma euclidea e il prodotto scalare di qualsiasi vettore dello spazio:*

$$\forall U \in \mathbb{R}^{n \times n} \text{ ortogonale}, \quad \forall \mathbf{x} \in \mathbb{R}^n \implies \|U\mathbf{x}\|_2 = \|\mathbf{x}\|_2. \quad (2.58)$$

Inoltre, preservano i prodotti scalari tra coppie di vettori generici:

$$\langle U\mathbf{x}, U\mathbf{y} \rangle = \langle \mathbf{x}, \mathbf{y} \rangle \quad \forall \mathbf{x}, \mathbf{y} \in \mathbb{R}^n. \quad (2.59)$$

Dimostrazione. Ricordiamo che per ogni vettore $\mathbf{v}$, $\|\mathbf{v}\|_2^2 = \mathbf{v}^T \mathbf{v}$. Ponendo $\mathbf{v} = U\mathbf{x}$:

$$\|U\mathbf{x}\|_2^2 = (U\mathbf{x})^T (U\mathbf{x}). \quad (2.60)$$

Applicando la proprietà di trasposizione del prodotto $(U\mathbf{x})^T = \mathbf{x}^T U^T$:

$$\|U\mathbf{x}\|_2^2 = \mathbf{x}^T (U^T U) \mathbf{x}. \quad (2.61)$$

Essendo U ortogonale, $U^T U = I_n$:

$$\|U\mathbf{x}\|_2^2 = \mathbf{x}^T I_n \mathbf{x} = \mathbf{x}^T \mathbf{x} = \|\mathbf{x}\|_2^2. \quad (2.62)$$

Estraendo la radice quadrata aritmetica, si ottiene $\|U\mathbf{x}\|_2 = \|\mathbf{x}\|_2$. Analogamente:

$$\langle U\mathbf{x}, U\mathbf{y} \rangle = (U\mathbf{x})^T (U\mathbf{y}) = \mathbf{x}^T (U^T U) \mathbf{y} = \mathbf{x}^T I_n \mathbf{y} = \mathbf{x}^T \mathbf{y} = \langle \mathbf{x}, \mathbf{y} \rangle. \quad (2.63)$$

□




Figura 2.3: Isometria euclidea di una trasformazione ortogonale U : conservazione della norma e rotazione pura.

Rilevanza Numerica Fondamentale dell'Isometria

L'uguaglianza $\|U\mathbf{x}\|_2 = \|\mathbf{x}\|_2$ rappresenta il pilastro teorico dell'analisi di stabilità numerica nell'algebra lineare. Poiché le matrici ortogonali non amplificano la norma di alcun vettore, l'applicazione di matrici ortogonali a un vettore affetto da errori di troncamento o rumore:

$$\|U(\mathbf{x} + \mathbf{e}) - U\mathbf{x}\|_2 = \|U\mathbf{e}\|_2 = \|\mathbf{e}\|_2 \quad (2.64)$$

preserva esattamente l'entità dell'errore senza ingigantirlo. Per questa ragione, algoritmi fondati su trasformazioni ortogonali (es. Householder, rotazioni di Givens e decomposizione QR) offrono eccellenti garanzie di stabilità numerica all'indietro (*backward stability*).

2.7 Formulario di Sintesi del Capitolo

La tabella 2.2 compendia i risultati analitici, le formule e le proprietà studiate nel presente capitolo.

Proprietà / Oggetto	Formulazione Matematica	Caratteristica Chiave
Prodotto Matrice-Matrice	$C_{ij} = \sum_{k=1}^m A_{ik}B_{kj}$	Richiede $A \in \mathbb{R}^{n \times m}, B \in \mathbb{R}^{m \times p}$
Costo Prodotto Quadrato	$2n^3 - n^2 \text{ FLOPs} \implies \mathcal{O}(n^3)$	Legge cubica: $T(2n) \approx 8T(n)$
Teorema Rango-Nullità	$\dim(\text{Im}(A)) + \dim(\ker(A)) = m$	m è il numero di colonne di A
Vettori Ortonormali	$\langle \mathbf{u}_i, \mathbf{u}_j \rangle = \delta_{ij}$	Ortogonalità con $\ \mathbf{u}_i\ _2 = 1$
Matrice Ortogonale	$U^T U = U U^T = I_n$	Equivalente a $U^{-1} = U^T$
Righe e Colonne di U	Formano basi ortonormali di $\mathbb{R}^n$	Deriva dal calcolo $U^T U = I_n$
Entrate di U Ortogonale	$-1 \leq U_{ij} \leq 1$	Deriva da $\sum_{i=1}^n U_{ij}^2 = 1$
Matrice Diagonale Ortogonale	$D = \text{diag}(\pm 1, \dots, \pm 1)$	2^n matrici distinte in $\mathbb{R}^{n \times n}$
Triangolare Ortogonale	$R = \text{diag}(\pm 1, \dots, \pm 1)$	Dimostrazione per induzione su colonne
Isometria Euclidea	$\ U\mathbf{x}\ _2 = \ \mathbf{x}\ _2$	Trasformazione rigida: preserva lunghezze
Invarianza del Prodotto Scalare	$\langle U\mathbf{x}, U\mathbf{y} \rangle = \langle \mathbf{x}, \mathbf{y} \rangle$	Preserva angoli tra vettori
Trasposta del Prodotto	$(AB)^T = B^T A^T$	Inverte l'ordine dei fattori

Tabella 2.2: Quadro sinottico delle definizioni, complessità computazionali e proprietà delle matrici ortogonali.

Capitolo 3

Matrici a Colonne Ortonormali, Autovalori, Decomposizione Spettrale e Forme Quadratiche

Il presente capitolo approfondisce le proprietà algebriche e geometriche delle matrici a colonne ortonormali nel caso rettangolare, confrontando sistematicamente i prodotti $V^T V$ e $V V^T$. Vengono quindi introdotti la teoria spettrale, il concetto di autovalore e autovettore, la diagonalizzazione e l'espansione diadica, culminando nel Teorema Spettrale per matrici simmetriche. Infine, si analizzano le forme quadratiche, la disuguaglianza del quoziente di Rayleigh, la classificazione delle matrici simmetriche definite e semidefinite positive (SPD e SPSD), e la genesi naturale delle strutture simmetriche tramite i gramiani $B^T B$ e $B B^T$ [1].

3.1 Richiamo sulle Matrici Ortogonali Quadrate e Isometria

Nel capitolo precedente è stata introdotta la nozione di matrice ortogonale nello spazio euclideo $\mathbb{R}^n$. Richiamiamo sinteticamente le formulazioni equivalenti che ne regolano il comportamento.

Definizione 3.1.1 (Caratterizzazioni Equivalenti di Matrice Ortogonale). Una matrice quadrata $U \in \mathbb{R}^{n \times n}$ si dice **ortogonale** se soddisfa una qualsiasi delle seguenti condizioni mutuamente equivalenti:

1. $U^T U = I_n$, ovvero l'inversa coincide con la trasposta ($U^{-1} = U^T$).

2. $UU^T = I_n$.

3. L'insieme delle colonne di $U = [\mathbf{u}_1, \dots, \mathbf{u}_n]$ costituisce una base ortonormale di $\mathbb{R}^n$:

$$\langle \mathbf{u}_i, \mathbf{u}_j \rangle = \mathbf{u}_i^T \mathbf{u}_j = \delta_{ij} = \begin{cases} 1 & \text{se } i = j, \\ 0 & \text{se } i \neq j. \end{cases} \quad (3.1)$$

4. L'insieme delle righe di U costituisce una base ortonormale di $\mathbb{R}^n$.

Chiarimento Terminologico Storico

In letteratura si adotta storicamente la locuzione *matrice ortogonale*, benché le colonne (e le righe) della matrice non siano unicamente tra loro ortogonali, bensì **normalizzate a norma unitaria**, costituendo pertanto un sistema strettamente **ortonormale**.

La caratteristica geometrica cruciale di una trasformazione ortogonale risiede nella conservazione delle distanze e delle norme euclidee, come espresso dalla proprietà di isometria.

Proprietà 3.1.1 (Isometria Euclidea). *Sia $U \in \mathbb{R}^{n \times n}$ una matrice ortogonale. Per ogni vettore $\mathbf{x} \in \mathbb{R}^n$, l'applicazione lineare preserva esattamente la norma euclidea:*

$$\|U\mathbf{x}\|_2 = \|\mathbf{x}\|_2. \quad (3.2)$$

Dimostrazione. Calcolando la norma euclidea al quadrato di $U\mathbf{x}$ e applicando l'identità $(U\mathbf{x})^T = \mathbf{x}^T U^T$:

$$\|U\mathbf{x}\|_2^2 = (U\mathbf{x})^T (U\mathbf{x}) = \mathbf{x}^T (U^T U) \mathbf{x} = \mathbf{x}^T I_n \mathbf{x} = \mathbf{x}^T \mathbf{x} = \|\mathbf{x}\|_2^2. \quad (3.3)$$

Estraendo la radice quadrata aritmetica si ottiene $\|U\mathbf{x}\|_2 = \|\mathbf{x}\|_2$. $\square$

3.2 Matrici Rettangolari a Colonne Ortonormali: $V^T V$ vs $V V^T$

Nelle applicazioni computazionali (quali la riduzione di dimensionalità, la PCA e la fattorizzazione ai valori singolari in forma compatta) si manipolano costantemente matrici rettangolari le cui colonne formano un sistema ortonormale.

3.2.1 Definizione e Vincolo sulla Dimensionalità

Definizione 3.2.1 (Matrice Rettangolare a Colonne Ortonormali). Una matrice $V \in \mathbb{R}^{n \times k}$ con $k < n$ (*tall-skinny*, ovvero alta e stretta) possiede colonne mutuamente ortonormali se:

$$V = \begin{bmatrix} | & | & \dots & | \\ \mathbf{v}_1 & \mathbf{v}_2 & \dots & \mathbf{v}_k \\ | & | & \dots & | \end{bmatrix}, \quad \mathbf{v}_i \in \mathbb{R}^n, \quad (3.4)$$

con vettori colonna soddisfacenti la condizione di ortonormalità:

$$\langle \mathbf{v}_i, \mathbf{v}_j \rangle = \mathbf{v}_i^T \mathbf{v}_j = \delta_{ij} \quad \forall i, j \in \{1, \dots, k\}. \quad (3.5)$$

Vincolo sulla Dimensione: Perché deve essere $k \leq n$?

In uno spazio vettoriale di dimensione n (come $\mathbb{R}^n$), la dimensione di qualsiasi sottospazio è al più n . Poiché ogni famiglia finita di vettori ortonormali è intrinsecamente linearmente indipendente, non possono sussistere più di n vettori ortonormali in $\mathbb{R}^n$. Di conseguenza, una matrice a colonne ortonormali può avere al massimo tante colonne quante sono le sue righe ($k \leq n$).

3.2.2 Il Prodotto $V^T V$ (Gramiano delle Colonne)

Consideriamo il prodotto tra la trasposta $V^T \in \mathbb{R}^{k \times n}$ e la matrice $V \in \mathbb{R}^{n \times k}$. Il risultato è una matrice quadrata di ordine k :

$$V^T V \in \mathbb{R}^{k \times k}. \quad (3.6)$$

Sviluppando il prodotto per blocchi, considerando V^T per righe e V per colonne:

$$V^T V = \begin{bmatrix} - & \mathbf{v}_1^T & - \\ - & \mathbf{v}_2^T & - \\ & \vdots & \\ - & \mathbf{v}_k^T & - \end{bmatrix} \begin{bmatrix} | & | & \dots & | \\ \mathbf{v}_1 & \mathbf{v}_2 & \dots & \mathbf{v}_k \\ | & | & \dots & | \end{bmatrix} = \begin{bmatrix} \mathbf{v}_1^T \mathbf{v}_1 & \mathbf{v}_1^T \mathbf{v}_2 & \dots & \mathbf{v}_1^T \mathbf{v}_k \\ \mathbf{v}_2^T \mathbf{v}_1 & \mathbf{v}_2^T \mathbf{v}_2 & \dots & \mathbf{v}_2^T \mathbf{v}_k \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{v}_k^T \mathbf{v}_1 & \mathbf{v}_k^T \mathbf{v}_2 & \dots & \mathbf{v}_k^T \mathbf{v}_k \end{bmatrix}. \quad (3.7)$$

Imponendo l'ortonormalità $\mathbf{v}_i^T \mathbf{v}_j = \delta_{ij}$, la matrice risultante coincide con l'identità di ordine k :

$$V^T V = I_k. \quad (3.8)$$

3.2.3 Il Prodotto Inverso VV^T (Proiettore Ortogonale)

Invertendo l'ordine dei fattori, otteniamo una matrice quadrata di dimensione considerevolmente superiore, pari a $n \times n$:

$$VV^T \in \mathbb{R}^{n \times n}. \quad (3.9)$$

Teorema 3.2.1 (Non-Coincidenza con l'Identità). *Sia $V \in \mathbb{R}^{n \times k}$ a colonne ortonormali con $k < n$. Allora:*

$$VV^T \neq I_n. \quad (3.10)$$

Dimostrazione. La dimostrazione discende direttamente dal teorema sul rango del prodotto matriciale:

1. Il rango del prodotto di due matrici è superiormente limitato dal rango dei singoli fattori:

$$\text{rank}(VV^T) \leq \min(\text{rank}(V), \text{rank}(V^T)). \quad (3.11)$$

2. Essendo le k colonne di V ortonormali e dunque linearmente indipendenti, si ha $\text{rank}(V) = \text{rank}(V^T) = k$.
3. Pertanto, $\text{rank}(VV^T) \leq k$. In realtà, poiché $V^TV = I_k$, vale esattamente $\text{rank}(VV^T) = k$.
4. D'altra parte, la matrice identità $I_n \in \mathbb{R}^{n \times n}$ ha rango pieno pari a n .
5. Poiché per ipotesi $k < n$, segue:

$$\text{rank}(VV^T) = k < n = \text{rank}(I_n) \implies VV^T \neq I_n. \quad (3.12)$$

La matrice VV^T è singolare e possiede un nucleo non banale di dimensione $n - k > 0$. $\square$

Espansione per Prodotti Esterni e Significato Geometrico

Applicando la decomposizione per blocchi, il prodotto VV^T può essere espresso come somma di diadi (*outer products*):

$$VV^T = \sum_{i=1}^k \mathbf{v}_i \mathbf{v}_i^T = \mathbf{v}_1 \mathbf{v}_1^T + \mathbf{v}_2 \mathbf{v}_2^T + \cdots + \mathbf{v}_k \mathbf{v}_k^T. \quad (3.13)$$

Ciascun addendo $\mathbf{v}_i \mathbf{v}_i^T$ è una matrice simmetrica di rango 1. L'operatore $P = VV^T$:

- È idempotente: $P^2 = (VV^T)(VV^T) = V(V^TV)V^T = VI_kV^T = VV^T = P$.
- È simmetrico: $P^T = (VV^T)^T = (V^T)^TV^T = VV^T = P$.

Di conseguenza, $P = VV^T$ è il **proiettore ortogonale** da $\mathbb{R}^n$ sul sottospazio generato dalle colonne di V :

$$\mathcal{S} = \text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_k\}. \quad (3.14)$$




Figura 3.1: Confronto dimensionale e di rango: il prodotto VV^T genera un proiettore ortogonale di dimensione $n \times n$ con rango strettamente deficitario $k < n$.

3.3 Isometria Parziale per Matrici Rettangolari Ortonormali

Nel caso rettangolare ($V \in \mathbb{R}^{n \times k}$ con $k < n$), la proprietà di isometria si applica asimmetricamente a seconda dello spazio di partenza del vettore.

3.3.1 Quesito (a): Conservazione della Norma per Vettori in $\mathbb{R}^k$

Proposizione 3.3.1 (Isometria Destra). *Sia $V \in \mathbb{R}^{n \times k}$ a colonne ortonormali con $k < n$. Per ogni vettore $\mathbf{x} \in \mathbb{R}^k$, vale:*

$$\|V\mathbf{x}\|_2 = \|\mathbf{x}\|_2. \quad (3.15)$$

Dimostrazione. Calcoliamo la norma quadratica dell'immagine $V\mathbf{x} \in \mathbb{R}^n$:

$$\|V\mathbf{x}\|_2^2 = (V\mathbf{x})^T(V\mathbf{x}) = \mathbf{x}^T(V^TV)\mathbf{x}. \quad (3.16)$$

Poiché le colonne di V sono ortonormali, abbiamo dimostrato che $V^T V = I_k$. Sostituendo:

$$\|V\mathbf{x}\|_2^2 = \mathbf{x}^T I_k \mathbf{x} = \mathbf{x}^T \mathbf{x} = \|\mathbf{x}\|_2^2. \quad (3.17)$$

Estraendo la radice quadrata aritmetica, $\|V\mathbf{x}\|_2 = \|\mathbf{x}\|_2$ per ogni $\mathbf{x} \in \mathbb{R}^k$. $\square$

Interpretazione Geometrica

L'applicazione $V : \mathbb{R}^k \rightarrow \mathbb{R}^n$ costituisce un'**immersione isometrica**: essa mappa lo spazio a dimensione inferiore $\mathbb{R}^k$ in un sottospazio k -dimensionale di $\mathbb{R}^n$, conservando rigorosamente lunghezze e angoli tra vettori.

3.3.2 Quesito (b): Conservazione della Norma per Vettori in $\mathbb{R}^n$ sotto V^T

Proposizione 3.3.2 (Mancata Isometria Sinistra). *Sia $V \in \mathbb{R}^{n \times k}$ a colonne ortonormali con $k < n$. L'operatore trasposto $V^T : \mathbb{R}^n \rightarrow \mathbb{R}^k$ **non** preserva la norma euclidea su tutto $\mathbb{R}^n$:*

$$\exists \mathbf{y} \in \mathbb{R}^n \quad \text{tale che} \quad \|V^T \mathbf{y}\|_2 \neq \|\mathbf{y}\|_2. \quad (3.18)$$

Dimostrazione. Valutiamo la norma euclidea al quadrato di $V^T \mathbf{y}$:

$$\|V^T \mathbf{y}\|_2^2 = (V^T \mathbf{y})^T (V^T \mathbf{y}) = \mathbf{y}^T (V V^T) \mathbf{y}. \quad (3.19)$$

Poiché $V V^T \neq I_n$, l'espressione non collassa identicamente a $\|\mathbf{y}\|_2^2$.

Controesempio basato sul nucleo: Consideriamo la matrice $V^T \in \mathbb{R}^{k \times n}$. Dal Teorema del Rango-Nullità:

$$\dim(\ker(V^T)) = n - \text{rank}(V^T) = n - k. \quad (3.20)$$

Essendo $k < n$, la dimensione del nucleo è strettamente positiva ($n - k > 0$). Esiste pertanto almeno un vettore non nullo $\tilde{\mathbf{y}} \in \mathbb{R}^n \setminus \{\mathbf{0}\}$ tale che:

$$\tilde{\mathbf{y}} \in \ker(V^T) \implies V^T \tilde{\mathbf{y}} = \mathbf{0} \in \mathbb{R}^k. \quad (3.21)$$

Calcolando le norme:

$$\|V^T \tilde{\mathbf{y}}\|_2 = \|\mathbf{0}\|_2 = 0 \neq \|\tilde{\mathbf{y}}\|_2. \quad (3.22)$$

Pertanto, la contrazione della norma è massima per tutti i vettori ortogonali al sottospazio generato dalle colonne di V . $\square$

3.4 Autovalori e Autovettori: Fondamenti ed Esempio Guida

3.4.1 Definizioni Fondamentali

Sia $A \in \mathbb{R}^{n \times n}$ una matrice **quadrata**.

Definizione 3.4.1 (Autovalore, Autovettore e Autocoppia). Uno scalare $\lambda \in \mathbb{R}$ (o in $\mathbb{C}$) è detto **autovalore** di A se esiste un vettore **non nullo** $\mathbf{v} \in \mathbb{R}^n \setminus \{\mathbf{0}\}$ (o $\mathbb{C}^n \setminus \{\mathbf{0}\}$) tale che:

$$A\mathbf{v} = \lambda\mathbf{v}. \quad (3.23)$$

Il vettore $\mathbf{v}$ è detto **autovettore** associato a λ . La coppia $(\lambda, \mathbf{v})$ è definita **autocoppia** (*eigenpair*).

L'equazione $A\mathbf{v} = \lambda\mathbf{v}$ può essere riformulata come un sistema lineare omogeneo:

$$(A - \lambda I_n)\mathbf{v} = \mathbf{0}. \quad (3.24)$$

Affinché tale sistema ammetta soluzioni non nulle ($\mathbf{v} \neq \mathbf{0}$), la matrice dei coefficienti $(A - \lambda I_n)$ deve essere singolare, ossia avere determinante nullo:

$$p(\lambda) = \det(A - \lambda I_n) = 0. \quad (3.25)$$

Il polinomio $p(\lambda)$ è il **polinomio caratteristico** di A , di grado n . Gli autovalori di A sono tutte e sole le radici (reali o complesse) del polinomio caratteristico.

3.4.2 Esempio Guidato Passo-Passo

Esempio 3.4.1 (Calcolo di Autovalori e Autovettori per Matrice 2×2). Consideriamo la matrice simmetrica reale:

$$A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \in \mathbb{R}^{2 \times 2}. \quad (3.26)$$

Passo 1: Determinazione del Polinomio Caratteristico e degli Autovalori.

$$p(\lambda) = \det(A - \lambda I_2) = \det \begin{bmatrix} 2 - \lambda & 1 \\ 1 & 2 - \lambda \end{bmatrix} = (2 - \lambda)^2 - 1. \quad (3.27)$$

Sfruttando la scomposizione come differenza di quadrati $a^2 - b^2 = (a - b)(a + b)$:

$$p(\lambda) = ((2 - \lambda) - 1)((2 - \lambda) + 1) = (1 - \lambda)(3 - \lambda) = 0. \quad (3.28)$$

Le radici del polinomio forniscono i due autovalori:

$$\lambda_1 = 3, \quad \lambda_2 = 1. \quad (3.29)$$

Passo 2: Ricerca dell'Autovettore per $\lambda_1 = 3$. Risolviamo il sistema $(A - 3I_2)\mathbf{v}_1 = \mathbf{0}$:

$$\begin{bmatrix} 2-3 & 1 \\ 1 & 2-3 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} -1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \implies -x + y = 0 \iff y = x. \quad (3.30)$$

Ponendo $x = 1$, otteniamo l'autovettore:

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}. \quad (3.31)$$

Passo 3: Ricerca dell'Autovettore per $\lambda_2 = 1$. Risolviamo il sistema $(A - I_2)\mathbf{v}_2 = \mathbf{0}$:

$$\begin{bmatrix} 2-1 & 1 \\ 1 & 2-1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \implies x+y = 0 \iff y = -x. \quad (3.32)$$

Ponendo $x = 1$, ricaviamo l'autovettore:

$$\mathbf{v}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}. \quad (3.33)$$

Si noti che $\mathbf{v}_1^T \mathbf{v}_2 = 1(1) + 1(-1) = 0$: i due autovettori risultano mutuamente ortogonali.

3.5 Diagonalizzazione ed Espansione Diadica

3.5.1 Matrici Diagonalizzabili

Definizione 3.5.1 (Diagonalizzabilità). Una matrice $A \in \mathbb{R}^{n \times n}$ si dice **diagonalizzabile** se ammette n autovettori linearmente indipendenti, ovvero se esiste una base di $\mathbb{R}^n$ formata da autovettori di A .

In tal caso, organizzando gli n autovettori nelle colonne della matrice modale $V = [\mathbf{v}_1, \dots, \mathbf{v}_n] \in \mathbb{R}^{n \times n}$ e gli autovalori sulla diagonale di $D = \text{diag}(\lambda_1, \dots, \lambda_n)$:

$$AV = A[\mathbf{v}_1, \dots, \mathbf{v}_n] = [\lambda_1 \mathbf{v}_1, \dots, \lambda_n \mathbf{v}_n] = [\mathbf{v}_1, \dots, \mathbf{v}_n] \begin{bmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_n \end{bmatrix} = VD. \quad (3.34)$$

Essendo gli autovettori linearmente indipendenti, V è invertibile. Moltiplicando a destra per V^{-1} :

$$A = VDV^{-1}. \quad (3.35)$$

3.5.2 Espansione Diadica (Outer Product Expansion)

Sia $W = V^{-1} \in \mathbb{R}^{n \times n}$. Rappresentiamo W partizionata per righe:

$$W = V^{-1} = \begin{bmatrix} - & \mathbf{w}_1^T & - \\ - & \mathbf{w}_2^T & - \\ & \vdots & \\ - & \mathbf{w}_n^T & - \end{bmatrix}. \quad (3.36)$$

Poiché $WV = I_n$, sussiste la relazione di bi-ortonormalità: $\mathbf{w}_i^T \mathbf{v}_j = \delta_{ij}$. Sviluppando la fattorizzazione $A = VDW$:

$$\begin{aligned} A &= \begin{bmatrix} | & & | \\ \mathbf{v}_1 & \dots & \mathbf{v}_n \\ | & & | \end{bmatrix} \begin{bmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_n \end{bmatrix} \begin{bmatrix} - & \mathbf{w}_1^T & - \\ & \vdots & \\ - & \mathbf{w}_n^T & - \end{bmatrix} \\ &= \begin{bmatrix} | & & | \\ \lambda_1 \mathbf{v}_1 & \dots & \lambda_n \mathbf{v}_n \\ | & & | \end{bmatrix} \begin{bmatrix} - & \mathbf{w}_1^T & - \\ & \vdots & \\ - & \mathbf{w}_n^T & - \end{bmatrix}. \end{aligned} \quad (3.37)$$

Eseguendo la moltiplicazione a blocchi colonna per riga si ottiene:

$$A = \sum_{i=1}^n \lambda_i \mathbf{v}_i \mathbf{w}_i^T = \lambda_1 \mathbf{v}_1 \mathbf{w}_1^T + \lambda_2 \mathbf{v}_2 \mathbf{w}_2^T + \dots + \lambda_n \mathbf{v}_n \mathbf{w}_n^T. \quad (3.38)$$

Significato dell'Espansione Diadica

La matrice A è espressa come combinazione lineare pesata di n matrici elementari di rango 1, ciascuna generata dal prodotto esterno $\mathbf{v}_i \mathbf{w}_i^T$. Gli autovalori λ_i agiscono come pesi di modulazione. Questa struttura analitica costituisce la base concettuale della decomposizione a valori singolari (SVD) e dell'approssimazione a basso rango di Eckart-Young-Mirsky.

3.5.3 Casi Patologici di Mancata Diagonalizzabilità

Non tutte le matrici ammettono una decomposizione $A = VDV^{-1}$ su campo reale. Esistono due ostacoli teorici fondamentali.

Caso 1: Assenza di Autovalori Reali

Consideriamo la matrice di rotazione nel piano di un angolo pari a $\theta = 90^\circ$:

$$A = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}. \quad (3.39)$$

Il relativo polinomio caratteristico è:

$$p(\lambda) = \det \begin{bmatrix} -\lambda & -1 \\ 1 & -\lambda \end{bmatrix} = \lambda^2 + 1 = 0 \implies \lambda_{1,2} = \pm i \notin \mathbb{R}. \quad (3.40)$$

Beninteso che la matrice ha entrate puramente reali, essa **non ammette autovalori né autovettori reali**. Geometricamente, una rotazione pura non banale non preserva la direzione di alcun vettore reale in $\mathbb{R}^2$.

Caso 2: Matrici Difettive (Molteplicità Geometrica Inferiore a Quella Algebrica)

Consideriamo la matrice di scorrimento (*shear matrix*):

$$A = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}. \quad (3.41)$$

1. Il polinomio caratteristico è $p(\lambda) = (1 - \lambda)^2 = 0$. Esiste un solo autovalore $\lambda = 1$ con **molteplicità algebrica** $m_a(1) = 2$.
2. Calcoliamo la **molteplicità geometrica** $m_g(1) = \dim(\ker(A - I_2))$:

$$A - I_2 = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix} \implies \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \implies y = 0, \quad x \in \mathbb{R} \text{ libero}. \quad (3.42)$$

L'autospazio associato è unidimensionale: $\ker(A - I_2) = \text{span} \left\{ \begin{bmatrix} 1 \\ 0 \end{bmatrix} \right\}$,
da cui $m_g(1) = 1$.

Poiché $m_g(1) = 1 < 2 = m_a(1)$, non è possibile reperire 2 autovettori linearmente indipendenti per costruire la matrice V . La matrice A è detta **difettiva** e non è diagonalizzabile (può essere unicamente ridotta in forma canonica di Jordan).

3.6 Esercizi Guidati sugli Autovalori (Q1 – Q4)

3.6.1 Esercizio Q1: Autocoppie di una Matrice Diagonale

Esempio 3.6.1 (Spettro di una Matrice Diagonale). Data una generica matrice diagonale $D = \text{diag}(d_1, d_2, \dots, d_n) \in \mathbb{R}^{n \times n}$, determiniamo le sue autocoppie.

Risoluzione: Valutiamo l'azione di D sul generico vettore della base canonica $\mathbf{e}_i = [0, \dots, 1, \dots, 0]^T$:

$$D\mathbf{e}_i = \begin{bmatrix} d_1 & & & \\ & d_2 & & \\ & & \ddots & \\ & & & d_n \end{bmatrix} \begin{bmatrix} 0 \\ \vdots \\ 1 \\ \vdots \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ \vdots \\ d_i \\ \vdots \\ 0 \end{bmatrix} = d_i \mathbf{e}_i. \quad (3.43)$$

Pertanto:

- Gli autovalori sono esattamente le entrate poste sulla diagonale principale: $\lambda_i = d_i$ per $i = 1, \dots, n$.
- Gli autovettori canonici associati sono i vettori della base standard: $\mathbf{v}_i = \mathbf{e}_i$.
- Le autocoppie canoniche sono $(d_1, \mathbf{e}_1), (d_2, \mathbf{e}_2), \dots, (d_n, \mathbf{e}_n)$.

Proprietà 3.6.1 (Autovalori Coincidenti e Struttura dell'Autospazio). *Cosa accade qualora due o più valori diagonali coincidano, ad esempio $d_1 = d_2 = \lambda$? In tale evenienza, **qualsiasi combinazione lineare** $\alpha\mathbf{e}_1 + \beta\mathbf{e}_2$ (con α, β non entrambi nulli) è ancora un autovettore per λ .*

Dimostrazione generale: Siano $\mathbf{v}, \mathbf{w} \in \mathbb{R}^n$ due autovettori di una matrice A associati al **medesimo** autovalore λ , ovvero $A\mathbf{v} = \lambda\mathbf{v}$ e $A\mathbf{w} = \lambda\mathbf{w}$. Per ogni coppia di scalari $\alpha, \beta \in \mathbb{R}$:

$$A(\alpha\mathbf{v} + \beta\mathbf{w}) = \alpha(A\mathbf{v}) + \beta(A\mathbf{w}) = \alpha(\lambda\mathbf{v}) + \beta(\lambda\mathbf{w}) = \lambda(\alpha\mathbf{v} + \beta\mathbf{w}). \quad (3.44)$$

Pertanto l'insieme degli autovettori associati a λ , unitamente al vettore nullo, costituisce un sottospazio vettoriale chiuso denominato **autospazio** (eigenspace):

$$\mathcal{E}(\lambda) = \ker(A - \lambda I_n). \quad (3.45)$$

3.6.2 Esercizio Q2: Autocoppie della Matrice Identità

Esempio 3.6.2 (Spettro della Matrice Identità). Determiniamo autovalori e autovettori della matrice identità $I_n \in \mathbb{R}^{n \times n}$.

Risoluzione: Per definizione dell'operatore identità, per ogni vettore non nullo $\mathbf{x} \in \mathbb{R}^n \setminus \{\mathbf{0}\}$:

$$I_n \mathbf{x} = 1 \cdot \mathbf{x}. \quad (3.46)$$

- **Autovalore:** $\lambda = 1$ con molteplicità algebrica e geometrica pari a n ($m_a = m_g = n$).
- **Autovettori:** qualsiasi vettore non nullo di $\mathbb{R}^n$.
- L'intero spazio $\mathbb{R}^n$ coincide con l'autospazio associato: $\mathcal{E}(1) = \mathbb{R}^n$.

3.6.3 Esercizio Q3: Somma e Prodotto di Matrici con Autovalore Comune

Esempio 3.6.3 (Autovalori di Somma e Prodotto di Matrici). Sia dato $\lambda \in \mathbb{R}$ autovalore comune di $A \in \mathbb{R}^{n \times n}$ e $B \in \mathbb{R}^{n \times n}$.

1. 2λ è necessariamente autovalore di $A + B$?
2. λ^2 è necessariamente autovalore di AB ?

Risposta analitica: NO a entrambi i quesiti. Affinché le relazioni spettrali valgano sulla somma o sul prodotto, le due matrici A e B devono condividere il **medesimo autovettore** associato a λ . Se i vettori propri non sono allineati, la proprietà decade.

Controesempio per la somma: Consideriamo:

$$A = \begin{bmatrix} 5 & 0 \\ 0 & 1 \end{bmatrix}, \quad B = \begin{bmatrix} 1 & 0 \\ 0 & 5 \end{bmatrix}. \quad (3.47)$$

Entrambe le matrici possiedono l'insieme di autovalori $\{1, 5\}$ (in particolare condividono $\lambda = 1$ e $\lambda = 5$). Calcoliamo la somma:

$$A + B = \begin{bmatrix} 6 & 0 \\ 0 & 6 \end{bmatrix} = 6I_2. \quad (3.48)$$

Gli autovalori di $A + B$ sono entrambi pari a 6. Tuttavia, raddoppiando gli autovalori originari:

$$2 \cdot 1 = 2 \neq 6, \quad 2 \cdot 5 = 10 \neq 6. \quad (3.49)$$

Quindi 2λ non appartiene allo spettro della matrice somma.

Controesempio per il prodotto: Consideriamo:

$$A = \begin{bmatrix} 2 & 0 \\ 0 & 3 \end{bmatrix}, \quad B = \begin{bmatrix} 10 & 0 \\ 0 & 2 \end{bmatrix}. \quad (3.50)$$

Entrambe le matrici condividono l'autovalore $\lambda = 2$. Il prodotto risulta:

$$AB = \begin{bmatrix} 20 & 0 \\ 0 & 6 \end{bmatrix}. \quad (3.51)$$

Gli autovalori di AB sono $\{20, 6\}$, nessuno dei quali coincide con $\lambda^2 = 2^2 = 4$.

3.6.4 Esercizio Q4: Autocoppie della Potenza di una Matrice

Teorema 3.6.1 (Spettro della Potenza A^k). *Sia $A \in \mathbb{R}^{n \times n}$ una matrice quadrata e sia $(\lambda, \mathbf{v})$ una sua autocoppia ($A\mathbf{v} = \lambda\mathbf{v}$). Allora per ogni esponente intero positivo $k \in \mathbb{N}$:*

$$(\lambda^k, \mathbf{v}) \text{ è un'autocoppia di } A^k, \quad \text{ovvero} \quad A^k \mathbf{v} = \lambda^k \mathbf{v}. \quad (3.52)$$

Dimostrazione. La dimostrazione procede agevolmente per induzione su k :

1. **Base dell'induzione ($k = 1$):** $A^1 \mathbf{v} = A\mathbf{v} = \lambda\mathbf{v} = \lambda^1 \mathbf{v}$.
2. **Passo induttivo:** Assumiamo vera l'ipotesi induttiva $A^k \mathbf{v} = \lambda^k \mathbf{v}$. Moltiplicando a sinistra per A :

$$A^{k+1} \mathbf{v} = A(A^k \mathbf{v}) = A(\lambda^k \mathbf{v}) = \lambda^k (A\mathbf{v}) = \lambda^k (\lambda \mathbf{v}) = \lambda^{k+1} \mathbf{v}. \quad (3.53)$$

La tesi è dunque verificata per ogni $k \geq 1$. □

Corollario 3.6.1 (Fattorizzazione della Potenza per Matrici Diagonalizzabili). *Se $A = VDV^{-1}$ è diagonalizzabile, calcolando la potenza per composizione telescopica:*

$$\begin{aligned} A^k &= (VDV^{-1})(VDV^{-1}) \cdots (VDV^{-1}) \\ &= VD(V^{-1}V)D \cdots (V^{-1}V)DV^{-1} = VD^kV^{-1}. \end{aligned} \quad (3.54)$$

Essendo $D = \text{diag}(\lambda_1, \dots, \lambda_n)$ diagonale, la sua potenza k -esima è immediata:

$$D^k = \text{diag}(\lambda_1^k, \lambda_2^k, \dots, \lambda_n^k). \quad (3.55)$$

Avvertenza sull'Invarianza dell'Autovettore

Si presti estrema attenzione al fatto che, elevando la matrice a potenza, **soltanto gli autovalori** vengono elevati alla potenza k , mentre **gli autovettori permangono rigorosamente invariati**. La scrittura $\mathbf{v}^k$ è priva di significato nell'algebra vettoriale.

3.7 Matrici Simmetriche e il Teorema Spettrale

Le matrici simmetriche costituiscono la classe di matrici più rilevante nell'algebra lineare computazionale, nell'ottimizzazione e nel machine learning.

Definizione 3.7.1 (Matrice Simmetrica). Una matrice quadrata $A \in \mathbb{R}^{n \times n}$ si dice **simmetrica** se coincide con la propria trasposta:

$$A^T = A \iff A_{ij} = A_{ji} \quad \forall i, j \in \{1, \dots, n\}. \quad (3.56)$$

Teorema 3.7.1 (Teorema Spettrale per Matrici Reali Simmetriche). Sia $A \in \mathbb{R}^{n \times n}$ una matrice simmetrica reale ($A^T = A$). Allora:

1. Tutti gli n autovalori di A sono numeri **reali**: $\lambda_1, \lambda_2, \dots, \lambda_n \in \mathbb{R}$.
2. Gli autovettori associati ad autovalori distinti sono tra loro **ortogonali**.
3. La matrice A è **ortogonalmente diagonalizzabile**: esistono una matrice ortogonale $U \in \mathbb{R}^{n \times n}$ ($U^T U = U U^T = I_n$) e una matrice diagonale reale $D \in \mathbb{R}^{n \times n}$ tali che:

$$A = U D U^T. \quad (3.57)$$

In altri termini, esiste sempre una **base ortonormale di $\mathbb{R}^n$ interamente costituita da autovettori di A** .

Ortogonalità per Autovalori Distinti. Siano $(\lambda_1, \mathbf{u}_1)$ e $(\lambda_2, \mathbf{u}_2)$ due autocopie di A , con $\lambda_1 \neq \lambda_2$. Consideriamo la quantità scalare $\mathbf{u}_1^T A \mathbf{u}_2$:

1. Calcolando l'azione di A verso destra:

$$\mathbf{u}_1^T (A \mathbf{u}_2) = \mathbf{u}_1^T (\lambda_2 \mathbf{u}_2) = \lambda_2 (\mathbf{u}_1^T \mathbf{u}_2). \quad (3.58)$$

2. Sfruttando la simmetria di A ($A = A^T$) e l'azione verso sinistra:

$$\mathbf{u}_1^T A \mathbf{u}_2 = (A^T \mathbf{u}_1)^T \mathbf{u}_2 = (A \mathbf{u}_1)^T \mathbf{u}_2 = (\lambda_1 \mathbf{u}_1)^T \mathbf{u}_2 = \lambda_1 (\mathbf{u}_1^T \mathbf{u}_2). \quad (3.59)$$

Uguagliando le due espressioni ottenute:

$$\lambda_1(\mathbf{u}_1^T \mathbf{u}_2) = \lambda_2(\mathbf{u}_1^T \mathbf{u}_2) \iff (\lambda_1 - \lambda_2)(\mathbf{u}_1^T \mathbf{u}_2) = 0. \quad (3.60)$$

Poiché per ipotesi $\lambda_1 \neq \lambda_2$, deve necessariamente risultare:

$$\mathbf{u}_1^T \mathbf{u}_2 = 0, \quad (3.61)$$

dimostrando che gli autovettori sono ortogonali. $\square$

3.8 Forme Quadratiche e Disuguaglianza di Rayleigh

3.8.1 Definizione di Forma Quadratica

Definizione 3.8.1 (Forma Quadratica). Sia $A \in \mathbb{R}^{n \times n}$ una matrice simmetrica reale. La funzione $q : \mathbb{R}^n \rightarrow \mathbb{R}$ definita da:

$$q(\mathbf{x}) = \mathbf{x}^T A \mathbf{x} = \sum_{i=1}^n \sum_{j=1}^n A_{ij} x_i x_j \quad (3.62)$$

è detta **forma quadratica** associata alla matrice A .

3.8.2 Teorema dei Limiti Spettrali (Disuguaglianza di Rayleigh)

Teorema 3.8.1 (Limiti Spettrali della Forma Quadratica). Sia $A \in \mathbb{R}^{n \times n}$ simmetrica reale, con autovalori ordinati in senso decrescente:

$$\lambda_{\max} = \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n = \lambda_{\min}. \quad (3.63)$$

Allora per ogni vettore $\mathbf{x} \in \mathbb{R}^n$ sussiste la doppia disuguaglianza:

$$\lambda_{\min} \|\mathbf{x}\|_2^2 \leq \mathbf{x}^T A \mathbf{x} \leq \lambda_{\max} \|\mathbf{x}\|_2^2. \quad (3.64)$$

Dimostrazione. La dimostrazione si articola in passaggi analitici espliciti:

1. **Fattorizzazione Spettrale:** Per il Teorema Spettrale 3.7.1, decomponiamo $A = U D U^T$, dove $U \in \mathbb{R}^{n \times n}$ è ortogonale e $D = \text{diag}(\lambda_1, \dots, \lambda_n)$.
2. **Sostituzione nella Forma Quadratica:**

$$\mathbf{x}^T A \mathbf{x} = \mathbf{x}^T (U D U^T) \mathbf{x} = (U^T \mathbf{x})^T D (U^T \mathbf{x}). \quad (3.65)$$

3. **Cambio di Coordinate Ortogonale:** Definiamo il vettore $\mathbf{y} \in \mathbb{R}^n$ tramite la trasformazione:

$$\mathbf{y} = U^T \mathbf{x} \iff \mathbf{x} = U \mathbf{y}. \quad (3.66)$$

Poiché U è ortogonale, l'applicazione preserva la norma euclidea (Proprietà 3.1.1):

$$\|\mathbf{y}\|_2^2 = \|U^T \mathbf{x}\|_2^2 = \|\mathbf{x}\|_2^2 \implies \sum_{i=1}^n y_i^2 = \|\mathbf{x}\|_2^2. \quad (3.67)$$

4. **Espansione in Componenti:**

$$\mathbf{x}^T A \mathbf{x} = \mathbf{y}^T D \mathbf{y} = \sum_{i=1}^n \lambda_i y_i^2 = \lambda_1 y_1^2 + \lambda_2 y_2^2 + \cdots + \lambda_n y_n^2. \quad (3.68)$$

5. **Derivazione del Limite Superiore:** Essendo $\lambda_i \leq \lambda_{\max}$ per ogni $i \in \{1, \dots, n\}$ e dato che $y_i^2 \geq 0$:

$$\mathbf{x}^T A \mathbf{x} = \sum_{i=1}^n \lambda_i y_i^2 \leq \sum_{i=1}^n \lambda_{\max} y_i^2 = \lambda_{\max} \sum_{i=1}^n y_i^2 = \lambda_{\max} \|\mathbf{y}\|_2^2 = \lambda_{\max} \|\mathbf{x}\|_2^2. \quad (3.69)$$

6. **Derivazione del Limite Inferiore:** In modo del tutto analogo, poiché $\lambda_i \geq \lambda_{\min}$ per ogni i :

$$\mathbf{x}^T A \mathbf{x} = \sum_{i=1}^n \lambda_i y_i^2 \geq \sum_{i=1}^n \lambda_{\min} y_i^2 = \lambda_{\min} \sum_{i=1}^n y_i^2 = \lambda_{\min} \|\mathbf{y}\|_2^2 = \lambda_{\min} \|\mathbf{x}\|_2^2. \quad (3.70)$$

Combinando i due estremi, la tesi è pienamente provata per qualsiasi $\mathbf{x} \in \mathbb{R}^n$. $\square$

3.8.3 Condizioni di Uguaglianza e Quoziente di Rayleigh

Proprietà 3.8.1 (Condizioni di Uguaglianza ed Estremi Vettoriali).

1. L'uguaglianza superiore $\mathbf{x}^T A \mathbf{x} = \lambda_{\max} \|\mathbf{x}\|_2^2$ si verifica **se e solo se** $\mathbf{x}$ è un autovettore di A associato all'autovalore massimo $\lambda_{\max}$.
2. L'uguaglianza inferiore $\mathbf{x}^T A \mathbf{x} = \lambda_{\min} \|\mathbf{x}\|_2^2$ si verifica **se e solo se** $\mathbf{x}$ è un autovettore di A associato all'autovalore minimo $\lambda_{\min}$.

Dimostrazione. Analizziamo il limite superiore:

$$\lambda_{\max} \sum_{i=1}^n y_i^2 - \sum_{i=1}^n \lambda_i y_i^2 = \sum_{i=1}^n (\lambda_{\max} - \lambda_i) y_i^2 = 0. \quad (3.71)$$

Poiché $(\lambda_{\max} - \lambda_i) \geq 0$ e $y_i^2 \geq 0$, ogni termine della sommatoria è non-negativo. La somma si annulla se e solo se, per ciascun indice i con $\lambda_i < \lambda_{\max}$, risulta $y_i = 0$. Dunque il vettore trasformato $\mathbf{y}$ possiede componenti non nulle unicamente in corrispondenza degli indici associati a $\lambda_{\max}$. Tornando alle coordinate originarie $\mathbf{x} = U\mathbf{y}$, ciò equivale ad asserire che $\mathbf{x}$ appartiene all'autospazio $\mathcal{E}(\lambda_{\max})$. $\square$

Definizione 3.8.2 (Quoziente di Rayleigh). Per ogni vettore non nullo $\mathbf{x} \in \mathbb{R}^n \setminus \{\mathbf{0}\}$, il **quoziente di Rayleigh** di una matrice simmetrica A è il rapporto scalare:

$$R_A(\mathbf{x}) = \frac{\mathbf{x}^T A \mathbf{x}}{\mathbf{x}^T \mathbf{x}} = \frac{\mathbf{x}^T A \mathbf{x}}{\|\mathbf{x}\|_2^2}. \quad (3.72)$$

Dal Teorema 3.8.1 segue immediatamente la caratterizzazione variazionale degli autovalori estremi:

$$\lambda_{\min} = \min_{\mathbf{x} \neq \mathbf{0}} R_A(\mathbf{x}), \quad \lambda_{\max} = \max_{\mathbf{x} \neq \mathbf{0}} R_A(\mathbf{x}). \quad (3.73)$$

3.9 Matrici Simmetriche Definite e Semidefinite Positive

3.9.1 Definizioni Assiomatiche

Sia $A \in \mathbb{R}^{n \times n}$ una matrice simmetrica reale ($A^T = A$).

Definizione 3.9.1 (Matrice Simmetrica Definita Positiva – SPD). La matrice A si definisce **simmetrica definita positiva** (*Symmetric Positive Definite*, SPD) se la forma quadratica associata è strettamente positiva per qualsiasi vettore non nullo:

$$\mathbf{v}^T A \mathbf{v} > 0 \quad \forall \mathbf{v} \in \mathbb{R}^n \setminus \{\mathbf{0}\}. \quad (3.74)$$

Definizione 3.9.2 (Matrice Simmetrica Semidefinita Positiva – SPSD). La matrice A si definisce **simmetrica semidefinita positiva** (*Symmetric Positive Semi-Definite*, SPSD) se la forma quadratica associata è non-negativa per qualsiasi vettore:

$$\mathbf{v}^T A \mathbf{v} \geq 0 \quad \forall \mathbf{v} \in \mathbb{R}^n. \quad (3.75)$$

3.9.2 Caratterizzazione Spettrale Equivalente

Teorema 3.9.1 (Criterio Spettrale per Matrici SPD e SPSD). *Sia $A \in \mathbb{R}^{n \times n}$ simmetrica reale con autovalori $\lambda_1, \dots, \lambda_n$. Allora:*

1. A è **SPD** $\iff \lambda_i > 0$ per ogni $i \in \{1, \dots, n\}$ (tutti gli autovalori sono strettamente positivi).
2. A è **SPSD** $\iff \lambda_i \geq 0$ per ogni $i \in \{1, \dots, n\}$ (tutti gli autovalori sono non-negativi).

Dimostrazione. La dimostrazione segue direttamente dalla disuguaglianza del quoziente di Rayleigh:

- Se tutti i $\lambda_i > 0$, allora $\lambda_{\min} > 0$. Dalla disuguaglianza $\mathbf{v}^T A \mathbf{v} \geq \lambda_{\min} \|\mathbf{v}\|_2^2$, per ogni $\mathbf{v} \neq \mathbf{0}$ si ha $\mathbf{v}^T A \mathbf{v} > 0$, dunque A è SPD.
- Viceversa, se A è SPD, scegliendo $\mathbf{v} = \mathbf{u}_i$ (autovettore unitario per λ_i):

$$\mathbf{u}_i^T A \mathbf{u}_i = \lambda_i \|\mathbf{u}_i\|_2^2 = \lambda_i > 0. \quad (3.76)$$

- Il medesimo ragionamento con disuguaglianze deboli dimostra l'equivalenza per matrici SPSD.

□

3.9.3 Gerarchia e Inclusione delle Classi Matriciali




Figura 3.2: Gerarchia strutturale e progressivo restringimento delle classi di matrici nell'algebra lineare.

Si noti che l'inclusione è stretta:

$$\text{SPD} \subset \text{SPSD} \subset \text{Simmetriche}. \quad (3.77)$$

Una matrice SPSPD appartiene alla classe SPD se e solo se è non singolare, ossia se non possiede alcun autovalore nullo ($\lambda_{\min} > 0 \iff \det(A) = \prod_{i=1}^n \lambda_i > 0$).

3.9.4 Esempi Notevoli in $\mathbb{R}^{2 \times 2}$

Esempio 3.9.1 (Verifica di Matrici SPD e SPSPD).

1. Esempi SPD:

- $A_1 = \begin{bmatrix} 1 & 0 \\ 0 & 2 \end{bmatrix}$: simmetrica diagonale con autovalori $\lambda_1 = 1 > 0, \lambda_2 = 2 > 0 \implies \text{SPD}$.
- $A_2 = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$: simmetrica con autovalori calcolati nell'Esempio 3.4.1 pari a $\lambda_1 = 3 > 0, \lambda_2 = 1 > 0 \implies \text{SPD}$.

2. Esempi SPSPD non SPD:

- $A_3 = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$: simmetrica diagonale con autovalori $\lambda_1 = 1 \geq 0, \lambda_2 = 0 \geq 0 \implies \text{SPSPD}$. Non è SPD in quanto $\det(A_3) = 0$.
- $A_4 = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$: le due righe sono identiche, quindi $\text{rank}(A_4) = 1 < 2$, implicando $\lambda_1 = 0$. Poiché la traccia eguaglia la somma degli autovalori, $\text{Tr}(A_4) = 1 + 1 = 2 \implies \lambda_1 + \lambda_2 = 2 \implies \lambda_2 = 2 \geq 0$. Dunque gli autovalori sono $\{2, 0\} \implies \text{SPSPD}$.

3. Controesempio di Matrice Indefinita: Sia la matrice proposta $A_5 = \begin{bmatrix} 1 & 2 \\ 2 & 0 \end{bmatrix}$. Sebbene le entrate diagonali siano non-negative, il determinante risulta:

$$\det(A_5) = 1(0) - 2(2) = -4 < 0. \quad (3.78)$$

Poiché $\det(A_5) = \lambda_1 \lambda_2 = -4 < 0$, i due autovalori hanno segni discordi ($\lambda_1 > 0$ e $\lambda_2 < 0$). La matrice è **indefinita** (né SPD né SPSPD).

3.10 Generazione Naturale di Matrici SPSPD: $B^T B$ e BB^T

Nelle applicazioni di calcolo scientifico e statistica, le matrici simmetriche semidefinite positive non vengono solitamente costruite assemblando coefficienti a mano, bensì scaturiscono naturalmente dal prodotto di una matrice rettangolare per la propria trasposta.

Proposizione 3.10.1 (Semidefinitenza Positiva dei Gramiani). *Sia $B \in \mathbb{R}^{n \times m}$ una matrice arbitraria (quadrata o rettangolare). Allora:*

1. *La matrice quadrata $B^T B \in \mathbb{R}^{m \times m}$ è simmetrica semidefinita positiva (SPSPD).*
2. *La matrice quadrata $BB^T \in \mathbb{R}^{n \times n}$ è simmetrica semidefinita positiva (SPSPD).*

Dimostrazione. Dimostriamo le due proprietà separatamente:

1. Verifica della Simmetria: Applicando la proprietà distributiva della trasposizione sul prodotto matriciale:

$$(B^T B)^T = B^T (B^T)^T = B^T B, \quad (BB^T)^T = (B^T)^T B^T = BB^T. \quad (3.79)$$

Entrambe le matrici risultano formalmente simmetriche.

2. Semidefinitenza Positiva di $B^T B$: Sia $\mathbf{v} \in \mathbb{R}^m$ un qualsiasi vettore di dimensione compatibile. Esaminiamo la forma quadratica associata a $B^T B$:

$$\mathbf{v}^T (B^T B) \mathbf{v} = (\mathbf{v}^T B^T) (B \mathbf{v}) = (B \mathbf{v})^T (B \mathbf{v}). \quad (3.80)$$

Riconosciamo nel prodotto scalare $(B \mathbf{v})^T (B \mathbf{v})$ la definizione della norma euclidea al quadrato del vettore immagine $\mathbf{w} = B \mathbf{v} \in \mathbb{R}^n$:

$$\mathbf{v}^T (B^T B) \mathbf{v} = \|B \mathbf{v}\|_2^2. \quad (3.81)$$

Per il primo assioma della norma vettoriale (non-negatività), vale $\|B \mathbf{v}\|_2^2 \geq 0$ per ogni $\mathbf{v} \in \mathbb{R}^m$. Di conseguenza:

$$\mathbf{v}^T (B^T B) \mathbf{v} \geq 0 \quad \forall \mathbf{v} \in \mathbb{R}^m \implies B^T B \text{ è SPSPD}. \quad (3.82)$$

3. Semidefinitenza Positiva di BB^T : Sia $\mathbf{u} \in \mathbb{R}^n$ un qualsiasi vettore. Procedendo in modo perfettamente simmetrico:

$$\mathbf{u}^T (BB^T) \mathbf{u} = (\mathbf{u}^T B) (B^T \mathbf{u}) = (B^T \mathbf{u})^T (B^T \mathbf{u}) = \|B^T \mathbf{u}\|_2^2 \geq 0 \quad \forall \mathbf{u} \in \mathbb{R}^n. \quad (3.83)$$

Pertanto anche BB^T è SPSPD. $\square$

Corollario 3.10.1 (Condizione di Definitenza Stretta per $B^T B$). *La matrice $B^T B \in \mathbb{R}^{m \times m}$ è **strettamente definita positiva (SPD)** se e solo se B ha rango massimo di colonna:*

$$B^T B \in SPD \iff \text{rank}(B) = m \iff \ker(B) = \{\mathbf{0}\}. \quad (3.84)$$

Dimostrazione. Dalla dimostrazione precedente, $\mathbf{v}^T(B^T B)\mathbf{v} = \|B\mathbf{v}\|_2^2$. Tale quantità si annulla se e solo se $\|B\mathbf{v}\|_2 = 0 \iff B\mathbf{v} = \mathbf{0} \iff \mathbf{v} \in \ker(B)$. Se $\ker(B) = \{\mathbf{0}\}$, nessun vettore non nullo può azzerare la forma quadratica, rendendo $B^T B$ strettamente definita positiva. $\square$

Rilevanza nelle Equazioni Normali e nella SVD

La proprietà appena dimostrata costituisce il fondamento teorico di due pilastri del calcolo numerico:

1. **Problemi di Minimi Quadrati Lineari:** La risoluzione del problema $\min_{\mathbf{x}} \|A\mathbf{x} - \mathbf{b}\|_2$ conduce al sistema delle equazioni normali:

$$A^T A \mathbf{x} = A^T \mathbf{b}. \quad (3.85)$$

Se A ha colonne linearmente indipendenti, $A^T A$ è SPD, garantendo l'esistenza e l'unicità della soluzione (risolvibile efficientemente tramite la fattorizzazione di Cholesky).

2. **Fattorizzazione ai Valori Singolari (SVD):** I valori singolari σ_i di una matrice arbitraria B sono definiti come le radici quadrate non-negative degli autovalori della matrice SPSD $B^T B$:

$$\sigma_i = \sqrt{\lambda_i(B^T B)} \geq 0. \quad (3.86)$$

3.11 Formulario di Sintesi del Capitolo

La tabella 3.1 riassume in modo organico le definizioni, le strutture matriciali e le proprietà algebriche analizzate nel presente capitolo.

Concetto / Matrice	Formulazione Matematica	Proprietà Salienti / Spettro
Colonne Ortonormali ($k < n$)	$V \in \mathbb{R}^{n \times k}$, $\mathbf{v}_i^T \mathbf{v}_j = \delta_{ij}$	$V^T V = I_k$, mentre $V V^T \neq I_n$
Proiettore Ortogonale	$P = V V^T = \sum_{i=1}^k \mathbf{v}_i \mathbf{v}_i^T$	Simmetrico ($P^T = P$), idempotente ($P^2 = P$), $\text{rank}(P) = k$
Isometria Parziale	$\ V \mathbf{x}\ _2 = \ \mathbf{x}\ _2 \quad (\forall \mathbf{x} \in \mathbb{R}^k)$	Non preserva la norma da $\mathbb{R}^n$: $\ V^T \tilde{\mathbf{y}}\ _2 = 0$ per $\tilde{\mathbf{y}} \in \ker(V^T)$
Autocoppia	$A \mathbf{v} = \lambda \mathbf{v}$, $\mathbf{v} \neq \mathbf{0}$	λ radice di $\det(A - \lambda I_n) = 0$
Diagonalizzazione	$A = V D V^{-1}$	Richiede n autovettori linearmente indipendenti
Espansione Diadica	$A = \sum_{i=1}^n \lambda_i \mathbf{v}_i \mathbf{w}_i^T$	Combinazione lineare di n matrici di rango 1
Potenza di Matrice	$A^k = V D^k V^{-1}$	Autocoppie $(\lambda_i^k, \mathbf{v}_i)$: autovettori invariati
Teorema Spettrale	$A^T = A \implies A = U D U^T$	Autovalori reali, autovettori ortonormali ($U^T U = I_n$)
Disuguaglianza di Rayleigh	$\lambda_{\min} \ \mathbf{x}\ _2^2 \leq \mathbf{x}^T A \mathbf{x} \leq \lambda_{\max} \ \mathbf{x}\ _2^2$	Estremi raggiunti sui corrispondenti autospazi
Matrice SPD	$A^T = A$, $\mathbf{x}^T A \mathbf{x} > 0 \quad (\forall \mathbf{x} \neq \mathbf{0})$	Tutti $\lambda_i > 0$; invertibile con $\det(A) > 0$
Matrice SPSD	$A^T = A$, $\mathbf{x}^T A \mathbf{x} \geq 0 \quad (\forall \mathbf{x})$	Tutti $\lambda_i \geq 0$; ammette autovalori nulli
Gramiani $B^T B$ e $B B^T$	$\mathbf{v}^T (B^T B) \mathbf{v} = \ B \mathbf{v}\ _2^2 \geq 0$	Sempre SPSD per ogni $B \in \mathbb{R}^{n \times m}$

Tabella 3.1: Quadro sinottico delle proprietà spettrali, proiettori ortogonali e forme quadratiche.

Parte II

Ottimizzazione Continua e Machine Learning

Bibliografia

- [1] Lloyd N. Trefethen and David Bau III. *Numerical Linear Algebra*. SIAM, Philadelphia, 1997.
- [2] Gene H. Golub and Charles F. Van Loan. *Matrix Computations*. Johns Hopkins University Press, Baltimore, 4th edition, 2013.