

Computational Mathematics for Learning and Data Analysis

Fondamenti Computazionali, Algebra Lineare Numerica e
Ottimizzazione

Anno Accademico 2026/2027

Indice

Sezione 0: Introduzione Generale ai Modelli Computazionali	1
0 Modelli Matematici del Machine Learning e Principi Computazionali	2
0.1 I Due Pilastri della Matematica Computazionale nel Machine Learning	2
0.2 La Filosofia della Modellazione Matematica: Brunelleschi e Galileo	3
0.3 Caratterizzazione e Tassonomia dei Modelli	4
0.4 I Quattro Modelli Matematici Cardine del Corso	7
0.5 Principi Metodologici dell'Apprendimento Computazionale . .	13
0.6 Formulario Sinottico dei Modelli Fondamentali	13
 I Algebra Lineare Numerica e Analisi dei Dati	 15
1 Richiami di Algebra Lineare: Vettori, Norme, Basi e Trasformazioni	16
1.1 Introduzione al Calcolo Numerico e Motivazioni Applicative .	16
1.2 Vettori, Spazi Vettoriali e Rappresentazione Geometrica	18
1.3 Norme Vettoriali e Spazi Normati	20
1.4 Prodotto Scalare Standard (Inner Product)	22
1.5 Basi di Spazi Vettoriali e Indipendenza Lineare	23
1.6 Esercitazione Guidata: Sfere Unitarie e Geometria delle Norme	25
1.7 Tre Visioni del Prodotto Matrice-Vettore	28
1.8 Matrici come Trasformazioni Lineari nel Piano	30
1.9 Introduzione alla Complessità Computazionale e Flops	31
1.10 Quadro Sinottico dei Concetti Fondamentali	33

2	Prodotto tra Matrici, Complessità Computazionale e Matrici Ortogonali	34
2.1	Moltiplicazione Matrice-Matrice	34
2.2	Complessità Computazionale e Legge di Scaling	36
2.3	Proprietà Fondamentali: Rango, Spazi Fondamentali e Invertibilità	38
2.4	Ortogonalità e Ortonormalità Vettoriale	41
2.5	Matrici Ortogonali	42
2.6	I Quattro Quesiti Notabili sulle Matrici Ortogonali	44
2.7	Formulario di Sintesi del Capitolo	48
3	Matrici Ortonormali, Autovalori e Forme Quadratiche	49
3.1	Richiamo sulle Matrici Ortogonali Quadrate e Isometria	49
3.2	Matrici Rettangolari a Colonne Ortonormali	50
3.3	Isometria Parziale per Matrici Rettangolari Ortonormali	53
3.4	Autovalori e Autovettori: Fondamenti ed Esempio Guida	55
3.5	Diagonalizzazione ed Espansione Diadica	56
3.6	Esercizi Guidati sugli Autovalori (Q1 – Q4)	59
3.7	Matrici Simmetriche e il Teorema Spettrale	62
3.8	Forme Quadratiche e Disuguaglianza di Rayleigh	63
3.9	Matrici Simmetriche Definite e Semidefinite Positive	65
3.10	Generazione Naturale di Matrici SPSD	68
3.11	Formulario di Sintesi del Capitolo	70
4	Decomposizione a Valori Singolari (SVD)	71
4.1	Panoramica dell'Algebra Lineare Numerica e Quadro Didattico	71
4.2	Definizione della Decomposizione a Valori Singolari (Full SVD)	73
4.3	Esistenza e Costruzione della SVD	77
4.4	Thin SVD vs Full SVD e Profilo Computazionale	81
4.5	Rango Numerico e i Quattro Sottospazi Fondamentali	84
4.6	Problemi ed Esercizi Applicativi Svolti	87
4.7	Formulario di Sintesi del Capitolo	93
5	SVD, Norme Matriciali e Applicazioni	94
5.1	Richiamo e Raccordo: Full SVD vs Thin SVD	95
5.2	Norme Matriciali e Norme Indotte	97
5.3	La Norma Spettrale (Norma 2 Matriciale)	99
5.4	La Norma di Frobenius	101
5.5	Generalizzazione a Matrici Complesse e Caso Simmetrico Reale	102
5.6	Il Problema dell'Approssimazione a Basso Rango e Teorema di Eckart-Young	104

5.7	Interpretazione Geometrica della SVD: Dalla Sfera all'Ellissoide	106
5.8	Applicazione 1: Compressione Digitale di Immagini via Truncated SVD	108
5.9	Applicazione 2: Analisi di Dati Tabulari e Rilevamento di Anomalie	110
5.10	Applicazione 3: Analisi delle Componenti Principali (PCA) tramite SVD	112
5.11	Formulario e Tavola Sinottica di Sintesi	115
 II Ottimizzazione Continua e Machine Learning		116
6	Problemi Elementari di Ottimizzazione Univariata	117
6.1	Introduzione, Motivazione e Obiettivi Didattici	117
6.2	Definizioni Fondamentali: Spazi, Funzioni, Grafi e Insiemi di Livello	118
6.3	Il Problema di Ottimizzazione Univariato Libero	120
6.4	Riformulazioni Semplici ed Equivalenza di Problemi	121
6.5	Ottimizzazione Vincolata e Regione Ammissibile	122
6.6	Perché l'Ottimizzazione è Difficile: Teoria vs Pratica Numerica	125
6.7	Ottimizzazione Univariata: Il Caso Lineare	128
6.8	L'Illusione degli Insiemi Aperti nel Calcolo Numerico	129
6.9	Ottimizzazione Univariata: Il Caso Quadratico Omogeneo	130
6.10	Ottimizzazione Univariata: Caso Quadratico Non Omogeneo	132
6.11	Formulario Sinottico dei Risultati Univariati	136
7	Ottimizzazione Multivariata: Geometria, Funzioni Lineari e Forme Quadratiche	137
7.1	Dall'Univariato al Multivariato: La Dimensionalità dello Spazio $\mathbb{R}^n$	137
7.2	Ottimizzazione Vettoriale e Multi-Obiettivo	139
7.3	Geometria Euclidea in $\mathbb{R}^n$ e Tomografia di Funzione	142
7.4	Funzioni Lineari Multivariate	143
7.5	Tomografia Lineare e Direzione di Massima Discesa	144
7.6	Dalle Funzioni Lineari alle Funzioni Quadratiche: Il Caso Separabile	147
7.7	La Forma Quadratica Generale Omogenea e la Simmetrizzazione	148
7.8	Decomposizione Spettrale e Tassonomia delle Matrici	150
7.9	Tomografia Spettrale nei Quattro Regimi	152
7.10	Geometria degli Insiemi di Livello	154
7.11	Ottimizzazione Quadratica: Libera vs Vincolata su Box	157

8	Ottimizzazione Quadratica Non Omogenea e GMQ	159
8.1	Ottimizzazione Quadratica Non Omogenea: Il Caso Non Singolare	160
8.2	Ottimizzazione Quadratica Non Omogenea: Il Caso Singolare	163
8.3	La Condizione di Ottimalità e il Legame con l'Algebra Lineare	167
8.4	Algoritmi Iterativi e il Metodo del Gradiente (GMQ)	168
8.5	Analisi Sperimentale e Dinamica delle Iterate	172
8.6	Quadro Sinottico Comparativo	176
9	Analisi di Convergenza e Complessità del Metodo del Gradiente	177
9.1	Algoritmi Iterativi e Successioni Minimizzanti	178
9.2	Il Metodo GMQ e Richiamo delle Proprietà Cardine	179
9.3	Forma Omogenea dell'Errore e Decadimento	180
9.4	Disuguaglianza di Kantorovich e Tasso di Convergenza Lineare	182
9.5	Complessità Computazionale e Tassi di Convergenza	183
9.6	Il Caso Singolare Semidefinito Positivo ($Q \geq 0$)	185
9.7	Rivelazione Computazionale di Problemi Illimitati	186
9.8	Limiti Inferiori di Complessità e Prospettive	187

Sezione 0: Introduzione Generale ai Modelli Computazionali

Capitolo 0

Modelli Matematici del Machine Learning e Principi Computazionali

0.1 I Due Pilastri della Matematica Computazionale nel Machine Learning

Il trattamento computazionale dell'apprendimento automatico e dell'analisi di grandi moli di dati si fonda su due discipline matematiche complementari e profondamente interconnesse [1]:

- **Algebra Lineare Numerica:** fornisce il linguaggio per descrivere le trasformazioni geometriche, proiettare i dati su sottospazi a dimensionalità ridotta, calcolare decomposizioni matriciali fondamentali (SVD, QR, Cholesky) e quantificare la propagazione degli errori floating-point tramite il numero di condizionamento [2, 3].
- **Ottimizzazione Matematica:** formalizza il processo decisionale attraverso la formulazione di problemi vincolati e non vincolati, studia le condizioni analitiche di ottimalità (teoremi di Fermat e condizioni di Karush-Kuhn-Tucker), investiga la dualità lagrangiana e progetta algoritmi iterativi di discesa scalabili [4, 5, 6].

Nelle applicazioni reali di Data Science, nessun modello di ottimizzazione può prescindere da algoritmi di algebra lineare stabili ed efficienti, poiché la risoluzione della direzione di discesa ad ogni passo iterativo si riconduce sistematicamente alla risoluzione di un sistema algebrico lineare.

FONDAMENTI DI COMPUTATIONAL MATHEMATICS FOR DATA ANALYSIS

I due fondamenti complementari dell'apprendimento automatico moderno

Algebra Lineare Numerica

IL MOTORE COMPUTAZIONALE

Geometria e Rappresentazione:

Basi ortonormali, sottospazi, proiettori ortogonali.

Fattorizzazioni Matriciali:

Valori singolari (SVD), spettrale, QR, Cholesky.

Stabilità e Trattamento Errori:

Condizionamento $\kappa(A)$, propagazione all'indietro.

Algoritmi su Larga Scala:

Solutori per matrici sparse, metodi di Krylov/Lanczos.

Ottimizzazione Matematica

IL FORMALISMO DECISIONALE

Formulazione dell'Apprendimento:

Rischio empirico, regolarizzazione, vincoli decisionali.

Condizioni di Ottimalità:

Punti stazionari, convessità globale, condizioni KKT.

Teoria della Dualità:

Duale di Lagrange, gap di dualità, metodi kernel.

Metodi di Discesa e Convergenza:

Gradiente, Newton, Quasi-Newton e direzioni scalate.

Punto di Confluenza Operativo: Il Ciclo Algoritmico del Machine Learning

L'ottimizzazione formula il problema (*cosa* minimizzare e sotto quali vincoli) e genera a ogni passo un sistema direzionale $\nabla^2 f(x)\Delta x = -\nabla f(x)$.

L'algebra lineare numerica fornisce gli algoritmi efficienti e stabili per risolverlo su miliardi di parametri (*come* calcolarlo computazionalmente).

Figura 1: Quadro concettuale sinergico: integrazione complementare tra Algebra Lineare Numerica e Ottimizzazione Matematica nel Machine Learning.

0.2 La Filosofia della Modellazione Matematica: Brunelleschi e Galileo

0.2.1 La Nascita del Modello: Dalla Prospettiva al Calcolo

Il processo di estrazione di conoscenza da grandi volumi di dati risponde a un'esigenza epistemologica precisa: i dati grezzi sono disorganizzati, cognitivamente inaccessibili all'uomo e incapaci di prendere decisioni autonome.

Definizione 0.2.1 (Modello Computazionale). L'apprendimento (*machine learning*) consiste nell'estrarre regolarità strutturali da insiemi di osservazioni empiriche per sintetizzarle in un artefatto matematico astratto

(**modello**), manipulabile computazionalmente e atto a generare predizioni o decisioni operative.

Questa impostazione affonda le sue radici nella storia della scienza:

- **Filippo Brunelleschi e la Prospettiva:** per innalzare l'ardita cupola di Santa Maria del Fiore a Firenze senza armature lignee da terra, Brunelleschi non procedette per tentativi ed errori in cantiere; costruì modelli matematici rigorosi (proiezioni geometriche basate sul cono ottico) capaci di descrivere le forze di spinta radiali.
- **L'Economicità della Matematica:** costruire modelli fisici in scala (es. gallerie del vento in aerodinamica) comporta costi materiali ingenti. **La matematica costa infinitamente meno del legno o dell'acciaio:** una formula o un algoritmo consentono di simulare miliardi di scenari operativi a costo computazionale trascurabile.
- **Galileo Galilei e l'Astrazione:** la fisica moderna nasce nel momento in cui si smette di descrivere passivamente la realtà in ogni dettaglio accidentale e si formula una legge astratta parsimoniosa espressa in linguaggio algebrico.

Definizione di Modello Matematico Computazionale

Un modello non è una copia esatta della realtà fisica. È una **formalizzazione matematica astratta** volta a catturare le relazioni causali o correlative essenziali del fenomeno, trascurando il rumore al fine di rendere il problema trattabile mediante algoritmi al calcolatore.

0.3 Caratterizzazione e Tassonomia dei Modelli

0.3.1 Il Triangolo dei Tre Requisiti Contraddittori

Nel concepire un modello computazionale si persegue idealmente la massimizzazione congiunta di tre proprietà:

1. **Accuratezza (Accurate):** capacità del modello di riprodurre fedelmente la fisica o il comportamento effettivo del sistema analizzato.
2. **Economicità Computazionale (Computationally Inexpensive):** semplicità algoritmica, traducibile in basso consumo di memoria e tempo di risoluzione contenuto (complessità lineare $\mathcal{O}(n)$ o quasi-lineare).

3. **Generalità (General)**: attitudine del modello a essere impiegato efficacemente su un ampio spettro di scenari e domini applicativi differenti.

Proprietà 0.3.1 (Principio di Incompatibilità dei Modelli). *È teoricamente e praticamente impossibile massimizzare simultaneamente tutti e tre i requisiti: modelli estremamente fedeli richiedono un numero sterminato di parametri che ne distrugge l'economicità computazionale; modelli parsimoniosi e rapidi sacrificano inevitabilmente l'accuratezza fine o la generalità. La formulazione di un modello è sempre un **compromesso ingegneristico (trade-off)**.*




Figura 2: Il triangolo dei requisiti contrastanti nella modellazione computazionale: accuratezza, economicità e generalità.

0.3.2 Modelli Analitici vs Modelli Guidati dai Dati (Data-Driven)

La tabella 1 riassume la demarcazione strutturale tra le due polarità della modellazione computazionale.

Proprietà	Approccio Analitico (White-Box)	Approccio Guidato dai Dati (Black-Box)
Principio Base	Modella analiticamente ogni singolo componente fisico e le sue interazioni differenziali.	Non descrive la meccanica interna del sistema; modella direttamente la relazione ingresso-uscita.
Struttura Matematica	Flessibile, non lineare, basata su principi primi fisici e leggi di conservazione.	Standardizzata, rigida, parametrica (es. reti neurali profonde, SVM, iperpiani lineari).
Trattamento Parametri	Pochi parametri calibrabili, dotati di preciso significato fisico intrinseco.	Enorme numero di parametri (da milioni a miliardi), stimati automaticamente via ottimizzazione.
Costo di Sviluppo	Elevato: richiede conoscenza di dominio avanzata e accesso interno al sistema.	Basso/scalabile: necessita di osservazioni storiche e algoritmi di ottimizzazione standardizzati.

Tabella 1: Confronto concettuale tra modellazione analitica basata su principi primi e modellazione empirica guidata dai dati.

0.3.3 Fitting vs Machine Learning: Rischio Empirico e Generalizzazione

Un modello è sempre un'approssimazione («*the map is not the territory*»):

- **Fitting (Minimizzazione del Rischio Empirico):** ricerca i parametri ottimali che minimizzano lo scostamento esclusivamente sui punti noti del campione di addestramento (*training set*):

$$\min_{\mathbf{w}} \mathcal{R}_{\text{emp}}(\mathbf{w}) = \frac{1}{m} \sum_{i=1}^m \ell(f(\mathbf{x}^i; \mathbf{w}), y^i). \quad (1)$$

- **Generalizzazione (Apprendimento):** richiede che $f(\mathbf{x}; \mathbf{w})$ mantenga un errore contenuto su dati non visti durante l'addestramento (*test set*). Un modello iper-parametrizzato che minimizza a zero l'errore empirico incorre nell'**overfitting**, catturando il rumore anziché il segnale.

0.4 I Quattro Modelli Matematici Cardine del Corso

0.4.1 Esempio 1: Stima Lineare e Minimi Quadrati

Dato un insieme di m osservazioni $(\mathbf{x}^i, y^i) \in \mathbb{R}^n \times \mathbb{R}$, si ipotizza una relazione lineare tra ingressi e uscita:

$$f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0 = \sum_{j=1}^n w_j x_j + w_0. \quad (2)$$

Inglobando il termine di bias w_0 nella matrice di progetto estesa X :

$$\mathbf{w}_{\text{ext}} = \begin{bmatrix} w_0 \\ \mathbf{w} \end{bmatrix} \in \mathbb{R}^{n+1}, \quad X = \begin{bmatrix} 1 & (\mathbf{x}^1)^T \\ \vdots & \vdots \\ 1 & (\mathbf{x}^m)^T \end{bmatrix} \in \mathbb{R}^{m \times (n+1)}, \quad \mathbf{y} = \begin{bmatrix} y^1 \\ \vdots \\ y^m \end{bmatrix} \in \mathbb{R}^m. \quad (3)$$

Il problema dei minimi quadrati lineari consiste nel risolvere:

$$\min_{\mathbf{w}} \mathcal{L}(\mathbf{w}) = \|\mathbf{y} - X\mathbf{w}\|_2^2 = \mathbf{y}^T \mathbf{y} - 2\mathbf{w}^T X^T \mathbf{y} + \mathbf{w}^T X^T X \mathbf{w}. \quad (4)$$

Annullando il gradiente rispetto a $\mathbf{w}$ si perviene alla condizione di stazionarietà, nota come **Equazioni Normali di Gauss**:

$$\nabla \mathcal{L}(\mathbf{w}) = -2X^T \mathbf{y} + 2X^T X \mathbf{w} = \mathbf{0} \implies X^T X \mathbf{w} = X^T \mathbf{y}. \quad (5)$$

Se la matrice X ha rango pieno per colonne ($\text{rank}(X) = n + 1$), il gramiano $X^T X$ è simmetrico, strettamente definito positivo e invertibile:

$$\mathbf{w}^* = (X^T X)^{-1} X^T \mathbf{y}. \quad (6)$$

Regola Aurea Numerica: Mai Calcolare $(X^T X)^{-1}$

Nel calcolo scientifico professionale **non si forma mai la matrice $X^T X$ né si calcola la sua inversa esplicita**. L'operazione di prodotto moltiplica al quadrato il numero di condizionamento ($\kappa(X^T X) = \kappa(X)^2$), amplificando catastroficamente gli errori di arrotondamento floating-point. La soluzione si calcola stabilmente mediante fattorizzazione QR o decomposizione SVD (operatore backslash in GNU Octave: $\mathbf{w} = \mathbf{X} \backslash \mathbf{y}$).

0.4.2 Esempio 2: Approssimazione di Basso Rango e Sistemi di Raccomandazione

Sia data una matrice dati $M \in \mathbb{R}^{n \times m}$ parzialmente osservata (es. n utenti e m film su una piattaforma, dove M_{ij} rappresenta il punteggio assegnato). Si cerca una fattorizzazione di rango ridotto $k \ll \min(n, m)$ tale che $M \approx AB$:

$$A \in \mathbb{R}^{n \times k}, \quad B \in \mathbb{R}^{k \times m} \implies \min_{A, B} \|M - AB\|_F^2 = \sum_{i=1}^n \sum_{j=1}^m (M_{ij} - (AB)_{ij})^2. \quad (7)$$




Figura 3: Fattorizzazione matriciale a basso rango: compressione da nm locazioni a $k(n + m)$.

Compressione di Memoria e Proprietà Spettrali

Memorizzare M densamente richiede $n \cdot m$ locazioni; memorizzare A e B richiede $k(n + m)$ valori. Ad esempio, per $n = 10^6$, $m = 10^5$ e rango $k = 10$:

$$\text{Memoria originaria} = 10^6 \times 10^5 = 10^{11} \text{ celle}, \quad (8)$$

$$\text{Fattorizzata} = 10 \times (10^6 + 10^5) \approx 1.1 \times 10^7 \text{ celle}, \quad (9)$$

ottenendo un **abbattimento dello spazio occupato del 99.99%**.

In virtù del Teorema di Eckart-Young-Mirsky, la soluzione ottima in norma di Frobenius è data dalla Decomposizione a Valori Singolari (SVD) troncata.

Avvertenza Computazionale su Matrici Sparse

Se M è sparsa, è **tassativo non formare mai** $M^T M$ né MM^T . Il prodotto matriciale distrugge la sparsità generando una matrice densa che esaurisce all'istante la RAM di sistema (*Out Of Memory*). Si impiegano esclusivamente metodi iterativi a blocchi basati su prodotti matrice-vettore (metodi di Lanczos).

0.4.3 Esempio 3: Support Vector Machines (SVM) — Margine, Dualità e Kernel

Nel contesto della classificazione binaria supervisionata con etichette $y^h \in \{-1, +1\}$, un classificatore lineare assegna la classe mediante la regola di decisione $\hat{y} = \text{sign}(\mathbf{w}_+^T \mathbf{x} - w_0)$.




Figura 4: Geometria del margine nelle Support Vector Machines lineari: massimizzazione della distanza ortogonale tra gli iperpiani di supporto.

Massimizzare il margine geometrico $2/\|\mathbf{w}_+\|_2$ equivale a minimizzare il semiquadrato della norma del vettore dei pesi:

$$\min_{\mathbf{w}_+, w_0} \frac{1}{2} \|\mathbf{w}_+\|_2^2 \quad \text{s.t.} \quad y^h (\mathbf{w}_+^T \mathbf{x}^h - w_0) \geq 1 \quad \forall h = 1, \dots, m. \quad (10)$$

Per dati non perfettamente separabili, si introducono variabili di rilassamento $\xi_h \geq 0$ (*slack variables*), pervenendo al modello a margine morbido (**Soft Margin**):

$$\begin{aligned} \min_{\mathbf{w}_+, w_0, \xi} \quad & \frac{1}{2} \|\mathbf{w}_+\|_2^2 + C \sum_{h=1}^m \xi_h \\ \text{s.t.} \quad & y^h(\mathbf{w}_+^T \mathbf{x}^h - w_0) \geq 1 - \xi_h, \quad \xi_h \geq 0 \quad \forall h = 1, \dots, m. \end{aligned} \quad (11)$$

Il parametro $C > 0$ governa il trade-off bias-varianza: per $C \rightarrow \infty$ si impone la separazione rigida, mentre valori finiti consentono violazioni controllate a beneficio della generalizzazione su dati di test.

Lifting Non Lineare, Dualità e Kernel Trick

Qualora i punti non siano separabili linearmente nello spazio originario $\mathbb{R}^n$, si applica un'immersione non lineare $\phi : \mathbb{R}^n \rightarrow \mathcal{H}$ verso uno spazio delle caratteristiche a dimensionalità superiore (*lifting*):

$$\mathbf{x} \mapsto \phi(\mathbf{x}). \quad (12)$$

Formulando il problema duale di Lagrange (dualità di Wolfe):

$$\begin{aligned} \max_{\alpha} \quad & \sum_{h=1}^m \alpha_h - \frac{1}{2} \sum_{h=1}^m \sum_{k=1}^m \alpha_h \alpha_k y^h y^k \langle \phi(\mathbf{x}^h), \phi(\mathbf{x}^k) \rangle_{\mathcal{H}} \\ \text{s.t.} \quad & \sum_{h=1}^m y^h \alpha_h = 0, \quad 0 \leq \alpha_h \leq C \quad \forall h = 1, \dots, m. \end{aligned} \quad (13)$$

Poiché i dati intervengono unicamente tramite prodotti scalari, in virtù del Teorema di Mercer si adotta una **funzione kernel** $K(\mathbf{x}^h, \mathbf{x}^k) = \langle \phi(\mathbf{x}^h), \phi(\mathbf{x}^k) \rangle_{\mathcal{H}}$. Ad esempio, il **Kernel Gaussiano RBF**:

$$K(\mathbf{x}, \mathbf{z}) = \exp(-\gamma \|\mathbf{x} - \mathbf{z}\|_2^2) \quad (14)$$

corrisponde a uno spazio di Hilbert $\mathcal{H}$ a dimensione infinita, computabile con costo $\mathcal{O}(n)$ senza mai materializzare esplicitamente $\phi(\mathbf{x})$.

0.4.4 Esempio 4: Clustering e Algoritmo K-Means

Dato un dataset non etichettato $X = \{\mathbf{x}^1, \dots, \mathbf{x}^m\} \subset \mathbb{R}^h$, il clustering mira a partizionare X in k cluster disgiunti $\{X_p\}_{p=1}^k$ massimizzando la coesione interna.

Formulazione Ottimizzatoria Biconvessa

Introducendo k centroidi $\mathbf{c}^1, \dots, \mathbf{c}^k \in \mathbb{R}^h$ e le variabili binarie di appartenenza $z_{ip} \in \{0, 1\}$:

$$\min_{\mathbf{c}, Z} \sum_{i=1}^m \sum_{p=1}^k z_{ip} \|\mathbf{c}^p - \mathbf{x}^i\|_2^2 \quad \text{s.t.} \quad \sum_{p=1}^k z_{ip} = 1 \quad \forall i, \quad z_{ip} \in \{0, 1\} \quad \forall i, p. \quad (15)$$

Il problema è fortemente non convesso a causa dell'interezza $z_{ip} \in \{0, 1\}$ e del termine bilineare $z_{ip}\mathbf{c}^p$. Tuttavia, possiede una struttura biconvessa separabile che abilita l'ottimizzazione a **blocchi alternati (Block Gauss-Seidel)**:

1. **Fissato $\mathbf{c}$, si ottimizza Z :** ciascun punto viene assegnato al centroide più vicino in norma euclidea ($z_{i\bar{p}} = 1 \iff \bar{p} = \arg \min_p \|\mathbf{c}^p - \mathbf{x}^i\|_2^2$).
2. **Fissato Z , si ottimizza $\mathbf{c}$:** per ciascun cluster p , annullando il gradiente quadratico convesso rispetto a $\mathbf{c}^p$:

$$2 \sum_{i \in I(p)} (\mathbf{c}^p - \mathbf{x}^i) = \mathbf{0} \implies (\mathbf{c}^p)^* = \frac{1}{|I(p)|} \sum_{i \in I(p)} \mathbf{x}^i. \quad (16)$$

Il centroide ottimo è analiticamente il **baricentro (media vettoriale)** dei punti appartenenti al cluster.

Algorithm 1: Algoritmo K-Means per Clustering Euclideo

Dati: Dataset $X = \{\mathbf{x}^1, \dots, \mathbf{x}^m\} \subset \mathbb{R}^h$, numero di cluster k ,
centroidi iniziali $\mathbf{c}^1, \dots, \mathbf{c}^k$, tolleranza $\epsilon > 0$

Risultato: Centroidi finali $\mathbf{c}^1, \dots, \mathbf{c}^k$ e partizione $\{I(p)\}_{p=1}^k$

```
1  $v \leftarrow \infty$ 
2 repeat
3   // Fase 1: Assegnamento dei punti ai centroidi
4   for  $p \leftarrow 1$  to  $k$  do
5      $I(p) \leftarrow \emptyset$ 
6   for  $i \leftarrow 1$  to  $m$  do
7      $p^* \leftarrow \arg \min_{p \in \{1, \dots, k\}} \|\mathbf{c}^p - \mathbf{x}^i\|_2^2$ 
8      $I(p^*) \leftarrow I(p^*) \cup \{i\}$ 
9   // Fase 2: Aggiornamento dei centroidi (baricentro)
10  for  $p \leftarrow 1$  to  $k$  do
11    if  $I(p) \neq \emptyset$  then
12       $\mathbf{c}^p \leftarrow \frac{1}{|I(p)|} \sum_{i \in I(p)} \mathbf{x}^i$ 
13  // Fase 3: Valutazione obiettivo
14   $v_{\text{new}} \leftarrow \sum_{p=1}^k \sum_{i \in I(p)} \|\mathbf{c}^p - \mathbf{x}^i\|_2^2$ 
15   $v \leftarrow v_{\text{new}}$ 
16 until  $(v - v_{\text{new}}) \leq \epsilon$ 
17 return  $\mathbf{c}^1, \dots, \mathbf{c}^k$ 
```

Perché il Calcolo Scientifico Viola il Paradigma Agile

Nello sviluppo software tradizionale (Agile), un sistema complesso viene suddiviso in componenti modulari indipendenti modificabili isolatamente. Nel calcolo scientifico ciò non è possibile:

- Se si sostituisce la metrica euclidea ℓ_2 con la distanza Manhattan ℓ_1 , la forma chiusa del baricentro decade: l'ottimo per ℓ_1 non è più la media aritmetica, bensì la **mediana componente per componente**.
- L'interdipendenza tra la funzione di costo e l'algoritmo di aggiornamento impone una progettazione matematica globale ed integrata.

0.5 Principi Metodologici dell'Apprendimento Computazionale

0.5.1 La Metafora della “Magic Academy”

Per chiarire la distinzione tra l'impiego superficiale di strumenti predefiniti e la reale competenza scientifica, si consideri la metafora della **Magic Academy**:

- **L'Apprendista Stregone (*Black-Box Practitioner*):** invoca funzioni di alto livello (`import sklearn, fit(), predict()`) come formule magiche precostituite. Fin quando i dati sono ideali ottiene risultati apparentemente corretti; tuttavia, di fronte a instabilità numerica, perdita di convergenza o mal condizionamento, non possiede gli strumenti per comprendere la causa del fallimento.
- **Il Maestro Mago (*Computational Scientist*):** conosce le proprietà spettrali delle matrici e la teoria della convergenza, riconosce quando un problema è mal posto, valuta la propagazione degli errori floating-point e sostituisce algoritmi instabili con routine numericamente solide.

0.5.2 I Tre Principi Guida del Machine Learning

1. **L'Apprendimento è Calcolo Numerico:** Ogni algoritmo di intelligenza artificiale si riduce, in ultima istanza, alla risoluzione di un sistema algebrico lineare o alla minimizzazione di una funzione di costo.
2. **La Sfida Dimensionale:** I problemi del machine learning non sono teoricamente intrattabili: sono quasi sempre formulazioni lineari o convesse. **La loro difficoltà risiede esclusivamente nella scala colossale** (*«hard because large, not hard because hard»*), con milioni o miliardi di variabili.
3. **L'Algebra Lineare come Motore dell'Ottimizzazione:** Risolvere problemi su scala titanica richiede l'uso efficiente dell'hardware: l'algebra lineare numerica rappresenta il motore computazionale irrinunciabile che rende l'ottimizzazione rapida, scalabile e priva di instabilità.

0.6 Formulario Sinottico dei Modelli Fondamentali

La tabella 2 sintetizza i quattro modelli matematici esaminati e le relative proprietà computazionali.

Modello	Formulazione	Paradigma	Note Computazionali
Minimi Quadrati	$\min_{\mathbf{w}} \ \mathbf{y} - X\mathbf{w}\ _2^2$	Equazioni normali: $\mathbf{w}^* = (X^T X)^{-1} X^T \mathbf{y}$	Risolvere via fattorizzazione QR; mai invertire $X^T X$ esplicitamente.
Basso Rango	$\min_{A,B} \ M - AB\ _F^2$	Decomposizione SVD troncata (Eckart-Young)	Compressione $nm \rightarrow k(n+m)$; evitare $M^T M$ per matrici sparse.
SVM (Hard)	$\min \frac{1}{2} \ \mathbf{w}_+\ _2^2$ s.t. $y^h(\mathbf{w}_+^T \mathbf{x}^h - w_0) \geq 1$	Programma quadratico convesso (QP)	Massimizza il margine geometrico $2/\ \mathbf{w}_+\ _2$ a separazione rigida.
SVM (Soft)	$\min \frac{1}{2} \ \mathbf{w}_+\ _2^2 + C \sum \xi_h$ s.t. $y^h(\mathbf{w}_+^T \mathbf{x}^h - w_0) \geq 1 - \xi_h$	QP con vincoli lineari (equivalente a Hinge loss)	Parametro $C > 0$ governa il trade-off bias-varianza tollerando violazioni.
SVM (Kernel)	$\max_{\boldsymbol{\alpha}} \mathbf{1}^T \boldsymbol{\alpha} - \frac{1}{2} \boldsymbol{\alpha}^T \tilde{K} \boldsymbol{\alpha}$ s.t. $\mathbf{y}^T \boldsymbol{\alpha} = 0, 0 \leq \alpha_h \leq C$	QP con vincoli a scatola (<i>box constraints</i>)	Prodotti scalari in spazi di Hilbert $\mathcal{H}$ a dimensione infinita (RBF) in $\mathcal{O}(n)$.
K-Means	$\min \sum_{i,p} z_{ip} \ \mathbf{c}^p - \mathbf{x}^i\ _2^2$ s.t. $\sum_p z_{ip} = 1, z_{ip} \in \{0, 1\}$	Minimizzazione alternata (Block Gauss-Seidel)	Convergenza a minimo locale; baricentri calcolati in forma analitica chiusa.

Tabella 2: Formulario sinottico dei modelli matematici introduttivi e delle rispettive proprietà computazionali.

Parte I

**Algebra Lineare Numerica e
Analisi dei Dati**

Capitolo 1

Richiami di Algebra Lineare: Vettori, Norme, Basi e Trasformazioni

1.1 Introduzione al Calcolo Numerico e Motivazioni Applicative

Il corso affronta la risoluzione computazionale ed efficiente dei problemi tipici dell'algebra lineare su calcolatori elettronici [2, 7]. Nella matematica applicata, nella scienza dei dati e nel machine learning, la formulazione generale di un problema decisionale assume la forma di un'ottimizzazione:

$$\min_{\mathbf{x} \in S} f(\mathbf{x}), \quad (1.1)$$

dove $f : \mathbb{R}^n \rightarrow \mathbb{R}$ denota la funzione obiettivo e $S \subseteq \mathbb{R}^n$ definisce l'insieme ammissibile dei vincoli.

Nell'ambito dell'algebra lineare numerica (*Numerical Linear Algebra*), tale formulazione generale viene frequentemente ricondotta o approssimata tramite il problema lineare ai minimi quadrati (*least squares problem*):

$$\min_{\mathbf{x} \in \mathbb{R}^n} \|A\mathbf{x} - \mathbf{b}\|_2^2, \quad (1.2)$$

dove $A \in \mathbb{R}^{m \times n}$ rappresenta la matrice del modello o dei dati, $\mathbf{b} \in \mathbb{R}^m$ il vettore dei termini noti (o target osservati) e $\mathbf{x} \in \mathbb{R}^n$ l'incognita da stimare.

Perché Focalizzarsi sui Problemi Lineari?

I motivi cardine che rendono lo studio dei problemi lineari insostituibile nel calcolo scientifico moderno sono molteplici:

1. **Trattabilità teorica e chiarezza analitica:** I problemi lineari godono di una struttura algebrica pulita e ben compresa; ciò consente di formulare garanzie a priori sull'esistenza, unicità e convergenza delle soluzioni.
2. **Efficienza e precisione di macchina:** È possibile progettare algoritmi diretti o iterativi in grado di determinare la soluzione numerica fino alla precisione limite dell'aritmetica di macchina (standard IEEE 754 a virgola mobile, $\epsilon_{\text{mach}} \approx 10^{-16}$ in doppia precisione).
3. **Sfruttamento di strutture matriciali speciali:** Matrici reali caratterizzate da proprietà specifiche (simmetriche, definite positive, ortogonali, a bande, di Toeplitz o fortemente sparse) ammettono algoritmi dedicati con complessità temporale e spaziale drasticamente ridotta rispetto ai metodi generici.
4. **Blocco costitutivo di algoritmi non lineari:** La quasi totalità dei metodi numerici avanzati per problemi non lineari complessi (metodi di Newton, Quasi-Newton come BFGS, algoritmi di ottimizzazione vincolata e discretizzazione di equazioni differenziali) richiede la risoluzione di uno o più sistemi lineari a ogni singola iterazione.
5. **Stabilità e controllo dell'errore:** Nel calcolo applicato è essenziale prevenire fenomeni di propagazione incontrollata degli errori di arrotondamento, instabilità algoritmica o cancellazione numerica distruttiva.

1.2 Vettori, Spazi Vettoriali e Rappresentazione Geometrica

1.2.1 Notazione e Convenzioni

Salvo diversa indicazione esplicita, **tutti i vettori sono considerati vettori colonna**. Un vettore $\mathbf{x} \in \mathbb{R}^n$ si denota:

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}, \quad \mathbf{x}^T = \begin{bmatrix} x_1 & x_2 & \dots & x_n \end{bmatrix}. \quad (1.3)$$

Consideriamo, a titolo esemplificativo in $\mathbb{R}^2$, i vettori:

$$\mathbf{x} = \begin{bmatrix} 2 \\ 4 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}. \quad (1.4)$$

L'operazione fondamentale che definisce la struttura di spazio vettoriale è la somma componente per componente:

$$\mathbf{x} + \mathbf{y} = \begin{bmatrix} 2 \\ 4 \end{bmatrix} + \begin{bmatrix} 2 \\ 1 \end{bmatrix} = \begin{bmatrix} 2+2 \\ 4+1 \end{bmatrix} = \begin{bmatrix} 4 \\ 5 \end{bmatrix}. \quad (1.5)$$

1.2.2 Interpretazione Geometrica: Punti, Frecce e Regola del Parallelogramma

Un vettore $\mathbf{x} = [x_1, x_2]^T \in \mathbb{R}^2$ ammette una duplice interpretazione geometrica:

- come **punto** nel piano cartesiano con coordinate (x_1, x_2) rispetto all'origine;
- come **freccia orientata** (segmento orientato) avente punto di applicazione nell'origine $(0, 0)$ e vertice in (x_1, x_2) .

La somma vettoriale $\mathbf{x} + \mathbf{y}$ corrisponde alla classica **regola del parallelogramma**: traslando l'origine di $\mathbf{y}$ sulla punta di $\mathbf{x}$, il vettore risultante connette l'origine con il vertice opposto del parallelogramma individuato dai due vettori, terminando nel punto $(4, 5)$. Tale nozione si estende inalterata agli spazi euclidei di dimensione $n \geq 3$.




Figura 1.1: Interpretazione geometrica della somma vettoriale in $\mathbb{R}^2$ tramite la regola del parallelogramma.

1.2.3 Il Problema della Misura della “Grandezza” di un Vettore

Si consideri la seguente domanda apparentemente elementare:

Dati i vettori $\mathbf{v}, \mathbf{w} \in \mathbb{R}^4$:

$$\mathbf{v} = \begin{bmatrix} 2 \\ 2 \\ 2 \\ 2 \end{bmatrix}, \quad \mathbf{w} = \begin{bmatrix} 4 \\ 0 \\ 0 \\ 0 \end{bmatrix}, \quad (1.6)$$

quale tra questi due vettori è il “più grande”?

La risposta non è univoca, poiché la nozione di “grandezza” dipende criticamente dal criterio matematico adottato:

- In base al **valore massimo delle coordinate**, $\mathbf{w}$ presenta un elemento pari a 4, mentre gli elementi di $\mathbf{v}$ non superano 2.
- In base alla **somma assoluta delle coordinate**, $\mathbf{v}$ totalizza $2 + 2 + 2 + 2 = 8$, mentre $\mathbf{w}$ raggiunge appena 4.
- In base alla **lunghezza geometrica euclidea**, entrambi misurano $\sqrt{16} = 4$.

Per rendere quantitativo e inequivocabile questo confronto occorre formalizzare la nozione di **norma vettoriale**.

1.3 Norme Vettoriali e Spazi Normati

Definizione 1.3.1 (Norma Vettoriale). Sia V uno spazio vettoriale su $\mathbb{R}$ (o $\mathbb{C}$). Una funzione $\|\cdot\| : V \rightarrow \mathbb{R}$ è detta **norma vettoriale** se e solo se soddisfa i seguenti tre assiomi per ogni $\mathbf{v}, \mathbf{w} \in V$ e ogni scalare $\lambda \in \mathbb{R}$:

1. **Non-negatività e positività stretta (separazione):**

$$\|\mathbf{v}\| \geq 0 \quad \forall \mathbf{v} \in V, \quad \|\mathbf{v}\| = 0 \iff \mathbf{v} = \mathbf{0}_V. \quad (1.7)$$

2. **Omogeneità assoluta:**

$$\|\lambda \mathbf{v}\| = |\lambda| \cdot \|\mathbf{v}\| \quad \forall \lambda \in \mathbb{R}, \forall \mathbf{v} \in V. \quad (1.8)$$

3. **Disuguaglianza triangolare (sub-additività):**

$$\|\mathbf{v} + \mathbf{w}\| \leq \|\mathbf{v}\| + \|\mathbf{w}\| \quad \forall \mathbf{v}, \mathbf{w} \in V. \quad (1.9)$$

Uno spazio vettoriale V equipaggiato con una norma $\|\cdot\|$ prende il nome di **spazio normato**.

1.3.1 Famiglia delle ℓ_p -Norme su $\mathbb{R}^n$

Sia $\mathbf{v} = [v_1, v_2, \dots, v_n]^T \in \mathbb{R}^n$. Le norme più frequentemente utilizzate nell'analisi numerica e nei modelli di apprendimento appartengono alla classe delle ℓ_p -norme:

$$\|\mathbf{v}\|_p = \left(\sum_{i=1}^n |v_i|^p \right)^{1/p} \quad (p \geq 1). \quad (1.10)$$

I tre casi d'uso canonici corrispondono a:

1. **Norma Euclidea (ℓ_2).** Rappresenta la naturale lunghezza euclidea del segmento nello spazio affine:

$$\|\mathbf{v}\|_2 = \sqrt{\sum_{i=1}^n v_i^2} = \sqrt{\mathbf{v}^T \mathbf{v}}. \quad (1.11)$$

2. **Norma di Manhattan (ℓ_1 o Taxi-cab).** Calcola la somma dei moduli delle singole coordinate:

$$\|\mathbf{v}\|_1 = \sum_{i=1}^n |v_i|. \quad (1.12)$$

3. Norma del Massimo (ℓ_∞ o Norma di Chebyshev). Rileva la massima magnitudine assoluta tra tutte le componenti:

$$\|\mathbf{v}\|_\infty = \lim_{p \rightarrow \infty} \|\mathbf{v}\|_p = \max_{1 \leq i \leq n} |v_i|. \quad (1.13)$$

1.3.2 Risoluzione Rigorosa del Confronto tra i Vettori $\mathbf{v}$ e $\mathbf{w}$

Riprendiamo i vettori $\mathbf{v} = [2, 2, 2, 2]^T$ e $\mathbf{w} = [4, 0, 0, 0]^T \in \mathbb{R}^4$:

Esempio 1.3.1 (Valutazione Comparativa nelle Tre Norme).

- **In norma euclidea ℓ_2 :**

$$\|\mathbf{v}\|_2 = \sqrt{2^2 + 2^2 + 2^2 + 2^2} = \sqrt{4 + 4 + 4 + 4} = \sqrt{16} = 4, \quad (1.14)$$

$$\|\mathbf{w}\|_2 = \sqrt{4^2 + 0^2 + 0^2 + 0^2} = \sqrt{16 + 0 + 0 + 0} = \sqrt{16} = 4. \quad (1.15)$$

I due vettori possiedono esattamente la **stessa lunghezza euclidea**:
 $\|\mathbf{v}\|_2 = \|\mathbf{w}\|_2 = 4$.

- **In norma ℓ_1 :**

$$\|\mathbf{v}\|_1 = |2| + |2| + |2| + |2| = 8, \quad (1.16)$$

$$\|\mathbf{w}\|_1 = |4| + |0| + |0| + |0| = 4. \quad (1.17)$$

In norma ℓ_1 , risulta $\|\mathbf{v}\|_1 = 8 > 4 = \|\mathbf{w}\|_1$.

- **In norma ℓ_∞ :**

$$\|\mathbf{v}\|_\infty = \max\{|2|, |2|, |2|, |2|\} = 2, \quad (1.18)$$

$$\|\mathbf{w}\|_\infty = \max\{|4|, |0|, |0|, |0|\} = 4. \quad (1.19)$$

In norma infinito, l'ordinamento si inverte: $\|\mathbf{v}\|_\infty = 2 < 4 = \|\mathbf{w}\|_\infty$.

Criteri di Selezione della Norma nei Problemi Reali

La scelta della norma non è una mera preferenza formale, ma governa le proprietà matematiche del modello:

- **Trattabilità analitica e differenziabilità:** La norma euclidea quadra $\|\cdot\|_2^2$ è ovunque liscia e differenziabile, e la sua minimizzazione conduce a sistemi di equazioni lineari chiusi (equazioni normali).
- **Sparsità delle soluzioni:** La norma ℓ_1 non è differenziabile nell'origine ed induce soluzioni a supporto compatto (vettori sparsi), risultando fondamentale in statistica (Lasso) e nell'elaborazione di segnali (*compressed sensing*).
- **Limitazione del picco d'errore:** La norma ℓ_∞ trova impiego nell'approssimazione minimax e nel controllo ottimo, dove conta garantire un limite assoluto sul peggior scostamento possibile.

1.4 Prodotto Scalare Standard (Inner Product)

Definizione 1.4.1 (Prodotto Scalare in $\mathbb{R}^n$). Dati due vettori colonna $\mathbf{v}, \mathbf{w} \in \mathbb{R}^n$, il **prodotto scalare standard** (o *inner product*) è l'applicazione bilineare definita da:

$$\langle \mathbf{v}, \mathbf{w} \rangle = \mathbf{v}^T \mathbf{w} = \sum_{i=1}^n v_i w_i = v_1 w_1 + v_2 w_2 + \cdots + v_n w_n. \quad (1.20)$$

1.4.1 Notazione Matriciale e Dimensione del Risultato

Poiché $\mathbf{v}, \mathbf{w} \in \mathbb{R}^{n \times 1}$, la trasposta $\mathbf{v}^T$ è una matrice riga di tipo $1 \times n$:

$$\mathbf{v}^T = \begin{bmatrix} v_1 & v_2 & \cdots & v_n \end{bmatrix}, \quad \mathbf{w} = \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_n \end{bmatrix}. \quad (1.21)$$

Il prodotto riga per colonna $\mathbf{v}^T \mathbf{w}$ produce formalmente una matrice scalare 1×1 :

$$\mathbf{v}^T \mathbf{w} = \begin{bmatrix} v_1 & v_2 & \dots & v_n \end{bmatrix} \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_n \end{bmatrix} = \sum_{i=1}^n v_i w_i \in \mathbb{R}. \quad (1.22)$$

Proprietà 1.4.1 (Legame Diretto con la Norma Euclidea). *Il prodotto scalare di un vettore con se stesso restituisce il quadrato della sua norma euclidea:*

$$\langle \mathbf{v}, \mathbf{v} \rangle = \mathbf{v}^T \mathbf{v} = \sum_{i=1}^n v_i^2 = \|\mathbf{v}\|_2^2 \implies \|\mathbf{v}\|_2 = \sqrt{\langle \mathbf{v}, \mathbf{v} \rangle} = \sqrt{\mathbf{v}^T \mathbf{v}}. \quad (1.23)$$

Inoltre, due vettori non nulli si dicono **ortogonali** se e solo se $\langle \mathbf{v}, \mathbf{w} \rangle = 0$.

1.5 Basi di Spazi Vettoriali e Indipendenza Lineare

Definizione 1.5.1 (Combinazione Lineare). Dato un insieme ordinato di vettori $\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k\} \subseteq V$ e un insieme di scalari $\alpha_1, \alpha_2, \dots, \alpha_k \in \mathbb{R}$, la **combinazione lineare** associata è il vettore:

$$\mathbf{v} = \sum_{i=1}^k \alpha_i \mathbf{v}_i = \alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \dots + \alpha_k \mathbf{v}_k. \quad (1.24)$$

Definizione 1.5.2 (Base di uno Spazio Vettoriale). Un sottoinsieme ordinato $\mathcal{B} = \{\mathbf{v}_1, \dots, \mathbf{v}_k\} \subseteq V$ costituisce una **base** di V se ogni elemento $\mathbf{v} \in V$ può essere espresso come combinazione lineare dei vettori di $\mathcal{B}$ in **modo unico**.

1.5.1 Esempi Notabili di Basi

1. Base Canonica (Standard). In $\mathbb{R}^n$, i vettori della base canonica $\mathbf{e}_1, \dots, \mathbf{e}_n$ presentano valore 1 nella posizione corrispondente all'indice e 0 altrove:

$$\mathbf{e}_1 = \begin{bmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix}, \quad \mathbf{e}_2 = \begin{bmatrix} 0 \\ 1 \\ \vdots \\ 0 \end{bmatrix}, \quad \dots, \quad \mathbf{e}_n = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 1 \end{bmatrix}. \quad (1.25)$$

Ogni vettore $\mathbf{x} = [x_1, \dots, x_n]^T$ ammette l'espansione canonica immediata $\mathbf{x} = \sum_{i=1}^n x_i \mathbf{e}_i$.

2. Base Non Canonica in $\mathbb{R}^2$. Si consideri la coppia di vettori in $\mathbb{R}^2$:

$$\mathcal{B} = \left\{ \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ -1 \end{bmatrix} \right\}. \quad (1.26)$$

Per verificare che $\mathcal{B}$ sia una base, mostriamo che per ogni $[x, y]^T \in \mathbb{R}^2$ esistono unici scalari $\alpha_1, \alpha_2 \in \mathbb{R}$ tali che:

$$\begin{bmatrix} x \\ y \end{bmatrix} = \alpha_1 \begin{bmatrix} 1 \\ 0 \end{bmatrix} + \alpha_2 \begin{bmatrix} 1 \\ -1 \end{bmatrix} = \begin{bmatrix} \alpha_1 + \alpha_2 \\ -\alpha_2 \end{bmatrix}. \quad (1.27)$$

Il sistema lineare triangolare risultante:

$$\begin{cases} \alpha_1 + \alpha_2 = x \\ -\alpha_2 = y \end{cases} \implies \begin{cases} \alpha_2 = -y \\ \alpha_1 = x + y \end{cases} \quad (1.28)$$

ammette soluzione unica per qualsiasi scelta di (x, y) . I coefficienti cercati sono univocamente $(\alpha_1, \alpha_2) = (x + y, -y)$, dimostrando che $\mathcal{B}$ è una base valida.

1.5.2 Indipendenza Lineare e Criteri di Cardinalità

Definizione 1.5.3 (Indipendenza Lineare). Un insieme di vettori $\{\mathbf{v}_1, \dots, \mathbf{v}_k\}$ si dice **linearmente indipendente** se l'unica combinazione lineare che genera il vettore nullo è quella banale:

$$\sum_{i=1}^k \alpha_i \mathbf{v}_i = \mathbf{0}_V \implies \alpha_1 = \alpha_2 = \dots = \alpha_k = 0. \quad (1.29)$$

Se esistono coefficienti non tutti nulli per cui la somma si annulla, i vettori sono detti **linearmente dipendenti**.

Esempio 1.5.1 (Quesiti di Verifica dell'Indipendenza Lineare). Illustriamo mediante due quesiti pratici la verifica dell'indipendenza lineare e della nozione di base:

1. **Tre vettori in $\mathbb{R}^2$.** Sia dato l'insieme:

$$\mathcal{S} = \{[1, 0]^T, [2, 1]^T, [1, 1]^T\} \subset \mathbb{R}^2.$$

Determinare se $\mathcal{S}$ costituisce una base.

Risposta: NO.

- *Vincolo di dimensione:* La dimensione di $\mathbb{R}^2$ è 2. Qualsiasi base di $\mathbb{R}^2$ deve contenere esattamente due vettori. Tre o più vettori in $\mathbb{R}^2$ sono necessariamente linearmente dipendenti.
- *Dipendenza esplicita:* Poiché $[1, 1]^T = -[1, 0]^T + [2, 1]^T$, vale la combinazione non banale:

$$1 \begin{bmatrix} 1 \\ 0 \end{bmatrix} - 1 \begin{bmatrix} 2 \\ 1 \end{bmatrix} + 1 \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}. \quad (1.30)$$

2. **Due vettori collineari in $\mathbb{R}^2$.** Sia dato l'insieme:

$$\mathcal{S}' = \{[2, 1]^T, [-4, -2]^T\} \subset \mathbb{R}^2.$$

Determinare se $\mathcal{S}'$ costituisce una base.

Risposta: NO.

I due vettori sono collineari (proporzionali):

$$\begin{bmatrix} -4 \\ -2 \end{bmatrix} = -2 \begin{bmatrix} 2 \\ 1 \end{bmatrix} \implies 2 \begin{bmatrix} 2 \\ 1 \end{bmatrix} + \begin{bmatrix} -4 \\ -2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}. \quad (1.31)$$

Il loro span genera esclusivamente la retta $y = \frac{1}{2}x$ e non l'intero piano $\mathbb{R}^2$.

1.6 Esercitazione Guidata: Sfere Unitarie e Geometria delle Norme

1.6.1 Esercizio 1: Calcolo Comparativo delle Norme in $\mathbb{R}^3$

Dato il vettore $\mathbf{v} = [1, 2, -3]^T \in \mathbb{R}^3$, calcoliamo le tre norme fondamentali:

1. **Norma ℓ_1 :**

$$\|\mathbf{v}\|_1 = |1| + |2| + |-3| = 1 + 2 + 3 = 6. \quad (1.32)$$

2. **Norma ℓ_2 :**

$$\|\mathbf{v}\|_2 = \sqrt{1^2 + 2^2 + (-3)^2} = \sqrt{1 + 4 + 9} = \sqrt{14} \approx 3.742. \quad (1.33)$$

3. **Norma ℓ_∞ :**

$$\|\mathbf{v}\|_\infty = \max\{|1|, |2|, |-3|\} = \max\{1, 2, 3\} = 3. \quad (1.34)$$

1.6.2 Esercizio 2: Tracciamento delle Sfere Unitarie nel Piano $\mathbb{R}^2$

Si consideri il luogo geometrico dei vettori di norma unitaria al variare della metrica, per $\mathbf{v} = [x, y]^T \in \mathbb{R}^2$:

1. Sfera Euclidea $S_2 = \{\mathbf{v} \in \mathbb{R}^2 : \|\mathbf{v}\|_2 = 1\}$. L'equazione coincide con $\sqrt{x^2 + y^2} = 1 \iff x^2 + y^2 = 1$. È la **circonferenza unitaria** centrata nell'origine con raggio $R = 1$.

2. Sfera di Manhattan $S_1 = \{\mathbf{v} \in \mathbb{R}^2 : \|\mathbf{v}\|_1 = 1\}$. L'equazione $|x| + |y| = 1$ definisce, per interpolazione lineare nei quattro quadranti cartesiani:

$$\begin{cases} x + y = 1 \implies y = 1 - x & (x \geq 0, y \geq 0), \\ -x + y = 1 \implies y = 1 + x & (x \leq 0, y \geq 0), \\ -x - y = 1 \implies y = -1 - x & (x \leq 0, y \leq 0), \\ x - y = 1 \implies y = x - 1 & (x \geq 0, y \leq 0). \end{cases} \quad (1.35)$$

Geometricamente è un **quadrato ruotato di 45°** (losanga o *diamond*) con vertici nei punti cardinali $(\pm 1, 0)$ e $(0, \pm 1)$.

3. Sfera del Massimo $S_\infty = \{\mathbf{v} \in \mathbb{R}^2 : \|\mathbf{v}\|_\infty = 1\}$. La condizione $\max\{|x|, |y|\} = 1$ impone che almeno una coordinata abbia modulo pari a 1 mentre l'altra rimanga confinata in $[-1, 1]$. Geometricamente corrisponde al perimetro di un **quadrato con lati paralleli agli assi**, avente lato di lunghezza 2 e vertici nei punti $(\pm 1, \pm 1)$.




Figura 1.2: Confronto geometrico delle sfere unitarie S_1 (verde), S_2 (blu) e S_∞ (arancione tratteggiato) in $\mathbb{R}^2$. I quattro punti rossi indicano l'intersezione $S_1 \cap S_2 \cap S_\infty = \{\pm \mathbf{e}_1, \pm \mathbf{e}_2\}$.

Proprietà 1.6.1 (Intersezione Comune delle Sfere Unitarie). *L'intersezione dei tre luoghi geometrici è data esattamente dall'insieme dei vettori della base canonica e dai rispettivi opposti:*

$$S_1 \cap S_2 \cap S_\infty = \left\{ \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \end{bmatrix}, \begin{bmatrix} -1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ -1 \end{bmatrix} \right\} = \{\pm \mathbf{e}_1, \pm \mathbf{e}_2\}. \quad (1.36)$$

Solo per questi specifici quattro vettori, tutte e tre le norme assumono simultaneamente valore unitario $\|\mathbf{v}\|_1 = \|\mathbf{v}\|_2 = \|\mathbf{v}\|_\infty = 1$.

1.6.3 Esercizio 3: Verifica di Base in $\mathbb{R}^3$

Si considerino i tre vettori in $\mathbb{R}^3$:

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 0 \\ 2 \end{bmatrix}, \quad \mathbf{v}_2 = \begin{bmatrix} 2 \\ 2 \\ 0 \end{bmatrix}, \quad \mathbf{v}_3 = \begin{bmatrix} -3 \\ -4 \\ 2 \end{bmatrix}. \quad (1.37)$$

Verifichiamo se $\mathbf{v}_3$ sia esprimibile come combinazione lineare di $\mathbf{v}_1$ e $\mathbf{v}_2$:

$$\alpha \mathbf{v}_1 + \beta \mathbf{v}_2 = \mathbf{v}_3 \iff \begin{cases} \alpha + 2\beta = -3 & (\text{componente 1}), \\ 2\beta = -4 & (\text{componente 2}), \\ 2\alpha = 2 & (\text{componente 3}). \end{cases} \quad (1.38)$$

Dalla terza equazione si ricava $\alpha = 1$, mentre dalla seconda si ottiene $\beta = -2$. Sostituendo nella prima equazione:

$$\alpha + 2\beta = 1 + 2(-2) = 1 - 4 = -3, \quad (1.39)$$

il sistema risulta consistente e confermato. Abbiamo ottenuto la relazione di dipendenza lineare non banale:

$$\mathbf{v}_1 - 2\mathbf{v}_2 - \mathbf{v}_3 = \mathbf{0}_{\mathbb{R}^3}. \quad (1.40)$$

I tre vettori sono linearmente dipendenti; il vettore $\mathbf{v}_3$ appartiene al sottospazio piano $\text{span}(\mathbf{v}_1, \mathbf{v}_2)$ e dunque l'insieme $\{\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3\}$ **non costituisce una base di $\mathbb{R}^3$** .

1.7 Tre Visioni del Prodotto Matrice-Vettore

1.7.1 Definizione e Compatibilità Dimensionale

Una matrice $A \in \mathbb{R}^{n \times m}$ è una tabella rettangolare ordinata formata da n righe ed m colonne:

$$A = \begin{bmatrix} A_{11} & A_{12} & \cdots & A_{1m} \\ A_{21} & A_{22} & \cdots & A_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ A_{n1} & A_{n2} & \cdots & A_{nm} \end{bmatrix}. \quad (1.41)$$

Nel prodotto matrice-vettore $\mathbf{c} = A\mathbf{b}$, la compatibilità algebrica impone:

$$A \in \mathbb{R}^{n \times m}, \quad \mathbf{b} \in \mathbb{R}^{m \times 1} \implies \mathbf{c} = A\mathbf{b} \in \mathbb{R}^{n \times 1}. \quad (1.42)$$

Il numero di colonne di A deve coincidere esattamente con il numero di righe di $\mathbf{b}$.

1.7.2 Le Tre Visioni Equivalenti del Prodotto

Si consideri l'esempio numerico concreto:

$$A = \begin{bmatrix} 2 & 0 & 1 \\ 3 & -1 & 0 \end{bmatrix} \in \mathbb{R}^{2 \times 3}, \quad \mathbf{b} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} \in \mathbb{R}^3. \quad (1.43)$$

L'algebra lineare computazionale interpreta questo calcolo attraverso tre prospettive complementari:

Visione 1: Formula Scalare per Componenti. Ogni elemento c_i del vettore di output si ottiene accumulando i prodotti lungo riga e colonna:

$$c_i = \sum_{j=1}^m A_{ij} b_j \quad (i = 1, \dots, n). \quad (1.44)$$

Nel nostro esempio:

$$c_1 = 2 \cdot 1 + 0 \cdot 2 + 1 \cdot 3 = 2 + 0 + 3 = 5, \quad (1.45)$$

$$c_2 = 3 \cdot 1 + (-1) \cdot 2 + 0 \cdot 3 = 3 - 2 + 0 = 1 \implies \mathbf{c} = \begin{bmatrix} 5 \\ 1 \end{bmatrix}. \quad (1.46)$$

Visione 2: Prospettiva per Righe (Prodotto Scalare). Rappresentando la matrice A per righe orizzontali $\mathbf{u}_1^T, \dots, \mathbf{u}_n^T$ con $\mathbf{u}_i \in \mathbb{R}^m$:

$$A = \begin{bmatrix} - & \mathbf{u}_1^T & - \\ - & \mathbf{u}_2^T & - \\ & \vdots & \\ - & \mathbf{u}_n^T & - \end{bmatrix} \implies c_i = \langle \mathbf{u}_i, \mathbf{b} \rangle = \mathbf{u}_i^T \mathbf{b}. \quad (1.47)$$

Ogni elemento dell'output è il prodotto scalare euclideo tra la riga corrispondente di A e il vettore $\mathbf{b}$.

Visione 3: Prospettiva per Colonne (Combinazione Lineare delle Colonne). Rappresentando A tramite le sue m colonne verticali $\mathbf{w}_1, \dots, \mathbf{w}_m \in \mathbb{R}^n$:

$$A = \begin{bmatrix} | & | & & | \\ \mathbf{w}_1 & \mathbf{w}_2 & \dots & \mathbf{w}_m \\ | & | & & | \end{bmatrix} \implies \mathbf{c} = A\mathbf{b} = \sum_{j=1}^m b_j \mathbf{w}_j. \quad (1.48)$$

Il vettore risultante $\mathbf{c}$ è la **combinazione lineare delle colonne di A** pesata dai coefficienti scalari forniti dal vettore $\mathbf{b}$:

$$\mathbf{c} = 1 \begin{bmatrix} 2 \\ 3 \end{bmatrix} + 2 \begin{bmatrix} 0 \\ -1 \end{bmatrix} + 3 \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 2 + 0 + 3 \\ 3 - 2 + 0 \end{bmatrix} = \begin{bmatrix} 5 \\ 1 \end{bmatrix}. \quad (1.49)$$

Rilevanza della Visione per Colonne

La prospettiva per colonne è cruciale in tutto il corso: essa mostra immediatamente che il sottospazio di tutti i possibili vettori generabili da $A\mathbf{b}$ al variare di $\mathbf{b}$ è lo **spazio delle colonne** $\text{range}(A) = \text{span}(\mathbf{w}_1, \dots, \mathbf{w}_m)$. Risolvere un sistema $A\mathbf{x} = \mathbf{b}$ equivale a ricercare i pesi $\mathbf{x}$ con cui combinare le colonne di A per ricostruire $\mathbf{b}$.

1.8 Matrici come Trasformazioni Lineari nel Piano

Una matrice quadrata $A \in \mathbb{R}^{2 \times 2}$ agisce sui vettori del piano euclideo definendo una trasformazione lineare $T_A : \mathbb{R}^2 \rightarrow \mathbb{R}^2$, con $T_A(\mathbf{v}) = A\mathbf{v}$. L'effetto geometrico complessivo di A è interamente governato dalle immagini dei vettori della base canonica:

$$A\mathbf{e}_1 = \text{prima colonna di } A, \quad A\mathbf{e}_2 = \text{seconda colonna di } A. \quad (1.50)$$

1.8.1 Esempi Geometrici Fondamentali

1. Rotazione Oraria di 90° . Si consideri la matrice:

$$A_{\text{rot}} = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix}. \quad (1.51)$$

L'azione sui vettori canonici vale:

$$A_{\text{rot}}\mathbf{e}_1 = \begin{bmatrix} 0 \\ -1 \end{bmatrix} = -\mathbf{e}_2, \quad A_{\text{rot}}\mathbf{e}_2 = \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \mathbf{e}_1. \quad (1.52)$$

Il vettore orizzontale $\mathbf{e}_1$ viene ruotato verso il basso ($-\mathbf{e}_2$), mentre il vettore verticale $\mathbf{e}_2$ viene ruotato verso destra ($\mathbf{e}_1$). Applicato a un vettore generico $\mathbf{v} = [v_1, v_2]^T$, restituisce $[v_2, -v_1]^T$, ruotando l'intero piano di 90° in senso orario.

2. Scorrimento Orizzontale (*Shear Mapping*). Si consideri la matrice triangolare:

$$A_{\text{shear}} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}. \quad (1.53)$$

L'azione sulla base canonica restituisce:

$$A_{\text{shear}}\mathbf{e}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \mathbf{e}_1, \quad A_{\text{shear}}\mathbf{e}_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \mathbf{e}_1 + \mathbf{e}_2. \quad (1.54)$$

L'asse delle ascisse rimane immobile, mentre la coordinata orizzontale di ogni punto subisce una traslazione proporzionale alla sua ordinata ($x \mapsto x + y$, $y \mapsto y$). Tale trasformazione muta i quadrati in parallelogrammi preservandone l'area ($\det A_{\text{shear}} = 1$).

3. Omotetia Uniforme e Riflessione.

- $A = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} = 2I$: scala uniformemente ogni vettore dello spazio di un fattore 2 ($A\mathbf{v} = 2\mathbf{v}$), conservando direzioni e angoli.
- $A = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$: scambia tra loro le coordinate ($x \mapsto y, y \mapsto x$), realizzando la riflessione speculare rispetto alla retta bisettrice $y = x$.

1.9 Introduzione alla Complessità Computazionale e Flops

Nell'algebra lineare numerica non basta verificare teoricamente la risolubilità di un'equazione: è indispensabile quantificare il numero di operazioni elementari in virgola mobile (**flops**, *floating-point operations* — addizioni, sottrazioni, moltiplicazioni, divisioni) richieste per eseguirla al calcolatore.

1.9.1 Conteggio delle Operazioni per il Prodotto Scalare

Siano $\mathbf{v}, \mathbf{w} \in \mathbb{R}^n$. Il calcolo di $\langle \mathbf{v}, \mathbf{w} \rangle = \sum_{i=1}^n v_i w_i$ richiede:

1. n moltiplicazioni elementari ($v_1 w_1, v_2 w_2, \dots, v_n w_n$);
2. $n - 1$ addizioni per accumulare i prodotti parziali.

Il costo computazionale esatto ammonta a:

$$\text{Flops}(n) = n + (n - 1) = 2n - 1 \implies \mathcal{O}(n). \quad (1.55)$$

1.9.2 Modello di Scaling Temporale Lineare

Si assuma che il tempo di esecuzione su un'architettura hardware sia proporzionale al numero di operazioni. Se il calcolo del prodotto scalare per vettori di dimensione $n = 10^7$ (10 milioni di elementi) impiega 3 secondi, per vettori di dimensione triplicata $n' = 3 \cdot 10^7$:

$$\text{Tempo stimato} = 3 \times (\text{tempo base}) = 3 \times 3 \text{ s} = 9 \text{ s}. \quad (1.56)$$

La complessità lineare $\mathcal{O}(n)$ assicura che il tempo di computazione scali proporzionalmente al fattore di ingrandimento dei dati.

Nota 1.9.1 (Quesito Aperto: Il Costo del Prodotto Matrice-Vettore). Data una matrice quadrata $A \in \mathbb{R}^{n \times n}$ e un vettore $\mathbf{b} \in \mathbb{R}^n$:

- Il calcolo di $A\mathbf{b}$ equivale a calcolare n prodotti scalari indipendenti, ciascuno di costo $2n - 1$:

$$\text{Flops}_{\text{mat-vec}}(n) = n(2n - 1) = 2n^2 - n \implies \mathcal{O}(n^2). \quad (1.57)$$

- Se per $n = 1\,000$ l'operazione impiega 3 secondi, raddoppiando la dimensione a $n' = 2\,000$, la crescita quadratica $\mathcal{O}(n^2)$ comporta un incremento per un fattore $(2)^2 = 4$, portando il tempo atteso a circa $4 \times 3\text{ s} = 12\text{ s}$.

1.10 Quadro Sinottico dei Concetti Fondamentali

Oggetto / Concetto	Definizione Matematica	Proprietà Chiave / Complessità
Norma ℓ_1	$\ \mathbf{v}\ _1 = \sum_{i=1}^n v_i $	Sfera unitaria a rombo (45°), induce sparsità nei modelli.
Norma ℓ_2	$\ \mathbf{v}\ _2 = \sqrt{\sum_{i=1}^n v_i^2} = \sqrt{\mathbf{v}^T \mathbf{v}}$	Lunghezza euclidea invariante per rotazioni, liscia e differenziabile.
Norma ℓ_∞	$\ \mathbf{v}\ _\infty = \max_{1 \leq i \leq n} v_i $	Sfera unitaria a quadrato parallelo agli assi cartesiani.
Prodotto Scalare	$\langle \mathbf{v}, \mathbf{w} \rangle = \mathbf{v}^T \mathbf{w} = \sum_{i=1}^n v_i w_i$	Operazioni aritmetiche: $2n - 1 \implies \mathcal{O}(n)$.
Base	Insieme lin. indep. con $\text{span} = V$	Rappresentazione unica delle coordinate di ogni vettore.
Prodotto $A\mathbf{b}$ (Righe)	$c_i = \mathbf{u}_i^T \mathbf{b}$	n prodotti scalari tra le righe di A e il vettore $\mathbf{b}$.
Prodotto $A\mathbf{b}$ (Colonne)	$\mathbf{c} = \sum_{j=1}^m b_j \mathbf{w}_j$	Combinazione lineare delle colonne pesata da $\mathbf{b}$; descrive $\text{range}(A)$.
Rotazione 90° Oraria	$A = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix}$	Mappa $\mathbf{e}_1 \mapsto -\mathbf{e}_2$ e $\mathbf{e}_2 \mapsto \mathbf{e}_1$.
Riflessione su $y = x$	$A = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$	Mappa $\mathbf{e}_1 \mapsto \mathbf{e}_2$ e $\mathbf{e}_2 \mapsto \mathbf{e}_1$, invertendo le coordinate.

Tabella 1.1: Sintesi dei concetti algebrici, geometrici e computazionali trattati nel Capitolo 1.

Capitolo 2

Prodotto tra Matrici, Complessità Computazionale e Matrici Ortogonali

Il presente capitolo approfondisce le operazioni algebriche di livello superiore tra matrici, analizzando la moltiplicazione matrice-matrice, il relativo profilo di complessità computazionale e le proprietà strutturali degli spazi fondamentali associati a una matrice. Vengono quindi introdotte l'ortogonalità vettoriale e le matrici ortogonali, componenti basilari per la progettazione di algoritmi stabili e per le fattorizzazioni matriciali dell'algebra lineare numerica [2].

2.1 Moltiplicazione Matrice-Matrice

2.1.1 Condizione di Compatibilità Dimensionale

Siano date due matrici a entrate reali A e B . L'operazione di moltiplicazione matriciale $C = AB$ è lecita ed algebricamente definita **se e solo se** il numero di colonne del primo fattore A coincide con il numero di righe del secondo fattore B .

Definizione 2.1.1 (Compatibilità del Prodotto Matriciale). Dati $n, m, p \in \mathbb{N}$, siano $A \in \mathbb{R}^{n \times m}$ e $B \in \mathbb{R}^{m \times p}$. Il prodotto matrice-matrice restituisce la matrice $C = AB \in \mathbb{R}^{n \times p}$ la cui dimensione è data dal numero di righe del primo fattore per il numero di colonne del secondo:

$$A \in \mathbb{R}^{n \times m}, \quad B \in \mathbb{R}^{m \times p} \implies C = AB \in \mathbb{R}^{n \times p}. \quad (2.1)$$

Se il numero di colonne di A differisce dal numero di righe di B , il prodotto non è definito. In generale, anche per matrici quadrate ($n = m = p$), la

moltiplicazione non gode della proprietà commutativa:

$$AB \neq BA \quad (\text{in generale}). \quad (2.2)$$




Figura 2.1: Compatibilità dimensionale nel prodotto matriciale: l'elemento generico C_{ij} nasce dall'intersezione tra la riga $\mathbf{u}_i^T$ di A e la colonna $\mathbf{w}_j$ di B .

2.1.2 Definizione per Componenti

Ciascun elemento C_{ij} posizionato all'intersezione tra la riga i ($1 \leq i \leq n$) e la colonna j ($1 \leq j \leq p$) della matrice risultante è generato dal prodotto scalare euclideo tra la riga i -esima di A e la colonna j -esima di B :

Definizione 2.1.2 (Formula per Componenti del Prodotto). Dati $A \in \mathbb{R}^{n \times m}$ e $B \in \mathbb{R}^{m \times p}$, la voce (i, j) del prodotto $C = AB$ è pari a:

$$C_{ij} = \sum_{k=1}^m A_{ik} B_{kj} = A_{i1} B_{1j} + A_{i2} B_{2j} + \cdots + A_{im} B_{mj}. \quad (2.3)$$

In forma vettoriale, indicando con $\mathbf{u}_i^T$ la i -esima riga di A e con $\mathbf{w}_j$ la j -esima colonna di B :

$$C_{ij} = \langle \mathbf{u}_i, \mathbf{w}_j \rangle = \mathbf{u}_i^T \mathbf{w}_j. \quad (2.4)$$

2.1.3 Esempio Numerico Passo-Passo

Esempio 2.1.1 (Calcolo Dettagliato del Prodotto Rettangolare). Siano assegnate le matrici:

$$A = \begin{bmatrix} 1 & 2 \\ 0 & 3 \end{bmatrix} \in \mathbb{R}^{2 \times 2}, \quad B = \begin{bmatrix} 0 & 1 & -1 \\ 1 & 0 & 2 \end{bmatrix} \in \mathbb{R}^{2 \times 3}. \quad (2.5)$$

Poiché le colonne di A ($m = 2$) eguagliano le righe di B ($m = 2$), la matrice prodotto $C = AB$ è ben definita ed ha dimensione 2×3 . Calcoliamo analiticamente le sue sei componenti:

Prima riga di C (prodotto della riga 1 di A con le colonne di B):

$$C_{11} = A_{11}B_{11} + A_{12}B_{21} = 1 \cdot 0 + 2 \cdot 1 = 0 + 2 = 2, \quad (2.6)$$

$$C_{12} = A_{11}B_{12} + A_{12}B_{22} = 1 \cdot 1 + 2 \cdot 0 = 1 + 0 = 1, \quad (2.7)$$

$$C_{13} = A_{11}B_{13} + A_{12}B_{23} = 1 \cdot (-1) + 2 \cdot 2 = -1 + 4 = 3. \quad (2.8)$$

Seconda riga di C (prodotto della riga 2 di A con le colonne di B):

$$C_{21} = A_{21}B_{11} + A_{22}B_{21} = 0 \cdot 0 + 3 \cdot 1 = 0 + 3 = 3, \quad (2.9)$$

$$C_{22} = A_{21}B_{12} + A_{22}B_{22} = 0 \cdot 1 + 3 \cdot 0 = 0 + 0 = 0, \quad (2.10)$$

$$C_{23} = A_{21}B_{13} + A_{22}B_{23} = 0 \cdot (-1) + 3 \cdot 2 = 0 + 6 = 6. \quad (2.11)$$

Ricomponendo i valori calcolati nella tabella matriciale:

$$C = AB = \begin{bmatrix} 2 & 1 & 3 \\ 3 & 0 & 6 \end{bmatrix} \in \mathbb{R}^{2 \times 3}. \quad (2.12)$$

2.2 Complessità Computazionale e Legge di Scaling

2.2.1 Conteggio Rigoroso dei FLOPs

La valutazione del tempo di esecuzione di un algoritmo numerico richiede la stima analitica delle operazioni in virgola mobile (*FLOPs*, floating-point operations).

Proprietà 2.2.1 (Costo Computazionale del Prodotto Matrice-Matrice).

1. **Costo di una singola entrata:** La valutazione di $C_{ij} = \sum_{k=1}^m A_{ik}B_{kj}$ richiede m moltiplicazioni tra scalari ed $m - 1$ addizioni, per un totale di:

$$FLOPs \text{ per entrata} = m + (m - 1) = 2m - 1 \implies \mathcal{O}(m). \quad (2.13)$$

2. **Costo del caso rettangolare generale** ($A \in \mathbb{R}^{n \times m}, B \in \mathbb{R}^{m \times p}$): Dovendo calcolare $n \cdot p$ elementi indipendenti:

$$FLOPs \text{ Totali} = n \cdot p \cdot (2m - 1) = 2nmp - np \implies \mathcal{O}(nmp). \quad (2.14)$$

3. **Costo del caso quadrato** ($n = m = p$): Se entrambe le matrici appartengono a $\mathbb{R}^{n \times n}$, la matrice C contiene n^2 elementi:

$$FLOPs \text{ Totali}(n) = n^2 \cdot (2n - 1) = 2n^3 - n^2 \implies \mathcal{O}(n^3). \quad (2.15)$$

Il termine dominante $2n^3$ impone una crescita cubica al crescere della taglia n .

2.2.2 Legge di Scalabilità Temporale Cubica

Sia $T(n) \approx \gamma n^3$ il tempo di calcolo su un'architettura hardware fissata, dove la costante $\gamma > 0$ racchiude l'efficienza della cache, la frequenza di clock della CPU e il fattore di conversione del compilatore.

Esempio 2.2.1 (Previsione dei Tempi con Raddoppio della Dimensione). Supponiamo che il prodotto tra due matrici quadrate dense di dimensione $n = 1000$ richieda 3 secondi di CPU:

$$T(1000) \approx \gamma \cdot (1000)^3 = 3 \text{ s.} \quad (2.16)$$

Se raddoppiamo la dimensione portandola a $n' = 2000$, la legge cubica stabilisce:

$$T(2000) \approx \gamma \cdot (2000)^3 = \gamma \cdot (2 \cdot 1000)^3 = 8 \cdot (\gamma \cdot 1000^3) = 8 \cdot T(1000). \quad (2.17)$$

Il tempo di esecuzione scala di un fattore 8:

$$T(2000) \approx 8 \cdot 3 \text{ s} = 24 \text{ secondi.} \quad (2.18)$$

2.2.3 Quadro Comparativo delle Operazioni Fondamentali

La tabella 2.1 illustra come le tre operazioni cardine dell'algebra lineare numerica scalino in risposta a un incremento di un fattore 10 della dimensione lineare n (passaggio da $n = 10^3$ a $n = 10^4$).

Operazione	Dati Coinvolti	Formula FLOPs	Costo	Fattore ($10\times$)
Prodotto Scalare	$\mathbf{v}, \mathbf{w} \in \mathbb{R}^n$	$2n - 1$	$\mathcal{O}(n)$	$10^1 = 10$
Matrice-Vettore	$A \in \mathbb{R}^{n \times n}, \mathbf{b} \in \mathbb{R}^n$	$2n^2 - n$	$\mathcal{O}(n^2)$	$10^2 = 100$
Matrice-Matrice	$A, B \in \mathbb{R}^{n \times n}$	$2n^3 - n^2$	$\mathcal{O}(n^3)$	$10^3 = 1000$

Tabella 2.1: Confronto di complessità computazionale e fattore di scaling per una dilatazione di ordine di grandezza dei dati.

Se un'operazione matrice-matrice con $n = 1000$ impiega 1 secondo, la medesima operazione con $n = 10\,000$ richiederà 1000 secondi (≈ 16.6 minuti).

2.3 Proprietà Fondamentali: Rango, Spazi Fondamentali e Invertibilità

2.3.1 Definizioni degli Spazi Associati a una Matrice

Sia $A \in \mathbb{R}^{n \times m}$ interpretata come operatore lineare $T_A : \mathbb{R}^m \rightarrow \mathbb{R}^n$ tale che $T_A(\mathbf{x}) = A\mathbf{x}$.

Definizione 2.3.1 (Rango di una Matrice). Il **rango** di A , denotato con $\text{rank}(A)$, è la dimensione dello spazio generato dalle sue colonne. Vale il teorema fondamentale per cui il rango per colonne coincide sempre con il rango per righe:

$$\text{rank}(A) = \dim(\text{col}(A)) = \dim(\text{row}(A)) \leq \min(n, m). \quad (2.19)$$

Se $\text{rank}(A) = \min(n, m)$, la matrice si dice a **rango pieno** (*full rank*).

Definizione 2.3.2 (Spazio Nullo o Kernel). Il **nucleo** (*kernel* o *nullspace*) di A è il sottospazio di $\mathbb{R}^m$ costituito da tutti i vettori che vengono mappati nel vettore nullo di $\mathbb{R}^n$:

$$\ker(A) = \{\mathbf{x} \in \mathbb{R}^m : A\mathbf{x} = \mathbf{0}_{\mathbb{R}^n}\} \subseteq \mathbb{R}^m. \quad (2.20)$$

Definizione 2.3.3 (Immagine o Range). L'**immagine** (*image* o *range*) di A è il sottospazio di $\mathbb{R}^n$ generato da tutte le combinazioni lineari delle colonne di A :

$$\text{Im}(A) = \text{span}(\text{colonne di } A) = \{A\mathbf{x} : \mathbf{x} \in \mathbb{R}^m\} \subseteq \mathbb{R}^n. \quad (2.21)$$

Vale $\dim(\text{Im}(A)) = \text{rank}(A)$.

Teorema 2.3.1 (Teorema del Rango-Nullità). *Per ogni matrice $A \in \mathbb{R}^{n \times m}$ avente m colonne, la somma della dimensione dell'immagine e della dimensione del nucleo eguaglia la dimensione dello spazio di partenza:*

$$\dim(\text{Im}(A)) + \dim(\ker(A)) = m. \quad (2.22)$$




Figura 2.2: Rappresentazione geometrica dei sottospazi fondamentali e del Teorema del Rango-Nullità: $\dim(\ker(A)) + \dim(\text{Im}(A)) = m$. La restrizione di A al sottospazio ortogonale $(\ker(A))^\perp$ mappa biunivocamente su $\text{Im}(A)$.

2.3.2 Invertibilità di Matrici Quadrate

Nel contesto di matrici quadrate $A \in \mathbb{R}^{n \times n}$, le nozioni di rango, nucleo e invertibilità si fondono in un unico teorema di equivalenza.

Definizione 2.3.4 (Matrice Invertibile o Non Singolare). Una matrice $A \in \mathbb{R}^{n \times n}$ si dice **invertibile** se esiste un'unica matrice $A^{-1} \in \mathbb{R}^{n \times n}$ tale che:

$$AA^{-1} = I_n \quad \text{e} \quad A^{-1}A = I_n. \quad (2.23)$$

Teorema 2.3.2 (Caratterizzazioni Equivalenti di Invertibilità). Sia $A \in \mathbb{R}^{n \times n}$. Le seguenti affermazioni sono equivalenti:

1. A è invertibile.
2. $\text{rank}(A) = n$ (A ha rango massimo).
3. $\det(A) \neq 0$.
4. $\ker(A) = \{\mathbf{0}_{\mathbb{R}^n}\}$ (il nucleo contiene esclusivamente il vettore nullo).
5. Le colonne di A formano una base di $\mathbb{R}^n$.
6. Il sistema lineare $A\mathbf{x} = \mathbf{b}$ ammette una e una sola soluzione $\mathbf{x} = A^{-1}\mathbf{b}$ per ogni $\mathbf{b} \in \mathbb{R}^n$.

2.3.3 Esempio Guidato: Calcolo di Rango, Nucleo e Immagine

Esempio 2.3.1 (Analisi Completa di una Matrice 3×3 Singolare). Consideriamo la matrice:

$$A = \begin{bmatrix} 1 & 2 & 0 \\ 2 & 4 & 0 \\ 0 & 0 & 1 \end{bmatrix} \in \mathbb{R}^{3 \times 3}. \quad (2.24)$$

1. Calcolo del Rango via Eliminazione Gaussiana: Applichiamo l'operazione elementare per righe $R_2 \leftarrow R_2 - 2R_1$:

$$\begin{bmatrix} 1 & 2 & 0 \\ 2 & 4 & 0 \\ 0 & 0 & 1 \end{bmatrix} \xrightarrow{R_2 \rightarrow R_2 - 2R_1} \begin{bmatrix} 1 & 2 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix} \xrightarrow{R_2 \leftrightarrow R_3} \begin{bmatrix} 1 & 2 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 0 \end{bmatrix}. \quad (2.25)$$

La matrice ridotta a gradini presenta 2 pivot non nulli. Di conseguenza:

$$\text{rank}(A) = 2. \quad (2.26)$$

Poiché $\text{rank}(A) = 2 < 3$, la matrice A **non è invertibile** ($\det(A) = 0$).

2. Determinazione dell'Immagine $\text{Im}(A)$: Osservando le colonne di A :

$$\mathbf{a}_1 = \begin{bmatrix} 1 \\ 2 \\ 0 \end{bmatrix}, \quad \mathbf{a}_2 = \begin{bmatrix} 2 \\ 4 \\ 0 \end{bmatrix} = 2\mathbf{a}_1, \quad \mathbf{a}_3 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}. \quad (2.27)$$

La seconda colonna è collineare alla prima ed è dunque ridondante. Le colonne $\mathbf{a}_1$ e $\mathbf{a}_3$ sono linearmente indipendenti e costituiscono una base dell'immagine:

$$\text{Im}(A) = \text{span} \left\{ \begin{bmatrix} 1 \\ 2 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} \right\}, \quad \dim(\text{Im}(A)) = 2. \quad (2.28)$$

3. Determinazione del Nucleo $\ker(A)$: Risolviamo il sistema omogeneo $A\mathbf{x} = \mathbf{0}_{\mathbb{R}^3}$ per $\mathbf{x} = [x_1, x_2, x_3]^T$:

$$\begin{bmatrix} 1 & 2 & 0 \\ 2 & 4 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} \implies \begin{cases} x_1 + 2x_2 = 0 \\ x_3 = 0 \end{cases} \implies \begin{cases} x_1 = -2x_2 \\ x_3 = 0 \end{cases}. \quad (2.29)$$

Assegnando alla variabile libera x_2 il parametro $t \in \mathbb{R}$:

$$\mathbf{x} = \begin{bmatrix} -2t \\ t \\ 0 \end{bmatrix} = t \begin{bmatrix} -2 \\ 1 \\ 0 \end{bmatrix} \implies \ker(A) = \text{span} \left\{ \begin{bmatrix} -2 \\ 1 \\ 0 \end{bmatrix} \right\}. \quad (2.30)$$

La dimensione del nucleo è $\dim(\ker(A)) = 1$. Verifichiamo il Teorema del Rango-Nullità:

$$\dim(\text{Im}(A)) + \dim(\ker(A)) = 2 + 1 = 3 = m. \quad (2.31)$$

2.4 Ortogonalità e Ortonormalità Vettoriale

2.4.1 Definizioni Fondamentali

Definizione 2.4.1 (Vettori Ortogonali). Due vettori $\mathbf{v}, \mathbf{w} \in \mathbb{R}^n$ si dicono **ortogonali** ($\mathbf{v} \perp \mathbf{w}$) se e solo se il loro prodotto scalare standard è nullo:

$$\langle \mathbf{v}, \mathbf{w} \rangle = \mathbf{v}^T \mathbf{w} = 0. \quad (2.32)$$

Definizione 2.4.2 (Insieme Ortogonale ed Ortonormale). Un insieme di vettori $\{\mathbf{v}_1, \dots, \mathbf{v}_k\} \subset \mathbb{R}^n$ è detto:

1. **Ortogonale** se i vettori sono a due a due ortogonali:

$$\langle \mathbf{v}_i, \mathbf{v}_j \rangle = 0 \quad \forall i \neq j. \quad (2.33)$$

2. **Ortonormale** se è ortogonale e ciascun vettore possiede norma euclidea unitaria:

$$\langle \mathbf{v}_i, \mathbf{v}_j \rangle = \delta_{ij} = \begin{cases} 1 & \text{se } i = j, \\ 0 & \text{se } i \neq j, \end{cases} \quad (2.34)$$

dove δ_{ij} denota la delta di Kronecker.

2.4.2 Esercizi Costruttivi di Normalizzazione in $\mathbb{R}^2$

Esempio 2.4.1 (Costruzione e Normalizzazione di una Coppia Ortogonale).

1. **Ricerca di un vettore ortogonale:** Sia assegnato il vettore $\mathbf{v}_1 = [2, 1]^T \in \mathbb{R}^2$. Cerchiamo un vettore non nullo $\mathbf{v}_2 = [x, y]^T$ tale che $\langle \mathbf{v}_1, \mathbf{v}_2 \rangle = 0$:

$$2x + y = 0 \implies y = -2x. \quad (2.35)$$

Scegliendo $x = 1$, otteniamo $y = -2$, da cui la coppia ortogonale:

$$\mathbf{v}_1 = \begin{bmatrix} 2 \\ 1 \end{bmatrix}, \quad \mathbf{v}_2 = \begin{bmatrix} 1 \\ -2 \end{bmatrix}, \quad \langle \mathbf{v}_1, \mathbf{v}_2 \rangle = 2(1) + 1(-2) = 0. \quad (2.36)$$

2. **Normalizzazione euclidea (Ortonormalizzazione):** Dividiamo ciascun vettore per la rispettiva norma euclidea ℓ_2 :

$$\|\mathbf{v}_1\|_2 = \sqrt{2^2 + 1^2} = \sqrt{5} \implies \mathbf{u}_1 = \frac{\mathbf{v}_1}{\|\mathbf{v}_1\|_2} = \begin{bmatrix} 2/\sqrt{5} \\ 1/\sqrt{5} \end{bmatrix}, \quad (2.37)$$

$$\|\mathbf{v}_2\|_2 = \sqrt{1^2 + (-2)^2} = \sqrt{5} \implies \mathbf{u}_2 = \frac{\mathbf{v}_2}{\|\mathbf{v}_2\|_2} = \begin{bmatrix} 1/\sqrt{5} \\ -2/\sqrt{5} \end{bmatrix}. \quad (2.38)$$

Verifichiamo le proprietà di ortonormalità:

$$\|\mathbf{u}_1\|_2 = 1, \quad \|\mathbf{u}_2\|_2 = 1, \quad (2.39)$$

$$\langle \mathbf{u}_1, \mathbf{u}_2 \rangle = \frac{2}{\sqrt{5}} \frac{1}{\sqrt{5}} + \frac{1}{\sqrt{5}} \left(-\frac{2}{\sqrt{5}} \right) = \frac{2}{5} - \frac{2}{5} = 0. \quad (2.40)$$

L'insieme $\{\mathbf{u}_1, \mathbf{u}_2\}$ costituisce una base ortonormale di $\mathbb{R}^2$.

2.5 Matrici Ortogonali

2.5.1 Definizione e Proprietà della Trasposta

Richiamiamo che per una generica matrice rettangolare $A \in \mathbb{R}^{n \times m}$, la matrice trasposta $A^T \in \mathbb{R}^{m \times n}$ ha elementi $(A^T)_{ij} = A_{ji}$. Per qualsiasi coppia di matrici compatibili, vale l'inversione dell'ordine nella trasposizione:

$$(AB)^T = B^T A^T. \quad (2.41)$$

Definizione 2.5.1 (Matrice Ortogonale). Una matrice quadrata $U \in \mathbb{R}^{n \times n}$ è definita **ortogonale** se e solo se la sua trasposta coincide con la sua inversa:

$$U^T U = U U^T = I_n \iff U^{-1} = U^T. \quad (2.42)$$

2.5.2 Caratterizzazione per Colonne e per Righe

Teorema 2.5.1 (Ortonormalità delle Colonne e delle Righe). *Una matrice quadrata $U \in \mathbb{R}^{n \times n}$ è ortogonale se e solo se le sue colonne formano una base ortonormale di $\mathbb{R}^n$. Equivalentemente, U è ortogonale se e solo se le sue righe formano una base ortonormale di $\mathbb{R}^n$.*

Dimostrazione. Partizioniamo U per vettori colonna $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_n \in \mathbb{R}^n$:

$$U = \begin{bmatrix} \mathbf{u}_1 & \mathbf{u}_2 & \dots & \mathbf{u}_n \end{bmatrix}. \quad (2.43)$$

La trasposta U^T si esprime mediante le medesime partizioni come matrice a blocchi per righe:

$$U^T = \begin{bmatrix} \mathbf{u}_1^T \\ \mathbf{u}_2^T \\ \vdots \\ \mathbf{u}_n^T \end{bmatrix}. \quad (2.44)$$

Eseguiamo la moltiplicazione a blocchi $U^T U$:

$$\begin{aligned} U^T U &= \begin{bmatrix} \mathbf{u}_1^T \\ \mathbf{u}_2^T \\ \vdots \\ \mathbf{u}_n^T \end{bmatrix} \begin{bmatrix} \mathbf{u}_1 & \mathbf{u}_2 & \dots & \mathbf{u}_n \end{bmatrix} \\ &= \begin{bmatrix} \mathbf{u}_1^T \mathbf{u}_1 & \mathbf{u}_1^T \mathbf{u}_2 & \dots & \mathbf{u}_1^T \mathbf{u}_n \\ \mathbf{u}_2^T \mathbf{u}_1 & \mathbf{u}_2^T \mathbf{u}_2 & \dots & \mathbf{u}_2^T \mathbf{u}_n \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{u}_n^T \mathbf{u}_1 & \mathbf{u}_n^T \mathbf{u}_2 & \dots & \mathbf{u}_n^T \mathbf{u}_n \end{bmatrix} = [\langle \mathbf{u}_i, \mathbf{u}_j \rangle]_{i,j=1}^n. \end{aligned} \quad (2.45)$$

Affinché il prodotto coincida con la matrice identità I_n , deve risultare:

$$\langle \mathbf{u}_i, \mathbf{u}_j \rangle = \delta_{ij} \quad \forall i, j \in \{1, \dots, n\}. \quad (2.46)$$

Questo dimostra in modo costruttivo che le colonne sono mutuamente ortogonali e a norma euclidea unitaria. Lo stesso argomento applicato a $UU^T = I_n$ prova l'ortonormalità delle righe. $\square$

2.5.3 Esempio Notevole: Rotazione nel Piano

Esempio 2.5.1 (Matrice di Rotazione Piana). Sia $\theta \in \mathbb{R}$. Consideriamo la matrice di rotazione:

$$U = \begin{bmatrix} \cos \theta & \sin \theta \\ -\sin \theta & \cos \theta \end{bmatrix}. \quad (2.47)$$

Verifichiamo la condizione $U^T U = I_2$:

$$\begin{aligned} U^T U &= \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix} \begin{bmatrix} \cos \theta & \sin \theta \\ -\sin \theta & \cos \theta \end{bmatrix} \\ &= \begin{bmatrix} \cos^2 \theta + \sin^2 \theta & \cos \theta \sin \theta - \sin \theta \cos \theta \\ \sin \theta \cos \theta - \cos \theta \sin \theta & \sin^2 \theta + \cos^2 \theta \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = I_2. \end{aligned} \quad (2.48)$$

La matrice U è ortogonale per qualunque valore dell'angolo θ .

2.5.4 Chiusura del Prodotto di Matrici Ortogonali

Proposizione 2.5.1 (Gruppo Ortogonale e Chiusura rispetto al Prodotto).
Se $U, V \in \mathbb{R}^{n \times n}$ sono matrici ortogonali, il loro prodotto $Q = UV$ è anch'esso una matrice ortogonale.

Dimostrazione. Calcoliamo QQ^T sfruttando la regola di inversione della trasposta $(UV)^T = V^T U^T$:

$$QQ^T = (UV)(UV)^T = (UV)(V^T U^T). \quad (2.49)$$

Per la proprietà associativa del prodotto matriciale:

$$QQ^T = U(VV^T)U^T. \quad (2.50)$$

Poiché V è ortogonale, $VV^T = I_n$:

$$QQ^T = UI_n U^T = UU^T = I_n. \quad (2.51)$$

In modo del tutto analogo si verifica che $Q^T Q = V^T (U^T U) V = V^T I_n V = I_n$.
 Pertanto $Q = UV$ è ortogonale. $\square$

2.6 I Quattro Quesiti Notabili sulle Matrici Ortogonali

2.6.1 Quesito 1: Limite Superiore sulle Singole Entrate

Esempio 2.6.1 (Gli Elementi di una Matrice Ortogonale Possono Superare 1?). **Domanda:** È possibile che una matrice ortogonale $U \in \mathbb{R}^{n \times n}$ contenga un elemento $U_{ij} > 1$?

Risposta: NO.

Dimostrazione: Sia $\mathbf{u}_j$ la j -esima colonna di U . Poiché U è ortogonale, $\mathbf{u}_j$ ha norma euclidea unitaria:

$$\|\mathbf{u}_j\|_2^2 = \sum_{k=1}^n U_{kj}^2 = 1. \quad (2.52)$$

Poiché ogni quadrato $U_{kj}^2 \geq 0$, ogni singolo termine della sommatoria è limitato superiormente dalla somma complessiva:

$$U_{ij}^2 \leq \sum_{k=1}^n U_{kj}^2 = 1 \implies |U_{ij}| \leq 1 \implies -1 \leq U_{ij} \leq 1. \quad (2.53)$$

Nessuna componente di una matrice ortogonale può superare 1 in valore assoluto.

2.6.2 Quesito 2: Matrici Diagonali Ortogonali

Esempio 2.6.2 (Caratterizzazione delle Matrici Diagonali Ortogonali). **Domanda:** A quali condizioni una matrice diagonale $D \in \mathbb{R}^{n \times n}$ risulta ortogonale?

Risoluzione: Sia $D = \text{diag}(d_1, d_2, \dots, d_n)$. Essendo diagonale, essa coincide con la propria trasposta: $D^T = D$. Calcoliamo $D^T D$:

$$D^T D = D^2 = \text{diag}(d_1^2, d_2^2, \dots, d_n^2). \quad (2.54)$$

Affinché $D^T D = I_n$, occorre che:

$$d_i^2 = 1 \iff d_i = \pm 1 \quad \forall i = 1, \dots, n. \quad (2.55)$$

Conclusione: Una matrice diagonale è ortogonale se e solo se tutte le entrate diagonali sono pari a $+1$ o -1 . Esistono esattamente 2^n matrici diagonali ortogonali distinte in $\mathbb{R}^{n \times n}$.

2.6.3 Quesito 3: Matrici Triangolari Superiori Ortogonali

Esempio 2.6.3 (Caratterizzazione delle Matrici Triangolari Ortogonali). **Domanda:** Quando una matrice triangolare superiore $R \in \mathbb{R}^{n \times n}$ è ortogonale?

Dimostrazione per induzione sulle colonne: Sia R triangolare superiore ($R_{ij} = 0$ per ogni $i > j$):

$$R = \begin{bmatrix} r_{11} & r_{12} & r_{13} & \cdots & r_{1n} \\ 0 & r_{22} & r_{23} & \cdots & r_{2n} \\ 0 & 0 & r_{33} & \cdots & r_{3n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & r_{nn} \end{bmatrix}. \quad (2.56)$$

Poiché R è ortogonale, le sue colonne $\mathbf{r}_1, \dots, \mathbf{r}_n$ devono formare una base ortonormale:

1. **Prima colonna** $\mathbf{r}_1 = [r_{11}, 0, \dots, 0]^T$: La norma unitaria impone $r_{11}^2 = 1 \implies r_{11} = \pm 1$.
2. **Seconda colonna** $\mathbf{r}_2 = [r_{12}, r_{22}, 0, \dots, 0]^T$: L'ortogonalità rispetto a $\mathbf{r}_1$ impone:

$$\langle \mathbf{r}_1, \mathbf{r}_2 \rangle = r_{11} r_{12} = 0 \implies r_{12} = 0 \quad (\text{poiché } r_{11} = \pm 1 \neq 0). \quad (2.57)$$

Dalla norma unitaria: $\|\mathbf{r}_2\|_2^2 = r_{12}^2 + r_{22}^2 = 0 + r_{22}^2 = 1 \implies r_{22} = \pm 1$.

3. **Terza colonna** $\mathbf{r}_3 = [r_{13}, r_{23}, r_{33}, 0, \dots, 0]^T$: L'ortogonalità verso $\mathbf{r}_1$ e $\mathbf{r}_2$ impone $r_{11}r_{13} = 0 \implies r_{13} = 0$ e $r_{22}r_{23} = 0 \implies r_{23} = 0$. Segue $r_{33} = \pm 1$.
4. **Passo induttivo generale**: Per ogni colonna j , tutti gli elementi fuori diagonale si annullano ($r_{ij} = 0$ per ogni $i < j$), mentre gli elementi diagonali valgono $r_{jj} = \pm 1$.

Conclusione: Una matrice triangolare superiore è ortogonale se e solo se è diagonale con entrate ± 1 .

2.6.4 Quesito 4: Isometria Euclidea e Preservazione delle Norme

Teorema 2.6.1 (Proprietà di Isometria delle Matrici Ortogonali). *Le matrici ortogonali preservano rigidamente la norma euclidea e il prodotto scalare di qualsiasi vettore dello spazio:*

$$\forall U \in \mathbb{R}^{n \times n} \text{ ortogonale}, \quad \forall \mathbf{x} \in \mathbb{R}^n \implies \|U\mathbf{x}\|_2 = \|\mathbf{x}\|_2. \quad (2.58)$$

Inoltre, preservano i prodotti scalari tra coppie di vettori generici:

$$\langle U\mathbf{x}, U\mathbf{y} \rangle = \langle \mathbf{x}, \mathbf{y} \rangle \quad \forall \mathbf{x}, \mathbf{y} \in \mathbb{R}^n. \quad (2.59)$$

Dimostrazione. Ricordiamo che per ogni vettore $\mathbf{v}$, $\|\mathbf{v}\|_2^2 = \mathbf{v}^T \mathbf{v}$. Ponendo $\mathbf{v} = U\mathbf{x}$:

$$\|U\mathbf{x}\|_2^2 = (U\mathbf{x})^T (U\mathbf{x}). \quad (2.60)$$

Applicando la proprietà di trasposizione del prodotto $(U\mathbf{x})^T = \mathbf{x}^T U^T$:

$$\|U\mathbf{x}\|_2^2 = \mathbf{x}^T (U^T U) \mathbf{x}. \quad (2.61)$$

Essendo U ortogonale, $U^T U = I_n$:

$$\|U\mathbf{x}\|_2^2 = \mathbf{x}^T I_n \mathbf{x} = \mathbf{x}^T \mathbf{x} = \|\mathbf{x}\|_2^2. \quad (2.62)$$

Estraendo la radice quadrata aritmetica, si ottiene $\|U\mathbf{x}\|_2 = \|\mathbf{x}\|_2$. Analogamente:

$$\langle U\mathbf{x}, U\mathbf{y} \rangle = (U\mathbf{x})^T (U\mathbf{y}) = \mathbf{x}^T (U^T U) \mathbf{y} = \mathbf{x}^T I_n \mathbf{y} = \mathbf{x}^T \mathbf{y} = \langle \mathbf{x}, \mathbf{y} \rangle. \quad (2.63)$$

□




Figura 2.3: Isometria euclidea di una trasformazione ortogonale U : conservazione della norma e rotazione pura.

Rilevanza Numerica Fondamentale dell'Isometria

L'uguaglianza $\|U\mathbf{x}\|_2 = \|\mathbf{x}\|_2$ rappresenta il pilastro teorico dell'analisi di stabilità numerica nell'algebra lineare. Poiché le matrici ortogonali non amplificano la norma di alcun vettore, l'applicazione di matrici ortogonali a un vettore affetto da errori di troncamento o rumore:

$$\|U(\mathbf{x} + \mathbf{e}) - U\mathbf{x}\|_2 = \|U\mathbf{e}\|_2 = \|\mathbf{e}\|_2 \quad (2.64)$$

preserva esattamente l'entità dell'errore senza ingigantirlo. Per questa ragione, algoritmi fondati su trasformazioni ortogonali (es. Householder, rotazioni di Givens e decomposizione QR) offrono eccellenti garanzie di stabilità numerica all'indietro (*backward stability*).

2.7 Formulario di Sintesi del Capitolo

La tabella 2.2 compendia i risultati analitici, le formule e le proprietà studiate nel presente capitolo.

Proprietà / Oggetto	Formulazione Matematica	Caratteristica Chiave
Prodotto Matrice-Matrice	$C_{ij} = \sum_{k=1}^m A_{ik}B_{kj}$	Richiede $A \in \mathbb{R}^{n \times m}, B \in \mathbb{R}^{m \times p}$
Costo Prodotto Quadrato	$2n^3 - n^2 \text{ FLOPs} \implies \mathcal{O}(n^3)$	Legge cubica: $T(2n) \approx 8T(n)$
Teorema Rango-Nullità	$\dim(\text{Im}(A)) + \dim(\ker(A)) = m$	m è il numero di colonne di A
Vettori Ortonormali	$\langle \mathbf{u}_i, \mathbf{u}_j \rangle = \delta_{ij}$	Ortogonalità con $\ \mathbf{u}_i\ _2 = 1$
Matrice Ortogonale	$U^T U = U U^T = I_n$	Equivalente a $U^{-1} = U^T$
Righe e Colonne di U	Formano basi ortonormali di $\mathbb{R}^n$	Deriva dal calcolo $U^T U = I_n$
Entrate di U Ortogonale	$-1 \leq U_{ij} \leq 1$	Deriva da $\sum_{i=1}^n U_{ij}^2 = 1$
Matrice Diagonale Ortogonale	$D = \text{diag}(\pm 1, \dots, \pm 1)$	2^n matrici distinte in $\mathbb{R}^{n \times n}$
Triangolare Ortogonale	$R = \text{diag}(\pm 1, \dots, \pm 1)$	Dimostrazione per induzione su colonne
Isometria Euclidea	$\ U\mathbf{x}\ _2 = \ \mathbf{x}\ _2$	Trasformazione rigida: preserva lunghezze
Invarianza del Prodotto Scalare	$\langle U\mathbf{x}, U\mathbf{y} \rangle = \langle \mathbf{x}, \mathbf{y} \rangle$	Preserva angoli tra vettori
Trasposta del Prodotto	$(AB)^T = B^T A^T$	Inverte l'ordine dei fattori

Tabella 2.2: Quadro sinottico delle definizioni, complessità computazionali e proprietà delle matrici ortogonali.

Capitolo 3

Matrici a Colonne Ortonormali, Autovalori, Decomposizione Spettrale e Forme Quadratiche

Il presente capitolo approfondisce le proprietà algebriche e geometriche delle matrici a colonne ortonormali nel caso rettangolare, confrontando sistematicamente i prodotti $V^T V$ e $V V^T$. Vengono quindi introdotti la teoria spettrale, il concetto di autovalore e autovettore, la diagonalizzazione e l'espansione diadica, culminando nel Teorema Spettrale per matrici simmetriche. Infine, si analizzano le forme quadratiche, la disuguaglianza del quoziente di Rayleigh, la classificazione delle matrici simmetriche definite e semidefinite positive (SPD e SPSD), e la genesi naturale delle strutture simmetriche tramite i gramiani $B^T B$ e $B B^T$ [2].

3.1 Richiamo sulle Matrici Ortogonali Quadrate e Isometria

Nel capitolo precedente è stata introdotta la nozione di matrice ortogonale nello spazio euclideo $\mathbb{R}^n$. Richiamiamo sinteticamente le formulazioni equivalenti che ne regolano il comportamento.

Definizione 3.1.1 (Caratterizzazioni Equivalenti di Matrice Ortogonale). Una matrice quadrata $U \in \mathbb{R}^{n \times n}$ si dice **ortogonale** se soddisfa una qualsiasi delle seguenti condizioni mutuamente equivalenti:

1. $U^T U = I_n$, ovvero l'inversa coincide con la trasposta ($U^{-1} = U^T$).

2. $UU^T = I_n$.

3. L'insieme delle colonne di $U = [\mathbf{u}_1, \dots, \mathbf{u}_n]$ costituisce una base ortonormale di $\mathbb{R}^n$:

$$\langle \mathbf{u}_i, \mathbf{u}_j \rangle = \mathbf{u}_i^T \mathbf{u}_j = \delta_{ij} = \begin{cases} 1 & \text{se } i = j, \\ 0 & \text{se } i \neq j. \end{cases} \quad (3.1)$$

4. L'insieme delle righe di U costituisce una base ortonormale di $\mathbb{R}^n$.

Chiarimento Terminologico Storico

In letteratura si adotta storicamente la locuzione *matrice ortogonale*, benché le colonne (e le righe) della matrice non siano unicamente tra loro ortogonali, bensì **normalizzate a norma unitaria**, costituendo pertanto un sistema strettamente **ortonormale**.

La caratteristica geometrica cruciale di una trasformazione ortogonale risiede nella conservazione delle distanze e delle norme euclidee, come espresso dalla proprietà di isometria.

Proprietà 3.1.1 (Isometria Euclidea). *Sia $U \in \mathbb{R}^{n \times n}$ una matrice ortogonale. Per ogni vettore $\mathbf{x} \in \mathbb{R}^n$, l'applicazione lineare preserva esattamente la norma euclidea:*

$$\|U\mathbf{x}\|_2 = \|\mathbf{x}\|_2. \quad (3.2)$$

Dimostrazione. Calcolando la norma euclidea al quadrato di $U\mathbf{x}$ e applicando l'identità $(U\mathbf{x})^T = \mathbf{x}^T U^T$:

$$\|U\mathbf{x}\|_2^2 = (U\mathbf{x})^T (U\mathbf{x}) = \mathbf{x}^T (U^T U) \mathbf{x} = \mathbf{x}^T I_n \mathbf{x} = \mathbf{x}^T \mathbf{x} = \|\mathbf{x}\|_2^2. \quad (3.3)$$

Estraendo la radice quadrata aritmetica si ottiene $\|U\mathbf{x}\|_2 = \|\mathbf{x}\|_2$. $\square$

3.2 Matrici Rettangolari a Colonne Ortonormali: $V^T V$ vs $V V^T$

Nelle applicazioni computazionali (quali la riduzione di dimensionalità, la PCA e la fattorizzazione ai valori singolari in forma compatta) si manipolano costantemente matrici rettangolari le cui colonne formano un sistema ortonormale.

3.2.1 Definizione e Vincolo sulla Dimensionalità

Definizione 3.2.1 (Matrice Rettangolare a Colonne Ortonormali). Una matrice $V \in \mathbb{R}^{n \times k}$ con $k < n$ (*tall-skinny*, ovvero alta e stretta) possiede colonne mutuamente ortonormali se:

$$V = \begin{bmatrix} | & | & \dots & | \\ \mathbf{v}_1 & \mathbf{v}_2 & \dots & \mathbf{v}_k \\ | & | & \dots & | \end{bmatrix}, \quad \mathbf{v}_i \in \mathbb{R}^n, \quad (3.4)$$

con vettori colonna soddisfacenti la condizione di ortonormalità:

$$\langle \mathbf{v}_i, \mathbf{v}_j \rangle = \mathbf{v}_i^T \mathbf{v}_j = \delta_{ij} \quad \forall i, j \in \{1, \dots, k\}. \quad (3.5)$$

Vincolo sulla Dimensione: Perché deve essere $k \leq n$?

In uno spazio vettoriale di dimensione n (come $\mathbb{R}^n$), la dimensione di qualsiasi sottospazio è al più n . Poiché ogni famiglia finita di vettori ortonormali è intrinsecamente linearmente indipendente, non possono sussistere più di n vettori ortonormali in $\mathbb{R}^n$. Di conseguenza, una matrice a colonne ortonormali può avere al massimo tante colonne quante sono le sue righe ($k \leq n$).

3.2.2 Il Prodotto $V^T V$ (Gramiano delle Colonne)

Consideriamo il prodotto tra la trasposta $V^T \in \mathbb{R}^{k \times n}$ e la matrice $V \in \mathbb{R}^{n \times k}$. Il risultato è una matrice quadrata di ordine k :

$$V^T V \in \mathbb{R}^{k \times k}. \quad (3.6)$$

Sviluppando il prodotto per blocchi, considerando V^T per righe e V per colonne:

$$V^T V = \begin{bmatrix} - & \mathbf{v}_1^T & - \\ - & \mathbf{v}_2^T & - \\ & \vdots & \\ - & \mathbf{v}_k^T & - \end{bmatrix} \begin{bmatrix} | & | & \dots & | \\ \mathbf{v}_1 & \mathbf{v}_2 & \dots & \mathbf{v}_k \\ | & | & \dots & | \end{bmatrix} = \begin{bmatrix} \mathbf{v}_1^T \mathbf{v}_1 & \mathbf{v}_1^T \mathbf{v}_2 & \dots & \mathbf{v}_1^T \mathbf{v}_k \\ \mathbf{v}_2^T \mathbf{v}_1 & \mathbf{v}_2^T \mathbf{v}_2 & \dots & \mathbf{v}_2^T \mathbf{v}_k \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{v}_k^T \mathbf{v}_1 & \mathbf{v}_k^T \mathbf{v}_2 & \dots & \mathbf{v}_k^T \mathbf{v}_k \end{bmatrix}. \quad (3.7)$$

Imponendo l'ortonormalità $\mathbf{v}_i^T \mathbf{v}_j = \delta_{ij}$, la matrice risultante coincide con l'identità di ordine k :

$$V^T V = I_k. \quad (3.8)$$

3.2.3 Il Prodotto Inverso VV^T (Proiettore Ortogonale)

Invertendo l'ordine dei fattori, otteniamo una matrice quadrata di dimensione considerevolmente superiore, pari a $n \times n$:

$$VV^T \in \mathbb{R}^{n \times n}. \quad (3.9)$$

Teorema 3.2.1 (Non-Coincidenza con l'Identità). *Sia $V \in \mathbb{R}^{n \times k}$ a colonne ortonormali con $k < n$. Allora:*

$$VV^T \neq I_n. \quad (3.10)$$

Dimostrazione. La dimostrazione discende direttamente dal teorema sul rango del prodotto matriciale:

1. Il rango del prodotto di due matrici è superiormente limitato dal rango dei singoli fattori:

$$\text{rank}(VV^T) \leq \min(\text{rank}(V), \text{rank}(V^T)). \quad (3.11)$$

2. Essendo le k colonne di V ortonormali e dunque linearmente indipendenti, si ha $\text{rank}(V) = \text{rank}(V^T) = k$.
3. Pertanto, $\text{rank}(VV^T) \leq k$. In realtà, poiché $V^TV = I_k$, vale esattamente $\text{rank}(VV^T) = k$.
4. D'altra parte, la matrice identità $I_n \in \mathbb{R}^{n \times n}$ ha rango pieno pari a n .
5. Poiché per ipotesi $k < n$, segue:

$$\text{rank}(VV^T) = k < n = \text{rank}(I_n) \implies VV^T \neq I_n. \quad (3.12)$$

La matrice VV^T è singolare e possiede un nucleo non banale di dimensione $n - k > 0$. $\square$

Espansione per Prodotti Esterni e Significato Geometrico

Applicando la decomposizione per blocchi, il prodotto VV^T può essere espresso come somma di diadi (*outer products*):

$$VV^T = \sum_{i=1}^k \mathbf{v}_i \mathbf{v}_i^T = \mathbf{v}_1 \mathbf{v}_1^T + \mathbf{v}_2 \mathbf{v}_2^T + \cdots + \mathbf{v}_k \mathbf{v}_k^T. \quad (3.13)$$

Ciascun addendo $\mathbf{v}_i \mathbf{v}_i^T$ è una matrice simmetrica di rango 1. L'operatore $P = VV^T$:

- È idempotente: $P^2 = (VV^T)(VV^T) = V(V^TV)V^T = VI_kV^T = VV^T = P$.
- È simmetrico: $P^T = (VV^T)^T = (V^T)^TV^T = VV^T = P$.

Di conseguenza, $P = VV^T$ è il **proiettore ortogonale** da $\mathbb{R}^n$ sul sottospazio generato dalle colonne di V :

$$\mathcal{S} = \text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_k\}. \quad (3.14)$$




Figura 3.1: Confronto dimensionale e di rango: il prodotto VV^T genera un proiettore ortogonale di dimensione $n \times n$ con rango strettamente deficitario $k < n$.

3.3 Isometria Parziale per Matrici Rettangolari Ortonormali

Nel caso rettangolare ($V \in \mathbb{R}^{n \times k}$ con $k < n$), la proprietà di isometria si applica asimmetricamente a seconda dello spazio di partenza del vettore.

3.3.1 Quesito (a): Conservazione della Norma per Vettori in $\mathbb{R}^k$

Proposizione 3.3.1 (Isometria Destra). *Sia $V \in \mathbb{R}^{n \times k}$ a colonne ortonormali con $k < n$. Per ogni vettore $\mathbf{x} \in \mathbb{R}^k$, vale:*

$$\|V\mathbf{x}\|_2 = \|\mathbf{x}\|_2. \quad (3.15)$$

Dimostrazione. Calcoliamo la norma quadratica dell'immagine $V\mathbf{x} \in \mathbb{R}^n$:

$$\|V\mathbf{x}\|_2^2 = (V\mathbf{x})^T(V\mathbf{x}) = \mathbf{x}^T(V^TV)\mathbf{x}. \quad (3.16)$$

Poiché le colonne di V sono ortonormali, abbiamo dimostrato che $V^T V = I_k$. Sostituendo:

$$\|V\mathbf{x}\|_2^2 = \mathbf{x}^T I_k \mathbf{x} = \mathbf{x}^T \mathbf{x} = \|\mathbf{x}\|_2^2. \quad (3.17)$$

Estraendo la radice quadrata aritmetica, $\|V\mathbf{x}\|_2 = \|\mathbf{x}\|_2$ per ogni $\mathbf{x} \in \mathbb{R}^k$. $\square$

Interpretazione Geometrica

L'applicazione $V : \mathbb{R}^k \rightarrow \mathbb{R}^n$ costituisce un'**immersione isometrica**: essa mappa lo spazio a dimensione inferiore $\mathbb{R}^k$ in un sottospazio k -dimensionale di $\mathbb{R}^n$, conservando rigorosamente lunghezze e angoli tra vettori.

3.3.2 Quesito (b): Conservazione della Norma per Vettori in $\mathbb{R}^n$ sotto V^T

Proposizione 3.3.2 (Mancata Isometria Sinistra). *Sia $V \in \mathbb{R}^{n \times k}$ a colonne ortonormali con $k < n$. L'operatore trasposto $V^T : \mathbb{R}^n \rightarrow \mathbb{R}^k$ **non** preserva la norma euclidea su tutto $\mathbb{R}^n$:*

$$\exists \mathbf{y} \in \mathbb{R}^n \quad \text{tale che} \quad \|V^T \mathbf{y}\|_2 \neq \|\mathbf{y}\|_2. \quad (3.18)$$

Dimostrazione. Valutiamo la norma euclidea al quadrato di $V^T \mathbf{y}$:

$$\|V^T \mathbf{y}\|_2^2 = (V^T \mathbf{y})^T (V^T \mathbf{y}) = \mathbf{y}^T (V V^T) \mathbf{y}. \quad (3.19)$$

Poiché $V V^T \neq I_n$, l'espressione non collassa identicamente a $\|\mathbf{y}\|_2^2$.

Controesempio basato sul nucleo: Consideriamo la matrice $V^T \in \mathbb{R}^{k \times n}$. Dal Teorema del Rango-Nullità:

$$\dim(\ker(V^T)) = n - \text{rank}(V^T) = n - k. \quad (3.20)$$

Essendo $k < n$, la dimensione del nucleo è strettamente positiva ($n - k > 0$). Esiste pertanto almeno un vettore non nullo $\tilde{\mathbf{y}} \in \mathbb{R}^n \setminus \{\mathbf{0}\}$ tale che:

$$\tilde{\mathbf{y}} \in \ker(V^T) \implies V^T \tilde{\mathbf{y}} = \mathbf{0} \in \mathbb{R}^k. \quad (3.21)$$

Calcolando le norme:

$$\|V^T \tilde{\mathbf{y}}\|_2 = \|\mathbf{0}\|_2 = 0 \neq \|\tilde{\mathbf{y}}\|_2. \quad (3.22)$$

Pertanto, la contrazione della norma è massima per tutti i vettori ortogonali al sottospazio generato dalle colonne di V . $\square$

3.4 Autovalori e Autovettori: Fondamenti ed Esempio Guida

3.4.1 Definizioni Fondamentali

Sia $A \in \mathbb{R}^{n \times n}$ una matrice **quadrata**.

Definizione 3.4.1 (Autovalore, Autovettore e Autocoppia). Uno scalare $\lambda \in \mathbb{R}$ (o in $\mathbb{C}$) è detto **autovalore** di A se esiste un vettore **non nullo** $\mathbf{v} \in \mathbb{R}^n \setminus \{\mathbf{0}\}$ (o $\mathbb{C}^n \setminus \{\mathbf{0}\}$) tale che:

$$A\mathbf{v} = \lambda\mathbf{v}. \quad (3.23)$$

Il vettore $\mathbf{v}$ è detto **autovettore** associato a λ . La coppia $(\lambda, \mathbf{v})$ è definita **autocoppia** (*eigenpair*).

L'equazione $A\mathbf{v} = \lambda\mathbf{v}$ può essere riformulata come un sistema lineare omogeneo:

$$(A - \lambda I_n)\mathbf{v} = \mathbf{0}. \quad (3.24)$$

Affinché tale sistema ammetta soluzioni non nulle ($\mathbf{v} \neq \mathbf{0}$), la matrice dei coefficienti $(A - \lambda I_n)$ deve essere singolare, ossia avere determinante nullo:

$$p(\lambda) = \det(A - \lambda I_n) = 0. \quad (3.25)$$

Il polinomio $p(\lambda)$ è il **polinomio caratteristico** di A , di grado n . Gli autovalori di A sono tutte e sole le radici (reali o complesse) del polinomio caratteristico.

3.4.2 Esempio Guidato Passo-Passo

Esempio 3.4.1 (Calcolo di Autovalori e Autovettori per Matrice 2×2). Consideriamo la matrice simmetrica reale:

$$A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \in \mathbb{R}^{2 \times 2}. \quad (3.26)$$

Passo 1: Determinazione del Polinomio Caratteristico e degli Autovalori.

$$p(\lambda) = \det(A - \lambda I_2) = \det \begin{bmatrix} 2 - \lambda & 1 \\ 1 & 2 - \lambda \end{bmatrix} = (2 - \lambda)^2 - 1. \quad (3.27)$$

Sfruttando la scomposizione come differenza di quadrati $a^2 - b^2 = (a - b)(a + b)$:

$$p(\lambda) = ((2 - \lambda) - 1)((2 - \lambda) + 1) = (1 - \lambda)(3 - \lambda) = 0. \quad (3.28)$$

Le radici del polinomio forniscono i due autovalori:

$$\lambda_1 = 3, \quad \lambda_2 = 1. \quad (3.29)$$

Passo 2: Ricerca dell'Autovettore per $\lambda_1 = 3$. Risolviamo il sistema $(A - 3I_2)\mathbf{v}_1 = \mathbf{0}$:

$$\begin{bmatrix} 2-3 & 1 \\ 1 & 2-3 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} -1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \implies -x + y = 0 \iff y = x. \quad (3.30)$$

Ponendo $x = 1$, otteniamo l'autovettore:

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}. \quad (3.31)$$

Passo 3: Ricerca dell'Autovettore per $\lambda_2 = 1$. Risolviamo il sistema $(A - I_2)\mathbf{v}_2 = \mathbf{0}$:

$$\begin{bmatrix} 2-1 & 1 \\ 1 & 2-1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \implies x+y = 0 \iff y = -x. \quad (3.32)$$

Ponendo $x = 1$, ricaviamo l'autovettore:

$$\mathbf{v}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}. \quad (3.33)$$

Si noti che $\mathbf{v}_1^T \mathbf{v}_2 = 1(1) + 1(-1) = 0$: i due autovettori risultano mutuamente ortogonali.

3.5 Diagonalizzazione ed Espansione Diadica

3.5.1 Matrici Diagonalizzabili

Definizione 3.5.1 (Diagonalizzabilità). Una matrice $A \in \mathbb{R}^{n \times n}$ si dice **diagonalizzabile** se ammette n autovettori linearmente indipendenti, ovvero se esiste una base di $\mathbb{R}^n$ formata da autovettori di A .

In tal caso, organizzando gli n autovettori nelle colonne della matrice modale $V = [\mathbf{v}_1, \dots, \mathbf{v}_n] \in \mathbb{R}^{n \times n}$ e gli autovalori sulla diagonale di $D = \text{diag}(\lambda_1, \dots, \lambda_n)$:

$$AV = A[\mathbf{v}_1, \dots, \mathbf{v}_n] = [\lambda_1 \mathbf{v}_1, \dots, \lambda_n \mathbf{v}_n] = [\mathbf{v}_1, \dots, \mathbf{v}_n] \begin{bmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_n \end{bmatrix} = VD. \quad (3.34)$$

Essendo gli autovettori linearmente indipendenti, V è invertibile. Moltiplicando a destra per V^{-1} :

$$A = VDV^{-1}. \quad (3.35)$$

3.5.2 Espansione Diadica (Outer Product Expansion)

Sia $W = V^{-1} \in \mathbb{R}^{n \times n}$. Rappresentiamo W partizionata per righe:

$$W = V^{-1} = \begin{bmatrix} - & \mathbf{w}_1^T & - \\ - & \mathbf{w}_2^T & - \\ & \vdots & \\ - & \mathbf{w}_n^T & - \end{bmatrix}. \quad (3.36)$$

Poiché $WV = I_n$, sussiste la relazione di bi-ortonormalità: $\mathbf{w}_i^T \mathbf{v}_j = \delta_{ij}$. Sviluppando la fattorizzazione $A = VDW$:

$$\begin{aligned} A &= \begin{bmatrix} | & & | \\ \mathbf{v}_1 & \dots & \mathbf{v}_n \\ | & & | \end{bmatrix} \begin{bmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_n \end{bmatrix} \begin{bmatrix} - & \mathbf{w}_1^T & - \\ & \vdots & \\ - & \mathbf{w}_n^T & - \end{bmatrix} \\ &= \begin{bmatrix} | & & | \\ \lambda_1 \mathbf{v}_1 & \dots & \lambda_n \mathbf{v}_n \\ | & & | \end{bmatrix} \begin{bmatrix} - & \mathbf{w}_1^T & - \\ & \vdots & \\ - & \mathbf{w}_n^T & - \end{bmatrix}. \end{aligned} \quad (3.37)$$

Eseguendo la moltiplicazione a blocchi colonna per riga si ottiene:

$$A = \sum_{i=1}^n \lambda_i \mathbf{v}_i \mathbf{w}_i^T = \lambda_1 \mathbf{v}_1 \mathbf{w}_1^T + \lambda_2 \mathbf{v}_2 \mathbf{w}_2^T + \dots + \lambda_n \mathbf{v}_n \mathbf{w}_n^T. \quad (3.38)$$

Significato dell'Espansione Diadica

La matrice A è espressa come combinazione lineare pesata di n matrici elementari di rango 1, ciascuna generata dal prodotto esterno $\mathbf{v}_i \mathbf{w}_i^T$. Gli autovalori λ_i agiscono come pesi di modulazione. Questa struttura analitica costituisce la base concettuale della decomposizione a valori singolari (SVD) e dell'approssimazione a basso rango di Eckart-Young-Mirsky.

3.5.3 Casi Patologici di Mancata Diagonalizzabilità

Non tutte le matrici ammettono una decomposizione $A = VDV^{-1}$ su campo reale. Esistono due ostacoli teorici fondamentali.

Caso 1: Assenza di Autovalori Reali

Consideriamo la matrice di rotazione nel piano di un angolo pari a $\theta = 90^\circ$:

$$A = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}. \quad (3.39)$$

Il relativo polinomio caratteristico è:

$$p(\lambda) = \det \begin{bmatrix} -\lambda & -1 \\ 1 & -\lambda \end{bmatrix} = \lambda^2 + 1 = 0 \implies \lambda_{1,2} = \pm i \notin \mathbb{R}. \quad (3.40)$$

Beninteso che la matrice ha entrate puramente reali, essa **non ammette autovalori né autovettori reali**. Geometricamente, una rotazione pura non banale non preserva la direzione di alcun vettore reale in $\mathbb{R}^2$.

Caso 2: Matrici Difettive (Molteplicità Geometrica Inferiore a Quella Algebrica)

Consideriamo la matrice di scorrimento (*shear matrix*):

$$A = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}. \quad (3.41)$$

1. Il polinomio caratteristico è $p(\lambda) = (1 - \lambda)^2 = 0$. Esiste un solo autovalore $\lambda = 1$ con **molteplicità algebrica** $m_a(1) = 2$.
2. Calcoliamo la **molteplicità geometrica** $m_g(1) = \dim(\ker(A - I_2))$:

$$A - I_2 = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix} \implies \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \implies y = 0, \quad x \in \mathbb{R} \text{ libero.} \quad (3.42)$$

L'autospazio associato è unidimensionale: $\ker(A - I_2) = \text{span} \left\{ \begin{bmatrix} 1 \\ 0 \end{bmatrix} \right\}$,
da cui $m_g(1) = 1$.

Poiché $m_g(1) = 1 < 2 = m_a(1)$, non è possibile reperire 2 autovettori linearmente indipendenti per costruire la matrice V . La matrice A è detta **difettiva** e non è diagonalizzabile (può essere unicamente ridotta in forma canonica di Jordan).

3.6 Esercizi Guidati sugli Autovalori (Q1 – Q4)

3.6.1 Esercizio Q1: Autocoppie di una Matrice Diagonale

Esempio 3.6.1 (Spettro di una Matrice Diagonale). Data una generica matrice diagonale $D = \text{diag}(d_1, d_2, \dots, d_n) \in \mathbb{R}^{n \times n}$, determiniamo le sue autocoppie.

Risoluzione: Valutiamo l'azione di D sul generico vettore della base canonica $\mathbf{e}_i = [0, \dots, 1, \dots, 0]^T$:

$$D\mathbf{e}_i = \begin{bmatrix} d_1 & & & \\ & d_2 & & \\ & & \ddots & \\ & & & d_n \end{bmatrix} \begin{bmatrix} 0 \\ \vdots \\ 1 \\ \vdots \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ \vdots \\ d_i \\ \vdots \\ 0 \end{bmatrix} = d_i \mathbf{e}_i. \quad (3.43)$$

Pertanto:

- Gli autovalori sono esattamente le entrate poste sulla diagonale principale: $\lambda_i = d_i$ per $i = 1, \dots, n$.
- Gli autovettori canonici associati sono i vettori della base standard: $\mathbf{v}_i = \mathbf{e}_i$.
- Le autocoppie canoniche sono $(d_1, \mathbf{e}_1), (d_2, \mathbf{e}_2), \dots, (d_n, \mathbf{e}_n)$.

Proprietà 3.6.1 (Autovalori Coincidenti e Struttura dell'Autospazio). *Cosa accade qualora due o più valori diagonali coincidano, ad esempio $d_1 = d_2 = \lambda$? In tale evenienza, **qualsiasi combinazione lineare** $\alpha\mathbf{e}_1 + \beta\mathbf{e}_2$ (con α, β non entrambi nulli) è ancora un autovettore per λ .*

Dimostrazione generale: Siano $\mathbf{v}, \mathbf{w} \in \mathbb{R}^n$ due autovettori di una matrice A associati al **medesimo** autovalore λ , ovvero $A\mathbf{v} = \lambda\mathbf{v}$ e $A\mathbf{w} = \lambda\mathbf{w}$. Per ogni coppia di scalari $\alpha, \beta \in \mathbb{R}$:

$$A(\alpha\mathbf{v} + \beta\mathbf{w}) = \alpha(A\mathbf{v}) + \beta(A\mathbf{w}) = \alpha(\lambda\mathbf{v}) + \beta(\lambda\mathbf{w}) = \lambda(\alpha\mathbf{v} + \beta\mathbf{w}). \quad (3.44)$$

Pertanto l'insieme degli autovettori associati a λ , unitamente al vettore nullo, costituisce un sottospazio vettoriale chiuso denominato **autospazio** (eigenspace):

$$\mathcal{E}(\lambda) = \ker(A - \lambda I_n). \quad (3.45)$$

3.6.2 Esercizio Q2: Autocoppie della Matrice Identità

Esempio 3.6.2 (Spettro della Matrice Identità). Determiniamo autovalori e autovettori della matrice identità $I_n \in \mathbb{R}^{n \times n}$.

Risoluzione: Per definizione dell'operatore identità, per ogni vettore non nullo $\mathbf{x} \in \mathbb{R}^n \setminus \{\mathbf{0}\}$:

$$I_n \mathbf{x} = 1 \cdot \mathbf{x}. \quad (3.46)$$

- **Autovalore:** $\lambda = 1$ con molteplicità algebrica e geometrica pari a n ($m_a = m_g = n$).
- **Autovettori:** qualsiasi vettore non nullo di $\mathbb{R}^n$.
- L'intero spazio $\mathbb{R}^n$ coincide con l'autospazio associato: $\mathcal{E}(1) = \mathbb{R}^n$.

3.6.3 Esercizio Q3: Somma e Prodotto di Matrici con Autovalore Comune

Esempio 3.6.3 (Autovalori di Somma e Prodotto di Matrici). Sia dato $\lambda \in \mathbb{R}$ autovalore comune di $A \in \mathbb{R}^{n \times n}$ e $B \in \mathbb{R}^{n \times n}$.

1. 2λ è necessariamente autovalore di $A + B$?
2. λ^2 è necessariamente autovalore di AB ?

Risposta analitica: NO a entrambi i quesiti. Affinché le relazioni spettrali valgano sulla somma o sul prodotto, le due matrici A e B devono condividere il **medesimo autovettore** associato a λ . Se i vettori propri non sono allineati, la proprietà decade.

Controesempio per la somma: Consideriamo:

$$A = \begin{bmatrix} 5 & 0 \\ 0 & 1 \end{bmatrix}, \quad B = \begin{bmatrix} 1 & 0 \\ 0 & 5 \end{bmatrix}. \quad (3.47)$$

Entrambe le matrici possiedono l'insieme di autovalori $\{1, 5\}$ (in particolare condividono $\lambda = 1$ e $\lambda = 5$). Calcoliamo la somma:

$$A + B = \begin{bmatrix} 6 & 0 \\ 0 & 6 \end{bmatrix} = 6I_2. \quad (3.48)$$

Gli autovalori di $A + B$ sono entrambi pari a 6. Tuttavia, raddoppiando gli autovalori originari:

$$2 \cdot 1 = 2 \neq 6, \quad 2 \cdot 5 = 10 \neq 6. \quad (3.49)$$

Quindi 2λ non appartiene allo spettro della matrice somma.

Controesempio per il prodotto: Consideriamo:

$$A = \begin{bmatrix} 2 & 0 \\ 0 & 3 \end{bmatrix}, \quad B = \begin{bmatrix} 10 & 0 \\ 0 & 2 \end{bmatrix}. \quad (3.50)$$

Entrambe le matrici condividono l'autovalore $\lambda = 2$. Il prodotto risulta:

$$AB = \begin{bmatrix} 20 & 0 \\ 0 & 6 \end{bmatrix}. \quad (3.51)$$

Gli autovalori di AB sono $\{20, 6\}$, nessuno dei quali coincide con $\lambda^2 = 2^2 = 4$.

3.6.4 Esercizio Q4: Autocoppie della Potenza di una Matrice

Teorema 3.6.1 (Spettro della Potenza A^k). *Sia $A \in \mathbb{R}^{n \times n}$ una matrice quadrata e sia $(\lambda, \mathbf{v})$ una sua autocoppia ($A\mathbf{v} = \lambda\mathbf{v}$). Allora per ogni esponente intero positivo $k \in \mathbb{N}$:*

$$(\lambda^k, \mathbf{v}) \text{ è un'autocoppia di } A^k, \quad \text{ovvero} \quad A^k \mathbf{v} = \lambda^k \mathbf{v}. \quad (3.52)$$

Dimostrazione. La dimostrazione procede agevolmente per induzione su k :

1. **Base dell'induzione ($k = 1$):** $A^1 \mathbf{v} = A\mathbf{v} = \lambda\mathbf{v} = \lambda^1 \mathbf{v}$.
2. **Passo induttivo:** Assumiamo vera l'ipotesi induttiva $A^k \mathbf{v} = \lambda^k \mathbf{v}$. Moltiplicando a sinistra per A :

$$A^{k+1} \mathbf{v} = A(A^k \mathbf{v}) = A(\lambda^k \mathbf{v}) = \lambda^k (A\mathbf{v}) = \lambda^k (\lambda \mathbf{v}) = \lambda^{k+1} \mathbf{v}. \quad (3.53)$$

La tesi è dunque verificata per ogni $k \geq 1$. □

Corollario 3.6.1 (Fattorizzazione della Potenza per Matrici Diagonalizzabili). *Se $A = VDV^{-1}$ è diagonalizzabile, calcolando la potenza per composizione telescopica:*

$$\begin{aligned} A^k &= (VDV^{-1})(VDV^{-1}) \cdots (VDV^{-1}) \\ &= VD(V^{-1}V)D \cdots (V^{-1}V)DV^{-1} = VD^kV^{-1}. \end{aligned} \quad (3.54)$$

Essendo $D = \text{diag}(\lambda_1, \dots, \lambda_n)$ diagonale, la sua potenza k -esima è immediata:

$$D^k = \text{diag}(\lambda_1^k, \lambda_2^k, \dots, \lambda_n^k). \quad (3.55)$$

Avvertenza sull'Invarianza dell'Autovettore

Si presti estrema attenzione al fatto che, elevando la matrice a potenza, **soltanto gli autovalori** vengono elevati alla potenza k , mentre **gli autovettori permangono rigorosamente invariati**. La scrittura $\mathbf{v}^k$ è priva di significato nell'algebra vettoriale.

3.7 Matrici Simmetriche e il Teorema Spettrale

Le matrici simmetriche costituiscono la classe di matrici più rilevante nell'algebra lineare computazionale, nell'ottimizzazione e nel machine learning.

Definizione 3.7.1 (Matrice Simmetrica). Una matrice quadrata $A \in \mathbb{R}^{n \times n}$ si dice **simmetrica** se coincide con la propria trasposta:

$$A^T = A \iff A_{ij} = A_{ji} \quad \forall i, j \in \{1, \dots, n\}. \quad (3.56)$$

Teorema 3.7.1 (Teorema Spettrale per Matrici Reali Simmetriche). Sia $A \in \mathbb{R}^{n \times n}$ una matrice simmetrica reale ($A^T = A$). Allora:

1. Tutti gli n autovalori di A sono numeri **reali**: $\lambda_1, \lambda_2, \dots, \lambda_n \in \mathbb{R}$.
2. Gli autovettori associati ad autovalori distinti sono tra loro **ortogonali**.
3. La matrice A è **ortogonalmente diagonalizzabile**: esistono una matrice ortogonale $U \in \mathbb{R}^{n \times n}$ ($U^T U = U U^T = I_n$) e una matrice diagonale reale $D \in \mathbb{R}^{n \times n}$ tali che:

$$A = U D U^T. \quad (3.57)$$

In altri termini, esiste sempre una **base ortonormale di $\mathbb{R}^n$ interamente costituita da autovettori di A** .

Ortogonalità per Autovalori Distinti. Siano $(\lambda_1, \mathbf{u}_1)$ e $(\lambda_2, \mathbf{u}_2)$ due autocopie di A , con $\lambda_1 \neq \lambda_2$. Consideriamo la quantità scalare $\mathbf{u}_1^T A \mathbf{u}_2$:

1. Calcolando l'azione di A verso destra:

$$\mathbf{u}_1^T (A \mathbf{u}_2) = \mathbf{u}_1^T (\lambda_2 \mathbf{u}_2) = \lambda_2 (\mathbf{u}_1^T \mathbf{u}_2). \quad (3.58)$$

2. Sfruttando la simmetria di A ($A = A^T$) e l'azione verso sinistra:

$$\mathbf{u}_1^T A \mathbf{u}_2 = (A^T \mathbf{u}_1)^T \mathbf{u}_2 = (A \mathbf{u}_1)^T \mathbf{u}_2 = (\lambda_1 \mathbf{u}_1)^T \mathbf{u}_2 = \lambda_1 (\mathbf{u}_1^T \mathbf{u}_2). \quad (3.59)$$

Uguagliando le due espressioni ottenute:

$$\lambda_1(\mathbf{u}_1^T \mathbf{u}_2) = \lambda_2(\mathbf{u}_1^T \mathbf{u}_2) \iff (\lambda_1 - \lambda_2)(\mathbf{u}_1^T \mathbf{u}_2) = 0. \quad (3.60)$$

Poiché per ipotesi $\lambda_1 \neq \lambda_2$, deve necessariamente risultare:

$$\mathbf{u}_1^T \mathbf{u}_2 = 0, \quad (3.61)$$

dimostrando che gli autovettori sono ortogonali. $\square$

3.8 Forme Quadratiche e Disuguaglianza di Rayleigh

3.8.1 Definizione di Forma Quadratica

Definizione 3.8.1 (Forma Quadratica). Sia $A \in \mathbb{R}^{n \times n}$ una matrice simmetrica reale. La funzione $q : \mathbb{R}^n \rightarrow \mathbb{R}$ definita da:

$$q(\mathbf{x}) = \mathbf{x}^T A \mathbf{x} = \sum_{i=1}^n \sum_{j=1}^n A_{ij} x_i x_j \quad (3.62)$$

è detta **forma quadratica** associata alla matrice A .

3.8.2 Teorema dei Limiti Spettrali (Disuguaglianza di Rayleigh)

Teorema 3.8.1 (Limiti Spettrali della Forma Quadratica). Sia $A \in \mathbb{R}^{n \times n}$ simmetrica reale, con autovalori ordinati in senso decrescente:

$$\lambda_{\max} = \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n = \lambda_{\min}. \quad (3.63)$$

Allora per ogni vettore $\mathbf{x} \in \mathbb{R}^n$ sussiste la doppia disuguaglianza:

$$\lambda_{\min} \|\mathbf{x}\|_2^2 \leq \mathbf{x}^T A \mathbf{x} \leq \lambda_{\max} \|\mathbf{x}\|_2^2. \quad (3.64)$$

Dimostrazione. La dimostrazione si articola in passaggi analitici espliciti:

1. **Fattorizzazione Spettrale:** Per il Teorema Spettrale 3.7.1, decomponiamo $A = U D U^T$, dove $U \in \mathbb{R}^{n \times n}$ è ortogonale e $D = \text{diag}(\lambda_1, \dots, \lambda_n)$.
2. **Sostituzione nella Forma Quadratica:**

$$\mathbf{x}^T A \mathbf{x} = \mathbf{x}^T (U D U^T) \mathbf{x} = (U^T \mathbf{x})^T D (U^T \mathbf{x}). \quad (3.65)$$

3. **Cambio di Coordinate Ortogonale:** Definiamo il vettore $\mathbf{y} \in \mathbb{R}^n$ tramite la trasformazione:

$$\mathbf{y} = U^T \mathbf{x} \iff \mathbf{x} = U \mathbf{y}. \quad (3.66)$$

Poiché U è ortogonale, l'applicazione preserva la norma euclidea (Proprietà 3.1.1):

$$\|\mathbf{y}\|_2^2 = \|U^T \mathbf{x}\|_2^2 = \|\mathbf{x}\|_2^2 \implies \sum_{i=1}^n y_i^2 = \|\mathbf{x}\|_2^2. \quad (3.67)$$

4. **Espansione in Componenti:**

$$\mathbf{x}^T A \mathbf{x} = \mathbf{y}^T D \mathbf{y} = \sum_{i=1}^n \lambda_i y_i^2 = \lambda_1 y_1^2 + \lambda_2 y_2^2 + \cdots + \lambda_n y_n^2. \quad (3.68)$$

5. **Derivazione del Limite Superiore:** Essendo $\lambda_i \leq \lambda_{\max}$ per ogni $i \in \{1, \dots, n\}$ e dato che $y_i^2 \geq 0$:

$$\mathbf{x}^T A \mathbf{x} = \sum_{i=1}^n \lambda_i y_i^2 \leq \sum_{i=1}^n \lambda_{\max} y_i^2 = \lambda_{\max} \sum_{i=1}^n y_i^2 = \lambda_{\max} \|\mathbf{y}\|_2^2 = \lambda_{\max} \|\mathbf{x}\|_2^2. \quad (3.69)$$

6. **Derivazione del Limite Inferiore:** In modo del tutto analogo, poiché $\lambda_i \geq \lambda_{\min}$ per ogni i :

$$\mathbf{x}^T A \mathbf{x} = \sum_{i=1}^n \lambda_i y_i^2 \geq \sum_{i=1}^n \lambda_{\min} y_i^2 = \lambda_{\min} \sum_{i=1}^n y_i^2 = \lambda_{\min} \|\mathbf{y}\|_2^2 = \lambda_{\min} \|\mathbf{x}\|_2^2. \quad (3.70)$$

Combinando i due estremi, la tesi è pienamente provata per qualsiasi $\mathbf{x} \in \mathbb{R}^n$. $\square$

3.8.3 Condizioni di Uguaglianza e Quoziente di Rayleigh

Proprietà 3.8.1 (Condizioni di Uguaglianza ed Estremi Vettoriali).

1. L'uguaglianza superiore $\mathbf{x}^T A \mathbf{x} = \lambda_{\max} \|\mathbf{x}\|_2^2$ si verifica **se e solo se** $\mathbf{x}$ è un autovettore di A associato all'autovalore massimo $\lambda_{\max}$.
2. L'uguaglianza inferiore $\mathbf{x}^T A \mathbf{x} = \lambda_{\min} \|\mathbf{x}\|_2^2$ si verifica **se e solo se** $\mathbf{x}$ è un autovettore di A associato all'autovalore minimo $\lambda_{\min}$.

Dimostrazione. Analizziamo il limite superiore:

$$\lambda_{\max} \sum_{i=1}^n y_i^2 - \sum_{i=1}^n \lambda_i y_i^2 = \sum_{i=1}^n (\lambda_{\max} - \lambda_i) y_i^2 = 0. \quad (3.71)$$

Poiché $(\lambda_{\max} - \lambda_i) \geq 0$ e $y_i^2 \geq 0$, ogni termine della sommatoria è non-negativo. La somma si annulla se e solo se, per ciascun indice i con $\lambda_i < \lambda_{\max}$, risulta $y_i = 0$. Dunque il vettore trasformato $\mathbf{y}$ possiede componenti non nulle unicamente in corrispondenza degli indici associati a $\lambda_{\max}$. Tornando alle coordinate originarie $\mathbf{x} = U\mathbf{y}$, ciò equivale ad asserire che $\mathbf{x}$ appartiene all'autospazio $\mathcal{E}(\lambda_{\max})$. $\square$

Definizione 3.8.2 (Quoziente di Rayleigh). Per ogni vettore non nullo $\mathbf{x} \in \mathbb{R}^n \setminus \{\mathbf{0}\}$, il **quoziente di Rayleigh** di una matrice simmetrica A è il rapporto scalare:

$$R_A(\mathbf{x}) = \frac{\mathbf{x}^T A \mathbf{x}}{\mathbf{x}^T \mathbf{x}} = \frac{\mathbf{x}^T A \mathbf{x}}{\|\mathbf{x}\|_2^2}. \quad (3.72)$$

Dal Teorema 3.8.1 segue immediatamente la caratterizzazione variazionale degli autovalori estremi:

$$\lambda_{\min} = \min_{\mathbf{x} \neq \mathbf{0}} R_A(\mathbf{x}), \quad \lambda_{\max} = \max_{\mathbf{x} \neq \mathbf{0}} R_A(\mathbf{x}). \quad (3.73)$$

3.9 Matrici Simmetriche Definite e Semidefinite Positive

3.9.1 Definizioni Assiomatiche

Sia $A \in \mathbb{R}^{n \times n}$ una matrice simmetrica reale ($A^T = A$).

Definizione 3.9.1 (Matrice Simmetrica Definita Positiva – SPD). La matrice A si definisce **simmetrica definita positiva** (*Symmetric Positive Definite*, SPD) se la forma quadratica associata è strettamente positiva per qualsiasi vettore non nullo:

$$\mathbf{v}^T A \mathbf{v} > 0 \quad \forall \mathbf{v} \in \mathbb{R}^n \setminus \{\mathbf{0}\}. \quad (3.74)$$

Definizione 3.9.2 (Matrice Simmetrica Semidefinita Positiva – SPSD). La matrice A si definisce **simmetrica semidefinita positiva** (*Symmetric Positive Semi-Definite*, SPSD) se la forma quadratica associata è non-negativa per qualsiasi vettore:

$$\mathbf{v}^T A \mathbf{v} \geq 0 \quad \forall \mathbf{v} \in \mathbb{R}^n. \quad (3.75)$$

3.9.2 Caratterizzazione Spettrale Equivalente

Teorema 3.9.1 (Criterio Spettrale per Matrici SPD e SPSD). *Sia $A \in \mathbb{R}^{n \times n}$ simmetrica reale con autovalori $\lambda_1, \dots, \lambda_n$. Allora:*

1. A è **SPD** $\iff \lambda_i > 0$ per ogni $i \in \{1, \dots, n\}$ (tutti gli autovalori sono strettamente positivi).
2. A è **SPSD** $\iff \lambda_i \geq 0$ per ogni $i \in \{1, \dots, n\}$ (tutti gli autovalori sono non-negativi).

Dimostrazione. La dimostrazione segue direttamente dalla disuguaglianza del quoziente di Rayleigh:

- Se tutti i $\lambda_i > 0$, allora $\lambda_{\min} > 0$. Dalla disuguaglianza $\mathbf{v}^T A \mathbf{v} \geq \lambda_{\min} \|\mathbf{v}\|_2^2$, per ogni $\mathbf{v} \neq \mathbf{0}$ si ha $\mathbf{v}^T A \mathbf{v} > 0$, dunque A è SPD.
- Viceversa, se A è SPD, scegliendo $\mathbf{v} = \mathbf{u}_i$ (autovettore unitario per λ_i):

$$\mathbf{u}_i^T A \mathbf{u}_i = \lambda_i \|\mathbf{u}_i\|_2^2 = \lambda_i > 0. \quad (3.76)$$

- Il medesimo ragionamento con disuguaglianze deboli dimostra l'equivalenza per matrici SPSD.

□

3.9.3 Gerarchia e Inclusione delle Classi Matriciali




Figura 3.2: Gerarchia strutturale e progressivo restringimento delle classi di matrici nell'algebra lineare.

Si noti che l'inclusione è stretta:

$$\text{SPD} \subset \text{SPSD} \subset \text{Simmetriche}. \quad (3.77)$$

Una matrice SPSPD appartiene alla classe SPD se e solo se è non singolare, ossia se non possiede alcun autovalore nullo ($\lambda_{\min} > 0 \iff \det(A) = \prod_{i=1}^n \lambda_i > 0$).

3.9.4 Esempi Notevoli in $\mathbb{R}^{2 \times 2}$

Esempio 3.9.1 (Verifica di Matrici SPD e SPSPD).

1. Esempi SPD:

- $A_1 = \begin{bmatrix} 1 & 0 \\ 0 & 2 \end{bmatrix}$: simmetrica diagonale con autovalori $\lambda_1 = 1 > 0, \lambda_2 = 2 > 0 \implies \text{SPD}$.
- $A_2 = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$: simmetrica con autovalori calcolati nell'Esempio 3.4.1 pari a $\lambda_1 = 3 > 0, \lambda_2 = 1 > 0 \implies \text{SPD}$.

2. Esempi SPSPD non SPD:

- $A_3 = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$: simmetrica diagonale con autovalori $\lambda_1 = 1 \geq 0, \lambda_2 = 0 \geq 0 \implies \text{SPSPD}$. Non è SPD in quanto $\det(A_3) = 0$.
- $A_4 = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$: le due righe sono identiche, quindi $\text{rank}(A_4) = 1 < 2$, implicando $\lambda_1 = 0$. Poiché la traccia eguaglia la somma degli autovalori, $\text{Tr}(A_4) = 1 + 1 = 2 \implies \lambda_1 + \lambda_2 = 2 \implies \lambda_2 = 2 \geq 0$. Dunque gli autovalori sono $\{2, 0\} \implies \text{SPSPD}$.

3. Controesempio di Matrice Indefinita: Sia la matrice proposta $A_5 = \begin{bmatrix} 1 & 2 \\ 2 & 0 \end{bmatrix}$. Sebbene le entrate diagonali siano non-negative, il determinante risulta:

$$\det(A_5) = 1(0) - 2(2) = -4 < 0. \quad (3.78)$$

Poiché $\det(A_5) = \lambda_1 \lambda_2 = -4 < 0$, i due autovalori hanno segni discordi ($\lambda_1 > 0$ e $\lambda_2 < 0$). La matrice è **indefinita** (né SPD né SPSPD).

3.10 Generazione Naturale di Matrici SPSD: $B^T B$ e BB^T

Nelle applicazioni di calcolo scientifico e statistica, le matrici simmetriche semidefinite positive non vengono solitamente costruite assemblando coefficienti a mano, bensì scaturiscono naturalmente dal prodotto di una matrice rettangolare per la propria trasposta.

Proposizione 3.10.1 (Semidefinitenza Positiva dei Gramiani). *Sia $B \in \mathbb{R}^{n \times m}$ una matrice arbitraria (quadrata o rettangolare). Allora:*

1. *La matrice quadrata $B^T B \in \mathbb{R}^{m \times m}$ è simmetrica semidefinita positiva (SPSD).*
2. *La matrice quadrata $BB^T \in \mathbb{R}^{n \times n}$ è simmetrica semidefinita positiva (SPSD).*

Dimostrazione. Dimostriamo le due proprietà separatamente:

1. Verifica della Simmetria: Applicando la proprietà distributiva della trasposizione sul prodotto matriciale:

$$(B^T B)^T = B^T (B^T)^T = B^T B, \quad (BB^T)^T = (B^T)^T B^T = BB^T. \quad (3.79)$$

Entrambe le matrici risultano formalmente simmetriche.

2. Semidefinitenza Positiva di $B^T B$: Sia $\mathbf{v} \in \mathbb{R}^m$ un qualsiasi vettore di dimensione compatibile. Esaminiamo la forma quadratica associata a $B^T B$:

$$\mathbf{v}^T (B^T B) \mathbf{v} = (\mathbf{v}^T B^T) (B \mathbf{v}) = (B \mathbf{v})^T (B \mathbf{v}). \quad (3.80)$$

Riconosciamo nel prodotto scalare $(B \mathbf{v})^T (B \mathbf{v})$ la definizione della norma euclidea al quadrato del vettore immagine $\mathbf{w} = B \mathbf{v} \in \mathbb{R}^n$:

$$\mathbf{v}^T (B^T B) \mathbf{v} = \|B \mathbf{v}\|_2^2. \quad (3.81)$$

Per il primo assioma della norma vettoriale (non-negatività), vale $\|B \mathbf{v}\|_2^2 \geq 0$ per ogni $\mathbf{v} \in \mathbb{R}^m$. Di conseguenza:

$$\mathbf{v}^T (B^T B) \mathbf{v} \geq 0 \quad \forall \mathbf{v} \in \mathbb{R}^m \implies B^T B \text{ è SPSD}. \quad (3.82)$$

3. Semidefinitenza Positiva di BB^T : Sia $\mathbf{u} \in \mathbb{R}^n$ un qualsiasi vettore. Procedendo in modo perfettamente simmetrico:

$$\mathbf{u}^T (BB^T) \mathbf{u} = (\mathbf{u}^T B) (B^T \mathbf{u}) = (B^T \mathbf{u})^T (B^T \mathbf{u}) = \|B^T \mathbf{u}\|_2^2 \geq 0 \quad \forall \mathbf{u} \in \mathbb{R}^n. \quad (3.83)$$

Pertanto anche BB^T è SPSD. $\square$

Corollario 3.10.1 (Condizione di Definitenza Stretta per $B^T B$). *La matrice $B^T B \in \mathbb{R}^{m \times m}$ è **strettamente definita positiva (SPD)** se e solo se B ha rango massimo di colonna:*

$$B^T B \in SPD \iff \text{rank}(B) = m \iff \ker(B) = \{\mathbf{0}\}. \quad (3.84)$$

Dimostrazione. Dalla dimostrazione precedente, $\mathbf{v}^T(B^T B)\mathbf{v} = \|B\mathbf{v}\|_2^2$. Tale quantità si annulla se e solo se $\|B\mathbf{v}\|_2 = 0 \iff B\mathbf{v} = \mathbf{0} \iff \mathbf{v} \in \ker(B)$. Se $\ker(B) = \{\mathbf{0}\}$, nessun vettore non nullo può azzerare la forma quadratica, rendendo $B^T B$ strettamente definita positiva. $\square$

Rilevanza nelle Equazioni Normali e nella SVD

La proprietà appena dimostrata costituisce il fondamento teorico di due pilastri del calcolo numerico:

1. **Problemi di Minimi Quadrati Lineari:** La risoluzione del problema $\min_{\mathbf{x}} \|A\mathbf{x} - \mathbf{b}\|_2$ conduce al sistema delle equazioni normali:

$$A^T A \mathbf{x} = A^T \mathbf{b}. \quad (3.85)$$

Se A ha colonne linearmente indipendenti, $A^T A$ è SPD, garantendo l'esistenza e l'unicità della soluzione (risolvibile efficientemente tramite la fattorizzazione di Cholesky).

2. **Fattorizzazione ai Valori Singolari (SVD):** I valori singolari σ_i di una matrice arbitraria B sono definiti come le radici quadrate non-negative degli autovalori della matrice SPSD $B^T B$:

$$\sigma_i = \sqrt{\lambda_i(B^T B)} \geq 0. \quad (3.86)$$

3.11 Formulario di Sintesi del Capitolo

La tabella 3.1 riassume in modo organico le definizioni, le strutture matriciali e le proprietà algebriche analizzate nel presente capitolo.

Concetto / Matrice	Formulazione Matematica	Proprietà Salienti / Spettro
Colonne Ortonormali ($k < n$)	$V \in \mathbb{R}^{n \times k}$, $\mathbf{v}_i^T \mathbf{v}_j = \delta_{ij}$	$V^T V = I_k$, mentre $V V^T \neq I_n$
Proiettore Ortogonale	$P = V V^T = \sum_{i=1}^k \mathbf{v}_i \mathbf{v}_i^T$	Simmetrico ($P^T = P$), idempotente ($P^2 = P$), $\text{rank}(P) = k$
Isometria Parziale	$\ V \mathbf{x}\ _2 = \ \mathbf{x}\ _2 \quad (\forall \mathbf{x} \in \mathbb{R}^k)$	Non preserva la norma da $\mathbb{R}^n$: $\ V^T \tilde{\mathbf{y}}\ _2 = 0$ per $\tilde{\mathbf{y}} \in \ker(V^T)$
Autocoppia	$A \mathbf{v} = \lambda \mathbf{v}$, $\mathbf{v} \neq \mathbf{0}$	λ radice di $\det(A - \lambda I_n) = 0$
Diagonalizzazione	$A = V D V^{-1}$	Richiede n autovettori linearmente indipendenti
Espansione Diadica	$A = \sum_{i=1}^n \lambda_i \mathbf{v}_i \mathbf{w}_i^T$	Combinazione lineare di n matrici di rango 1
Potenza di Matrice	$A^k = V D^k V^{-1}$	Autocoppie $(\lambda_i^k, \mathbf{v}_i)$: autovettori invariati
Teorema Spettrale	$A^T = A \implies A = U D U^T$	Autovalori reali, autovettori ortonormali ($U^T U = I_n$)
Disuguaglianza di Rayleigh	$\lambda_{\min} \ \mathbf{x}\ _2^2 \leq \mathbf{x}^T A \mathbf{x} \leq \lambda_{\max} \ \mathbf{x}\ _2^2$	Estremi raggiunti sui corrispondenti autospazi
Matrice SPD	$A^T = A$, $\mathbf{x}^T A \mathbf{x} > 0 \quad (\forall \mathbf{x} \neq \mathbf{0})$	Tutti $\lambda_i > 0$; invertibile con $\det(A) > 0$
Matrice SPSD	$A^T = A$, $\mathbf{x}^T A \mathbf{x} \geq 0 \quad (\forall \mathbf{x})$	Tutti $\lambda_i \geq 0$; ammette autovalori nulli
Gramiani $B^T B$ e $B B^T$	$\mathbf{v}^T (B^T B) \mathbf{v} = \ B \mathbf{v}\ _2^2 \geq 0$	Sempre SPSD per ogni $B \in \mathbb{R}^{n \times m}$

Tabella 3.1: Quadro sinottico delle proprietà spettrali, proiettori ortogonali e forme quadratiche.

Capitolo 4

Decomposizione a Valori Singolari (SVD): Teoria, Geometria e Applicazioni

Il presente capitolo apre la trattazione monografica avanzata dell'algebra lineare numerica moderna, introducendo la **Decomposizione a Valori Singolari** (*Singular Value Decomposition*, SVD). Dopo aver delineato il quadro metodologico complessivo dei metodi computazionali (fattorizzazioni matriciali, sistemi lineari, problemi ai minimi quadrati, calcolo di autovalori e analisi di stabilità floating-point), viene formalizzata la SVD sia nella versione estesa (*Full SVD*) che compatta (*Thin SVD*). Si sviluppa quindi la derivazione costruttiva rigorosa basata sulla decomposizione spettrale delle matrici semi-definite positive associate $A^T A$ e AA^T . Vengono infine analizzate la struttura dei quattro sottospazi fondamentali e una rassegna di problemi teorico-applicativi fondamentali per l'analisi dati e l'apprendimento automatico [7, 2, 1].

4.1 Panoramica dell'Algebra Lineare Numerica e Quadro Didattico

L'algebra lineare numerica costituisce la spina dorsale computazionale della scienza dei dati e dell'ottimizzazione [3, 2]. Nelle applicazioni reali, i modelli fisici, statistici e di machine learning raramente si presentano in forma scalare o direttamente analitica: essi si traducono quasi invariabilmente in trasformazioni di matrici su larga scala. Il percorso monografico affronta sei pilastri algoritmici essenziali:

1. **Singular Value Decomposition (SVD):** rappresenta lo strumento fondamentale per eccellenza per l'analisi spettrale di matrici generiche, rettangolari e potenzialmente a rango deficitario. Permette di identificare basi ortonormali ottimali per il dominio e il codominio, quantificare il rango numerico e calcolare la migliore approssimazione a basso rango tramite il Teorema di Eckart-Young-Mirsky.
2. **Fattorizzazione QR:** scompone una matrice $A \in \mathbb{R}^{n \times m}$ nel prodotto $A = QR$, dove Q ha colonne ortonormali e R è triangolare superiore. Essa garantisce stabilità incondizionata nella risoluzione di problemi ai minimi quadrati lineari e fornisce il motore iterativo per l'estrazione di autovalori.
3. **Metodi Numerici per Sistemi Lineari ($Ax = b$):**
 - **Formulazione generale:** data una matrice di coefficienti $A \in \mathbb{R}^{n \times n}$ e un vettore di termini noti $b \in \mathbb{R}^n$, si ricerca il vettore delle incognite $x \in \mathbb{R}^n$.
 - **Metodi Diretti:** basati su fattorizzazioni triangolari o ortogonali (LU , Cholesky LL^T , QR). In assenza di errori di roundoff, forniscono la soluzione esatta in un numero finito e deterministico di passi (con complessità tipica $\mathcal{O}(n^3)$).
 - **Metodi Iterativi:** concepiti principalmente per matrici sparse e di grandissime dimensioni ($n \gg 10^5$). Generano una successione di approssimazioni $\{x^{(k)}\}_{k \geq 0}$ a partire da un vettore iniziale $x^{(0)}$, arrestandosi quando il residuo relativo $\|b - Ax^{(k)}\|_2 / \|b\|_2$ scende al di sotto di una tolleranza prefissata ϵ_{tol} .
4. **Metodi Numerici per Problemi ai Minimi Quadrati:**

$$\min_{x \in \mathbb{R}^m} \|Ax - b\|_2, \quad (4.1)$$

con $A \in \mathbb{R}^{n \times m}$ matrice tipicamente sovradeterminata ($n > m$, configurazione geometrica “alta e stretta”) e $b \in \mathbb{R}^n$. Lo studio include sia l'approccio classico delle equazioni normali ($A^T Ax = A^T b$), sia formulazioni ortogonali stabili (QR e SVD).
5. **Metodi per il Calcolo di Autovalori e Autovettori:** algoritmi dedicati per il problema secolare $A v = \lambda v$, tra cui il metodo delle potenze, l'iterazione inversa, la deflazione e l'algoritmo QR con shift spettrale.
6. **Condizionamento e Stabilità Numerica:**

- **Aritmetica di macchina finita:** i computer moderni operano secondo lo standard IEEE 754 in virgola mobile a 64 bit (doppia precisione), introducendo a ogni operazione elementare un errore di arrotondamento relativo delimitato dalla precisione di macchina:

$$\epsilon_{\text{mach}} = 2^{-53} \approx 1.11 \times 10^{-16}. \quad (4.2)$$

- **Sensibilità del problema vs instabilità dell'algoritmo:** si analizza formalmente se l'errore finale sia imputabile alla sensibilità intrinseca del modello rispetto a perturbazioni sui dati d'ingresso (misurata dal *numero di condizionamento* $\kappa(A)$) o alla propagazione distruttiva indotta dallo specifico schema algoritmico.

Principio Guida dell'Algebra Lineare Numerica

Un algoritmo matematicamente esatto in aritmetica esatta può rivelarsi del tutto inservibile su un calcolatore elettronico qualora non sia numericamente stabile. L'uso sistematico di matrici ortogonali (che conservano le norme euclidee) è la strategia cardine per confinare rigorosamente l'amplificazione degli errori di arrotondamento.

Riferimento ai Fondamenti Numerici (Capitolo 0)

I fondamenti della propagazione dell'errore floating-point, la definizione del numero di condizionamento $\kappa(A)$ e la regola aurea che vieta la risoluzione esplicita delle equazioni normali $A^T A$ (poiché $\kappa(A^T A) = \kappa(A)^2$) sono stati discussi nel Capitolo 0 a pagina 7. In questo capitolo, la decomposizione SVD fornirà lo strumento d'elezione per calcolare soluzioni ai minimi quadrati evitando tale amplificazione del mal condizionamento.

4.2 Definizione della Decomposizione a Valori Singolari (Full SVD)

La decomposizione spettrale per matrici simmetriche analizzata nel capitolo precedente ($A = QDQ^T$) possiede un limite strutturale invalicabile: essa richiede necessariamente che la matrice sia quadrata e simmetrica. La Decomposizione a Valori Singolari supera completamente questa restrizione, estendendo i concetti di autovalore e di basi ortonormali a **qualsiasi matrice reale di dimensioni arbitrarie**.

4.2.1 Definizione Matematica Formale

Definizione 4.2.1 (Full Singular Value Decomposition (Full SVD)). Sia $A \in \mathbb{R}^{n \times m}$ una matrice reale arbitraria. Una **Decomposizione a Valori Singolari (Full SVD)** di A è una fattorizzazione del tipo:

$$A = U \Sigma V^T, \quad (4.3)$$

dove i tre fattori soddisfano rigorosamente le seguenti proprietà:

1. $U \in \mathbb{R}^{n \times n}$ è una matrice ortogonale quadrata:

$$U^T U = U U^T = I_n. \quad (4.4)$$

Le colonne di $U = [\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_n]$, con $\mathbf{u}_i \in \mathbb{R}^n$, prendono il nome di **vettori singolari sinistri** (*left singular vectors*) e costituiscono una base ortonormale di $\mathbb{R}^n$.

2. $V \in \mathbb{R}^{m \times m}$ è una matrice ortogonale quadrata:

$$V^T V = V V^T = I_m. \quad (4.5)$$

Le colonne di $V = [\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_m]$, con $\mathbf{v}_j \in \mathbb{R}^m$, prendono il nome di **vettori singolari destri** (*right singular vectors*) e costituiscono una base ortonormale di $\mathbb{R}^m$.

3. $\Sigma \in \mathbb{R}^{n \times m}$ è una matrice rettangolare avente le medesime dimensioni di A , le cui uniche entrate non nulle possono trovarsi lungo la diagonale principale:

$$\Sigma_{ii} = \sigma_i \quad \text{per } i = 1, \dots, \min\{n, m\}, \quad \Sigma_{ij} = 0 \quad \text{se } i \neq j. \quad (4.6)$$

I coefficienti scalari σ_i sono chiamati **valori singolari** di A e soddisfano la proprietà fondamentale di non-negatività e ordinamento decrescente:

$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_{\min\{n, m\}} \geq 0. \quad (4.7)$$

4.2.2 Significato Geometrico e Algebrico dell'Ortogonalità

L'ortogonalità di U e V garantisce che le colonne soddisfino la condizione di ortonormalità rispetto al prodotto scalare standard euclideo:

$$\langle \mathbf{u}_i, \mathbf{u}_j \rangle = \mathbf{u}_i^T \mathbf{u}_j = \delta_{ij}, \quad \langle \mathbf{v}_i, \mathbf{v}_j \rangle = \mathbf{v}_i^T \mathbf{v}_j = \delta_{ij}. \quad (4.8)$$

Dal punto di vista geometrico, l'azione di A su un vettore $\mathbf{x} \in \mathbb{R}^m$ può essere interpretata come una sequenza di tre trasformazioni lineari canoniche fondamentali:

$$\mathbf{x} \xrightarrow{V^T} \tilde{\mathbf{x}} = V^T \mathbf{x} \xrightarrow{\Sigma} \tilde{\mathbf{y}} = \Sigma \tilde{\mathbf{x}} \xrightarrow{U} \mathbf{y} = U \tilde{\mathbf{y}} = A\mathbf{x}. \quad (4.9)$$

- **Rotazione / riflessione in $\mathbb{R}^m$ (V^T):** il vettore $\mathbf{x}$ viene proiettato sulla base ortonormale fornita dai vettori singolari destri $\{\mathbf{v}_j\}$. Essendo V ortogonale, l'operazione preserva le lunghezze euclidee ($\|V^T \mathbf{x}\|_2 = \|\mathbf{x}\|_2$).
- **Stiramento lungo gli assi coordinati (Σ):** ciascuna coordinata viene scalata indipendentemente per il corrispondente valore singolare σ_i . Se la dimensione varia ($n \neq m$), la matrice Σ effettua anche un'immersione (in $\mathbb{R}^n$) o una proiezione.
- **Rotazione / riflessione in $\mathbb{R}^n$ (U):** il vettore scalato viene riorientato nello spazio di arrivo $\mathbb{R}^n$ secondo la base ortonormale dei vettori singolari sinistri $\{\mathbf{u}_i\}$.

4.2.3 Struttura a Blocchi di Σ e Morfologia della Matrice

A seconda del rapporto dimensionale tra il numero di righe n e il numero di colonne m , la matrice $\Sigma \in \mathbb{R}^{n \times m}$ assume tre configurazioni strutturali a blocchi ben distinte:

1. **Caso Matrice Quadrata ($n = m$):** Tutti i fattori hanno dimensione $n \times n$. La matrice Σ è puramente diagonale quadrata:

$$\Sigma = \begin{bmatrix} \sigma_1 & & 0 \\ & \ddots & \\ 0 & & \sigma_n \end{bmatrix} \in \mathbb{R}^{n \times n}. \quad (4.10)$$

2. **Caso Matrice “Bassa e Larga” ($n < m$):** Il numero di vincoli o osservazioni n è inferiore alla dimensionalità delle incognite m (sistema sottodeterminato). La matrice $U \in \mathbb{R}^{n \times n}$ è quadrata e piccola, $V \in \mathbb{R}^{m \times m}$ è quadrata e grande. La matrice Σ si partiziona in un blocco diagonale $n \times n$ seguito da un blocco nullo:

$$\Sigma = \begin{bmatrix} \Sigma_1 & 0_{n \times (m-n)} \end{bmatrix} = \begin{bmatrix} \sigma_1 & & 0 & 0 & \dots & 0 \\ & \ddots & & & & \\ 0 & & \sigma_n & 0 & \dots & 0 \end{bmatrix} \in \mathbb{R}^{n \times m}, \quad (4.11)$$

dove $\Sigma_1 = \text{diag}(\sigma_1, \dots, \sigma_n) \in \mathbb{R}^{n \times n}$.

3. **Caso Matrice “Alta e Stretta”** ($n > m$): Configurazione classica dei problemi ai minimi quadrati e del data mining (n campioni, m variabili predittive). $U \in \mathbb{R}^{n \times n}$ è una matrice quadrata molto grande, $V \in \mathbb{R}^{m \times m}$ è quadrata e piccola. La matrice Σ si partiziona verticalmente in un blocco diagonale $m \times m$ e in un blocco nullo inferiore di dimensione $(n - m) \times m$:

$$\Sigma = \begin{bmatrix} \Sigma_1 & 0 \\ 0_{(n-m) \times m} & 0 \end{bmatrix} = \begin{bmatrix} \sigma_1 & & 0 \\ & \ddots & \\ 0 & & \sigma_m \\ 0 & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & 0 \end{bmatrix} \in \mathbb{R}^{n \times m}, \quad (4.12)$$

dove $\Sigma_1 = \text{diag}(\sigma_1, \dots, \sigma_m) \in \mathbb{R}^{m \times m}$.

4.2.4 Forma Diadica (Outer Product Expansion)

Ricordando la regola generale del prodotto di matrici partizionate per colonne: date $B = [\mathbf{b}_1, \dots, \mathbf{b}_k]$ e $C = [\mathbf{c}_1, \dots, \mathbf{c}_k]$, il loro prodotto si decompone come somma di k diadi esterne:

$$BC^T = \sum_{j=1}^k \mathbf{b}_j \mathbf{c}_j^T. \quad (4.13)$$

Applicando tale espansione alla fattorizzazione SVD, poiché la matrice Σ agisce semplicemente moltiplicando la colonna j -esima di U per il fattore scalare σ_j , l'operatore matriciale A può essere scritto in modo compatto e suggestivo come:

$$A = \sum_{j=1}^{\min\{n,m\}} \sigma_j \mathbf{u}_j \mathbf{v}_j^T = \sigma_1 \mathbf{u}_1 \mathbf{v}_1^T + \sigma_2 \mathbf{u}_2 \mathbf{v}_2^T + \dots + \sigma_p \mathbf{u}_p \mathbf{v}_p^T, \quad (4.14)$$

dove $p = \min\{n, m\}$. Ciascun termine $\mathbf{u}_j \mathbf{v}_j^T \in \mathbb{R}^{n \times m}$ è una **matrice di rango 1**. L'espansione diadica esprime dunque A come combinazione lineare pesata di matrici ortonormali di rango unitario, dove i pesi coincidono con i valori singolari decrescenti $\sigma_j \geq 0$.

4.3 Esistenza e Costruzione della SVD

4.3.1 Teorema Fondamentale di Esistenza

Teorema 4.3.1 (Esistenza Globale della SVD). *Per ogni matrice reale $A \in \mathbb{R}^{n \times m}$, di dimensioni arbitrarie e di rango arbitrario, esistono due matrici ortogonali $U \in \mathbb{R}^{n \times n}$ e $V \in \mathbb{R}^{m \times m}$ e una matrice diagonale rettangolare $\Sigma \in \mathbb{R}^{n \times m}$ con elementi diagonali non-negativi ordinati $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_{\min\{n,m\}} \geq 0$ tali che:*

$$A = U\Sigma V^T. \quad (4.15)$$

4.3.2 Derivazione Costruttiva tramite Ingegneria Inversa (Reverse Engineering)

Per comprendere da dove scaturiscano naturalmente i fattori U, Σ, V , si adotta una strategia costruttiva di *reverse engineering*. Ipotizziamo a priori che la fattorizzazione $A = U\Sigma V^T$ esista ed esaminiamo il comportamento del gramiano simmetrico associato $A^T A \in \mathbb{R}^{m \times m}$:

$$\begin{aligned} A^T A &= (U\Sigma V^T)^T (U\Sigma V^T) \\ &= (V\Sigma^T U^T)(U\Sigma V^T) \\ &= V\Sigma^T (U^T U) \Sigma V^T. \end{aligned} \quad (4.16)$$

Poiché per ipotesi U è ortogonale, vale l'identità $U^T U = I_n$. Pertanto:

$$A^T A = V(\Sigma^T \Sigma) V^T. \quad (4.17)$$

Nel caso in cui $n = m$, la matrice Σ è quadrata e simmetrica ($\Sigma^T = \Sigma$), per cui $\Sigma^T \Sigma = \Sigma^2 = \text{diag}(\sigma_1^2, \dots, \sigma_n^2)$. L'equazione:

$$A^T A = V\Sigma^2 V^T \quad (4.18)$$

coincide esattamente con la **decomposizione spettrale** della matrice reale simmetrica $A^T A$. Ne deduciamo due proprietà algebriche fondamentali:

- Le colonne della matrice V devono necessariamente essere gli autovettori ortonormali della matrice $A^T A$.
- I valori singolari al quadrato σ_j^2 di A devono coincidere con gli autovalori di $A^T A$:

$$\lambda_j(A^T A) = \sigma_j^2 \implies \sigma_j = \sqrt{\lambda_j(A^T A)}. \quad (4.19)$$

In modo del tutto speculare, calcolando il gramiano esterno $AA^T \in \mathbb{R}^{n \times n}$:

$$AA^T = (U\Sigma V^T)(V\Sigma^T U^T) = U(\Sigma\Sigma^T)U^T = U\Sigma^2 U^T, \quad (4.20)$$

si evince che le colonne di U corrispondono agli autovettori ortonormali di AA^T .

4.3.3 Dimostrazione Rigorosa per Matrici Quadrate Invertibili

Formalizziamo ora la dimostrazione completa del Teorema 4.3.1 nel caso in cui $A \in \mathbb{R}^{n \times n}$ sia una matrice quadrata invertibile ($\det(A) \neq 0$).

Dimostrazione. La dimostrazione procede in cinque passi costruttivi concatenati:

Passo 1: Proprietà algebriche della matrice $A^T A$. Si consideri la matrice $M = A^T A \in \mathbb{R}^{n \times n}$.

1. M è simmetrica: $M^T = (A^T A)^T = A^T (A^T)^T = A^T A = M$.
2. M è strettamente definita positiva (SPD). Infatti, per qualsiasi vettore non nullo $\mathbf{x} \in \mathbb{R}^n \setminus \{\mathbf{0}\}$:

$$\mathbf{x}^T M \mathbf{x} = \mathbf{x}^T (A^T A) \mathbf{x} = (A\mathbf{x})^T (A\mathbf{x}) = \|A\mathbf{x}\|_2^2. \quad (4.21)$$

Poiché A è invertibile per ipotesi, il suo nucleo è banale ($\ker(A) = \{\mathbf{0}\}$); dunque $\mathbf{x} \neq \mathbf{0} \implies A\mathbf{x} \neq \mathbf{0}$, da cui $\|A\mathbf{x}\|_2^2 > 0$.

Passo 2: Decomposizione spettrale di $A^T A$. Essendo $A^T A$ una matrice simmetrica reale definita positiva, per il Teorema Spettrale esistono una matrice ortogonale $Q \in \mathbb{R}^{n \times n}$ ($Q^T Q = I_n$) e una matrice diagonale $D \in \mathbb{R}^{n \times n}$ tali che:

$$A^T A = Q D Q^T, \quad (4.22)$$

dove gli elementi diagonali di D sono tutti strettamente positivi e possono essere ordinati in senso non decrescente:

$$D = \begin{bmatrix} d_1 & & 0 \\ & \ddots & \\ 0 & & d_n \end{bmatrix}, \quad d_1 \geq d_2 \geq \dots \geq d_n > 0. \quad (4.23)$$

Passo 3: Definizione operativa dei fattori V e Σ . In coerenza con il reverse engineering, poniamo:

$$V := Q \in \mathbb{R}^{n \times n} \quad (\implies V \text{ è ortogonale: } V^T V = I_n), \quad (4.24)$$

$$\Sigma := D^{1/2} = \begin{bmatrix} \sqrt{d_1} & & 0 \\ & \ddots & \\ 0 & & \sqrt{d_n} \end{bmatrix} \in \mathbb{R}^{n \times n}. \quad (4.25)$$

Poiché ogni $d_j > 0$, i valori $\sigma_j := \sqrt{d_j}$ sono tutti numeri reali ben definiti, strettamente positivi e ordinati:

$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_n > 0. \quad (4.26)$$

Passo 4: Ricavo algebrico della matrice U . Dovendo sussistere la relazione di fattorizzazione $A = U\Sigma V^T$, sostituiamo le quantità appena introdotte:

$$A = U D^{1/2} Q^T. \quad (4.27)$$

Moltiplicando ambo i membri a destra per la matrice ortogonale Q e sfruttando l'identità $Q^T Q = I_n$, otteniamo:

$$A Q = U D^{1/2}. \quad (4.28)$$

Poiché tutti gli elementi diagonali di $D^{1/2}$ sono strettamente positivi ($\sigma_j > 0$), la matrice diagonale $D^{1/2}$ è invertibile, con inversa data da:

$$D^{-1/2} = \begin{bmatrix} \frac{1}{\sqrt{d_1}} & & 0 \\ & \ddots & \\ 0 & & \frac{1}{\sqrt{d_n}} \end{bmatrix}. \quad (4.29)$$

Possiamo quindi isolare algebricamente la matrice U :

$$U := A Q D^{-1/2}. \quad (4.30)$$

Passo 5: Verifica dell'ortogonalità della matrice U . Rimane da verificare che la matrice U così costruita sia effettivamente una matrice ortogonale, ossia che soddisfi $U^T U = I_n$. Calcoliamo esplicitamente il prodotto:

$$\begin{aligned} U^T U &= (A Q D^{-1/2})^T (A Q D^{-1/2}) \\ &= (D^{-1/2})^T Q^T A^T A Q D^{-1/2}. \end{aligned} \quad (4.31)$$

Poiché $D^{-1/2}$ è diagonale, essa coincide con la propria trasposta, $(D^{-1/2})^T = D^{-1/2}$. Sostituendo la decomposizione spettrale originaria $A^T A = Q D Q^T$:

$$\begin{aligned} U^T U &= D^{-1/2} Q^T (Q D Q^T) Q D^{-1/2} \\ &= D^{-1/2} (Q^T Q) D (Q^T Q) D^{-1/2}. \end{aligned} \quad (4.32)$$

Essendo Q ortogonale, vale $Q^T Q = I_n$:

$$\begin{aligned} U^T U &= D^{-1/2} I_n D I_n D^{-1/2} \\ &= D^{-1/2} D D^{-1/2}. \end{aligned} \quad (4.33)$$

Moltiplicando le matrici diagonali componente per componente:

$$D^{-1/2} D D^{-1/2} = \begin{bmatrix} \frac{1}{\sqrt{d_1}} \cdot d_1 \cdot \frac{1}{\sqrt{d_1}} & & 0 \\ & \ddots & \\ 0 & & \frac{1}{\sqrt{d_n}} \cdot d_n \cdot \frac{1}{\sqrt{d_n}} \end{bmatrix} = \begin{bmatrix} \frac{d_1}{d_1} & & 0 \\ & \ddots & \\ 0 & & \frac{d_n}{d_n} \end{bmatrix} = I_n. \quad (4.34)$$

Poiché $U \in \mathbb{R}^{n \times n}$ è quadrata e soddisfa $U^T U = I_n$, ne consegue che U è ortogonale ($U U^T = I_n$). La tesi è pienamente dimostrata. $\square$

4.3.4 Estensione al Caso Generale Rettangolare o con Rango Deficitario

Nel caso in cui $A \in \mathbb{R}^{n \times m}$ sia rettangolare oppure quadrata singolare, la matrice simmetrica $A^T A \in \mathbb{R}^{m \times m}$ non è più definita positiva, bensì **semi-definita positiva** (SPSD). Sia $r = \text{rank}(A) = \text{rank}(A^T A) \leq \min\{n, m\}$. Gli autovalori di $A^T A$ si partizionano in:

$$d_1 \geq d_2 \geq \dots \geq d_r > d_{r+1} = \dots = d_m = 0. \quad (4.35)$$

Di conseguenza, la matrice D ammette autovalori nulli e l'inversa globale $D^{-1/2}$ non esiste più. Si procede allora con la **costruzione colonna per colonna**:

1. Per gli indici corrispondenti a valori singolari non nulli ($j = 1, \dots, r$), si ricavano le colonne di U esattamente come nella (4.30):

$$\mathbf{u}_j := \frac{1}{\sqrt{d_j}} A \mathbf{q}_j = \frac{1}{\sigma_j} A \mathbf{v}_j. \quad (4.36)$$

Si verifica banalmente che questi r vettori $\{\mathbf{u}_1, \dots, \mathbf{u}_r\} \subset \mathbb{R}^n$ sono ortonormali:

$$\mathbf{u}_i^T \mathbf{u}_j = \left(\frac{1}{\sigma_i} A \mathbf{v}_i \right)^T \left(\frac{1}{\sigma_j} A \mathbf{v}_j \right) = \frac{\mathbf{v}_i^T (A^T A) \mathbf{v}_j}{\sigma_i \sigma_j} = \frac{\mathbf{v}_i^T (d_j \mathbf{v}_j)}{\sigma_i \sigma_j} = \frac{d_j \delta_{ij}}{\sigma_i \sigma_j} = \delta_{ij}. \quad (4.37)$$

2. Se $r < n$, i primi r vettori generano soltanto un sottospazio di dimensione r in $\mathbb{R}^n$. Per formare una base ortonormale completa di $\mathbb{R}^n$, si selezionano ulteriori $n - r$ vettori ortonormali $\{\mathbf{u}_{r+1}, \dots, \mathbf{u}_n\}$ appartenenti al complemento ortogonale $\text{span}(\mathbf{u}_1, \dots, \mathbf{u}_r)^\perp = \ker(A^T)$, ottenibili mediante il processo di ortonormalizzazione di Gram-Schmidt.

4.4 Thin SVD vs Full SVD e Profilo Computazionale

Nelle moderne applicazioni computazionali di big data e machine learning, la dimensione della matrice $A \in \mathbb{R}^{n \times m}$ è tipicamente fortemente sbilanciata ($n \gg m$, ovvero milioni di osservazioni e poche decine o centinaia di feature). In tali regimi, l'utilizzo della Full SVD si rivela disastroso in termini di memoria e tempo di calcolo.

4.4.1 Definizione della Thin SVD (Economy SVD)

Si consideri una matrice alta e stretta $A \in \mathbb{R}^{n \times m}$ con $n > m$. La Full SVD decompone A come:

$$A = U \Sigma V^T, \quad U \in \mathbb{R}^{n \times n}, \quad \Sigma \in \mathbb{R}^{n \times m}, \quad V \in \mathbb{R}^{m \times m}. \quad (4.38)$$

Poiché $n > m$, la matrice Σ contiene $(n - m)$ righe identicamente nulle nella parte inferiore:

$$\Sigma = \begin{bmatrix} \Sigma_0 \\ 0_{(n-m) \times m} \end{bmatrix}, \quad \Sigma_0 = \text{diag}(\sigma_1, \dots, \sigma_m) \in \mathbb{R}^{m \times m}. \quad (4.39)$$

Partizioniamo conformemente la matrice ortogonale U nelle prime m colonne U_0 e nelle restanti $n - m$ colonne $U_\perp$:

$$U = \begin{bmatrix} U_0 & U_\perp \end{bmatrix}, \quad U_0 \in \mathbb{R}^{n \times m}, \quad U_\perp \in \mathbb{R}^{n \times (n-m)}. \quad (4.40)$$

Eseguendo la moltiplicazione a blocchi di partizione:

$$\begin{aligned} A &= \begin{bmatrix} U_0 & U_\perp \end{bmatrix} \begin{bmatrix} \Sigma_0 \\ 0 \end{bmatrix} V^T \\ &= (U_0 \Sigma_0 + U_\perp \cdot 0) V^T \\ &= U_0 \Sigma_0 V^T. \end{aligned} \quad (4.41)$$

Si osserva immediatamente che le ultime $n - m$ colonne raccolte in $U_\perp$ vengono moltiplicate esclusivamente per entrate nulle: **esse non forniscono alcun contributo alla ricostruzione algebrica della matrice A .**

Definizione 4.4.1 (Thin SVD / Economy SVD). Data $A \in \mathbb{R}^{n \times m}$ con $n \geq m$, la **Thin SVD** (o SVD ridotta) di A è la fattorizzazione:

$$A = U_0 \Sigma_0 V^T, \quad (4.42)$$

dove:

- $U_0 \in \mathbb{R}^{n \times m}$ possiede colonne mutuamente ortonormali ($U_0^T U_0 = I_m$), ma non è quadrata (pertanto $U_0 U_0^T \neq I_n$, costituendo un proiettore ortogonale su $\text{Im}(A)$).
- $\Sigma_0 = \text{diag}(\sigma_1, \dots, \sigma_m) \in \mathbb{R}^{m \times m}$ è una matrice diagonale quadrata contenente tutti i valori singolari.
- $V \in \mathbb{R}^{m \times m}$ è la classica matrice quadrata ortogonale ($V^T V = V V^T = I_m$).

Sia la Full SVD che la Thin SVD conducono alla medesima identica espansione diadica:

$$A = \sum_{j=1}^m \sigma_j \mathbf{u}_j \mathbf{v}_j^T. \quad (4.43)$$




Figura 4.1: Confronto geometrico e strutturale a blocchi tra Full SVD e Thin SVD per una matrice alta e stretta ($n > m$).

4.4.2 Confronto di Memoria e Complessità Algoritmica Asintotica

La tabella 4.1 sintetizza il divario computazionale tra le due varianti per matrici rettangolari alte e strette con $n \geq m$.

Proprietà / Risorsa	Full SVD ($n \geq m$)	Thin SVD ($n \geq m$)
Dimensione di U	$n \times n$	$n \times m$
Dimensione di Σ	$n \times m$	$m \times m$ (quadrata)
Dimensione di V	$m \times m$	$m \times m$
Occupazione di Memoria	$\mathcal{O}(n^2)$ parole	$\mathcal{O}(nm)$ parole
Complessità Asintotica	$\mathcal{O}(n^2m)$ operazioni flop	$\mathcal{O}(nm^2)$ operazioni flop

Tabella 4.1: Confronto asintotico di occupazione spaziale e costo temporale tra Full SVD e Thin SVD.

Esempio 4.4.1 (Impatto Pratico nei Big Data). Si consideri un dataset scientifico o finanziario composto da $n = 10^6$ istanze (righe) e $m = 10$ grandezze descrittive (colonne).

- **Full SVD:** la matrice U ha dimensione $10^6 \times 10^6$, richiedendo 10^{12} numeri in virgola mobile a 64 bit. In termini di memoria RAM:

$$10^{12} \times 8 \text{ byte} = 8 \times 10^{12} \text{ byte} \approx 8 \text{ TB (Terabyte)}, \quad (4.44)$$

un quantitativo del tutto intrattabile su un singolo server convenzionale.

- **Thin SVD:** la matrice U_0 richiede unicamente $n \times m = 10^7$ elementi:

$$10^7 \times 8 \text{ byte} = 80 \text{ MB (Megabyte)}, \quad (4.45)$$

un'allocazione trascurabile gestibile istantaneamente su qualsiasi laptop.

Per questa ragione fondamentale, tutti i software e le librerie scientifiche moderne (come `scipy.linalg.svd(..., full_matrices=False)` in Python, `svd(A, 'econ')` in MATLAB e le routine LAPACK `dgesdd/dgesvd` con job 'S') adottano di default o raccomandano tassativamente l'estrazione della Thin SVD.

4.5 Rango Numerico e i Quattro Sottospazi Fondamentali

4.5.1 Determinazione Esatta del Rango tramite i Valori Singolari

Uno dei pregi teorici e numerici più eclatanti della decomposizione SVD risiede nella capacità di identificare il rango esatto e numerico di una matrice. Riprendiamo l'espansione diadica (4.14):

$$A = \sum_{j=1}^{\min\{n,m\}} \sigma_j \mathbf{u}_j \mathbf{v}_j^T. \quad (4.46)$$

Poiché i vettori $\{\mathbf{u}_j\}_{j=1}^n$ sono ortonormali in $\mathbb{R}^n$ e i vettori $\{\mathbf{v}_j\}_{j=1}^m$ sono ortonormali in $\mathbb{R}^m$, ogni singolo termine $\mathbf{u}_j \mathbf{v}_j^T$ possiede rango esattamente pari a 1. Inoltre, le matrici di rango uno sono ortogonali a due a due rispetto al prodotto scalare di Frobenius:

$$\langle \mathbf{u}_i \mathbf{v}_i^T, \mathbf{u}_j \mathbf{v}_j^T \rangle_F = \text{Tr} \left((\mathbf{u}_i \mathbf{v}_i^T)^T (\mathbf{u}_j \mathbf{v}_j^T) \right) = \text{Tr} \left(\mathbf{v}_i \mathbf{u}_i^T \mathbf{u}_j \mathbf{v}_j^T \right) = \delta_{ij} \delta_{ij} = \delta_{ij}. \quad (4.47)$$

Da ciò consegue immediatamente la seguente proposizione:

Proposizione 4.5.1 (Caratterizzazione del Rango via SVD). *Il rango di $A \in \mathbb{R}^{n \times m}$ coincide esattamente con il numero di valori singolari strettamente positivi:*

$$\text{rank}(A) = r \iff \sigma_1 \geq \dots \geq \sigma_r > \sigma_{r+1} = \dots = \sigma_{\min\{n,m\}} = 0. \quad (4.48)$$

Ne consegue che la somma diadica può arrestarsi all'indice r :

$$A = \sum_{j=1}^r \sigma_j \mathbf{u}_j \mathbf{v}_j^T. \quad (4.49)$$

4.5.2 Caratterizzazione Completa dei Quattro Sottospazi Fondamentali

La Full SVD genera automaticamente basi ortonormali complete per tutti e quattro i sottospazi fondamentali dell'algebra lineare associati a A e A^T . Per comprendere il meccanismo analitico in piena trasparenza, analizziamo in dettaglio il caso didattico esaminato in aula: una matrice $A \in \mathbb{R}^{6 \times 4}$ ($n = 6, m = 4$) avente rango $r = 3$.

In questo caso, la matrice Σ contiene $r = 3$ valori singolari strettamente positivi $\sigma_1 \geq \sigma_2 \geq \sigma_3 > 0$ e un quarto valore nullo $\sigma_4 = 0$:

$$A = \sigma_1 \mathbf{u}_1 \mathbf{v}_1^T + \sigma_2 \mathbf{u}_2 \mathbf{v}_2^T + \sigma_3 \mathbf{u}_3 \mathbf{v}_3^T. \quad (4.50)$$

1. Nucleo di A ($\ker(A) \subseteq \mathbb{R}^4$). Il nucleo è definito dall'insieme $\{\mathbf{x} \in \mathbb{R}^4 : A\mathbf{x} = \mathbf{0}\}$. Moltiplichiamo A per il quarto vettore singolare destro $\mathbf{v}_4$:

$$\begin{aligned} A\mathbf{v}_4 &= (\sigma_1 \mathbf{u}_1 \mathbf{v}_1^T + \sigma_2 \mathbf{u}_2 \mathbf{v}_2^T + \sigma_3 \mathbf{u}_3 \mathbf{v}_3^T) \mathbf{v}_4 \\ &= \sigma_1 \mathbf{u}_1 (\mathbf{v}_1^T \mathbf{v}_4) + \sigma_2 \mathbf{u}_2 (\mathbf{v}_2^T \mathbf{v}_4) + \sigma_3 \mathbf{u}_3 (\mathbf{v}_3^T \mathbf{v}_4). \end{aligned} \quad (4.51)$$

Essendo la matrice V ortogonale, le sue colonne sono ortonormali: $\mathbf{v}_1^T \mathbf{v}_4 = 0$, $\mathbf{v}_2^T \mathbf{v}_4 = 0$, $\mathbf{v}_3^T \mathbf{v}_4 = 0$. Pertanto:

$$A\mathbf{v}_4 = \mathbf{0} \implies \mathbf{v}_4 \in \ker(A). \quad (4.52)$$

Per il teorema del rango-nullità, $\dim(\ker(A)) = m - r = 4 - 3 = 1$. Essendo $\mathbf{v}_4$ un vettore non nullo (ha norma 1), esso costituisce una base ortonormale del nucleo:

$$\ker(A) = \text{span}\{\mathbf{v}_4\}. \quad (4.53)$$

2. Immagine di A ($\text{Im}(A) \subseteq \mathbb{R}^6$). L'immagine è lo spazio $\{A\mathbf{x} : \mathbf{x} \in \mathbb{R}^4\}$. Per qualsiasi vettore $\mathbf{x} \in \mathbb{R}^4$:

$$\begin{aligned} A\mathbf{x} &= \sigma_1 \mathbf{u}_1(\mathbf{v}_1^T \mathbf{x}) + \sigma_2 \mathbf{u}_2(\mathbf{v}_2^T \mathbf{x}) + \sigma_3 \mathbf{u}_3(\mathbf{v}_3^T \mathbf{x}) \\ &= (\sigma_1 \mathbf{v}_1^T \mathbf{x}) \mathbf{u}_1 + (\sigma_2 \mathbf{v}_2^T \mathbf{x}) \mathbf{u}_2 + (\sigma_3 \mathbf{v}_3^T \mathbf{x}) \mathbf{u}_3. \end{aligned} \quad (4.54)$$

Poiché i coefficienti scalari tra parentesi possono assumere valori arbitrari in $\mathbb{R}$, qualsiasi vettore $A\mathbf{x}$ risulta essere combinazione lineare unicamente delle prime tre colonne di U . Poiché $\{\mathbf{u}_1, \mathbf{u}_2, \mathbf{u}_3\}$ sono vettori ortonormali (dunque linearmente indipendenti) e $\dim(\text{Im}(A)) = r = 3$:

$$\text{Im}(A) = \text{span}\{\mathbf{u}_1, \mathbf{u}_2, \mathbf{u}_3\}. \quad (4.55)$$

3. Immagine e Nucleo della Trasposta A^T . Considerando la trasposta $A^T = (U\Sigma V^T)^T = V\Sigma^T U^T$, i ruoli delle basi U e V risultano esattamente scambiati:

$$A^T = \sigma_1 \mathbf{v}_1 \mathbf{u}_1^T + \sigma_2 \mathbf{v}_2 \mathbf{u}_2^T + \sigma_3 \mathbf{v}_3 \mathbf{u}_3^T. \quad (4.56)$$

Applicando il medesimo ragionamento:

- **Immagine di A^T** ($\text{Im}(A^T) \subseteq \mathbb{R}^4$):

$$\text{Im}(A^T) = \text{span}\{\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3\}. \quad (4.57)$$

- **Nucleo di A^T** ($\ker(A^T) \subseteq \mathbb{R}^6$): moltiplicando A^T per i rimanenti vettori singolari sinistri $\mathbf{u}_4, \mathbf{u}_5, \mathbf{u}_6$, per ortonormalità si ottiene $A^T \mathbf{u}_k = \mathbf{0}$ per ogni $k \in \{4, 5, 6\}$. Poiché $\dim(\ker(A^T)) = n - r = 6 - 3 = 3$:

$$\ker(A^T) = \text{span}\{\mathbf{u}_4, \mathbf{u}_5, \mathbf{u}_6\}. \quad (4.58)$$

Teorema 4.5.1 (Teorema Fondamentale dei Sottospazi via SVD). *Sia $A \in \mathbb{R}^{n \times m}$ con SVD $A = U\Sigma V^T$ e rango r . Allora le colonne di U e V forniscono direttamente basi ortonormali per i quattro sottospazi fondamentali:*

1. $\text{Im}(A) = \text{span}\{\mathbf{u}_1, \dots, \mathbf{u}_r\} \subseteq \mathbb{R}^n$ (dimensione r).
2. $\ker(A^T) = \text{span}\{\mathbf{u}_{r+1}, \dots, \mathbf{u}_n\} \subseteq \mathbb{R}^n$ (dimensione $n - r$).
3. $\text{Im}(A^T) = \text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_r\} \subseteq \mathbb{R}^m$ (dimensione r).
4. $\ker(A) = \text{span}\{\mathbf{v}_{r+1}, \dots, \mathbf{v}_m\} \subseteq \mathbb{R}^m$ (dimensione $m - r$).

Inoltre, sussistono le relazioni di ortogonalità diretta:

$$\text{Im}(A) \oplus \ker(A^T) = \mathbb{R}^n, \quad \text{Im}(A^T) \oplus \ker(A) = \mathbb{R}^m. \quad (4.59)$$

4.6 Problemi ed Esercizi Applicativi Svolti

Durante la sessione di lavoro guidato in aula [intervallo temporale 80:00 - 104:00], gli studenti affrontano una sequenza di quattro problemi concettuali fondamentali. Dal confronto con la docente emergono una serie di errori tipici, fraintendimenti diffusi e precisazioni essenziali, prima della formalizzazione conclusiva delle soluzioni alla lavagna [104:00 - 111:06].

Valore Didattico ed Errori Comuni Emersi in Aula

Nei compiti d'esame e nelle prove orali di calcolo numerico, questi problemi rappresentano snodi concettuali critici:

1. **Inversione dell'ordinamento in A^{-1} :** molti studenti scrivono semplicemente $A^{-1} = V\Sigma^{-1}U^T$ ritenendo concluso l'esercizio. Tuttavia, poiché $\sigma_1 \geq \dots \geq \sigma_n > 0$, i reciproci sono in ordine strettamente crescente ($1/\sigma_1 \leq \dots \leq 1/\sigma_n$), violando la definizione di SVD. È indispensabile riordinare colonne e diagonale.
2. **Il prodotto V^TU in A^2 :** si tende erroneamente ad affermare che i valori singolari di A^2 siano σ_i^2 . Poiché V e U sono matrici ortogonali distinte, $V^TU \neq I_n$, rendendo il blocco centrale non diagonale (la proprietà vale solo se A è normale).
3. **Normalizzazione unitaria nel rango 1 ($A = \mathbf{x}\mathbf{y}^T$):** non è lecito porre $\mathbf{u}_1 = \mathbf{x}$, $\mathbf{v}_1 = \mathbf{y}$ e $\sigma_1 = 1$, poiché le colonne di U e V devono avere norma euclidea esattamente pari a 1. I fattori di scala confluiscono nel valore singolare $\sigma_1 = \|\mathbf{x}\|_2\|\mathbf{y}\|_2 \geq 0$.
4. **Autovalori negativi in matrici simmetriche ($A = QDQ^T$):** D contiene autovalori reali con segno arbitrario. Per ricondursi a valori singolari non negativi $\sigma_i = |\lambda_i| \geq 0$, l'eventuale segno negativo deve essere assorbito nel vettore singolare sinistro ($\mathbf{u}_j = -\mathbf{q}_j$).

4.6.1 Problema 1: SVD dell'Inversa di una Matrice Quadrata

Esempio 4.6.1 (SVD dell'Inversa A^{-1}). **Enunciato:** Sia $A \in \mathbb{R}^{n \times n}$ una matrice quadrata invertibile, con SVD nota $A = U\Sigma V^T$. Determinare la forma canonica formale della SVD dell'inversa A^{-1} .

Risoluzione Dettagliata:

1. Poiché A è invertibile, ha rango massimo $\text{rank}(A) = n$. Ciò implica che tutti i suoi valori singolari sono strettamente positivi:

$$\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_n > 0. \quad (4.60)$$

2. Calcoliamo l'inversa algebrica sfruttando le proprietà dell'inversa di un prodotto matriciale:

$$A^{-1} = (U\Sigma V^T)^{-1} = (V^T)^{-1}\Sigma^{-1}U^{-1}. \quad (4.61)$$

3. Poiché U e V sono matrici ortogonali, le loro inverse coincidono con le rispettive trasposte:

$$(V^T)^{-1} = (V^{-1})^{-1} = V, \quad U^{-1} = U^T. \quad (4.62)$$

Sostituendo, otteniamo la decomposizione preliminare:

$$A^{-1} = V\Sigma^{-1}U^T. \quad (4.63)$$

4. Analizziamo la matrice diagonale Σ^{-1} :

$$\Sigma^{-1} = \text{diag}\left(\frac{1}{\sigma_1}, \frac{1}{\sigma_2}, \dots, \frac{1}{\sigma_n}\right). \quad (4.64)$$

Tuttavia, poiché per ipotesi $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_n > 0$, passando ai valori reciproci l'ordinamento naturale si inverte completamente:

$$\frac{1}{\sigma_n} \geq \frac{1}{\sigma_{n-1}} \geq \cdots \geq \frac{1}{\sigma_1} > 0. \quad (4.65)$$

Affinché l'espressione costituisca formalmente una SVD valida secondo la Definizione 4.2.1, i valori singolari devono essere tassativamente ordinati in senso decrescente.

5. **Riorganizzazione canonica:** Definiamo la matrice di permutazione invertente $J \in \mathbb{R}^{n \times n}$ (matrice antidiagonale unitaria):

$$J = \begin{bmatrix} 0 & \cdots & 0 & 1 \\ 0 & \cdots & 1 & 0 \\ \vdots & \ddots & \vdots & \vdots \\ 1 & \cdots & 0 & 0 \end{bmatrix}, \quad J = J^T = J^{-1}. \quad (4.66)$$

Inserendo l'identità $I_n = JJ$ nell'espressione di A^{-1} :

$$A^{-1} = V(JJ)\Sigma^{-1}(JJ)U^T = (VJ)(J\Sigma^{-1}J)(UJ)^T. \quad (4.67)$$

Ponendo:

- $\tilde{U} := VJ = [\mathbf{v}_n, \mathbf{v}_{n-1}, \dots, \mathbf{v}_1] \in \mathbb{R}^{n \times n}$ (ortogonale, colonne invertite di V),
- $\tilde{\Sigma} := J\Sigma^{-1}J = \text{diag}\left(\frac{1}{\sigma_n}, \frac{1}{\sigma_{n-1}}, \dots, \frac{1}{\sigma_1}\right)$ (diagonale, ordinamento corretto),
- $\tilde{V} := UJ = [\mathbf{u}_n, \mathbf{u}_{n-1}, \dots, \mathbf{u}_1] \in \mathbb{R}^{n \times n}$ (ortogonale, colonne invertite di U),

la forma canonica rigorosa della SVD dell'inversa è:

$$A^{-1} = \tilde{U}\tilde{\Sigma}\tilde{V}^T = \begin{bmatrix} \mathbf{v}_n & \dots & \mathbf{v}_1 \end{bmatrix} \begin{bmatrix} \frac{1}{\sigma_n} & & 0 \\ & \ddots & \\ 0 & & \frac{1}{\sigma_1} \end{bmatrix} \begin{bmatrix} \mathbf{u}_n^T \\ \vdots \\ \mathbf{u}_1^T \end{bmatrix}. \quad (4.68)$$

Estensione: Pseudo-inversa di Moore-Penrose ($A^\dagger$)

Qualora la matrice $A \in \mathbb{R}^{n \times m}$ non sia quadrata o abbia rango deficitario $r < \min\{n, m\}$, l'inversa ordinaria non esiste. Si definisce allora la **pseudo-inversa di Moore-Penrose** $A^\dagger \in \mathbb{R}^{m \times n}$ tramite la SVD:

$$A^\dagger = V\Sigma^\dagger U^T, \quad (4.69)$$

dove $\Sigma^\dagger \in \mathbb{R}^{m \times n}$ è ottenuta invertendo i soli valori singolari non nulli e lasciando nulle tutte le altre entrate:

$$\Sigma^\dagger = \begin{bmatrix} \frac{1}{\sigma_1} & & 0 & 0 & \dots & 0 \\ & \ddots & & & & \\ 0 & & \frac{1}{\sigma_r} & 0 & \dots & 0 \\ 0 & \dots & 0 & 0 & \dots & 0 \\ \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ 0 & \dots & 0 & 0 & \dots & 0 \end{bmatrix}. \quad (4.70)$$

La pseudo-inversa fornisce la soluzione a norma minima del problema ai minimi quadrati generale.

4.6.2 Problema 2: SVD del Quadrato di una Matrice (A^2)

Esempio 4.6.2 (SVD di A^2 e il Fallimento della Diagonalizzazione Banale).
Enunciato: Sia $A \in \mathbb{R}^{n \times n}$ una matrice quadrata con SVD $A = U\Sigma V^T$. È

possibile ottenere la SVD di A^2 elevando semplicemente al quadrato i valori singolari?

Analisi Critica: Calcoliamo la potenza seconda di A sostituendo la fattorizzazione SVD:

$$\begin{aligned} A^2 &= (U\Sigma V^T)(U\Sigma V^T) \\ &= U\Sigma(V^T U)\Sigma V^T. \end{aligned} \quad (4.71)$$

Poiché U e V sono matrici ortogonali generiche e tra loro indipendenti, il loro prodotto scalare mutuo $V^T U$:

$$V^T U \neq I_n \quad (\text{in generale}). \quad (4.72)$$

Di conseguenza, il blocco intermedio $\Sigma(V^T U)\Sigma$ non è una matrice diagonale.

Conclusione Fondamentale

Per una generica matrice quadrata A , i valori singolari di A^2 **non sono affatto** i quadrati dei valori singolari di A :

$$\sigma_i(A^2) \neq \sigma_i(A)^2 \quad (\text{in generale}). \quad (4.73)$$

L'uguaglianza $\sigma_i(A^2) = \sigma_i(A)^2$ sussiste se e solo se la matrice è **normale** ($A^T A = A A^T$), classe che comprende le matrici simmetriche, antisimmetriche e ortogonali.

4.6.3 Problema 3: Thin SVD di una Matrice di Rango 1

Esempio 4.6.3 (Thin SVD di una Matrice a Rango Unitario $A = \mathbf{xy}^T$).

Enunciato: Siano $\mathbf{x} \in \mathbb{R}^n \setminus \{\mathbf{0}\}$ e $\mathbf{y} \in \mathbb{R}^m \setminus \{\mathbf{0}\}$ due vettori colonna non nulli. Sia $A = \mathbf{xy}^T \in \mathbb{R}^{n \times m}$ la matrice generata dal loro prodotto esterno. Determinare la Thin SVD di A .

Risoluzione Dettagliata:

1. La matrice $A = \mathbf{xy}^T$ ha chiaramente rango $\text{rank}(A) = 1$, poiché tutte le sue colonne sono multipli scalari del singolo vettore $\mathbf{x}$.
2. Possedendo un unico valore singolare strettamente positivo, la sua espansione Thin SVD assume la forma compatta a un solo termine:

$$A = \sigma_1 \mathbf{u}_1 \mathbf{v}_1^T, \quad (4.74)$$

con il vincolo normativo fondamentale:

$$\|\mathbf{u}_1\|_2 = 1, \quad \|\mathbf{v}_1\|_2 = 1, \quad \sigma_1 > 0. \quad (4.75)$$

3. Riscriviamo i vettori $\mathbf{x}$ e $\mathbf{y}$ evidenziando la loro norma euclidea:

$$\mathbf{x} = \|\mathbf{x}\|_2 \left(\frac{\mathbf{x}}{\|\mathbf{x}\|_2} \right), \quad \mathbf{y} = \|\mathbf{y}\|_2 \left(\frac{\mathbf{y}}{\|\mathbf{y}\|_2} \right). \quad (4.76)$$

4. Sostituendo nel prodotto esterno:

$$\begin{aligned} A = \mathbf{x}\mathbf{y}^T &= \left[\|\mathbf{x}\|_2 \left(\frac{\mathbf{x}}{\|\mathbf{x}\|_2} \right) \right] \left[\|\mathbf{y}\|_2 \left(\frac{\mathbf{y}}{\|\mathbf{y}\|_2} \right) \right]^T \\ &= (\|\mathbf{x}\|_2 \|\mathbf{y}\|_2) \left(\frac{\mathbf{x}}{\|\mathbf{x}\|_2} \right) \left(\frac{\mathbf{y}}{\|\mathbf{y}\|_2} \right)^T. \end{aligned} \quad (4.77)$$

5. Identificando direttamente con la forma diadica $\sigma_1 \mathbf{u}_1 \mathbf{v}_1^T$:

$$\sigma_1 = \|\mathbf{x}\|_2 \|\mathbf{y}\|_2, \quad (4.78)$$

$$\mathbf{u}_1 = \frac{\mathbf{x}}{\|\mathbf{x}\|_2} \in \mathbb{R}^n, \quad (4.79)$$

$$\mathbf{v}_1 = \frac{\mathbf{y}}{\|\mathbf{y}\|_2} \in \mathbb{R}^m. \quad (4.80)$$

Entrambi i vettori sono chiaramente a norma unitaria e $\sigma_1 > 0$. La Thin SVD è dunque completamente determinata.

4.6.4 Problema 4: SVD di una Matrice Simmetrica dalla Decomposizione Spettrale

Esempio 4.6.4 (Ricavo della SVD da Decomposizione Spettrale $A = QDQ^T$).

Enunciato: Sia $A \in \mathbb{R}^{n \times n}$ una matrice simmetrica ($A^T = A$), con decomposizione spettrale nota $A = QDQ^T$, dove Q è ortogonale e $D = \text{diag}(\lambda_1, \dots, \lambda_n)$. Come si deduce la SVD formale di A ?

Risoluzione e Discussione:

1. Una matrice simmetrica ammette autovalori reali $\lambda_i \in \mathbb{R}$, i quali tuttavia possono assumere valore negativo ($\lambda_i < 0$).
2. I valori singolari σ_i devono per definizione essere non negativi ($\sigma_i \geq 0$). Poiché $A^T A = (QDQ^T)(QDQ^T) = QD^2Q^T$, gli autovalori di $A^T A$ sono λ_i^2 , da cui:

$$\sigma_i = \sqrt{\lambda_i^2} = |\lambda_i|. \quad (4.81)$$

3. Riconciliazione dei segni nei vettori singolari: scrivendo l'espansione spettrale per sommatoria diadica:

$$A = \sum_{j=1}^n \lambda_j \mathbf{q}_j \mathbf{q}_j^T. \quad (4.82)$$

Possiamo isolare il segno dell'autovalore $\text{sgn}(\lambda_j) \in \{+1, -1\}$ (ponendo arbitrariamente $\text{sgn}(0) = +1$):

$$\lambda_j \mathbf{q}_j \mathbf{q}_j^T = |\lambda_j| (\text{sgn}(\lambda_j) \mathbf{q}_j) \mathbf{q}_j^T. \quad (4.83)$$

Ne consegue che, per ciascun autovalore:

$$\sigma_j = |\lambda_j|, \quad \mathbf{u}_j = \text{sgn}(\lambda_j) \mathbf{q}_j, \quad \mathbf{v}_j = \mathbf{q}_j. \quad (4.84)$$

Se $\lambda_j < 0$, il segno negativo viene assorbito invertendo la direzione del vettore singolare sinistro $\mathbf{u}_j = -\mathbf{q}_j$, conservando la normalizzazione $\|\mathbf{u}_j\|_2 = 1$.

4. Infine, per soddisfare l'assioma di ordinamento della SVD ($\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_n \geq 0$), è sufficiente permutare simultaneamente le colonne di U , le colonne di V e gli elementi di Σ ordinando i moduli decrescenti $|\lambda_{\pi(1)}| \geq |\lambda_{\pi(2)}| \geq \dots \geq |\lambda_{\pi(n)}|$.

Raccordo Didattico con la Lezione Successiva

Come discusso in aula [100:31 - 103:59] e formalizzato alla lavagna, la trattazione estesa del Problema 4, insieme all'introduzione delle norme matriciali indotte, all'analisi di sensitività e alle applicazioni avanzate della SVD (compressione di immagini e Principal Component Analysis), costituisce il punto di partenza naturale della lezione successiva.

4.7 Formulario di Sintesi del Capitolo

La tabella 4.2 fornisce una visione d'insieme strutturata delle definizioni, delle fattorizzazioni e delle proprietà algebriche analizzate in questo capitolo.

Concetto / Oggetto	Formulazione Matematica	Proprietà / Note Fondamentali
Full SVD	$A = U\Sigma V^T$	$U \in \mathbb{R}^{n \times n}$ ort., $V \in \mathbb{R}^{m \times m}$ ort., $\Sigma \in \mathbb{R}^{n \times m}$ diag.
Valori Singolari	$\sigma_i = \sqrt{\lambda_i(A^T A)}$	Reali, ordinati: $\sigma_1 \geq \dots \geq \sigma_{\min\{n,m\}} \geq 0$
Espansione Diadica	$A = \sum_{j=1}^{\text{rank}(A)} \sigma_j \mathbf{u}_j \mathbf{v}_j^T$	Somma pesata di matrici ortonormali di rango 1
Thin SVD ($n \geq m$)	$A = U_0 \Sigma_0 V^T$	$U_0 \in \mathbb{R}^{n \times m}$ ($U_0^T U_0 = I_m$), $\Sigma_0 \in \mathbb{R}^{m \times m}$
Costo Computazionale Thin	$\mathcal{O}(nm^2)$ flop, memoria $\mathcal{O}(nm)$	Risparmio critico quando $n \gg m$ rispetto a Full ($\mathcal{O}(n^2 m)$)
Rango Matrice	$\text{rank}(A) = r$	Numero di valori singolari strettamente positivi $\sigma_j > 0$
Immagine $\text{Im}(A)$	$\text{span}\{\mathbf{u}_1, \dots, \mathbf{u}_r\} \subseteq \mathbb{R}^n$	Base ortonormale dai primi r vettori di U
Nucleo $\ker(A)$	$\text{span}\{\mathbf{v}_{r+1}, \dots, \mathbf{v}_m\} \subseteq \mathbb{R}^m$	Base ortonormale dagli ultimi $m - r$ vettori di V
Immagine Trasposta $\text{Im}(A^T)$	$\text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_r\} \subseteq \mathbb{R}^m$	Base ortonormale dai primi r vettori di V
Nucleo Trasposta $\ker(A^T)$	$\text{span}\{\mathbf{u}_{r+1}, \dots, \mathbf{u}_n\} \subseteq \mathbb{R}^n$	Base ortonormale dagli ultimi $n - r$ vettori di U
SVD dell'Inversa	$A^{-1} = \tilde{U} \tilde{\Sigma} \tilde{V}^T$	$\tilde{\sigma}_i = 1/\sigma_{n-i+1}$, basi invertite e scambiate
Pseudo-inversa Moore-Penrose	$A^\dagger = V \Sigma^\dagger U^T$	$\Sigma^\dagger_i = 1/\sigma_i$ per $i \leq r$, zeri altrove
SVD Matrice Rango 1 ($A = \mathbf{x} \mathbf{y}^T$)	$\sigma_1 = \ \mathbf{x}\ _2 \ \mathbf{y}\ _2$, $\mathbf{u}_1 = \frac{\mathbf{x}}{\ \mathbf{x}\ _2}$, $\mathbf{v}_1 = \frac{\mathbf{y}}{\ \mathbf{y}\ _2}$	$\text{rank}(A) = 1$, unico termine singolare
SVD Matrice Simmetrica	$\sigma_i = \lambda_i $, $\mathbf{u}_i = \text{sgn}(\lambda_i) \mathbf{q}_i$, $\mathbf{v}_i = \mathbf{q}_i$	Dedotta dalla decomposizione spettrale $A = Q D Q^T$

Tabella 4.2: Quadro sinottico completo della Decomposizione a Valori Singolari (SVD), sottospazi associati e proprietà algebriche.

Capitolo 5

SVD, Norme Matriciali e Applicazioni: Teorema di Eckart-Young, Compressione e PCA

Il presente capitolo approfondisce le implicazioni analitiche, geometriche e computazionali della **Decomposizione a Valori Singolari** (*Singular Value Decomposition*, SVD). Partendo dal raccordo tra la versione estesa (*Full SVD*) e la variante compatta a memoria ridotta (*Thin SVD*), viene sviluppata la teoria rigorosa delle **norme matriciali indotte** e della **norma di Frobenius**, derivando in dettaglio l'espressione analitica della norma spettrale $\|A\|_2 = \sigma_1$ e della norma di Frobenius $\|A\|_F = \sqrt{\sum \sigma_i^2}$. Viene quindi formalizzato e dimostrato il fondamentale **Teorema di Eckart-Young-Mirsky** per l'approssimazione ottimale a basso rango, quantificando esattamente l'errore residuo in ambo le norme. Infine, la trattazione si arricchisce di tre applicazioni cardine della moderna data science: l'interpretazione geometrica tridirezionale dell'operatore lineare (sfera unitaria in ellissoide), la compressione digitale di immagini, l'analisi di dati tabulari con rilevamento delle anomalie e la riduzione dimensionale mediante l'Analisi delle Componenti Principali (PCA) [7, 2, 1].

5.1 Richiamo e Raccordo: Full SVD vs Thin SVD

Raccordo Didattico: Dalla Fondazione Teorica (Capitolo 4) all'Efficienza Applicativa

La teoria assiomatica della SVD, la dimostrazione formale dell'esistenza, la distinzione strutturale tra Full SVD e Thin SVD e le basi dei quattro sottospazi fondamentali sono state stabilite nel Capitolo 4 (in particolare Definizione 4.4.1 e Figura 4.1 a pagina 82). In questa sede richiamiamo rapidamente le dimensioni dei blocchi per evidenziare il drastico risparmio computazionale e di memoria che rende la Thin SVD lo standard operativo negli ambienti di calcolo reale.

Data una matrice generica rettangolare $A \in \mathbb{R}^{m \times n}$, con configurazione ad asse verticale ($m \geq n$, matrice “alta e stretta”) e rango $\text{rank}(A) = r \leq n$, la **Full SVD** fattorizza A nel prodotto di tre fattori:

$$A = U \Sigma V^T, \quad (5.1)$$

dove:

- $U \in \mathbb{R}^{m \times m}$ è una matrice ortogonale quadrata ($U^T U = U U^T = I_m$), le cui colonne $\{\mathbf{u}_i\}_{i=1}^m$ sono i *left singular vectors* (vettori singolari sinistri) e costituiscono una base ortonormale di $\mathbb{R}^m$.
- $\Sigma \in \mathbb{R}^{m \times n}$ è una matrice rettangolare diagonale estesa contenente i valori singolari non-negativi ordinati in modo non crescente:

$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > \sigma_{r+1} = \dots = \sigma_n = 0, \quad (5.2)$$

mentre il blocco inferiore di dimensione $(m - n) \times n$ è interamente nullo:

$$\Sigma = \begin{bmatrix} \Sigma_0 \\ \mathbf{0}_{(m-n) \times n} \end{bmatrix}, \quad \Sigma_0 = \text{diag}(\sigma_1, \dots, \sigma_n) \in \mathbb{R}^{n \times n}. \quad (5.3)$$

- $V \in \mathbb{R}^{n \times n}$ è una matrice ortogonale quadrata ($V^T V = V V^T = I_n$), le cui colonne $\{\mathbf{v}_j\}_{j=1}^n$ sono i *right singular vectors* (vettori singolari destri) e costituiscono una base ortonormale di $\mathbb{R}^n$.

I valori singolari sono legati in modo univoco agli autovalori della matrice simmetrica semi-definita positiva associata $A^T A \in \mathbb{R}^{n \times n}$:

$$\sigma_i = \sqrt{\lambda_i(A^T A)}, \quad i = 1, \dots, n. \quad (5.4)$$

5.1.1 La Thin SVD (o Economy SVD)

Nel contesto tipico delle scienze applicate e del machine learning in cui il numero di campioni o istanze eccede enormemente il numero di variabili ($m \gg n$), il blocco inferiore di Σ di taglia $(m - n) \times n$ è costituito da soli zeri. Moltiplicando a blocchi:

$$A = U\Sigma V^T = \begin{bmatrix} U_0 & U_\perp \end{bmatrix} \begin{bmatrix} \Sigma_0 \\ \mathbf{0} \end{bmatrix} V^T = U_0 \Sigma_0 V^T + U_\perp \mathbf{0} V^T = U_0 \Sigma_0 V^T. \quad (5.5)$$

La matrice $U_\perp \in \mathbb{R}^{m \times (m-n)}$, costituita dalle ultime $m - n$ colonne di U , viene moltiplicata unicamente per zeri e non contribuisce in alcun modo alla ricostruzione di A . Eliminando tali componenti ridondanti, si ottiene la **Thin SVD** (detta anche *Economy SVD*):

$$A = U_0 \Sigma_0 V^T, \quad (5.6)$$

con le seguenti dimensioni e proprietà algebriche:

1. $U_0 \in \mathbb{R}^{m \times n}$ ha colonne mutuamente ortonormali: $U_0^T U_0 = I_n$, ma in generale $U_0 U_0^T \neq I_m$ poiché essa proietta sul sottospazio immagine $\text{Im}(A)$.
2. $\Sigma_0 \in \mathbb{R}^{n \times n}$ è strettamente quadrata e diagonale: $\Sigma_0 = \text{diag}(\sigma_1, \dots, \sigma_n)$.
3. $V^T \in \mathbb{R}^{n \times n}$ rimane la medesima matrice ortogonale quadrata della Full SVD.




Figura 5.1: Confronto geometrico e dimensionale tra Full SVD ed Economy (Thin) SVD per matrici ad asse verticale ($m \geq n$). Nella Thin SVD il blocco inferiore nullo di Σ e le colonne superflue $U_\perp$ vengono omesse.

5.1.2 Vantaggi Computazionali e Significato Geometrico-Funzionale

- **Costo di memoria (Storage):** la memorizzazione della matrice completa $U \in \mathbb{R}^{m \times m}$ richiede $\mathcal{O}(m^2)$ elementi. Quando $m = 10^5$ e $n = 10^2$, memorizzare U richiede circa 80 Gigabyte di memoria RAM in doppia precisione, rendendo l'approccio Full SVD intrattabile. Al contrario, memorizzare $U_0 \in \mathbb{R}^{m \times n}$ richiede soltanto $m \cdot n = 10^7$ elementi (≈ 80 Megabyte).
- **Tempo di calcolo (FLOPs):** la Full SVD calcola esplicitamente tutte le direzioni ortonormali di $\mathbb{R}^m$, richiedendo circa $\mathcal{O}(m^2n)$ o $\mathcal{O}(m^3)$ operazioni; la Thin SVD impiega $\mathcal{O}(mn^2)$ operazioni, con un tempo di esecuzione inferiore di diversi ordini di grandezza.
- **Relazione con i sottospazi fondamentali:**

$$\text{Im}(A) = \text{span}\{\mathbf{u}_1, \dots, \mathbf{u}_r\} \subseteq \text{span}(U_0), \quad \ker(A^T) = \text{span}(U_\perp). \quad (5.7)$$

La Thin SVD contiene tutte le informazioni essenziali sull'immagine e sullo spazio delle righe di A . Il complemento ortogonale $U_\perp$ descrive unicamente il nucleo di A^T , e viene trascurato a meno di specifiche necessità teoriche.

5.2 Norme Matriciali e Norme Indotte

Così come le norme vettoriali quantificano la “lunghezza” o l'ampiezza di un vettore in $\mathbb{R}^n$, le norme matriciali forniscono una metrica rigorosa per misurare la “grandezza” di un operatore lineare o quantificare l'errore commesso nell'approssimazione di matrici.

5.2.1 Definizione Assiomatica di Norma Matriciale

Definizione 5.2.1 (Norma Matriciale Generale). Una funzione $\|\cdot\| : \mathbb{R}^{m \times n} \rightarrow \mathbb{R}$ si definisce **norma matriciale** se soddisfa i seguenti quattro assiomi fondamentali per ogni coppia di matrici $A, B \in \mathbb{R}^{m \times n}$ e per ogni scalare $\alpha \in \mathbb{R}$:

1. **Non-negatività e separazione:**

$$\|A\| \geq 0, \quad \text{e} \quad \|A\| = 0 \iff A = \mathbf{0}_{m \times n}. \quad (5.8)$$

2. **Omogeneità assoluta:**

$$\|\alpha A\| = |\alpha| \cdot \|A\|. \quad (5.9)$$

3. **Disuguaglianza triangolare:**

$$\|A + B\| \leq \|A\| + \|B\|. \quad (5.10)$$

4. **Sub-moltiplicatività:** per matrici di dimensioni compatibili rispetto al prodotto matriciale ($A \in \mathbb{R}^{m \times n}, B \in \mathbb{R}^{n \times p}$),

$$\|AB\| \leq \|A\| \cdot \|B\|. \quad (5.11)$$

5.2.2 Norme Matriciali Indotte da Norme Vettoriali

Data una norma vettoriale $\|\cdot\|$ definita sia sullo spazio di partenza $\mathbb{R}^n$ che sullo spazio di arrivo $\mathbb{R}^m$, è possibile associare ad essa una specifica norma matriciale detta **norma indotta** (o *operator norm*).

Definizione 5.2.2 (Norma Matriciale Indotta). Sia $\|\cdot\|$ una norma vettoriale. La norma matriciale indotta per $A \in \mathbb{R}^{m \times n}$ è definita come il massimo fattore di amplificazione che l'operatore lineare A può imprimere a un vettore non nullo:

$$\|A\| := \max_{\mathbf{v} \in \mathbb{R}^n, \mathbf{v} \neq \mathbf{0}} \frac{\|A\mathbf{v}\|}{\|\mathbf{v}\|}. \quad (5.12)$$

Poiché la funzione di amplificazione è invariante per scalatura ($\|A(\alpha\mathbf{v})\|/\|\alpha\mathbf{v}\| = \|A\mathbf{v}\|/\|\mathbf{v}\|$), ponendo $\mathbf{x} = \mathbf{v}/\|\mathbf{v}\|$ la definizione si riformula equivalentemente sulla sfera unitaria:

$$\|A\| = \max_{\|\mathbf{x}\|=1} \|A\mathbf{x}\|. \quad (5.13)$$

Chiarimento Notazionale d'Aula

Si adotta convenzionalmente il medesimo simbolo con doppie barre $\|\cdot\|$ sia per i vettori sia per le matrici. Il contesto definisce in modo non ambiguo l'oggetto matematico: nell'espressione $\|A\mathbf{x}\|$, l'argomento è un vettore di $\mathbb{R}^m$ e $\|\cdot\|$ denota la norma vettoriale di arrivo; al contrario, in $\|A\|$ l'argomento è l'operatore A e $\|\cdot\|$ indica la norma indotta su $\mathbb{R}^{m \times n}$.

Dalla definizione (5.13) discende immediatamente la **disuguaglianza fondamentale di compatibilità**:

$$\|A\mathbf{v}\| \leq \|A\| \cdot \|\mathbf{v}\| \quad \forall \mathbf{v} \in \mathbb{R}^n. \quad (5.14)$$

5.3 La Norma Spettrale (Norma 2 Matriciale)

La **norma spettrale** (o norma 2 matriciale), indicata con $\|A\|_2$, è la norma indotta dalla classica norma vettoriale euclidea (ℓ_2 norm):

$$\|\mathbf{x}\|_2 = \sqrt{\mathbf{x}^T \mathbf{x}} = \sqrt{\sum_{i=1}^n x_i^2}. \quad (5.15)$$

Pertanto:

$$\|A\|_2 := \max_{\mathbf{x} \neq \mathbf{0}} \frac{\|A\mathbf{x}\|_2}{\|\mathbf{x}\|_2} = \max_{\|\mathbf{x}\|_2=1} \|A\mathbf{x}\|_2. \quad (5.16)$$

5.3.1 Derivazione Rigorosa Passo-Passo tramite SVD

Teorema 5.3.1 (Caratterizzazione della Norma Spettrale). *Per qualsiasi matrice reale $A \in \mathbb{R}^{m \times n}$, la norma spettrale $\|A\|_2$ coincide esattamente con il suo valore singolare massimo:*

$$\|A\|_2 = \sigma_1. \quad (5.17)$$

Dimostrazione. Sviluppiamo la dimostrazione attraverso quattro passaggi sequenziali:

Passo 1: Sostituzione della Full SVD. Sostituiamo la decomposizione a valori singolari $A = U\Sigma V^T$ al numeratore del quoziente:

$$\|A\|_2 = \max_{\mathbf{x} \neq \mathbf{0}} \frac{\|U\Sigma V^T \mathbf{x}\|_2}{\|\mathbf{x}\|_2}. \quad (5.18)$$

Passo 2: Invarianza isometrica della matrice ortogonale sinistra U . Poiché $U \in \mathbb{R}^{m \times m}$ è ortogonale, in virtù della proprietà fondamentale di isometria euclidea stabilita nel Capitolo 2 (Teorema 2.6.1 a pagina 46), essa preserva la lunghezza euclidea di qualsiasi vettore:

$$\|U\mathbf{y}\|_2 = \|\mathbf{y}\|_2 \quad \forall \mathbf{y} \in \mathbb{R}^m. \quad (5.19)$$

Ponendo $\mathbf{y} = \Sigma V^T \mathbf{x} \in \mathbb{R}^m$, il fattore U non altera la norma e può essere semplificato:

$$\|U\Sigma V^T \mathbf{x}\|_2 = \|\Sigma V^T \mathbf{x}\|_2 \implies \|A\|_2 = \max_{\mathbf{x} \neq \mathbf{0}} \frac{\|\Sigma V^T \mathbf{x}\|_2}{\|\mathbf{x}\|_2}. \quad (5.20)$$

Passo 3: Cambio di variabile tramite la matrice ortogonale destra V . Definiamo il vettore trasformato $\mathbf{z} := V^T \mathbf{x} \in \mathbb{R}^n$. Ancora per l'isometria di matrici ortogonali (Teorema 2.6.1), si ha $\|\mathbf{x}\|_2 = \|V\mathbf{z}\|_2 = \|\mathbf{z}\|_2$. Poiché V^T stabilisce una biiezione lineare isometrica su $\mathbb{R}^n$, il problema di massimizzazione si mappa direttamente sul vettore $\mathbf{z}$:

$$\|A\|_2 = \max_{\mathbf{z} \neq \mathbf{0}} \frac{\|\Sigma\mathbf{z}\|_2}{\|\mathbf{z}\|_2} = \max_{\|\mathbf{z}\|_2=1} \|\Sigma\mathbf{z}\|_2. \quad (5.21)$$

Passo 4: Massimizzazione esplicita sotto vincolo quadratico. Esplicitando il vettore $\Sigma\mathbf{z}$ per componenti scalari:

$$\Sigma\mathbf{z} = \begin{bmatrix} \sigma_1 z_1 \\ \sigma_2 z_2 \\ \vdots \\ \sigma_r z_r \\ 0 \\ \vdots \end{bmatrix} \implies \|\Sigma\mathbf{z}\|_2^2 = \sum_{i=1}^r \sigma_i^2 z_i^2. \quad (5.22)$$

Sotto il vincolo di sfera unitaria $\|\mathbf{z}\|_2^2 = \sum_{i=1}^n z_i^2 = 1$, il problema equivale a determinare:

$$\|A\|_2^2 = \max_{\sum_{i=1}^n z_i^2=1} (\sigma_1^2 z_1^2 + \sigma_2^2 z_2^2 + \cdots + \sigma_r^2 z_r^2). \quad (5.23)$$

Essendo i valori singolari ordinati in modo decrescente ($\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r \geq 0$), la combinazione convessa dei pesi $w_i = z_i^2$ (con $w_i \geq 0$ e $\sum w_i = 1$) è massimizzata concentrando l'intero peso scalare sul coefficiente associato al valore singolare più grande σ_1^2 :

$$\sum_{i=1}^r \sigma_i^2 z_i^2 \leq \sum_{i=1}^r \sigma_1^2 z_i^2 = \sigma_1^2 \sum_{i=1}^r z_i^2 \leq \sigma_1^2(1) = \sigma_1^2. \quad (5.24)$$

Tale limite superiore viene raggiunto scegliendo $\mathbf{z} = \mathbf{e}_1 = [1, 0, \dots, 0]^T$ (ovvero $\mathbf{x} = V\mathbf{e}_1 = \mathbf{v}_1$). Estrahendo la radice quadrata:

$$\|A\|_2 = \sigma_1. \quad (5.25)$$

□

Corollario 5.3.1 (Invarianza Unitaria della Norma Spettrale). *La moltiplicazione a sinistra o a destra per matrici ortogonali non altera la norma spettrale:*

$$\|Q_1 A Q_2\|_2 = \|A\|_2 \quad \forall Q_1 \in \mathbb{R}^{m \times m}, Q_2 \in \mathbb{R}^{n \times n} \text{ ortogonali.} \quad (5.26)$$

5.4 La Norma di Frobenius

A differenza della norma spettrale, la **norma di Frobenius** non è una norma indotta da una norma vettoriale, ma rappresenta l'estensione naturale della norma euclidea considerando la matrice $A \in \mathbb{R}^{m \times n}$ come un vettore lungo di dimensione $m \cdot n$.

5.4.1 Definizione e Riformulazione tramite Traccia

Definizione 5.4.1 (Norma di Frobenius). La norma di Frobenius $\|A\|_F$ di $A \in \mathbb{R}^{m \times n}$ è definita da:

$$\|A\|_F := \sqrt{\sum_{i=1}^m \sum_{j=1}^n a_{ij}^2}. \quad (5.27)$$

Tale norma può essere calcolata in forma analitica compatta mediante l'operatore **traccia** $\text{Tr}(\cdot)$, definito per matrici quadrate come la somma degli elementi diagonali ($\text{Tr}(M) = \sum_i M_{ii}$).

Proposizione 5.4.1 (Formulazione con Traccia).

$$\|A\|_F = \sqrt{\text{Tr}(A^T A)} = \sqrt{\text{Tr}(A A^T)}. \quad (5.28)$$

Dimostrazione. L'entrata diagonale j -esima del prodotto simmetrico $A^T A \in \mathbb{R}^{n \times n}$ coincide con la norma euclidea al quadrato della j -esima colonna di A :

$$(A^T A)_{jj} = \sum_{k=1}^m (A^T)_{jk} A_{kj} = \sum_{k=1}^m A_{kj}^2. \quad (5.29)$$

Sommando su tutti gli indici $j = 1, \dots, n$:

$$\text{Tr}(A^T A) = \sum_{j=1}^n (A^T A)_{jj} = \sum_{j=1}^n \sum_{k=1}^m A_{kj}^2 = \sum_{i=1}^m \sum_{j=1}^n a_{ij}^2 = \|A\|_F^2. \quad (5.30)$$

□

5.4.2 Espressione Spettrale della Norma di Frobenius via SVD

Teorema 5.4.1 (Norma di Frobenius e Valori Singolari). *La norma di Frobenius di una matrice $A \in \mathbb{R}^{m \times n}$ con valori singolari $\sigma_1, \dots, \sigma_r$ equivale alla radice quadrata della somma dei quadrati di tutti i suoi valori singolari:*

$$\|A\|_F = \sqrt{\sum_{i=1}^r \sigma_i^2} = \sqrt{\sigma_1^2 + \sigma_2^2 + \dots + \sigma_r^2}. \quad (5.31)$$

Dimostrazione. La dimostrazione sfrutta la proprietà ciclica fondamentale della traccia: per matrici di dimensioni compatibili, $\text{Tr}(M_1 M_2 M_3) = \text{Tr}(M_2 M_3 M_1) = \text{Tr}(M_3 M_1 M_2)$.

1. Sostituiamo la SVD $A = U \Sigma V^T$ nella formula della traccia:

$$\|A\|_F^2 = \text{Tr}(A^T A) = \text{Tr}\left((U \Sigma V^T)^T (U \Sigma V^T)\right) = \text{Tr}\left(V \Sigma^T U^T U \Sigma V^T\right). \quad (5.32)$$

2. Essendo U ortogonale, $U^T U = I_m$, per cui:

$$\|A\|_F^2 = \text{Tr}\left(V \Sigma^T \Sigma V^T\right). \quad (5.33)$$

3. Applichiamo la permutazione ciclica della traccia, spostando la matrice ortogonale V alla fine del prodotto matriciale:

$$\text{Tr}\left(V(\Sigma^T \Sigma V^T)\right) = \text{Tr}\left((\Sigma^T \Sigma V^T)V\right) = \text{Tr}\left(\Sigma^T \Sigma (V^T V)\right). \quad (5.34)$$

4. Essendo V ortogonale, $V^T V = I_n$, quindi:

$$\|A\|_F^2 = \text{Tr}(\Sigma^T \Sigma). \quad (5.35)$$

5. Il prodotto $\Sigma^T \Sigma \in \mathbb{R}^{n \times n}$ è una matrice diagonale i cui elementi sono $\sigma_1^2, \sigma_2^2, \dots, \sigma_r^2, 0, \dots, 0$. La sua traccia è la somma dei suoi elementi diagonali:

$$\text{Tr}(\Sigma^T \Sigma) = \sum_{i=1}^r \sigma_i^2 \implies \|A\|_F = \sqrt{\sum_{i=1}^r \sigma_i^2}. \quad (5.36)$$

□

Corollario 5.4.1 (Invarianza Unitaria di Frobenius). *Anche la norma di Frobenius è unitariamente invariante:*

$$\|Q_1 A Q_2\|_F = \|A\|_F \quad \forall Q_1 \in \mathbb{R}^{m \times m}, Q_2 \in \mathbb{R}^{n \times n} \text{ ortogonali}. \quad (5.37)$$

5.5 Generalizzazione a Matrici Complesse e Caso Simmetrico Reale

5.5.1 Estensione allo Spazio Complesso ($\mathbb{C}$)

I concetti di trasposizione, ortogonalità e SVD si estendono con eleganza allo spazio vettoriale complesso $\mathbb{C}$:

- **Trasposta Coniugata (Aggiunta):** al posto di A^T , si utilizza la matrice aggiunta $A^* \in \mathbb{C}^{n \times m}$ (indicata talvolta con A^H), definita da:

$$(A^*)_{ij} = \overline{a_{ji}}. \quad (5.38)$$

- **Matrici Unitarie:** una matrice complessa quadrata $Q \in \mathbb{C}^{n \times n}$ si dice **unitaria** se la sua inversa coincide con la trasposta coniugata:

$$Q^*Q = QQ^* = I_n. \quad (5.39)$$

- **Matrici Hermitiane:** una matrice $A \in \mathbb{C}^{n \times n}$ si dice **hermitiana** se $A^* = A$. Le matrici hermitiane ammettono autovalori strettamente reali e una base ortonormale di autovettori in $\mathbb{C}^n$.

- **SVD Complessa:** per qualsiasi matrice rettangolare complessa $A \in \mathbb{C}^{m \times n}$:

$$A = U\Sigma V^*, \quad (5.40)$$

dove $U \in \mathbb{C}^{m \times m}$ e $V \in \mathbb{C}^{n \times n}$ sono unitarie, mentre $\Sigma \in \mathbb{R}^{m \times n}$ è una matrice **reale** contenente valori singolari $\sigma_i \geq 0$.

5.5.2 SVD di Matrici Simmetriche Reali dalla Decomposizione Spettrale

Come analizzato e risolto nel Problema 4.6.4 del Capitolo 4 (pagina 91), per una matrice reale simmetrica ($A = A^T$) con fattorizzazione spettrale $A = QDQ^T = \sum_{i=1}^n d_i \mathbf{q}_i \mathbf{q}_i^T$, non occorre materializzare il gramiano $A^T A = A^2$. I fattori dell'SVD $A = U\Sigma V^T$ si determinano per via algebrica diretta:

1. **Valori Singolari:** $\sigma_i = \sqrt{\lambda_i(A^T A)} = \sqrt{d_i^2} = |d_i| \geq 0$.
2. **Vettori Singolari Destri:** $\mathbf{v}_i = \mathbf{q}_i$.
3. **Vettori Singolari Sinistri:** assorbono il segno degli autovalori per preservare la coerenza diadica $d_i \mathbf{q}_i \mathbf{q}_i^T = |d_i| \mathbf{u}_i \mathbf{q}_i^T$:

$$\mathbf{u}_i = \text{sgn}(d_i) \mathbf{q}_i = \begin{cases} \mathbf{q}_i & \text{se } d_i \geq 0, \\ -\mathbf{q}_i & \text{se } d_i < 0. \end{cases} \quad (5.41)$$

4. **Ordinamento:** permutazione simultanea per garantire l'assioma fondamentale $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_n \geq 0$.

Questa conciliazione diretta chiude il cerchio tra l'algebra spettrale delle matrici simmetriche e la decomposizione a valori singolari, fungendo da analogo reale della SVD unitaria complessa introdotta sopra.

5.6 Il Problema dell'Approssimazione a Basso Rango e Teorema di Eckart-Young

In moltissimi problemi applicativi di data science, signal processing e modellazione numerica, una matrice di dati $A \in \mathbb{R}^{m \times n}$ ha rango teorico o numerico pieno r , ma la maggior parte dell'informazione strutturale è concentrata in un sottospazio di dimensione molto inferiore $k \ll r$.

5.6.1 Formulazione del Problema di Ottimo

Fissato un rango target $k < \text{rank}(A)$, si ricerca una matrice $B \in \mathbb{R}^{m \times n}$ di rango al più k che minimizzi la distanza da A in una norma prefissata:

$$\min_{B \in \mathbb{R}^{m \times n}, \text{rank}(B) \leq k} \|A - B\|. \quad (5.42)$$

5.6.2 Esempio Introduttivo Giocattolo 2×2

Consideriamo la matrice reale quadrata di rango 2 analizzata durante la lezione:

$$A = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}, \quad \text{rank}(A) = 2. \quad (5.43)$$

Si vuole determinare la migliore matrice B di rango $k = 1$ che minimizzi l'errore di approssimazione nella norma di Frobenius $\|A - B\|_F$.

Tentativo 1 (Sostituzione euristica di una riga): Rendiamo la prima riga proporzionale alla seconda:

$$B_1 = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix} \implies A - B_1 = \begin{bmatrix} 0 & 0 \\ 1 & 0 \end{bmatrix} \implies \|A - B_1\|_F = \sqrt{0^2 + 0^2 + 1^2 + 0^2} = 1.0. \quad (5.44)$$

Tentativo 2 (Perturbazione bilanciata d'aula): Modifichiamo un solo coefficiente per rendere le colonne proporzionali ($[2, 4]^T = \frac{4}{3}[1.5, 3]^T$):

$$B_2 = \begin{bmatrix} 1.5 & 2 \\ 3 & 4 \end{bmatrix} \implies A - B_2 = \begin{bmatrix} -0.5 & 0 \\ 0 & 0 \end{bmatrix} \implies \|A - B_2\|_F = 0.5. \quad (5.45)$$

L'errore si è dimezzato ($0.5 < 1.0$). Si può fare di meglio?

Soluzione Esatta Ottimale tramite SVD: Calcolando la SVD esatta di A , si ottengono i valori singolari:

$$\sigma_1 \approx 5.46498, \quad \sigma_2 \approx 0.36597. \quad (5.46)$$

Come enunciato dal Teorema di Eckart-Young, l'errore minimo teorico insuperabile è dato da $\sigma_2 \approx 0.366$, sensibilmente inferiore sia a 1.0 sia a 0.5.

5.6.3 Il Teorema di Eckart-Young-Mirsky

Teorema 5.6.1 (Eckart-Young-Mirsky). *Sia $A \in \mathbb{R}^{m \times n}$ con $\text{rank}(A) = r$ e decomposizione a valori singolari in forma diadica:*

$$A = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^T. \quad (5.47)$$

Per ogni intero $k < r$, la matrice A_k definita dalla troncatura alle prime k componenti della SVD:

$$A_k := \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^T = U_k \Sigma_k V_k^T \quad (5.48)$$

(dove $U_k \in \mathbb{R}^{m \times k}$, $\Sigma_k = \text{diag}(\sigma_1, \dots, \sigma_k)$, $V_k \in \mathbb{R}^{n \times k}$) è la soluzione ottima globale del problema di migliore approssimazione di rango k :

$$\min_{\text{rank}(B) \leq k} \|A - B\| = \|A - A_k\| \quad (5.49)$$

sia per la norma spettrale $\|\cdot\|_2$, sia per la norma di Frobenius $\|\cdot\|_F$ (e in generale per qualsiasi norma unitariamente invariante).

5.6.4 Quantificazione Analitica dell'Errore di Approssimazione

Costruiamo la matrice residua di errore sottraendo l'approssimazione A_k dalla matrice originaria A :

$$E_k := A - A_k = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^T - \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^T = \sum_{i=k+1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^T. \quad (5.50)$$

L'espressione a destra è a tutti gli effetti la forma diadica SVD della matrice di errore E_k , avente come valori singolari non nulli l'insieme residuo $\{\sigma_{k+1}, \sigma_{k+2}, \dots, \sigma_r\}$. Applicando i Teoremi 5.3.1 e 5.4.1:

Valutazione Esatta dell'Errore di Troncatura SVD

1. **Errore in Norma Spettrale (Norma 2):** coincide esattamente con il primo valore singolare scartato:

$$\min_{\text{rank}(B) \leq k} \|A - B\|_2 = \|A - A_k\|_2 = \sigma_{k+1}. \quad (5.51)$$

2. **Errore in Norma di Frobenius:** coincide con la radice quadrata della somma dei quadrati di tutti i valori singolari scartati:

$$\min_{\text{rank}(B) \leq k} \|A - B\|_F = \|A - A_k\|_F = \sqrt{\sum_{i=k+1}^r \sigma_i^2} = \sqrt{\sigma_{k+1}^2 + \dots + \sigma_r^2}. \quad (5.52)$$




Figura 5.2: Decadimento dello spettro singolare e partizione dell'energia tra segnale conservato nell'approssimazione a rango k (A_k) ed errore residuo quantificato dal Teorema di Eckart-Young.

5.7 Interpretazione Geometrica della SVD: Dalla Sfera all'Ellissoide

La decomposizione $A = U\Sigma V^T$ possiede una trasparente interpretazione geometrica: essa afferma che la trasformazione lineare generata da qualsiasi matrice reale $A \in \mathbb{R}^{m \times n}$ trasforma la sfera unitaria euclidea dello spazio di partenza in un iper-ellissoide nello spazio di arrivo. Tale trasformazione si decompone nella composizione ordinata di tre azioni geometriche canoniche:




Figura 5.3: Interpretazione geometrica dell'azione di una matrice $A = U\Sigma V^T$ sulla sfera unitaria euclidea rappresentata a quattro quadranti: (1) Sfera originaria con i vettori singolari destri $\mathbf{v}_i$; (2) Isometria V^T che allinea le direzioni $\mathbf{v}_i$ con la base canonica $\mathbf{e}_i$; (3) Deformazione assi-simmetrica Σ che genera un ellissoide con semiassi σ_i ; (4) Isometria finale U che orienta i semiassi dell'ellissoide lungo i vettori singolari sinistri $\mathbf{u}_i$.

1. **Azione di V^T (Isometria in $\mathbb{R}^n$):** ruota la sfera unitaria rigida, facendo coincidere le direzioni ortogonali dei vettori singolari destri $\{\mathbf{v}_i\}_{i=1}^n$ con gli assi canonici $\{\mathbf{e}_i\}_{i=1}^n$. Essendo V^T ortogonale, le distanze e la forma sferica rimangono inalterate.
2. **Azione di Σ (Stiramento assi-simmetrico):** ciascun asse coordinato viene allungato o contratto per il corrispondente valore singolare σ_i . La

sfera unitaria viene così deformata in un iper-ellissoide avente semiassi principali di lunghezza $\sigma_1, \sigma_2, \dots, \sigma_r$. Se $r < n$, l'ellissoide collassa lungo le direzioni degenerate a valore singolare nullo.

3. **Azione di U (Isometria in $\mathbb{R}^m$):** applica una rotazione/riflessione finale rigida nello spazio di arrivo $\mathbb{R}^m$, orientando i semiassi principali dell'ellissoide lungo le direzioni dei vettori singolari sinistri $\{\mathbf{u}_i\}_{i=1}^m$.

5.8 Applicazione 1: Compressione Digitale di Immagini via Truncated SVD

5.8.1 Modellazione Matriciale dell'Immagine

Un'immagine in scala di grigi con risoluzione $m \times n$ (ad esempio 600×402 pixel) viene rappresentata matematicamente da una matrice $A \in \mathbb{R}^{m \times n}$, dove l'elemento $a_{ij} \in [0, 255]$ codifica l'intensità luminosa del pixel posizionato alla riga i e colonna j .

Memorizzare l'immagine non compressa richiede la memorizzazione di tutti gli $m \cdot n$ pixel scalari (per 600×402 , 241 200 valori).

5.8.2 Meccanismo di Compressione e Rapporto di Memorizzazione

Applicando il Teorema di Eckart-Young, sostituiamo alla matrice originaria A la sua migliore approssimazione di rango k :

$$A_k = U_k \Sigma_k V_k^T = \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^T. \quad (5.53)$$

Per ricostruire A_k , non è necessario memorizzare l'intera matrice $m \times n$, bensì soltanto i suoi fattori spettrali:

- $U_k \in \mathbb{R}^{m \times k}$: le prime k colonne di U ($m \cdot k$ scalari).
- $\Sigma_k \in \mathbb{R}^{k \times k}$: i primi k valori singolari (k scalari).
- $V_k \in \mathbb{R}^{n \times k}$: le prime k colonne di V ($n \cdot k$ scalari).

Il numero totale di scalari da memorizzare è dato da:

$$\text{Memoria}(A_k) = k(m + n + 1). \quad (5.54)$$

Il **tasso di compressione** (rapporto tra memoria ridotta e memoria iniziale) è pari a:

$$\rho_k = \frac{k(m + n + 1)}{m \cdot n}. \quad (5.55)$$

Esempio 5.8.1 (Compressione di un'immagine 600×402). Per un'immagine con $m = 600$ e $n = 402$:

- Matrice originaria piena: $600 \times 402 = 241\,200$ scalari.
- $k = 10$: $10 \times (600 + 402 + 1) = 10\,030$ scalari ($\approx 4.1\%$ della memoria originale, risparmio del 95.9%).
- $k = 30$: $30 \times (600 + 402 + 1) = 30\,090$ scalari ($\approx 12.5\%$ della memoria originale, risparmio dell' 87.5%).

5.8.3 Comportamento Visivo al Variare di k

Come mostrato nella demo interattiva analizzata a lezione (<https://timbaumann.info/svd-image-compression-demo/>):

1. $k = 1$ (**Rango 1**): l'immagine è costituita da una singola matrice diadica $\sigma_1 \mathbf{u}_1 \mathbf{v}_1^T$. Visivamente compaiono soltanto gradienti verticali e orizzontali grossolani; il contenuto semantico è irriconoscibile.
2. $k = 2$ o $k = 5$: emergono i contorni sfocati delle forme dominanti e dei contrasti principali tra luce e ombra.
3. $k = 10$ o $k = 15$: il soggetto dell'immagine (ad esempio un volto o un edificio) è perfettamente distinguibile, pur presentando lievi artefatti a blocchi nei dettagli fini.
4. $k = 30$ o $k = 40$: l'immagine ricostruita A_k è praticamente indistinguibile dall'originale a occhio nudo, poiché i valori singolari residui decadono a valori trascurabili ($\sum_{i=k+1}^r \sigma_i^2 \approx 0$).

Listing 5.1: Implementazione Python di compressione immagini e calcolo dell'errore relativo con SVD.

```
1 import numpy as np
2
3 def compress_image_svd(A: np.ndarray, k: int):
4     """
5     Comprime una matrice immagine 2D A di taglia (m, n)
        al rango k tramite SVD.
```

```

6 Restituisce: immagine ricostruita A_k, memoria
   scalari e errore relativo Frobenius.
7 """
8 # 1. Calcolo Thin SVD
9 U, S, Vt = np.linalg.svd(A, full_matrices=False)
10
11 # 2. Troncatura alle prime k componenti
12 Uk = U[:, :k]
13 Sk = S[:k]
14 Vtk = Vt[:k, :]
15
16 # 3. Ricostruzione matrice approssimata A_k
17 Ak = Uk @ np.diag(Sk) @ Vtk
18
19 # 4. Calcolo metriche
20 m, n = A.shape
21 mem_orig = m * n
22 mem_comp = k * (m + n + 1)
23 compression_ratio = mem_comp / mem_orig
24
25 err_frobenius = np.linalg.norm(A - Ak, 'fro') / np.
   linalg.norm(A, 'fro')
26
27 return Ak, compression_ratio, err_frobenius

```

5.9 Applicazione 2: Analisi di Dati Tabulari e Rilevamento di Anomalie

L'approssimazione a basso rango basata sulla SVD trova un impiego naturale nell'analisi di matrici di dati osservazionali, permettendo di estrarre fattori latenti e rilevare anomalie o valori anomali (*outlier*).

5.9.1 Modellazione a Basso Rango di Punteggi di Test

Consideriamo la matrice $M \in \mathbb{R}^{4 \times 3}$ analizzata a lezione, contenente i punteggi conseguiti da 4 studenti su 3 prove d'esame (Test A, Test B, Test C):

$$M = \begin{bmatrix} 90 & 95 & 55 \\ 32 & 35 & 20 \\ 70 & 75 & 50 \\ 70 & 31 & 49 \end{bmatrix}. \quad (5.56)$$

Ipotizziamo che le prestazioni siano descrivibili in prima approssimazione da un **modello a rango 1**:

$$M \approx \mathbf{xy}^T = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} \begin{bmatrix} y_1 & y_2 & y_3 \end{bmatrix} = \begin{bmatrix} x_1 y_1 & x_1 y_2 & x_1 y_3 \\ x_2 y_1 & x_2 y_2 & x_2 y_3 \\ x_3 y_1 & x_3 y_2 & x_3 y_3 \\ x_4 y_1 & x_4 y_2 & x_4 y_3 \end{bmatrix}. \quad (5.57)$$

5.9.2 Interpretazione Semantica delle Componenti Fattoriali

- **Vettore riga $\mathbf{y}^T = [y_1, y_2, y_3]$** : cattura la *facilità relativa* di ciascun test. Se il Test C registra sistematicamente punteggi inferiori rispetto ai primi due, y_3 risulterà marcatamente inferiore a y_1 e y_2 .
- **Vettore colonna $\mathbf{x} = [x_1, x_2, x_3, x_4]^T$** : misura l'*abilità o preparazione globale* di ciascuno studente. Lo studente 1 ha punteggi elevati e avrà x_1 grande; lo studente 2 presenta punteggi scarsi su tutti i test e avrà x_2 basso.

5.9.3 Rilevamento di Anomalie tramite la Matrice Residua

Calcolando la matrice dei residui tra i dati reali e l'approssimazione ottimale di rango 1:

$$R = M - \mathbf{xy}^T = M - \sigma_1 \mathbf{u}_1 \mathbf{v}_1^T : \quad (5.58)$$

- **Residuo prossimo allo zero ($r_{ij} \approx 0$)**: il punteggio dello studente sul test è perfettamente spiegato dal modello fattoriale (abilità $\times$ facilità).
- **Residuo marcatamente positivo ($r_{ij} \gg 0$)**: lo studente ha ottenuto una prestazione di gran lunga superiore al suo standard atteso su quel test. Nel contesto accademico, questo può indicare una preparazione mirata su quello specifico argomento oppure un episodio anomalo (ad esempio copiatura o collaborazione non consentita).
- **Residuo marcatamente negativo ($r_{ij} \ll 0$)**: lo studente ha registrato un crollo insolito (si osservi lo studente 4 al Test B: voto 31, a fronte di 70 e 49 sugli altri test). Ciò riflette circostanze contingenti estrinseche (malessere improvviso, ritardo, problema tecnico).

Qualora una singola componente non catturi sufficiente varianza, il modello viene esteso a **rango 2**:

$$M \approx \sigma_1 \mathbf{u}_1 \mathbf{v}_1^T + \sigma_2 \mathbf{u}_2 \mathbf{v}_2^T, \quad (5.59)$$

dove la seconda componente può riflettere un fattore latente secondario (ad esempio abilità in quesiti teorici vs problemi computazionali pratici).

5.10 Applicazione 3: Analisi delle Componenti Principali (PCA) tramite SVD

L'**Analisi delle Componenti Principali** (*Principal Component Analysis*, PCA) è la tecnica fondamentale di apprendimento non supervisionato per la riduzione della dimensionalità e l'estrazione di feature. La SVD fornisce il motore algebrico esatto e numericamente stabile per calcolare la PCA senza dover mai formare esplicitamente matrici di covarianza mal condizionate.

5.10.1 Formulazione Matematica della PCA

Consideriamo un dataset composto da n osservazioni vettoriali in dimensione m :

$$\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n \in \mathbb{R}^m. \quad (5.60)$$

Organizziamo i dati nella matrice $A \in \mathbb{R}^{m \times n}$, dove ogni colonna rappresenta un campione:

$$A = [\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n]. \quad (5.61)$$

Passo 1: Centratura dei Dati (Mean-Centering). Calcoliamo il vettore media campionaria $\boldsymbol{\mu} \in \mathbb{R}^m$:

$$\boldsymbol{\mu} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i. \quad (5.62)$$

Costruiamo la matrice a media nulla $\hat{A} \in \mathbb{R}^{m \times n}$ sottraendo il baricentro $\boldsymbol{\mu}$ da ogni singola colonna:

$$\hat{\mathbf{x}}_i = \mathbf{x}_i - \boldsymbol{\mu} \implies \hat{A} = [\hat{\mathbf{x}}_1, \dots, \hat{\mathbf{x}}_n] = A - \boldsymbol{\mu} \mathbf{1}_n^T. \quad (5.63)$$

Passo 2: Matrice di Covarianza Campionaria. La matrice di covarianza empirica $C \in \mathbb{R}^{m \times m}$ tra le m variabili è data da:

$$C = \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \boldsymbol{\mu})(\mathbf{x}_i - \boldsymbol{\mu})^T = \frac{1}{n} \hat{A} \hat{A}^T. \quad (5.64)$$

Passo 3: Connessione Diretta con la SVD. Calcoliamo la SVD della matrice centrata $\hat{A} \in \mathbb{R}^{m \times n}$:

$$\hat{A} = U\Sigma V^T. \quad (5.65)$$

Sostituendo tale fattorizzazione nell'espressione della matrice di covarianza C :

$$C = \frac{1}{n} \hat{A} \hat{A}^T = \frac{1}{n} (U\Sigma V^T)(U\Sigma V^T)^T = \frac{1}{n} U\Sigma(V^T V)\Sigma^T U^T = U \left(\frac{1}{n} \Sigma \Sigma^T \right) U^T. \quad (5.66)$$

Poiché $\frac{1}{n} \Sigma \Sigma^T = \text{diag} \left(\frac{\sigma_1^2}{n}, \dots, \frac{\sigma_m^2}{n} \right)$ è una matrice diagonale con entrate non-negative ordinate, la relazione precedente è esattamente la **decomposizione spettrale** della matrice di covarianza C .

Teorema 5.10.1 (PCA via SVD). *Le **componenti principali** del dataset coincidono rigorosamente con le colonne della matrice ortogonale sinistra $U = [\mathbf{u}_1, \dots, \mathbf{u}_m]$ della SVD della matrice centrata $\hat{A}$:*

1. La **prima componente principale** $\mathbf{u}_1$ è la direzione in $\mathbb{R}^m$ lungo la quale i dati centrati presentano la massima varianza campionaria, pari a σ_1^2/n .
2. La **seconda componente principale** $\mathbf{u}_2$, ortogonale a $\mathbf{u}_1$, massimizza la varianza residua, pari a σ_2^2/n .
3. La proiezione a dimensione ridotta k ($k < m$) si calcola direttamente da:

$$Y_k = U_k^T \hat{A} = \Sigma_k V_k^T \in \mathbb{R}^{k \times n}. \quad (5.67)$$

5.10.2 Interpretazione Geometrica nel Piano Bidimensionale

Nel caso didattico in due dimensioni ($m = 2$) illustrato in Figura 5.4:

1. I dati originari formano una nube di punti sparpagliata non centrata rispetto all'origine.
2. La sottrazione del baricentro $\boldsymbol{\mu}$ trasla l'origine del sistema di riferimento nel centro geometrico della nube.
3. Il primo vettore singolare sinistro $\mathbf{u}_1$ si posiziona lungo l'asse di massima dispersione (asse maggiore dell'ellisse di covarianza).
4. Il secondo vettore $\mathbf{u}_2$ si orienta lungo l'asse ortogonale minore.

5. Proiettando ciascun punto sul sottospazio monodimensionale generato da $\mathbf{u}_1$, si ottiene la migliore approssimazione lineare possibile a un solo grado di libertà, massimizzando la varianza spiegata e minimizzando la somma dei quadrati delle distanze ortogonali di proiezione.




Figura 5.4: Interpretazione geometrica dell'Analisi delle Componenti Principali (PCA) via SVD: (a) Distribuzione iniziale con baricentro μ ; (b) Dati centrati con le direzioni principali $\mathbf{u}_1$ (massima varianza) e $\mathbf{u}_2$ ortogonale ricavate dalla SVD della matrice centrata $\hat{A} = U\Sigma V^T$, con proiezioni ortogonali sul sottospazio ottimo.

5.11 Formulario e Tavola Sinottica di Sintesi

Concetto / Oggetto	Formulazione Matematica	Significato Computazionale
Full SVD	$A = U\Sigma V^T, \quad U \in \mathbb{R}^{m \times m}, V \in \mathbb{R}^{n \times n}$	Basi complete per dominio, codominio e 4 sottospazi.
Thin SVD	$A = U_0 \Sigma_0 V^T, \quad U_0 \in \mathbb{R}^{m \times n}, \Sigma_0 \in \mathbb{R}^{n \times n}$	Risparmio $\mathcal{O}(m^2) \rightarrow \mathcal{O}(mn)$ di memoria, conserva $\text{Im}(A)$.
Norma Indotta	$\ A\ = \max_{\ \mathbf{x}\ =1} \ A\mathbf{x}\ $	Massimo fattore di amplificazione vettoriale.
Norma Spettrale	$\ A\ _2 = \sigma_1$	Valore singolare massimo; invarianza unitaria.
Norma di Frobenius	$\ A\ _F = \sqrt{\text{Tr}(A^T A)} = \sqrt{\sum \sigma_i^2}$	Lunghezza euclidea estesa a matrice; invarianza unitaria.
SVD Simmetrica Reale	$\sigma_i = d_i , \quad \mathbf{u}_i = \text{sgn}(d_i)\mathbf{q}_i, \quad \mathbf{v}_i = \mathbf{q}_i$	Dedotta direttamente da $A = QDQ^T$.
Eckart-Young (A_k)	$A_k = \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^T$	Ottimo globale per $\min_{\text{rank}(B) \leq k} \ A - B\ $.
Errore Spettrale	$\ A - A_k\ _2 = \sigma_{k+1}$	Primo valore singolare scartato.
Errore Frobenius	$\ A - A_k\ _F = \sqrt{\sum_{i=k+1}^r \sigma_i^2}$	Energia totale scartata.
Compressione Immagini	Memoria = $k(m + n + 1) \ll mn$	Compressione ad alta fedeltà per spettro decadente.
PCA via SVD	$\hat{A} = U\Sigma V^T, \quad C = \frac{1}{n}U\Sigma\Sigma^T U^T$	Colonne di U sono gli autovettori della covarianza.

Tabella 5.1: Quadro sinottico riassuntivo delle norme matriciali, decomposizioni SVD, approssimazioni a basso rango e applicazioni.

Parte II

Ottimizzazione Continua e Machine Learning

Capitolo 6

Problemi Elementari di Ottimizzazione Univariata

6.1 Introduzione, Motivazione e Obiettivi Didattici

L'ottimizzazione matematica costituisce, assieme all'algebra lineare numerica, il secondo pilastro computazionale dell'apprendimento automatico e della scienza dei dati [4, 5]. Nella pratica del machine learning, la quasi totalità dei modelli (dalla regressione lineare alle reti neurali profonde con centinaia di miliardi di parametri) si riduce concettualmente alla formulazione e risoluzione di un problema di ottimo vincolato o libero:

$$\min_{w \in \mathcal{W}} \mathcal{L}(w; \mathcal{D}) + \lambda \Omega(w) \quad (6.1)$$

dove $\mathcal{L}$ rappresenta la funzione di perdita empirica sui dati $\mathcal{D}$, Ω definisce un regolarizzatore geometrico e $\mathcal{W}$ delimita l'insieme dei parametri ammissibili.

Tuttavia, l'ottimizzazione non lineare generale è un dominio teoricamente intrattabile: in assenza di proprietà strutturali forti, trovare il minimo globale di una funzione arbitraria è un problema formalmente insolubile in tempo finito. Per costruire un percorso computazionale solido e rigoroso, la metodologia adottata in questa seconda parte del corso segue un paradigma costruttivo e modulare:

1. **Analisi di problemi elementari univariati:** si studiano funzioni lineari e quadratiche nello spazio $\mathbb{R}$, caratterizzate da strutture analitiche così elementari da ammettere formule risolutive chiuse a costo computazionale $\mathcal{O}(1)$.

2. **Sviluppo dell'intuizione geometrica e algebrica:** comprendere a fondo il comportamento delle derivate, delle curvature, degli insiemi di livello e l'impatto dei vincoli di frontiera.
3. **Identificazione dei confini di trattabilità:** analizzare esattamente in quali punti la rimozione di un'ipotesi o l'estensione a dimensioni multiple trasforma un problema banale in una sfida computazionalmente ardua.
4. **I problemi semplici come sottomodelli algoritmici:** nella quasi totalità degli algoritmi avanzati per l'ottimizzazione vincolata e su larga scala (come i metodi di Newton, Quasi-Newton, Sequential Quadratic Programming e le tecniche di ricerca lineare univariata o *line search*), il nucleo computazionale fondamentale consiste nel risolvere ripetutamente a ogni iterazione un'approssimazione locale elementare (lineare o quadratica) del problema reale.

Filosofia Metodologica

La comprensione viscerale dei problemi univariati lineari e quadratici non è un mero esercizio propedeutico: costituisce l'alfabeto con cui sono scritti gli algoritmi numerici più sofisticati impiegati nell'addestramento dei modelli di intelligenza artificiale.

6.2 Definizioni Fondamentali: Spazi, Funzioni, Grafi e Insiemi di Livello

6.2.1 Spazi di Input e Output

Consideriamo l'ambiente analitico univariato più essenziale:

- **Spazio di ingresso (input space):** $x \in \mathbb{R}$
- **Spazio di uscita (output space):** $y \in \mathbb{R}$

Una funzione scalare $f : \mathbb{R} \rightarrow \mathbb{R}$ assegna a ogni elemento del dominio un unico valore reale $y = f(x)$.

6.2.2 Grafo di una Funzione

Definizione 6.2.1 (Grafo). Dato un operatore scalare $f : \mathbb{R} \rightarrow \mathbb{R}$, il **grafo** di f , denotato con $\text{gr}(f)$, è il sottoinsieme dello spazio cartesiano bidimensionale $\mathbb{R}^2$ definito da:

$$\text{gr}(f) = \{(x, f(x)) \in \mathbb{R}^2 : x \in \mathbb{R}\} \subset \mathbb{R}^2 \quad (6.2)$$

Dal punto di vista geometrico, $\text{gr}(f)$ è una curva piana continua o discontinua che giace nel piano (x, y) .

6.2.3 Immagine (Codominio Effettivo)

Definizione 6.2.2 (Immagine). L'**immagine** di una funzione f , denotata con $\text{im}(f)$, è il sottoinsieme di $\mathbb{R}$ costituito da tutti i valori di output effettivamente generati dalla funzione:

$$\text{im}(f) = \{y \in \mathbb{R} : \exists x \in \mathbb{R} \text{ tale che } y = f(x)\} = f(\mathbb{R}) \subseteq \mathbb{R} \quad (6.3)$$

Geometricamente, $\text{im}(f)$ coincide esattamente con la proiezione ortogonale del grafo $\text{gr}(f)$ sull'asse verticale delle ordinate (asse y).

6.2.4 Insiemi di Livello e Insiemi di Sottolivello

Definizione 6.2.3 (Insieme di Livello). Dato un valore bersaglio $v \in \mathbb{R}$, l'**insieme di livello** (o *level set*) a valore v , indicato con $L(f, v)$, è la controimmagine di v nel dominio:

$$L(f, v) = \{x \in \mathbb{R} : f(x) = v\} \subset \mathbb{R} \quad (6.4)$$

L'interpretazione geometrica è immediata: $L(f, v)$ rappresenta l'intersezione tra la curva del grafo $\text{gr}(f)$ e la retta orizzontale $y = v$, proiettata sull'asse orizzontale delle ascisse x .

Nota 6.2.1 (Radici o Zeri di una Funzione). Il caso notevole in cui il valore di livello è nullo ($v = 0$) identifica l'insieme delle radici della funzione:

$$\text{roots}(f) = L(f, 0) = \{x \in \mathbb{R} : f(x) = 0\} \quad (6.5)$$

Definizione 6.2.4 (Insieme di Sottolivello). Dato un valore $v \in \mathbb{R}$, l'**insieme di sottolivello** (o *sublevel set*) a soglia v , indicato con $S(f, v)$, è definito come:

$$S(f, v) = \{x \in \mathbb{R} : f(x) \leq v\} \subset \mathbb{R} \quad (6.6)$$

Gli insiemi di sottolivello giocano un ruolo strutturale cardine nell'analisi della convessità e nella convergenza degli algoritmi iterativi di discesa.

6.3 Il Problema di Ottimizzazione Univariato Libero

6.3.1 Formulazione Formale

Dato un obiettivo reale $f : \mathbb{R} \rightarrow \mathbb{R}$, il problema di minimizzazione scalare non vincolato si denota con:

$$(P) \quad f^* = \min\{f(x) : x \in \mathbb{R}\} \quad (6.7)$$

6.3.2 Valore Ottimo vs Soluzione Ottima

In ottimizzazione matematica è fondamentale mantenere una rigorosa distinzione concettuale e notazionale tra due entità distinte:

Definizione 6.3.1 (Valore Ottimo). Il **valore ottimo** (denotato con $f^* \in \mathbb{R}$ oppure con $\nu(P)$) è lo scalare che rappresenta l'estremo inferiore raggiunto dall'immagine della funzione:

$$f^* = \min(\text{im}(f)) = \min\{v \in \mathbb{R} : L(f, v) \neq \emptyset\} \quad (6.8)$$

Se il minimo esiste, il valore ottimo f^* è **strettamente unico**.

Definizione 6.3.2 (Soluzione Ottima o Minimizzatore). Una **soluzione ottima** (denotata con x^*) è un punto del dominio $x^* \in \mathbb{R}$ in cui la funzione assume il valore ottimo:

$$f(x^*) = f^* \iff f(x^*) \leq f(x), \quad \forall x \in \mathbb{R} \quad (6.9)$$

L'insieme di tutti i punti minimizzatori è denotato con l'operatore insiemistico $\arg \min$:

$$X^* = \arg \min\{f(x) : x \in \mathbb{R}\} = L(f, f^*) \quad (6.10)$$

Proprietà 6.3.1 (Non Unicità dei Minimizzatori). Mentre il valore ottimo f^* è invariabilmente uno scalare unico, l'insieme dei punti di minimo X^* può:

1. Essere vuoto ($X^* = \emptyset$, quando il minimo non è raggiunto).
2. Contenere un singolo punto isolato ($|X^*| = 1$, minimo unico).
3. Contenere un insieme discreto o finito di punti multipli (es. $f(x) = \sin(x)$ con $f^* = -1$ e $X^* = \{-\pi/2 + 2k\pi : k \in \mathbb{Z}\}$).
4. Contenere un continuo di punti (es. una funzione costante su un intervallo).

6.3.3 Indifferenza Algoritmica tra Ottimi Equivalenti

Dal punto di vista dell'analisi di ottimizzazione pura:

$$\forall x_1^*, x_2^* \in X^* \implies f(x_1^*) = f(x_2^*) = f^* \quad (6.11)$$

Tutti i punti appartenenti a X^* risultano perfettamente indistinguibili rispetto alla funzione obiettivo. A meno di vincoli secondari o regolarizzazioni aggiuntive (quali la preferenza per norme minime $\|x\|_2$ o parsimonia ℓ_1), qualsiasi algoritmo numerico è matematicamente autorizzato a restituire un qualunque elemento arbitrario dell'insieme X^* .

6.4 Riformulazioni Semplici ed Equivalenza di Problemi

Due problemi di ottimizzazione si definiscono **equivalenti** se la conoscenza della soluzione dell'uno consente di determinare immediatamente l'insieme dei minimizzatori X^* dell'altro, senza richiedere computazioni iterate non banali.

6.4.1 Dualità Minimo–Massimo

Senza perdita di generalità (*without loss of generality*, w.l.o.g.), l'intera teoria dell'ottimizzazione può essere formalizzata unicamente per problemi di minimizzazione. Qualsiasi istanza di massimizzazione può essere trasformata invertendo il segno della funzione obiettivo:

$$\min\{f(x) : x \in \mathbb{R}\} = -\max\{-f(x) : x \in \mathbb{R}\} \quad (6.12)$$

$$\arg \min\{f(x) : x \in \mathbb{R}\} = \arg \max\{-f(x) : x \in \mathbb{R}\} \quad (6.13)$$

Attenzione Concettuale

Non confondere l'equivalenza sopra esposta con la relazione tra $\min f(x)$ e $\max f(x)$: massimizzare $f(x)$ e minimizzare $f(x)$ definiscono problemi radicalmente differenti, con insiemi di soluzioni e proprietà di curvatura diametralmente opposte. L'equivalenza sussiste esclusivamente tra minimizzare $f(x)$ e massimizzare $-f(x)$.

6.4.2 Invarianza per Traslazione Verticale (Costante Additiva)

L'addizione di una costante reale arbitraria $c \in \mathbb{R}$ sposta rigidamente il grafo lungo l'asse delle ordinate:

$$\min\{f(x) + c : x \in \mathbb{R}\} = \min\{f(x) : x \in \mathbb{R}\} + c = f^* + c \quad (6.14)$$

$$\arg \min\{f(x) + c : x \in \mathbb{R}\} = \arg \min\{f(x) : x \in \mathbb{R}\} = X^* \quad (6.15)$$

Il valore ottimo viene traslato di c , mentre l'insieme dei punti di minimo X^* resta rigorosamente invariato.

6.4.3 Invarianza per Scalatura Positiva (Costante Moltiplicativa)

La moltiplicazione della funzione per uno scalare strettamente positivo $c > 0$ comprime o dilata verticalmente il profilo geometrico del grafo:

$$\min\{c \cdot f(x) : x \in \mathbb{R}\} = c \cdot \min\{f(x) : x \in \mathbb{R}\} = cf^* \quad (c > 0) \quad (6.16)$$

$$\arg \min\{c \cdot f(x) : x \in \mathbb{R}\} = \arg \min\{f(x) : x \in \mathbb{R}\} = X^* \quad (6.17)$$

Se $c < 0$, il fattore moltiplicativo negativo ribalta il grafo rispetto all'asse delle ascisse, invertendo l'orientamento della ricerca da minimo a massimo:

$$\min\{c \cdot f(x) : x \in \mathbb{R}\} = c \cdot \max\{f(x) : x \in \mathbb{R}\} = -|c| \max\{f(x) : x \in \mathbb{R}\} \quad (6.18)$$

6.5 Ottimizzazione Vincolata e Regione Ammissibile

6.5.1 Formulazione Generale del Problema Vincolato

Nei contesti applicativi dell'ingegneria e dell'apprendimento automatico le variabili decisionali sono vincolate da risorse finite, requisiti fisici o vincoli di sicurezza. Si definisce la **regione ammissibile** (o *feasible region*) $X \subseteq \mathbb{R}$:

$$(P_X) \quad f^* = \min\{f(x) : x \in X\} \quad (6.19)$$

- Un punto $x \in X$ si definisce **soluzione ammissibile**.
- Un punto $x \in \mathbb{R} \setminus X$ si definisce **soluzione inammissibile**.

- Il valore ottimo vincolato è $f^* = \min(\text{im}(X, f)) = \min\{f(x) : x \in X\}$.
- L'insieme delle soluzioni ottime vincolate è dato da:

$$X^* = L(f, f^*) \cap X \quad (6.20)$$

6.5.2 Principio di Peggioramento Monotono per Restrizione

Teorema 6.5.1 (Disuguaglianza Fondamentale dei Vincoli). *Siano $X_1 \subseteq X_2 \subseteq \mathbb{R}$ due regioni ammissibili annidate. Allora:*

$$\min_{x \in X_1} f(x) \geq \min_{x \in X_2} f(x) \quad (6.21)$$

In particolare, per ogni insieme ammissibile $X \subseteq \mathbb{R}$:

$$\min_{x \in X} f(x) \geq \min_{x \in \mathbb{R}} f(x) \quad (6.22)$$

Dimostrazione. Sia $x_1^* \in \arg \min_{x \in X_1} f(x)$. Poiché $X_1 \subseteq X_2$, ne consegue che $x_1^* \in X_2$. Dalla definizione di minimo globale su X_2 , $f(x) \geq \min_{z \in X_2} f(z)$ per qualsiasi $x \in X_2$. Valutando in $x = x_1^*$ si ottiene la tesi. $\square$

Interpretazione Operativa

L'introduzione di vincoli aggiuntivi non può mai migliorare il valore ottimo di un problema di minimizzazione; può unicamente lasciarlo invariato oppure peggiorarlo (ossia incrementarlo).

6.5.3 Tassonomia dei Vincoli Ridondanti

Dato il problema $\min_{x \in X} f(x)$ avente ottimo libero $X_{\text{libero}}^* = \arg \min_{x \in \mathbb{R}} f(x)$:

- **Vincolo completamente inutile (o inattivo):** si verifica quando $X_{\text{libero}}^* \subseteq X$. In tal caso il valore ottimo vincolato coincide perfettamente con quello libero ($f_X^* = f_{\mathbb{R}}^*$) e l'insieme delle soluzioni ottime non subisce alcuna alterazione.
- **Vincolo parzialmente inutile:** si verifica quando $X_{\text{libero}}^* \cap X \neq \emptyset$, ma $X_{\text{libero}}^* \not\subseteq X$. Il vincolo elimina alcune soluzioni ottime alternative senza peggiorare il valore ottimo ($f_X^* = f_{\mathbb{R}}^*$ rimane inalterato, ma $X_X^* \subset X_{\text{libero}}^*$ si riduce).
- **Vincolo attivo ed essenziale:** quando $X_{\text{libero}}^* \cap X = \emptyset$. Il vincolo costringe la soluzione a spostarsi sulla frontiera di X , causando un incremento strettamente positivo del valore ottimo ($f_X^* > f_{\mathbb{R}}^*$).

6.5.4 Rappresentazione Funzionale della Regione Ammissibile

Nella prassi matematica e algoritmica, l'insieme X non viene espresso come una collezione insiemistica astratta, bensì mediante un sistema di equazioni e disequazioni basate su funzioni vincolo $g_i : \mathbb{R} \rightarrow \mathbb{R}$:

1. Vincoli di Uguaglianza:

$$g(x) = v \iff X = L(g, v) \quad (6.23)$$

In forma canonica omogenea (traslando la costante nella funzione):

$$g(x) = 0 \quad (6.24)$$

2. Vincoli di Disuguaglianza:

$$g(x) \leq v \iff X = S(g, v) = \{x \in \mathbb{R} : g(x) \leq v\} \quad (6.25)$$

In forma canonica normalizzata a zero:

$$g(x) \leq 0 \quad (6.26)$$

Qualora il vincolo originale sia formulato come $g(x) \geq 0$, si moltiplica ambo i membri per -1 , ottenendo la forma canonica $-g(x) \leq 0$.

3. Congiunzione di Vincoli Multipli: Più vincoli simultanei corrispondono all'intersezione dei rispettivi sub-level set:

$$\begin{cases} g_1(x) \leq 0 \\ g_2(x) \leq 0 \end{cases} \iff X = S(g_1, 0) \cap S(g_2, 0) \quad (6.27)$$

4. Vincoli di Box (Intervalli Chiusi): Costituiscono la classe fondamentale nell'ottimizzazione univariata:

$$x_- \leq x \leq x_+ \iff X = [x_-, x_+] \quad (6.28)$$

esprimibile in forma canonica mediante il sistema a due disequazioni:

$$\begin{cases} x - x_+ \leq 0 \\ x_- - x \leq 0 \end{cases} \quad (6.29)$$

6.6 Perché l'Ottimizzazione è Difficile: Teoria vs Pratica Numerica

6.6.1 I Casi di Non Esistenza del Minimo

Un problema di ottimizzazione può fallire nell'ammettere un minimo per due ragioni topologiche distinte:

Caso 1: Problema Illimitato Inferiormente ($f^* = -\infty$)

La funzione decresce senza alcun limite inferiore nel dominio:

$$\forall M \in \mathbb{R}, \quad \exists x \in X \quad \text{tale che} \quad f(x) \leq M \quad (6.30)$$

L'esempio canonico è la retta $f(x) = x$ per $x \rightarrow -\infty$. In tale circostanza si scrive convenzionalmente $f^* = -\infty$ e $\arg \min f(x) = \emptyset$.

Caso 2: Infimo Finito Non Raggiunto (f^* finito, ma $x^* \notin X$)

L'immagine $\text{im}(f)$ è limitata inferiormente nel senso dei reali, ma l'estremo inferiore non è un punto dell'immagine:

$$\inf\{f(x) : x \in X\} > -\infty \quad \text{ma} \quad \nexists x^* \in X \quad \text{tale che} \quad f(x^*) = \inf_{x \in X} f(x) \quad (6.31)$$

Si distinguono due manifestazioni tipiche:

- **Casi regolari asintotici:** $f(x) = e^x$ su $X = \mathbb{R}$. L'estremo inferiore è $\inf_{x \in \mathbb{R}} e^x = 0$, ma l'equazione $e^x = 0$ non ammette alcuna soluzione finita in $\mathbb{R}$. Il minimo viene approssimato asintoticamente per $x \rightarrow -\infty$.
- **Casi discontinui patologici:**

$$f(x) = \begin{cases} 1 & \text{se } x = 0 \\ |x| & \text{se } x \neq 0 \end{cases} \quad (6.32)$$

L'infimo della funzione è 0, ma in corrispondenza del candidato naturale $x = 0$ la funzione salta al valore 1. Non esiste alcun punto in cui $f(x) = 0$.

6.6.2 Formalizzazione nei Numeri Reali Estesi $\overline{\mathbb{R}}$

Per gestire analiticamente le configurazioni limite, si estende il corpo dei reali introducendo i simboli di infinito:

$$\overline{\mathbb{R}} = \mathbb{R} \cup \{-\infty, +\infty\} \quad (6.33)$$

In $\overline{\mathbb{R}}$, ogni sottoinsieme $S \subseteq \overline{\mathbb{R}}$ ammette **sempre** sia un infimo che un supremo:

$$\inf S = \max\{v \in \overline{\mathbb{R}} : v \leq s, \forall s \in S\} \quad (6.34)$$

$$\sup S = \min\{v \in \overline{\mathbb{R}} : v \geq s, \forall s \in S\} \quad (6.35)$$

Con le convenzioni standard per gli insiemi vuoti:

$$\inf \emptyset = +\infty, \quad \sup \emptyset = -\infty \quad (6.36)$$

6.6.3 L'Ottimizzazione nell'Aritmetica Floating Point

Nell'hardware di calcolo (CPU e GPU moderne), il continuo reale $\mathbb{R}$ non esiste: si opera esclusivamente attraverso l'aritmetica floating point a precisione finita (standard IEEE 754 in formato 'double' a 64 bit, 'single' a 32 bit, o formati a precisione ridotta FP8/INT4 nei tensori per deep learning).

Le conseguenze algoritmiche sono categoriche:

1. **Risoluzione discreta finita:** tra due numeri macchina consecutivi esiste una distanza minima invalicabile, governata dall'epsilon macchina ($\varepsilon_{\text{mach}} \approx 10^{-16}$ nel formato 'double').
2. **Impossibilità della convergenza esatta:** cercare la soluzione esatta x^* è matematicamente privo di senso sul calcolatore. Qualsiasi criterio d'arresto deve accettare una soluzione ε -approssimata (**ε -optimum**):

$$f^* \leq f(x_\varepsilon) \leq f^* + \varepsilon \quad (6.37)$$

6.6.4 Metriche di Errore: Gap Assoluto vs Gap Relativo

Per valutare l'accuratezza di una soluzione approssimata x :

Definizione 6.6.1 (Gap Assoluto).

$$A(x) = f(x) - f^* \geq 0 \quad (6.38)$$

Criticità: il gap assoluto è sensibile all'ordine di grandezza del problema. Se $f^* = 10^7$, un errore $A(x) = 1$ indica una precisione impeccabile; se $f^* = 10^{-7}$, un errore $A(x) = 1$ rende la soluzione priva di qualsiasi significato fisico.

Definizione 6.6.2 (Gap Relativo Normalizzato).

$$R(x) = \frac{f(x) - f^*}{\max(|f^*|, 1)} \geq 0 \quad (6.39)$$

Vantaggi: fornisce una misura adimensionale e invariante rispetto a riscalature positive della funzione. L'inserimento del termine $\max(|f^*|, 1)$ al denominatore evita la singolarità numerica quando $f^* \rightarrow 0$.

6.6.5 L'Impossibilità dell'Ottimizzazione Black-Box Generica

Supponiamo che una funzione $f : [x_-, x_+] \rightarrow \mathbb{R}$ sia accessibile unicamente come una scatola nera (*black-box oracle*): fornendo un input x , l'oracolo restituisce esclusivamente il valore scalare $f(x)$, senza fornire informazioni analitiche, gradienti o curvature.

Teorema 6.6.1 (Teorema Informale di Impossibilità per Oracolo Avversario). *È teoricamente e praticamente impossibile identificare il minimo globale di una funzione continua arbitraria su un intervallo limitato $[x_-, x_+]$ in un numero finito di interrogazioni all'oracolo.*

Argomento dell'Oracolo Avversario (Needle in a Haystack). Si consideri un intervallo $[x_-, x_+]$ e una funzione identicamente nulla $f(x) = 0$ per ogni x , eccetto che in un singolo punto x_0 non noto a priori, in cui la funzione presenta una buca profondissima (*l'ago nel pagliaio*):

$$f(x_0) = -1, \quad f(x) = 0 \quad \forall x \neq x_0 \quad (6.40)$$

Qualsiasi algoritmo deterministico o casuale che esegua K interrogazioni $x_1, \dots, x_K$ riceverà come risposta il valore 0. L'oracolo, operando da avversario malevolo, potrà sempre collocare x_0 in uno degli infiniti punti non campionati di $[x_-, x_+] \setminus \{x_1, \dots, x_K\}$.

Anche qualora si imponga che la funzione sia continua, collegando il punto $(x_0, -1)$ a zero tramite una cuspidi strettissima di base $\delta > 0$, nessun algoritmo con passo di campionamento discreto $\Delta x > \delta$ potrà mai rilevare la presenza della buca. $\square$

Condizione Necessaria per l'Efficienza Computazionale

L'ottimizzazione matematica diventa possibile e scalabile esclusivamente quando la funzione obiettivo possiede **struttura analitica sfruttabile**: regolarità lipschitziana, differenziabilità, convessità o linearità.

6.7 Ottimizzazione Univariata: Il Caso Lineare

6.7.1 Proprietà Geometriche ed Analitiche

La funzione univariata più elementare non costante è la retta omogenea:

$$f(x) = bx, \quad b \in \mathbb{R} \quad (6.41)$$

Il coefficiente b definisce il coefficiente angolare o **pendenza** (*slope*):

- Se $b > 0$: la funzione è *strettamente crescente*:

$$x_1 > x_2 \iff x_1 - x_2 > 0 \implies b(x_1 - x_2) > 0 \iff f(x_1) > f(x_2) \quad (6.42)$$

- Se $b < 0$: la funzione è *strettamente decrescente*.
- Se $b = 0$: la funzione collassa sulla retta costante identicamente nulla $f(x) = 0$.

6.7.2 Ottimizzazione Non Vincolata su $\mathbb{R}$

Il problema libero $\min_{x \in \mathbb{R}} bx$ è computazionalmente triviale:

- Se $b > 0$: $\lim_{x \rightarrow -\infty} bx = -\infty \implies f^* = -\infty$ (illimitato inferiormente).
- Se $b < 0$: $\lim_{x \rightarrow +\infty} bx = -\infty \implies f^* = -\infty$ (illimitato inferiormente).
- Se $b = 0$: $f^* = 0$, $X^* = \mathbb{R}$ (ogni punto è soluzione ottima indifferente).

6.7.3 Ottimizzazione su Box Vincolato $[x_-, x_+]$

Si consideri il problema vincolato su un intervallo limitato chiuso $[x_-, x_+]$:

$$\min\{bx : x \in [x_-, x_+]\} \quad (6.43)$$

Grazie alla monotonia globale della funzione lineare, il minimo e il massimo si collocano inderogabilmente sui punti di frontiera del box. La regola decisionale opera a costo $\mathcal{O}(1)$:

Condizione	Minimo x^*	Valore Min f^*	Massimo $x_{\max}^*$	Valore Max $f_{\max}^*$
$b > 0$	x_-	bx_-	x_+	bx_+
$b < 0$	x_+	bx_+	x_-	bx_-
$b = 0$	Indifferente	0	Indifferente	0

Tabella 6.1: Quadro decisionale a costo computazionale $\mathcal{O}(1)$ per l'ottimizzazione lineare vincolata.

6.8 L'Illusione degli Insiemi Aperti nel Calcolo Numerico

6.8.1 Il Paradosso Analitico degli Intervalli Aperti

Cosa accadrebbe se la regione ammissibile fosse definita come un intervallo aperto:

$$X = (x_-, x_+) = \{x \in \mathbb{R} : x_- < x < x_+\} \quad (6.44)$$

Supponendo $b > 0$, la funzione $f(x) = bx$ ammette infimo $\inf_{x \in X} f(x) = bx_-$. Tuttavia:

$$\nexists x \in (x_-, x_+) \quad \text{tale che} \quad f(x) = bx_- \quad (6.45)$$

La teoria matematica pura decreta che il problema **non ammette soluzione ottima**.

6.8.2 La Risoluzione Pratica nell'Informatica Computazionale

Dal punto di vista dell'analisi numerica applicata:

1. **I parametri fisici non hanno precisione infinita:** nessuna variabile ingegneristica (corrente, peso, concentrazione) può richiedere un vincolo stretto $x > x_-$ senza un margine finito di sicurezza.
2. **L'aritmetica di macchina non ammette aperti:** tra il numero x_- e il numero floating point immediatamente successivo $x_- + \varepsilon_{\text{mach}}$ non esiste alcun valore rappresentabile.

3. **Formulazione con margine ε :** per evitare di toccare la frontiera vietata, si arretra il vincolo introducendo una tolleranza numerica esplicita:

$$X = [x_- + \varepsilon_-, x_+ - \varepsilon_+] \quad (6.46)$$

Regola Metodologica Aurea

In tutta la trattazione di questo corso, le regioni ammissibili e i vincoli di box saranno considerati rigorosamente **chiusi e limitati**.

6.9 Ottimizzazione Univariata: Il Caso Quadratico Omogeneo

6.9.1 Definizione e Curvatura

La forma quadratica omogenea univariata è definita da:

$$f(x) = ax^2, \quad a \in \mathbb{R} \quad (6.47)$$

Il coefficiente a definisce la **curvatura** della parabola:

- $a > 0$ (**Funzione Convessa**): la parabola volge la concavità verso l'alto. La funzione è strettamente decrescente per $x \leq 0$ e strettamente crescente per $x \geq 0$. Il vertice $(0, 0)$ rappresenta il punto di minimo assoluto. All'aumentare di a , la parabola diviene più stretta e ripida; al tendere di $a \rightarrow 0^+$, la parabola si appiattisce.
- $a < 0$ (**Funzione Concava**): la parabola volge la concavità verso il basso. Il vertice $(0, 0)$ rappresenta il punto di massimo assoluto.
- $a = 0$: la funzione degenera sulla retta costante identicamente nulla.

6.9.2 Risoluzione Libera su $\mathbb{R}$

- Se $a > 0$: $x^* = 0$, $f^* = 0$, con $\max_{x \in \mathbb{R}} ax^2 = +\infty$.
- Se $a < 0$: $x_{\max}^* = 0$, $f_{\max}^* = 0$, con $\min_{x \in \mathbb{R}} ax^2 = -\infty$.
- Se $a = 0$: $f^* = 0$, ogni punto $x \in \mathbb{R}$ è soluzione ottima.

6.9.3 Risoluzione su Box Vincolato $[x_-, x_+]$ (per $a > 0$)

Dato un intervallo limitato chiuso $[x_-, x_+]$, la posizione relativa dello zero (il vertice della parabola) individua tre configurazioni mutuamente esclusive:




Figura 6.1: Le tre configurazioni topologiche per l'ottimizzazione quadratica omogenea vincolata su box $[x_-, x_+]$.

1. **Configurazione Strettamente Negativa ($x_+ < 0$):** l'intero intervallo giace a sinistra del vertice. In tale regione la parabola convessa è strettamente decrescente:

$$x^* = x_+, \quad f^* = a(x_+)^2 \quad (6.48)$$

$$x_{\max}^* = x_-, \quad f_{\max}^* = a(x_-)^2 \quad (6.49)$$

2. **Configurazione Strettamente Positiva ($x_- > 0$):** l'intero intervallo giace a destra del vertice. La funzione è strettamente crescente:

$$x^* = x_-, \quad f^* = a(x_-)^2 \quad (6.50)$$

$$x_{\max}^* = x_+, \quad f_{\max}^* = a(x_+)^2 \quad (6.51)$$

3. **Configurazione con Vertice Interno ($x_- \leq 0 \leq x_+$):** il vertice appartiene alla regione ammissibile, per cui il minimo vincolato coincide con il minimo globale libero:

$$x^* = 0, \quad f^* = 0 \quad (6.52)$$

Il punto di massimo si colloca invece sulla frontiera del box più distante dall'origine:

$$x_{\max}^* = \arg \max \{a(x_-)^2, a(x_+)^2\} = \begin{cases} x_- & \text{se } |x_-| > |x_+| \\ x_+ & \text{se } |x_+| > |x_-| \end{cases} \quad (6.53)$$

6.10 Ottimizzazione Univariata: Caso Quadratico Non Omogeneo

6.10.1 Definizione e Non Separabilità dell'Operatore Minimo

Si consideri la funzione quadratica scalare completa, provvista di termine lineare:

$$f(x) = ax^2 + bx, \quad a, b \in \mathbb{R}, \quad a \neq 0, b \neq 0 \quad (6.54)$$

Proprietà Fondamentale di Non Linearità dell'Operatore Minimo

In generale, l'operatore di minimo non è additivo:

$$\min\{ax^2 + bx\} \neq \min\{ax^2\} + \min\{bx\} \quad (6.55)$$

Il minimo della somma di due funzioni non coincide con la somma dei rispettivi minimi, tranne nel caso eccezionale in cui le due funzioni condividano esattamente il medesimo punto di minimo (ipotesi qui violata, poiché il termine lineare bx non ammette minimo finito su $\mathbb{R}$).

6.10.2 Il Principio del Cambio di Coordinate (Shift dell'Origine)

Per risolvere il problema senza ricorrere al calcolo differenziale, si applica una delle tecniche algebriche più eleganti e feconde dell'ottimizzazione: il **cambio di coordinate per traslazione**. L'obiettivo è definire una nuova variabile traslata z attorno a uno spostamento dell'origine $\bar{x} \in \mathbb{R}$ da determinare:

$$z = x - \bar{x} \quad \Longleftrightarrow \quad x = z + \bar{x} \quad (6.56)$$

in modo che, espressa in funzione di z , la funzione quadratica divenga **omogenea puro** (annullando il termine lineare moltiplicato per z).

6.10.3 Derivazione Algebrica Passo-Passo

Sostituendo l'espressione $x = z + \bar{x}$ nella funzione $f(x)$:

$$\begin{aligned} f(z + \bar{x}) &= a(z + \bar{x})^2 + b(z + \bar{x}) \\ &= a(z^2 + 2z\bar{x} + \bar{x}^2) + bz + b\bar{x} \\ &= az^2 + 2a\bar{x}z + a\bar{x}^2 + bz + b\bar{x} \end{aligned} \quad (6.57)$$

Raccogliendo i termini rispetto alle potenze decrescenti di z :

$$f(z + \bar{x}) = az^2 + (2a\bar{x} + b)z + (a\bar{x}^2 + b\bar{x}) \quad (6.58)$$

Si osservi che il termine costante indipendente da z corrisponde esattamente al valore della funzione originaria calcolata nel punto di traslazione $\bar{x}$:

$$a\bar{x}^2 + b\bar{x} = f(\bar{x}) \quad (6.59)$$

Pertanto la funzione trasformata si riscrive esattamente come:

$$f(z + \bar{x}) = az^2 + (2a\bar{x} + b)z + f(\bar{x}) \quad (6.60)$$

Per eliminare la componente lineare e rendere la funzione omogenea rispetto alla nuova variabile z , imponiamo che il coefficiente di z sia identicamente nullo:

$$2a\bar{x} + b = 0 \implies \bar{x} = -\frac{b}{2a} \quad (6.61)$$

6.10.4 Risoluzione nello Spazio Traslato e Mappatura Inversa

Ponendo $\bar{x} = -\frac{b}{2a}$, la funzione espressa in z assume la forma canonica omogenea disaccoppiata:

$$g(z) = f(z + \bar{x}) = az^2 + f(\bar{x}) \quad (6.62)$$

Poiché $f(\bar{x})$ è una costante additiva indipendente dalla variabile di ottimizzazione z :

$$\arg \min_{z \in \mathbb{R}} g(z) = \arg \min_{z \in \mathbb{R}} (az^2 + f(\bar{x})) = \arg \min_{z \in \mathbb{R}} (az^2) \quad (6.63)$$

Per $a > 0$ (parabola convessa), la soluzione ottima nello spazio trasformato è immediata:

$$z^* = 0 \quad (6.64)$$

Riconvertendo la soluzione nello spazio originario delle variabili x :

$$x^* = z^* + \bar{x} = 0 + \bar{x} = -\frac{b}{2a} \quad (6.65)$$

Il valore ottimo si determina valutando la funzione in $x^* = \bar{x}$:

$$\begin{aligned} f^* = f(\bar{x}) &= a \left(-\frac{b}{2a} \right)^2 + b \left(-\frac{b}{2a} \right) \\ &= a \frac{b^2}{4a^2} - \frac{b^2}{2a} = \frac{b^2}{4a} - \frac{2b^2}{4a} = -\frac{b^2}{4a} \end{aligned} \quad (6.66)$$




Figura 6.2: Visualizzazione geometrica del cambio di coordinate per la parabola non omogenea: il vertice x^* si colloca esattamente a metà strada tra le due radici x_1 e x_2 .

6.10.5 Interpretazione Geometrica: La Mediana delle Radici

La funzione quadratica $f(x) = ax^2 + bx = x(ax + b)$ ammette sempre due radici reali distinte (se $b \neq 0$):

$$x_1 = 0, \quad x_2 = -\frac{b}{a} \quad (6.67)$$

Il punto di ottimo calcolato con il cambio di coordinate coincide esattamente con il **punto medio (o mediana geometrica)** delle radici:

$$\bar{x} = \frac{x_1 + x_2}{2} = \frac{0 + (-b/a)}{2} = -\frac{b}{2a} \quad (6.68)$$

Questa proprietà di simmetria è universale per qualsiasi parabola univariata e riflette il fatto che la derivata di un polinomio di secondo grado è una retta che interseca l'asse delle ascisse esattamente nel punto mediano dei suoi zeri reali.

6.10.6 Ottimizzazione su Box Vincolato per Funzione Generale

Nel caso in cui sia presente il vincolo $x \in [x_-, x_+]$, il cambio di coordinate trasla con identico rigore anche gli estremi dell'intervallo ammissibile per la variabile z :

$$x \in [x_-, x_+] \iff z \in [x_- - \bar{x}, x_+ - \bar{x}] \quad (6.69)$$

Posti $z_- = x_- - \bar{x}$ e $z_+ = x_+ - \bar{x}$, il problema si riduce esattamente alla minimizzazione quadratica omogenea vincolata sul box $[z_-, z_+]$ risolta nella Sezione 6.9:

$$z^* = \begin{cases} z_+ & \text{se } z_+ < 0 \\ z_- & \text{se } z_- > 0 \\ 0 & \text{se } z_- \leq 0 \leq z_+ \end{cases} \quad (6.70)$$

da cui si ricava la soluzione originale risostituendo $x^* = z^* + \bar{x}$.

6.11 Formulario Sinottico dei Risultati Univariati

Classe	Forma	Condizione	Minimo Libero x^*	Valore f^*
Lineare	bx	$b > 0$	Non esiste ($x \rightarrow -\infty$)	$-\infty$
		$b < 0$	Non esiste ($x \rightarrow +\infty$)	$-\infty$
		$b = 0$ (degenere)	Indifferente ($\forall x \in \mathbb{R}$)	0
Quadratica omogenea	ax^2	$a > 0$ (convessa)	$x^* = 0$ (unico)	0
		$a < 0$ (concava)	Non esiste ($x \rightarrow \pm\infty$)	$-\infty$
		$a = 0$ (degenere)	Indifferente ($\forall x \in \mathbb{R}$)	0
Quadratica generale	$ax^2 + bx$	$a > 0$ (convessa)	$x^* = -b/(2a)$ (vertice)	$-b^2/(4a)$
		$a < 0$ (concava)	Non esiste ($x \rightarrow \pm\infty$)	$-\infty$
		$a = 0, b \neq 0$	Non esiste (lineare)	$-\infty$

Tabella 6.2: Quadro sinottico comparativo dell'ottimizzazione univariata libera.

Capitolo 7

Ottimizzazione Multivariata: Geometria, Funzioni Lineari e Forme Quadratiche

7.1 Dall'Univariato al Multivariato: La Dimensionalità dello Spazio $\mathbb{R}^n$

7.1.1 Lo Spazio di Input Multivariato

Nelle applicazioni reali della scienza dei dati, dell'apprendimento automatico e dell'ingegneria computazionale, i modelli decisionali dipendono quasi universalmente da una molteplicità di variabili interconnesse. L'oggetto fondamentale d'indagine diviene la funzione scalare multivariata:

$$f : \mathbb{R}^n \rightarrow \mathbb{R}, \quad f(x) = f(x_1, x_2, \dots, x_n) \quad (7.1)$$

dove l'argomento x è un vettore colonna strutturato di n componenti reali:

$$x = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = [x_i]_{i=1}^n \in \mathbb{R}^n \quad (7.2)$$

La dimensione vettoriale n copre ordini di grandezza radicalmente disomogenei:

- **Piccola scala** ($n \in \{2, 3, 10^2\}$): modelli geometrici euclidei, cinematica inversa, allocazione elementare di risorse.

- **Media e grande scala** ($n \in \{10^4, 10^5\}$): elaborazione di segnali e immagini, calcolo strutturale, flussi di rete e logistica integrata.
- **Scala mostruosa** (*heinously large*, $n \in \{10^9, 10^{11}\}$): addestramento di reti neurali profonde e modelli linguistici di grandi dimensioni (LLM), dove n enumera i pesi sinaptici e i parametri di attenzione del trasformatore.

7.1.2 La Maledizione della Dimensionalità

Lo spazio vettoriale continuo $\mathbb{R}^n$ è definito come il prodotto cartesiano di $\mathbb{R}$ iterato n volte:

$$\mathbb{R}^n = \underbrace{\mathbb{R} \times \mathbb{R} \times \cdots \times \mathbb{R}}_{n \text{ volte}} \quad (7.3)$$

L'Espansione Volumetrica Esponenziale

La quantità di spazio racchiusa in $\mathbb{R}^n$ cresce esponenzialmente rispetto alla dimensione n . L'introduzione di variabili addizionali in un modello non costituisce mai un'operazione computazionalmente neutra, bensì altera la densità geometrica dello spazio esplorabile.

Per quantificare rigorosamente l'esplosione combinatoria generata dalla dimensionalità, si consideri la semplificazione più drastica possibile:

1. Si limiti il dominio continuo a un ipercubo unitario compatto (*box*):

$$X = \{x \in \mathbb{R}^n : 0 \leq x_i \leq 1, i = 1, \dots, n\} = [0, 1]^n \quad (7.4)$$

2. Si rinunci interamente alla continuità interna, campionando unicamente i valori estremi discreti per ciascuna variabile, ossia $x_i \in \{0, 1\}$.

L'insieme discreto risultante coincide con i vertici dell'**ipercubo booleano** $\{0, 1\}^n$, con cardinalità:

$$|V| = 2^n \text{ vertici} \quad (7.5)$$

Anche per dimensioni apparentemente modeste (ad esempio $n = 100$), si ottiene $2^{100} \approx 1.26 \times 10^{30}$ configurazioni discrete. Tale numero supera di svariati ordini di grandezza la capacità di calcolo di qualsiasi supercomputer, rendendo l'esplorazione esaustiva (*brute-force*) impraticabile.

7.2 Ottimizzazione Vettoriale e Multi-Obiettivo

7.2.1 La Criticità dell'Unico Obiettivo Scalare

L'ipotesi fondante dell'ottimizzazione classica risiede nella comprimibilità dell'intero valore di una decisione $x \in X$ in un singolo valore scalare $f(x) \in \mathbb{R}$.

Poiché la retta reale $\mathbb{R}$ è dotata di un **ordinamento totale**:

$$\forall a, b \in \mathbb{R} \implies a \leq b \quad \vee \quad b \leq a \quad (7.6)$$

dati due punti distinti x' e x'' , è sempre possibile stabilire in modo univoco e oggettivo quale configurazione sia preferibile confrontando $f(x')$ con $f(x'')$.

Nelle applicazioni empiriche, tuttavia, i processi decisionali complessi richiedono il bilanciamento di criteri multipli, intrinsecamente contrastanti e privi di una metrica comune (*incommensurabili*):

- **Acquisto di un autoveicolo:** costo d'acquisto vs consumo di carburante vs sicurezza passiva vs estetica.
- **Apprendimento automatico:** minimizzazione della funzione di perdita empirica sui dati $\mathcal{L}(w)$ vs minimizzazione della complessità strutturale del modello $R(w)$ per prevenire il sovradattamento (*overfitting*).

Un problema di **ottimizzazione multi-obiettivo** (o vettoriale) si formula come:

$$\min_{x \in X} F(x) = \begin{bmatrix} f_1(x) \\ f_2(x) \\ \vdots \\ f_k(x) \end{bmatrix}, \quad F : X \rightarrow \mathbb{R}^k, \quad k \geq 2 \quad (7.7)$$

7.2.2 Esempio Didattico: La Selezione di Portafoglio di Markowitz

Si consideri un investitore finanziario che alloca il proprio capitale su un paniere di asset:

- **Obiettivo 1 (Rendimento atteso):** $f_1(x) \in \mathbb{R}$, da massimizzare (ovvero $-f_1(x)$ da minimizzare).
- **Obiettivo 2 (Rischio finanziario / Volatilità):** $f_2(x) \in \mathbb{R}$ (varianza della distribuzione dei rendimenti), da minimizzare.

Gli asset a basso rischio (es. titoli di stato a breve termine) offrono rendimenti minimi, mentre gli asset ad alto potenziale di rendimento comportano oscillazioni marcate. Non esiste alcun portafoglio che minimizzi contemporaneamente la varianza e massimizzi il rendimento assoluto.

7.2.3 Ordinamento Parziale e Frontiera di Pareto

Lo spazio vettoriale $\mathbb{R}^k$ con $k \geq 2$ non possiede un ordinamento totale naturale, bensì un **ordinamento parziale** indotto dal cono ortante non negativo:

$$u \leq v \iff u_i \leq v_i \quad \forall i = 1, \dots, k \quad (7.8)$$

Definizione 7.2.1 (Dominanza di Pareto). Si assuma per convenzione che tutti i k criteri siano da minimizzare. Un punto ammissibile $x' \in X$ **domina in senso paretiano** un punto $x'' \in X$ (notazione: $x' \succ_P x''$) se e solo se:

$$f_i(x') \leq f_i(x'') \quad \forall i \in \{1, \dots, k\} \quad \wedge \quad \exists j \in \{1, \dots, k\} : f_j(x') < f_j(x'') \quad (7.9)$$

Definizione 7.2.2 (Soluzione Non Dominata o Pareto-Ottima). Un punto $x^* \in X$ si definisce **Pareto-ottimo** (o non dominato) se non esiste alcun altro vettore $x \in X$ che domini x^* . L'insieme di tutte le immagini $F(x^*)$ nello spazio degli obiettivi costituisce la **Frontiera di Pareto**.




Figura 7.1: Rappresentazione geometrica della Frontiera di Pareto nel problema di selezione di portafoglio di Markowitz.

Un algoritmo di ottimizzazione matematico non possiede la prerogativa intrinseca di selezionare un singolo punto sulla frontiera di Pareto: la

scelta finale appartiene al decisore umano in base alle preferenze soggettive (propensione al rischio vs orizzonte temporale).

7.2.4 Tecniche Operative di Riduzione a Singolo Obiettivo

Per applicare gli algoritmi di ottimizzazione continua a problemi multi-obiettivo, si impiegano due strategie fondamentali:

1. **Scalarizzazione (*Scalarization*)**: Si aggregano i criteri mediante una combinazione lineare pesata:

$$\min_{x \in X} \{f_1(x) + \alpha f_2(x)\}, \quad \alpha > 0 \quad (7.10)$$

Il coefficiente α funge da *tasso di cambio*: quantifica quanto peggioramento di f_1 si accetta di tollerare per guadagnare un'unità di miglioramento su f_2 . Al variare di $\alpha \in (0, +\infty)$, la risoluzione genera i punti della frontiera di Pareto. Nel machine learning, la minimizzazione della perdita regolarizzata:

$$\min_w \{\mathcal{L}(w) + \lambda R(w)\} \quad (7.11)$$

rappresenta esattamente una scalarizzazione, dove il parametro di trade-off λ viene identificato empiricamente tramite validazione incrociata.

2. **Metodo dei Vincoli (*Budgeting*)**: Si elegge un unico criterio come obiettivo primario, declassando tutti gli altri a vincoli limitati da soglie prefissate (budget):

$$\min_{x \in X} \{f_1(x) : f_2(x) \leq \beta_2, \dots, f_k(x) \leq \beta_k\} \quad (7.12)$$

Campionando sistematicamente i vettori soglia β , si traccia la frontiera non dominata.

Convenzione Standard

Salvo esplicita menzione contraria, si presuppone che la fase di formulazione abbia già ricondotto il problema a una singola funzione obiettivo scalare $f : \mathbb{R}^n \rightarrow \mathbb{R}$.

7.3 Geometria Euclidea in $\mathbb{R}^n$ e Tomografia di Funzione

7.3.1 Prodotto Scalare Canonico e Norma Indotta

Dati due vettori $x, z \in \mathbb{R}^n$, il **prodotto scalare euclideo canonico** è definito da:

$$\langle x, z \rangle = x^T z = \sum_{i=1}^n x_i z_i = x_1 z_1 + x_2 z_2 + \cdots + x_n z_n \quad (7.13)$$

Il prodotto scalare soddisfa gli assiomi fondamentali di simmetria ($\langle x, z \rangle = \langle z, x \rangle$), bilinearità e positività definita ($\langle x, x \rangle > 0$ per ogni $x \neq 0$).

La **norma euclidea** (norma ℓ_2) indotta dal prodotto scalare misura la lunghezza geometrica del vettore:

$$\|x\| = \sqrt{\langle x, x \rangle} = \sqrt{\sum_{i=1}^n x_i^2} \quad (7.14)$$

7.3.2 Interpretazione Angolare e Disuguaglianza di Cauchy-Schwarz

Geometricamente, il prodotto scalare codifica l'angolo convesso $\theta \in [0, \pi]$ sotteso dai vettori x e z :

$$\langle x, z \rangle = \|x\| \|z\| \cos(\theta) \quad (7.15)$$

Da cui derivano le configurazioni spaziali:

- $\langle x, z \rangle > 0 \iff \theta \in [0, \pi/2)$: i vettori puntano nella medesima direzione generale (angolo acuto).
- $\langle x, z \rangle = 0 \iff \theta = \pi/2$: i vettori sono reciprocamente **ortogonali** ($x \perp z$).
- $\langle x, z \rangle < 0 \iff \theta \in (\pi/2, \pi]$: i vettori puntano in direzioni opposte (angolo ottuso).

Poiché $|\cos(\theta)| \leq 1$, discende direttamente la fondamentale **disuguaglianza di Cauchy-Schwarz**:

$$|\langle x, z \rangle| \leq \|x\| \|z\|, \quad \forall x, z \in \mathbb{R}^n \quad (7.16)$$

con uguaglianza stretta $|\langle x, z \rangle| = \|x\| \|z\|$ se e solo se x e z sono collineari ($x = \gamma z$ con $\gamma \in \mathbb{R}$).

7.3.3 Il Concetto di Tomografia di una Funzione

Nello spazio multivariato con $n \geq 3$, il grafo di una funzione $\text{gr}(f) = \{(x, f(x)) : x \in \mathbb{R}^n\} \subset \mathbb{R}^{n+1}$ non è visualizzabile. Lo strumento analitico primario per comprenderne il comportamento locale e globale è la **tomografia**.

Definizione 7.3.1 (Tomografia Direzionale). Dato un punto di ancoraggio $x \in \mathbb{R}^n$ e una direzione vettoriale non nulla $d \in \mathbb{R}^n \setminus \{0\}$, la **tomografia** di f da x lungo la direzione d è la funzione univariata $\phi_{x,d} : \mathbb{R} \rightarrow \mathbb{R}$ definita da:

$$\phi_{x,d}(\alpha) = f(x + \alpha d), \quad \alpha \in \mathbb{R} \quad (7.17)$$

Lo scalare α quantifica l'ampiezza dello spostamento con segno lungo la retta passante per x ed orientata secondo d .

La lunghezza della direzione funge unicamente da fattore di scala per il parametro α :

$$\phi_{x,\beta d}(\alpha) = f(x + \alpha(\beta d)) = \phi_{x,d}(\alpha\beta) \quad (7.18)$$

Pertanto, per rimuovere qualsiasi arbitrarietà di scala, è norma analitica fissare la direzione di esplorazione unitaria:

$$\|d\| = 1 \quad (7.19)$$

7.4 Funzioni Lineari Multivariate

7.4.1 Definizione e Proprietà di Separabilità

Una funzione multivariata $f : \mathbb{R}^n \rightarrow \mathbb{R}$ si definisce **lineare** se è esprimibile mediante il prodotto scalare con un vettore costante assegnato $b \in \mathbb{R}^n$:

$$f(x) = \langle b, x \rangle = b^T x = \sum_{i=1}^n b_i x_i \quad (7.20)$$

Una funzione lineare è intrinsecamente **separabile**: coincide esattamente con la somma di n funzioni lineari univariate indipendenti:

$$f(x) = \sum_{i=1}^n f_i(x_i), \quad \text{con } f_i(x_i) = b_i x_i \quad (7.21)$$

L'operazione non presenta accoppiamenti bilineari tra variabili distinte.

7.4.2 Geometria del Grafo e degli Insiemi di Livello

- **Grafo:** $\text{gr}(f) = \{(x, b^T x) : x \in \mathbb{R}^n\}$ è un iperpiano vettoriale di dimensione n immerso nello spazio $\mathbb{R}^{n+1}$, passante per l'origine.
- **Insiemi di Livello:** Fissato un valore $v \in \mathbb{R}$, l'insieme di livello è definito da:

$$L(f, v) = \{x \in \mathbb{R}^n : b^T x = v\} \quad (7.22)$$

Tale insieme costituisce un iperpiano affine di dimensione $n - 1$ in $\mathbb{R}^n$. Al variare di v , gli insiemi di livello formano una famiglia infinita di iperpiani paralleli ed equidistanti.

Teorema 7.4.1 (Ortogonalità del Vettore b agli Insiemi di Livello). *Il vettore dei coefficienti b è ortogonale a ogni direzione tangente agli insiemi di livello $L(f, v)$, per qualsiasi valore $v \in \mathbb{R}$.*

Dimostrazione. Siano $x, z \in L(f, v)$ due punti arbitrari appartenenti al medesimo insieme di livello. Per definizione:

$$b^T x = v \quad \wedge \quad b^T z = v \quad (7.23)$$

Sottraendo membro a membro:

$$b^T z - b^T x = 0 \iff b^T (z - x) = 0 \iff \langle b, z - x \rangle = 0 \quad (7.24)$$

Il vettore differenza $z - x$ rappresenta una generica direzione tangente all'iperpiano di livello. Poiché b risulta perpendicolare a qualsiasi vettore di spostamento interno all'insieme di livello, si conclude che $b \perp L(f, v)$. $\square$

7.5 Tomografia Lineare e Direzione di Massima Discesa

7.5.1 Calcolo della Sezione Tomografica

Fissata l'origine $x = 0$ e una direzione unitaria $\|d\| = 1$, la tomografia di una funzione lineare $f(x) = b^T x$ si riduce a:

$$\phi_{0,d}(\alpha) = f(0 + \alpha d) = b^T(\alpha d) = \alpha \langle b, d \rangle = \alpha \|b\| \|d\| \cos(\theta) = \alpha \|b\| \cos(\theta) \quad (7.25)$$

dove θ rappresenta l'angolo geometrico tra il vettore caratteristico b e la direzione di campionamento d .

La tomografia è una **retta univariata** passante per l'origine, la cui pendenza costante è dettata dal prodotto scalare $\langle b, d \rangle$.

7.5.2 Analisi Direzionale: L'Analogia dello Schermo Radar

Ruotando la direzione d lungo l'angolo giro (in analogia con il fascio rotante di un radar), si evidenziano cinque regimi analitici fondamentali:

1. d **perfettamente concorde con** b ($\theta = 0 \implies \cos(\theta) = 1$):

$$\phi_{0,d}(\alpha) = \alpha \|b\| \quad (7.26)$$

La retta esibisce la massima pendenza positiva possibile. Spostandosi lungo d , la funzione cresce alla massima velocità ammissibile (**massima salita**).

2. d **acuto rispetto a** b ($\theta \in (0, \pi/2) \implies \cos(\theta) > 0$): La pendenza è strettamente positiva ma inferiore a $\|b\|$.

3. d **ortogonale a** b ($\theta = \pi/2 \implies \cos(\theta) = 0$):

$$\phi_{0,d}(\alpha) = 0, \quad \forall \alpha \in \mathbb{R} \quad (7.27)$$


La tomografia è una retta orizzontale identicamente nulla. Muoversi lungo una direzione ortogonale a b equivale a muoversi parallelamente all'iperpiano di livello $L(f, 0)$, mantenendo il valore della funzione invariato.

4. d **ottuso rispetto a** b ($\theta \in (\pi/2, \pi) \implies \cos(\theta) < 0$): La retta ha pendenza negativa: procedendo per valori positivi di α , la funzione decresce.

5. d **opposto a** b ($\theta = \pi \implies \cos(\theta) = -1$):

$$\phi_{0,d}(\alpha) = -\alpha \|b\| \quad (7.28)$$

La retta raggiunge la massima pendenza negativa (**massima discesa**).



(a) Spazio delle Direzioni Unitarie $\|d\|=1$ (b) Profili Tomografici Univariati

Figura 7.2: Visualizzazione tomografica di una funzione lineare: rotazione della direzione esplorativa ed identificazione delle pendenze estreme.

7.5.3 Derivazione Formale della Direzione di Massima Discesa

Si supponga di trovarsi nell'origine e di poter compiere un unico passo di lunghezza fissata $\|\Delta x\| = \varepsilon > 0$. La variazione indotta sul valore dell'obiettivo è:

$$\Delta f = f(\varepsilon d) - f(0) = \varepsilon \langle b, d \rangle = \varepsilon \|b\| \cos(\theta) \quad (7.29)$$

Per indurre la massima riduzione possibile di valore ($\Delta f < 0$ minimo), con $\varepsilon > 0$ e $\|d\| = 1$, si deve risolvere:

$$\min_{\|d\|=1} \langle b, d \rangle = \min_{\|d\|=1} \|b\| \cos(\theta) \quad (7.30)$$

Il valore minimo del coseno è -1 , conseguito univocamente per $\theta = \pi$. Ne deriva la regola fondamentale:

$$d^* = -\frac{b}{\|b\|} \quad (7.31)$$

Principio dell'Antigradiente

La direzione lungo la quale una funzione lineare sperimenta la massima velocità istantanea di decrescita è rigorosamente l'**antigradiente** $-b$, ovvero la direzione opposta al vettore dei coefficienti.

7.6 Dalle Funzioni Lineari alle Funzioni Quadratiche: Il Caso Separabile

7.6.1 Funzioni Quadratiche Separabili

Il modo più elementare per estendere il concetto di funzione quadratica univariata a n variabili consiste nel comporre additivamente n parabole indipendenti:

$$f(x) = \sum_{i=1}^n (a_i x_i^2 + b_i x_i), \quad a, b \in \mathbb{R}^n \quad (7.32)$$

Quando $a_i = 1$ e $b_i = 0$ per ogni i , la funzione coincide con il quadrato della norma euclidea:

$$f(x) = \sum_{i=1}^n x_i^2 = \|x\|^2 \quad (7.33)$$

In tal caso la funzione è isotropa: gli insiemi di livello $L(f, v) = \{x \in \mathbb{R}^n : \|x\|^2 = v\}$ sono le ipersfere euclidee centrate nell'origine di raggio $r = \sqrt{v}$.

7.6.2 Curvatura Anisotropia ed Eccentricità

Si consideri il caso in dimensione $n = 2$, ponendo $b = 0$, $a_2 = 1$ e variando il parametro $a_1 = a > 0$:

$$f(x_1, x_2) = ax_1^2 + x_2^2 \quad (7.34)$$

Gli insiemi di livello corrispondenti a un valore target $v > 0$ descrivono l'equazione:

$$ax_1^2 + x_2^2 = v \iff \frac{x_1^2}{v/a} + \frac{x_2^2}{v} = 1 \quad (7.35)$$

La geometria dell'ellisse dipende dal rapporto delle curvature:

- **Se $a = 1$:** i semiassi coincidono ($\sqrt{v/a} = \sqrt{v}$): l'insieme di livello è una circonferenza perfetta.
- **Se $a > 1$:** la funzione cresce più rapidamente lungo x_1 che lungo x_2 . I punti che raggiungono il livello v si trovano più vicini all'origine lungo l'asse x_1 ($|x_1| = \sqrt{v/a} < \sqrt{v}$). L'ellisse si presenta **allungata verticalmente**.
- **Se $0 < a < 1$:** la curvatura lungo x_1 è più blanda: l'ellisse si presenta **allungata orizzontalmente**.

- **Al tendere di $a \rightarrow 0^+$:** la curvatura lungo l'asse orizzontale svanisce. Il semiasse orizzontale $\sqrt{v/a} \rightarrow +\infty$: l'ellisse degenera in due rette parallele orizzontali $x_2 = \pm\sqrt{v}$.

7.7 La Forma Quadratica Generale Omogenea e la Simmetrizzazione

7.7.1 Definizione e Termini Incrociati

Una funzione quadratica omogenea generale ammette termini bilineari misti $x_i x_j$ con $i \neq j$:

$$f(x) = \frac{1}{2} x^T Q x = \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n Q_{ij} x_i x_j = \frac{1}{2} \sum_{i=1}^n Q_{ii} x_i^2 + \frac{1}{2} \sum_{i=1}^n \sum_{j \neq i}^n Q_{ij} x_i x_j \quad (7.36)$$

dove $Q \in \mathbb{R}^{n \times n}$ è una matrice quadrata assegnata. Il coefficiente $1/2$ è introdotto per convenzione analitica affinché la matrice Hessiana della funzione coincida esattamente con Q .

I coefficienti diagonali Q_{ii} determinano la curvatura pura lungo le direzioni canoniche, mentre i coefficienti fuori diagonale Q_{ij} introducono accoppiamento e rotazione degli assi principali.

Esempio 7.7.1 (Calcolo di Forma Quadratica in Dimensione 2). Si consideri la matrice non simmetrica e il vettore:

$$Q = \begin{bmatrix} 1 & 3 \\ 2 & 2 \end{bmatrix}, \quad x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \quad (7.37)$$

Calcolando il prodotto per passi successivi:

1. Vettore intermedio Qx :

$$Qx = \begin{bmatrix} 1 & 3 \\ 2 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} x_1 + 3x_2 \\ 2x_1 + 2x_2 \end{bmatrix} \quad (7.38)$$

2. Prodotto a sinistra per x^T :

$$\begin{aligned} x^T Q x &= \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} x_1 + 3x_2 \\ 2x_1 + 2x_2 \end{bmatrix} = x_1(x_1 + 3x_2) + x_2(2x_1 + 2x_2) \\ &= x_1^2 + 3x_1x_2 + 2x_1x_2 + 2x_2^2 = x_1^2 + 5x_1x_2 + 2x_2^2 \end{aligned} \quad (7.39)$$

I valori fuori diagonale ($Q_{12} = 3$ e $Q_{21} = 2$) si fondono in un unico termine simmetrico bilineare avente coefficiente $3 + 2 = 5$.

7.7.2 Teorema di Simmetrizzazione

Teorema 7.7.1 (Invarianza per Simmetrizzazione). *Sia $Q \in \mathbb{R}^{n \times n}$ una generica matrice reale quadrata non simmetrica ($Q \neq Q^T$). La funzione quadratica $f(x) = \frac{1}{2}x^T Qx$ coincide identicamente su tutto $\mathbb{R}^n$ con la funzione generata dalla matrice simmetrizzata:*

$$Q_{sym} = \frac{Q + Q^T}{2} \quad (7.40)$$

ovvero:

$$\frac{1}{2}x^T Qx = \frac{1}{2}x^T Q_{sym}x, \quad \forall x \in \mathbb{R}^n \quad (7.41)$$

Dimostrazione. La quantità $x^T Qx$ è uno scalare, ovvero una matrice di dimensione 1×1 . Poiché uno scalare coincide identicamente con la propria trasposta:

$$x^T Qx = (x^T Qx)^T \quad (7.42)$$

Applicando la regola di trasposizione del prodotto di matrici $(ABC)^T = C^T B^T A^T$:

$$(x^T Qx)^T = x^T Q^T (x^T)^T = x^T Q^T x \quad (7.43)$$

Esprimendo $x^T Qx$ come semisomma aritmetica di se stesso e del suo trasposto:

$$x^T Qx = \frac{x^T Qx + x^T Q^T x}{2} = x^T \left(\frac{Q + Q^T}{2} \right) x = x^T Q_{sym}x \quad (7.44)$$

Moltiplicando per il fattore scalare $1/2$ si ottiene l'uguaglianza funzionale esatta. $\square$

Vantaggio Computazionale e Convenzione Universale

Una matrice simmetrica di dimensione $n \times n$ richiede la memorizzazione di soli $n(n+1)/2$ coefficienti distinti anziché n^2 , dimezzando i requisiti di memoria per modelli di grandi dimensioni.

Convenzione Operativa: In tutta la trattazione seguente dell'ottimizzazione continua, ogni matrice quadratica Q è rigorosamente assunta **simmetrica**:

$$Q = Q^T \quad (7.45)$$

7.8 Decomposizione Spettrale e Tassonomia delle Matrici

Raccordo con l'Algebra Spettrale (Capitolo 3)

I fondamenti algebrici delle forme quadratiche, la dimostrazione formale del Teorema Spettrale (Teorema 3.7.1), il Quoziente di Rayleigh (Teorema 3.8.1) e il criterio spettrale di definitezza SPD/SPSD (Teorema 3.9.1) sono stati analizzati rigorosamente nel Capitolo 3 a pagina 65. In questo capitolo, tale apparato viene reinterpretato dal punto di vista dell'analisi e dell'ottimizzazione convessa: la matrice simmetrica Q coincide con l'Hessiana della funzione obiettivo, e i suoi autovalori governano direttamente la curvatura tomografica del paesaggio di costo.

7.8.1 Simmetria Centrale e Tomografia

Poiché $(-x)^T Q (-x) = (-1)^2 x^T Q x = x^T Q x$, ogni forma quadratica omogenea è dotata di simmetria centrale rispetto all'origine:

$$f(-x) = f(x), \quad \forall x \in \mathbb{R}^n \quad (7.46)$$

L'origine $x = 0$ è sempre un punto stazionario di riferimento. Fissata una direzione unitaria $\|d\| = 1$, la tomografia condotta dall'origine vale:

$$\phi_{0,d}(\alpha) = \frac{1}{2}(\alpha d)^T Q (\alpha d) = \frac{1}{2}\alpha^2(d^T Q d) \quad (7.47)$$

La sezione tomografica è sempre una **parabola omogenea univariata**, la cui curvatura è governata dallo scalare:

$$a_d = d^T Q d \quad (7.48)$$

7.8.2 Il Teorema Spettrale per Matrici Reali Simmetriche

La curvatura a_d al variare dell'orientamento di d è interamente codificata dalla struttura spettrale di Q . In virtù della simmetria di $Q = Q^T \in \mathbb{R}^{n \times n}$:

1. **Realtà dello Spettro:** Tutti gli n autovalori $\lambda_1, \lambda_2, \dots, \lambda_n$ sono numeri strettamente reali.

2. **Base Ortonormale di Autovettori:** Esiste una base di $\mathbb{R}^n$ costituita da n autovettori mutuamente ortogonali e normalizzati:

$$H_i^T H_j = \begin{cases} 1 & \text{se } i = j \\ 0 & \text{se } i \neq j \end{cases} \quad (7.49)$$

3. **Fattorizzazione Spettrale:** Definita la matrice ortogonale degli autovettori $H = [H_1, \dots, H_n] \in \mathbb{R}^{n \times n}$ (con $H^T H = H H^T = I$) e la matrice diagonale $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$:

$$Q = H \Lambda H^T = \sum_{i=1}^n \lambda_i H_i H_i^T \quad (7.50)$$

Ordinamento degli Autovalori

Si adotta la convenzione di ordinamento decrescente:

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \quad (7.51)$$

dove $\lambda_{\max} = \lambda_1$ e $\lambda_{\min} = \lambda_n$.

7.8.3 Caratterizzazione Variazionale: Il Quoziente di Rayleigh

Per qualsiasi vettore non nullo $d \in \mathbb{R}^n \setminus \{0\}$, il **quoziente di Rayleigh** è delimitato dall'autovalore minimo e massimo:

$$\lambda_n \leq \frac{d^T Q d}{\|d\|^2} \leq \lambda_1 \quad (7.52)$$

In particolare, per direzioni unitarie $\|d\| = 1$:

$$\max_{\|d\|=1} d^T Q d = \lambda_1 = H_1^T Q H_1 \quad (7.53)$$

$$\min_{\|d\|=1} d^T Q d = \lambda_n = H_n^T Q H_n \quad (7.54)$$

7.8.4 Tassonomia della Definitezza delle Matrici

Il segno degli autovalori classifica in modo esaustivo il comportamento della forma quadratica:

Classe	Notazione	Spettro	Curvatura $d^T Q d$ ($\forall d \neq 0$)
Definita Positiva	$Q \succ 0$	$\lambda_n > 0$	$d^T Q d > 0$ (strettamente convessa)
Semidefinita Positiva	$Q \succeq 0$	$\lambda_n = 0 \wedge \lambda_1 > 0$	$d^T Q d \geq 0$ (convessa degenere)
Definita Negativa	$Q \prec 0$	$\lambda_1 < 0$	$d^T Q d < 0$ (strettamente concava)
Semidefinita Negativa	$Q \preceq 0$	$\lambda_1 = 0 \wedge \lambda_n < 0$	$d^T Q d \leq 0$ (concava degenere)
Indefinita	$Q \succ \prec 0$	$\lambda_1 > 0 \wedge \lambda_n < 0$	Assume sia valori positivi che negativi

Tabella 7.1: Quadro tassonomico della definitezza per matrici simmetriche reali.

7.9 Tomografia Spettrale nei Quattro Regimi

Selezionando una direzione di campionamento d coincidente con un autovettore normalizzato H_i , la tomografia assume la formulazione analitica pura:

$$\phi_{H_i}(\alpha) = \frac{1}{2}\alpha^2(H_i^T Q H_i) = \frac{1}{2}\alpha^2(H_i^T (\lambda_i H_i)) = \frac{1}{2}\lambda_i \alpha^2 \quad (7.55)$$

Esaminiamo i quattro casi strutturali mediante le configurazioni discusse a lezione.

7.9.1 Caso I: Matrice Definita Positiva ($Q \succ 0$)

Si consideri la matrice simmetrica con autovalori positivi:

$$Q = \begin{bmatrix} 6 & -2 \\ -2 & 6 \end{bmatrix}, \quad H = \frac{\sqrt{2}}{2} \begin{bmatrix} -1 & 1 \\ 1 & 1 \end{bmatrix}, \quad \lambda = \begin{bmatrix} 8 \\ 4 \end{bmatrix} \quad (7.56)$$

- Lungo $d = \pm H_1$: la tomografia è $\phi(\alpha) = 4\alpha^2$ (parabola a massima ripidezza).
- Lungo $d = \pm H_2$: la tomografia è $\phi(\alpha) = 2\alpha^2$ (parabola a minima ripidezza).

- Per qualsiasi direzione intermedia, la curvatura varia con continuità nell'intervallo $[4, 8] > 0$.
- **Ottimizzazione:** La funzione è strettamente convessa. Il minimo globale libero è **unico**:

$$x^* = 0, \quad f^* = 0, \quad \lim_{\|x\| \rightarrow \infty} f(x) = +\infty \quad (7.57)$$

7.9.2 Caso II: Matrice Semidefinita Positiva ($Q \succeq 0$)

Si consideri la configurazione singolare con autovalore nullo:

$$Q = \begin{bmatrix} 4 & -4 \\ -4 & 4 \end{bmatrix}, \quad H = \frac{\sqrt{2}}{2} \begin{bmatrix} -1 & 1 \\ 1 & 1 \end{bmatrix}, \quad \lambda = \begin{bmatrix} 8 \\ 0 \end{bmatrix} \quad (7.58)$$

- L'autovalore $\lambda_2 = 0$ individua il nucleo della matrice: $\ker(Q) = \text{span}(H_2)$.
- Lungo $d = \pm H_1$: tomografia parabolica convessa $\phi(\alpha) = 4\alpha^2$.
- Lungo $d = \pm H_2$: poiché $\lambda_2 = 0$, si ottiene:

$$\phi_{H_2}(\alpha) = 0, \quad \forall \alpha \in \mathbb{R} \quad (7.59)$$

La tomografia è una retta orizzontale identicamente piatta.

- **Ottimizzazione:** Il valore ottimo è $f^* = 0$, ma l'insieme delle soluzioni ottime è **infinito**:

$$X^* = \ker(Q) = \{x \in \mathbb{R}^2 : x = \gamma H_2, \gamma \in \mathbb{R}\} \quad (7.60)$$

L'intero asse identificato dall'autovettore H_2 è costituito da minimi globali equivalenti.

7.9.3 Caso III: Matrice Indefinita ($Q \succ \prec 0$)

Si consideri una matrice con autovalori di segno discorde:

$$Q = \begin{bmatrix} 3 & -5 \\ -5 & 3 \end{bmatrix}, \quad H = \frac{\sqrt{2}}{2} \begin{bmatrix} -1 & 1 \\ 1 & 1 \end{bmatrix}, \quad \lambda = \begin{bmatrix} 8 \\ -2 \end{bmatrix} \quad (7.61)$$

- Lungo $d = \pm H_1$: parabola convessa rivolta verso l'alto ($\phi(\alpha) = 4\alpha^2 \rightarrow +\infty$).

- Lungo $d = \pm H_2$: parabola concava rivolta verso il basso ($\phi(\alpha) = -\alpha^2 \rightarrow -\infty$).
- Lungo le direzioni asintotiche per cui $d^T Q d = 0$, la sezione tomografica degenera a una retta piatta.
- **Ottimizzazione:** La funzione è illimitata sia inferiormente che superiormente:

$$\inf_{x \in \mathbb{R}^n} f(x) = -\infty, \quad \sup_{x \in \mathbb{R}^n} f(x) = +\infty \quad (7.62)$$

Il punto stazionario $x = 0$ non è né un minimo né un massimo, bensì un **punto di sella** (*saddle point*).

7.9.4 Caso IV: Matrice Definita Negativa ($Q \prec 0$)

Si consideri una matrice con autovalori strettamente negativi:

$$Q = \begin{bmatrix} -6 & -2 \\ -2 & -6 \end{bmatrix}, \quad H = \frac{\sqrt{2}}{2} \begin{bmatrix} -1 & 1 \\ 1 & 1 \end{bmatrix}, \quad \lambda = \begin{bmatrix} -4 \\ -8 \end{bmatrix} \quad (7.63)$$

La funzione è strettamente concava:

$$x_{\max}^* = 0, \quad f_{\max}^* = 0, \quad \inf_{x \in \mathbb{R}^n} f(x) = -\infty \quad (7.64)$$

7.10 Geometria degli Insiemi di Livello

7.10.1 Diagonalizzazione e Cambio di Base Ortonormali

Si consideri l'insieme di livello a valore unitario:

$$L(f, 1) = \left\{ x \in \mathbb{R}^n : \frac{1}{2} x^T Q x = 1 \right\} \quad (7.65)$$

Applicando la decomposizione spettrale $Q = H \Lambda H^T$ ed effettuando la rotazione ortonormale di coordinate:

$$y = H^T x \iff x = H y \quad (7.66)$$

l'equazione assume forma canonica diagonale priva di termini misti:

$$\frac{1}{2} (H y)^T Q (H y) = 1 \iff \frac{1}{2} y^T (H^T Q H) y = 1 \iff \frac{1}{2} y^T \Lambda y = 1 \quad (7.67)$$

Espressa esplicitamente in coordinate y :

$$\sum_{i=1}^n \frac{1}{2} \lambda_i y_i^2 = 1 \iff \sum_{i=1}^n \frac{y_i^2}{\frac{2}{\lambda_i}} = 1 \quad (7.68)$$

7.10.2 Teorema dei Semiassi dell'Ellissoide

Teorema 7.10.1 (Orientamento e Lunghezza dei Semiassi). *Sia $Q \succ 0$ definita positiva. L'insieme di livello $L(f, 1)$ è un ellissoide n -dimensionale compatto avente:*

1. Gli **assi di simmetria** allineati esattamente lungo le direzioni degli autovettori ortonormali H_i .
2. La **lunghezza del semiasse** lungo la direzione H_i pari a:

$$\text{semiasse}_i = \sqrt{\frac{2}{\lambda_i}} \quad (7.69)$$

Dimostrazione. Intersecando l'ellissoide con la retta dell'autovettore H_i , ponendo $x = \alpha H_i$:

$$\phi_{H_i}(\alpha) = 1 \iff \frac{1}{2}\lambda_i\alpha^2 = 1 \iff \alpha^2 = \frac{2}{\lambda_i} \iff \alpha = \sqrt{\frac{2}{\lambda_i}} \quad (7.70)$$

che identifica la distanza euclidea del vertice dall'origine lungo l'asse dell'autovettore. $\square$

Relazione Inversa tra Curvatura e Lunghezza dell'Asse

La lunghezza del semiasse è inversamente proporzionale alla radice dell'autovalore:

- λ_i grande $\implies$ alta curvatura / rapida crescita $\implies$ **semiasse corto.**
- λ_i piccolo $\implies$ bassa curvatura / lenta crescita $\implies$ **semiasse lungo.**




Figura 7.3: Geometria dell'insieme di livello $L(f, 1)$ per matrice definita positiva: allineamento con gli autovettori ortonormali H_1, H_2 e proporzionalità inversa dei semiassi.

7.10.3 Degenerazione a Cilindro Ellittico Aperto ($\lambda_i \rightarrow 0$)

Al tendere di un autovalore a zero ($\lambda_i \rightarrow 0^+$):

$$\lim_{\lambda_i \rightarrow 0^+} \text{semiasse}_i = \lim_{\lambda_i \rightarrow 0^+} \sqrt{\frac{2}{\lambda_i}} = +\infty \quad (7.71)$$

In dimensione $n = 3$, con autovalori $\lambda_1 > 0$, $\lambda_2 > 0$ e $\lambda_3 \rightarrow 0^+$, l'ellissoide compatto si allunga progressivamente lungo la direzione dell'autovettore H_3 . Al limite $\lambda_3 = 0$, l'ellissoide si apre all'infinito trasformandosi in un **cilindro ellittico cavo** a sezione costante allineato a H_3 .

7.10.4 Sintesi delle Geometrie di Livello

Regime Spettrale	Geometria del Grafo $\text{gr}(f)$	Insiemi di Livello $L(f, v)$
$Q \succ 0$	Paraboloide convesso	Ellissoidi compatti ($v > 0$)
$Q \succeq 0$ ($\exists \lambda_i = 0$)	Paraboloide degenerare a doccia	Cilindri ellittici aperti (∞)
$Q \succ \prec 0$	Paraboloide iperbolico (Sella)	Iperboloidi a una o due falde
$Q \prec 0$	Paraboloide concavo rovesciato	Ellissoidi compatti ($v < 0$)

Tabella 7.2: Quadro riassuntivo delle geometrie spaziali per forme quadratiche omogenee.

7.11 Ottimizzazione Quadratica: Libera vs Vincolata su Box

7.11.1 Il Caso Non Vincolato: Risoluzione Analitica Immediata

Nel problema non vincolato:

$$\min_{x \in \mathbb{R}^n} \frac{1}{2} x^T Q x \quad (7.72)$$

l'analisi spettrale fornisce una risposta completa ed esaustiva:

- Se $Q \succ 0$: soluzione unica $x^* = 0$, $f^* = 0$.
- Se $Q \succeq 0$: sottospazio di soluzioni ottime $X^* = \ker(Q)$, $f^* = 0$.
- Se esiste almeno un autovalore strettamente negativo ($\lambda_n < 0$): $f^* = -\infty$.

7.11.2 Il Caso Vincolato su Box: Transizione di Complessità e $\mathcal{NP}$ -Durezza

Si consideri ora il problema vincolato su un iper-rettangolo limitato:

$$(P_{\text{box}}) \quad \min \left\{ \frac{1}{2} x^T Q x : x \in X = [x_-, x_+] \subset \mathbb{R}^n \right\} \quad (7.73)$$

dove $[x_-, x_+] = \{x \in \mathbb{R}^n : x_i^- \leq x_i \leq x_i^+, i = 1, \dots, n\}$.

Mentre nel caso scalare univariato ($n = 1$) l'ottimizzazione vincolata su intervallo si risolveva a costo $\mathcal{O}(1)$, in dimensione arbitraria si assiste a una brusca transizione computazionale:

1. **Se $Q \succeq 0$ (Problema Convesso):** Il problema ammette un unico minimo globale (o un insieme convesso compatto di minimi equivalenti). Può essere risolto in tempo polinomiale mediante metodi di punto interno (*interior-point methods*) o algoritmi di gradiente proiettato [4, 5]. Tuttavia, **non esiste alcuna formula analitica in forma chiusa**: la soluzione esige procedure iterative computazionali.
2. **Se Q è Indefinita ($Q \succ \prec 0$) o Definita Negativa ($Q \prec 0$) (Problema Non Convesso):** Lungo le direzioni a curvatura negativa la funzione è concava, respingendo i punti di minimo verso la frontiera estrema della regione ammissibile. I minimi locali e globali si concentrano esclusivamente sui **vertici dell'iper-rettangolo**:

$$x^* \in \text{vertici}(X) = \prod_{i=1}^n \{x_i^-, x_i^+\} \quad (7.74)$$

Poiché l'ipercubo possiede 2^n vertici, la ricerca esaustiva è intrattabile.

Teorema 7.11.1 (Teorema di Complessità per QP su Box [8]). *Il problema di programmazione quadratica vincolato su box (P_{box}) con matrice Q generica non semidefinita positiva è $\mathcal{NP}$ -difficile.*

Il Paradosso Didattico dell'Ottimizzazione

L'introduzione di vincoli apparentemente banali (semplici intervalli coordinata per coordinata $x_i \in [x_i^-, x_i^+]$) su una forma quadratica omogenea trasforma un problema risolubile istantaneamente all'origine in un problema appartenente alla classe dei problemi $\mathcal{NP}$ -difficili.

Capitolo 8

Ottimizzazione Quadratica Non Omogenea, Condizioni di Ottimalità e Metodo del Gradiente

Il presente capitolo estende lo studio dell'ottimizzazione quadratica multivariata al caso generale non omogeneo, introducendo un termine lineare che trasla il centro della funzione rispetto all'origine. Vengono analizzati in dettaglio sia il caso in cui la matrice dell'Hessiano sia non singolare sia il caso singolare, caratterizzando rigorosamente l'esistenza di minimi tramite la decomposizione ortogonale e la compatibilità del sistema gradiente. Si formalizza quindi il ponte concettuale fondamentale tra algebra lineare numerica e ottimizzazione continua, motivando il passaggio dai metodi diretti agli schemi iterativi. Infine, si introduce e si analizza l'algoritmo del Gradiente per Funzioni Quadratiche (GMQ) con ricerca esatta del passo (*exact line search*), dimostrandone le proprietà di convergenza, l'ottimizzazione del costo per iterazione e la dinamica sperimentale a zig-zag al variare del condizionamento spettrale.

8.1 Ottimizzazione Quadratica Non Omogenea: Il Caso Non Singolare

8.1.1 Introduzione e Motivazione

Nel capitolo precedente è stata esaminata in dettaglio la forma quadratica puramente omogenea:

$$f_0(x) = \frac{1}{2}x^T Qx, \quad Q \in \mathbb{R}^{n \times n} \text{ simmetrica.} \quad (8.1)$$

In tale contesto, sotto l'ipotesi di stretta convessità ($Q \succ 0$), il problema ammette un unico punto di minimo globale banale posizionato esattamente nell'origine dello spazio vettoriale:

$$x^* = 0, \quad f_0(x^*) = 0. \quad (8.2)$$

Nelle applicazioni reali della scienza dei dati, dell'ingegneria e dell'apprendimento automatico (in particolare nella regressione ai minimi quadrati lineari e nei modelli di classificazione a margine), il centro di gravità della funzione obiettivo non si trova quasi mai nell'origine. Risulta pertanto essenziale introdurre un termine lineare $q^T x$ che produca una traslazione rigida:

$$f(x) = \frac{1}{2}x^T Qx + q^T x, \quad Q = Q^T \in \mathbb{R}^{n \times n}, \quad q \in \mathbb{R}^n. \quad (8.3)$$

In questa prima trattazione si assume che la matrice Q sia **non singolare**:

$$\det(Q) \neq 0 \iff \lambda_i \neq 0 \quad \forall i \in \{1, \dots, n\} \iff \exists Q^{-1}. \quad (8.4)$$

Non si impone a priori che tutti gli autovalori abbiano lo stesso segno, ma si esclude rigorosamente la presenza di autovalori nulli nello spettro di Q .

8.1.2 Il Principio del Cambio di Coordinate Multivariato

Per minimizzare la funzione non omogenea (8.3), si generalizza a n dimensioni il principio algebrico del completamento del quadrato già impiegato nel caso scalare univariato: **applicare una traslazione rigida dello spazio vettoriale** al fine di riassorbire il termine lineare $q^T x$ e ricondurre la funzione a una forma puramente omogenea in una nuova variabile z .

Si introduce la trasformazione affine di coordinate:

$$z = x - \bar{x} \iff x = z + \bar{x}, \quad (8.5)$$

dove $\bar{x} \in \mathbb{R}^n$ rappresenta il nuovo baricentro (vettore di traslazione) da determinare analiticamente.

8.1.3 Derivazione Algebrica Dettagliata

Sostituendo l'espressione $x = z + \bar{x}$ nella formulazione di $f(x)$, si ottiene:

$$f(x) = f(z + \bar{x}) = \frac{1}{2}(z + \bar{x})^T Q(z + \bar{x}) + q^T(z + \bar{x}). \quad (8.6)$$

Sviluppiamo la forma bilineare sfruttando la linearità e la distributività del prodotto matriciale:

$$\frac{1}{2}(z + \bar{x})^T Q(z + \bar{x}) = \frac{1}{2} \left(z^T Q z + z^T Q \bar{x} + \bar{x}^T Q z + \bar{x}^T Q \bar{x} \right). \quad (8.7)$$

Poiché Q è simmetrica ($Q = Q^T$), i termini misti scalari risultano identici:

$$z^T Q \bar{x} = (z^T Q \bar{x})^T = \bar{x}^T Q^T z = \bar{x}^T Q z. \quad (8.8)$$

Di conseguenza:

$$\frac{1}{2}(z + \bar{x})^T Q(z + \bar{x}) = \frac{1}{2} z^T Q z + \bar{x}^T Q z + \frac{1}{2} \bar{x}^T Q \bar{x}. \quad (8.9)$$

Espandendo analogamente il termine lineare:

$$q^T(z + \bar{x}) = q^T z + q^T \bar{x}. \quad (8.10)$$

Raggruppando i termini rispetto alla variabile z :

$$f(z + \bar{x}) = \frac{1}{2} z^T Q z + (\bar{x}^T Q z + q^T z) + \left(\frac{1}{2} \bar{x}^T Q \bar{x} + q^T \bar{x} \right). \quad (8.11)$$

Coerenza Dimensionale e Raccoglimento

Facendo attenzione alle dimensioni vettoriali: $\bar{x}^T Q$ è un vettore riga $1 \times n$, mentre z è un vettore colonna $n \times 1$. Possiamo raccogliere il vettore z a destra:

$$\bar{x}^T Q z + q^T z = (Q \bar{x})^T z + q^T z = (Q \bar{x} + q)^T z. \quad (8.12)$$

Inoltre, la somma delle quantità indipendenti da z coincide esattamente con il valore assunto dalla funzione originale calcolata nel centro di traslazione $\bar{x}$:

$$\frac{1}{2} \bar{x}^T Q \bar{x} + q^T \bar{x} = f(\bar{x}). \quad (8.13)$$

Riassemblando l'identità fondamentale:

$$f(z + \bar{x}) = \frac{1}{2} z^T Q z + (Q \bar{x} + q)^T z + f(\bar{x}). \quad (8.14)$$

8.1.4 Annullamento del Termine Lineare e Centro di Traslazione

Affinché la funzione espressa nelle coordinate z si riduca a una forma quadratica omogenea pura a meno di una costante additiva, imponiamo che il coefficiente vettoriale del termine lineare in z sia identicamente nullo:

$$Q\bar{x} + q = 0 \iff Q\bar{x} = -q. \quad (8.15)$$

Poiché la matrice Q è non singolare per ipotesi ($\det(Q) \neq 0$), l'inversa Q^{-1} esiste ed è univocamente determinata. Il vettore di traslazione ottimale è dunque:

$$\bar{x} = -Q^{-1}q. \quad (8.16)$$

Definendo la funzione traslata $g(z) := f(z + \bar{x})$, essa assume la struttura canonica:

$$g(z) = \frac{1}{2}z^T Q z + f(\bar{x}), \quad (8.17)$$

dove lo scalare $f(\bar{x}) \in \mathbb{R}$ costituisce un offset verticale fisso che non incide sulla collocazione geometrica dell'argomento di minimo:

$$\arg \min_{z \in \mathbb{R}^n} g(z) = \arg \min_{z \in \mathbb{R}^n} \left\{ \frac{1}{2}z^T Q z \right\}. \quad (8.18)$$

8.1.5 Soluzione Ottima e Valore Ottimo

Dall'analisi delle forme quadratiche omogenee, sappiamo che se la matrice Q è definita positiva ($Q \succ 0$), l'unico punto di minimo globale per la variabile traslata z è l'origine:

$$z^* = 0. \quad (8.19)$$

Tornando al sistema di coordinate originario x mediante la relazione (8.5):

$$x^* = z^* + \bar{x} = 0 + \bar{x} = \bar{x} = -Q^{-1}q. \quad (8.20)$$

Il valore ottimo $f^* := f(x^*)$ si calcola sostituendo x^* in $f(x)$:

$$f^* = f(x^*) = \frac{1}{2}(-Q^{-1}q)^T Q (-Q^{-1}q) + q^T (-Q^{-1}q). \quad (8.21)$$

Sfruttando la simmetria di Q , si ha $(Q^{-1})^T = Q^{-1}$, da cui:

$$f^* = \frac{1}{2}q^T Q^{-1} Q Q^{-1} q - q^T Q^{-1} q = \frac{1}{2}q^T Q^{-1} q - q^T Q^{-1} q = -\frac{1}{2}q^T Q^{-1} q. \quad (8.22)$$

8.1.6 Caratterizzazione al Variare dello Spettro di Q

Al variare dei segni degli autovalori di Q (tutti non nulli), si delineano tre scenari esaustivi:

1. $Q \succ 0$ (**Definita Positiva**):

- Tutti gli autovalori sono strettamente positivi ($\lambda_i > 0$).
- Esiste un **unico minimo globale** $x^* = -Q^{-1}q$.
- Il valore ottimo finito è $f^* = -\frac{1}{2}q^T Q^{-1}q$.
- La funzione è superiormente illimitata: $\sup_{x \in \mathbb{R}^n} f(x) = +\infty$.

2. $Q \prec 0$ (**Definita Negativa**):

- Tutti gli autovalori sono strettamente negativi ($\lambda_i < 0$).
- Esiste un **unico massimo globale** $x_{\max}^* = -Q^{-1}q$.
- La funzione è inferiormente illimitata: $\inf_{x \in \mathbb{R}^n} f(x) = -\infty$.

3. $Q \succ \prec 0$ (**Indefinita**):

- Coesistono autovalori strettamente positivi e strettamente negativi.
- Il punto stazionario $\bar{x} = -Q^{-1}q$ costituisce un **punto di sella**.
- La funzione è simultaneamente illimitata sia inferiormente che superiormente:

$$\inf_{x \in \mathbb{R}^n} f(x) = -\infty, \quad \sup_{x \in \mathbb{R}^n} f(x) = +\infty. \quad (8.23)$$

8.2 Ottimizzazione Quadratica Non Omogenea: Il Caso Singolare

8.2.1 La Singularità di Q e la Rottura della Formula Chiusa

Cosa accade se la matrice simmetrica Q presenta uno o più autovalori nulli?

$$\exists i \in \{1, \dots, n\} : \lambda_i = 0 \iff \det(Q) = 0 \iff Q \text{ è singolare.} \quad (8.24)$$

In questo scenario, la matrice inversa Q^{-1} non esiste e il sistema lineare $Q\bar{x} = -q$ non può essere risolto tramite inversione diretta.

Per analizzare la geometria del problema, partizioniamo l'insieme degli indici dello spettro $I = \{1, 2, \dots, n\}$ in base alla nullità degli autovalori:

$$I^0 = \{i \in I : \lambda_i = 0\}, \quad k = |I^0| > 0, \quad (8.25)$$

$$I^+ = \{i \in I : \lambda_i \neq 0\}, \quad h = |I^+| > 0, \quad k + h = n. \quad (8.26)$$

Gli autovettori ortonormali $\{H_i\}_{i=1}^n$ di Q individuano due sottospazi ortogonali fondamentali di $\mathbb{R}^n$:

1. Il Nucleo (*Kernel* o Spazio Nullo):

$$\ker(Q) = \{v \in \mathbb{R}^n : Qv = 0\} = \text{span}(\{H_i\}_{i \in I^0}), \quad \dim(\ker(Q)) = k. \quad (8.27)$$

2. L'Immagine (*Image* o Spazio Colonna):

$$\begin{aligned} \text{im}(Q) &= \{w \in \mathbb{R}^n : \exists x \in \mathbb{R}^n, Qx = w\} \\ &= \text{span}(\{H_i\}_{i \in I^+}), \quad \dim(\text{im}(Q)) = h. \end{aligned} \quad (8.28)$$

Poiché la base spettrale H è ortonormale, vale il fondamentale **teorema di decomposizione ortogonale**:

$$\mathbb{R}^n = \text{im}(Q) \oplus \ker(Q), \quad \text{con } \text{im}(Q) \perp \ker(Q). \quad (8.29)$$

Ogni vettore dello spazio può essere decomposto in modo unico nella somma di una componente nell'immagine e di una nel nucleo.

$$\text{im}(Q) = \text{span}\{H_i : \lambda_i \neq 0\}$$

(Spazio Colonna)




Figura 8.1: Decomposizione ortogonale dello spazio $\mathbb{R}^n = \text{im}(Q) \oplus \ker(Q)$: il termine lineare q si scompone in modo unico nella somma $q = q^+ + q^0$, con $q^+ \perp q^0$.

8.2.2 Competizione Funzionale: Termine Quadratico vs Termine Lineare

Esaminiamo la tomografia della funzione lungo una direzione appartenente al nucleo $v \in \ker(Q)$:

$$f(v) = \frac{1}{2}v^T Q v + q^T v = \frac{1}{2}v^T(0) + q^T v = q^T v. \quad (8.30)$$

Lungo il sottospazio nullo, la componente quadratica di secondo grado svanisce completamente. La funzione degenera in una **funzione puramente lineare**:

$$\phi_{0,v}(\alpha) = \alpha(q^T v). \quad (8.31)$$

Da questa proprietà scaturisce un dilemma strutturale:

- Una retta non costante su $\mathbb{R}$ ($\alpha \mapsto c\alpha$ con $c \neq 0$) non ammette mai minimo globale, poiché tende a $-\infty$ verso una delle due direzioni.
- L'unico modo per impedire alla funzione di precipitare a $-\infty$ lungo il nucleo è che la retta sia orizzontale, ovvero:

$$q^T v = 0 \quad \forall v \in \ker(Q) \iff q \perp \ker(Q). \quad (8.32)$$

- Essendo $\text{im}(Q) \perp \ker(Q)$, la condizione di ortogonalità al nucleo equivale rigorosamente a:

$$q \in \text{im}(Q). \quad (8.33)$$

8.2.3 Decomposizione di q e Condizioni di Esistenza del Minimo

Decomponiamo il vettore q secondo la partizione ortogonale:

$$q = q^+ + q^0, \quad \text{con } q^+ \in \text{im}(Q), \quad q^0 \in \ker(Q), \quad q^+ \perp q^0. \quad (8.34)$$

Sostituendo tale scomposizione nello sviluppo traslato (8.14):

$$f(z + \bar{x}) = \frac{1}{2}z^T Q z + (Q\bar{x} + q^+ + q^0)^T z + f(\bar{x}). \quad (8.35)$$

Poiché $q^+ \in \text{im}(Q)$, per definizione di immagine di un'applicazione lineare esiste sempre almeno un vettore $\bar{x} \in \mathbb{R}^n$ che soddisfa:

$$Q\bar{x} = -q^+ \iff Q\bar{x} + q^+ = 0. \quad (8.36)$$

Fissando un tale vettore $\bar{x}$, l'espressione si riduce a:

$$f(z + \bar{x}) = \frac{1}{2}z^T Q z + (q^0)^T z + f(\bar{x}). \quad (8.37)$$

Si determinano ora due scenari mutualmente esclusivi ed esaustivi:

Scenario A: $q^0 \neq 0 \iff q \notin \text{im}(Q)$ (**Problema Illimitato Inferiormente**). Se il termine lineare q possiede una componente non nulla lungo il nucleo di Q , scegliamo come direzione $d = q^0 \in \ker(Q)$ e muoviamoci lungo $z = -\alpha q^0$ con $\alpha > 0$:

$$g(-\alpha q^0) = \frac{1}{2}(-\alpha q^0)^T Q(-\alpha q^0) + (q^0)^T(-\alpha q^0) + f(\bar{x}). \quad (8.38)$$

Poiché $Qq^0 = 0$:

$$g(-\alpha q^0) = 0 - \alpha \|q^0\|^2 + f(\bar{x}). \quad (8.39)$$

Facendo crescere indefinitamente il passo $\alpha \rightarrow +\infty$:

$$\lim_{\alpha \rightarrow +\infty} g(-\alpha q^0) = -\infty \implies f^* = -\infty. \quad (8.40)$$

La funzione è illimitata inferiormente e non ammette minimo.

Scenario B: $q^0 = 0 \iff q \in \text{im}(Q)$ (**Esistenza di Infiniti Minimi Globali**). Se la componente nel nucleo è nulla, il sistema lineare:

$$Q\bar{x} = -q \quad (8.41)$$

è **compatibile** per il Teorema di Rouché-Capelli. La funzione traslata (8.37) diventa puramente omogenea:

$$g(z) = \frac{1}{2}z^T Qz + f(\bar{x}). \quad (8.42)$$

Ipotizzando $Q \succeq 0$ (semidefinita positiva):

- Il minimo della parte omogenea $\frac{1}{2}z^T Qz$ è zero, raggiunto per qualsiasi vettore $z \in \ker(Q)$.
- Nello spazio originario, l'insieme delle soluzioni ottime è la varietà affine:

$$X^* = \bar{x} + \ker(Q) = \{x \in \mathbb{R}^n : x = \bar{x} + v, v \in \ker(Q)\}. \quad (8.43)$$

- Tutti i punti dell'insieme X^* condividono **esattamente il medesimo valore obiettivo**:

$$\begin{aligned} f(\bar{x} + v) &= \frac{1}{2}(\bar{x} + v)^T Q(\bar{x} + v) + q^T(\bar{x} + v) \\ &= \frac{1}{2}\bar{x}^T Q\bar{x} + q^T\bar{x} + \underbrace{\bar{x}^T Qv}_{=0} + \underbrace{\frac{1}{2}v^T Qv}_{=0} + \underbrace{q^T v}_{=0} \\ &= f(\bar{x}) \quad (\text{essendo } v \in \ker(Q) \text{ e } q \perp v). \end{aligned} \quad (8.44)$$

Teorema 8.2.1 (Esistenza del Minimo per Funzioni Quadratiche Semidefinite Positive). *Sia $f(x) = \frac{1}{2}x^T Qx + q^T x$ con $Q \succeq 0$. La funzione ammette minimo finito se e solo se il sistema lineare $Qx = -q$ ammette soluzione, ovvero se e solo se $q \in \text{im}(Q)$. In tal caso, l'insieme dei minimi globali è dato dal sottospazio affine $X^* = \bar{x} + \ker(Q)$ e il valore ottimo finito vale $f^* = f(\bar{x}) = -\frac{1}{2}q^T \bar{x}$.*

8.3 La Condizione di Ottimalità e il Legame con l'Algebra Lineare

8.3.1 Il Gradiente della Funzione Quadratica

Calcoliamo il vettore gradiente di $f(x) = \frac{1}{2}x^T Qx + q^T x$ tramite differenziazione vettoriale:

$$\nabla f(x) = Qx + q. \quad (8.45)$$

La condizione di stazionarietà di primo ordine (necessaria per ogni punto di estremo e sufficiente per il minimo globale in presenza di convessità $Q \succeq 0$) impone l'annullamento del gradiente:

$$\nabla f(x^*) = 0 \iff Qx^* + q = 0 \iff Qx^* = -q. \quad (8.46)$$

8.3.2 Il Ponte Concettuale tra Algebra Lineare e Ottimizzazione

Questa equivalenza algebrica costituisce il baricentro concettuale dell'intero corso di Computational Mathematics:

$$\underbrace{Qx = -q}_{\text{Algebra Lineare Numerica}} \iff \underbrace{\min_{x \in \mathbb{R}^n} \left(\frac{1}{2}x^T Qx + q^T x \right)}_{\text{Ottimizzazione Continua}} \quad (8.47)$$

Ogni problema di risoluzione di sistemi lineari simmetrici semidefiniti positivi ammette un'interpretazione variazionale identica come minimizzazione di un'energia quadratica convessa.

8.3.3 Il Limite Computazionale dei Metodi Diretti

Di fronte a tale equivalenza, una domanda sorge spontanea: perché non risolvere sistematicamente il problema tramite i metodi diretti classici dell'algebra lineare numerica (eliminazione gaussiana, fattorizzazione LU o fattorizzazione di Cholesky $Q = LL^T$)?

Le ragioni risiedono nella scalabilità computazionale ed energetica:

1. **Complessità Temporale Asintotica $\mathcal{O}(n^3)$:** La risoluzione esatta diretta di un sistema lineare denso di ordine n richiede:

$$\frac{1}{3}n^3 \text{ FLOPs (Cholesky)} \quad \text{oppure} \quad \frac{2}{3}n^3 \text{ FLOPs (Gauss/LU)}. \quad (8.48)$$

- Per $n \approx 10^2$: $n^3 = 10^6$ FLOPs $\rightarrow$ frazioni di millisecondo.
 - Per $n \approx 10^4$: $n^3 = 10^{12}$ FLOPs $\rightarrow$ svariati secondi o minuti.
 - Per $n \approx 10^9$ (modelli linguistici e deep learning): $n^3 = 10^{27}$ FLOPs $\rightarrow$ infattibile su qualsiasi scala temporale umana.
2. **Complessità di Memoria e Fenomeno del Fill-in:** Anche quando la matrice dei dati Q è altamente sparsa (cioè memorizzabile con soli $\mathcal{O}(n)$ elementi non nulli), i fattori triangolari L calcolati durante l'eliminazione gaussiana subiscono il fenomeno del **fill-in** (generazione di elementi non nulli in posizioni originariamente nulle). Ciò distrugge la sparsità e richiede $\mathcal{O}(n^2)$ parole di memoria, esaurendo istantaneamente la RAM di calcolo.

8.4 Algoritmi Iterativi e il Metodo del Gradiente (GMQ)

8.4.1 La Filosofia degli Algoritmi Iterativi

Per aggirare la barriera asintotica $\mathcal{O}(n^3)$, l'ottimizzazione continua si affida a **schemi iterativi**:

1. Si sceglie un punto di innesco iniziale $x^0 \in \mathbb{R}^n$ (spesso $x^0 = 0$).
2. Si costruisce una mappa di transizione $x^k \rightarrow x^{k+1}$ che genera una sequenza $\{x^k\}_{k=0,1,2,\dots}$.
3. Si richiede che i valori della funzione obiettivo costituiscano una **successione monotona decrescente**:

$$f(x^{k+1}) < f(x^k) \quad \forall k \geq 0. \quad (8.49)$$

Poiché ogni successione reale monotona decrescente e inferiormente limitata converge necessariamente a un limite finito, l'algoritmo convergerà verso l'infimo della funzione.

8.4.2 Il Vettore Residuo come Direzione di Discesa

Assegnata l'iterata corrente x^k , definiamo il **vettore residuo** (che coincide con il gradiente istantaneo):

$$g^k := \nabla f(x^k) = Qx^k + q. \quad (8.50)$$

Se $\|g^k\| \leq \varepsilon$ per una tolleranza numerica prefissata $\varepsilon > 0$, la condizione di stazionarietà è soddisfatta e l'algoritmo si arresta. Se invece $\|g^k\| > \varepsilon$, consideriamo la tomografia lungo la direzione dell'**antigradiente** $d = -g^k$:

$$\phi_{x^k, -g^k}(\alpha) = f(x^k - \alpha g^k) - f(x^k). \quad (8.51)$$

Sviluppiamo esplicitamente l'incremento univariato $\phi(\alpha)$:

$$\begin{aligned} \phi(\alpha) &= \frac{1}{2}(x^k - \alpha g^k)^T Q(x^k - \alpha g^k) + q^T(x^k - \alpha g^k) - \left(\frac{1}{2}(x^k)^T Qx^k + q^T x^k \right) \\ &= \frac{1}{2}\alpha^2 (g^k)^T Qg^k - \alpha (g^k)^T Qx^k - \alpha q^T g^k \\ &= \frac{1}{2}\alpha^2 (g^k)^T Qg^k - \alpha (g^k)^T (Qx^k + q). \end{aligned} \quad (8.52)$$

Riconoscendo che $Qx^k + q = g^k$, otteniamo la fondamentale **formula della tomografia di discesa**:

$$\phi_{x^k, -g^k}(\alpha) = \frac{1}{2}\alpha^2 (g^k)^T Qg^k - \alpha \|g^k\|^2. \quad (8.53)$$

Esaminando i segni dei coefficienti:

- Se $Q \succ 0$, la curvatura è strettamente positiva: $(g^k)^T Qg^k > 0$.
- Essendo $g^k \neq 0$, la pendenza nell'origine è strettamente negativa: $-\|g^k\|^2 < 0$.

Per valori sufficientemente piccoli di $\alpha > 0$, il termine lineare $-\alpha \|g^k\|^2$ domina rigorosamente sulla componente quadratica di ordine superiore $\frac{1}{2}\alpha^2 (g^k)^T Qg^k$. Ne consegue che:

$$\exists \alpha > 0 : \phi_{x^k, -g^k}(\alpha) < 0 \iff f(x^k - \alpha g^k) < f(x^k). \quad (8.54)$$

La Duplice Valenza del Gradiente

Il gradiente istantaneo $g^k = Qx^k + q$ riveste due ruoli complementari:

1. Se non nullo, funge da **certificato di non ottimalità** dello stato corrente.
2. Fornisce una **direzione costruttiva di discesa**: il vettore opposto $-g^k$ garantisce sempre una riduzione locale del valore obiettivo.

8.4.3 Calcolo Esatto del Passo Ottimale (*Exact Line Search*)

Anziché scegliere α euristicamente, possiamo determinare in forma analitica chiusa il valore α_k che massimizza la diminuzione di f , minimizzando la parabola convessa $\phi(\alpha)$ data in (8.53):

$$\min_{\alpha > 0} \left\{ \frac{1}{2} \left((g^k)^T Q g^k \right) \alpha^2 - \left(\|g^k\|^2 \right) \alpha \right\}. \quad (8.55)$$

Derivando rispetto ad α e azzerando la derivata prima:

$$\frac{d\phi}{d\alpha} = \alpha (g^k)^T Q g^k - \|g^k\|^2 = 0 \iff \alpha_k = \frac{\|g^k\|^2}{(g^k)^T Q g^k}. \quad (8.56)$$

Proprietà 8.4.1 (Limitazione Spettrale del Passo). *Dalla proprietà variazionale del quoziente di Rayleigh per matrici simmetriche definite positive:*

$$\lambda_n \leq \frac{(g^k)^T Q g^k}{\|g^k\|^2} \leq \lambda_1. \quad (8.57)$$

Invertendo i rapporti, lo stepsize ottimale α_k risulta rigorosamente limitato dalle quantità spettrali estreme:

$$\frac{1}{\lambda_1} \leq \alpha_k \leq \frac{1}{\lambda_n}. \quad (8.58)$$

8.4.4 Algoritmo GMQ e Ottimizzazione del Costo Computazionale

L'algoritmo del Gradiente per Funzioni Quadratiche (**GMQ**) implementa tale strategia iterativa. A prima vista, sembrerebbe richiedere due prodotti matrice-vettore a ogni passo: il calcolo del nuovo gradiente Qx^{k+1} e la forma quadratica a denominatore $(g^k)^T Q g^k$. Ciascun prodotto costa $\mathcal{O}(n^2)$.

Tuttavia, tramite un elegante accorgimento algebrico, è possibile ridurre il costo a **un solo prodotto matrice-vettore per iterazione**:

1. Si calcola il vettore ausiliario:

$$v^k = Q g^k \quad [\text{costo } \mathcal{O}(n^2)]. \quad (8.59)$$

2. Il denominatore del passo diviene un semplice prodotto scalare:

$$(g^k)^T Q g^k = \langle g^k, v^k \rangle \quad [\text{costo } \mathcal{O}(n)]. \quad (8.60)$$

3. L'aggiornamento della soluzione vale:

$$x^{k+1} = x^k - \alpha_k g^k \quad [\text{costo } \mathcal{O}(n)]. \quad (8.61)$$

4. Il gradiente successivo può essere aggiornato per via ricorsiva:

$$g^{k+1} = Qx^{k+1} + q = Q(x^k - \alpha_k g^k) + q = (Qx^k + q) - \alpha_k Qg^k = g^k - \alpha_k v^k. \quad (8.62)$$

Tale aggiornamento vettoriale richiede unicamente $\mathcal{O}(n)$ FLOPs, eliminando del tutto la necessità di calcolare Qx^{k+1} .

Algorithm 2: Metodo del Gradiente per Funzioni Quadratiche (GMQ Ottimizzato)

Dati: Matrice $Q = Q^T \succeq 0 \in \mathbb{R}^{n \times n}$, vettore $q \in \mathbb{R}^n$, stima iniziale $x^0 \in \mathbb{R}^n$, tolleranza $\varepsilon > 0$, max iterazioni $K_{\max}$

Risultato: Punto stazionario $x^* \approx -Q^{-1}q$

```

1  $x \leftarrow x^0$ 
2  $g \leftarrow Qx + q$ 
3  $k \leftarrow 0$ 
4 while  $\|g\| > \varepsilon$  e  $k < K_{\max}$  do
5    $v \leftarrow Qg$ 
     // Unico prodotto matrice-vettore per iterazione
6    $\alpha \leftarrow \frac{\|g\|^2}{\langle g, v \rangle}$ 
     // Calcolo esatto del passo ottimale
7    $x \leftarrow x - \alpha g$ 
     // Aggiornamento dello stato
8    $g \leftarrow g - \alpha v$ 
     // Aggiornamento ricorsivo del gradiente
9    $k \leftarrow k + 1$ 
10 return  $x$ 
```

Se l'algoritmo converge in $K \ll n$ iterazioni, la complessità complessiva risulta $\mathcal{O}(Kn^2)$ FLOPs, risultando incomparabilmente più vantaggiosa rispetto agli $\mathcal{O}(n^3)$ dei metodi diretti. Nel caso di matrici fortemente sparse con numero costante di elementi non nulli per riga, il costo di ciascun prodotto matrice-vettore scende a $\mathcal{O}(n)$, portando il costo globale a $\mathcal{O}(Kn)$.

8.5 Analisi Sperimentale e Dinamica delle Iterate

8.5.1 Geometria del Passo e Fenomeno dello Zig-Zag

Una proprietà fondamentale della ricerca esatta del passo consiste nella **ortogonalità tra gradienti consecutivi**:

Proposizione 8.5.1 (Ortogonalità dei Gradienti Consecutivi). *In ogni iterazione del metodo GMQ con passo ottimale analitico vale:*

$$\langle g^{k+1}, g^k \rangle = 0 \iff g^{k+1} \perp g^k. \quad (8.63)$$

Dimostrazione. Sfruttando la formula di aggiornamento del gradiente $g^{k+1} = g^k - \alpha_k Qg^k$:

$$\begin{aligned} \langle g^{k+1}, g^k \rangle &= (g^{k+1})^T g^k = (g^k - \alpha_k Qg^k)^T g^k \\ &= \|g^k\|^2 - \alpha_k (g^k)^T Qg^k. \end{aligned} \quad (8.64)$$

Sostituendo l'espressione di $\alpha_k = \frac{\|g^k\|^2}{(g^k)^T Qg^k}$:

$$\langle g^{k+1}, g^k \rangle = \|g^k\|^2 - \frac{\|g^k\|^2}{(g^k)^T Qg^k} (g^k)^T Qg^k = \|g^k\|^2 - \|g^k\|^2 = 0. \quad (8.65)$$

□

Geometricamente, la traiettoria generata dal gradiente compie ad ogni iterazione una **svolta ad angolo retto esatto** (90°).




Figura 8.2: Traiettorie a zig-zag del metodo GMQ su insiemi di livello ellittici: la scelta analitica del passo ottimale impone la perfetta ortogonalità tra direzioni successive ($\langle g^{k+1}, g^k \rangle = 0$), costringendo le iterate a compiere svolte ad angolo retto esatto (90°).

8.5.2 Rassegna dei Casi Sperimentali

L'analisi al calcolatore in dimensione $n = 2$ mette in luce come il comportamento di convergenza dipenda criticamente dal condizionamento spettrale di Q :

Esperimento 1: Matrice Identità ($Q = I$)

Ponendo $Q = I_2$, gli autovalori coincidono: $\lambda_1 = \lambda_2 = 1$. Gli insiemi di livello sono circonferenze perfette. Dato $q = [10, 5]^T$ e punto iniziale $x^0 = [0, 0]^T$:

$$g^0 = Qx^0 + q = q = \begin{bmatrix} 10 \\ 5 \end{bmatrix}, \quad \|g^0\|^2 = 125, \quad (g^0)^T Q g^0 = \|g^0\|^2 = 125. \quad (8.66)$$

Il passo vale esattamente $\alpha_0 = 1$. L'aggiornamento restituisce:

$$x^1 = x^0 - 1 \cdot g^0 = \begin{bmatrix} -10 \\ -5 \end{bmatrix}. \quad (8.67)$$

Al passo successivo $g^1 = Qx^1 + q = [-10, -5]^T + [10, 5]^T = 0$. L'algoritmo converge all'ottimo esatto in **1 sola iterazione**. Geometricamente, per insiemi di livello sferici l'antigradiente punta direttamente verso il centro.

Esperimento 2: Matrice Ben Condizionata ($Q \succ 0$)

Con $Q = \begin{bmatrix} 6 & -2 \\ -2 & 6 \end{bmatrix}$, gli autovalori valgono $\lambda_1 = 8$ e $\lambda_2 = 4$, con rapporto di condizionamento $\kappa(Q) = \lambda_1/\lambda_2 = 2$. Gli insiemi di livello sono ellissi poco eccentriche. L'algoritmo genera la caratteristica traiettoria a zig-zag ortogonale e raggiunge la tolleranza numerica $\|g\| \leq 10^{-6}$ in sole **12 iterazioni**.

Esperimento 3: Matrice Mal Condizionata (Allungamento Spettrale)

Riducendo progressivamente l'autovalore minimo ($\lambda_2 \rightarrow 0^+$), il condizionamento $\kappa(Q)$ diverge verso valori elevati. Gli insiemi di livello si stirano formando strette gole o canali (*ravines*). In questo scenario, il rimbalzo a 90° fa oscillare violentemente le iterate tra le pareti ripide della valle, producendo avanzamenti impercettibili lungo la direzione di fondo gola. Il numero di iterazioni cresce vistosamente, degradando l'efficienza complessiva.

Esperimento 4: Matrice Singolare Compatibile ($Q \succeq 0, q \in \text{im}(Q)$)

Con autovalore nullo ($\lambda_2 = 0$) e termine lineare ortogonale al nucleo, esiste un'intera retta affine di minimi equivalenti. Il metodo GMQ riduce la norma del gradiente fino alla tolleranza prefissata, arrestandosi con successo sul punto ottimo della retta più prossimo alla traiettoria seguita.

Esperimento 5: Matrice Singolare Incompatibile ($Q \succeq 0, q \notin \text{im}(Q)$)

Quando q possiede una componente non nulla lungo il nucleo ($q^0 \neq 0$), la funzione decresce indefinitamente ad ogni passo: $f(x^k) \rightarrow -\infty$. La norma del gradiente non tende mai a zero, bensì rimane confinata attorno a un valore positivo non nullo. L'algoritmo non termina mai spontaneamente, riflettendo l'illimitatezza inferiore del problema analitico.

Dalla Dinamica Sperimentale all'Analisi Teorica di Convergenza

Le evidenze numeriche emerse da questi esperimenti sollevano due quesiti teorici fondamentali:

1. **Quantificazione del tasso di convergenza:** come dipende analiticamente la velocità di contrazione dell'errore ad ogni iterazione dal condizionamento spettrale $\kappa(Q)$?
2. **Complessità iterativa e regime singolare:** quante iterazioni $k(\epsilon)$ sono richieste per raggiungere una tolleranza ϵ , e quale legge governa la convergenza quando $Q \succeq 0$ perde la stretta convessità?

Questi aspetti vengono approfonditi e dimostrati rigorosamente nel Capitolo 9, dove la convergenza lineare viene formalizzata tramite la disuguaglianza di Kantorovich, la complessità asintotica $\mathcal{O}(\kappa(Q) \log(1/\epsilon))$ viene ricavata in forma chiusa e vengono stabiliti il bound sublineare di Bubeck e i limiti inferiori di complessità di Nesterov.

8.6 Quadro Sinottico Comparativo

Regime di Q	Vincolo su q	Soluzioni Ottime X^* e Valore f^*	Comportamento Dinamico GMQ
$Q \succ 0$	Qualsiasi $q \in \mathbb{R}^n$	Unico minimo $x^* = -Q^{-1}q$, $f^* = -\frac{1}{2}q^T Q^{-1}q$	Convergenza lineare a x^* (1 passo se $Q = I$)
$Q \succeq 0$ ($\det Q = 0$)	$q \in \text{im}(Q)$	Infiniti minimi $X^* = \bar{x} + \ker(Q)$, $f^* = -\frac{1}{2}q^T \bar{x}$	Converge a una soluzione ottima in X^*
$Q \succeq 0$ ($\det Q = 0$)	$q \notin \text{im}(Q)$	Nessun minimo ($f^* = -\infty$, illimitata)	Divergenza: $f(x^k) \rightarrow -\infty$, $\ g^k\ \not\rightarrow 0$
$Q \succ \prec 0$	Qualsiasi $q \in \mathbb{R}^n$	Nessun minimo né massimo (Punto di sella)	Non converge (può divergere a seconda di x^0)
$Q \prec 0$	Qualsiasi $q \in \mathbb{R}^n$	Unico massimo, nessun minimo ($f^* = -\infty$)	Diverge a $-\infty$ lungo l'antigradiente

Tabella 8.1: Quadro riassuntivo del comportamento dell'ottimizzazione quadratica non omogenea e del metodo iterativo GMQ.

Capitolo 9

Analisi di Convergenza e Complessità del Metodo del Gradiente per Funzioni Quadratiche

Il presente capitolo approfondisce l'analisi teorica, computazionale e sperimentale del Metodo del Gradiente con ricerca esatta del passo (*Steepest Descent*) applicato alla minimizzazione di funzioni quadratiche multivariate:

$$f(x) = \frac{1}{2}x^T Qx + q^T x, \quad Q = Q^T \in \mathbb{R}^{n \times n}, \quad q \in \mathbb{R}^n. \quad (9.1)$$

La trattazione si articola in due parti logiche. Nella prima parte si analizza il caso strettamente convesso ($Q \succ 0$), formalizzando la convergenza lineare dell'errore assoluto e ricavando il tasso di contrazione teorico mediante la celebre disuguaglianza di Kantorovich, evidenziando il ruolo unificante del numero di condizionamento spettrale $\kappa(Q)$ e l'indipendenza dalla dimensione spaziale n . Nella seconda parte si affronta la teoria della complessità algoritmica, confrontando lo spazio di output e lo spazio di input, classificando i tassi di convergenza asintotici (sublineare, lineare, superlineare e quadratico) e analizzando in dettaglio il caso singolare semidefinito positivo ($Q \succeq 0, \lambda_n = 0$), il bound sublineare di Bubeck $\mathcal{O}(1/\epsilon)$ e la rivelazione computazionale di problemi illimitati inferiormente ($f^* = -\infty$).

9.1 Algoritmi Iterativi e Successioni Minimizzanti

9.1.1 Dalla Risoluzione Diretta agli Schemi Iterativi

Come analizzato nel Capitolo 8 (Sezione 8.3), minimizzare la funzione quadratica $f(x) = \frac{1}{2}x^T Qx + q^T x$ equivale formalmente a risolvere il sistema lineare simmetrico $Qx = -q$. L'approccio classico basato sui metodi diretti esatti dell'algebra lineare numerica (eliminazione gaussiana, fattorizzazione di Cholesky $Q = LL^T$) comporta una complessità computazionale pari a:

$$T_{\text{diretto}}(n) \in \mathcal{O}(n^3) \text{ FLOPs,} \quad (9.2)$$

a cui si aggiunge il fenomeno del *fill-in* (generazione di elementi non nulli nei fattori triangolari) che distrugge la sparsità originaria della matrice e richiede $\mathcal{O}(n^2)$ parole di memoria. Nelle applicazioni su larga scala di Machine Learning e Data Science ($n \geq 10^4$ o $n \geq 10^6$), i metodi diretti sono totalmente impraticabili.

Gli algoritmi iterativi superano questa barriera operando mediante trasformazioni atomiche a basso costo, basate unicamente su prodotti matrice-vettore Qv di costo $\mathcal{O}(n^2)$ (che scende a $\mathcal{O}(n)$ se Q è sparsa), generando una successione di stime $\{x_k\}$ che converge progressivamente alla soluzione ottima.

9.1.2 Definizioni Fondamentali

Definizione 9.1.1 (Algoritmo di Ottimizzazione Iterativo). Un procedimento iterativo è un processo computazionale che, a partire da una stima iniziale $x_0 \in \mathbb{R}^n$ (spesso assunta come $x_0 = 0$), genera una successione infinita di punti (detti iterati):

$$\{x_k\}_{k=0}^{\infty} \subset \mathbb{R}^n \quad \text{secondo una legge di transizione } x_k \rightsquigarrow x_{k+1}, \quad (9.3)$$

con l'obiettivo che la successione converga verso un punto di minimo x^* .

Definizione 9.1.2 (Successione Minimizzante). La sequenza dei valori assunti dalla funzione obiettivo lungo la traiettoria degli iterati, definita da $f_k = f(x_k)$, si dice **successione minimizzante** se soddisfa:

$$\lim_{k \rightarrow \infty} f(x_k) = f^* \equiv \inf_{x \in \mathbb{R}^n} f(x). \quad (9.4)$$

Qualora il problema sia illimitato inferiormente ($f^* = -\infty$), la successione soddisfa $\lim_{k \rightarrow \infty} f(x_k) = -\infty$.

Definizione 9.1.3 (Metodo di Discesa (Algoritmo Monotono)). Un algoritmo iterativo si definisce **strettamente di discesa** (o monotono decrescente) se a ogni passo garantisce una riduzione stretta del valore obiettivo:

$$f(x_{k+1}) < f(x_k) \quad \forall k \text{ tale che } \nabla f(x_k) \neq 0. \quad (9.5)$$

Proposizione 9.1.1 (Esistenza del Limite della Successione Minimizzante). Poiché ogni successione numerica $\{f(x_k)\}$ strettamente monotona decrescente e limitata inferiormente da $f^* > -\infty$ ammette limite finito per il teorema di regolarità delle successioni monotone, la proprietà di discesa assicura che il limite $\lim_{k \rightarrow \infty} f(x_k)$ esista sempre.

Spazio di Output vs. Spazio di Input

La convergenza dei valori nello spazio di output $f(x_k) \rightarrow f^*$ assicura automaticamente che gli iterati convergano a un punto x^* nello spazio di input?

- **Se $Q \succ 0$ (strettamente convessa):** la risposta è affermativa. Gli insiemi di sottolivello $\{x \in \mathbb{R}^n \mid f(x) \leq f(x_0)\}$ sono ellissoidi compatti (chiusi e limitati); pertanto la convergenza del valore implica la convergenza geometrica dell'iterato all'unico minimo globale x^* .
- **Se $Q \succeq 0$ con autovalori nulli o in problemi non convessi:** la risposta è in generale negativa, poiché esistono direzioni a curvatura nulla lungo cui gli iterati possono allontanarsi illimitatamente pur mantenendo un valore di funzione quasi invariato.

9.2 Il Metodo GMQ e Richiamo delle Proprietà Cardine

Nel Capitolo 8 (Sezioni 8.4 e 8.5) è stato formalizzato l'algoritmo del Gradiente per Funzioni Quadratiche (**GMQ**) con ricerca esatta del passo (*exact line search*). Richiamiamo in modo compatto le proprietà analitiche ed operative ivi stabilite, che costituiscono il punto di partenza per l'analisi di convergenza e complessità:

1. **Direzione di massima discesa (*Steepest Descent*):** Assegnato l'iterato $x_k \in \mathbb{R}^n$, l'avanzamento avviene lungo l'opposto del gradiente istantaneo $g_k \equiv \nabla f(x_k) = Qx_k + q$:

$$d_k = -g_k, \quad x_{k+1} = x_k - \alpha_k g_k, \quad \alpha_k > 0. \quad (9.6)$$

2. **Passo ottimale analitico:** Come dimostrato minimizzando l'incremento univariato lungo la retta d'azione, lo stepsize esatto assume la forma chiusa:

$$\alpha_k = \frac{\|g_k\|^2}{g_k^T Q g_k}, \quad \text{con } \frac{1}{\lambda_1} \leq \alpha_k \leq \frac{1}{\lambda_n}, \quad (9.7)$$

dove i limiti inferiore e superiore discendono dalla caratterizzazione variazionale del quoziente di Rayleigh su matrici simmetriche definite positive.

3. **Ortogonalità rigorosa dei gradienti consecutivi:** La scelta esatta del passo impone che il gradiente successivo sia perpendicolare alla direzione di ricerca precedente:

$$\langle g_{k+1}, g_k \rangle = g_{k+1}^T g_k = 0 \quad \forall k \geq 0. \quad (9.8)$$

Tale vincolo geometrico costringe le iterate a compiere svolte ad angolo retto esatto (90°), originando la dinamica a zig-zag illustrata nella Figura 8.2 del Capitolo 8.

4. **Aggiornamento ricorsivo del gradiente a costo $\mathcal{O}(n)$:** L'aggiornamento $x_{k+1} = x_k - \alpha_k g_k$ induce la formula ricorsiva:

$$g_{k+1} = Q(x_k - \alpha_k g_k) + q = g_k - \alpha_k Q g_k = g_k - \alpha_k v_k, \quad \text{con } v_k := Q g_k. \quad (9.9)$$

Precalcolando il vettore ausiliario v_k , sia il denominatore del passo $\langle g_k, v_k \rangle$ sia il gradiente successivo si valutano con soli $\mathcal{O}(n)$ FLOPs, limitando il carico computazionale dell'algoritmo a **un solo prodotto matrice-vettore per iterazione** (Algoritmo 2).

Sulla scorta di queste premesse algebriche ed algoritmiche, procediamo ora all'analisi quantitativa dell'evoluzione dell'errore e della velocità di convergenza.

9.3 Forma Omogenea dell'Errore e Decadimento

9.3.1 Errore Assoluto della Funzione Obiettivo

Sotto l'ipotesi di non singolarità di $Q \succ 0$, l'unico punto di minimo globale x^* soddisfa $Qx^* + q = 0 \iff x^* = -Q^{-1}q$. Valutando la funzione obiettivo in x^* :

$$f(x^*) = \frac{1}{2}(x^*)^T Q x^* + q^T x^* = \frac{1}{2}(x^*)^T Q x^* - (x^*)^T Q x^* = -\frac{1}{2}(x^*)^T Q x^*. \quad (9.10)$$

Definiamo l'**errore assoluto di funzione**:

$$A(x) \equiv f(x) - f(x^*) \geq 0. \quad (9.11)$$

Sottraendo le due espressioni:

$$f(x) - f(x^*) = \frac{1}{2}x^T Qx + q^T x + \frac{1}{2}(x^*)^T Qx^* = \frac{1}{2}x^T Qx - x^T Qx^* + \frac{1}{2}(x^*)^T Qx^*. \quad (9.12)$$

Riconoscendo il quadrato matriciale:

$$A(x) = \frac{1}{2}(x - x^*)^T Q(x - x^*). \quad (9.13)$$

Inoltre, poiché $g(x) = Qx + q = Q(x - x^*)$, possiamo invertire la relazione: $x - x^* = Q^{-1}g(x)$. Sostituendo in (9.13):

$$A(x) = \frac{1}{2}(Q^{-1}g(x))^T Q(Q^{-1}g(x)) = \frac{1}{2}g(x)^T Q^{-1}g(x). \quad (9.14)$$

9.3.2 Derivazione Esatta della Ricorrenza dell'Errore

Valutiamo l'errore $a_{k+1} \equiv A(x_{k+1})$ in funzione dell'errore precedente $a_k \equiv A(x_k)$:

$$\begin{aligned} a_{k+1} &= \frac{1}{2}(x_{k+1} - x^*)^T Q(x_{k+1} - x^*) \\ &= \frac{1}{2}[(x_k - x^*) - \alpha_k g_k]^T Q[(x_k - x^*) - \alpha_k g_k] \\ &= \frac{1}{2}(x_k - x^*)^T Q(x_k - x^*) - \alpha_k g_k^T Q(x_k - x^*) + \frac{1}{2}\alpha_k^2 (g_k^T Q g_k). \end{aligned} \quad (9.15)$$

Poiché $Q(x_k - x^*) = g_k$, il termine lineare misto diventa $g_k^T g_k = \|g_k\|^2$:

$$a_{k+1} = a_k - \alpha_k \|g_k\|^2 + \frac{1}{2}\alpha_k^2 (g_k^T Q g_k). \quad (9.16)$$

Sostituendo il valore del passo ottimo $\alpha_k = \frac{\|g_k\|^2}{g_k^T Q g_k}$:

$$a_{k+1} = a_k - \frac{\|g_k\|^4}{g_k^T Q g_k} + \frac{1}{2} \frac{\|g_k\|^4}{(g_k^T Q g_k)^2} (g_k^T Q g_k) = a_k - \frac{1}{2} \frac{\|g_k\|^4}{g_k^T Q g_k}. \quad (9.17)$$

Raccogliendo a_k ed esprimendolo a denominatore tramite la formula duale (9.14) ($a_k = \frac{1}{2}g_k^T Q^{-1}g_k$):

$$a_{k+1} = a_k \left[1 - \frac{\frac{1}{2} \frac{\|g_k\|^4}{g_k^T Q g_k}}{\frac{1}{2} g_k^T Q^{-1} g_k} \right] = a_k \left[1 - \frac{\|g_k\|^4}{(g_k^T Q g_k)(g_k^T Q^{-1} g_k)} \right]. \quad (9.18)$$

Questa fondamentale identità algebrica esprime il fattore di contrazione esatto dell'errore ad ogni singola iterazione.

9.4 Disuguaglianza di Kantorovich e Tasso di Convergenza Lineare

9.4.1 Numero di Condizionamento Spettrale

Sia $Q \in \mathbb{R}^{n \times n}$ una matrice simmetrica definita positiva ($Q \succ 0$). Indichiamo con $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n > 0$ i suoi autovalori ordinati.

Definizione 9.4.1 (Numero di Condizionamento Spettrale). Il numero di condizionamento spettrale di Q è definito dal rapporto tra l'autovalore massimo e l'autovalore minimo:

$$\kappa(Q) = \frac{\lambda_1}{\lambda_n} = \frac{\lambda_{\max}(Q)}{\lambda_{\min}(Q)} \geq 1. \quad (9.19)$$

9.4.2 Disuguaglianza di Kantorovich

Teorema 9.4.1 (Disuguaglianza di Kantorovich [5]). Sia $Q \in \mathbb{R}^{n \times n}$ una matrice simmetrica definita positiva con autovalore massimo λ_1 e autovalore minimo λ_n . Per ogni vettore non nullo $y \in \mathbb{R}^n \setminus \{0\}$, vale la disuguaglianza:

$$\frac{\|y\|^4}{(y^T Q y)(y^T Q^{-1} y)} \geq \frac{4\lambda_1 \lambda_n}{(\lambda_1 + \lambda_n)^2}. \quad (9.20)$$

9.4.3 Derivazione del Tasso Teorico di Convergenza

Applicando la disuguaglianza di Kantorovich (9.20) al termine sottrattivo della relazione (9.18) con $y = g_k$:

$$1 - \frac{\|g_k\|^4}{(g_k^T Q g_k)(g_k^T Q^{-1} g_k)} \leq 1 - \frac{4\lambda_1 \lambda_n}{(\lambda_1 + \lambda_n)^2}. \quad (9.21)$$

Sviluppando algebricamente il membro di destra:

$$\frac{(\lambda_1 + \lambda_n)^2 - 4\lambda_1 \lambda_n}{(\lambda_1 + \lambda_n)^2} = \frac{(\lambda_1 - \lambda_n)^2}{(\lambda_1 + \lambda_n)^2} = \left(\frac{\lambda_1 - \lambda_n}{\lambda_1 + \lambda_n} \right)^2. \quad (9.22)$$

Dividendo numeratore e denominatore per $\lambda_n > 0$ ed esprimendo la relazione tramite il numero di condizionamento $\kappa = \lambda_1/\lambda_n$:

$$r = \left(\frac{\kappa - 1}{\kappa + 1} \right)^2 < 1. \quad (9.23)$$

Si ottiene così il celebre teorema di convergenza lineare:

Teorema 9.4.2 (Convergenza Lineare Globale del Metodo del Gradiente per $Q \succ 0$). Sia $f(x) = \frac{1}{2}x^T Q x + q^T x$ con $Q \succ 0$. Il metodo del gradiente con passo ottimo soddisfa a ogni iterazione:

$$A(x_{k+1}) \leq \left(\frac{\kappa - 1}{\kappa + 1} \right)^2 A(x_k), \quad (9.24)$$

da cui, applicando ricorsivamente la disuguaglianza per k passi:

$$f(x_k) - f(x^*) \leq \left(\frac{\kappa - 1}{\kappa + 1} \right)^{2k} (f(x_0) - f(x^*)). \quad (9.25)$$

9.4.4 Interpretazione Geometrica dei Casi Limite

- **Caso Ideale Isotropo** ($\kappa = 1$): Tutti gli autovalori sono identici: $\lambda_1 = \lambda_2 = \dots = \lambda_n$. La matrice è proporzionale all'identità ($Q = \lambda I$). Gli insiemi di livello sono ipersfere perfette. Sostituendo $\kappa = 1$:

$$r = \left(\frac{1 - 1}{1 + 1} \right)^2 = 0 \implies A(x_1) \leq 0 \cdot A(x_0) = 0. \quad (9.26)$$

L'algoritmo raggiunge l'ottimo esatto in **1 sola iterazione**, indipendentemente dal punto di partenza x_0 , poiché il gradiente punta esattamente verso il centro della sfera.

- **Caso Mal Condizionato** ($\kappa \gg 1$): L'autovalore massimo è ordini di grandezza superiore al minimo. Gli insiemi di livello sono ellissoidi estremamente schiacciati. Poiché $\kappa \rightarrow \infty$, il fattore $r \rightarrow 1^-$:

$$r = \left(\frac{1 - 1/\kappa}{1 + 1/\kappa} \right)^2 \approx \left(1 - \frac{2}{\kappa} \right)^2 \approx 1 - \frac{4}{\kappa}. \quad (9.27)$$

A ogni iterazione si abbatta solo una minuscola frazione di errore ($\approx 4/\kappa$), costringendo l'algoritmo a una lentissima traiettoria oscillatoria ortogonale lungo le pareti della gola.

9.5 Complessità Computazionale e Tassi di Convergenza

9.5.1 Derivazione del Numero di Iterazioni $\mathcal{O}(\log(1/\epsilon))$

Supponiamo che l'errore contragga linearmente secondo la legge $v_k \leq r^k v_0$, dove $v_0 = A(x_0)$ è l'errore iniziale e $r < 1$. Desideriamo calcolare il numero

di iterazioni k sufficiente a garantire una tolleranza prefissata $\epsilon > 0$:

$$r^k v_0 \leq \epsilon \iff r^k \leq \frac{\epsilon}{v_0}. \quad (9.28)$$

Applicando il logaritmo naturale ad ambo i membri (ricordando che $\ln(r) < 0$ poiché $r < 1$):

$$k \ln(r) \leq \ln\left(\frac{\epsilon}{v_0}\right) \iff k \geq \frac{\ln(\epsilon/v_0)}{\ln(r)} = \frac{\ln(v_0/\epsilon)}{\ln(1/r)}. \quad (9.29)$$

Nel regime mal condizionato ($r \rightarrow 1^-$), possiamo porre $\delta = \frac{1-r}{r} \approx 1 - r \rightarrow 0$. Utilizzando l'approssimazione al primo ordine di Taylor $\ln(1 + \delta) \approx \delta$:

$$\ln\left(\frac{1}{r}\right) = \ln\left(1 + \frac{1-r}{r}\right) \approx \frac{1-r}{r} \implies \frac{1}{\ln(1/r)} \approx \frac{r}{1-r}. \quad (9.30)$$

Sostituendo l'espressione, il numero di iterazioni necessario scala come:

$$k \in \mathcal{O}\left(\frac{r}{1-r} \ln\left(\frac{v_0}{\epsilon}\right)\right) = \mathcal{O}\left(\kappa(Q) \log\left(\frac{1}{\epsilon}\right)\right). \quad (9.31)$$

9.5.2 Tassonomia Comparativa dei Regimi di Convergenza

Definizione 9.5.1 (Ordine e Tasso Asintotico di Convergenza). Sia $\{e_k\}_{k=0}^\infty$ la sequenza degli errori $e_k = f(x_k) - f^* \geq 0$. Si definisce ordine di convergenza $p \geq 1$ e tasso asintotico $r > 0$ il valore del limite:

$$\lim_{k \rightarrow \infty} \frac{e_{k+1}}{e_k^p} = r. \quad (9.32)$$

Regime	Ordine p	Tasso r	Legge di Decadimento	Complessità $k(\epsilon)$
Sublineare (Lento)	$p = 1$	$r = 1$	$e_k \approx \mathcal{O}(1/k)$	$\mathcal{O}(1/\epsilon)$
Sublineare (Nesterov)	$p = 1$	$r = 1$	$e_k \approx \mathcal{O}(1/k^2)$	$\mathcal{O}(1/\sqrt{\epsilon})$
Sublineare (Stocastico)	$p = 1$	$r = 1$	$e_k \approx \mathcal{O}(1/\sqrt{k})$	$\mathcal{O}(1/\epsilon^2)$
Lineare	$p = 1$	$r < 1$	$e_k \leq r^k e_0$	$\mathcal{O}(\log(1/\epsilon))$
Superlineare	$1 < p < 2$	$r > 0$	$e_k \approx r^{k^p}$	Intermedio
Quadratico (Newton)	$p = 2$	$r > 0$	$e_k \approx r^{2^k}$	$\mathcal{O}(\log(\log(1/\epsilon)))$

Tabella 9.1: Tassonomia universale dei regimi di convergenza negli algoritmi di ottimizzazione continua.

- **Sublineare** ($p = 1, r = 1$): il rapporto $e_{k+1}/e_k \rightarrow 1$. L'errore non si riduce geometricamente. Per guadagnare un singolo ordine di grandezza sull'accuratezza (da $\epsilon = 10^{-3}$ a 10^{-4}), il numero di iterazioni viene moltiplicato per 10 (nel caso $1/k$) o per 100 (nel caso stocastico $1/\sqrt{k}$).
- **Lineare** ($p = 1, r < 1$): nel grafico semilogaritmico ($\log(\text{errore})$ vs k), la convergenza corrisponde a una retta decrescente di pendenza costante $\log(r)$. Guadagnare un ordine di grandezza richiede semplicemente un numero costante aggiuntivo di iterazioni ($\approx 2.3/\ln(1/r)$).
- **Quadratico** ($p = 2$): l'errore è proporzionale al quadrato dell'errore precedente ($e_{k+1} \approx r e_k^2$). Il numero di cifre decimali esatte **raddoppia ad ogni iterazione** ($1 \rightarrow 2 \rightarrow 4 \rightarrow 8 \rightarrow 16$). La complessità $\mathcal{O}(\log(\log(1/\epsilon)))$ equivale a una costante pratica (5–8 iterazioni bastano per raggiungere la precisione macchina).

9.6 Il Caso Singolare Semidefinito Positivo ($Q \succeq 0$)

9.6.1 Perdita di Stretta Convessità e Condizionamento Infinito

Quando la matrice Q è singolare ($\det(Q) = 0$), il suo autovalore minimo è identicamente nullo: $\lambda_n = 0$. Il numero di condizionamento teorico diventa infinito:

$$\kappa(Q) = \frac{\lambda_1}{0} = +\infty \implies r = \left(\frac{\infty - 1}{\infty + 1} \right)^2 = 1. \quad (9.33)$$

Il bound di Kantorovich restituisce $A(x_{k+1}) \leq 1 \cdot A(x_k)$, che non fornisce alcuna garanzia di contrazione geometrica dell'errore.

9.6.2 Teorema di Bubeck sulla Convergenza Sublineare

Teorema 9.6.1 (Bound Sublineare per Matrici Singolari [9]). *Sia $f(x) = \frac{1}{2}x^T Q x + q^T x$ con $Q \succeq 0$ simmetrica semidefinita positiva e $q \in \text{im}(Q)$. Applicando il metodo del gradiente con passo ottimo (o con passo costante $\alpha = 1/\lambda_1$), la successione soddisfa:*

$$f(x_k) - f^* \leq \frac{2\lambda_1 \|x_0 - x^*\|^2}{k-1}, \quad \forall k \geq 2, \quad (9.34)$$

dove $\lambda_1 = \lambda_{\max}(Q)$ e x^* è una soluzione ottima.

Idea della Dimostrazione. La convergenza sublineare discende dal fatto che il gradiente è Lipschitziano con costante $L = \lambda_1$. In assenza di forte convessità ($\mu = \lambda_n = 0$), la disuguaglianza di discesa garantisce $f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|g_k\|^2$, ma la norma del gradiente non può più essere legata inferiormente all'errore di funzione tramite un termine quadratico non degenerare, conducendo al decadimento armonico $\mathcal{O}(1/k)$. $\square$

Risolvendo la disequazione (9.34) rispetto al numero di iterazioni affinché $f(x_k) - f^* \leq \epsilon$:

$$\frac{2\lambda_1 \|x_0 - x^*\|^2}{k-1} \leq \epsilon \iff k \geq 1 + \frac{2\lambda_1 \|x_0 - x^*\|^2}{\epsilon} \implies k \in \mathcal{O}\left(\frac{1}{\epsilon}\right). \quad (9.35)$$

La complessità degrada drasticamente da logaritmica ad algebrica inversa:

- Per raggiungere $\epsilon = 10^{-3}$, occorrono $\approx 10^3$ iterazioni;
- Per raggiungere $\epsilon = 10^{-6}$, occorrono oltre 10^6 iterazioni, rendendo il metodo del gradiente convenzionale computazionalmente intrattabile per requisiti di elevata precisione.

9.7 Rivelazione Computazionale di Problemi Illimitati

9.7.1 Condizioni Algebriche di Illimitatezza Inferiore

Come dimostrato nel Capitolo 8 (Sezione 8.2 e Teorema 8.2.1), per una matrice singolare $Q \succeq 0$ lo spazio si decompone come $\mathbb{R}^n = \text{im}(Q) \oplus \text{ker}(Q)$. Scomponendo il termine lineare $q = q^+ + q^0$:

- **Se $q^0 = 0 \iff q \in \text{im}(Q)$:** il sistema $Qx = -q$ è compatibile e ammette la varietà affine di minimi $X^* = x^* + \text{ker}(Q)$, con valore ottimo finito $f^* = -\frac{1}{2}q^T x^*$;
- **Se $q^0 \neq 0 \iff q \notin \text{im}(Q)$:** il sistema è incompatibile. Lungo la direzione $d = -q^0 \in \text{ker}(Q)$, la forma quadratica si annulla ($d^T Q d = 0$) mentre il termine lineare decresce strettamente ($q^T d = -\|q^0\|^2 < 0$), causando la divergenza illimitata $f(x) \rightarrow -\infty$.

Mentre sul piano algebrico tale patologia si riflette nell'incompatibilità del sistema di stazionarietà, sul piano computazionale è indispensabile che l'algoritmo sia in grado di arrestarsi prontamente senza generare cicli infiniti o divergenze numeriche.

9.7.2 Il Controllo Algoritmico nello Script GMQ

Negli schemi numerici ad alta efficienza (come lo script `GMQ.m`), la condizione di illimitatezza inferiore viene intercettata automaticamente controllando il denominatore del passo ottimo:

Listing 9.1: Verifica numerica di illimitatezza nello script GMQ.

```
1 v = Q * g;  
2 den = g' * v; % calcola g_k' * Q * g_k  
3  
4 if den <= 1e-14  
5     fprintf('g' * Q * g = %1.4e ==> unbounded\n', den);  
6     status = 'unbounded';  
7     break;  
8 end
```

Questo semplice controllo intercetta simultaneamente due condizioni patologiche:

1. $g_k^T Q g_k \approx 0$ con $\|g_k\| > 0$: il gradiente appartiene al nucleo $\ker(Q)$. La funzione decresce linearmente senza limite lungo $-g_k$ ($f \rightarrow -\infty$);
2. $g_k^T Q g_k < 0$: la matrice Q è indefinita o definita negativa. Muovendosi lungo l'antigradiente la parabola è concava e precipita a $-\infty$ parabolicamente.

9.8 Limiti Inferiori di Complessità e Prospettive

La lentezza del metodo del gradiente nel caso singolare ($\mathcal{O}(1/\epsilon)$) o mal condizionato ($\mathcal{O}(\kappa \log(1/\epsilon))$) solleva un fondamentale quesito teorico: si tratta di una carenza intrinseca dell'algoritmo o di una difficoltà insita nella classe del problema?

I teoremi sui **limiti inferiori di complessità di Nesterov e Nemirovski** [10] stabiliscono che:

- Per classi generali di funzioni convesse con gradiente Lipschitziano, nessun algoritmo basato esclusivamente su informazioni del primo ordine (valutazioni di f e ∇f) può convergere più velocemente di:

$$f(x_k) - f^* \geq \frac{3L\|x_0 - x^*\|^2}{32(k+1)^2} \implies k \in \Omega\left(\frac{1}{\sqrt{\epsilon}}\right); \quad (9.36)$$

- Per funzioni quadratiche fortemente convesse ($Q \succ 0$), il limite inferiore del primo ordine scala come:

$$k \in \Omega \left(\sqrt{\kappa(Q)} \log \left(\frac{1}{\epsilon} \right) \right). \quad (9.37)$$

Il metodo del gradiente classico presenta invece una dipendenza lineare da $\kappa(Q)$. Questo divario teorico motiva l'introduzione di metodi accelerati del primo ordine dotati di memoria (come il **Metodo del Gradiente Coniugato**), che mantengono un costo per iterazione di un singolo prodotto matrice-vettore $\mathcal{O}(n^2)$, ma abbattano la dipendenza del tasso di convergenza da κ a $\sqrt{\kappa}$.

Bibliografia

- [1] Gilbert Strang. *Linear Algebra and Learning from Data*. Wellesley-Cambridge Press, Wellesley, MA, 2019.
- [2] Lloyd N. Trefethen and David Bau III. *Numerical Linear Algebra*. SIAM, Philadelphia, 1997.
- [3] J. W. Demmel. *Applied Numerical Linear Algebra*. SIAM, Philadelphia, PA, 1997.
- [4] Stephen Boyd and Lieven Vandenberghe. *Convex Optimization*. Cambridge University Press, Cambridge, 2004.
- [5] Jorge Nocedal and Stephen J. Wright. *Numerical Optimization*. Springer, New York, 2nd edition, 2006.
- [6] Mokhtar S. Bazaraa, Hanif D. Sherali, and Chitharanjan M. Shetty. *Nonlinear Programming: Theory and Algorithms*. John Wiley & Sons, Hoboken, NJ, 3rd edition, 2006.
- [7] Gene H. Golub and Charles F. Van Loan. *Matrix Computations*. Johns Hopkins University Press, Baltimore, 4th edition, 2013.
- [8] Etienne de Klerk. The complexity of a simple quadratic program on a box. *Operations Research Letters*, 36(4):468–472, 2008.
- [9] Sébastien Bubeck. Convex optimization: Algorithms and complexity. *Foundations and Trends® in Machine Learning*, 8(3–4):231–357, 2015.
- [10] Yurii Nesterov. *Introductory Lectures on Convex Optimization: A Basic Course*. Springer, Boston, MA, 2004.