

Computational Mathematics for Learning and Data Analysis

Fondamenti Computazionali, Algebra Lineare Numerica e
Ottimizzazione

Anno Accademico 2026/2027

Indice

I	Algebra Lineare Numerica e Analisi dei Dati	1
1	Fondamenti di Algebra Lineare Numerica e Decomposizione SVD	2
1.1	Il Ruolo dell'Algebra Lineare nel Machine Learning e nella Data Analysis	2
1.2	Norme Vettoriali e Matriciali	3
1.2.1	Famiglia delle ℓ_p -Norme	3
1.2.2	Norme Matriciali e Norme Subordinate	4
1.3	Condizionamento e Stabilità Numerica	4
1.3.1	Numero di Condizionamento di un Sistema Lineare	5
1.4	Decomposizione Spettrale (Eigendecomposition)	5
1.4.1	Matrici Semidefinite Positive (SPSD) e Forme Quadratiche	6
1.5	Decomposizione ai Valori Singolari (SVD)	6
1.5.1	Formulazione Esterna e SVD Compatta	7
1.6	Proprietà ed Applicazioni Fondamentali di SVD	8
1.6.1	Miglior Approssimazione di Basso Rango: Teorema di Eckart-Young-Mirsky	8
1.6.2	Pseudoinversa di Moore-Penrose e Minimi Quadrati	8
1.6.3	Connessione tra SVD e Principal Component Analysis (PCA)	9
1.7	Sintesi dei Concetti Chiave	11
II	Ottimizzazione Continua e Machine Learning	12

Parte I

Algebra Lineare Numerica e Analisi dei Dati

Capitolo 1

Fondamenti di Algebra Lineare Numerica e Decomposizione SVD

1.1 Il Ruolo dell'Algebra Lineare nel Machine Learning e nella Data Analysis

Il moderno apprendimento automatico e l'analisi su larga scala dei dati poggiano in larga misura su concetti e strumenti derivati dall'algebra lineare numerica e dall'ottimizzazione continua [1, 2]. I dati del mondo reale (immagini, testi, serie temporali, grafi o segnali sensoriali) vengono sistematicamente codificati sotto forma di vettori e matrici numeriche:

- **Matrice dei dati (Design Matrix):** Sia $\mathcal{D} = \{\mathbf{x}_1, \dots, \mathbf{x}_n\}$ un insieme di n campioni statistici, ciascuno caratterizzato da d feature numeriche. L'intera collezione si rappresenta come matrice $X \in \mathbb{R}^{n \times d}$:

$$X = \begin{bmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \vdots \\ \mathbf{x}_n^T \end{bmatrix} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1d} \\ x_{21} & x_{22} & \cdots & x_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{nd} \end{bmatrix}, \quad (1.1)$$

dove le righe corrispondono alle osservazioni e le colonne alle variabili misurate.

- **Matrice di Gram e Matrice di Covarianza:** Le relazioni lineari tra coppie di osservazioni o coppie di variabili si quantificano mediante prodotti matriciali: la matrice di Gram $G = XX^T \in \mathbb{R}^{n \times n}$ quantifica le

similarità tra campioni, mentre la matrice di covarianza campionaria non centrata $\Sigma_X = \frac{1}{n}X^T X \in \mathbb{R}^{d \times d}$ misura la varianza e covarianza congiunta tra le feature.

A differenza dell'algebra lineare simbolica o teorica, l'algebra lineare *computazionale* o *numerica* deve affrontare due vincoli ineludibili: il costo computazionale asintotico delle operazioni su larga scala e la propagazione degli errori dovuti all'aritmetica di macchina a precisione finita (standard IEEE 754) [3].

1.2 Norme Vettoriali e Matriciali

La quantificazione della magnitudine di vettori e matrici, nonché la misura di errore e distanza tra predizioni ed etichette reali, richiede la definizione assiomatica di **norma**.

Definizione 1.2.1 (Norma Vettoriale). Una funzione $\|\cdot\| : \mathbb{R}^d \rightarrow \mathbb{R}$ si definisce **norma** su $\mathbb{R}^d$ se soddisfa le seguenti tre proprietà per ogni $\mathbf{x}, \mathbf{y} \in \mathbb{R}^d$ e $\alpha \in \mathbb{R}$:

1. **Non-negatività e positività:** $\|\mathbf{x}\| \geq 0$, con $\|\mathbf{x}\| = 0 \iff \mathbf{x} = \mathbf{0}$;
2. **Omogeneità assoluta:** $\|\alpha\mathbf{x}\| = |\alpha| \|\mathbf{x}\|$;
3. **Disuguaglianza triangolare:** $\|\mathbf{x} + \mathbf{y}\| \leq \|\mathbf{x}\| + \|\mathbf{y}\|$.

1.2.1 Famiglia delle ℓ_p -Norme

Le norme vettoriali più utilizzate nell'analisi dei dati appartengono alla famiglia delle norme ℓ_p (con $p \geq 1$):

$$\|\mathbf{x}\|_p = \left(\sum_{i=1}^d |x_i|^p \right)^{1/p}. \quad (1.2)$$

I tre casi fondamentali sono:

1. **Norma di Manhattan (ℓ_1):** $\|\mathbf{x}\|_1 = \sum_{i=1}^d |x_i|$. Fondamentale per indurre sparsità nei modelli lineari (regolarizzazione Lasso).
2. **Norma Euclidea (ℓ_2):** $\|\mathbf{x}\|_2 = \sqrt{\sum_{i=1}^d x_i^2} = \sqrt{\mathbf{x}^T \mathbf{x}}$. Rappresenta la distanza geometrica ordinaria ed è invariante per rotazioni ortogonali.

3. **Norma di Chebyshev** (ℓ_∞): $\|\mathbf{x}\|_\infty = \max_{1 \leq i \leq d} |x_i|$. Misura lo scostamento massimo su singola coordinata.

Proprietà 1.2.1 (Equivalenza Topologica delle Norme). *In uno spazio vettoriale a dimensione finita $\mathbb{R}^d$, tutte le norme sono topologicamente equivalenti: per ogni coppia di norme $\|\cdot\|_a$ e $\|\cdot\|_b$, esistono costanti positive $c_1, c_2 > 0$ tali che:*

$$c_1 \|\mathbf{x}\|_b \leq \|\mathbf{x}\|_a \leq c_2 \|\mathbf{x}\|_b \quad \forall \mathbf{x} \in \mathbb{R}^d. \quad (1.3)$$

1.2.2 Norme Matriciali e Norme Subordinate

Per quantificare la dimensione di una trasformazione lineare $A \in \mathbb{R}^{m \times n}$ si utilizzano norme matriciali. Si distinguono due grandi categorie:

Norma di Frobenius. Estende direttamente la norma Euclidea trattando la matrice come un lungo vettore di dimensione $m \cdot n$:

$$\|A\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n a_{ij}^2} = \sqrt{\text{Tr}(A^T A)}. \quad (1.4)$$

Norme Indotte (o Subordinate). Misurano la massima amplificazione che la matrice A può imprimere a un vettore non nullo rispetto a una norma vettoriale data:

$$\|A\|_p = \sup_{\mathbf{x} \neq \mathbf{0}} \frac{\|A\mathbf{x}\|_p}{\|\mathbf{x}\|_p} = \max_{\|\mathbf{x}\|_p=1} \|A\mathbf{x}\|_p. \quad (1.5)$$

Le espressioni computazionali notevoli sono:

- $\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}|$ (massima somma assoluta sulle colonne);
- $\|A\|_\infty = \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}|$ (massima somma assoluta sulle righe);
- $\|A\|_2 = \sigma_{\max}(A) = \sqrt{\lambda_{\max}(A^T A)}$ (**norma spettrale**, pari al massimo valore singolare di A).

Ogni norma indotta è **sub-moltiplicativa**: $\|AB\| \leq \|A\| \|B\|$.

1.3 Condizionamento e Stabilità Numerica

Un problema computazionale $y = f(x)$ si definisce **ben condizionato** se a piccole perturbazioni sui dati di ingresso x corrispondono piccole variazioni sul risultato y . Al contrario, un problema si definisce **mal condizionato** (*ill-conditioned*) se minime perturbazioni nei dati producono oscillazioni macroscopicamente ampie nella soluzione [2].

1.3.1 Numero di Condizionamento di un Sistema Lineare

Si consideri il sistema lineare quadrato $A\mathbf{x} = \mathbf{b}$, con $A \in \mathbb{R}^{n \times n}$ non singolare e $\mathbf{b} \neq \mathbf{0}$. Si supponga che il termine noto sia affetto da un rumore di misura $\delta\mathbf{b}$, generando una variazione $\delta\mathbf{x}$ nella soluzione:

$$A(\mathbf{x} + \delta\mathbf{x}) = \mathbf{b} + \delta\mathbf{b} \implies A\delta\mathbf{x} = \delta\mathbf{b} \implies \delta\mathbf{x} = A^{-1}\delta\mathbf{b}. \quad (1.6)$$

Dalla sub-moltiplicatività della norma segue:

$$\|\delta\mathbf{x}\| \leq \|A^{-1}\| \|\delta\mathbf{b}\| \quad \text{e} \quad \|\mathbf{b}\| \leq \|A\| \|\mathbf{x}\| \implies \frac{1}{\|\mathbf{x}\|} \leq \frac{\|A\|}{\|\mathbf{b}\|}. \quad (1.7)$$

Moltiplicando le due disuguaglianze membro a membro si ottiene la relazione fondamentale:

$$\frac{\|\delta\mathbf{x}\|}{\|\mathbf{x}\|} \leq (\|A\| \|A^{-1}\|) \frac{\|\delta\mathbf{b}\|}{\|\mathbf{b}\|}. \quad (1.8)$$

Definizione 1.3.1 (Numero di Condizionamento). Il **numero di condizionamento** di una matrice quadrata invertibile $A \in \mathbb{R}^{n \times n}$ associato alla norma $\|\cdot\|$ è il valore:

$$\kappa(A) = \|A\| \|A^{-1}\|. \quad (1.9)$$

Nel caso della norma spettrale $\|\cdot\|_2$, indicando con $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_n > 0$ i valori singolari di A :

$$\kappa_2(A) = \|A\|_2 \|A^{-1}\|_2 = \frac{\sigma_{\max}(A)}{\sigma_{\min}(A)} = \frac{\sigma_1}{\sigma_n} \geq 1. \quad (1.10)$$

Significato Computazionale di $\kappa(A)$

In aritmetica floating-point a doppia precisione (con precisione di macchina $\epsilon_{\text{mach}} \approx 10^{-16}$), la risoluzione di un sistema con $\kappa(A) \approx 10^k$ comporta tipicamente la perdita di circa k cifre decimali significative. Se $\kappa(A) \geq 10^{16}$, la matrice è considerata numericamente singolare.

1.4 Decomposizione Spettrale (Eigendecomposition)

Sia $A \in \mathbb{R}^{n \times n}$ una matrice quadrata. Uno scalare $\lambda \in \mathbb{C}$ è un **autovalore** di A con corrispondente **autovettore** non nullo $\mathbf{v} \neq \mathbf{0}$ se soddisfa l'equazione agli autovalori:

$$A\mathbf{v} = \lambda\mathbf{v}. \quad (1.11)$$

Teorema 1.4.1 (Teorema Spettrale per Matrici Simmetriche Reali). *Sia $A \in \mathbb{R}^{n \times n}$ una matrice simmetrica reale ($A = A^T$). Allora:*

1. *Tutti gli autovalori di A sono reali: $\lambda_1, \dots, \lambda_n \in \mathbb{R}$.*
2. *Gli autovettori associati ad autovalori distinti sono mutuamente ortogonali.*
3. *Esiste una matrice ortogonale $Q \in \mathbb{R}^{n \times n}$ ($Q^T Q = Q Q^T = I_n$) le cui colonne sono autovettori normalizzati di A , tale che:*

$$A = Q \Lambda Q^T = \sum_{i=1}^n \lambda_i \mathbf{q}_i \mathbf{q}_i^T, \quad (1.12)$$

dove $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$.

1.4.1 Matrici Semidefinite Positive (SPSD) e Forme Quadratiche

Una matrice simmetrica $A \in \mathbb{R}^{n \times n}$ si definisce:

- **Semidefinita positiva** ($A \succeq 0$) se $\mathbf{x}^T A \mathbf{x} \geq 0$ per ogni $\mathbf{x} \in \mathbb{R}^n \iff \lambda_i(A) \geq 0$ per tutti gli $i = 1, \dots, n$.
- **Definita positiva** ($A \succ 0$) se $\mathbf{x}^T A \mathbf{x} > 0$ per ogni $\mathbf{x} \neq \mathbf{0} \iff \lambda_i(A) > 0$ per tutti gli $i = 1, \dots, n$.

Esempio 1.4.1 (La Matrice di Covarianza è sempre Semidefinita Positiva). Sia $X \in \mathbb{R}^{n \times d}$ una matrice centrata con media campionaria nulla. La matrice di covarianza $C = \frac{1}{n} X^T X$ è simmetrica e per ogni vettore $\mathbf{w} \in \mathbb{R}^d$ vale:

$$\mathbf{w}^T C \mathbf{w} = \mathbf{w}^T \left(\frac{1}{n} X^T X \right) \mathbf{w} = \frac{1}{n} (X \mathbf{w})^T (X \mathbf{w}) = \frac{1}{n} \|X \mathbf{w}\|_2^2 \geq 0. \quad (1.13)$$

Dunque tutti gli autovalori di C sono reali e non negativi, confermando che $C \succeq 0$.

1.5 Decomposizione ai Valori Singolari (SVD)

La decomposizione spettrale è applicabile esclusivamente a matrici quadrate simmetriche. La **Singular Value Decomposition (SVD)** costituisce la generalizzazione fondamentale dell'algebra lineare a matrici rettangolari arbitrarie $A \in \mathbb{R}^{m \times n}$ [2, 1].

Teorema 1.5.1 (Esistenza della SVD). *Data una qualsiasi matrice reale $A \in \mathbb{R}^{m \times n}$ di rango $r \leq \min(m, n)$, esistono due matrici ortogonali $U \in \mathbb{R}^{m \times m}$ e $V \in \mathbb{R}^{n \times n}$ e una matrice pseudo-diagonale $\Sigma \in \mathbb{R}^{m \times n}$ tali che:*

$$A = U\Sigma V^T, \quad (1.14)$$

dove Σ presenta sulla diagonale principale i valori singolari disposti in ordine decrescente:

$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > \sigma_{r+1} = \dots = \sigma_{\min(m,n)} = 0. \quad (1.15)$$




Figura 1.1: Rappresentazione a blocchi dimensionali della Decomposizione ai Valori Singolari (SVD completa).

1.5.1 Formulazione Esterna e SVD Compatta

La matrice A può essere espressa come somma di r matrici di rango 1:

$$A = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^T, \quad (1.16)$$

dove:

- $\mathbf{u}_i \in \mathbb{R}^m$ è la i -esima colonna di U (**vettore singolare sinistro**), autovettore di AA^T con autovalore $\lambda_i = \sigma_i^2$;
- $\mathbf{v}_i \in \mathbb{R}^n$ è la i -esima colonna di V (**vettore singolare destro**), autovettore di $A^T A$ con autovalore $\lambda_i = \sigma_i^2$;
- $\sigma_i = \sqrt{\lambda_i(A^T A)} = \sqrt{\lambda_i(AA^T)}$ è l' i -esimo valore singolare.

Nella pratica computazionale, se $m \gg n$, si adotta la **thin SVD** (o SVD economica), trattenendo unicamente le prime n colonne di U e la sottomatrice quadrata $\Sigma_n \in \mathbb{R}^{n \times n}$, con risparmio lineare di memoria $\mathcal{O}(mn)$ anziché $\mathcal{O}(m^2)$.

1.6 Proprietà ed Applicazioni Fondamentali di SVD

1.6.1 Miglior Approssimazione di Basso Rango: Teorema di Eckart-Young-Mirsky

Nel data mining, nella compressione di segnali e nella riduzione della dimensionalità, si ricerca frequentemente una matrice $\hat{A}_k$ di rango ristretto $k < r$ che approssimi al meglio la matrice originaria A .

Teorema 1.6.1 (Teorema di Eckart-Young-Mirsky). *Sia $A = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^T$ la SVD di $A \in \mathbb{R}^{m \times n}$. Per qualsiasi intero $1 \leq k < r$, la matrice di rango al più k definita dalla SVD troncata:*

$$A_k = \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^T = U_k \Sigma_k V_k^T \quad (1.17)$$

è la soluzione ottima del problema di miglior approssimazione sia in norma spettrale sia in norma di Frobenius:

$$A_k = \arg \min_{B \in \mathbb{R}^{m \times n}, \text{rank}(B) \leq k} \|A - B\|_2 = \arg \min_{B \in \mathbb{R}^{m \times n}, \text{rank}(B) \leq k} \|A - B\|_F. \quad (1.18)$$

Inoltre, gli errori minimi ottimali valgono esattamente:

$$\|A - A_k\|_2 = \sigma_{k+1}, \quad (1.19)$$

$$\|A - A_k\|_F = \sqrt{\sum_{j=k+1}^r \sigma_j^2}. \quad (1.20)$$

1.6.2 Pseudoinversa di Moore-Penrose e Minimi Quadrati

Quando una matrice rettangolare $A \in \mathbb{R}^{m \times n}$ non è invertibile ($m \neq n$ o rango carente), la SVD fornisce lo strumento naturale per definire la **pseudoinversa di Moore-Penrose** $A^\dagger \in \mathbb{R}^{n \times m}$:

$$A^\dagger = V \Sigma^\dagger U^T = \sum_{i=1}^r \frac{1}{\sigma_i} \mathbf{v}_i \mathbf{u}_i^T, \quad (1.21)$$

dove $\Sigma^\dagger$ si ottiene trasponendo Σ e invertendo i soli elementi diagonali non nulli $\sigma_i > 0$.

Proprietà 1.6.1 (Proprietà di Minimi Quadrati). *Dato il problema dei minimi quadrati lineari $\min_{\mathbf{x} \in \mathbb{R}^n} \|\mathbf{A}\mathbf{x} - \mathbf{b}\|_2$, il vettore*

$$\mathbf{x}^* = \mathbf{A}^\dagger \mathbf{b} \quad (1.22)$$

è l'unica soluzione a norma minima $\|\mathbf{x}^\|_2$ tra tutte le soluzioni che minimizzano il residuo quadratico.*

1.6.3 Connessione tra SVD e Principal Component Analysis (PCA)

Sia $X \in \mathbb{R}^{n \times d}$ una matrice di n dati centrati per colonna (media campionaria $\boldsymbol{\mu} = \mathbf{0}$). La matrice di covarianza campionaria vale:

$$C = \frac{1}{n-1} X^T X. \quad (1.23)$$

Calcolando la SVD di X : $X = U\Sigma V^T$, si ricava:

$$C = \frac{1}{n-1} (V\Sigma U^T)(U\Sigma V^T) = \frac{1}{n-1} V\Sigma^2 V^T = V \left(\frac{\Sigma^2}{n-1} \right) V^T. \quad (1.24)$$

Da questa uguaglianza discendono immediatamente tre conclusioni cruciali:

1. I vettori singolari destri $\mathbf{v}_i$ di X (colonne di V) sono esattamente gli **autovettori della matrice di covarianza** (direzioni principali della PCA).
2. La varianza campionaria spiegata dalla i -esima componente principale è legata al valore singolare dalla relazione $\lambda_i = \frac{\sigma_i^2}{n-1}$.
3. Le proiezioni dei dati (coordinate dei punteggi / *scores*) nello spazio ridotto a k dimensioni si calcolano senza mai costruire esplicitamente la matrice $C \in \mathbb{R}^{d \times d}$:

$$\mathbf{Z}_k = X\mathbf{V}_k = (U_k \Sigma_k V_k^T) \mathbf{V}_k = U_k \Sigma_k. \quad (1.25)$$

Listing 1.1: Calcolo compatto di Truncated SVD e PCA con NumPy.

```

1 import numpy as np
2
3 def compute_svd_pca(X: np.ndarray, k: int):
4     """
```

```

5     Calcola la proiezione PCA a k dimensioni sfruttando
      la SVD.
6     X: matrice dei dati (n_samples, n_features)
7     k: numero di componenti principali da trattenere
8     """
9     # 1. Centratura dei dati (media zero su ogni colonna
      )
10    X_centered = X - np.mean(X, axis=0)
11    n = X.shape[0]
12
13    # 2. Decomposizione SVD economica
14    U, s, Vt = np.linalg.svd(X_centered, full_matrices=
      False)
15
16    # 3. Troncamento ai primi k fattori
17    Uk = U[:, :k]
18    sk = s[:k]
19    Vk = Vt[:k, :].T
20
21    # 4. Calcolo delle proiezioni (scores) e varianza
      spiegata
22    scores = Uk * sk # equivalente a X_centered @ Vk
23    explained_variance = (sk ** 2) / (n - 1)
24    explained_variance_ratio = explained_variance / np.
      sum((s ** 2) / (n - 1))
25
26    return scores, Vk, explained_variance_ratio

```

1.7 Sintesi dei Concetti Chiave

Strumento Matematico	Definizione Operativa	Impatto nella Data Analysis / ML
Norma ℓ_2 e $\ A\ _F$	Radice della somma dei quadrati	Ottimizzazione least squares, misura di errore MSE.
Norma ℓ_1	Somma dei valori assoluti	Sparsità, feature selection robusta (Lasso).
Numero di condizionamento κ	$\sigma_{\max}/\sigma_{\min}$	Stabilità numerica, amplificazione del rumore nei dati.
Eigendecomposition	$A = Q\Lambda Q^T$ (solo per $A = A^T$)	Analisi spettrale, forme quadratiche, kernel positivi.
SVD completa	$A = U\Sigma V^T$ (qualsiasi rettangolare)	Decomposizione geometrica universale dei dati.
Eckart-Young-Mirsky	$A_k = \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^T$	Compressione ottimale a basso rango, filtro di rumore.
SVD per PCA	$Z_k = U_k \Sigma_k$	Riduzione dimensionale senza formare la matrice $X^T X$.

Tabella 1.1: Quadro riassuntivo dei concetti di algebra lineare numerica e SVD introdotti nel capitolo.

Parte II

Ottimizzazione Continua e Machine Learning

Bibliografia

- [1] Gilbert Strang. *Linear Algebra and Learning from Data*. Wellesley-Cambridge Press, Wellesley, MA, 2019.
- [2] Gene H. Golub and Charles F. Van Loan. *Matrix Computations*. Johns Hopkins University Press, Baltimore, 4th edition, 2013.
- [3] Lloyd N. Trefethen and David Bau III. *Numerical Linear Algebra*. SIAM, Philadelphia, 1997.