

Appunti di Data Mining

Anno Accademico 2026/2027

Indice

1	Introduzione al Data Mining e Processo KDD	1
1.1	Definizione e Motivazioni Fondamentali	1
1.2	Tipologie di Origine del Dato: Primari e Secondari	3
1.3	Il Processo KDD (Knowledge Discovery in Databases)	3
1.4	Tassonomia dei Compiti di Data Mining	5
1.5	Sfide Metodologiche e Computazionali nel Data Mining	10
2	Data Understanding ed Esplorazione dei Dati	11
2.1	Obiettivi del Data Understanding	11
2.2	Tipologie di Dataset	12
2.3	Oggetti e Attributi	13
2.4	Qualità del Dato (Data Quality)	15
2.5	Statistica Descrittiva ed Esplorazione Univariata	16
2.6	Tecniche di Visualizzazione Multivariata	23
2.7	Analisi di Correlazione e Associazione	28
2.8	Gestione di Outlier e Valori Mancanti	36
2.9	Checklist Operativa di Data Understanding	40
3	Data Preparation e Data Cleaning	41
3.1	Obiettivi della Data Preparation	41
3.2	Aggregazione dei Dati	43
3.3	Riduzione dei Dati tramite Campionamento (Sampling)	44
3.4	Riduzione di Dimensionalità	46
3.5	Selezione delle Feature (Feature Subset Selection)	48
3.6	Creazione di Feature (Feature Creation)	50
3.7	Principal Component Analysis (PCA)	50
3.8	Gestione dei Valori Mancanti e Anomali (Cleaning)	55
3.9	Discretizzazione e Binarizzazione	59
3.10	Trasformazione degli Attributi e Stabilizzazione della Varianza	65

4	Similarità dei Dati e Introduzione all'Analisi dei Cluster	71
4.1	Prossimità: Similarità e Dissimilarità	71
4.2	Distanza Euclidea e Proprietà delle Metriche	72
4.3	Distanza di Minkowski: Una Famiglia di Metriche	73
4.4	Similarità tra Dati Binari	74
4.5	Similarità del Coseno	76
4.6	Correlazione	77
4.7	Misure Basate sull'Informazione: Entropia e Mutua Informazione	77
4.8	Che cos'è l'Analisi dei Cluster?	79
4.9	Ambiguità e Soggettività del Concetto di Cluster	80
4.10	Tassonomia dei Clustering	81
4.11	Tipologie di Cluster	82
4.12	Caratteristiche dei Dati di Input e Algoritmi di Clustering . .	84

Capitolo 1

Introduzione al Data Mining e Processo KDD

1.1 Definizione e Motivazioni Fondamentali

Il costante progresso tecnologico nella generazione e memorizzazione dei dati ha portato a una crescita esponenziale delle informazioni disponibili, sia nel contesto commerciale sia in quello scientifico. Il paradigma moderno della raccolta dati si riassume spesso nel principio di raccogliere qualsiasi dato possibile, ovunque e in qualsiasi momento, nell'aspettativa che tali dati possano acquisire valore non soltanto per lo scopo originario per cui sono stati raccolti, ma anche per scopi secondari non previsti inizialmente.

Definizione 1.1.1 (Data Mining). Il **Data Mining** è l'applicazione di tecniche ed algoritmi efficienti all'analisi di collezioni di dati di grandi dimensioni, finalizzata all'estrazione di pattern validi, inediti, potenzialmente utili e interpretabili (conoscenza nascosta o *hidden knowledge*).

Il Data Mining non consiste nella semplice esecuzione di query su basi di dati tradizionali (ad esempio, il recupero del saldo medio tramite SQL), bensì nella scoperta automatica o semi-automatica di strutture, dipendenze o regolarità non banali nei dati.

1.1.1 Prospettive Applicative

Le motivazioni alla base dell'adozione delle tecniche di Data Mining possono essere distinte principalmente secondo due punti di vista:

- **Punto di vista commerciale:** Le aziende gestiscono volumi enormi di dati (*data warehousing*): dati web (Yahoo, Facebook), transazioni

di e-commerce e vendite al dettaglio (Amazon), registrazioni di carte di credito e conti correnti bancari. A fronte di una potenza di calcolo sempre più economica e accessibile, la pressione competitiva richiede di estrarre valore da tali moli di dati per migliorare e personalizzare i servizi offerti (ad esempio nel *Customer Relationship Management - CRM*).

- **Punto di vista scientifico e sociale:** In discipline quali l'astronomia (*Sky Survey Data*), l'osservazione della Terra (i satelliti del sistema NASA EOSDIS raccolgono petabyte di dati ambientali all'anno), la genomica (espressione genica, proteomica), la neuroimaging (fMRI) e le simulazioni numeriche complesse, i dati vengono generati a velocità tali da rendere impossibile l'analisi manuale. Il Data Mining supporta gli scienziati nell'analisi automatica e nella formulazione guidata di nuove ipotesi.

I Big Data rappresentano a tutti gli effetti un proxy della vita sociale (comportamenti d'acquisto, stili di vita, opinioni, reti di relazioni, mobilità sul territorio), offrendo grandi opportunità per affrontare problematiche globali: dall'efficientamento della sanità alla ricerca di fonti di energia pulita, dalla previsione degli impatti climatici all'ottimizzazione della produzione agricola.


In tale scenario moderno, l'Intelligenza Artificiale applicata poggia sul principio cardine:

$$\mathbf{AI} = \mathbf{Machine\ Learning} + \mathbf{Big\ Data} \quad (1.1)$$

in cui la disponibilità di basi di dati su scala massiva (*Big Data*) costituisce il substrato empirico e la sorgente di informazione, mentre gli algoritmi di *Machine Learning* e *Data Mining* forniscono il motore logico-induttivo capace di estrarre generalizzazioni e schemi decisionali non banali.

1.1.2 Una Confluenza di Discipline

Il Data Mining non è una disciplina isolata, bensì una confluenza sinergica di diverse aree dell'informatica e della matematica applicata:




1.2 Tipologie di Origine del Dato: Primari e Secondari

Nell'impostazione di un progetto analitico, è fondamentale distinguere l'origine dei dati analizzati:

- **Dati Primari (*Primary Data*):** Dati originali rilevati specificamente per un preciso obiettivo di indagine. Non hanno subito alterazioni o manipolazioni preventive da parte di terzi.
- **Dati Secondari (*Secondary Data*):** Dati che erano già stati raccolti in precedenza per scopi operativi o differenti da quello corrente e resi disponibili all'analista. Spesso derivano dalla fusione di sorgenti disomogenee e necessitano di profonde operazioni di normalizzazione e verifica della qualità.

1.3 Il Processo KDD (Knowledge Discovery in Databases)

Il Data Mining costituisce una fase specifica, sebbene centrale, all'interno del più ampio processo di scoperta della conoscenza, noto come **KDD** (*Knowledge Discovery in Databases*). Il KDD è un processo iterativo e interattivo composto da diverse fasi sequenziali con cicli di retroazione:



Ciascuna fase assolve compiti specifici:

1. **Business Understanding:** Comprensione degli obiettivi di dominio e traduzione del problema di business in un problema formale di analisi dati.
2. **Data Cleaning e Data Integration:**
 - *Data Cleaning*: rimozione di rumore, correzione di errori sintattici e gestione delle incoerenze.

- *Data Integration*: aggregazione e riconciliazione di dati provenienti da fonti multiple ed eterogenee, confluendo tipicamente in un **Data Warehouse** (un repository strutturato e ottimizzato per l'analisi e il supporto alle decisioni).

3. Data Selection e Data Transformation:

- *Data Selection*: estrazione del sottoinsieme di attributi e record strettamente pertinenti al task investigato (*task-relevant data*).
 - *Data Transformation*: trasformazione delle feature mediante aggregazioni, riscalamenti, normalizzazioni o discretizzazioni affinché siano adatte all'algoritmo.
4. **Data Mining**: Esecuzione vera e propria di algoritmi intelligenti per l'estrazione di pattern e modelli matematici.
 5. **Pattern Evaluation e Knowledge Presentation**: Identificazione dei pattern realmente significativi tramite metriche oggettive e soggettive, eliminazione della ridondanza e visualizzazione grafica dei risultati mediante strumenti interpretabili dall'utente finale.

1.4 Tassonomia dei Compiti di Data Mining

Seguendo la classificazione di Fayyad et al. [1], i compiti di Data Mining si dividono in due macro-categorie:

- **Metodi Predittivi (*Prediction Methods*)**: Mirano a stimare il valore futuro o sconosciuto di una variabile target specifica a partire dai valori di altre variabili osservate (attributi predittori).
- **Metodi Descrittivi (*Description Methods*)**: Mirano a identificare pattern leggibili ed interpretabili dall'essere umano che descrivano la struttura intrinseca e le relazioni nascoste nei dati.

1.4.1 Compiti Predittivi: La Classificazione

La **classificazione** ha come obiettivo l'apprendimento di una funzione obiettivo f che mappa ogni record di attributi x in una specifica etichetta di classe discreta $y \in \mathcal{Y}$.




Figura 1.1: Workflow concettuale del processo di classificazione.

Il dataset viene suddiviso in due insiemi disgiunti:

- **Training Set:** Utilizzato per addestrare il classificatore.
- **Test Set:** Utilizzato per valutare la capacità di generalizzazione del modello su istanze non osservate durante la fase di apprendimento.

Esempio 1.4.1 (Esempio Didattico: Induzione di un Albero Decisionale per il Merito Creditizio). Consideriamo un tipico problema di concessione del credito bancario, in cui l'obiettivo è stimare se un nuovo richiedente sia finanziariamente affidabile ($Credit\ Worthy \in \{\text{Sì}, \text{No}\}$).

1. Training Set (Dati storici con classe nota): L'istituto dispone di uno storico di clienti con esito di rimborso accertato:

TID	Occupato	Livello Istruzione	Anni di Residenza	Affidabile (Classe)
1	Sì	Laurea	5	Sì
2	Sì	Diploma	2	No
3	No	Triennale	1	No
4	Sì	Diploma	10	Sì

Tabella 1.1: Training set per l'addestramento del classificatore creditizio.

2. Modello Appreso (Albero Decisionale): L'algoritmo di classificazione estrae dai dati storici una sequenza gerarchica di test logici (Fig. 1.2):




Figura 1.2: Modello classificatore: albero decisionale appreso.

3. Test Set (Dati nuovi non osservati): Quando giungono nuove domande di prestito con classe incognita (?), il modello le valuta navigando la struttura ad albero:

TID	Occupato	Istruzione	Anni	Target	Predizione del Modello
5	Sì	Triennale	7	?	Sì (Occupato → Triennale → $7 > 3$)
6	No	Laurea	3	?	No (Non occupato)
7	Sì	Diploma	2	?	No (Occupato → Diploma → $2 \leq 3$)

Tabella 1.2: Valutazione del test set mediante l'albero decisionale.

L'esempio illustra come il classificatore non si limiti a memorizzare i record del training set, ma generalizzi una regola predittiva applicabile a qualsiasi nuova istanza.

Esempio 1.4.2 (Applicazioni di Classificazione). Tra le principali e più diffuse aree applicative dei modelli di classificazione troviamo:

- **Valutazione del Merito Creditizio (*Credit Worthiness*):** Predire se un richiedente prestito rimborserà il debito (*Yes/No*) sulla base di occupazione, livello di istruzione e anni di residenza.
- **Rilevamento Frodi Bancarie:** Classificare le transazioni con carta di credito come lecite o fraudolente. Le feature includono l'importo, l'orario, la posizione geografica e il profilo storico delle spese.
- **Churn Prediction:** Stimare la probabilità che un cliente di telecomunicazioni abbandoni il servizio per passare alla concorrenza, analizzando la durata delle chiamate, il volume del traffico dati e i reclami registrati.

- **Altre applicazioni:** Categorizzazione automatica di notizie (sport, finanza, politica), diagnosi clinica (tumore benigno o maligno), classificazione di coperture del suolo da immagini satellitari.

1.4.2 Compiti Descrittivi

1. Clustering (Raggruppamento)

Il **clustering** consiste nell'organizzare un insieme di oggetti in gruppi distinti (detti *cluster*), in modo tale che:

1. La distanza tra oggetti appartenenti allo stesso cluster (**distanza intra-cluster**) sia **minimizzata** (massima omogeneità interna).
2. La distanza tra oggetti appartenenti a cluster differenti (**distanza inter-cluster**) sia **massimizzata** (massima separazione esterna).




Figura 1.3: Principio geometrico fondamentale del clustering.

Il clustering è una tecnica non supervisionata: non richiede classi a priori.

- **Segmentazione di Mercato:** Raggruppare i clienti in base a dati socio-demografici e abitudini di acquisto per indirizzare campagne di marketing differenziate.
- **Clustering Documentale:** Raggruppare documenti testuali simili in base alle frequenze congiunte delle parole chiave (ad esempio, l'analisi dell'archivio email aziendale Enron).
- **Summarization e Scienze della Terra:** Ridurre la complessità di enormi serie spaziali partizionando le misurazioni di temperatura marina superficiale (*Sea Surface Temperature* - SST) e produzione primaria (*Net Primary Production* - NPP) negli emisferi settentrionale e meridionale.

2. Scoperta di Regole di Associazione (Association Analysis)

Dato un insieme di transazioni, ciascuna costituita da un sottoinsieme di elementi presi da un insieme globale di articoli (*items*), l'analisi delle associazioni si prefigge di scoprire dipendenze probabilistiche nella forma di regole:

$$X \implies Y \quad (1.2)$$

dove X e Y sono itemset disgiunti ($X \cap Y = \emptyset$). La regola indica che la presenza degli articoli nell'antecedente X predice sistematicamente la contestuale presenza dell'articolo o degli articoli nel conseguente Y .

Esempio 1.4.3 (Market Basket Analysis). Considerando uno storico di scontrini di cassa:

TID	Articoli Acquistati
1	Pane, Coca-Cola, Latte
2	Birra, Pane
3	Birra, Coca-Cola, Pannolini, Latte
4	Birra, Pane, Pannolini, Latte
5	Coca-Cola, Pannolini, Latte

L'algoritmo estrae regole ad elevata evidenza statistica, quali:

$$\{\text{Latte}\} \implies \{\text{Coca-Cola}\}, \quad \{\text{Pannolini, Latte}\} \implies \{\text{Birra}\}$$

Tali informazioni guidano la disposizione strategica dei beni sugli scaffali e la progettazione di offerte cross-selling.

Altre applicazioni: Diagnosi di allarmi nelle reti di telecomunicazione (individuazione di pattern temporali di allarmi di rete che scattano congiuntamente per identificare guasti sistemici alla radice); informatica medica (correlazione tra combinazioni di sintomi clinici, esami ematochimici e patologie emergenti).

3. Rilevamento di Anomalie (Anomaly / Deviation / Change Detection)

Consiste nell'identificare oggetti che deviano in modo significativo dal comportamento medio o atteso della popolazione. Le anomalie possono essere generate da guasti strumentali o errori di inserimento (e in tal caso rappresentano *rumore* da epurare), oppure riflettere eventi eccezionali di estremo interesse applicativo (frodi creditizie, intrusioni informatiche contro le reti aziendali, monitoraggio di repentini disboscamenti della copertura forestale tramite sensori remoti).

1.5 Sfide Metodologiche e Computazionali nel Data Mining

L'applicazione di metodi tradizionali di analisi statistica e database è spesso inadeguata a causa di cinque sfide primarie:

1. **Scalabilità (*Scalability*):** Gli algoritmi devono gestire volumi di dati di ordine di terabyte o petabyte senza che la complessità computazionale e l'occupazione di memoria esplodano.
2. **Alta Dimensionalità (*High Dimensionality*):** La presenza di centinaia o migliaia di attributi espone alla cosiddetta *maledizione della dimensionalità* (*curse of dimensionality*), in cui lo spazio geometrico diventa estremamente vuoto e le distanze tendono a perdere discriminatività.
3. **Dati Complessi ed Eterogenei:** Necessità di elaborare strutture semi-strutturate o non strutturate (grafi, testi, sequenze genomiche, serie spaziotemporali).
4. **Proprietà e Distribuzione dei Dati:** I dati sono frequentemente distribuiti geograficamente tra molteplici organizzazioni e soggetti a stringenti vincoli legali di privacy e sicurezza.
5. **Analisi Non Tradizionali:** Esigenza di estrarre conoscenza da flussi continui in tempo reale (*data stream mining*) senza possibilità di memorizzare l'intero dataset.

Capitolo 2

Data Understanding ed Esplorazione dei Dati

Laboratorio Pratico: Esecuzione Interattiva su Jupyter Notebook

I codici Python presentati in questo capitolo corrispondono al notebook di laboratorio:

- **Notebook:** `1_basics_and_understanding.ipynb`
- **Accesso diretto:** [[Apri su Jupyter Lab](http://localhost:8888)] (<http://localhost:8888>)
- **Avvio rapido del container:** Da terminale nella radice del progetto: `docker compose up jupyter`
- **Cartella di lavoro locale:** `Data-Mining/notebooks/` (dataset posizionati in `./data_notebook/`).

2.1 Obiettivi del Data Understanding

La fase di comprensione dei dati (*Data Understanding*) costituisce un prerequisito indispensabile per qualsiasi attività di Data Mining. Prima di selezionare o applicare qualsiasi algoritmo, l'analista deve acquisire una visione complessiva della struttura, della distribuzione e della qualità intrinseca del dataset rispetto agli obiettivi del progetto.

In questa fase preliminare è necessario rispondere a domande metodologiche cruciali:

- Quali tipologie di attributi compongono il dataset?

- Qual è il livello complessivo di qualità dei dati (presenza di rumore, errori o duplicati)?
- Come sono distribuite le variabili numeriche e categoriche?
- Sono presenti correlazioni evidenti o ridondanze tra gli attributi?
- Come sono strutturati gli outlier e quale significato applicativo assumono?
- Quali strategie adottare per i valori mancanti?
- È necessario derivare o trasformare attributi per rendere più efficace il mining?

2.2 Tipologie di Dataset

I dati raccolti si presentano in diverse strutture logico-geometriche in base alla natura del dominio applicativo:

1. Dati di tipo Record:

- **Data Matrix:** Insieme di oggetti descritti dallo stesso insieme fissato di attributi numerici. Un dataset di m oggetti e n attributi è rappresentato formalmente da una matrice $m \times n$:

$$\mathbf{X} = \begin{pmatrix} x_{1,1} & x_{1,2} & \cdots & x_{1,n} \\ x_{2,1} & x_{2,2} & \cdots & x_{2,n} \\ \vdots & \vdots & \ddots & \vdots \\ x_{m,1} & x_{m,2} & \cdots & x_{m,n} \end{pmatrix} \quad (2.1)$$

In tale formalizzazione, ciascun oggetto x_i è un punto in uno spazio vettoriale n -dimensionale $\mathbb{R}^n$.

- **Document Data (Bag-of-Words):** Ciascun documento testuale è rappresentato da un vettore di termini (*term vector*). Ciascuna componente del vettore corrisponde a una parola del vocabolario, e il valore associato ne indica la frequenza di occorrenza nel testo.
- **Dati Transazionali (*Transaction Data*):** Ciascun record rappresenta una transazione (identificata da un TID) e contiene un insieme variabile di articoli acquistati o eventi osservati.

2. **Dati a Grafo (*Graph Data*):** Strutture composte da nodi ed archi che modellano relazioni e connettività. Esempi includono la rete di collegamenti ipertestuali del World Wide Web, i grafi delle reti sociali e le strutture molecolari (ad esempio, la molecola planare del benzene C_6H_6).
3. **Dati Ordinati (*Ordered Data*):**
 - **Sequenze di transazioni:** Successioni temporali di acquisti o eventi per ciascun utente.
 - **Dati genomici:** Sequenze biologiche discrete composte dai caratteri dei nucleotidi {A, C, G, T}.
 - **Dati Spazio-Temporali:** Misurazioni continue o campionate su coordinate geografiche e intervalli temporali regolari (ad esempio, la temperatura media mensile della superficie terrestre e oceanica).

2.3 Oggetti e Attributi

Un dataset è una collezione di **oggetti dati** (*data objects*) e dei relativi **attributi** (*attributes*).

- Un **oggetto** (noto anche come record, punto, caso, campione, entità o istanza) rappresenta una singola entità del dominio di interesse.
- Un **attributo** (noto anche come variabile, campo, caratteristica, dimensione o feature) rappresenta una proprietà o caratteristica misurabile di un oggetto (ad esempio, l'età, il reddito imponibile o il colore degli occhi).

2.3.1 Scale di Misura degli Attributi

Il tipo di scala di misura di un attributo è definito dall'insieme di proprietà algebriche e operatori matematici che conservano il significato della misura:

1. **Distinzione** ($=, \neq$): Possibilità di distinguere se due valori sono uguali o diversi.
2. **Ordine** ($<, >$): Possibilità di stabilire una relazione d'ordine tra valori.
3. **Differenze significative** ($+, -$): Presenza di un'unità di misura costante che consente di quantificare l'intervallo tra due valori (lo zero è convenzionale/arbitrario).

4. **Rapporti significativi** (*, /): Presenza di uno **zero assoluto intrinseco** (indicante la totale assenza della grandezza misurata), che rende significativo il confronto proporzionale tra grandezze.

Scala	Proprietà	Descrizione	Esempi		Operatori Statistici
Nominale	Distinzione (=, $\neq$)	Valori qualitativi o etichette categoriche senza ordinamento intrinseco	Codice fiscale, CAP, occhi, genere	fiscale, colore	Moda, entropia, test χ^2 , contingenza
Ordinale	Distinzione e Ordine (=, $\neq$, $<$, $>$)	Valori con ordinamento significativo ma intervallo non costante	Titolo di studio, scala Likert (1–10), durezza minerali		Mediana, percentili, correlazione di rango (Spearman)
Intervallo	Ordine e Differenze (+, $-$)	Differenze quantitative dotate di senso; lo zero è convenzionale	Temperatura in $^{\circ}\text{C}$ o $^{\circ}\text{F}$, date di calendario		Media, varianza, deviazione standard, Pearson, test t ed F
Rapporto	Tutte le 4 proprietà (=, $<$, $+$, $*$, $/$)	Presenza di zero assoluto; rapporti tra misure fisicamente validi	Età, reddito, massa, conteggi, Kelvin		Media geometrica, armonica, variazione percentuale

Tabella 2.1: Tassonomia delle scale di misura degli attributi (Stevens).

2.3.2 Ulteriori Distinzioni degli Attributi

- **Attributi Binari:** Attributi nominali che ammettono esclusivamente due stati (0 e 1). Si distinguono in:
 - *Binari Simmetrici:* Entrambi gli esiti hanno pari importanza informativa (ad esempio il genere sessuale).
 - *Binari Asimmetrici:* Uno dei due esiti è raro ma di estrema rilevanza informativa (ad esempio, l'esito positivo a un test diagnostico per una malattia rara). Per convenzione, si associa il valore 1 all'evento di maggiore interesse.
- **Attributi Discreti vs Continui:**

- *Discreti*: Assumono un insieme finito o numerabile di valori (tipicamente rappresentati da numeri interi, conteggi o categorie). Gli attributi binari costituiscono un caso speciale di attributo discreto.
- *Continui*: Assumono valori in un sottoinsieme continuo dei numeri reali $\mathbb{R}$ (temperatura, peso, coordinate). Nella pratica computazionale, vengono misurati e memorizzati mediante rappresentazioni in virgola mobile (*floating-point*) con precisione finita.

2.4 Qualità del Dato (Data Quality)

La qualità del dato è un fattore critico per il successo di qualunque iniziativa analitica. Come evidenziato negli studi di Thomas Redman, i problemi derivanti da dati di scarsa qualità costano tipicamente alle organizzazioni tra il 10% e il 20% dei loro ricavi complessivi. Se un modello di rischio creditizio viene addestrato su dati viziati o errati, il sistema rifiuterà debitori solvibili ed erogherà prestiti a individui insolventi.

2.4.1 Dimensioni della Qualità del Dato

I problemi di qualità si manifestano sotto diverse dimensioni:

1. **Accuratezza Sintattica (*Syntactic Accuracy*)**: Il valore registrato viola i vincoli formali o non appartiene al dominio prefissato (ad esempio, la stringa "female" per il sesso, o la presenza di caratteri testuali in un campo numerico). Tali anomalie sono identificabili in modo immediato ed automatizzato mediante semplici controlli di schema e tipi.
2. **Accuratezza Semantica (*Semantic Accuracy*)**: Il dato è formalmente corretto e conforme al tipo previsto, ma falso nella realtà di riferimento (ad esempio, associare il nome anagrafico "John Smith" al genere femminile, o registrare un'età biologica pari a 180 anni). Rilevare queste discrepanze richiede la definizione di regole di dominio (*business rules*) o incroci con sorgenti esterne certificate.
3. **Completezza (*Completeness*)**: Mancanza sistematica di valori per determinati attributi o assenza di interi record. Una violazione insidiosa della completezza è il **bias di campionamento** (ad esempio, l'analisi del rischio di insolvenza svolta su un archivio storico che include esclusivamente clienti a cui il credito era già stato concesso, escludendo a priori i profili a basso reddito respinti).

4. **Dati Sbilanciati (*Unbalanced Data*):** Distribuzione fortemente asimmetrica delle classi (ad esempio, transazioni fraudolente pari allo 0.1% del totale o prodotti difettosi su linee di produzione ad altissima automazione).
5. **Tempestività (*Timeliness*):** Obsoleto grado di aggiornamento dei dati rispetto alla dinamica corrente del fenomeno osservato.
6. **Dati Duplicati (*Duplicate Data*):** Presenza di record identici o quasi-identici relativi alla medesima entità (ad esempio, un medesimo cliente registrato più volte con indirizzi email differenti a seguito della fusione di due banche dati eterogenee). Tali problematiche richiedono processi dedicati di deduplicazione e *record linkage*.

Anomalie nei Flussi di Misurazione e Sensori

Nei sistemi di monitoraggio industriale e IoT, un sensore guasto o bloccato trasmette tipicamente un valore costante pari a zero. In fase di esplorazione, tali registrazioni non devono essere considerate misurazioni fisiche effettive, bensì interpretate e gestite a tutti gli effetti come **valori mancanti** (dovuti a malfunzionamento del dispositivo).

2.5 Statistica Descrittiva ed Esplorazione Univariata

2.5.1 Misure di Tendenza Centrale

- **Media Campionaria ($\bar{x}$):** Per un campione di dimensione m :

$$\bar{x} = \frac{1}{m} \sum_{i=1}^m x_i \quad (2.2)$$

La media è una misura distributiva (può essere calcolata partizionando il dataset in sottoinsiemi), ma è **estremamente sensibile alla presenza di outlier**.

- **Mediana:** Il valore che occupa la posizione centrale nell'ordinamento crescente delle osservazioni (o la media dei due valori centrali se m è pari). È una misura robusta, con un punto di rottura (*breakdown point*) del 50%.

- **Media Troncata (*Trimmed Mean*):** Media calcolata escludendo una percentuale fissa (ad esempio il 5% o il 10%) dei valori più estremi a entrambe le estremità.
- **Moda:** Il valore o la categoria che si presenta con la frequenza assoluta massima. Una distribuzione può essere unimodale, bimodale, multimodale, oppure priva di moda se tutte le osservazioni compaiono una sola volta.

2.5.2 Asimmetria e Multimodalità

- **Asimmetria Positiva (*Positively Skewed / Right-skewed*):** La coda destra della distribuzione è allungata. La maggior parte delle osservazioni è concentrata su valori inferiori alla media aritmetica (Moda < Mediana < Media). Un esempio tipico è la distribuzione dei **redditi**: la grande maggioranza dei cittadini percepisce redditi bassi o medi, mentre un esiguo numero di individui percepisce redditi estremamente elevati, trainando la media verso l'alto.
- **Distribuzione Bimodale:** Presenza di due picchi distinti nella densità di frequenza. Segnala tipicamente l'influenza di una variabile latente binaria non esplicitata (ad esempio, la distribuzione del peso corporeo umano in una popolazione mista, influenzata dalla variabile binaria sesso).

2.5.3 Misure di Dispersione

- **Range:** Differenza tra valore massimo e valore minimo: $\text{Range} = x_{\max} - x_{\min}$.
- **Varianza Campionaria (s^2) e Deviazione Standard (s):**

$$s^2 = \frac{1}{m-1} \sum_{i=1}^m (x_i - \bar{x})^2, \quad s = \sqrt{s^2} \quad (2.3)$$

La deviazione standard misura la dispersione attorno alla media; è nulla solo se tutte le osservazioni sono identiche ($s = 0$), altrimenti $s > 0$. Risulta anch'essa sensibile agli outlier.

- **Misure Robuste di Dispersione:**

– *Absolute Average Deviation* (AAD):

$$\text{AAD} = \frac{1}{m} \sum_{i=1}^m |x_i - \bar{x}| \quad (2.4)$$

– *Median Absolute Deviation* (MAD):

$$\text{MAD} = \text{mediana}(|x_i - \text{mediana}(x)|) \quad (2.5)$$

– *Interquartile Range* (IQR): Distanza tra il terzo quartile Q_3 (75° percentile) e il primo quartile Q_1 (25° percentile):

$$\text{IQR} = Q_3 - Q_1 \quad (2.6)$$

2.5.4 Box Plot e Sintesi a Cinque Numeri

Il **Box Plot** (grafico a scatola e baffi) offre una sintesi visiva non parametrica della distribuzione basata sulla **sintesi a cinque numeri**:

$$[\text{Minimo}, Q_1, \text{Mediana}(Q_2), Q_3, \text{Massimo}]$$

La costruzione geometrica si fonda sul concetto di quantile: dato $p \in (0, 100)$, il $p\%$ -**quantile** (o p -esimo percentile) è la soglia x_p tale per cui il $p\%$ delle osservazioni campionarie assume valori inferiori o uguali a x_p , mentre il $(100 - p)\%$ assume valori superiori. In particolare:

- Q_1 corrisponde al 25%-quantile (primo quartile).
- La mediana Q_2 corrisponde al 50%-quantile (secondo quartile).
- Q_3 corrisponde al 75%-quantile (terzo quartile).
- La larghezza della scatola centrale riflette l'intervallo interquartile $\text{IQR} = Q_3 - Q_1$, racchiudendo il 50% centrale della massa dei dati.




Figura 2.1: Anatomia geometrica di un Box Plot con individuazione degli outlier.

I limiti dei baffi sono calcolati convenzionalmente estendendosi fino al valore osservato più estremo entro l'intervallo $[Q_1 - 1.5 \times \text{IQR}, Q_3 + 1.5 \times \text{IQR}]$.

Le osservazioni che cadono al di fuori di tali soglie sono etichettate visivamente come **outlier**.

Un'estensione fondamentale per l'analisi bivariata e multivariata è costituita dai **Box Plot Condizionali** (*Conditional Box Plots*): la distribuzione di un attributo numerico continuo viene stratificata e visualizzata affiancando i box plot per ciascuna modalità o categoria di una variabile discreta (tipicamente la classe target o un raggruppamento naturale). In Figura 2.2 è illustrata la distribuzione della lunghezza del petalo (*Petal Length*) stratificata sulle tre specie del dataset Iris: il grafico evidenzia visivamente che la specie *Setosa* è nettamente separabile dalle restanti due con variabilità molto ridotta, mentre *Versicolor* e *Virginica* presentano una parziale sovrapposizione nei rispettivi intervalli interquartili.




Figura 2.2: Box Plot Condizionale calcolato sui dati reali del dataset Iris: distribuzione empirica della lunghezza del petalo (*Petal Length*) stratificata sulle tre specie, con evidenza della mediana, dei quartili e dei singoli campioni osservati.

2.5.5 Laboratorio Python: Ispezione Descrittiva, Calcolo di IQR e Box Plot

Esegui questo blocco nel Notebook Interattivo

Notebook: [1_basics_and_understanding.ipynb](#)
Jupyter Lab]

[Apri su

Server locale: <http://localhost:8888> (comando di avvio: `docker compose up jupyter`)

Nel notebook didattico `1_basics_and_understanding.ipynb`, l'ispezione univariata, il calcolo delle statistiche sintetiche e l'identificazione degli outlier tramite la regola di Tukey sono implementati con Pandas e Seaborn come illustrato nel Listing 2.1:

Listing 2.1: Ispezione univariata, calcolo di IQR e tracciamento di Box Plot con Pandas e Seaborn.

```
1 import pandas as pd
2 import numpy as np
3 import seaborn as sns
4 import matplotlib.pyplot as plt
5
6 # 1. Caricamento del dataset delle mance (Tips)
7 data_path = './data_notebook/data/'
8 df = pd.read_csv(f'{data_path}correct_tips.csv',
9                 index_col=0)
10
11 # 2. Statistiche descrittive aggregate
12 print(df.describe().T[['mean', 'std', 'min', '25%', '50%',
13                        '75%', 'max']])
14
15 # 3. Calcolo analitico dell'IQR e soglie di Tukey per la
16     feature 'tip'
17 q25 = df['tip'].quantile(0.25)
18 q75 = df['tip'].quantile(0.75)
19 iqr = q75 - q25
20 lower_whisker = q25 - 1.5 * iqr
21 upper_whisker = q75 + 1.5 * iqr
22
23 outliers = df[(df['tip'] < lower_whisker) | (df['tip'] >
24             upper_whisker)]
25 print(f"IQR = {iqr:.2f} | Baffi: [{lower_whisker:.2f}, {
26     upper_whisker:.2f}] | Outlier trovati: {len(outliers)}")
27
28 # 4. Tracciamento di Box Plot univariato e condizionale
29 fig, axes = plt.subplots(1, 2, figsize=(12, 4))
30 df.boxplot(column=['tip'], ax=axes[0])
31 axes[0].set_title("Box Plot Univariato (Tip)")
32
33 sns.boxplot(data=df, x='sex', y='tip', hue='time', ax=
34             axes[1])
35 axes[1].set_title("Box Plot Condizionale (Tip per Sesso
```

```

30     e Fascia Oraria)")
31 plt.tight_layout()
plt.show()

```

Confronto Critico: Box Plot vs Istogramma

Sebbene il box plot sintetizzi efficacemente posizione e dispersione, **non è in grado di mostrare la reale forma della distribuzione**. Due distribuzioni aventi densità radicalmente differenti (ad esempio, una distribuzione unimodale uniforme e una distribuzione fortemente bimodale con una valle centrale vuota) possono produrre identici valori di Q_1 , mediana, Q_3 , Minimo e Massimo, e generare pertanto lo stesso identico box plot. L'istogramma è indispensabile per rilevare la multimodalità.




Figura 2.3: Confronto critico: due distribuzioni con andamenti diametralmente opposti (unimodale vs bimodale con centro svuotato) generano la medesima sintesi a cinque numeri e lo stesso Box Plot.

2.5.6 Bar Chart per Attributi Categorici

Il **Bar Chart** (grafico a barre) rappresenta visivamente la distribuzione di frequenza di un attributo qualitativo o categorico. Ciascuna categoria discreta è rappresentata da una barra verticale (o orizzontale), la cui altezza corrisponde al conteggio assoluto o alla frequenza relativa. A differenza degli istogrammi, le barre sono separate da spazi vuoti per evidenziare che le modalità non costituiscono un continuo numerico.




Figura 2.4: Esempio di Bar Chart per un attributo categorico nominale (Stato Civile).

2.5.7 Istogrammi per Attributi Numerici e Scelta dei Bin

Un **istogramma** mostra la distribuzione empirica di frequenza di un attributo numerico continuo. Il dominio di variabilità della grandezza viene partizionato (*discretizzato*) in un numero prefissato k di intervalli contigui detti *bin* (o classi di ampiezza). Per ciascun bin, l'altezza della barra sovrastante è proporzionale al numero di osservazioni campionarie che cadono al suo interno.




Figura 2.5: Esempio di Istogramma per un attributo numerico continuo con bin contigui di ampiezza costante.

Una scelta scorretta del numero di bin altera profondamente la percezione dei dati:

- Un numero insufficiente di bin provoca *oversmoothing*, livellando la distribuzione e mascherando asimmetrie e bimodalità.
- Un numero eccessivo di bin provoca *undersmoothing*, frammentando il campione in frequenze discontinue ed enfatizzando il rumore campionario.

Per distribuzioni unimodali approssimativamente normali e campioni di dimensione moderata n , la stima standard del numero ottimale di intervalli è fornita dalla **regola di Sturges**:

$$k = 1 + \lceil \log_2(n) \rceil = 1 + \lceil 3.322 \log_{10}(n) \rceil \quad (2.7)$$

dove n rappresenta la cardinalità campionaria. Tale euristica assume esplicitamente una distribuzione di tipo gaussiano. Quando il volume dei dati cresce notevolmente o la distribuzione sottostante presenta più modi o forte asimmetria, la regola di Sturges tende a generare un numero insufficiente di classi; in tali casi risulta fondamentale testare sperimentalmente diversi valori di k (ad esempio confrontando partizioni a bassa, media ed elevata risoluzione, come 5, 17 o 50 bin) per verificare la stabilità dei pattern riscontrati.

2.6 Tecniche di Visualizzazione Multivariata

2.6.1 Scatter Plot e Visualizzazione a Più Dimensioni

Lo **Scatter Plot** (grafico a dispersione) tratta coppie di attributi numerici come coordinate cartesiane (x_i, y_i) nel piano. È il principale strumento visuale per:

- Identificare correlazioni lineari o andamenti funzionali non lineari.
- Rilevare addensamenti naturali di punti (*cluster*).
- Individuare outlier multivariati non visibili nelle proiezioni univariate.

Esempio 2.6.1 (Analisi del Dataset Iris di Anderson/Fisher). Il celebre dataset *Iris* (150 campioni di fiori appartenenti a tre specie: *Setosa*, *Versicolor*, *Virginica*) descrive 4 attributi numerici: lunghezza e larghezza del sepalo, lunghezza e larghezza del petalo. Lo scatter plot bivariato mostra che gli attributi relativi al petalo (*Petal Length* vs *Petal Width*) garantiscono una separazione netta tra le specie, consentendo inoltre di isolare eventuali anomalie.




Figura 2.6: Scatter Plot bivariato reale (*Petal Length* vs *Petal Width*) per tutti i 150 campioni del dataset Iris, con codifica cromatica e geometrica per classe e identificazione visiva della netta separazione di *Setosa* e dei punti atipici di confine.

Per esplorare simultaneamente tutte le coppie di attributi numerici, si impiega una **Scatter Plot Matrix** (SPLOM), ovvero una griglia $n \times n$ in cui ogni cella non diagonale (i, j) visualizza il grafico di dispersione tra l'attributo i e l'attributo j , mentre la diagonale principale ospita gli istogrammi o le stime di densità univariate.




Figura 2.7: Scatter Plot Matrix (SPLOM) calcolata su tutti i 150 campioni del dataset Iris attraverso i 4 attributi continui, con stima di densità univariata (KDE) sulla diagonale principale e grafici di dispersione bivariati nelle celle esterne.

2.6.2 Laboratorio Python: Scatter Plot Multivariati e Matrice di Dispersione

Esegui questo blocco nel Notebook Interattivo

Notebook: `1_basics_and_understanding.ipynb`
[Jupyter Lab](#)

[Apri su

Server locale: `http://localhost:8888` (comando di avvio: `docker compose up jupyter`)

La rappresentazione visiva bivariata e la Scatter Plot Matrix sono generate con Seaborn e Pandas tramite il Listing 2.2:

Listing 2.2: Tracciamento di Scatter Plot bivariati e Scatter Matrix multivariata con Seaborn e Pandas.

```
1 import pandas as pd
2 import seaborn as sns
3 import matplotlib.pyplot as plt
4
5 df = pd.read_csv('./data_notebook/data/correct_tips.csv',
6                 , index_col=0)
7
8 # 1. Scatter plot bivariato con codifica cromatica e di
9     stile
10 plt.figure(figsize=(7, 4))
11 sns.scatterplot(data=df, x='total_bill', y='tip', hue='
12     time', style='sex', s=60)
13 plt.title("Relazione tra Conto Totale e Mancia (per
14     Orario e Sesso)")
15 plt.xlabel("Conto Totale ($)")
16 plt.ylabel("Mancia ($)")
17 plt.show()
18
19 # 2. Scatter Plot Matrix (SPLOM) sulle feature numeriche
20 numeric_features = ['total_bill', 'tip', 'size', 'age']
21 pd.plotting.scatter_matrix(df[numeric_features], figsize
22     =(8, 8), diagonal='kde', alpha=0.7)
23 plt.suptitle("Scatter Plot Matrix con stime di densita'
24     KDE diagonali", y=1.02)
25 plt.show()
```

2.6.3 La Visualizzazione come Test ed Euristica Esplorativa

L'ispezione visiva rappresenta un primo insostituibile test esplorativo sulla presenza di struttura nei dati, la cui corretta interpretazione richiede una precisa consapevolezza metodologica:

- **Presenza di evidenza grafica:** Quando le visualizzazioni evidenziano pattern netti, raggruppamenti separati (*cluster*) o eccezioni isolate (*outlier*), si ha la certezza empirica che vi sia una proprietà strutturale reale o un fenomeno oggettivo all'interno del dataset.
- **Assenza di evidenza grafica non implica assenza di struttura:** Al contrario, quando le visualizzazioni ordinarie non mostrano alcuna

configurazione apparente o sembrano puramente casuali, **non** si può dedurre che i dati siano privi di relazioni. Relazioni multivariate complesse, deboli associazioni non lineari o dipendenze spaziali che coinvolgono quattro o più attributi contemporaneamente sfuggono intrinsecamente a proiezioni bidimensionali, richiedendo l'impiego di tecniche analitiche o proiezioni a dimensionalità superiore.

2.6.4 Visualizzazione ad Alta Dimensionalità

Coordinate Parallele (Parallel Coordinates)

Quando il numero di dimensioni supera 3, la rappresentazione cartesiana convenzionale risulta inapplicabile. Le **Coordinate Parallele** sostituiscono gli assi ortogonali con un insieme di assi paralleli verticali equidistanti, ciascuno corrispondente a un attributo.




Figura 2.8: Rappresentazione a 4 dimensioni mediante Coordinate Parallele calcolata sui dati reali del dataset Iris (150 campioni normalizzati in $[0, 1]$): le curve sottili rappresentano le singole osservazioni, mentre le linee marcate evidenziano i profili medi distintivi di ciascuna specie.

- Ogni oggetto multidimensionale è rappresentato da una **linea spezzata poligonale** che connette i rispettivi valori scalati lungo gli assi verticali.
- Gli oggetti appartenenti alla stessa classe tendono a formare fasci di linee parallele o con andamenti coordinati.
- **Sensibilità all'ordinamento degli assi:** La visibilità di raggruppamenti e correlazioni dipende criticamente dalla disposizione sequen-

ziale degli assi. Due attributi fortemente correlati mostrano pattern geometrici regolari solo se posizionati come assi adiacenti.

Radar Plot e Star Plot

Nei **Radar Plot**, gli assi partono da un centro comune e si irradiano a stella a intervalli angolari costanti. Il valore di ciascun attributo definisce un vertice lungo il proprio raggio; congiungendo i vertici si ottiene un poligono per ogni istanza. Gli **Star Plot** applicano il medesimo principio disegnando ciascun oggetto in un grafico separato, facilitando il confronto per profili individuali.




Figura 2.9: Radar Plot empirico multivariato calcolato sui profili medi normalizzati delle tre specie di Iris sui 4 attributi morfologici.

2.7 Analisi di Correlazione e Associazione

L'analisi di correlazione ha lo scopo di identificare, quantificare e interpretare la forza e la direzione della relazione lineare tra coppie di attributi numerici continui.

2.7.1 Motivazioni e Multicollinearità nei Modelli Predittivi

Nel processo di data understanding, valutare la correlazione tra variabili persegue diversi obiettivi metodologici:

- **Individuazione di ridondanze informative:** Se due attributi manifestano un andamento pressoché coincidente, uno di essi può essere scartato senza perdita apprezzabile di potere descrittivo, riducendo la dimensionalità dello spazio di lavoro.
- **Preparazione per modelli predittivi e clustering:** Molteplici algoritmi di machine learning (quali regressione lineare, logistic regression o clustering basato su distanze) assumono feature indipendenti o beneficiano fortemente della rimozione di attributi collineari.
- **Rilevamento della multicollinearità:** Si verifica quando due o più variabili predittive (*feature*) in un modello di regressione risultano fortemente legate da una relazione lineare. Si consideri l'esempio paradigmatico della stima del valore degli immobili impiegando congiuntamente come predittori sia la *superficie in metri quadri* (m^2) sia la *superficie in piedi quadri* (ft^2). Le due variabili veicolano esattamente la medesima informazione; di conseguenza, il modello di regressione entra in severa instabilità numerica, non riuscendo ad isolare il contributo marginale di ciascun predittore e gonfiando la varianza degli stimatori.

2.7.2 Dalla Varianza alla Covarianza Campionaria

Mentre la varianza campionaria quantifica la dispersione delle osservazioni di una singola variabile attorno alla propria media:

$$s_x^2 = \text{Var}(X) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \quad (2.8)$$

nelle applicazioni analitiche l'interesse è costantemente rivolto alle interazioni tra coppie di variabili:

- I clienti con reddito imponibile più elevato tendono a spendere somme maggiori?
- Il prezzo unitario di un bene determina una contrazione delle quantità vendute?
- Un maggior numero di ore di studio settimanali conduce sistematicamente a voti d'esame superiori?
- Due sensori fisici disposti in parallelo forniscono misure ampiamente ridondanti?

Per misurare come due grandezze numeriche variano simultaneamente, si introduce la **covarianza campionaria**:

Definizione 2.7.1 (Covarianza Campionaria). Dato un campione di n coppie di valori (x_i, y_i) , la covarianza campionaria tra X e Y è definita da:

$$\text{Cov}(X, Y) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \quad (2.9)$$

dove $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ e $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$ rappresentano le medie campionarie.

Una proprietà teorica fondamentale sancisce che la varianza è semplicemente la covarianza di una variabile con se stessa:

$$\text{Cov}(X, X) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \text{Var}(X) = s_x^2 \quad (2.10)$$

2.7.3 Origine del Segno e Interpretazione Geometrica per Quadranti

Il segno algebrico di ciascun termine della sommatoria dipende dal prodotto degli scarti congiunti rispetto alle medie:

- **Scarti concordi positivi:** $(x_i - \bar{x}) > 0$ e $(y_i - \bar{y}) > 0 \implies (+) \times (+) = +$.
- **Scarti concordi negativi:** $(x_i - \bar{x}) < 0$ e $(y_i - \bar{y}) < 0 \implies (-) \times (-) = +$.
- **Scarti discordi:** $(+) \times (-) = -$ oppure $(-) \times (+) = -$.

Traslando l'origine cartesiana nel baricentro $(\bar{x}, \bar{y})$, lo spazio viene suddiviso in quattro quadranti (Figura 2.10):

1. Se dominano le osservazioni nei quadranti **I e III** (scarti concordi), i prodotti positivi prevalgono e la covarianza campionaria è positiva ($\text{Cov}(X, Y) > 0$).
2. Se prevalgono i quadranti **II e IV** (scarti discordi), dominano i prodotti negativi e la covarianza risulta negativa ($\text{Cov}(X, Y) < 0$).
3. Se i punti sono dispersi in modo uniforme o simmetrico tra i quattro quadranti, i termini positivi e negativi si elidono reciprocamente, generando una covarianza prossima a zero ($\text{Cov}(X, Y) \approx 0$).




Figura 2.10: Interpretazione geometrica della covarianza per quadranti centrati in $(\bar{x}, \bar{y})$. I punti nei quadranti concordi I e III producono contributi positivi, mentre i quadranti discordi II e IV producono contributi negativi.

2.7.4 Limite della Covarianza: Dipendenza dalla Scala Metrica

Nonostante la covarianza indichi chiaramente il segno della concordanza lineare, essa presenta un limite critico: **dipende strettamente dalle unità di misura delle variabili**. Si consideri ad esempio la relazione tra reddito annuo e spesa:

- Se entrambe le variabili sono espresse in euro, l'unità di misura della covarianza è pari a euro².
- Se si converte il reddito in *migliaia di euro*, il valore numerico della covarianza subisce un ridimensionamento di un fattore 1000, sebbene la relazione sostanziale sottostante tra le grandezze rimanga rigorosamente immutata.

Di conseguenza, la covarianza descrive la direzione della dipendenza lineare, ma la sua magnitudo assoluta non è comparabile tra coppie di variabili eterogenee né quantifica l'intensità intrinseca del legame.

2.7.5 Coefficiente di Correlazione Lineare di Pearson

Per ottenere una misura standardizzata e priva di unità di misura, si divide la covarianza campionaria per il prodotto delle rispettive deviazioni standard:

Definizione 2.7.2 (Coefficiente di Correlazione di Pearson). Dato un campione di n coppie (x_i, y_i) , il coefficiente campionario di correlazione lineare r_{xy} è definito come:

$$r_{xy} = \frac{\text{Cov}(X, Y)}{s_x s_y} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}} \quad (2.11)$$

dove s_x, s_y sono le deviazioni standard campionarie di X e Y .

Proprietà cardine del coefficiente di Pearson:

- **Adimensionalità e invarianza di scala:** r_{xy} è un numero puro, invariante rispetto a qualunque riscaldamento lineare affine positivo ($X' = aX + b$, con $a > 0$).
- **Delimitazione:** Risulta sempre $-1 \leq r_{xy} \leq +1$.
- **Perfetta collinearità** ($|r_{xy}| = 1$): I punti giacciono esattamente su una linea retta; con pendenza positiva se $r_{xy} = +1$, negativa se $r_{xy} = -1$.
- **Assenza di relazione lineare** ($r_{xy} \approx 0$): Segnala l'assenza di un legame lineare.
- **Cecità alle relazioni non lineari:** Come illustrato in Figura 2.11(d), un coefficiente nullo ($r_{xy} \approx 0$) non dimostra affatto indipendenza: relazioni deterministiche paraboliche o quadratiche possono avere correlazione lineare esattamente pari a zero.




Figura 2.11: Interpretazione visiva del coefficiente di correlazione di Pearson: (a) correlazione positiva; (b) correlazione negativa; (c) assenza di relazione lineare; (d) dipendenza deterministica non lineare sfuggita a Pearson.

2.7.6 Associazione Statistica vs Causalità e Fattori di Confondimento

Un principio fondamentale nella data science è la distinzione epistemologica tra associazione e causazione:

$$\text{Correlazione} \neq \text{Causalità} \quad (2.12)$$

Si consideri un dataset accademico in cui il numero di ore settimanali dedicate allo studio e i voti d'esame mostrano un'elevata correlazione positiva ($r_{xy} = +0.98$). Gli studenti con meno ore di studio tendono a trovarsi sotto la media, mentre chi studia più ore si colloca sopra la media. Tale dato riflette una fortissima associazione statistica, ma **non autorizza a concludere che 2 ore aggiuntive di studio causino direttamente e deterministicamente un incremento prefissato del voto**. Molteplici altre variabili (preparazione pregressa, frequenza alle lezioni, attenzione in aula) possono influenzare congiuntamente entrambi gli aspetti.

La correlazione lineare:

1. Non identifica la direzione della causalità ($X \rightarrow Y$ oppure $Y \rightarrow X$).

2. Può essere generata da un **fattore di confondimento** (*confounding variable*).

Esempio 2.7.1 (La Variabile Confondente: Gelati e Annegamenti). Nelle statistiche estive si osserva una correlazione positiva molto forte tra il volume di vendite di gelati e il numero di incidenti da annegamento. Chiaramente mangiare gelati non provoca annegamenti. Esiste una terza variabile latente non inclusa nella coppia, la **temperatura esterna elevata**, che aumenta simultaneamente sia la domanda di gelati sia il numero di bagnanti in acqua, inducendo una correlazione spuria tra le due grandezze.

2.7.7 Correlazione di Rango di Spearman per Relazioni Monotone

Nei contesti in cui la dipendenza tra due grandezze non è strettamente lineare, oppure in presenza di outlier marcati che distorcono la media e la deviazione standard, si ricorre al **coefficiente di correlazione di rango di Spearman** (ρ_s).

Spearman non confronta direttamente i valori numerici grezzi, ma li sostituisce con la loro posizione ordinale o **rango** (*rank*) nell'ordinamento crescente del campione:

Definizione 2.7.3 (Coefficiente di Correlazione di Rango di Spearman). Siano $\text{rank}(x_i)$ e $\text{rank}(y_i)$ i ranghi di x_i e y_i . Se non vi sono ex aequo (*ties*), il coefficiente è formulato come:

$$\rho_s = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)}, \quad \text{con } d_i = \text{rank}(x_i) - \text{rank}(y_i) \quad (2.13)$$

In presenza di ranghi parimerito, ρ_s equivale al coefficiente di Pearson calcolato direttamente sulle sequenze dei ranghi.

Proprietà essenziali:

- $\rho_s = +1$ quando l'ordinamento delle due variabili coincide perfettamente (relazione **monotona crescente**).
- $\rho_s = -1$ quando l'ordinamento è esattamente invertito (relazione **monotona decrescente**).
- Misura se due grandezze tendono a variare nella stessa direzione o in direzione opposta, senza vincoli di linearità (ad esempio per $Y = X^3$ o $Y = \log(X)$ si ha $\rho_s = 1$).
- Gode di elevata robustezza rispetto a valori estremi o outlier isolati.

2.7.8 Matrice di Correlazione e Selezione delle Feature

In dataset con molteplici attributi continui, si calcolano tutte le correlazioni bivariate a coppie organizzandole in una **matrice di correlazione** simmetrica $p \times p$. Nell'analisi del dataset Iris (Figura 2.12), ad esempio, la matrice evidenzia una fortissima correlazione sia lineare che monotonica tra *Petal Length* e *Petal Width* ($r = 0.96$, $\rho_s = 0.94$), e tra *Sepal Length* e *Petal Length* ($r = 0.87$, $\rho_s = 0.88$), segnalando una rilevante ridondanza informativa che suggerisce la possibilità di fondere o selezionare solo uno dei due attributi per l'addestramento di classificatori e modelli predittivi.




Figura 2.12: Matrici di correlazione bivariata calcolate sul dataset Iris: a sinistra la correlazione lineare di Pearson (r), a destra la correlazione di rango di Spearman (ρ_s). Si evidenzia visivamente l'intensa associazione positiva tra le dimensioni dei petali e l'associazione moderatamente negativa tra la larghezza del sepal e le restanti feature.

2.7.9 Laboratorio Python: Calcolo delle Matrici di Correlazione e Heatmap

Esegui questo blocco nel Notebook Interattivo

Notebook: `1_basics_and_understanding.ipynb`
[Apri su Jupyter Lab]

Server locale: `http://localhost:8888` (comando di avvio: `docker compose up jupyter`)

Nel notebook didattico `1_basics_and_understanding.ipynb`, il confronto tra i coefficienti di correlazione (Pearson, Spearman, Kendall) e la relativa

visualizzazione su mappa termica sono implementati come riportato nel Listing 2.3:

Listing 2.3: Calcolo comparativo delle matrici di correlazione (Pearson, Spearman, Kendall) e Heatmap con Seaborn.

```
1 import pandas as pd
2 import seaborn as sns
3 import matplotlib.pyplot as plt
4
5 df = pd.read_csv('./data_notebook/data/correct_tips.csv',
6                 , index_col=0)
7
8 # 1. Calcolo delle matrici di correlazione per attributi
9     numerici
10 corr_pearson = df.corr(numeric_only=True, method='
11     pearson') # lineare
12 corr_spearman = df.corr(numeric_only=True, method='
13     spearman') # monotonica
14 corr_kendall = df.corr(numeric_only=True, method='
15     kendall') # concordanza di ranghi
16
17 # 2. Visualizzazione comparativa tramite Heatmap
18     annotata
19 fig, axes = plt.subplots(1, 2, figsize=(13, 5))
20 sns.heatmap(corr_pearson, annot=True, fmt=".2f", cmap="
21     coolwarm", vmin=-1, vmax=1, ax=axes[0])
22 axes[0].set_title("Correlazione Lineare di Pearson (r)")
23
24 sns.heatmap(corr_spearman, annot=True, fmt=".2f", cmap="
25     coolwarm", vmin=-1, vmax=1, ax=axes[1])
26 axes[1].set_title("Correlazione di Rango di Spearman (
27     rho_s)")
28 plt.tight_layout()
29 plt.show()
```

2.8 Gestione di Outlier e Valori Mancanti

2.8.1 Outlier: Rumore vs Obiettivo Analitico

Un **outlier** (anomalia o valore aberrante) è un'istanza con caratteristiche che deviano in modo marcato dalla maggior parte delle osservazioni del campione:

- **Outlier come rumore (*noise*):** Generati da errori materiali di digitazione, malfunzionamenti transitori di sensori fisici o problemi nella conversione dei formati. Tali osservazioni falsano drasticamente medie, varianze e modelli di regressione, e devono essere identificate e rimosse (o corrette) nel pre-processing.
- **Outlier come obiettivo analitico (*target*):** Situazioni insolite o eccezionali reali, che rappresentano il primario scopo applicativo dell'analisi. Casi tipici comprendono la rilevazione di **frodi con carte di credito**, l'individuazione di **intrusioni informatiche di rete** (*intrusion detection*) e la diagnosi precoce di **patologie mediche rare**.

Anche qualora gli outlier derivino da misurazioni corrette di eventi rari, può risultare opportuno escluderli temporaneamente dal calcolo di parametri aggregati qualora l'obiettivo sia caratterizzare il comportamento della popolazione tipica.

2.8.2 Metodologie di Rilevamento degli Outlier

L'identificazione delle anomalie si articola su differenti livelli di dimensionalità:

- **Attributo Singolo (Univariato):**
 - *Attributi categorici:* Un outlier corrisponde a un valore che si presenta con una frequenza sensibilmente inferiore rispetto a tutte le altre modalità del dominio.
 - *Attributi numerici:* Ispezione visiva e analitica mediante Box Plot (valori esterni all'intervallo $[Q_1 - 1.5 \times \text{IQR}, Q_3 + 1.5 \times \text{IQR}]$) e calcolo dello z -score standardizzato ($z = \frac{x-\mu}{\sigma}$).
- **Attributi Multipli (Multivariato):**
 - *Scatter Plot 2D e 3D:* Permettono di cogliere outlier sia globali (estremi rispetto all'intera nuvola di punti) sia locali (anomali rispetto al cluster o alla classe specifica a cui appartengono, come illustrato in Figura 2.6).
 - *Grafici PCA (Principal Component Analysis):* Proiettano lo spazio multidimensionale sui piani di massima varianza per individuare punti isolati.
 - *Algoritmi di Clustering:* Negli algoritmi basati sulla densità o su distanze (come DBSCAN o k-means con soglie di distanza),

gli outlier emergono naturalmente come i punti che non possono essere assegnati ad alcun cluster principale o che rimangono completamente isolati.

2.8.3 Valori Mancanti (Missing Values) e Camuffamento

L'assenza di valori per singoli attributi in determinate istanze può derivare da diverse cause:

- **Informazione non raccolta o rifiutata:** Rifiuto esplicito dell'intervistato di condividere dati riservati (ad esempio reddito, peso corporeo o età).
- **Non applicabilità logica dell'attributo:** L'attributo non possiede significato logico per una specifica classe di istanze (ad esempio il reddito annuo per bambini o minori in età scolare).
- **Malfunzionamento o blocco di sensori:** Interruzioni momentanee di connettività o dispositivi fisici danneggiati.

Insidia del Camuffamento: Zeri e Valori di Default Fittizi

Spesso un valore mancante non viene salvato con codifica esplicita (NULL o NaN), bensì registrato con valori convenzionali o di default (ad esempio 0, -1 o 999). Un sensore bloccato, ad esempio, invia ripetutamente il valore 0. Se non intercettati nella fase di Data Understanding, tali numeri vengono trattati acriticamente dai software come misurazioni reali, distorcendo gravemente medie, deviazioni standard e modelli di classificazione.

2.8.4 Laboratorio Python: Rilevamento Valori Nulli, Smascheramento e Imputazione

Esegui questo blocco nel Notebook Interattivo

Notebook: `1_basics_and_understanding.ipynb`
Jupyter Lab]

[Apri su

Server locale: `http://localhost:8888` (comando di avvio: `docker compose up jupyter`)

Nel notebook didattico `1_basics_and_understanding.ipynb`, la gestione dei valori mancanti, l'identificazione di valori camuffati e l'imputazione

(univariata e basata su KNN) sono svolte con Pandas e Scikit-learn come mostrato nel Listing 2.4:

Listing 2.4: Rilevamento di valori nulli/camuffati e strategie di imputazione con Scikit-learn (SimpleImputer e KNNImputer).

```
1 import numpy as np
2 import pandas as pd
3 from sklearn.impute import SimpleImputer, KNNImputer
4
5 df = pd.read_csv('./data_notebook/data/tips.csv',
6                 index_col=0)
7
8 # 1. Ispezione dei valori mancanti espliciti
9 print("Conteggio valori nulli per colonna:\n", df.isnull()
10      ().sum())
11
12 # 2. Rilevamento e smascheramento di valori camuffati (
13     es. eta' pari a 0)
14 zero_ages = (df['age'] == 0).sum()
15 print(f"Record con eta' pari a zero (valore camuffato):
16       {zero_ages}")
17 df['age'] = df['age'].replace(0, np.nan)
18
19 # 3. Imputazione statistica univariata (mediana per
20     numerici, moda per categorici)
21 median_imputer = SimpleImputer(strategy='median')
22 df['age_imputed'] = median_imputer.fit_transform(df[['age']])
23
24 freq_imputer = SimpleImputer(strategy='most_frequent')
25 df['smoker_imputed'] = freq_imputer.fit_transform(df[['smoker']]).ravel()
26
27 # 4. Imputazione multivariata basata sui k-Nearest
28     Neighbors
29 knn_imputer = KNNImputer(n_neighbors=3, weights='distance')
30 num_cols = ['total_bill', 'tip', 'age', 'size']
31 df[num_cols] = knn_imputer.fit_transform(df[num_cols])
32 print("Missing residui dopo KNN Imputation:", df[
33       num_cols].isnull().sum().sum())
```

2.9 Checklist Operativa di Data Understanding

Al termine della fase di esplorazione, l'analista deve aver completato sistematicamente le seguenti verifiche:

1. **Valutazione della Qualità dei Dati:** Verificare la presenza di errori di accuratezza sintattica (valori fuori dominio) e semantica, grado di completezza, tempestività, duplicati e grado di sbilanciamento delle classi.
2. **Individuazione degli Outlier:** Rilevare anomalie univariati e multivariati mediante tecniche di visualizzazione (box plot, scatter plot, PCA, coordinate parallele) e decidere la politica di trattamento (rumore da rimuovere vs target primario di indagine).
3. **Rilevamento ed Esame dei Valori Mancanti:** Identificare i campi nulli e smascherare valori mancanti nascosti o camuffati sotto forma di zeri fittizi o codifiche di default.
4. **Scoperta e Conferma di Correlazioni e Dipendenze:** Calcolare matrici di correlazione lineare (Pearson) e di rango (Spearman) per confermare relazioni attese, rilevare dipendenze inattese e scongiurare la multicollinearità e le ridondanze tra feature.
5. **Verifica di Ipotesi e Assunzioni Specifiche del Dominio:** Controllare assunzioni applicative e distributive (ad esempio verificare se un attributo segue una distribuzione approssimativamente normale per l'uso della regola di Sturges o di stimatori parametrici).
6. **Confronto delle Statistiche con il Comportamento Atteso:** Verificare che medie, mediane, asimmetrie e dispersione riflettano coerentemente la conoscenza di dominio e i pattern attesi nel contesto applicativo.

Capitolo 3

Data Preparation e Data Cleaning


Laboratorio Pratico: Esecuzione Interattiva su Jupyter Notebook

I codici Python presentati in questo capitolo corrispondono al notebook di laboratorio:

- **Notebook:** `2_feature_engineering_....ipynb`
- **Accesso diretto:** [[Apri su Jupyter Lab](http://localhost:8888)] (<http://localhost:8888>)
- **Avvio rapido del container:** Da terminale nella radice del progetto: `docker compose up jupyter`
- **Cartella di lavoro locale:** `Data-Mining/notebooks/` (dataset posizionati in `./data_notebook/`).

3.1 Obiettivi della Data Preparation

Se la fase di *Data Understanding* (Capitolo 2) risponde alla domanda fondamentale «*come sono fatti i dati e quali criticità presentano?*», la fase di **Data Preparation** (*Preparazione dei Dati*) traduce tali evidenze analitiche in azioni trasformative concrete:



Gli obiettivi primari della preparazione dei dati si riassumono in:

- **Miglioramento della qualità dei dati (*Data Quality*):** Eliminare o correggere rumore, inconsistenze sintattiche e semantiche.
- **Adattamento ai requisiti degli algoritmi:** Molti algoritmi di Data Mining e Machine Learning richiedono formati specifici (ad esempio variabili binarie asimmetriche per le regole associative, oppure feature con scala numerica omogenea per metodi basati sulla distanza euclidea).
- **Efficienza computazionale e contrasto della dimensionalità:** Ridurre la complessità spaziale e temporale mediante campionamento (*data reduction*) o selezione/proiezione di attributi (*dimensionality reduction*).

Le macro-tecniche di Data Preparation comprendono:

1. **Aggregazione (*Aggregation*):** Combinazione di oggetti o attributi su scale più ampie.
2. **Riduzione dei Dati tramite Campionamento (*Sampling*):** Selezione di un sottoinsieme rappresentativo di istanze.
3. **Riduzione di Dimensionalità (*Dimensionality Reduction*):** Selezione o estrazione/proiezione (PCA, SVD).
4. **Creazione di Nuove Feature (*Feature Creation*):** Feature construction guidata dal dominio.
5. **Discretizzazione e Binarizzazione:** Conversione continuo-discreto e encoding categorico.
6. **Trasformazione degli Attributi (*Attribute Transformation*):** Normalizzazione, scalatura decimale, trasformazioni logaritmiche e stabilizzazione della varianza.

3.2 Aggregazione dei Dati

Definizione 3.2.1 (Aggregazione). L'**aggregazione** consiste nella combinazione di due o più attributi (o di due o più oggetti/record) in un singolo attributo (o singolo oggetto aggregato).

L'aggregazione persegue tre scopi metodologici fondamentali:

- **Riduzione della dimensione dei dati:** Diminuisce drasticamente il numero di record (righe) o il numero di colonne (feature) da elaborare.
- **Cambiamento di scala temporale o spaziale:**
 - *Aggregazione spaziale:* Misurazioni registrate per singola città o quartiere aggregate a livello regionale o nazionale.
 - *Aggregazione temporale:* Transazioni orarie o giornaliere aggregate su base settimanale, mensile o annuale.
- **Stabilizzazione statistica del dato:** I dati aggregati presentano intrinsecamente **minore variabilità** rispetto alle misurazioni individuali a granularità fine.

3.2.1 Esempio: Precipitazioni in Australia (1982–1993)

Si consideri lo studio delle precipitazioni su centinaia di stazioni meteorologiche terrestri in Australia per il periodo 1982–1993:

- Confrontando la deviazione standard delle precipitazioni medie **mensili** rispetto a quella delle precipitazioni medie **annuali**, si osserva che la deviazione standard annuale è fortemente concentrata su valori vicini allo zero (Figura 3.1).
- L'aggregazione temporale annuale comprime i picchi transitori e rimuove la dispersione stagionale. Tuttavia, se l'obiettivo di data mining è studiare **i pattern climatici stagionali o monsonici**, l'istogramma mensile risulta di gran lunga più informativo e appropriato rispetto a quello annuale.




Figura 3.1: Effetto dell'aggregazione sulla dispersione statistica (Esempio Precipitazioni in Australia): a sinistra la deviazione standard delle medie mensili (mostra ampia variabilità stagionale); a destra la deviazione standard delle medie annuali (evidenzia come l'aggregazione comprime la varianza e stabilizzi le osservazioni).

3.3 Riduzione dei Dati tramite Campionamento (Sampling)

Il **campionamento** (*Data Sampling*) rappresenta la tecnica cardine per la riduzione del numero di record (righe del dataset).

Nota 3.3.1 (Principio Guida del Campionamento Efficace). Un campione statistico $\mathcal{S}$ produce risultati analitici quasi identici a quelli ottenibili sull'intera popolazione $\mathcal{D}$ se e solo se $\mathcal{S}$ è **rappresentativo**. Un campione è rappresentativo se possiede approssimativamente le stesse proprietà distributive di interesse del dataset originario.

3.3.1 Trade-off sulla Dimensione del Campione

La scelta della cardinalità del campione riflette un compromesso analitico:

- Un campione eccessivamente ridotto (es. 500 punti su 8000) perde la continuità geometrica dei pattern, disgrega i cluster densi e non consente di cogliere dettagli fini.
- Un campione sufficientemente dimensionato (es. 2000 punti) preserva la silhouette delle distribuzioni e le relazioni topologiche consentendo tempi di esecuzione notevolmente inferiori.




Figura 3.2: Trade-off della dimensione del campione nel campionamento casuale: a sinistra la popolazione originaria ($N = 8000$) con strutture non lineari complesse; al centro un sotto-campionamento eccessivo ($n = 500$, 6.25%) che frammenta i cluster ed elimina dettagli; a destra un campione dimensionato efficacemente ($n = 2000$, 25%) che preserva fedelmente la topologia e le densità con una netta riduzione del carico computazionale.

3.3.2 Tipologie di Campionamento

Si distinguono due macro-famiglie di campionamento probabilistico:

1. **Simple Random Sampling (Campionamento Casuale Semplice):**
Ciascun oggetto della popolazione ha identica probabilità di estrazione:
 - **Campionamento Senza Reintegro (*Without Replacement*):**
Una volta selezionato, l'oggetto viene rimosso dalla popolazione. Ciascun oggetto compare al più una sola volta nel campione.
 - **Campionamento Con Reintegro (*With Replacement*):** L'oggetto estratto non viene rimosso e può essere selezionato nuovamente. La popolazione rimane identica ad ogni estrazione.
2. **Campionamento Stratificato (*Stratified Sampling*):** Si suddivide preliminarmente la popolazione in partizioni disgiunte (*strati*), ciascuna caratterizzata da una modalità specifica di classe o da un cluster naturale di densità (Figura 3.3). Successivamente, si estraggono campioni casuali da ogni singolo strato in proporzione alla sua frequenza.




Figura 3.3: Schema del Campionamento Stratificato: la popolazione viene partizionata in strati omogenei (classi o sottopopolazioni con picchi di densità); il campionamento casuale viene condotto separatamente all'interno di ogni strato, garantendo la presenza anche delle classi di minoranza.

Il campionamento stratificato è indispensabile in presenza di **distribuzioni bimodali o con forti picchi di densità** e in contesti di **classi fortemente sbilanciate** (ad esempio rilevamento frodi, dove le transazioni fraudolente sono meno dell'1% del totale).

3.4 Riduzione di Dimensionalità

Nei dataset multidimensionali moderni, gli oggetti sono descritti da centinaia o migliaia di attributi:

$$\mathbf{X} \in \mathbb{R}^{n \times p} \longrightarrow \mathbf{Z} \in \mathbb{R}^{n \times k} \quad \text{con } k \ll p \quad (3.1)$$

In tale passaggio:

- Gli oggetti (le n righe) rimangono inalterati nella loro identità ontologica.
- Le coordinate cambiano: ogni osservazione riceve k nuove coordinate sintetiche.
- La struttura geometrica sottostante viene selezionata in funzione della relazione da preservare (ad esempio la varianza globale o la separazione tra classi).

3.4.1 La Maledizione della Dimensionalità (*Curse of Dimensionality*)

All'aumentare del numero di dimensioni p , il volume dello spazio vettoriale cresce esponenzialmente rispetto al numero finito di osservazioni campionate n :

- **Iper-spazio vuoto (*Data Sparsity*):** I punti campionati diventano straordinariamente isolati nel volume dell'ipercubo unitario $[0, 1]^p$. Per preservare una densità campionaria costante al crescere delle dimensioni, la dimensione del campione n dovrebbe crescere esponenzialmente con p , condizione irrealizzabile nella pratica analitica.
- **Concentrazione delle distanze (*Distance Concentration*):** La differenza relativa tra la distanza massima e minima tra una query e qualsiasi punto del dataset tende asintoticamente a zero all'aumentare di p :

$$\lim_{p \rightarrow \infty} \frac{\text{dist}_{\max} - \text{dist}_{\min}}{\text{dist}_{\min}} = 0 \quad (3.2)$$

In spazi ad elevata dimensionalità, tutti i punti tendono ad apparire approssimativamente **equidistanti** tra loro.

Impatto Algoritmico della Maledizione della Dimensionalità

La perdita di contrasto metrico e la sparsità geometrica compromettono le prestazioni dei principali algoritmi di Data Mining:

1. **Classificazione k -Nearest Neighbors (k -NN):** Il k -NN assume che osservazioni vicine nello spazio delle feature condividano la medesima classe. Quando la distanza tra il punto query e il suo vicino più prossimo differisce in modo trascurabile da quella verso il punto più lontano, il concetto stesso di “vicinato” perde significato discriminante e le predizioni diventano sensibili al rumore casuale.
2. **Clustering basato su Partizionamento (k -Means):** L'assegnazione dei punti ai centroidi dipende dalle distanze euclidee. Con distanze uniformi, i punti risultano quasi equidistanti da tutti i baricentri dei cluster: le partizioni di Voronoi diventano instabili e l'algoritmo converge verso raggruppamenti arbitrari privi di coesione interna.
3. **Clustering basato su Densità (DBSCAN):** DBSCAN definisce i cluster attraverso ε -intorni e una soglia minima di densità MinPts. In spazi ad alta dimensionalità:

- Se il raggio ε è piccolo, gli iper-volumi locali risultano quasi sempre vuoti e la maggioranza dei punti viene etichettata erroneamente come rumore (*noise*).
 - Se si aumenta ε per catturare punti, l'iper-sfera include istanze disomogenee lungo direzioni irrilevanti, fondendo cluster distinti in un unico macro-cluster informe.
4. **Rilevamento delle Anomalie (*Outlier Detection*):** Gli approcci distance-based e density-based assumono che le anomalie risiedano in zone a densità significativamente inferiore o a distanze elevate dalla popolazione. Poiché tutte le distanze pairwise convergono verso valori simili, distinguere una vera anomalia dal rumore di fondo diventa inaffidabile.

3.4.2 Motivazioni della Riduzione di Dimensionalità

- **Visualizzazione:** Permette di ispezionare visivamente dataset a molte dimensioni proiettandoli in 2 o 3 dimensioni.
- **Compressione:** Riduce drasticamente l'occupazione di memoria e il tempo di elaborazione algoritmica.
- **Riduzione del rumore e multicollinearità:** Elimina feature ridondanti o prive di potere informativo per il task.

Avvertenza di Rischio

Una rappresentazione compressa a dimensionalità ridotta rischia di mascherare o cancellare eventi rari, cluster minoritari o dettagli critici per specifici compiti predittivi.

3.5 Selezione delle Feature (Feature Subset Selection)

La selezione delle feature ha l'obiettivo di individuare il sottoinsieme minimo di attributi sufficiente per l'analisi, rimuovendo:

1. **Feature Irrilevanti (*Irrelevant Features*):** Attributi che non veicolano informazione utile al task di mining (ad esempio l'ID studente o il CAP per prevedere il voto di laurea).

2. **Feature Ridondanti (*Redundant Features*)**: Attributi che duplicano in tutto o in parte l'informazione già presente in altre variabili (ad esempio prezzo di acquisto di un bene e relativa imposta sul valore aggiunto versata).

3.5.1 Tassonomia dei Metodi di Selezione

La letteratura distingue tre approcci metodologici principali (Figura 3.4):




Figura 3.4: Confronto schematico tra le tre famiglie di selezione delle feature: Filter, Wrapper ed Embedded.

3.5.2 Strategie Wrapper

Dato che lo spazio di ricerca esaustivo tra tutti i possibili sottoinsiemi di p feature ha cardinalità 2^p (per $p = 20$ esistono già oltre 1 milione di combinazioni), i metodi Wrapper adottano euristiche greedy:

- **Forward Selection:** Si parte dall'insieme vuoto $\emptyset$. Ad ogni iterazione si valuta l'aggiunta di ciascuna feature residua e si include quella che apporta il massimo incremento di accuratezza al modello. L'algoritmo si arresta quando l'incremento prestazionale scende sotto una soglia prefissata.
- **Backward Elimination:** Si parte dall'insieme completo di tutte le p feature. Ad ogni iterazione si rimuove la feature la cui esclusione provoca il minor decremento (o addirittura un miglioramento) nelle performance del modello.

3.6 Creazione di Feature (Feature Creation)

La **creazione di nuove feature** consiste nella definizione di attributi sintetici capaci di catturare le correlazioni o le proprietà rilevanti del fenomeno in modo molto più efficace ed esplicito rispetto alle feature grezze:

- **Feature Construction guidata dal dominio:** Combinazione algebrica di variabili con significato semantico.

Esempio 3.6.1 (Indice di Efficienza del Lavoratore). In un'analisi di produttività aziendale, un dipendente è descritto da: compiti completati mensilmente, ore lavorate mensili e tempo standard stimato per completare ciascun compito. Invece di usare i tre valori grezzi separatamente, si introduce l'attributo aggregato:

$$\text{Efficienza} = \frac{\text{Ore effettivamente impiegate per completare i task}}{\text{Ore standard mediamente stimate per completare i task}} \quad (3.3)$$

- **Feature da Dati Non Strutturati (Computer Vision):** Nelle immagini, i valori grezzi dei singoli pixel contigui non sono adatti direttamente agli algoritmi lineari di classificazione. Si estraggono feature ad alto livello (aree a forte gradiente di contrasto, densità di bordi, istogrammi di colore, mappe di calore di occhi e naso per il riconoscimento facciale).
- **Feature Projection (Proiezione):** Trasformazione matematica globale dallo spazio originale $\mathbb{R}^p$ a un sottospazio $\mathbb{R}^k$ ($k < p$). Tra i metodi lineari principali figurano la **Principal Component Analysis (PCA)** e la **Singular Value Decomposition (SVD)**; tra i metodi non lineari e supervisionati rientrano la *Linear Discriminant Analysis* (LDA), la *Non-Negative Matrix Factorization* (NMF) e gli *Autoencoder* neurali.

3.7 Principal Component Analysis (PCA)

La **Principal Component Analysis** (PCA) è la tecnica non supervisionata fondamentale per la riduzione lineare della dimensionalità.

3.7.1 Intuizione Geometrica e Obiettivi

Nelle applicazioni reali le feature numeriche sono spesso fortemente correlate tra loro. Si pensi a:

- Spese di affitto, stipendio mensile e spese per generi alimentari.
- Depositi bancari, stipendio e anzianità lavorativa.

La PCA determina un nuovo sistema ortogonale di coordinate ruotato rispetto a quello originario, con le seguenti proprietà:

1. La **prima componente principale (PC1)** si sviluppa lungo la direzione dello spazio che massimizza la varianza (dispersione) dei dati proiettati.
2. La **seconda componente principale (PC2)** è rigidamente **ortogonale** a PC1 e, con tale vincolo geometrico, cattura la massima quota della varianza residua.
3. Ciascuna componente successiva PC_i è mutuamente ortogonale a tutte le precedenti e massimizza la dispersione rimanente.

3.7.2 Procedura Algoritmica Formale in 5 Passi

Dato un dataset rappresentato da una matrice $\mathbf{D} \in \mathbb{R}^{m \times n}$ con m osservazioni e n attributi continui:

Algorithm 1: Calcolo delle Componenti Principali (PCA)

Dati: Matrice dei dati originaria $\mathbf{D} \in \mathbb{R}^{m \times n}$, numero di componenti desiderate $k \leq n$.

Risultato: Matrice trasformata ridotta $\mathbf{Z} \in \mathbb{R}^{m \times k}$.

// Passo 1: Centratura e Standardizzazione

1 Calcola la media campionaria di ciascuna colonna $\bar{x}_j = \frac{1}{m} \sum_{i=1}^m x_{ij}$

2 Sottrai la media per ottenere la matrice centrata $\mathbf{C} \in \mathbb{R}^{m \times n}$:

$$c_{ij} = x_{ij} - \bar{x}_j$$

3 (Opzionale/Raccomandato): Dividi per la deviazione standard s_j se le unità di misura differiscono

// Passo 2: Calcolo della Matrice di Covarianza

4 Calcola la matrice di covarianza campionaria $\mathbf{V} \in \mathbb{R}^{n \times n}$:

$$\mathbf{V} = \frac{1}{m-1} \mathbf{C}^T \mathbf{C} \quad (3.4)$$

La matrice $\mathbf{V}$ è quadrata, simmetrica ($v_{ij} = v_{ji}$) e semidefinita positiva. Gli elementi sulla diagonale principale rappresentano le varianze degli n attributi

// Passo 3: Risoluzione del Problema agli Autovalori

5 Determina gli autovettori ortonormali $\mathbf{e}_j$ e i corrispondenti autovalori λ_j risolvendo l'equazione caratteristica:

$$\mathbf{V} \mathbf{e}_j = \lambda_j \mathbf{e}_j \quad \text{con } \|\mathbf{e}_j\|_2 = 1 \quad (3.5)$$

// Passo 4: Ordinamento e Selezione delle k Componenti Principali

6 Ordina gli autovalori in ordine decrescente: $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$

7 Seleziona i primi k autovettori corrispondenti $\{\mathbf{e}_1, \dots, \mathbf{e}_k\}$ e costruisci la matrice di proiezione $\mathbf{P} \in \mathbb{R}^{n \times k}$ avente come colonne gli autovettori scelti

// Passo 5: Proiezione dei Dati nel Nuovo Spazio

8 Proietta la matrice centrata nello spazio a dimensionalità ridotta:

$$\mathbf{Z} = \mathbf{C} \mathbf{P} \in \mathbb{R}^{m \times k} \quad (3.6)$$

3.7.3 Significato della Covarianza e degli Autovalori

- **Segno della Covarianza:** Il segno di $\text{Cov}(x, y)$ indica la direzione della variazione congiunta:
 - $\text{Cov}(x, y) > 0$: x e y tendono ad aumentare o diminuire simultaneamente (ad es. ore di studio e voto conseguito).
 - $\text{Cov}(x, y) < 0$: all'aumentare di x , y tende a diminuire.
 - $\text{Cov}(x, y) \approx 0$: assenza di relazione lineare tra le due variabili.
- **Autovettori e Autovalori:** Gli autovettori individuano le **direzioni degli assi di massima varianza** (le Componenti Principali). Ciascun autovalore λ_j quantifica la quota assoluta di varianza spiegata dalla rispettiva componente PC_j .
- **Rapporto di Varianza Spiegata:** La percentuale di varianza spiegata dalla componente j -esima è pari a:

$$\text{Explained Variance Ratio}_j = \frac{\lambda_j}{\sum_{i=1}^n \lambda_i} \quad (3.7)$$




Figura 3.5: Scree Plot calcolato sulle 4 feature numeriche del dataset Iris. La prima componente principale (PC1) cattura il 73.0% della varianza globale, mentre con le prime due componenti (PC1 e PC2) si raggiunge il 95.8% della varianza complessiva, rendendo sufficiente la rappresentazione bidimensionale.




Figura 3.6: Proiezione bidimensionale PCA del dataset Iris lungo le prime due componenti principali (PC1 e PC2). Lo spazio originale quadridimensionale viene sintetizzato senza etichette nel pre-processing, preservando la separazione lineare netta della specie Setosa e la differenziazione morfologica tra Versicolor e Virginica.

3.7.4 Laboratorio Python: Principal Component Analysis (PCA) e Scree Plot

Esegui questo blocco nel Notebook Interattivo

Notebook: `2_feature_engineering_...ipynb` [Apri su Jupyter Lab]

Server locale: `http://localhost:8888` (comando di avvio: `docker compose up jupyter`)

Nel notebook didattico `2_feature_engineering_...ipynb`, la riduzione di dimensionalità mediante PCA, il calcolo della varianza spiegata e il tracciamento dello Scree Plot sono realizzati con Scikit-learn come illustrato nel Listing 3.1:

Listing 3.1: Esecuzione di PCA, analisi degli autovalori e Scree Plot con Scikit-learn.

```
1 import pandas as pd
2 import numpy as np
3 import matplotlib.pyplot as plt
```

```

4 from sklearn.decomposition import PCA
5
6 df = pd.read_csv('../data_notebook/data/correct_tips.csv'
7                   , index_col=0)
8 numeric_cols = ['total_bill', 'tip', 'size', 'age']
9 X = df[numeric_cols]
10
11 # 1. Istanziamento ed esecuzione della PCA completa
12 pca = PCA()
13 X_pca = pca.fit_transform(X)
14
15 # 2. Autovalori (varianza spiegata) e percentuale di
16   varianza per componente
17 eigenvalues = pca.explained_variance_
18 var_ratio = pca.explained_variance_ratio_
19 cum_var = np.cumsum(var_ratio)
20
21 for i, (eig, ratio, c) in enumerate(zip(eigenvalues,
22                                       var_ratio, cum_var), 1):
23     print(f"PC{i}: Autovalore={eig:.3f} | Varianza={
24           ratio*100:.1f}% | Cumulata={c*100:.1f}%")
25
26 # 3. Scree Plot degli autovalori
27 plt.figure(figsize=(7, 4))
28 plt.plot(range(1, len(eigenvalues) + 1), eigenvalues,
29          marker='o', linestyle='--', color='b')
30 plt.title("Scree Plot: Autovalori delle Componenti
31           Principali")
32 plt.xlabel("Componente Principale")
33 plt.ylabel("Autovalore (Varianza spiegata)")
34 plt.grid(True)
35 plt.show()

```

3.8 Gestione dei Valori Mancanti e Anomali (Cleaning)

3.8.1 Tipologie e Cause di Valori Anomali

I dati grezzi contengono frequentemente imperfezioni dovute a malfunzionamento di sensori, rifiuti di risposta in indagini campionarie, errori di digitazione o modifiche strutturali nelle procedure di raccolta:

- **Valori Mancanti (*Missing*):** Campi non pervenuti, omessi o codificati esplicitamente come NULL o NaN.
- **Valori Sconosciuti (*Unknown*):** Campi valorizzati formalmente ma privi di reale significato semantico nel dominio di riferimento.
- **Valori Non Validi (*Invalid*):** Dati che violano i vincoli di integrità del dominio (ad esempio un'età negativa, un punteggio esame superiore al massimo ammissibile o codici fiscali malformati).

3.8.2 Strategie Metodologiche di Trattamento dei Dati Mancanti

Nelle applicazioni pratiche di Data Mining, la gestione dei missing value si articola in tre macro-approcci complementari:

1. Eliminazione (*Data / Attribute Removal*):

- *Eliminazione delle Istanze (Listwise / Case Deletion)*: Rimozione dell'intero record che presenta uno o più attributi nulli. È lecita soltanto se la proporzione di missing è ridottissima ($< 3 \div 5\%$) e i valori sono assenti completamente a caso (*Missing Completely at Random* - MCAR). Se l'assenza dipende da altri fattori (es. clienti ad alto reddito che omettono lo stipendio), l'eliminazione introduce una grave distorsione di selezione (*selection bias*).
- *Eliminazione dell'Attributo (Feature Deletion)*: Rimozione dell'intera colonna. È raccomandata quando l'attributo presenta percentuali di assenza eccessive (superiori al $50 \div 60\%$) e non possiede una rilevanza predittiva insostituibile per il task.
- *Eliminazione a Coppie (Pairwise Deletion)*: Utilizzata nel calcolo di statistiche bivariati (come la covarianza o la matrice di correlazione), escludendo dal calcolo solo le singole coppie che contengono un valore nullo, massimizzando l'impiego dei dati disponibili.

2. Stima e Imputazione dei Valori (*Value Imputation*):

- **Sostituzione con Stimatori Globali (Media, Mediana, Moda):** La media aritmetica si impiega per variabili numeriche simmetriche; la mediana è lo stimatore raccomandato per distribuzioni asimmetriche con code pesanti e presenza di outlier; la moda si applica alle feature categoriche nominali od ordinali. *Criticità*: riduce artificialmente la varianza della feature e attenua le covarianze tra variabili distinte.

- **Campionamento dalla Distribuzione Empirica:** Il valore mancante viene rimpiazzato estraendo casualmente un'osservazione secondo la distribuzione di probabilità empirica dei valori validi osservati nel dataset. *Vantaggio:* preserva intatta la dispersione originale, la varianza e l'istogramma empirico della feature.
- **Imputazione Stratificata per Segmento o Cluster:** I dati vengono partizionati in gruppi omogenei (ad esempio per classe target, professione o tramite un algoritmo di clustering come k-means); il missing viene quindi rimpiazzato dalla mediana o media calcolata esclusivamente all'interno dello strato o cluster di appartenenza (es. stimare lo stipendio mancante usando la mediana della sola qualifica professionale del soggetto).
- **Modello Predittivo Supervisionato:** L'attributo affetto da valori mancanti viene trattato come variabile target Y . Si addestra un modello predittivo (albero di decisione, regressione o k -NN) impiegando gli attributi completi come predittori per stimare il valore incognito con la massima accuratezza contestuale.

3. **Tolleranza e Gestione Algoritmica Diretta (*Ignore Missing Values*):** Molti algoritmi avanzati gestiscono direttamente i missing durante la fase di apprendimento, senza richiedere una manipolazione preventiva dei dati:

- *Alberi di Decisione (es. C4.5):* Nelle valutazioni dei nodi, l'algoritmo distribuisce le istanze con valore mancante proporzionalmente su tutti i rami figli in base alle frequenze relative osservate, oppure crea un ramo dedicato (*missing branch*).
- *Regole Associative:* Nelle matrici transazionali binarie, un valore non presente corrisponde intrinsecamente all'assenza dell'item (0), rendendo l'omissione parte naturale della semantica del modello.




Figura 3.7: Panoramica schematica delle strategie di gestione dei missing value: eliminazione di record o attributi versus imputazione.

3.8.3 Rilevamento e Trattamento di Outlier Univariati

Nel pre-processing si utilizzano due regole formali (Figura 3.8):

1. Regola del Range Interquartile (Tukey IQR Fences):

$$\text{IQR} = Q_3 - Q_1, \quad L = Q_1 - 1.5 \times \text{IQR}, \quad U = Q_3 + 1.5 \times \text{IQR} \quad (3.8)$$


Un'osservazione x è classificata come outlier se $x < L$ oppure $x > U$.

- *Sostituzione (Winsorizing)*: I valori inferiori a L vengono sostituiti con L , quelli superiori a U vengono sostituiti con U .
- *Sostituzione con la mediana*: Il valore anomalo viene rimpiazzato direttamente con Q_2 .

2. Approccio Parametrico basato su Z-Score: Per dati distribuiti approssimativamente secondo una normale:

- Il 95% delle osservazioni ricade in $[-1.96, +1.96]$.
- Il 99% delle osservazioni ricade in $[-2.58, +2.58]$.
- La soglia canonica per identificare valori anomali estremi è posta a $|z| > 3.29$ (probabilità $< 0.1\%$).
- *Sostituzione del valore anomalo*: Si tronca il valore x al punteggio corrispondente a $z = \pm 3.0$ (estremità della campana gaussiana), oppure si sostituisce con il valore medio ($z = 0$).

A) Regola Non Parametrica del Range Interquartile (Tukey IQR Fences)



B) Regola Parametrica Z-Score (Distribuzione Gaussiana $\mathcal{N}(\mu, \sigma^2)$)




Figura 3.8: Confronto tra i metodi di rilevamento degli outlier univariati: Regola di Tukey basata su IQR e approccio parametrico basato su Z-Score.

3.9 Discretizzazione e Binarizzazione

3.9.1 Definizione e Vantaggi della Discretizzazione

La **discretizzazione** è il processo di trasformazione di un attributo continuo in un attributo ordinale discreto, mappando un insieme infinito di valori reali in un numero finito k di categorie o intervalli (*bins*).

- **Semplicità interpretativa:** Trasforma serie numeriche sparse in classi leggibili (es. {Giovane, Adulto, Anziano}).
- **Robustezza e stabilità:** Attenua l'influenza di piccoli errori di misurazione e di singoli outlier.
- **Requisito algoritmico:** Alcuni algoritmi (come le regole associative e determinati modelli bayesiani o ad albero) richiedono esplicitamente variabili categoriali discrete.

3.9.2 Discretizzazione Non Supervisionata (Unsupervised Binning)

Si applica quando non si dispone di un'etichetta target di classe per guidare la scelta dei confini:

1. **Natural Binning (Equal-Width Binning):** Divide l'escursione totale dei dati in k intervalli di ampiezza costante δ :

$$\delta = \frac{x_{\max} - x_{\min}}{k} \quad (3.9)$$

Un elemento x_j appartiene alla classe i ($i \in \{0, \dots, k-1\}$) se:

$$x_j \in [x_{\min} + i\delta, x_{\min} + (i+1)\delta) \quad (3.10)$$

Criticità: Se la distribuzione presenta asimmetria o outlier estremi, la maggior parte dei campioni si concentra in pochissimi intervalli, lasciando i restanti bin vuoti o quasi disabitati.

2. **Equal-Frequency (Quantile) Binning:** Ordina gli elementi e definisce k intervalli tali che ciascuno contenga all'incirca lo stesso numero di osservazioni $f = \frac{N}{k}$: Un elemento x_i (nell'ordinamento crescente con indice $i \in \{0, \dots, N-1\}$) appartiene alla classe j se:

$$j \times f \leq i < (j+1) \times f \quad (3.11)$$

Vantaggio: Massimizza l'entropia della partizione ed evita bin vuoti.

3.9.3 Criteri per la Scelta del Numero Ottimale di Classi

La scelta del parametro k determina il compromesso tra fedeltà distributiva e leggibilità:

- Se k è troppo piccolo: perdita marcata di informazione sulla reale forma distributiva.
- Se k è troppo grande: eccessiva frammentazione con forte rumore campionario.

I criteri analitici raccomandati in letteratura statistica sono:

- **Regola di Sturges (1929):** Adatta per distribuzioni simmetriche unimodali:

$$k = 1 + \frac{10}{3} \log_{10}(N) \approx 1 + 3.322 \log_{10}(N) = 1 + \log_2(N) \quad (3.12)$$

- **Regola di Scott (1979):** Calcola direttamente l'ampiezza ottimale dei bin h in funzione della deviazione standard s :

$$h = \frac{3.5 \times s}{\sqrt[3]{N}} \quad (3.13)$$

3.9.4 Discretizzazione Supervisionata: Metodo Basato sull'Entropia

Nel contesto della classificazione supervisionata, la discretizzazione di una feature continua X ha come obiettivo esplicito la **massimizzazione della purezza delle classi** all'interno di ciascun intervallo, minimizzando l'entropia condizionata rispetto all'etichetta Y . L'algoritmo procede solitamente con un approccio greedy bipartizionale:

1. Si valuta ogni possibile valore di soglia T lungo il dominio ordinato di X .
2. Per ogni split nei due sotto-intervalli $S_1 = \{x \leq T\}$ e $S_2 = \{x > T\}$, si calcola l'entropia pesata:

$$E(X, T) = \frac{|S_1|}{|S|} \text{Entropy}(S_1) + \frac{|S_2|}{|S|} \text{Entropy}(S_2) \quad (3.14)$$

dove l'entropia di un sottoinsieme S rispetto alle C classi è $\text{Entropy}(S) = -\sum_{c=1}^C p_c \log_2(p_c)$.

3. Si seleziona la soglia T^* che minimizza $E(X, T)$ (massimizzando il Guadagno Informativo o *Information Gain*).
4. Il procedimento viene iterato ricorsivamente sull'intervallo con entropia peggiore (più impuro) finché non si raggiunge il numero prefissato di classi o un criterio di stop basato sul principio del Minimum Description Length (MDL).

3.9.5 Binarizzazione

La **binarizzazione** mappa un attributo continuo (previa discretizzazione) o categorico in una o più variabili binarie (0 o 1). In letteratura e nei sistemi di Data Mining si distinguono due paradigmi principali:

1. **Codifica Binaria Compatta Posizionale (*Integer-to-Binary*):**

Un attributo categorico con m modalità distinte viene mappato su interi $\{0, 1, \dots, m-1\}$ e convertito nella relativa rappresentazione binaria posizionale impiegando $k = \lceil \log_2(m) \rceil$ bit.

- *Esempio:* Per un attributo con $m = 4$ stati (es. Rosso, Blu, Verde, Giallo), sono necessari $\lceil \log_2(4) \rceil = 2$ bit:

$$\text{Rosso} \rightarrow 00_2, \quad \text{Blu} \rightarrow 01_2, \quad \text{Verde} \rightarrow 10_2, \quad \text{Giallo} \rightarrow 11_2 \quad (3.15)$$

- *Criticità ed Effetti Collaterali:* Sebbene riduca al minimo il numero di colonne, questa codifica introduce **relazioni metriche e correlazioni spurie**:
 - *Distanza distorta:* La distanza di Hamming tra Rosso (00) e Blu (01) è pari a 1, mentre tra Rosso (00) e Giallo (11) è pari a 2. Il modello apprende erroneamente che Giallo è “più lontano” da Rosso rispetto a Blu, falsando il significato originario di una variabile nominale priva di ordinamento.
 - *Falsi pattern di correlazione:* La condivisione accidentale di singoli bit (es. il primo bit uguale a 1 per Verde e Giallo) induce correlazioni numeriche artificiali che ingannano gli stimatori di machine learning.

2. **Binarizzazione Asimmetrica / One-Hot Encoding:** Per un attributo a m modalità distinte, si introducono m distinte variabili indicatrici binarie $x_1, \dots, x_m$, dove $x_j = 1$ se l’osservazione possiede la modalità j , e $x_j = 0$ altrimenti (Tabella 3.1).

- *Proprietà Geometriche:* Tutte le modalità risultano ortogonali nello spazio euclideo $\mathbb{R}^m$ e reciprocamente equidistanti ($\|\mathbf{x}_i - \mathbf{x}_j\|_2 = \sqrt{2}$ per $i \neq j$), preservando fedelmente l’assoluta assenza di gerarchia della variabile nominale.
- *Requisito Fondamentale per l’Association Analysis (Regole Associative):* Negli algoritmi per pattern frequenti (come Apriori o FP-Growth), i record sono modellati come insiemi di item binari asimmetrici:

- La presenza dell’item (1, ad esempio l’acquisto di un determinato prodotto) possiede valore semantico discriminante e contribuisce al calcolo di supporto e confidenza.
- L’assenza dell’item (0) costituisce lo stato naturale di sfondo non informativo (in un catalogo di 50 000 articoli, ogni transazione contiene pochissimi oggetti).
- Con variabili binarie simmetriche o codifiche compatte posizionali, gli algoritmi estrarrebbero un numero sterminato di associazioni prive di valore pratico basate sulla non-compresenza simultanea (es. “chi non compra caviale non compra elicotteri”). La One-Hot encoding garantisce che ciascun valore sia trattato come un item asimmetrico indipendente.

Valore Categorico	Indice	x_1	x_2	x_3	x_4	x_5
awful	0	1	0	0	0	0
poor	1	0	1	0	0	0
OK	2	0	0	1	0	0
good	3	0	0	0	1	0
great	4	0	0	0	0	1

Tabella 3.1: Conversione di un attributo qualitativo con $m = 5$ modalità in 5 attributi binari asimmetrici (One-Hot Encoding).

3.9.6 Laboratorio Python: Discretizzazione ed Encoding Categorico

Esegui questo blocco nel Notebook Interattivo

Notebook: `2_feature_engineering_...ipynb` [Apri su Jupyter Lab]

Server locale: `http://localhost:8888` (comando di avvio: `docker compose up jupyter`)

Nel notebook didattico `2_feature_engineering_...ipynb`, la discretizzazione numerica e le strategie di codifica categorica (One-Hot Encoding e Target Encoding) sono implementate con Scikit-learn come mostrato nel Listing 3.2:

Listing 3.2: Discretizzazione con KBinsDiscretizer ed Encoding (One-Hot e Target Encoding) con Scikit-learn.

```

1 import pandas as pd
2 from sklearn.preprocessing import KBinsDiscretizer,
   OneHotEncoder, TargetEncoder
3
4 df = pd.read_csv('./data_notebook/data/correct_tips.csv',
   index_col=0)
5
6 # 1. Discretizzazione continua -> ordinale (Equal-Width
   vs Equal-Frequency)
7 kbins_uniform = KBinsDiscretizer(n_bins=4, encode='
   ordinal', strategy='uniform')
8 df['bill_uniform'] = kbins_uniform.fit_transform(df[['
   total_bill']])
9
10 kbins_quantile = KBinsDiscretizer(n_bins=4, encode='
   ordinal', strategy='quantile')
11 df['bill_quantile'] = kbins_quantile.fit_transform(df[['
   total_bill']])
12 print("Conteggi bin uniformi:\n", df['bill_uniform'].
   value_counts())
13
14 # 2. One-Hot Encoding per variabili categoriche nominali
15 ohe = OneHotEncoder(handle_unknown='ignore',
   sparse_output=False)
16 ohe_day = ohe.fit_transform(df[['day']])
17 df_ohe = pd.DataFrame(ohe_day, columns=ohe.
   get_feature_names_out(['day']))
18 print("Feature One-Hot generate:\n", df_ohe.head(3))
19
20 # 3. Target Encoding supervisionato
21 target_encoder = TargetEncoder(smooth="auto")
22 # Calcola la stima condizionata lisciata della variabile
   target numerica ('tip')
23 df['day_target_encoded'] = target_encoder.fit_transform(
   df[['day']], df['tip'])
24 print(df[['day', 'day_target_encoded']].drop_duplicates
   ())

```

3.10 Trasformazione degli Attributi e Stabilità della Varianza

3.10.1 Motivazioni e Proprietà Formali

Una trasformazione di attributo è una funzione $T : \mathcal{X} \rightarrow \mathcal{Y}$ che associa a ciascun valore originario x un nuovo valore sostitutivo $y = T(x)$. Le proprietà desiderabili di una buona trasformazione T sono:

1. **Conservazione dell'informazione essenziale:** Preservare l'ordinamento naturale degli oggetti ($x_a < x_b \implies T(x_a) < T(x_b)$ per trasformazioni strettamente monotone).
2. **Risoluzione di criticità distributive:** Rendere le distribuzioni unimodali e simmetriche, eliminare code pesanti ed eliminare la dispersione non omogenea.
3. **Linearizzazione delle relazioni:** Rendere approssimativamente lineari relazioni bivariati originariamente esponenziali o quadratiche.
4. **Regolarità analitica:** Funzioni continue, differenziabili e invertibili su tutto il dominio applicativo.

3.10.2 Famiglia delle Trasformazioni Esponenziali e Logaritmiche

La forma generale parametrica di trasformazione per $x > 0$ è definita da:

$$T_p(x) = \begin{cases} ax^p + b & \text{se } p \neq 0 \\ c \log(x) + d & \text{se } p = 0 \end{cases} \quad (3.16)$$

In base al parametro reale p :

- **Trasformazione Lineare ($p = 1$):** Preserva integralmente forma, skewness e correlazioni; consente il cambio di scala o di unità di misura:
 - Conversione monetaria: Lire = $1936.27 \times$ Euro ($p = 1, a = 1936.27, b = 0$).
 - Conversione termometrica: $^{\circ}\text{C} = \frac{5}{9}(^{\circ}\text{F} - 32) = \frac{5}{9}^{\circ}\text{F} - \frac{160}{9}$ ($p = 1, a = 5/9, b = -160/9$).

- **Trasformazione Logaritmica** ($p = 0$): Applicabile a valori positivi $x > 0$ nella forma generale $T(x) = c \log(x) + d$. Comprime le code destre di distribuzioni log-normali fortemente asimmetriche, stabilizzando la varianza e riducendo l’impatto dei picchi eccezionali.

Nota 3.10.1 (Logaritmo e Stagionalità). La trasformazione logaritmica non elimina la stagionalità intrinseca di una serie temporale, bensì ne comprime l’ampiezza delle oscillazioni quando queste crescono proporzionalmente al livello medio della serie.

Esempio 3.10.1 (Trasformazione Logaritmica su Dati Sparsi: Esempio Bar e Birra). Si consideri il dataset didattico introdotto a lezione (Tabella 3.2), in cui si analizza il guadagno (*Gain*) derivante dalla vendita di marche di birra in diversi locali commerciali.

Bar	Marca Birra	Gain Originale	Gain Trasformato	$\log_{10}(\text{Gain})$
Bar A	Bud	20		1.3010
Bar A	Becks	10000		4.0000
Bar C	Bud	300		2.4771
Bar D	Bud	400		2.6021
Bar D	Becks	5		0.6990
Bar E	Becks	120		2.0792
Bar E	Bud	120		2.0792
Bar F	Bud	11000		4.0414
Bar G	Bud	1300		3.1139
Bar H	Bud	3200		3.5051
Bar H	Becks	1000		3.0000
Bar I	Bud	135		2.1303

Tabella 3.2: Effetto della trasformazione logaritmica ($\log_{10}$) sul fatturato di birra in diversi bar: compressione della dispersione estrema.


Diagnosi Statistica e Compressione dei Valori Sparsi:

- *Serie grezza*: Media campionaria $\bar{x} \approx 2481.82$, Deviazione standard $s \approx 4079.02$, Minimo 5, 1° Quartile 120, Mediana 400, 3° Quartile 2250, Massimo 11000. La deviazione standard supera sensibilmente la media ($s > \bar{x}$) e il valore massimo supera il minimo di oltre tre ordini di grandezza ($2200\times$). Lo spazio dei dati è dominato da pochissimi valori enormi (“*Data are sparse!*”), che distorcerebbero pesantemente il calcolo delle distanze euclidee o i residui dei modelli di regressione.

- *Serie trasformata*: Applicando la funzione $y = \log_{10}(\text{Gain})$, l'intera escursione numerica viene ricondotta nell'intervallo compreso tra 0.6990 e 4.0414. Le differenze moltiplicative (ordini di grandezza) diventano distanze lineari omogenee, stabilizzando la varianza e ripristinando la simmetria distributiva (Figura 3.9).

A) Scala Naturale Lineare (Fatturato Grezzo $x \in [5, 11000]$) — Spazio Iper-Sparso

Diagnosi: “Data are sparse!” — Varianza dominata da pochissimi picchi ($s \approx 4079 > \bar{x}$)



B) Scala Logaritmica $\log_{10}(\text{Gain}) \in [0.70, 4.04]$ — Varianza Stabilizzata e Spazio Omogeneo

Distribuzione continua e ben distanziata su tutto il dominio $[0.70, 4.04]$




Figura 3.9: Effetto di compressione e regolarizzazione della trasformazione logaritmica sui dati Bar/Birra: passaggio da uno spazio vuoto e dominato da outlier a una distribuzione omogenea e a varianza stabilizzata.

- **Trasformazione Radice Quadrata** ($p = 1/c$ con $c = 2$): Utilizzata tipicamente per stabilizzare la varianza in processi di conteggio modellabili mediante distribuzioni di Poisson (dove la varianza teorica coincide con la media).
- **Trasformazione Reciproca** ($p < 0$, tipicamente $p = -1$): Indicata per serie temporali o variabili in cui la varianza cresce in modo quadratico o super-lineare rispetto al valore atteso.

3.10.3 Metodi di Normalizzazione

La normalizzazione uniforma la scala di variazione delle feature numeriche, evitando che attributi con magnitudo numerica elevata dominino impropriamente il calcolo delle distanze:

1. **Min-Max Normalization** (Scalatura su intervallo $[v'_{\min}, v'_{\max}]$):

$$v' = \frac{v - \min_A}{\max_A - \min_A} \times (v'_{\max} - v'_{\min}) + v'_{\min} \quad (3.17)$$

Nel caso canonico di scalatura sull'intervallo unitario $[0, 1]$:

$$v' = \frac{v - \min_A}{\max_A - \min_A} \quad (3.18)$$

2. **Z-Score Standardization (Standardizzazione a media nulla e varianza unitaria):**

$$v' = \frac{v - \bar{x}_A}{s_A} \quad (3.19)$$

dove $\bar{x}_A$ è la media campionaria e s_A è la deviazione standard. È robusta rispetto a future istanze esterne all'intervallo osservato.

3. **Decimal Scaling (Normalizzazione per Scalatura Decimale):**

Sposta il separatore decimale dividendo tutti i valori per la potenza di 10 sufficiente a garantire che il massimo valore assoluto sia strettamente inferiore a 1:

$$v' = \frac{v}{10^j} \quad (3.20)$$

dove j è il minimo intero positivo tale che $\max(|v'|) < 1$.

Esempio 3.10.2 (Scalatura Decimale). Si consideri la serie di valori:

$$V = \{-10, 201, 301, -401, 501, 601, 701\}$$

- Massimo valore assoluto: $m = \max(|v|) = 701$.
- Poiché $701 < 1000 = 10^3$, il minimo intero è $j = 3$.
- Dividendo per 1000, la serie normalizzata risulta:

$$V' = \{-0.01, 0.201, 0.301, -0.401, 0.501, 0.601, 0.701\} \quad (3.21)$$

3.10.4 Laboratorio Python: Standardizzazione vs Scalatura Min-Max e De-standardizzazione

Esegui questo blocco nel Notebook Interattivo

Notebook: `2_feature_engineering_...ipynb` [Apri su Jupyter Lab]

Server locale: `http://localhost:8888` (comando di avvio: `docker compose up jupyter`)

Nel notebook didattico `2_feature_engineering_...ipynb`, il confronto pratico tra `StandardScaler` e `MinMaxScaler`, unitamente al ripristino dei valori originali mediante `inverse_transform`, è implementato come riportato nel Listing 3.3:

Listing 3.3: Standardizzazione con StandardScaler, scalatura Min-Max e ripristino con inverse_transform.

```
1 import pandas as pd
2 from sklearn.preprocessing import StandardScaler,
  MinMaxScaler
3
4 df = pd.read_csv('./data_notebook/data/correct_tips.csv',
5                  , index_col=0)
6
7 # 1. Z-Score Standardization (media = 0, dev.std = 1)
8 scaler_std = StandardScaler()
9 df_standardized = df.copy()
10 df_standardized[num_cols] = scaler_std.fit_transform(df[
11     num_cols])
12
13 # 2. Min-Max Normalization (intervallo [0, 1])
14 scaler_minmax = MinMaxScaler()
15 df_normalized = df.copy()
16 df_normalized[num_cols] = scaler_minmax.fit_transform(df
17     [num_cols])
18
19 # 3. De-standardizzazione e ripristino della scala
20     fisica originale
21 df_reconstructed = df_standardized.copy()
22 df_reconstructed[num_cols] = scaler_std.
23     inverse_transform(df_standardized[num_cols]).round(2)
24 print("Valori ripristinati con inverse_transform:\n",
25     df_reconstructed[num_cols].head(3))
```

3.10.5 Laboratorio Python: Riduzione Non Lineare con t-SNE e Confronto con PCA

Esegui questo blocco nel Notebook Interattivo

Notebook: 2_feature_engineering_...ipynb [Apri su Jupyter Lab]

Server locale: <http://localhost:8888> (comando di avvio: docker compose up jupyter)

Nel notebook didattico `2_feature_engineering_...ipynb`, la mappatura non lineare basata su *t*-SNE e il confronto visivo con PCA sono strutturati come illustrato nel Listing 3.4:

Listing 3.4: Mappatura non lineare con t-SNE e confronto visivo bidimensionale con PCA in Scikit-learn.

```
1 import pandas as pd
2 import seaborn as sns
3 import matplotlib.pyplot as plt
4 from sklearn.decomposition import PCA
5 from sklearn.manifold import TSNE
6
7 df = pd.read_csv('./data_notebook/data/correct_tips.csv',
8                 , index_col=0)
9 num_cols = ['total_bill', 'tip', 'age', 'size']
10 X = df[num_cols]
11
12 # 1. Proiezione lineare globale con PCA (2 componenti)
13 X_pca = PCA(n_components=2).fit_transform(X)
14 df['pca_1'], df['pca_2'] = X_pca[:, 0], X_pca[:, 1]
15
16 # 2. Proiezione non lineare di vicinato con t-SNE
17 tsne = TSNE(n_components=2, perplexity=25, random_state
18             =42, init='pca', learning_rate='auto')
19 X_tsne = tsne.fit_transform(X)
20 df['tsne_1'], df['tsne_2'] = X_tsne[:, 0], X_tsne[:, 1]
21
22 # 3. Confronto visivo delle due rappresentazioni a 2D
23 fig, axes = plt.subplots(1, 2, figsize=(13, 5))
24 sns.scatterplot(data=df, x='pca_1', y='pca_2', hue='time',
25                , style='sex', ax=axes[0])
26 axes[0].set_title("Rappresentazione Globale Lineare: PCA
27                  (2D)")
28
29 sns.scatterplot(data=df, x='tsne_1', y='tsne_2', hue='
30                time', style='sex', ax=axes[1])
31 axes[1].set_title("Rappresentazione di Vicinato Non
32                  Lineare: t-SNE (2D)")
33 plt.tight_layout()
34 plt.show()
```

Capitolo 4

Similarità dei Dati e Introduzione all'Analisi dei Cluster

4.1 Prossimità: Similarità e Dissimilarità

Ogni tecnica di Data Mining che coinvolge il confronto tra oggetti — dalla classificazione al clustering, dal recupero di informazioni alla rilevazione di anomalie — si basa su un concetto fondamentale: la **prossimità** (*proximity*), termine ombrello che racchiude sia la *similarità* sia la *dissimilarità*.

Definizione 4.1.1 (Similarità). La **similarità** (*similarity*) è una misura numerica di quanto due oggetti dati si somiglino. Assume valore più alto quanto più gli oggetti sono simili e ricade tipicamente nell'intervallo $[0, 1]$.

Definizione 4.1.2 (Dissimilarità). La **dissimilarità** (*dissimilarity*) è una misura numerica di quanto due oggetti dati differiscano tra loro. Assume valore minimo (spesso 0) quando gli oggetti sono identici; il limite superiore varia a seconda della misura scelta.

La relazione tra le due è intuitiva: a bassa dissimilarità corrisponde alta similarità e viceversa. In molti contesti pratici si utilizza una trasformazione semplice come $s = 1 - d$ oppure $s = e^{-d}$ per convertire distanza in similarità.

4.1.1 Similarità e Dissimilarità per un Singolo Attributo

Prima di affrontare il caso multidimensionale, è utile esaminare come definire la prossimità per un singolo attributo in funzione del suo tipo. La seguente

tabella riassume le scelte più comuni:

Tipo di Attributo	Dissimilarità	Similarità
Nominale	$d = 0$ se $p = q$; $d = 1$ altrimenti	$s = 1$ se $p = q$; $s = 0$ altrimenti
Ordinale	$d = \frac{ p - q }{n - 1}$ (valori mappati in $0, \dots, n - 1$)	$s = 1 - d$
Intervallo / Rapporto	$d = p - q $	$s = -d$, $s = \frac{1}{1 + d}$, oppure $s = e^{-\alpha d}$

Tabella 4.1: Misure di prossimità per un singolo attributo in funzione del tipo di dato.

4.2 Distanza Euclidea e Proprietà delle Metriche

Quando gli oggetti dati sono punti nello spazio $\mathbb{R}^n$, la misura di distanza più immediata è la **distanza euclidea**.

Definizione 4.2.1 (Distanza Euclidea). Dati due punti $\mathbf{x} = (x_1, \dots, x_n)$ e $\mathbf{y} = (y_1, \dots, y_n)$ in $\mathbb{R}^n$, la **distanza euclidea** (norma L_2) è:

$$d(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_{k=1}^n (x_k - y_k)^2} \quad (4.1)$$

Standardizzazione necessaria

Se le scale degli attributi differiscono (ad esempio, un attributo varia in $[0, 1]$ e un altro in $[0,000, 10,000]$), gli attributi con range maggiore dominano il calcolo della distanza. Prima di applicare la distanza euclidea, occorre **standardizzare** i dati (ad esempio sottraendo la media e dividendo per la deviazione standard).

Esempio 4.2.1 (Matrice delle distanze eucldee). Consideriamo quattro punti nel piano:

Punto	x	y
p_1	0	2
p_2	2	0
p_3	3	1
p_4	5	1

Le distanze euclidee calcolate sono:

	p_1	p_2	p_3	p_4
p_1	0	2.828	3.162	5.099
p_2	2.828	0	1.414	3.162
p_3	3.162	1.414	0	2.000
p_4	5.099	3.162	2.000	0

4.2.1 Proprietà di una Metrica

Una funzione di distanza $d(\mathbf{x}, \mathbf{y})$ che rispetti le seguenti tre proprietà è chiamata **metrica**:

1. **Positività e definitezza:** $d(\mathbf{x}, \mathbf{y}) \geq 0$ per ogni $\mathbf{x}, \mathbf{y}$, e $d(\mathbf{x}, \mathbf{y}) = 0$ se e solo se $\mathbf{x} = \mathbf{y}$.
2. **Simmetria:** $d(\mathbf{x}, \mathbf{y}) = d(\mathbf{y}, \mathbf{x})$ per ogni $\mathbf{x}, \mathbf{y}$.
3. **Disuguaglianza triangolare:** $d(\mathbf{x}, \mathbf{z}) \leq d(\mathbf{x}, \mathbf{y}) + d(\mathbf{y}, \mathbf{z})$ per ogni $\mathbf{x}, \mathbf{y}, \mathbf{z}$.

Analogamente, una funzione di similarità $s(\mathbf{x}, \mathbf{y})$ soddisfa:

1. $s(\mathbf{x}, \mathbf{y}) = 1$ (o il valore massimo) se e solo se $\mathbf{x} = \mathbf{y}$.
2. $s(\mathbf{x}, \mathbf{y}) = s(\mathbf{y}, \mathbf{x})$ per ogni $\mathbf{x}, \mathbf{y}$ (simmetria).

4.3 Distanza di Minkowski: Una Famiglia di Metriche

La distanza euclidea è un caso particolare di una famiglia più ampia, la **distanza di Minkowski**.

Definizione 4.3.1 (Distanza di Minkowski). Dati due punti $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$ e un parametro $r \geq 1$, la **distanza di Minkowski** (norma L_r) è:

$$d(\mathbf{x}, \mathbf{y}) = \left(\sum_{k=1}^n |x_k - y_k|^r \right)^{1/r} \quad (4.2)$$

Il parametro r controlla la “forma” della sfera unitaria associata alla norma:




Figura 4.1: La famiglia delle norme di Minkowski al variare del parametro r .

Esempio 4.3.1 (Confronto tra norme L_1 , L_2 , L_∞). Con gli stessi quattro punti dell’esempio precedente:

L_1	p_1	p_2	p_3	p_4
p_1	0	4	4	6
p_2	4	0	2	4
p_3	4	2	0	2
p_4	6	4	2	0

L_∞	p_1	p_2	p_3	p_4
p_1	0	2	3	5
p_2	2	0	1	3
p_3	3	1	0	2
p_4	5	3	2	0

In L_1 la distanza tra p_1 e p_2 è $|0 - 2| + |2 - 0| = 4$; in L_∞ è $\max(|0 - 2|, |2 - 0|) = 2$.

La norma L_1 è particolarmente utile nei dati ad alta dimensionalità e sparsi, e la **distanza di Hamming** — il numero di bit diversi tra due vettori binari — ne è un caso speciale.

4.4 Similarità tra Dati Binari

Quando gli attributi sono **binari** (presenti/assenti, vero/falso), la nozione di distanza euclidea perde di significato semantico. Si preferisce invece ragionare in termini di *corrispondenze*.

Dati due oggetti p e q con attributi binari, definiamo la seguente **tabella di contingenza**:

	$q = 0$	$q = 1$
$p = 0$	M_{00} entrambi 0	M_{01} $p=0, q=1$
$p = 1$	M_{10} $p=1, q=0$	M_{11} entrambi 1

Definizione 4.4.1 (Simple Matching Coefficient — SMC).

$$\text{SMC}(p, q) = \frac{M_{11} + M_{00}}{M_{01} + M_{10} + M_{11} + M_{00}} \quad (4.3)$$

Conta sia le corrispondenze 1-1 che le corrispondenze 0-0.

Definizione 4.4.2 (Coefficiente di Jaccard).

$$J(p, q) = \frac{M_{11}}{M_{01} + M_{10} + M_{11}} \quad (4.4)$$

Ignora le corrispondenze 0-0: è adatto quando l'assenza di un attributo non è informativa (es. insiemi di acquisti, tag, malattie rare).

Esempio 4.4.1 (SMC vs. Jaccard). Siano:

$$p = [1, 0, 0, 0, 0, 0, 0, 0, 0, 0], \quad q = [0, 0, 0, 0, 0, 0, 1, 0, 0, 1]$$

- $M_{11} = 0$ (nessuna corrispondenza 1-1)
- $M_{10} = 1$ (solo $p_1 = 1$ con $q_1 = 0$)
- $M_{01} = 2$ ($q_7 = 1$ e $q_{10} = 1$ mentre $p = 0$)
- $M_{00} = 7$ (entrambi 0 per le restanti posizioni)

$$\text{SMC} = \frac{0 + 7}{2 + 1 + 0 + 7} = 0.7, \quad J = \frac{0}{2 + 1 + 0} = 0$$

SMC è alta perché conta i 7 zeri in comune; Jaccard è 0 perché non vi è nessuna co-occorrenza di 1. Per dati di tipo *market basket* (dove l'assenza di un prodotto non è informativa), Jaccard è la scelta corretta.

4.5 Similarità del Coseno

Nei dati documentali (vettori di frequenze di parole, *TF-IDF*), i vettori tendono ad essere ad alta dimensionalità e sparsi. La distanza euclidea è sensibile alla lunghezza del documento; la **similarità del coseno** normalizza per la norma e misura solo l'angolo tra i vettori.

Definizione 4.5.1 (Similarità del Coseno). Dati due vettori $\mathbf{d}_1, \mathbf{d}_2 \in \mathbb{R}^n$:

$$\cos(\mathbf{d}_1, \mathbf{d}_2) = \frac{\mathbf{d}_1 \cdot \mathbf{d}_2}{\|\mathbf{d}_1\| \|\mathbf{d}_2\|} \quad (4.5)$$

dove $\mathbf{d}_1 \cdot \mathbf{d}_2 = \sum_k d_{1k} \cdot d_{2k}$ è il prodotto scalare e $\|\mathbf{d}\| = \sqrt{\sum_k d_k^2}$ è la norma euclidea.

Il valore ricade in $[-1, 1]$; per vettori non negativi (come le frequenze di parole) il range è $[0, 1]$: 1 indica direzioni identiche, 0 indica vettori ortogonali.

Esempio 4.5.1 (Cosine Similarity su documenti).

$$\mathbf{d}_1 = [3, 2, 0, 5, 0, 0, 0, 2, 0, 0]$$

$$\mathbf{d}_2 = [1, 0, 0, 0, 0, 0, 0, 1, 0, 2]$$

$$\mathbf{d}_1 \cdot \mathbf{d}_2 = 3 \cdot 1 + 2 \cdot 0 + 5 \cdot 0 + 2 \cdot 1 = 5$$

$$\|\mathbf{d}_1\| = \sqrt{9 + 4 + 25 + 4} = \sqrt{42} \approx 6.481, \quad \|\mathbf{d}_2\| = \sqrt{1 + 1 + 4} = \sqrt{6} \approx 2.449$$

$$\cos(\mathbf{d}_1, \mathbf{d}_2) = \frac{5}{6.481 \times 2.449} \approx 0.315$$

I documenti condividono circa il 31.5% di “direzione”, nonostante la diversa lunghezza.

4.5.1 Similarità Pesata

In molti casi non tutti gli attributi contribuiscono egualmente alla similarità. Si può definire una **similarità pesata** introducendo pesi non negativi w_k con $\sum_k w_k = 1$:

$$s_w(\mathbf{x}, \mathbf{y}) = \frac{\sum_{k=1}^n w_k \cdot d_k \cdot s_k(x_k, y_k)}{\sum_{k=1}^n w_k \cdot d_k} \quad (4.6)$$

dove s_k è la similarità per il k -esimo attributo e d_k è un fattore di normalizzazione.

4.6 Correlazione

La **correlazione di Pearson** misura la relazione *lineare* tra due variabili (o tra due oggetti visti come vettori di attributi). Si calcola standardizzando i vettori e calcolando il loro prodotto scalare:

$$\text{corr}(p, q) = \frac{\sum_{k=1}^n (p_k - \bar{p})(q_k - \bar{q})}{(n-1) \sigma_p \sigma_q} \quad (4.7)$$

dove $\bar{p}, \bar{q}$ sono le medie e σ_p, σ_q le deviazioni standard. Il risultato ricade in $[-1, 1]$:

- +1: correlazione positiva perfetta (i valori crescono insieme);
- 0: nessuna correlazione lineare;
- -1: correlazione negativa perfetta (uno cresce mentre l'altro decresce).

4.7 Misure Basate sull'Informazione: Entropia e Mutua Informazione

Le misure basate sulla **teoria dell'informazione** consentono di quantificare la prossimità tra variabili categoriali o continue in modo non lineare, andando oltre il semplice confronto valore-per-valore.

4.7.1 Entropia

L'informazione contenuta in un evento è inversamente proporzionale alla sua probabilità: un evento certissimo non trasmette informazione, uno raro ne trasmette molta.

Definizione 4.7.1 (Entropia di Shannon). Per una variabile discreta X con n possibili valori $x_1, \dots, x_n$ e probabilità $p_1, \dots, p_n$:

$$H(X) = - \sum_{i=1}^n p_i \log_2 p_i \quad (4.8)$$

L'entropia è misurata in **bit** e ricade in $[0, \log_2 n]$.

Casi limite:

- Se una probabilità è 1 (evento certo), $H = 0$ — massima certezza, zero informazione.

- Se tutti i valori sono equiprobabili ($p_i = 1/n$), $H = \log_2 n$ — massima incertezza.

Esempio 4.7.1 (Moneta equa vs. truccata). Per una moneta con probabilità p di testa e $q = 1 - p$ di croce:

$$H = -p \log_2 p - q \log_2 q$$

Con $p = 0.5$ (moneta equa): $H = 1$ bit. Con $p = 1$ o $p = 0$ (moneta truccata): $H = 0$ bit.

4.7.2 Mutua Informazione

La **mutua informazione** (*Mutual Information*, MI) quantifica quanta informazione una variabile X fornisce su un'altra variabile Y :

Definizione 4.7.2 (Mutua Informazione).

$$I(X; Y) = H(X) + H(Y) - H(X, Y) \quad (4.9)$$

dove $H(X, Y) = -\sum_i \sum_j p_{ij} \log_2 p_{ij}$ è l'entropia congiunta e $p_{ij} = P(X = x_i, Y = y_j)$.

$I(X; Y) = 0$ se X e Y sono indipendenti. Il valore massimo per variabili discrete è $\log_2(\min(n_X, n_Y))$. A differenza della correlazione di Pearson, la MI cattura anche dipendenze *non lineari*.

Esempio 4.7.2 (Mutua Informazione: Studenti e Voti). Consideriamo le variabili *Status dello Studente* (Undergraduate/Graduate) e *Voto* (A/B/C) su 100 studenti:

Voto	Status		
	Undergrad	Grad	Totale
A	5	30	35
B	30	20	50
C	10	5	15
Totale	45	55	100

$$H(\text{Status}) = -(0.45 \log_2 0.45 + 0.55 \log_2 0.55) \approx 0.993 \text{ bit}$$

$$H(\text{Voto}) = -(0.35 \log_2 0.35 + 0.50 \log_2 0.50 + 0.15 \log_2 0.15) \approx 1.441 \text{ bit}$$

$$H(\text{Status}, \text{Voto}) \approx 2.271 \text{ bit}$$

$$I(\text{Status}; \text{Voto}) = 0.993 + 1.441 - 2.271 \approx \mathbf{0.163} \text{ bit}$$

La MI positiva indica che conoscere lo status fornisce (poca) informazione sul voto e viceversa.

4.8 Che cos'è l'Analisi dei Cluster?

Definizione 4.8.1 (Cluster Analysis). La **cluster analysis** (o **clustering**) è il processo di raggruppamento di un insieme di oggetti in **cluster**, ovvero gruppi tali che:

- gli oggetti *all'interno* dello stesso cluster siano il più possibile simili tra loro (*alta coesione intra-cluster*);
- gli oggetti di cluster *diversi* siano il più possibile dissimili (*alta separazione inter-cluster*).




Figura 4.2: Obiettivo fondamentale del clustering: massimizzare le distanze inter-cluster (separazione) e minimizzare le distanze intra-cluster (coesione).

Il clustering è un'attività di **apprendimento non supervisionato**: a differenza della classificazione, non si dispone di etichette predefinite. L'algoritmo deve scoprire autonomamente la struttura latente nei dati.

4.8.1 Applicazioni del Clustering

Il clustering trova applicazione in una vasta gamma di domini:

- **Comprensione:** raggruppare documenti per argomento (information retrieval), raggruppare geni con funzionalità simile (bioinformatica), raggruppare azioni con andamento correlato (finanza).
- **Riepilogo e compressione:** ridurre un dataset di grandi dimensioni sostituendo ogni cluster con un rappresentante (centroide o medoide), utile per la visualizzazione e per la pre-elaborazione di altri algoritmi.

- **Rilevamento di anomalie:** oggetti che non appartengono a nessun cluster (o a cluster molto piccoli) sono potenziali anomalie.
- **Clustering spaziale:** scoprire zone geografiche con caratteristiche ambientali simili (es. precipitazioni in Australia).

4.8.2 Cosa NON è il Clustering

È importante non confondere il clustering con altri processi superficialmente simili:

- **Segmentazione semplice:** dividere gli studenti in gruppi alfabetici per cognome è una partizione, non un clustering — i gruppi sono definiti da una regola esterna, non dalla similarità dei dati.
- **Risultati di una query:** recuperare tutti i documenti che contengono la parola “machine learning” produce un insieme, non un clustering — la specifica del gruppo è esterna.
- **Classificazione supervisionata:** le etichette di classe sono fornite a priori; il clustering le deve scoprire.
- **Association Analysis:** trova relazioni locali tra item (es. regole di associazione); il clustering cerca strutture globali di raggruppamento.

4.9 Ambiguità e Soggettività del Concetto di Cluster

Il clustering non ha un'unica risposta corretta

La stessa nuvola di punti può essere validamente interpretata come 2, 4 o 6 cluster a seconda della scala di analisi, della misura di prossimità scelta e dell'algoritmo impiegato. Non esiste una risposta “oggettivamente corretta”: il clustering è sempre relativo al modello e al contesto.

Questo fatto impone cautela nell'interpretazione dei risultati e rende indispensabile la valutazione qualitativa e quantitativa della bontà del clustering ottenuto.

4.10 Tassonomia dei Clustering

Un **clustering** è un insieme di cluster che partizioni o organizza gli oggetti. Esistono diverse tassonomie ortogonali.

4.10.1 Clustering Partizionale vs. Gerarchico




Figura 4.3: Clustering partizionale (partizioni disgiunte non sovrapposte) a confronto con il clustering gerarchico (dendrogramma annidato con livelli di aggregazione).

Definizione 4.10.1 (Clustering Partizionale). Un **clustering partizionale** divide gli oggetti in k sottoinsiemi disgiunti (cluster) tali che ogni oggetto appartiene ad esattamente un cluster.

Definizione 4.10.2 (Clustering Gerarchico). Un **clustering gerarchico** produce un insieme di cluster annidati organizzato come un albero (*dendrogramma*). A ogni livello dell'albero corrisponde una diversa granularità del raggruppamento.

4.10.2 Altre Distinzioni

- **Esclusivo vs. Non-esclusivo:** nel clustering non-esclusivo (*soft* o *overlapping*), un punto può appartenere a più cluster simultaneamente (ad es. un punto di confine).
- **Fuzzy vs. Non-fuzzy:** nel clustering fuzzy, ogni punto appartiene a ogni cluster con un peso $w_{ik} \in [0, 1]$ tale che $\sum_k w_{ik} = 1$. Il clustering probabilistico ha caratteristiche simili.

- **Parziale vs. Completo:** talvolta si vuole raggruppare solo un sottoinsieme dei dati (ad es. escludendo i rumori).
- **Omogeneo vs. Eterogeneo:** cluster di dimensioni, forme e densità molto diverse.

4.11 Tipologie di Cluster

Il termine “cluster” può avere significati molto diversi a seconda del modello adottato. Le cinque tipologie principali sono:

4.11.1 Cluster Ben Separati (*Well-Separated*)

Definizione 4.11.1 (Cluster Ben Separato). Un cluster ben separato è un insieme di punti tali che ogni punto è più vicino (o simile) a ogni altro punto del suo cluster che a qualsiasi punto di un cluster diverso.

Questa definizione intuitiva funziona bene quando i cluster sono effettivamente compatti e distanziati, ma fallisce in presenza di cluster elongati, di forme irregolari o di rumore.

4.11.2 Cluster Basati sul Centro (*Center-Based*)

Definizione 4.11.2 (Cluster Center-Based). Un cluster center-based è un insieme di oggetti tali che ogni oggetto è più vicino (simile) al **centro** del suo cluster che al centro di qualunque altro cluster. Il centro può essere:

- il **centroide**: media (vettore) di tutti i punti del cluster;
- il **medoide**: il punto reale del cluster più rappresentativo (minimizza la distanza media agli altri).

Questa è la definizione alla base degli algoritmi *K-means* e *K-medoids*.

4.11.3 Cluster per Contiguità (*Contiguity-Based*)

Definizione 4.11.3 (Cluster Contiguo). Un cluster contiguo (o basato sul vicinato transitivo) è un insieme di punti tale che ogni punto è più vicino ad almeno un altro punto del suo cluster che a qualsiasi punto di un altro cluster.

Questo approccio produce strutture basate su grafi (ogni punto è connesso ai suoi vicini più prossimi). È sensibile al **rumore**: anche un singolo punto intermedio (“ponte”) tra due cluster distinti può unirli erroneamente.

4.11.4 Cluster Basati sulla Densità (*Density-Based*)

Definizione 4.11.4 (Cluster Density-Based). Un cluster density-based è una regione densa di punti separata da regioni a bassa densità da altre regioni dense.

Questa definizione consente di scoprire cluster di forma arbitraria e gestisce in modo naturale rumori e outlier (che rimangono isolati nelle regioni a bassa densità). È alla base di algoritmi come DBSCAN.

4.11.5 Cluster Definiti da una Funzione Obiettivo

Un approccio alternativo consiste nel definire una **funzione obiettivo** f e cercare la partizione che la minimizza o massimizza. Il problema è in generale **NP-hard**: enumerare tutte le partizioni possibili ha costo esponenziale nel numero di punti.

- Gli algoritmi **gerarchici** tipicamente ottimizzano *obiettivi locali* (fusioni o divisioni greedy).
- Gli algoritmi **partizionali** (come K-means) tipicamente ottimizzano *obiettivi globali* (es. somma delle distanze al centroide).

La seguente tabella confronta sinteticamente le cinque tipologie:

Tipologia	Criterio di appartenenza	Algoritmi tipici
Well-Separated	Più vicino a tutti i punti del proprio cluster	— (definizione ideale)
Center-Based	Più vicino al centro del proprio cluster	K-means, K-medoids
Contiguity-Based	Più vicino ad almeno un punto del proprio cluster	Single-link HAC
Density-Based	In una regione ad alta densità	DBSCAN, OPTICS
Objective Function	Minimizza/massimizza una funzione globale	K-means (SSE), spettrale

Tabella 4.2: Confronto tra le principali tipologie di cluster.

4.12 Caratteristiche dei Dati di Input e Algoritmi di Clustering

La scelta della misura di prossimità e dell'algoritmo di clustering dipende fortemente dalle caratteristiche dei dati:

- **Dimensionalità:** ad alta dimensionalità, le misure di distanza euclidea diventano meno discriminanti (*curse of dimensionality*) — la differenza tra il vicino più prossimo e il più lontano tende a zero.
- **Sparsità:** dati con molti zeri (es. testi, transazioni) richiedono misure come Jaccard o cosine similarity.
- **Tipo di attributo:** la misura di prossimità deve essere coerente con il tipo (nominale, ordinale, continuo, binario).
- **Relazioni speciali:** autocorrelazione spaziale o temporale nei dati deve essere considerata.
- **Distribuzione dei dati:** cluster molto asimmetrici o con densità molto diverse possono richiedere algoritmi specifici.
- **Rumore e outlier:** interferiscono con quasi tutti gli algoritmi; DBSCAN li gestisce nativamente, K-means ne è molto sensibile.

Algoritmi di Clustering Principali

I tre grandi paradigmi algoritmici del clustering sono:

1. **K-means e varianti:** partizionale, ottimizza la somma degli errori quadratici (SSE), sensibile agli outlier e alla scelta di k .
2. **Clustering Gerarchico:** produce un dendrogramma; agglomerativo (*bottom-up*) o divisivo (*top-down*); non richiede di specificare k a priori.
3. **Clustering Density-Based (DBSCAN):** scopre cluster di forma arbitraria, robusto al rumore, non richiede k ma richiede la definizione di densità (ϵ , *MinPts*).

Ognuno verrà trattato in dettaglio nei capitoli successivi.

Bibliografia

- [1] Usama Fayyad, Gregory Piatetsky-Shapiro, and Padhraic Smyth. From data mining to knowledge discovery in databases. *AI Magazine*, 17(3):37–54, 1996.