

Appunti di Data Mining

Anno Accademico 2026/2027

Indice

1	Introduzione al Data Mining e Processo KDD	1
1.1	Definizione e Motivazioni Fondamentali	1
1.1.1	Prospettive Applicative	1
1.1.2	Una Confluenza di Discipline	2
1.2	Tipologie di Origine del Dato: Primari e Secondari	3
1.3	Il Processo KDD (Knowledge Discovery in Databases)	3
1.4	Tassonomia dei Compiti di Data Mining	5
1.4.1	Compiti Predittivi: La Classificazione	5
1.4.2	Compiti Descrittivi	6
1.5	Sfide Metodologiche e Computazionali nel Data Mining	8
2	Data Understanding ed Esplorazione dei Dati	10
2.1	Obiettivi del Data Understanding	10
2.2	Tipologie di Dataset	11
2.3	Oggetti e Attributi	12
2.3.1	Scale di Misura degli Attributi	12
2.3.2	Ulteriori Distinzioni degli Attributi	12
2.4	Qualità del Dato (Data Quality)	14
2.4.1	Dimensioni della Qualità del Dato	14
2.5	Statistica Descrittiva ed Esplorazione Univariata	15
2.5.1	Misure di Tendenza Centrale	15
2.5.2	Asimmetria e Multimodalità	16
2.5.3	Misure di Dispersione	16
2.5.4	Box Plot e Sintesi a Cinque Numeri	16
2.5.5	Bar Chart per Attributi Categorici	17
2.5.6	Istogrammi per Attributi Numerici e Scelta dei Bin	19
2.6	Tecniche di Visualizzazione Multivariata	20
2.6.1	Scatter Plot e Visualizzazione a Più Dimensioni	20
2.6.2	Visualizzazione ad Alta Dimensionalità	22
2.7	Analisi di Correlazione Lineare	23
2.8	Gestione di Outlier e Valori Mancanti	24

2.8.1	Outlier: Rumore vs Conoscenza	24
2.8.2	Valori Mancanti (Missing Values)	25
2.9	Checklist Operativa di Data Understanding	26

Capitolo 1

Introduzione al Data Mining e Processo KDD

1.1 Definizione e Motivazioni Fondamentali

Il costante progresso tecnologico nella generazione e memorizzazione dei dati ha portato a una crescita esponenziale delle informazioni disponibili, sia nel contesto commerciale sia in quello scientifico. Il paradigma moderno della raccolta dati si riassume spesso nel principio di raccogliere qualsiasi dato possibile, ovunque e in qualsiasi momento, nell'aspettativa che tali dati possano acquisire valore non soltanto per lo scopo originario per cui sono stati raccolti, ma anche per scopi secondari non previsti inizialmente.

Definizione 1.1 (Data Mining). Il **Data Mining** è l'applicazione di tecniche ed algoritmi efficienti all'analisi di collezioni di dati di grandi dimensioni, finalizzata all'estrazione di pattern validi, inediti, potenzialmente utili e interpretabili (conoscenza nascosta o *hidden knowledge*).

Il Data Mining non consiste nella semplice esecuzione di query su basi di dati tradizionali (ad esempio, il recupero del saldo medio tramite SQL), bensì nella scoperta automatica o semi-automatica di strutture, dipendenze o regolarità non banali nei dati.

1.1.1 Prospettive Applicative

Le motivazioni alla base dell'adozione delle tecniche di Data Mining possono essere distinte principalmente secondo due punti di vista:

- **Punto di vista commerciale:** Le aziende gestiscono volumi enormi di dati (*data warehousing*): dati web (Yahoo, Facebook), transazioni


di e-commerce e vendite al dettaglio (Amazon), registrazioni di carte di credito e conti correnti bancari. A fronte di una potenza di calcolo sempre più economica e accessibile, la pressione competitiva richiede di estrarre valore da tali moli di dati per migliorare e personalizzare i servizi offerti (ad esempio nel *Customer Relationship Management - CRM*).

- **Punto di vista scientifico e sociale:** In discipline quali l'astronomia (*Sky Survey Data*), l'osservazione della Terra (i satelliti del sistema NASA EOSDIS raccolgono petabyte di dati ambientali all'anno), la genomica (espressione genica, proteomica), la neuroimaging (fMRI) e le simulazioni numeriche complesse, i dati vengono generati a velocità tali da rendere impossibile l'analisi manuale. Il Data Mining supporta gli scienziati nell'analisi automatica e nella formulazione guidata di nuove ipotesi.

I Big Data rappresentano a tutti gli effetti un proxy della vita sociale (comportamenti d'acquisto, stili di vita, opinioni, reti di relazioni, mobilità sul territorio), offrendo grandi opportunità per affrontare problematiche globali: dall'efficientamento della sanità alla ricerca di fonti di energia pulita, dalla previsione degli impatti climatici all'ottimizzazione della produzione agricola.

1.1.2 Una Confluenza di Discipline

Il Data Mining non è una disciplina isolata, bensì una confluenza sinergica di diverse aree dell'informatica e della matematica applicata:




1.2 Tipologie di Origine del Dato: Primari e Secondari

Nell'impostazione di un progetto analitico, è fondamentale distinguere l'origine dei dati analizzati:

- **Dati Primari (*Primary Data*):** Dati originali rilevati specificamente per un preciso obiettivo di indagine. Non hanno subito alterazioni o manipolazioni preventive da parte di terzi.
- **Dati Secondari (*Secondary Data*):** Dati che erano già stati raccolti in precedenza per scopi operativi o differenti da quello corrente e resi disponibili all'analista. Spesso derivano dalla fusione di sorgenti disomogenee e necessitano di profonde operazioni di normalizzazione e verifica della qualità.

1.3 Il Processo KDD (Knowledge Discovery in Databases)

Il Data Mining costituisce una fase specifica, sebbene centrale, all'interno del più ampio processo di scoperta della conoscenza, noto come **KDD** (*Knowledge Discovery in Databases*). Il KDD è un processo iterativo e interattivo composto da diverse fasi sequenziali con cicli di retroazione:



Ciascuna fase assolve compiti specifici:

1. **Business Understanding:** Comprensione degli obiettivi di dominio e traduzione del problema di business in un problema formale di analisi dati.
2. **Data Cleaning e Data Integration:**
 - *Data Cleaning:* rimozione di rumore, correzione di errori sintattici e gestione delle incoerenze.

- *Data Integration*: aggregazione e riconciliazione di dati provenienti da fonti multiple ed eterogenee, confluendo tipicamente in un **Data Warehouse** (un repository strutturato e ottimizzato per l'analisi e il supporto alle decisioni).

3. Data Selection e Data Transformation:

- *Data Selection*: estrazione del sottoinsieme di attributi e record strettamente pertinenti al task investigato (*task-relevant data*).
 - *Data Transformation*: trasformazione delle feature mediante aggregazioni, riscalamenti, normalizzazioni o discretizzazioni affinché siano adatte all'algoritmo.
4. **Data Mining**: Esecuzione vera e propria di algoritmi intelligenti per l'estrazione di pattern e modelli matematici.
 5. **Pattern Evaluation e Knowledge Presentation**: Identificazione dei pattern realmente significativi tramite metriche oggettive e soggettive, eliminazione della ridondanza e visualizzazione grafica dei risultati mediante strumenti interpretabili dall'utente finale.

1.4 Tassonomia dei Compiti di Data Mining

Seguendo la classificazione di Fayyad et al. [1], i compiti di Data Mining si dividono in due macro-categorie:

- **Metodi Predittivi (*Prediction Methods*)**: Mirano a stimare il valore futuro o sconosciuto di una variabile target specifica a partire dai valori di altre variabili osservate (attributi predittori).
- **Metodi Descrittivi (*Description Methods*)**: Mirano a identificare pattern leggibili ed interpretabili dall'essere umano che descrivano la struttura intrinseca e le relazioni nascoste nei dati.

1.4.1 Compiti Predittivi: La Classificazione

La **classificazione** ha come obiettivo l'apprendimento di una funzione obiettivo f che mappa ogni record di attributi x in una specifica etichetta di classe discreta $y \in \mathcal{Y}$.

Il dataset viene suddiviso in due insiemi disgiunti:

- **Training Set**: Utilizzato per addestrare il classificatore.




Figura 1.1: Workflow concettuale del processo di classificazione.

- **Test Set:** Utilizzato per valutare la capacità di generalizzazione del modello su istanze non osservate durante la fase di apprendimento.

Esempio 1.2 (Applicazioni di Classificazione). Tra le principali e più diffuse aree applicative dei modelli di classificazione troviamo:

- **Valutazione del Merito Creditizio (*Credit Worthiness*):** Predire se un richiedente prestito rimborserà il debito (*Yes/No*) sulla base di occupazione, livello di istruzione e anni di residenza.
- **Rilevamento Frodi Bancarie:** Classificare le transazioni con carta di credito come lecite o fraudolente. Le feature includono l'importo, l'orario, la posizione geografica e il profilo storico delle spese.
- **Churn Prediction:** Stimare la probabilità che un cliente di telecomunicazioni abbandoni il servizio per passare alla concorrenza, analizzando la durata delle chiamate, il volume del traffico dati e i reclami registrati.
- **Altre applicazioni:** Categorizzazione automatica di notizie (sport, finanza, politica), diagnosi clinica (tumore benigno o maligno), classificazione di coperture del suolo da immagini satellitari.

1.4.2 Compiti Descrittivi

1. Clustering (Raggruppamento)

Il **clustering** consiste nell'organizzare un insieme di oggetti in gruppi distinti (detti *cluster*), in modo tale che:

1. La distanza tra oggetti appartenenti allo stesso cluster (**distanza intra-cluster**) sia **minimizzata** (massima omogeneità interna).
2. La distanza tra oggetti appartenenti a cluster differenti (**distanza inter-cluster**) sia **massimizzata** (massima separazione esterna).




Figura 1.2: Principio geometrico fondamentale del clustering.

Il clustering è una tecnica non supervisionata: non richiede classi a priori.

- **Segmentazione di Mercato:** Raggruppare i clienti in base a dati socio-demografici e abitudini di acquisto per indirizzare campagne di marketing differenziate.
- **Clustering Documentale:** Raggruppare documenti testuali simili in base alle frequenze congiunte delle parole chiave (ad esempio, l'analisi dell'archivio email aziendale Enron).
- **Summarization e Scienze della Terra:** Ridurre la complessità di enormi serie spaziali partizionando le misurazioni di temperatura marina superficiale (*Sea Surface Temperature* - SST) e produzione primaria (*Net Primary Production* - NPP) negli emisferi settentrionale e meridionale.

2. Scoperta di Regole di Associazione (Association Analysis)

Dato un insieme di transazioni, ciascuna costituita da un sottoinsieme di elementi presi da un insieme globale di articoli (*items*), l'analisi delle associazioni si prefigge di scoprire dipendenze probabilistiche nella forma di regole:

$$X \implies Y \quad (1.1)$$

dove X e Y sono itemset disgiunti ($X \cap Y = \emptyset$). La regola indica che la presenza degli articoli nell'antecedente X predice sistematicamente la contestuale presenza dell'articolo o degli articoli nel conseguente Y .

Esempio 1.3 (Market Basket Analysis). Considerando uno storico di scontrini di cassa: L'algoritmo estrae regole ad elevata evidenza statistica, quali:

TID	Articoli Acquistati
1	Pane, Coca-Cola, Latte
2	Birra, Pane
3	Birra, Coca-Cola, Pannolini, Latte
4	Birra, Pane, Pannolini, Latte
5	Coca-Cola, Pannolini, Latte

$$\{\text{Latte}\} \implies \{\text{Coca-Cola}\}, \quad \{\text{Pannolini, Latte}\} \implies \{\text{Birra}\}$$

Tali informazioni guidano la disposizione strategica dei beni sugli scaffali e la progettazione di offerte cross-selling.

Altre applicazioni: Diagnosi di allarmi nelle reti di telecomunicazione (individuazione di pattern temporali di allarmi di rete che scattano congiuntamente per identificare guasti sistemici alla radice); informatica medica (correlazione tra combinazioni di sintomi clinici, esami ematochimici e patologie emergenti).

3. Rilevamento di Anomalie (Anomaly / Deviation / Change Detection)

Consiste nell'identificare oggetti che deviano in modo significativo dal comportamento medio o atteso della popolazione. Le anomalie possono essere generate da guasti strumentali o errori di inserimento (e in tal caso rappresentano *rumore* da epurare), oppure riflettere eventi eccezionali di estremo interesse applicativo (frodi creditizie, intrusioni informatiche contro le reti aziendali, monitoraggio di repentini disboscamenti della copertura forestale tramite sensori remoti).

1.5 Sfide Metodologiche e Computazionali nel Data Mining

L'applicazione di metodi tradizionali di analisi statistica e database è spesso inadeguata a causa di cinque sfide primarie:

1. **Scalabilità (*Scalability*):** Gli algoritmi devono gestire volumi di dati di ordine di terabyte o petabyte senza che la complessità computazionale e l'occupazione di memoria esplodano.

2. **Alta Dimensionalità (*High Dimensionality*):** La presenza di centinaia o migliaia di attributi espone alla cosiddetta *maledizione della dimensionalità* (*curse of dimensionality*), in cui lo spazio geometrico diventa estremamente vuoto e le distanze tendono a perdere discriminatività.
3. **Dati Complessi ed Eterogenei:** Necessità di elaborare strutture semi-strutturate o non strutturate (grafi, testi, sequenze genomiche, serie spaziotemporali).
4. **Proprietà e Distribuzione dei Dati:** I dati sono frequentemente distribuiti geograficamente tra molteplici organizzazioni e soggetti a stringenti vincoli legali di privacy e sicurezza.
5. **Analisi Non Tradizionali:** Esigenza di estrarre conoscenza da flussi continui in tempo reale (*data stream mining*) senza possibilità di memorizzare l'intero dataset.

Capitolo 2

Data Understanding ed Esplorazione dei Dati

2.1 Obiettivi del Data Understanding

La fase di comprensione dei dati (*Data Understanding*) costituisce un prerequisito indispensabile per qualsiasi attività di Data Mining. Prima di selezionare o applicare qualsiasi algoritmo, l'analista deve acquisire una visione complessiva della struttura, della distribuzione e della qualità intrinseca del dataset rispetto agli obiettivi del progetto.

In questa fase preliminare è necessario rispondere a domande metodologiche cruciali:

- Quali tipologie di attributi compongono il dataset?
- Qual è il livello complessivo di qualità dei dati (presenza di rumore, errori o duplicati)?
- Come sono distribuite le variabili numeriche e categoriche?
- Sono presenti correlazioni evidenti o ridondanze tra gli attributi?
- Come sono strutturati gli outlier e quale significato applicativo assumono?
- Quali strategie adottare per i valori mancanti?
- È necessario derivare o trasformare attributi per rendere più efficace il mining?

2.2 Tipologie di Dataset

I dati raccolti si presentano in diverse strutture logico-geometriche in base alla natura del dominio applicativo:

1. Dati di tipo Record:

- **Data Matrix:** Insieme di oggetti descritti dallo stesso insieme fissato di attributi numerici. Un dataset di m oggetti e n attributi è rappresentato formalmente da una matrice $m \times n$:

$$\mathbf{X} = \begin{pmatrix} x_{1,1} & x_{1,2} & \cdots & x_{1,n} \\ x_{2,1} & x_{2,2} & \cdots & x_{2,n} \\ \vdots & \vdots & \ddots & \vdots \\ x_{m,1} & x_{m,2} & \cdots & x_{m,n} \end{pmatrix} \quad (2.1)$$

In tale formalizzazione, ciascun oggetto x_i è un punto in uno spazio vettoriale n -dimensionale $\mathbb{R}^n$.

- **Document Data (Bag-of-Words):** Ciascun documento testuale è rappresentato da un vettore di termini (*term vector*). Ciascuna componente del vettore corrisponde a una parola del vocabolario, e il valore associato ne indica la frequenza di occorrenza nel testo.
 - **Dati Transazionali (*Transaction Data*):** Ciascun record rappresenta una transazione (identificata da un TID) e contiene un insieme variabile di articoli acquistati o eventi osservati.
2. **Dati a Grafo (*Graph Data*):** Strutture composte da nodi ed archi che modellano relazioni e connettività. Esempi includono la rete di collegamenti ipertestuali del World Wide Web, i grafi delle reti sociali e le strutture molecolari (ad esempio, la molecola planare del benzene C_6H_6).

3. Dati Ordinati (*Ordered Data*):

- **Sequenze di transazioni:** Successioni temporali di acquisti o eventi per ciascun utente.
- **Dati genomici:** Sequenze biologiche discrete composte dai caratteri dei nucleotidi $\{\text{A}, \text{C}, \text{G}, \text{T}\}$.
- **Dati Spazio-Temporali:** Misurazioni continue o campionate su coordinate geografiche e intervalli temporali regolari (ad esempio, la temperatura media mensile della superficie terrestre e oceanica).

2.3 Oggetti e Attributi

Un dataset è una collezione di **oggetti dati** (*data objects*) e dei relativi **attributi** (*attributes*).

- Un **oggetto** (noto anche come record, punto, caso, campione, entità o istanza) rappresenta una singola entità del dominio di interesse.
- Un **attributo** (noto anche come variabile, campo, caratteristica, dimensione o feature) rappresenta una proprietà o caratteristica misurabile di un oggetto (ad esempio, l'età, il reddito imponibile o il colore degli occhi).

2.3.1 Scale di Misura degli Attributi

Il tipo di scala di misura di un attributo è definito dall'insieme di proprietà algebriche e operatori matematici che conservano il significato della misura:

1. **Distinzione** ($=, \neq$): Possibilità di distinguere se due valori sono uguali o diversi.
2. **Ordine** ($<, >$): Possibilità di stabilire una relazione d'ordine tra valori.
3. **Differenze significative** ($+, -$): Presenza di un'unità di misura costante che consente di quantificare l'intervallo tra due valori (lo zero è convenzionale/arbitrario).
4. **Rapporti significativi** ($*, /$): Presenza di uno **zero assoluto intrinseco** (indicante la totale assenza della grandezza misurata), che rende significativo il confronto proporzionale tra grandezze.

2.3.2 Ulteriori Distinzioni degli Attributi

- **Attributi Binari:** Attributi nominali che ammettono esclusivamente due stati (0 e 1). Si distinguono in:
 - *Binari Simmetrici:* Entrambi gli esiti hanno pari importanza informativa (ad esempio il genere sessuale).
 - *Binari Asimmetrici:* Uno dei due esiti è raro ma di estrema rilevanza informativa (ad esempio, l'esito positivo a un test diagnostico per una malattia rara). Per convenzione, si associa il valore 1 all'evento di maggiore interesse.

Scala	Proprietà	Descrizione	Esempi	Operatori Statistici
Nominale	Distinzione ($=$, $\neq$)	Valori qualitativi o etichette categoriche senza ordinamento intrinseco	Codice fiscale, CAP, colore occhi, genere	Moda, entropia, test χ^2 , contingenza
Ordinale	Distinzione e Ordine ($=$, $\neq$, $<$, $>$)	Valori con ordinamento significativo ma intervallo non costante	Titolo di studio, scala Likert (1–10), durezza minerali	Mediana, percentili, correlazione di rango (Spearman)
Intervallo	Ordine e Differenze ($+$, $-$)	Differenze quantitative dotate di senso; lo zero è convenzionale	Temperatura in $^{\circ}\text{C}$ o $^{\circ}\text{F}$, date di calendario	Media, varianza, deviazione standard, Pearson, test t ed F
Rapporto	Tutte le 4 proprietà ($=$, $<$, $+$, $*$, $/$)	Presenza di zero assoluto; rapporti tra misure fisicamente validi	Età, reddito, massa, conteggi, Kelvin	Media geometrica, armonica, variazione percentuale

Tabella 2.1: Tassonomia delle scale di misura degli attributi (Stevens).

- **Attributi Discreti vs Continui:**

- *Discreti*: Assumono un insieme finito o numerabile di valori (tipicamente rappresentati da numeri interi, conteggi o categorie). Gli attributi binari costituiscono un caso speciale di attributo discreto.
- *Continui*: Assumono valori in un sottoinsieme continuo dei numeri reali $\mathbb{R}$ (temperatura, peso, coordinate). Nella pratica computazionale, vengono misurati e memorizzati mediante rappresentazioni in virgola mobile (*floating-point*) con precisione finita.

2.4 Qualità del Dato (Data Quality)

La qualità del dato è un fattore critico per il successo di qualunque iniziativa analitica. Come evidenziato negli studi di Thomas Redman, i problemi derivanti da dati di scarsa qualità costano tipicamente alle organizzazioni tra il 10% e il 20% dei loro ricavi complessivi. Se un modello di rischio creditizio viene addestrato su dati viziati o errati, il sistema rifiuterà debitori solvibili ed erogherà prestiti a individui insolventi.

2.4.1 Dimensioni della Qualità del Dato

I problemi di qualità si manifestano sotto diverse dimensioni:

1. **Accuratezza Sintattica (*Syntactic Accuracy*)**: Il valore registrato viola i vincoli formali o non appartiene al dominio prefissato (ad esempio, la stringa "fmale" o la presenza di lettere in un campo numerico). Tali anomalie sono identificabili in modo automatizzato mediante semplici controlli di schema.
2. **Accuratezza Semantica (*Semantic Accuracy*)**: Il dato è formalmente corretto rispetto al tipo, ma falso nella realtà di riferimento (ad esempio, associare il nome "John Smith" al genere femminile o registrare un'età di 180 anni). Rilevare queste discrepanze richiede regole di dominio (*business rules*) o incroci con sorgenti esterne affidabili.
3. **Completezza (*Completeness*)**: Mancanza sistematica di valori per determinati attributi o assenza di interi record. Una violazione tipica della completezza è il **bias di campionamento** (ad esempio, l'analisi del rischio di insolvenza svolta su un archivio storico che include solo clienti già approvati dalla banca, escludendo a priori i profili a basso reddito).

4. **Dati Sbilanciati (*Unbalanced Data*):** Distribuzione fortemente asimmetrica delle classi (ad esempio, transazioni fraudolente pari allo 0.1% del totale o prodotti difettosi su linee di produzione altamente automatizzate).
5. **Tempestività (*Timeliness*):** Obsoleto grado di aggiornamento dei dati rispetto alla dinamica corrente del fenomeno osservato.
6. **Dati Duplicati (*Duplicate Data*):** Presenza di record identici o quasi-identici relativi alla medesima entità (ad esempio, un medesimo cliente registrato più volte con indirizzi email differenti a seguito della fusione di due database). Tali discrepanze vengono affrontate tramite tecniche di deduplicazione e *record linkage*.

2.5 Statistica Descrittiva ed Esplorazione Univariata

2.5.1 Misure di Tendenza Centrale

- **Media Campionaria ($\bar{x}$):** Per un campione di dimensione m :

$$\bar{x} = \frac{1}{m} \sum_{i=1}^m x_i \quad (2.2)$$

La media è una misura distributiva (può essere calcolata partizionando il dataset in sottoinsiemi), ma è **estremamente sensibile alla presenza di outlier**.

- **Mediana:** Il valore che occupa la posizione centrale nell'ordinamento crescente delle osservazioni (o la media dei due valori centrali se m è pari). È una misura robusta, con un punto di rottura (*breakdown point*) del 50%.
- **Media Troncata (*Trimmed Mean*):** Media calcolata escludendo una percentuale fissa (ad esempio il 5% o il 10%) dei valori più estremi a entrambe le estremità.
- **Moda:** Il valore o la categoria che si presenta con la frequenza assoluta massima. Una distribuzione può essere unimodale, bimodale, multimodale, oppure priva di moda se tutte le osservazioni compaiono una sola volta.

2.5.2 Asimmetria e Multimodalità

- **Asimmetria Positiva (*Positively Skewed* / *Right-skewed*):** La coda destra della distribuzione è allungata. La maggior parte delle osservazioni è concentrata su valori inferiori alla media aritmetica (Moda < Mediana < Media). Un esempio tipico è la distribuzione dei **redditi**: la grande maggioranza dei cittadini percepisce redditi bassi o medi, mentre un esiguo numero di individui percepisce redditi estremamente elevati, trainando la media verso l'alto.
- **Distribuzione Bimodale:** Presenza di due picchi distinti nella densità di frequenza. Segnala tipicamente l'influenza di una variabile latente binaria non esplicitata (ad esempio, la distribuzione del peso corporeo umano in una popolazione mista, influenzata dalla variabile binaria sesso).

2.5.3 Misure di Dispersione

- **Range:** Differenza tra valore massimo e valore minimo: $\text{Range} = x_{\max} - x_{\min}$.
- **Varianza Campionaria (s^2) e Deviazione Standard (s):**

$$s^2 = \frac{1}{m-1} \sum_{i=1}^m (x_i - \bar{x})^2, \quad s = \sqrt{s^2} \quad (2.3)$$

La deviazione standard misura la dispersione attorno alla media; è nulla solo se tutte le osservazioni sono identiche ($s = 0$), altrimenti $s > 0$. Risulta anch'essa sensibile agli outlier.

- **Misure Robuste di Dispersione:**
 - *Absolute Average Deviation* (AAD): $\text{AAD} = \frac{1}{m} \sum |x_i - \bar{x}|$.
 - *Median Absolute Deviation* (MAD): $\text{MAD} = \text{mediana}(|x_i - \text{mediana}(x)|)$.
 - *Interquartile Range* (IQR): Distanza tra il terzo quartile Q_3 (75° percentile) e il primo quartile Q_1 (25° percentile):

$$\text{IQR} = Q_3 - Q_1 \quad (2.4)$$

2.5.4 Box Plot e Sintesi a Cinque Numeri

Il **Box Plot** (grafico a scatola e baffi) offre una sintesi visiva non parametrica della distribuzione basata sulla **sintesi a cinque numeri**:

$$[\text{Minimo}, Q_1, \text{Mediana}(Q_2), Q_3, \text{Massimo}]$$




Figura 2.1: Anatomia geometrica di un Box Plot con individuazione degli outlier.

I limiti dei baffi sono calcolati convenzionalmente estendendosi fino al valore osservato più estremo entro l'intervallo $[Q_1 - 1.5 \times IQR, Q_3 + 1.5 \times IQR]$. Le osservazioni che cadono al di fuori di tali soglie sono etichettate visivamente come **outlier**.




Figura 2.2: Esempio di Box Plot Condizionale: distribuzione dell'attributo *Petal Length* condizionata alla specie di fiore nel dataset Iris.

Confronto Critico: Box Plot vs Istogramma

Sebbene il box plot sintetizzi efficacemente posizione e dispersione, **non è in grado di mostrare la reale forma della distribuzione**. Due distribuzioni aventi densità radicalmente differenti (ad esempio, una distribuzione unimodale uniforme e una distribuzione fortemente bimodale con una valle centrale vuota) possono produrre identici valori di Q_1 , mediana, Q_3 , Minimo e Massimo, e generare pertanto lo stesso identico box plot. L'istogramma è indispensabile per rilevare la multimodalità.

2.5.5 Bar Chart per Attributi Categorici

Il **Bar Chart** (grafico a barre) rappresenta visivamente la distribuzione di frequenza di un attributo qualitativo o categorico. Ciascuna categoria




Figura 2.3: Confronto critico: due distribuzioni con andamenti diametralmente opposti (unimodale vs bimodale con centro svuotato) generano la medesima sintesi a cinque numeri e lo stesso Box Plot.

discreta è rappresentata da una barra verticale (o orizzontale), la cui altezza corrisponde al conteggio assoluto o alla frequenza relativa. A differenza degli istogrammi, le barre sono separate da spazi vuoti per evidenziare che le modalità non costituiscono un continuo numerico.




Figura 2.4: Esempio di Bar Chart per un attributo categorico nominale (Stato Civile).

2.5.6 Istogrammi per Attributi Numerici e Scelta dei Bin

Un **istogramma** mostra la distribuzione empirica di frequenza di un attributo numerico continuo. Il dominio di variabilità della grandezza viene partizionato (*discretizzato*) in un numero prefissato k di intervalli contigui detti *bin* (o classi di ampiezza). Per ciascun bin, l'altezza della barra sovrastante è proporzionale al numero di osservazioni campionarie che cadono al suo interno.




Figura 2.5: Esempio di Istogramma per un attributo numerico continuo con bin contigui di ampiezza costante.

Una scelta scorretta del numero di bin altera profondamente la percezione dei dati:

- Un numero insufficiente di bin provoca *oversmoothing*, livellando la distribuzione e mascherando asimmetrie e bimodalità.
- Un numero eccessivo di bin provoca *undersmoothing*, frammentando il campione in frequenze discontinue ed enfatizzando il rumore campionario.

Per distribuzioni unimodali prossime alla normale e campioni di dimensione moderata n , il numero raccomandato di bin è fornito dalla **regola di Sturges**:

$$k = 1 + \lceil \log_2(n) \rceil \quad (2.5)$$

2.6 Tecniche di Visualizzazione Multivariata

2.6.1 Scatter Plot e Visualizzazione a Più Dimensioni

Lo **Scatter Plot** (grafico a dispersione) tratta coppie di attributi numerici come coordinate cartesiane (x_i, y_i) nel piano. È il principale strumento visuale per:

- Identificare correlazioni lineari o andamenti funzionali non lineari.
- Rilevare addensamenti naturali di punti (*cluster*).
- Individuare outlier multivariati non visibili nelle proiezioni univariate.

Esempio 2.1 (Analisi del Dataset Iris di Anderson/Fisher). Il celebre dataset *Iris* (150 campioni di fiori appartenenti a tre specie: *Setosa*, *Versicolor*, *Virginica*) descrive 4 attributi numerici: lunghezza e larghezza del sepal, lunghezza e larghezza del petalo. Lo scatter plot bivariato mostra che gli attributi relativi al petalo (*Petal Length* vs *Petal Width*) garantiscono una separazione netta tra le specie, consentendo inoltre di isolare eventuali anomalie.




Figura 2.6: Scatter Plot bivariato con codifica grafica delle classi e rilevamento visivo di outlier locali e globali.

Per esplorare simultaneamente tutte le coppie di attributi numerici, si impiega una **Scatter Plot Matrix** (SPLM), ovvero una griglia $n \times n$ in cui ogni cella non diagonale (i, j) visualizza il grafico di dispersione tra l'attributo i e l'attributo j , mentre la diagonale principale ospita gli istogrammi o le stime di densità univariate.




Figura 2.7: Scatter Plot Matrix (SPLOM) del dataset Iris con il confronto a coppie per tutte e tre le specie e le stime di densità univariata lungo la diagonale.

2.6.2 Visualizzazione ad Alta Dimensionalità

Coordinate Parallele (Parallel Coordinates)

Quando il numero di dimensioni supera 3, la rappresentazione cartesiana convenzionale risulta inapplicabile. Le **Coordinate Parallele** sostituiscono gli assi ortogonali con un insieme di assi paralleli verticali equidistanti, ciascuno corrispondente a un attributo.




Figura 2.8: Rappresentazione di dati a 4 dimensioni mediante Coordinate Parallele per tutte e tre le specie del dataset Iris.

- Ogni oggetto multidimensionale è rappresentato da una **linea spezzata poligonale** che connette i rispettivi valori scalati lungo gli assi verticali.
- Gli oggetti appartenenti alla stessa classe tendono a formare fasci di linee parallele o con andamenti coordinati.
- **Sensibilità all'ordinamento degli assi:** La visibilità di raggruppamenti e correlazioni dipende criticamente dalla disposizione sequenziale degli assi. Due attributi fortemente correlati mostrano pattern geometrici regolari solo se posizionati come assi adiacenti.

Radar Plot e Star Plot

Nei **Radar Plot**, gli assi partono da un centro comune e si irradiano a stella a intervalli angolari costanti. Il valore di ciascun attributo definisce un vertice

lungo il proprio raggio; congiungendo i vertici si ottiene un poligono per ogni istanza. Gli **Star Plot** applicano il medesimo principio disegnando ciascun oggetto in un grafico separato, facilitando il confronto per profili individuali.




Figura 2.9: Esempio di Radar Plot con confronto visivo dei profili multivariati per tutte e tre le specie di Iris.

2.7 Analisi di Correlazione Lineare

La correlazione quantifica la forza e la direzione della relazione lineare tra due attributi numerici continui X e Y .

Definizione 2.2 (Coefficiente di Correlazione di Pearson). Dato un campione di m coppie di osservazioni (x_i, y_i) , il coefficiente campionario di correlazione lineare r_{xy} è definito come:

$$r_{xy} = \frac{\sum_{i=1}^m (x_i - \bar{x})(y_i - \bar{y})}{(m-1)s_x s_y} = \frac{\text{Cov}(X, Y)}{s_x s_y} \quad (2.6)$$

dove $\bar{x}, \bar{y}$ sono le medie campionarie e s_x, s_y le rispettive deviazioni standard.

- $r_{xy} \in [-1, +1]$.

- Se $|r_{xy}| = 1$, i punti (x_i, y_i) giacciono esattamente su una retta. Se $r_{xy} = +1$ la retta ha pendenza positiva; se $r_{xy} = -1$ ha pendenza negativa.
- Valori vicini a 0 indicano assenza di associazione **lineare**.
- **Avvertenza fondamentale:** $r_{xy} \approx 0$ non implica indipendenza statistica: possono sussistere relazioni non lineari deterministiche (ad esempio paraboliche $Y = X^2$) che il coefficiente di Pearson non è in grado di rilevare.




Figura 2.10: Interpretazione visiva del coefficiente di correlazione di Pearson: (a) correlazione positiva; (b) correlazione negativa; (c) assenza di relazione lineare; (d) dipendenza deterministica non lineare sfuggita a Pearson.

2.8 Gestione di Outlier e Valori Mancanti

2.8.1 Outlier: Rumore vs Conoscenza

Un **outlier** è un'istanza con caratteristiche che deviano marcatamente dalla maggior parte delle osservazioni:

- **Outlier come rumore:** Originati da guasti di sensori, errori di battitura o incongruenze di trasmissione. Tali anomalie falsano le misure di tendenza centrale (come la media) e i modelli predittivi, e devono pertanto essere rimossi.
- **Outlier come obiettivo analitico:** Casi eccezionali che costituiscono il vero target applicativo (transazioni bancarie fraudolente, accessi abusivi nei server, focolai di patologie rare).

Metodologie di rilevamento:

- *Singolo attributo:* Analisi delle frequenze estreme per variabili categoriche; Box Plot ($1.5 \times \text{IQR}$) e calcolo dello z -score ($z = \frac{x-\mu}{\sigma}$) per variabili numeriche.
- *Multivariato:* Scatter Plot bivariati e trivariati, proiezioni su componenti principali (*Principal Component Analysis* - PCA) e algoritmi di clustering (gli outlier sono i punti che ricadono in cluster residuali o che rimangono non assegnati).

2.8.2 Valori Mancanti (Missing Values)

Le cause della mancata registrazione di valori includono:

- Rifiuto del soggetto a rispondere (es. informazioni sul reddito o sul peso).
- Non applicabilità dell'attributo (es. reddito da lavoro dipendente per minori o disoccupati).
- Malfunzionamento temporaneo dei dispositivi di rilevamento.

Insidia dei Valori di Default Fittizi

In molti sistemi di registrazione, un valore mancante non viene salvato come NULL o NaN, bensì codificato con un valore numerico sentinella come 0, -1 o 999. Se non intercettati nella fase di Data Understanding, tali codifiche vengono trattate erroneamente come valori reali, distorcendo gravemente medie, deviazioni standard e modelli di classificazione.

2.9 Checklist Operativa di Data Understanding

Al termine della fase di esplorazione, l'analista deve aver completato le seguenti verifiche:

1. Identificazione formale della scala di misura di ogni attributo.
2. Verifica dell'accuratezza sintattica (valori fuori dominio) e semantica.
3. Ispezione e rimozione dei record duplicati.
4. Trattamento dei valori mancanti ed eliminazione di zeri fittizi o codifiche di default.
5. Rilevamento degli outlier univariati e multivariati e decisione sul loro trattamento (rumore da eliminare vs anomalia da analizzare).
6. Esame delle distribuzioni (asimmetrie, multimodalità) tramite istogrammi dimensionati secondo la regola di Sturges.
7. Calcolo della matrice di correlazione per rilevare attributi ridondanti o predittori correlati al target.

Bibliografia

- [1] Usama Fayyad, Gregory Piatetsky-Shapiro, and Padhraic Smyth. From data mining to knowledge discovery in databases. *AI Magazine*, 17(3):37–54, 1996.