

Appunti di Data Mining

Anno Accademico 2026/2027

Indice

1	Introduzione al Data Mining e Processo KDD	1
1.1	Definizione e Motivazioni Fondamentali	1
1.1.1	Prospettive Applicative	1
1.1.2	Una Confluenza di Discipline	2
1.2	Tipologie di Origine del Dato: Primari e Secondari	3
1.3	Il Processo KDD (Knowledge Discovery in Databases)	3
1.4	Tassonomia dei Compiti di Data Mining	5
1.4.1	Compiti Predittivi: La Classificazione	5
1.4.2	Compiti Descrittivi	8
1.5	Sfide Metodologiche e Computazionali nel Data Mining	10
2	Data Understanding ed Esplorazione dei Dati	11
2.1	Obiettivi del Data Understanding	11
2.2	Tipologie di Dataset	12
2.3	Oggetti e Attributi	13
2.3.1	Scale di Misura degli Attributi	13
2.3.2	Ulteriori Distinzioni degli Attributi	13
2.4	Qualità del Dato (Data Quality)	15
2.4.1	Dimensioni della Qualità del Dato	15
2.5	Statistica Descrittiva ed Esplorazione Univariata	16
2.5.1	Misure di Tendenza Centrale	16
2.5.2	Asimmetria e Multimodalità	17
2.5.3	Misure di Dispersione	17
2.5.4	Box Plot e Sintesi a Cinque Numeri	18
2.5.5	Bar Chart per Attributi Categorici	20
2.5.6	Istogrammi per Attributi Numerici e Scelta dei Bin	21
2.6	Tecniche di Visualizzazione Multivariata	22
2.6.1	Scatter Plot e Visualizzazione a Più Dimensioni	22
2.6.2	La Visualizzazione come Test ed Euristica Esplorativa	22
2.6.3	Visualizzazione ad Alta Dimensionalità	23
2.7	Analisi di Correlazione e Associazione	25

2.7.1	Motivazioni e Multicollinearità nei Modelli Predittivi .	26
2.7.2	Dalla Varianza alla Covarianza Campionaria	27
2.7.3	Origine del Segno e Interpretazione Geometrica per Quadranti	28
2.7.4	Limite della Covarianza: Dipendenza dalla Scala Metrica	28
2.7.5	Coefficiente di Correlazione Lineare di Pearson	29
2.7.6	Associazione Statistica vs Causalità e Fattori di Con- fondimento	30
2.7.7	Correlazione di Rango di Spearman per Relazioni Mo- notone	31
2.7.8	Matrice di Correlazione e Selezione delle Feature	32
2.8	Gestione di Outlier e Valori Mancanti	33
2.8.1	Outlier: Rumore vs Obiettivo Analitico	33
2.8.2	Metodologie di Rilevamento degli Outlier	33
2.8.3	Valori Mancanti (Missing Values) e Camuffamento . . .	34
2.9	Checklist Operativa di Data Understanding	34

Capitolo 1

Introduzione al Data Mining e Processo KDD

1.1 Definizione e Motivazioni Fondamentali

Il costante progresso tecnologico nella generazione e memorizzazione dei dati ha portato a una crescita esponenziale delle informazioni disponibili, sia nel contesto commerciale sia in quello scientifico. Il paradigma moderno della raccolta dati si riassume spesso nel principio di raccogliere qualsiasi dato possibile, ovunque e in qualsiasi momento, nell'aspettativa che tali dati possano acquisire valore non soltanto per lo scopo originario per cui sono stati raccolti, ma anche per scopi secondari non previsti inizialmente.

Definizione 1.1.1 (Data Mining). Il **Data Mining** è l'applicazione di tecniche ed algoritmi efficienti all'analisi di collezioni di dati di grandi dimensioni, finalizzata all'estrazione di pattern validi, inediti, potenzialmente utili e interpretabili (conoscenza nascosta o *hidden knowledge*).

Il Data Mining non consiste nella semplice esecuzione di query su basi di dati tradizionali (ad esempio, il recupero del saldo medio tramite SQL), bensì nella scoperta automatica o semi-automatica di strutture, dipendenze o regolarità non banali nei dati.

1.1.1 Prospettive Applicative

Le motivazioni alla base dell'adozione delle tecniche di Data Mining possono essere distinte principalmente secondo due punti di vista:

- **Punto di vista commerciale:** Le aziende gestiscono volumi enormi di dati (*data warehousing*): dati web (Yahoo, Facebook), transazioni

di e-commerce e vendite al dettaglio (Amazon), registrazioni di carte di credito e conti correnti bancari. A fronte di una potenza di calcolo sempre più economica e accessibile, la pressione competitiva richiede di estrarre valore da tali moli di dati per migliorare e personalizzare i servizi offerti (ad esempio nel *Customer Relationship Management - CRM*).

- **Punto di vista scientifico e sociale:** In discipline quali l'astronomia (*Sky Survey Data*), l'osservazione della Terra (i satelliti del sistema NASA EOSDIS raccolgono petabyte di dati ambientali all'anno), la genomica (espressione genica, proteomica), la neuroimaging (fMRI) e le simulazioni numeriche complesse, i dati vengono generati a velocità tali da rendere impossibile l'analisi manuale. Il Data Mining supporta gli scienziati nell'analisi automatica e nella formulazione guidata di nuove ipotesi.

I Big Data rappresentano a tutti gli effetti un proxy della vita sociale (comportamenti d'acquisto, stili di vita, opinioni, reti di relazioni, mobilità sul territorio), offrendo grandi opportunità per affrontare problematiche globali: dall'efficientamento della sanità alla ricerca di fonti di energia pulita, dalla previsione degli impatti climatici all'ottimizzazione della produzione agricola.


In tale scenario moderno, l'Intelligenza Artificiale applicata poggia sul principio cardine:

$$\mathbf{AI} = \mathbf{Machine\ Learning} + \mathbf{Big\ Data} \quad (1.1)$$

in cui la disponibilità di basi di dati su scala massiva (*Big Data*) costituisce il substrato empirico e la sorgente di informazione, mentre gli algoritmi di *Machine Learning* e *Data Mining* forniscono il motore logico-induttivo capace di estrarre generalizzazioni e schemi decisionali non banali.

1.1.2 Una Confluenza di Discipline

Il Data Mining non è una disciplina isolata, bensì una confluenza sinergica di diverse aree dell'informatica e della matematica applicata:




1.2 Tipologie di Origine del Dato: Primari e Secondari

Nell'impostazione di un progetto analitico, è fondamentale distinguere l'origine dei dati analizzati:

- **Dati Primari (*Primary Data*):** Dati originali rilevati specificamente per un preciso obiettivo di indagine. Non hanno subito alterazioni o manipolazioni preventive da parte di terzi.
- **Dati Secondari (*Secondary Data*):** Dati che erano già stati raccolti in precedenza per scopi operativi o differenti da quello corrente e resi disponibili all'analista. Spesso derivano dalla fusione di sorgenti disomogenee e necessitano di profonde operazioni di normalizzazione e verifica della qualità.

1.3 Il Processo KDD (Knowledge Discovery in Databases)

Il Data Mining costituisce una fase specifica, sebbene centrale, all'interno del più ampio processo di scoperta della conoscenza, noto come **KDD** (*Knowledge Discovery in Databases*). Il KDD è un processo iterativo e interattivo composto da diverse fasi sequenziali con cicli di retroazione:



Ciascuna fase assolve compiti specifici:

1. **Business Understanding:** Comprensione degli obiettivi di dominio e traduzione del problema di business in un problema formale di analisi dati.
2. **Data Cleaning e Data Integration:**
 - *Data Cleaning:* rimozione di rumore, correzione di errori sintattici e gestione delle incoerenze.

- *Data Integration*: aggregazione e riconciliazione di dati provenienti da fonti multiple ed eterogenee, conflueno tipicamente in un **Data Warehouse** (un repository strutturato e ottimizzato per l'analisi e il supporto alle decisioni).

3. Data Selection e Data Transformation:

- *Data Selection*: estrazione del sottoinsieme di attributi e record strettamente pertinenti al task investigato (*task-relevant data*).
 - *Data Transformation*: trasformazione delle feature mediante aggregazioni, riscalamenti, normalizzazioni o discretizzazioni affinché siano adatte all'algoritmo.
4. **Data Mining**: Esecuzione vera e propria di algoritmi intelligenti per l'estrazione di pattern e modelli matematici.
 5. **Pattern Evaluation e Knowledge Presentation**: Identificazione dei pattern realmente significativi tramite metriche oggettive e soggettive, eliminazione della ridondanza e visualizzazione grafica dei risultati mediante strumenti interpretabili dall'utente finale.

1.4 Tassonomia dei Compiti di Data Mining

Seguendo la classificazione di Fayyad et al. [1], i compiti di Data Mining si dividono in due macro-categorie:

- **Metodi Predittivi (*Prediction Methods*)**: Mirano a stimare il valore futuro o sconosciuto di una variabile target specifica a partire dai valori di altre variabili osservate (attributi predittori).
- **Metodi Descrittivi (*Description Methods*)**: Mirano a identificare pattern leggibili ed interpretabili dall'essere umano che descrivano la struttura intrinseca e le relazioni nascoste nei dati.

1.4.1 Compiti Predittivi: La Classificazione

La **classificazione** ha come obiettivo l'apprendimento di una funzione obiettivo f che mappa ogni record di attributi x in una specifica etichetta di classe discreta $y \in \mathcal{Y}$.

Il dataset viene suddiviso in due insiemi disgiunti:

- **Training Set**: Utilizzato per addestrare il classificatore.




Figura 1.1: Workflow concettuale del processo di classificazione.

- **Test Set:** Utilizzato per valutare la capacità di generalizzazione del modello su istanze non osservate durante la fase di apprendimento.

Esempio 1.4.1 (Esempio Didattico: Induzione di un Albero Decisionale per il Merito Creditizio). Consideriamo un tipico problema di concessione del credito bancario, in cui l'obiettivo è stimare se un nuovo richiedente sia finanziariamente affidabile ($Credit\ Worthy \in \{\text{Sì}, \text{No}\}$).

1. Training Set (Dati storici con classe nota): L'istituto dispone di uno storico di clienti con esito di rimborso accertato:

TID	Occupato	Livello Istruzione	Anni di Residenza	Affidabile (Classe)
1	Sì	Laurea	5	Sì
2	Sì	Diploma	2	No
3	No	Triennale	1	No
4	Sì	Diploma	10	Sì

Tabella 1.1: Training set per l'addestramento del classificatore creditizio.

2. Modello Appreso (Albero Decisionale): L'algoritmo di classificazione estrae dai dati storici una sequenza gerarchica di test logici (Fig. 1.2):

3. Test Set (Dati nuovi non osservati): Quando giungono nuove domande di prestito con classe incognita (?), il modello le valuta navigando la struttura ad albero: L'esempio illustra come il classificatore non si limiti a




Figura 1.2: Modello classificatore: albero decisionale appreso.

TID	Occupato	Istruzione	Anni	Target	Predizione del Modello
5	Sì	Triennale	7	?	Sì (Occupato → Triennale → $7 > 3$)
6	No	Laurea	3	?	No (Non occupato)
7	Sì	Diploma	2	?	No (Occupato → Diploma → $2 \leq 3$)

Tabella 1.2: Valutazione del test set mediante l'albero decisionale.

memorizzare i record del training set, ma generalizzi una regola predittiva applicabile a qualsiasi nuova istanza.

Esempio 1.4.2 (Applicazioni di Classificazione). Tra le principali e più diffuse aree applicative dei modelli di classificazione troviamo:

- **Valutazione del Merito Creditizio (*Credit Worthiness*):** Predire se un richiedente prestito rimborserà il debito (*Yes/No*) sulla base di occupazione, livello di istruzione e anni di residenza.
- **Rilevamento Frodi Bancarie:** Classificare le transazioni con carta di credito come lecite o fraudolente. Le feature includono l'importo, l'orario, la posizione geografica e il profilo storico delle spese.
- **Churn Prediction:** Stimare la probabilità che un cliente di telecomunicazioni abbandoni il servizio per passare alla concorrenza, analizzando la durata delle chiamate, il volume del traffico dati e i reclami registrati.
- **Altre applicazioni:** Categorizzazione automatica di notizie (sport, finanza, politica), diagnosi clinica (tumore benigno o maligno), classificazione di coperture del suolo da immagini satellitari.

1.4.2 Compiti Descrittivi

1. Clustering (Raggruppamento)

Il **clustering** consiste nell'organizzare un insieme di oggetti in gruppi distinti (detti *cluster*), in modo tale che:

1. La distanza tra oggetti appartenenti allo stesso cluster (**distanza intra-cluster**) sia **minimizzata** (massima omogeneità interna).
2. La distanza tra oggetti appartenenti a cluster differenti (**distanza inter-cluster**) sia **massimizzata** (massima separazione esterna).




Figura 1.3: Principio geometrico fondamentale del clustering.

Il clustering è una tecnica non supervisionata: non richiede classi a priori.

- **Segmentazione di Mercato:** Raggruppare i clienti in base a dati socio-demografici e abitudini di acquisto per indirizzare campagne di marketing differenziate.
- **Clustering Documentale:** Raggruppare documenti testuali simili in base alle frequenze congiunte delle parole chiave (ad esempio, l'analisi dell'archivio email aziendale Enron).
- **Summarization e Scienze della Terra:** Ridurre la complessità di enormi serie spaziali partizionando le misurazioni di temperatura marina superficiale (*Sea Surface Temperature* - SST) e produzione primaria (*Net Primary Production* - NPP) negli emisferi settentrionale e meridionale.

2. Scoperta di Regole di Associazione (Association Analysis)

Dato un insieme di transazioni, ciascuna costituita da un sottoinsieme di elementi presi da un insieme globale di articoli (*items*), l'analisi delle associazioni si prefigge di scoprire dipendenze probabilistiche nella forma di regole:

$$X \implies Y \quad (1.2)$$

dove X e Y sono itemset disgiunti ($X \cap Y = \emptyset$). La regola indica che la presenza degli articoli nell'antecedente X predice sistematicamente la contestuale presenza dell'articolo o degli articoli nel conseguente Y .

Esempio 1.4.3 (Market Basket Analysis). Considerando uno storico di scontrini di cassa: L'algoritmo estrae regole ad elevata evidenza statistica,

TID	Articoli Acquistati
1	Pane, Coca-Cola, Latte
2	Birra, Pane
3	Birra, Coca-Cola, Pannolini, Latte
4	Birra, Pane, Pannolini, Latte
5	Coca-Cola, Pannolini, Latte

quali:

$$\{\text{Latte}\} \implies \{\text{Coca-Cola}\}, \quad \{\text{Pannolini, Latte}\} \implies \{\text{Birra}\}$$

Tali informazioni guidano la disposizione strategica dei beni sugli scaffali e la progettazione di offerte cross-selling.

Altre applicazioni: Diagnosi di allarmi nelle reti di telecomunicazione (individuazione di pattern temporali di allarmi di rete che scattano congiuntamente per identificare guasti sistemici alla radice); informatica medica (correlazione tra combinazioni di sintomi clinici, esami ematochimici e patologie emergenti).

3. Rilevamento di Anomalie (Anomaly / Deviation / Change Detection)

Consiste nell'identificare oggetti che deviano in modo significativo dal comportamento medio o atteso della popolazione. Le anomalie possono essere generate da guasti strumentali o errori di inserimento (e in tal caso rappresentano *rumore* da epurare), oppure riflettere eventi eccezionali di estremo interesse applicativo (frodi creditizie, intrusioni informatiche contro le reti aziendali, monitoraggio di repentini disboscamenti della copertura forestale tramite sensori remoti).

1.5 Sfide Metodologiche e Computazionali nel Data Mining

L'applicazione di metodi tradizionali di analisi statistica e database è spesso inadeguata a causa di cinque sfide primarie:

1. **Scalabilità (*Scalability*):** Gli algoritmi devono gestire volumi di dati di ordine di terabyte o petabyte senza che la complessità computazionale e l'occupazione di memoria esplodano.
2. **Alta Dimensionalità (*High Dimensionality*):** La presenza di centinaia o migliaia di attributi espone alla cosiddetta *maledizione della dimensionalità* (*curse of dimensionality*), in cui lo spazio geometrico diventa estremamente vuoto e le distanze tendono a perdere discriminatività.
3. **Dati Complessi ed Eterogenei:** Necessità di elaborare strutture semi-strutturate o non strutturate (grafi, testi, sequenze genomiche, serie spaziotemporali).
4. **Proprietà e Distribuzione dei Dati:** I dati sono frequentemente distribuiti geograficamente tra molteplici organizzazioni e soggetti a stringenti vincoli legali di privacy e sicurezza.
5. **Analisi Non Tradizionali:** Esigenza di estrarre conoscenza da flussi continui in tempo reale (*data stream mining*) senza possibilità di memorizzare l'intero dataset.

Capitolo 2

Data Understanding ed Esplorazione dei Dati

2.1 Obiettivi del Data Understanding

La fase di comprensione dei dati (*Data Understanding*) costituisce un prerequisito indispensabile per qualsiasi attività di Data Mining. Prima di selezionare o applicare qualsiasi algoritmo, l'analista deve acquisire una visione complessiva della struttura, della distribuzione e della qualità intrinseca del dataset rispetto agli obiettivi del progetto.

In questa fase preliminare è necessario rispondere a domande metodologiche cruciali:

- Quali tipologie di attributi compongono il dataset?
- Qual è il livello complessivo di qualità dei dati (presenza di rumore, errori o duplicati)?
- Come sono distribuite le variabili numeriche e categoriche?
- Sono presenti correlazioni evidenti o ridondanze tra gli attributi?
- Come sono strutturati gli outlier e quale significato applicativo assumono?
- Quali strategie adottare per i valori mancanti?
- È necessario derivare o trasformare attributi per rendere più efficace il mining?

2.2 Tipologie di Dataset

I dati raccolti si presentano in diverse strutture logico-geometriche in base alla natura del dominio applicativo:

1. Dati di tipo Record:

- **Data Matrix:** Insieme di oggetti descritti dallo stesso insieme fissato di attributi numerici. Un dataset di m oggetti e n attributi è rappresentato formalmente da una matrice $m \times n$:

$$\mathbf{X} = \begin{pmatrix} x_{1,1} & x_{1,2} & \cdots & x_{1,n} \\ x_{2,1} & x_{2,2} & \cdots & x_{2,n} \\ \vdots & \vdots & \ddots & \vdots \\ x_{m,1} & x_{m,2} & \cdots & x_{m,n} \end{pmatrix} \quad (2.1)$$

In tale formalizzazione, ciascun oggetto x_i è un punto in uno spazio vettoriale n -dimensionale $\mathbb{R}^n$.

- **Document Data (Bag-of-Words):** Ciascun documento testuale è rappresentato da un vettore di termini (*term vector*). Ciascuna componente del vettore corrisponde a una parola del vocabolario, e il valore associato ne indica la frequenza di occorrenza nel testo.
 - **Dati Transazionali (*Transaction Data*):** Ciascun record rappresenta una transazione (identificata da un TID) e contiene un insieme variabile di articoli acquistati o eventi osservati.
2. **Dati a Grafo (*Graph Data*):** Strutture composte da nodi ed archi che modellano relazioni e connettività. Esempi includono la rete di collegamenti ipertestuali del World Wide Web, i grafi delle reti sociali e le strutture molecolari (ad esempio, la molecola planare del benzene C_6H_6).

3. Dati Ordinati (*Ordered Data*):

- **Sequenze di transazioni:** Successioni temporali di acquisti o eventi per ciascun utente.
- **Dati genomici:** Sequenze biologiche discrete composte dai caratteri dei nucleotidi $\{A, C, G, T\}$.
- **Dati Spazio-Temporali:** Misurazioni continue o campionate su coordinate geografiche e intervalli temporali regolari (ad esempio, la temperatura media mensile della superficie terrestre e oceanica).

2.3 Oggetti e Attributi

Un dataset è una collezione di **oggetti dati** (*data objects*) e dei relativi **attributi** (*attributes*).

- Un **oggetto** (noto anche come record, punto, caso, campione, entità o istanza) rappresenta una singola entità del dominio di interesse.
- Un **attributo** (noto anche come variabile, campo, caratteristica, dimensione o feature) rappresenta una proprietà o caratteristica misurabile di un oggetto (ad esempio, l'età, il reddito imponibile o il colore degli occhi).

2.3.1 Scale di Misura degli Attributi

Il tipo di scala di misura di un attributo è definito dall'insieme di proprietà algebriche e operatori matematici che conservano il significato della misura:

1. **Distinzione** ($=, \neq$): Possibilità di distinguere se due valori sono uguali o diversi.
2. **Ordine** ($<, >$): Possibilità di stabilire una relazione d'ordine tra valori.
3. **Differenze significative** ($+, -$): Presenza di un'unità di misura costante che consente di quantificare l'intervallo tra due valori (lo zero è convenzionale/arbitrario).
4. **Rapporti significativi** ($*, /$): Presenza di uno **zero assoluto intrinseco** (indicante la totale assenza della grandezza misurata), che rende significativo il confronto proporzionale tra grandezze.

2.3.2 Ulteriori Distinzioni degli Attributi

- **Attributi Binari:** Attributi nominali che ammettono esclusivamente due stati (0 e 1). Si distinguono in:
 - *Binari Simmetrici:* Entrambi gli esiti hanno pari importanza informativa (ad esempio il genere sessuale).
 - *Binari Asimmetrici:* Uno dei due esiti è raro ma di estrema rilevanza informativa (ad esempio, l'esito positivo a un test diagnostico per una malattia rara). Per convenzione, si associa il valore 1 all'evento di maggiore interesse.

Scala	Proprietà	Descrizione	Esempi	Operatori Statistici
Nominale	Distinzione ($=$, $\neq$)	Valori qualitativi o etichette categoriche senza ordinamento intrinseco	Codice fiscale, CAP, colore occhi, genere	Moda, entropia, test χ^2 , contingenza
Ordinale	Distinzione e Ordine ($=$, $\neq$, $<$, $>$)	Valori con ordinamento significativo ma intervallo non costante	Titolo di studio, scala Likert (1–10), durezza minerali	Mediana, percentili, correlazione di rango (Spearman)
Intervallo	Ordine e Differenze ($+$, $-$)	Differenze quantitative dotate di senso; lo zero è convenzionale	Temperatura in $^{\circ}\text{C}$ o $^{\circ}\text{F}$, date di calendario	Media, varianza, deviazione standard, Pearson, test t ed F
Rapporto	Tutte le 4 proprietà ($=$, $<$, $+$, $*$, $/$)	Presenza di zero assoluto; rapporti tra misure fisicamente validi	Età, reddito, massa, conteggi, Kelvin	Media geometrica, armonica, variazione percentuale

Tabella 2.1: Tassonomia delle scale di misura degli attributi (Stevens).

- **Attributi Discreti vs Continui:**

- *Discreti*: Assumono un insieme finito o numerabile di valori (tipicamente rappresentati da numeri interi, conteggi o categorie). Gli attributi binari costituiscono un caso speciale di attributo discreto.
- *Continui*: Assumono valori in un sottoinsieme continuo dei numeri reali $\mathbb{R}$ (temperatura, peso, coordinate). Nella pratica computazionale, vengono misurati e memorizzati mediante rappresentazioni in virgola mobile (*floating-point*) con precisione finita.

2.4 Qualità del Dato (Data Quality)

La qualità del dato è un fattore critico per il successo di qualunque iniziativa analitica. Come evidenziato negli studi di Thomas Redman, i problemi derivanti da dati di scarsa qualità costano tipicamente alle organizzazioni tra il 10% e il 20% dei loro ricavi complessivi. Se un modello di rischio creditizio viene addestrato su dati viziati o errati, il sistema rifiuterà debitori solvibili ed erogherà prestiti a individui insolventi.

2.4.1 Dimensioni della Qualità del Dato

I problemi di qualità si manifestano sotto diverse dimensioni:

1. **Accuratezza Sintattica (*Syntactic Accuracy*)**: Il valore registrato viola i vincoli formali o non appartiene al dominio prefissato (ad esempio, la stringa "female" per il sesso, o la presenza di caratteri testuali in un campo numerico). Tali anomalie sono identificabili in modo immediato ed automatizzato mediante semplici controlli di schema e tipi.
2. **Accuratezza Semantica (*Semantic Accuracy*)**: Il dato è formalmente corretto e conforme al tipo previsto, ma falso nella realtà di riferimento (ad esempio, associare il nome anagrafico "John Smith" al genere femminile, o registrare un'età biologica pari a 180 anni). Rilevare queste discrepanze richiede la definizione di regole di dominio (*business rules*) o incroci con sorgenti esterne certificate.
3. **Completezza (*Completeness*)**: Mancanza sistematica di valori per determinati attributi o assenza di interi record. Una violazione insidiosa della completezza è il **bias di campionamento** (ad esempio, l'analisi del rischio di insolvenza svolta su un archivio storico che include esclusivamente clienti a cui il credito era già stato concesso, escludendo a priori i profili a basso reddito respinti).

4. **Dati Sbilanciati (*Unbalanced Data*):** Distribuzione fortemente asimmetrica delle classi (ad esempio, transazioni fraudolente pari allo 0.1% del totale o prodotti difettosi su linee di produzione ad altissima automazione).
5. **Tempestività (*Timeliness*):** Obsoleto grado di aggiornamento dei dati rispetto alla dinamica corrente del fenomeno osservato.
6. **Dati Duplicati (*Duplicate Data*):** Presenza di record identici o quasi-identici relativi alla medesima entità (ad esempio, un medesimo cliente registrato più volte con indirizzi email differenti a seguito della fusione di due banche dati eterogenee). Tali problematiche richiedono processi dedicati di deduplicazione e *record linkage*.

Anomalie nei Flussi di Misurazione e Sensori

Nei sistemi di monitoraggio industriale e IoT, un sensore guasto o bloccato trasmette tipicamente un valore costante pari a zero. In fase di esplorazione, tali registrazioni non devono essere considerate misurazioni fisiche effettive, bensì interpretate e gestite a tutti gli effetti come **valori mancanti** (dovuti a malfunzionamento del dispositivo).

2.5 Statistica Descrittiva ed Esplorazione Univariata

2.5.1 Misure di Tendenza Centrale

- **Media Campionaria ($\bar{x}$):** Per un campione di dimensione m :

$$\bar{x} = \frac{1}{m} \sum_{i=1}^m x_i \quad (2.2)$$

La media è una misura distributiva (può essere calcolata partizionando il dataset in sottoinsiemi), ma è **estremamente sensibile alla presenza di outlier**.

- **Mediana:** Il valore che occupa la posizione centrale nell'ordinamento crescente delle osservazioni (o la media dei due valori centrali se m è pari). È una misura robusta, con un punto di rottura (*breakdown point*) del 50%.

- **Media Troncata (*Trimmed Mean*):** Media calcolata escludendo una percentuale fissa (ad esempio il 5% o il 10%) dei valori più estremi a entrambe le estremità.
- **Moda:** Il valore o la categoria che si presenta con la frequenza assoluta massima. Una distribuzione può essere unimodale, bimodale, multimodale, oppure priva di moda se tutte le osservazioni compaiono una sola volta.

2.5.2 Asimmetria e Multimodalità

- **Asimmetria Positiva (*Positively Skewed / Right-skewed*):** La coda destra della distribuzione è allungata. La maggior parte delle osservazioni è concentrata su valori inferiori alla media aritmetica (Moda < Mediana < Media). Un esempio tipico è la distribuzione dei **redditi**: la grande maggioranza dei cittadini percepisce redditi bassi o medi, mentre un esiguo numero di individui percepisce redditi estremamente elevati, trainando la media verso l'alto.
- **Distribuzione Bimodale:** Presenza di due picchi distinti nella densità di frequenza. Segnala tipicamente l'influenza di una variabile latente binaria non esplicitata (ad esempio, la distribuzione del peso corporeo umano in una popolazione mista, influenzata dalla variabile binaria sesso).

2.5.3 Misure di Dispersione

- **Range:** Differenza tra valore massimo e valore minimo: $\text{Range} = x_{\max} - x_{\min}$.
- **Varianza Campionaria (s^2) e Deviazione Standard (s):**

$$s^2 = \frac{1}{m-1} \sum_{i=1}^m (x_i - \bar{x})^2, \quad s = \sqrt{s^2} \quad (2.3)$$

La deviazione standard misura la dispersione attorno alla media; è nulla solo se tutte le osservazioni sono identiche ($s = 0$), altrimenti $s > 0$. Risulta anch'essa sensibile agli outlier.

- **Misure Robuste di Dispersione:**

– *Absolute Average Deviation* (AAD):

$$\text{AAD} = \frac{1}{m} \sum_{i=1}^m |x_i - \bar{x}| \quad (2.4)$$

– *Median Absolute Deviation* (MAD):

$$\text{MAD} = \text{mediana}(|x_i - \text{mediana}(x)|) \quad (2.5)$$

– *Interquartile Range* (IQR): Distanza tra il terzo quartile Q_3 (75° percentile) e il primo quartile Q_1 (25° percentile):

$$\text{IQR} = Q_3 - Q_1 \quad (2.6)$$

2.5.4 Box Plot e Sintesi a Cinque Numeri

Il **Box Plot** (grafico a scatola e baffi) offre una sintesi visiva non parametrica della distribuzione basata sulla **sintesi a cinque numeri**:

$$[\text{Minimo}, Q_1, \text{Mediana}(Q_2), Q_3, \text{Massimo}]$$

La costruzione geometrica si fonda sul concetto di quantile: dato $p \in (0, 100)$, il $p\%$ -**quantile** (o p -esimo percentile) è la soglia x_p tale per cui il $p\%$ delle osservazioni campionarie assume valori inferiori o uguali a x_p , mentre il $(100 - p)\%$ assume valori superiori. In particolare:

- Q_1 corrisponde al 25%-quantile (primo quartile).
- La mediana Q_2 corrisponde al 50%-quantile (secondo quartile).
- Q_3 corrisponde al 75%-quantile (terzo quartile).
- La larghezza della scatola centrale riflette l'intervallo interquartile $\text{IQR} = Q_3 - Q_1$, racchiudendo il 50% centrale della massa dei dati.




Figura 2.1: Anatomia geometrica di un Box Plot con individuazione degli outlier.

I limiti dei baffi sono calcolati convenzionalmente estendendosi fino al valore osservato più estremo entro l'intervallo $[Q_1 - 1.5 \times \text{IQR}, Q_3 + 1.5 \times \text{IQR}]$.

Le osservazioni che cadono al di fuori di tali soglie sono etichettate visivamente come **outlier**.

Un'estensione fondamentale per l'analisi bivariata e multivariata è costituita dai **Box Plot Condizionali** (*Conditional Box Plots*): la distribuzione di un attributo numerico continuo viene stratificata e visualizzata affiancando i box plot per ciascuna modalità o categoria di una variabile discreta (tipicamente la classe target o un raggruppamento naturale). In Figura 2.2 è illustrata la distribuzione della lunghezza del petalo (*Petal Length*) stratificata sulle tre specie del dataset Iris: il grafico evidenzia visivamente che la specie *Setosa* è nettamente separabile dalle restanti due con variabilità molto ridotta, mentre *Versicolor* e *Virginica* presentano una parziale sovrapposizione nei rispettivi intervalli interquartili.




Figura 2.2: Box Plot Condizionale calcolato sui dati reali del dataset Iris: distribuzione empirica della lunghezza del petalo (*Petal Length*) stratificata sulle tre specie, con evidenza della mediana, dei quartili e dei singoli campioni osservati.

Confronto Critico: Box Plot vs Istogramma

Sebbene il box plot sintetizzi efficacemente posizione e dispersione, **non è in grado di mostrare la reale forma della distribuzione**. Due distribuzioni aventi densità radicalmente differenti (ad esempio, una distribuzione unimodale uniforme e una distribuzione fortemente bimodale con una valle centrale vuota) possono produrre identici valori di Q_1 , mediana, Q_3 , Minimo e Massimo, e generare pertanto lo stesso identico box plot. L'istogramma è indispensabile per rilevare la multimodalità.




Figura 2.3: Confronto critico: due distribuzioni con andamenti diametralmente opposti (unimodale vs bimodale con centro svuotato) generano la medesima sintesi a cinque numeri e lo stesso Box Plot.

2.5.5 Bar Chart per Attributi Categorici

Il **Bar Chart** (grafico a barre) rappresenta visivamente la distribuzione di frequenza di un attributo qualitativo o categorico. Ciascuna categoria discreta è rappresentata da una barra verticale (o orizzontale), la cui altezza corrisponde al conteggio assoluto o alla frequenza relativa. A differenza degli istogrammi, le barre sono separate da spazi vuoti per evidenziare che le modalità non costituiscono un continuo numerico.




Figura 2.4: Esempio di Bar Chart per un attributo categorico nominale (Stato Civile).

2.5.6 Istogrammi per Attributi Numerici e Scelta dei Bin

Un **istogramma** mostra la distribuzione empirica di frequenza di un attributo numerico continuo. Il dominio di variabilità della grandezza viene partizionato (*discretizzato*) in un numero prefissato k di intervalli contigui detti *bin* (o classi di ampiezza). Per ciascun bin, l'altezza della barra sovrastante è proporzionale al numero di osservazioni campionarie che cadono al suo interno.




Figura 2.5: Esempio di Istogramma per un attributo numerico continuo con bin contigui di ampiezza costante.

Una scelta scorretta del numero di bin altera profondamente la percezione dei dati:

- Un numero insufficiente di bin provoca *oversmoothing*, livellando la distribuzione e mascherando asimmetrie e bimodalità.
- Un numero eccessivo di bin provoca *undersmoothing*, frammentando il campione in frequenze discontinue ed enfatizzando il rumore campionario.

Per distribuzioni unimodali approssimativamente normali e campioni di dimensione moderata n , la stima standard del numero ottimale di intervalli è fornita dalla **regola di Sturges**:

$$k = 1 + \lceil \log_2(n) \rceil = 1 + \lceil 3.322 \log_{10}(n) \rceil \quad (2.7)$$

dove n rappresenta la cardinalità campionaria. Tale euristica assume esplicitamente una distribuzione di tipo gaussiano. Quando il volume dei dati cresce notevolmente o la distribuzione sottostante presenta più modi o forte asimmetria, la regola di Sturges tende a generare un numero insufficiente di

classi; in tali casi risulta fondamentale testare sperimentalmente diversi valori di k (ad esempio confrontando partizioni a bassa, media ed elevata risoluzione, come 5, 17 o 50 bin) per verificare la stabilità dei pattern riscontrati.

2.6 Tecniche di Visualizzazione Multivariata

2.6.1 Scatter Plot e Visualizzazione a Più Dimensioni

Lo **Scatter Plot** (grafico a dispersione) tratta coppie di attributi numerici come coordinate cartesiane (x_i, y_i) nel piano. È il principale strumento visuale per:

- Identificare correlazioni lineari o andamenti funzionali non lineari.
- Rilevare addensamenti naturali di punti (*cluster*).
- Individuare outlier multivariati non visibili nelle proiezioni univariate.

Esempio 2.6.1 (Analisi del Dataset Iris di Anderson/Fisher). Il celebre dataset *Iris* (150 campioni di fiori appartenenti a tre specie: *Setosa*, *Versicolor*, *Virginica*) descrive 4 attributi numerici: lunghezza e larghezza del sepal, lunghezza e larghezza del petalo. Lo scatter plot bivariato mostra che gli attributi relativi al petalo (*Petal Length* vs *Petal Width*) garantiscono una separazione netta tra le specie, consentendo inoltre di isolare eventuali anomalie.

Per esplorare simultaneamente tutte le coppie di attributi numerici, si impiega una **Scatter Plot Matrix** (SPLM), ovvero una griglia $n \times n$ in cui ogni cella non diagonale (i, j) visualizza il grafico di dispersione tra l'attributo i e l'attributo j , mentre la diagonale principale ospita gli istogrammi o le stime di densità univariate.

2.6.2 La Visualizzazione come Test ed Euristica Esplorativa

L'ispezione visiva rappresenta un primo insostituibile test esplorativo sulla presenza di struttura nei dati, la cui corretta interpretazione richiede una precisa consapevolezza metodologica:

- **Presenza di evidenza grafica:** Quando le visualizzazioni evidenziano pattern netti, raggruppamenti separati (*cluster*) o eccezioni isolate (*outlier*), si ha la certezza empirica che vi sia una proprietà strutturale reale o un fenomeno oggettivo all'interno del dataset.




Figura 2.6: Scatter Plot bivariato reale (*Petal Length* vs *Petal Width*) per tutti i 150 campioni del dataset Iris, con codifica cromatica e geometrica per classe e identificazione visiva della netta separazione di *Setosa* e dei punti atipici di confine.

- **Assenza di evidenza grafica non implica assenza di struttura:** Al contrario, quando le visualizzazioni ordinarie non mostrano alcuna configurazione apparente o sembrano puramente casuali, **non** si può dedurre che i dati siano privi di relazioni. Relazioni multivariate complesse, deboli associazioni non lineari o dipendenze spaziali che coinvolgono quattro o più attributi contemporaneamente sfuggono intrinsecamente a proiezioni bidimensionali, richiedendo l'impiego di tecniche analitiche o proiezioni a dimensionalità superiore.

2.6.3 Visualizzazione ad Alta Dimensionalità

Coordinate Parallele (Parallel Coordinates)

Quando il numero di dimensioni supera 3, la rappresentazione cartesiana convenzionale risulta inapplicabile. Le **Coordinate Parallele** sostituiscono gli assi ortogonali con un insieme di assi paralleli verticali equidistanti, ciascuno corrispondente a un attributo.

- Ogni oggetto multidimensionale è rappresentato da una **linea spezzata poligonale** che connette i rispettivi valori scalati lungo gli assi verticali.




Figura 2.7: Scatter Plot Matrix (SPLOM) calcolata su tutti i 150 campioni del dataset Iris attraverso i 4 attributi continui, con stima di densità univariata (KDE) sulla diagonale principale e grafici di dispersione bivariati nelle celle esterne.




Figura 2.8: Rappresentazione a 4 dimensioni mediante Coordinate Parallele calcolata sui dati reali del dataset Iris (150 campioni normalizzati in $[0, 1]$): le curve sottili rappresentano le singole osservazioni, mentre le linee marcate evidenziano i profili medi distintivi di ciascuna specie.

- Gli oggetti appartenenti alla stessa classe tendono a formare fasci di linee parallele o con andamenti coordinati.
- **Sensibilità all'ordinamento degli assi:** La visibilità di raggruppamenti e correlazioni dipende criticamente dalla disposizione sequenziale degli assi. Due attributi fortemente correlati mostrano pattern geometrici regolari solo se posizionati come assi adiacenti.

Radar Plot e Star Plot

Nei **Radar Plot**, gli assi partono da un centro comune e si irradiano a stella a intervalli angolari costanti. Il valore di ciascun attributo definisce un vertice lungo il proprio raggio; congiungendo i vertici si ottiene un poligono per ogni istanza. Gli **Star Plot** applicano il medesimo principio disegnando ciascun oggetto in un grafico separato, facilitando il confronto per profili individuali.

2.7 Analisi di Correlazione e Associazione

L'analisi di correlazione ha lo scopo di identificare, quantificare e interpretare la forza e la direzione della relazione lineare tra coppie di attributi numerici continui.




Figura 2.9: Radar Plot empirico multivariato calcolato sui profili medi normalizzati delle tre specie di Iris sui 4 attributi morfologici.

2.7.1 Motivazioni e Multicollinearità nei Modelli Predittivi

Nel processo di data understanding, valutare la correlazione tra variabili persegue diversi obiettivi metodologici:

- **Individuazione di ridondanze informative:** Se due attributi manifestano un andamento pressoché coincidente, uno di essi può essere scartato senza perdita apprezzabile di potere descrittivo, riducendo la dimensionalità dello spazio di lavoro.
- **Preparazione per modelli predittivi e clustering:** Molteplici algoritmi di machine learning (quali regressione lineare, logistic regression o clustering basato su distanze) assumono feature indipendenti o beneficiano fortemente della rimozione di attributi collineari.
- **Rilevamento della multicollinearità:** Si verifica quando due o più variabili predittive (*feature*) in un modello di regressione risultano fortemente legate da una relazione lineare. Si consideri l'esempio paradigmatico della stima del valore degli immobili impiegando congiuntamente come predittori sia la *superficie in metri quadri* (m^2) sia la *superficie in piedi quadri* (ft^2). Le due variabili veicolano esattamente la medesima informazione; di conseguenza, il modello di regressione entra

in severa instabilità numerica, non riuscendo ad isolare il contributo marginale di ciascun predittore e gonfiando la varianza degli stimatori.

2.7.2 Dalla Varianza alla Covarianza Campionaria

Mentre la varianza campionaria quantifica la dispersione delle osservazioni di una singola variabile attorno alla propria media:

$$s_x^2 = \text{Var}(X) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \quad (2.8)$$

nelle applicazioni analitiche l'interesse è costantemente rivolto alle interazioni tra coppie di variabili:

- I clienti con reddito imponibile più elevato tendono a spendere somme maggiori?
- Il prezzo unitario di un bene determina una contrazione delle quantità vendute?
- Un maggior numero di ore di studio settimanali conduce sistematicamente a voti d'esame superiori?
- Due sensori fisici disposti in parallelo forniscono misure ampiamente ridondanti?

Per misurare come due grandezze numeriche variano simultaneamente, si introduce la **covarianza campionaria**:

Definizione 2.7.1 (Covarianza Campionaria). Dato un campione di n coppie di valori (x_i, y_i) , la covarianza campionaria tra X e Y è definita da:

$$\text{Cov}(X, Y) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \quad (2.9)$$

dove $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ e $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$ rappresentano le medie campionarie.

Una proprietà teorica fondamentale sancisce che la varianza è semplicemente la covarianza di una variabile con se stessa:

$$\text{Cov}(X, X) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \text{Var}(X) = s_x^2 \quad (2.10)$$

2.7.3 Origine del Segno e Interpretazione Geometrica per Quadranti

Il segno algebrico di ciascun termine della sommatoria dipende dal prodotto degli scarti congiunti rispetto alle medie:

- **Scarti concordi positivi:** $(x_i - \bar{x}) > 0$ e $(y_i - \bar{y}) > 0 \implies (+) \times (+) = +$.
- **Scarti concordi negativi:** $(x_i - \bar{x}) < 0$ e $(y_i - \bar{y}) < 0 \implies (-) \times (-) = +$.
- **Scarti discordi:** $(+) \times (-) = -$ oppure $(-) \times (+) = -$.

Traslando l'origine cartesiana nel baricentro $(\bar{x}, \bar{y})$, lo spazio viene suddiviso in quattro quadranti (Figura 2.10):

1. Se dominano le osservazioni nei quadranti **I e III** (scarti concordi), i prodotti positivi prevalgono e la covarianza campionaria è positiva ($\text{Cov}(X, Y) > 0$).
2. Se prevalgono i quadranti **II e IV** (scarti discordi), dominano i prodotti negativi e la covarianza risulta negativa ($\text{Cov}(X, Y) < 0$).
3. Se i punti sono dispersi in modo uniforme o simmetrico tra i quattro quadranti, i termini positivi e negativi si elidono reciprocamente, generando una covarianza prossima a zero ($\text{Cov}(X, Y) \approx 0$).

2.7.4 Limite della Covarianza: Dipendenza dalla Scala Metrica

Nonostante la covarianza indichi chiaramente il segno della concordanza lineare, essa presenta un limite critico: **dipende strettamente dalle unità di misura delle variabili**. Si consideri ad esempio la relazione tra reddito annuo e spesa:

- Se entrambe le variabili sono espresse in euro, l'unità di misura della covarianza è pari a euro².
- Se si converte il reddito in *migliaia di euro*, il valore numerico della covarianza subisce un ridimensionamento di un fattore 1000, sebbene la relazione sostanziale sottostante tra le grandezze rimanga rigorosamente immutata.




Figura 2.10: Interpretazione geometrica della covarianza per quadranti centrati in $(\bar{x}, \bar{y})$. I punti nei quadranti concordi I e III producono contributi positivi, mentre i quadranti discordi II e IV producono contributi negativi.

Di conseguenza, la covarianza descrive la direzione della dipendenza lineare, ma la sua magnitudo assoluta non è comparabile tra coppie di variabili eterogenee né quantifica l'intensità intrinseca del legame.

2.7.5 Coefficiente di Correlazione Lineare di Pearson

Per ottenere una misura standardizzata e priva di unità di misura, si divide la covarianza campionaria per il prodotto delle rispettive deviazioni standard:

Definizione 2.7.2 (Coefficiente di Correlazione di Pearson). Dato un campione di n coppie (x_i, y_i) , il coefficiente campionario di correlazione lineare r_{xy} è definito come:

$$r_{xy} = \frac{\text{Cov}(X, Y)}{s_x s_y} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}} \quad (2.11)$$

dove s_x, s_y sono le deviazioni standard campionarie di X e Y .

Proprietà cardine del coefficiente di Pearson:

- **Adimensionalità e invarianza di scala:** r_{xy} è un numero puro, invariante rispetto a qualunque riscalamento lineare affine positivo ($X' = aX + b$, con $a > 0$).
- **Delimitazione:** Risulta sempre $-1 \leq r_{xy} \leq +1$.

- **Perfetta collinearità** ($|r_{xy}| = 1$): I punti giacciono esattamente su una linea retta; con pendenza positiva se $r_{xy} = +1$, negativa se $r_{xy} = -1$.
- **Assenza di relazione lineare** ($r_{xy} \approx 0$): Segnala l'assenza di un legame lineare.
- **Cecità alle relazioni non lineari**: Come illustrato in Figura 2.11(d), un coefficiente nullo ($r_{xy} \approx 0$) non dimostra affatto indipendenza: relazioni deterministiche paraboliche o quadratiche possono avere correlazione lineare esattamente pari a zero.




Figura 2.11: Interpretazione visiva del coefficiente di correlazione di Pearson: (a) correlazione positiva; (b) correlazione negativa; (c) assenza di relazione lineare; (d) dipendenza deterministica non lineare sfuggita a Pearson.

2.7.6 Associazione Statistica vs Causalità e Fattori di Confondimento

Un principio fondamentale nella data science è la distinzione epistemologica tra associazione e causazione:

$$\text{Correlazione} \neq \text{Causalità} \quad (2.12)$$

Si consideri un dataset accademico in cui il numero di ore settimanali dedicate allo studio e i voti d'esame mostrano un'elevata correlazione positiva ($r_{xy} = +0.98$). Gli studenti con meno ore di studio tendono a trovarsi sotto la media, mentre chi studia più ore si colloca sopra la media. Tale dato riflette una fortissima associazione statistica, ma **non autorizza a concludere che 2 ore aggiuntive di studio causino direttamente e deterministicamente un incremento prefissato del voto**. Molteplici altre variabili (preparazione pregressa, frequenza alle lezioni, attenzione in aula) possono influenzare congiuntamente entrambi gli aspetti.

La correlazione lineare:

1. Non identifica la direzione della causalità ($X \rightarrow Y$ oppure $Y \rightarrow X$).
2. Può essere generata da un **fattore di confondimento** (*confounding variable*).

Esempio 2.7.1 (La Variabile Confondente: Gelati e Annegamenti). Nelle statistiche estive si osserva una correlazione positiva molto forte tra il volume di vendite di gelati e il numero di incidenti da annegamento. Chiaramente mangiare gelati non provoca annegamenti. Esiste una terza variabile latente non inclusa nella coppia, la **temperatura esterna elevata**, che aumenta simultaneamente sia la domanda di gelati sia il numero di bagnanti in acqua, inducendo una correlazione spuria tra le due grandezze.

2.7.7 Correlazione di Rango di Spearman per Relazioni Monotone

Nei contesti in cui la dipendenza tra due grandezze non è strettamente lineare, oppure in presenza di outlier marcati che distorcono la media e la deviazione standard, si ricorre al **coefficiente di correlazione di rango di Spearman** (ρ_s).

Spearman non confronta direttamente i valori numerici grezzi, ma li sostituisce con la loro posizione ordinale o **rango** (*rank*) nell'ordinamento crescente del campione:

Definizione 2.7.3 (Coefficiente di Correlazione di Rango di Spearman). Siano $\text{rank}(x_i)$ e $\text{rank}(y_i)$ i ranghi di x_i e y_i . Se non vi sono ex aequo (*ties*), il coefficiente è formulato come:

$$\rho_s = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)}, \quad \text{con } d_i = \text{rank}(x_i) - \text{rank}(y_i) \quad (2.13)$$

In presenza di ranghi parimerito, ρ_s equivale al coefficiente di Pearson calcolato direttamente sulle sequenze dei ranghi.

Proprietà essenziali:

- $\rho_s = +1$ quando l'ordinamento delle due variabili coincide perfettamente (relazione **monotona crescente**).
- $\rho_s = -1$ quando l'ordinamento è esattamente invertito (relazione **monotona decrescente**).
- Misura se due grandezze tendono a variare nella stessa direzione o in direzione opposta, senza vincoli di linearità (ad esempio per $Y = X^3$ o $Y = \log(X)$ si ha $\rho_s = 1$).
- Gode di elevata robustezza rispetto a valori estremi o outlier isolati.

2.7.8 Matrice di Correlazione e Selezione delle Feature

In dataset con molteplici attributi continui, si calcolano tutte le correlazioni bivariate a coppie organizzandole in una **matrice di correlazione** simmetrica $p \times p$. Nell'analisi del dataset Iris (Figura 2.12), ad esempio, la matrice evidenzia una fortissima correlazione sia lineare che monotonica tra *Petal Length* e *Petal Width* ($r = 0.96$, $\rho_s = 0.94$), e tra *Sepal Length* e *Petal Length* ($r = 0.87$, $\rho_s = 0.88$), segnalando una rilevante ridondanza informativa che suggerisce la possibilità di fondere o selezionare solo uno dei due attributi per l'addestramento di classificatori e modelli predittivi.




Figura 2.12: Matrici di correlazione bivariata calcolate sul dataset Iris: a sinistra la correlazione lineare di Pearson (r), a destra la correlazione di rango di Spearman (ρ_s). Si evidenzia visivamente l'intensa associazione positiva tra le dimensioni dei petali e l'associazione moderatamente negativa tra la larghezza del sepal e le restanti feature.

2.8 Gestione di Outlier e Valori Mancanti

2.8.1 Outlier: Rumore vs Obiettivo Analitico

Un **outlier** (anomalia o valore aberrante) è un'istanza con caratteristiche che deviano in modo marcato dalla maggior parte delle osservazioni del campione:

- **Outlier come rumore (*noise*):** Generati da errori materiali di digitazione, malfunzionamenti transitori di sensori fisici o problemi nella conversione dei formati. Tali osservazioni falsano drasticamente medie, varianze e modelli di regressione, e devono essere identificate e rimosse (o corrette) nel pre-processing.
- **Outlier come obiettivo analitico (*target*):** Situazioni insolite o eccezionali reali, che rappresentano il primario scopo applicativo dell'analisi. Casi tipici comprendono la rilevazione di **frodi con carte di credito**, l'individuazione di **intrusioni informatiche di rete** (*intrusion detection*) e la diagnosi precoce di **patologie mediche rare**.

Anche qualora gli outlier derivino da misurazioni corrette di eventi rari, può risultare opportuno escluderli temporaneamente dal calcolo di parametri aggregati qualora l'obiettivo sia caratterizzare il comportamento della popolazione tipica.

2.8.2 Metodologie di Rilevamento degli Outlier

L'identificazione delle anomalie si articola su differenti livelli di dimensionalità:

- **Attributo Singolo (Univariato):**
 - *Attributi categorici:* Un outlier corrisponde a un valore che si presenta con una frequenza sensibilmente inferiore rispetto a tutte le altre modalità del dominio.
 - *Attributi numerici:* Ispezione visiva e analitica mediante Box Plot (valori esterni all'intervallo $[Q_1 - 1.5 \times \text{IQR}, Q_3 + 1.5 \times \text{IQR}]$) e calcolo dello z -score standardizzato ($z = \frac{x-\mu}{\sigma}$).
- **Attributi Multipli (Multivariato):**
 - *Scatter Plot 2D e 3D:* Permettono di cogliere outlier sia globali (estremi rispetto all'intera nuvola di punti) sia locali (anomali rispetto al cluster o alla classe specifica a cui appartengono, come illustrato in Figura 2.6).

- *Grafici PCA (Principal Component Analysis)*: Proiettano lo spazio multidimensionale sui piani di massima varianza per individuare punti isolati.
- *Algoritmi di Clustering*: Negli algoritmi basati sulla densità o su distanze (come DBSCAN o k-means con soglie di distanza), gli outlier emergono naturalmente come i punti che non possono essere assegnati ad alcun cluster principale o che rimangono completamente isolati.

2.8.3 Valori Mancanti (Missing Values) e Camuffamento

L'assenza di valori per singoli attributi in determinate istanze può derivare da diverse cause:

- **Informazione non raccolta o rifiutata:** Rifiuto esplicito dell'intervistato di condividere dati riservati (ad esempio reddito, peso corporeo o età).
- **Non applicabilità logica dell'attributo:** L'attributo non possiede significato logico per una specifica classe di istanze (ad esempio il reddito annuo per bambini o minori in età scolare).
- **Malfunzionamento o blocco di sensori:** Interruzioni momentanee di connettività o dispositivi fisici danneggiati.

Insidia del Camuffamento: Zeri e Valori di Default Fittizi

Spesso un valore mancante non viene salvato con codifica esplicita (NULL o NaN), bensì registrato con valori convenzionali o di default (ad esempio 0, -1 o 999). Un sensore bloccato, ad esempio, invia ripetutamente il valore 0. Se non intercettati nella fase di Data Understanding, tali numeri vengono trattati acriticamente dai software come misurazioni reali, distorcendo gravemente medie, deviazioni standard e modelli di classificazione.

2.9 Checklist Operativa di Data Understanding

Al termine della fase di esplorazione, l'analista deve aver completato sistematicamente le seguenti verifiche:

1. **Valutazione della Qualità dei Dati:** Verificare la presenza di errori di accuratezza sintattica (valori fuori dominio) e semantica, grado di completezza, tempestività, duplicati e grado di sbilanciamento delle classi.
2. **Individuazione degli Outlier:** Rilevare anomalie univariati e multivariati mediante tecniche di visualizzazione (box plot, scatter plot, PCA, coordinate parallele) e decidere la politica di trattamento (rumore da rimuovere vs target primario di indagine).
3. **Rilevamento ed Esame dei Valori Mancanti:** Identificare i campi nulli e smascherare valori mancanti nascosti o camuffati sotto forma di zeri fittizi o codifiche di default.
4. **Scoperta e Conferma di Correlazioni e Dipendenze:** Calcolare matrici di correlazione lineare (Pearson) e di rango (Spearman) per confermare relazioni attese, rilevare dipendenze inattese e scongiurare la multicollinearità e le ridondanze tra feature.
5. **Verifica di Ipotesi e Assunzioni Specifiche del Dominio:** Controllare assunzioni applicative e distributive (ad esempio verificare se un attributo segue una distribuzione approssimativamente normale per l'uso della regola di Sturges o di stimatori parametrici).
6. **Confronto delle Statistiche con il Comportamento Atteso:** Verificare che medie, mediane, asimmetrie e dispersione riflettano coerentemente la conoscenza di dominio e i pattern attesi nel contesto applicativo.

Bibliografia

- [1] Usama Fayyad, Gregory Piatetsky-Shapiro, and Padhraic Smyth. From data mining to knowledge discovery in databases. *AI Magazine*, 17(3):37–54, 1996.