

Appunti di Data Mining

Anno Accademico 2026/2027

Indice

1	Introduzione al Data Mining e il Processo KDD	1
1.1	Fondamenti, Motivazioni e Definizione Formale	1
1.2	La Confluenza di Discipline e il Processo KDD	4
1.3	Tassonomia dei Task di Data Mining	7
1.4	Sfide Aperte del Data Mining Moderno	10
2	Data Understanding I: Tipologie di Dati, Attributi e Statistica Descrittiva	12
2.1	Conoscere i Dati e Tassonomia dei Dataset	12
2.2	Tipologie di Attributi e Proprietà di Scala	15
2.3	Problemi di Qualità del Dato	17
2.4	Ispezione delle Distribuzioni Monovariate	17
2.5	Misure di Tendenza Centrale e Dispersione	19
2.6	Five-Number Summary, Quartili e Box Plot	20
3	Data Understanding II – Analisi Multivariata, Correlazione e Rilevamento Outliers	22
3.1	Tecniche di Visualizzazione Multidimensionale	22
3.2	Analisi di Dipendenza Bivariata: Covarianza e Correlazione . .	27
3.3	Tassonomia e Rilevamento degli Outlier	31
3.4	Gestione dei Valori Mancanti	32
4	Data Preparation & Cleaning – Riduzione, Discretizzazione e Trasformazione	34
4.1	Differenze tra Data Understanding e Data Preparation	34
4.2	Aggregazione e Campionamento	35
4.3	Riduzione della Dimensionalità	37
4.4	Analisi delle Componenti Principali (PCA)	39
4.5	Gestione dei Valori Mancanti	43
4.6	Tecniche di Discretizzazione e Binarizzazione	43

4.7	Trasformazioni Funzionali di Attributi e Stabilizzazione della Varianza	46
4.8	Algoritmi di Normalizzazione	48
4.9	Trattamento Univariato degli Outlier	49
5	Laboratorio Python: Data Understanding e Data Preparation	52
5.1	Ambiente di Lavoro, Ingestione e Data Integration	53
5.2	Diagnosi e Imputazione dei Valori Mancanti	55
5.3	Esplorazione Multivariata e Analisi di Correlazione	56
5.4	Feature Transformation, Discretizzazione e Encoding	58
5.5	Riduzione Dimensionale: PCA e <i>t</i> -SNE	60
6	Misure di Prossimità, Teoria dell'Informazione e Cluster Analysis	64
6.1	Fondamenti di Similarità, Dissimilarità e Prossimità	64
6.2	Prossimità Unidimensionali per Singolo Attributo	65
6.3	Distanze Vettoriali e Metriche di Minkowski	67
6.4	Esempio di Calcolo delle Matrici di Distanza	68
6.5	Proprietà Matematiche di Metriche e Similarità	69
6.6	Prossimità tra Vettori Binari: SMC vs Indice di Jaccard	70
6.7	Similarità Coseno per Dati Documentali	72
6.8	Ponderazione, Dati Mancanti e Correlazione tra Oggetti	72
6.9	Teoria dell'Informazione: Entropia e Informazione Mutua	73
6.10	Principi Fondamentali della Cluster Analysis	76
6.11	Tassonomie dei Metodi e Strutture di Raggruppamento	77
6.12	Tipologie di Cluster e Formulazione Matematica	79
6.13	Caratteristiche dei Dati di Input e Famiglie Algoritmiche	80
7	Cluster Analysis: Algoritmi K-Means e Clustering Gerarchico	82
7.1	Introduzione alla Cluster Analysis Partizionale e Gerarchica	82
7.2	K-Means: Algoritmo di Lloyd e Geometria di Voronoi	84
7.3	Funzione Obiettivo SSE e Dimostrazione di Convergenza	87
7.4	Scelta del Parametro K, Minimi Locali e Inizializzazione	90
7.5	Euristiche di Inizializzazione e Varianti di K-Means	92
7.6	Limitazioni Strutturali di K-Means e Tecniche di Adattamento	94
7.7	Fondamenti del Clustering Gerarchico	96
7.8	Algoritmo Agglomerativo e Criteri di Collegamento (Linkage)	97
7.9	Clustering Gerarchico Divisivo basato su Minimum Spanning Tree (MST)	103
7.10	Complessità, Limiti e Confronto Sinottico	105

Capitolo 1

Introduzione al Data Mining e il Processo KDD

1.1 Fondamenti, Motivazioni e Definizione Formale

1.1.1 Che cos'è il Data Mining?

Il **Data Mining** (estrazione di conoscenza dai dati) è l'applicazione di algoritmi e tecniche computazionali efficienti per l'analisi di collezioni di dati di grandi dimensioni, al fine di scoprire pattern, regolarità, correlazioni e strutture informative finora sconosciute, non banali, valide e potenzialmente utili.

Dal punto di vista concettuale, il Data Mining non si limita alla semplice esecuzione di query su una base di dati (come avverrebbe in un sistema relazionale tramite SQL), né si riduce al calcolo di indicatori statistici descrittivi elementari. L'obiettivo centrale è l'estrazione di **conoscenza nascosta** (*hidden knowledge*): modelli impliciti, strutture di dipendenza latenti e relazioni predittive che non emergerebbero da un'ispezione manuale o tramite analisi tradizionali.

Definizione 1.1.1 (Data Mining). Il **Data Mining** è il processo computazionale di scoperta automatica o semi-automatica di pattern, regolarità, correlazioni o strutture latenti all'interno di moli massive di dati (*Big Data*), producendo modelli validi, inediti, potenzialmente utili e comprensibili per il decisore umano.

1.1.2 Il Contesto Applicativo: Driver Commerciali e Scientifici

L'esigenza di sviluppare discipline computazionali dedicate all'estrazione di pattern nasce dalla crescita esponenziale della quantità di dati generati, archiviati e gestiti a livello globale:

- **Punto di vista commerciale:** Le transazioni e-commerce, i log di navigazione web, le registrazioni di acquisto della grande distribuzione organizzata (GDO) e i flussi finanziari (pagamenti tramite carte di credito, bonifici, transazioni POS) generano flussi continui di dati nell'ordine dei terabyte o petabyte al giorno. Piattaforme digitali e istituti bancari non possono trarre vantaggio strategico dal semplice stoccaggio passivo; necessitano di trasformare questi log in insight comportamentali per ottimizzare il *Customer Relationship Management* (CRM), personalizzare offerte, prevenire l'abbandono dei clienti (*churn analysis*) e contrastare le frodi finanziarie in tempo reale.
- **Punto di vista scientifico:** La sensoristica remota e la strumentazione moderna producono moli di dati senza precedenti. Sistemi satellitari come il programma *NASA EOSDIS* riversano nei database petabyte di misurazioni ambientali su base annua; le telescopie astronomiche digitali mappano l'universo scansando miliardi di corpi celesti; la genomica genera sequenze di nucleotidi ad altissima frequenza; simulazioni fisiche, climatiche e biologiche computazionali producono terabyte di output in poche ore. In tale contesto, l'analisi empirica e l'elaborazione di ipotesi scientifiche richiedono processi di automazione avanzata capaci di sintetizzare matrici multidimensionali complesse.




Figura 1.1: Genesi ed evoluzione della necessità del Data Mining tra contesto commerciale e scientifico.

1.1.3 Big Data come Proxy della Vita Sociale e Sfide Globali

Le tracce digitali generate da dispositivi connessi, terminali mobili e ambienti interattivi costituiscono a tutti gli effetti un *proxy quantitativo* dei comportamenti e delle interazioni umane:

1. **Pattern di acquisto e stili di vita:** Lo scontrino della spesa, i registri fedeltà e il carrello virtuale tracciano le preferenze alimentari, le risposte ai prezzi e i comportamenti economici.
2. **Relazioni e reti sociali:** I grafi di interazione ricavati dalle piattaforme social descrivono la topologia dei contatti interpersonali e le modalità di propagazione delle informazioni e delle opinioni.
3. **Desideri, opinioni e sentimenti:** Le query immesse nei motori di ricerca, i post testuali e i contributi a enciclopedie aperte (es. Wikipedia) forniscono una misura in tempo reale degli interessi e dello stato emotivo collettivo.
4. **Mobilità e spostamenti:** I dati GPS, le connessioni alle celle telefoniche e i flussi del traffico aereo permettono di ricostruire la mobilità sia a livello locale (analisi della congestione urbana) sia globale (mappatura

delle rotte e previsione della diffusione di patogeni pandemici, come studiato tramite piattaforme quali *BioDiaspora*).

Questi strumenti offrono l'opportunità di affrontare problemi complessi di rilevanza sociale: ottimizzazione dei sistemi sanitari, transizione verso fonti di energia rinnovabile tramite reti elettriche intelligenti (*smart grid*), previsione degli effetti del cambiamento climatico e pianificazione della produzione agricola su scala globale.

1.2 La Confluenza di Discipline e il Processo KDD

1.2.1 Data Mining: Confluenza Multidisciplinare

Il Data Mining è un'area di ricerca e applicazione intrinsecamente interdisciplinare. Si colloca all'incrocio tra diversi settori:

- **Sistemi di Basi di Dati (Database Systems):** Forniscono l'infrastruttura per l'archiviazione, l'indicizzazione, l'accesso efficiente e il recupero dei dati su memoria secondaria e distribuita.
- **Statistica (Statistics):** Fornisce i fondamenti formali per la quantificazione dell'incertezza, l'inferenza, il campionamento, la verifica delle ipotesi (*hypothesis testing*) e la modellazione probabilistica.
- **Machine Learning (Apprendimento Automatico):** Introduce architetture computazionali e algoritmi ottimizzati capaci di apprendere regole direttamente dai dati per generalizzare su istanze mai osservate.
- **Teoria degli Algoritmi (Algorithms):** Garantisce che le procedure di calcolo siano computazionalmente sostenibili dal punto di vista della complessità spaziale e temporale, gestendo dataset con milioni di righe e migliaia di colonne.
- **Visualizzazione (Visualization):** Permette l'esplorazione percettiva e intuitiva dei dati e la comunicazione dei risultati all'analista o all'esperto di dominio.




Figura 1.2: La natura multidisciplinare del Data Mining alla confluenza di discipline informatiche e matematiche.

1.2.2 Il Processo KDD (Knowledge Discovery in Databases)

Il Data Mining non costituisce un'attività isolata, bensì la fase algoritmica cardine di un processo iterativo, ciclico ed esteso noto come **KDD** (*Knowledge Discovery in Databases*). L'intero ciclo di vita del dato si articola in sei fasi sequenziali con cicli di retroazione:




Figura 1.3: Architettura e passaggi sequenziali del processo KDD con percorsi di raffinamento iterativo.

Dettaglio delle Fasi del Processo KDD:

- 1. Comprensione del Business / Obiettivo (*Business Understanding*):** Formalizzazione del problema aziendale o scientifico, definizione degli indicatori di prestazione (KPI) e comprensione dei vincoli operativi.
- 2. Integrazione e Pulizia dei Dati (*Data Integration & Cleaning*):** Le sorgenti informative originali, spesso frammentate, incomplete e piene di rumore, vengono conciliate, ripulite dagli errori di sintassi e caricate in un repository integrato (spesso un *Data Warehouse* strutturato per query analitiche complesse).

3. **Selezione e Trasformazione (*Selection & Transformation*):** Estrazione del sottoinsieme di record e attributi pertinenti al target (*Task-relevant Data*); normalizzazione, aggregazione e discretizzazione delle feature.
4. **Data Mining:** Selezione e calibrazione degli algoritmi analitici appropriati (classificazione, clustering, regole associative, rilevamento anomalie) per estrarre regolarità strutturali dai dati.
5. **Valutazione dei Pattern (*Pattern Evaluation*):** Validazione dei risultati estratti sulla base di metriche formali (accuratezza, precisione, supporto, confidenza, silhouette score) e valutazione dell'effettiva utilità o novità per il contesto reale.
6. **Rappresentazione della Conoscenza (*Knowledge Representation*):** Sintesi e restituzione dei pattern validati tramite report, grafici e cruscotti decisionali, pronti all'uso per i decisori umani o all'integrazione in pipeline automatizzate.

1.3 Tassonomia dei Task di Data Mining

I task di Data Mining si dividono in due macrocategorie principali:

1. **Metodi Predittivi (*Predictive Methods*):** Mirano a costruire un modello statistico/matematico a partire da un insieme di variabili indipendenti (predittori) al fine di prevedere il valore incognito, continuo o discreto, di una specifica variabile dipendente (target).
2. **Metodi Descrittivi (*Descriptive Methods*):** Hanno come scopo l'individuazione di schemi, associazioni, raggruppamenti e proprietà intrinseche ai dati, senza che esista a priori una variabile target definita; il modello serve a rendere il dato comprensibile all'utente umano.

1.3.1 Classificazione (Predictive Modeling)

La classificazione assegna un record $x \in \mathcal{X}$ a una di un numero finito di classi predeterminate $y \in \mathcal{Y} = \{c_1, c_2, \dots, c_k\}$. L'algoritmo riceve un insieme di addestramento (*Training Set*) formato da coppie ordinate:

$$\mathcal{D}_{\text{train}} = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\} \quad (1.1)$$

L'obiettivo dell'apprendimento è derivare una funzione di classificazione (modello o classificatore):

$$f : \mathcal{X} \rightarrow \mathcal{Y} \quad (1.2)$$

che minimizzi l'errore di classificazione atteso su dati non visti (*Test Set*).

Esempio: Valutazione del Merito Creditizio (*Credit Worthiness*)

Si consideri il dataset per la concessione di prestiti bancari:

TID	Occupato	Livello Istruzione	Anni Residenza	Merito Creditizio (Y)
1	Sì	Laurea	5	Sì
2	Sì	Diploma	2	No
3	No	Triennale	1	No
4	Sì	Diploma	10	Sì

Tabella 1.1: Dataset giocattolo per l'induzione di un classificatore di merito creditizio.

Un algoritmo di apprendimento supervisionato induce un albero di decisione strutturato come segue:




Figura 1.4: Albero di decisione dedotto dal dataset di merito creditizio.

Applicazioni Tipiche della Classificazione:

- *Credit Card Fraud Detection*: identificazione di transazioni fraudolente tramite feature quali importo, posizione, timestamp e frequenza.

- *Churn Prediction*: predizione della probabilità che un cliente passi alla concorrenza.
- *Classificazione Biomedica*: distinzione istologica tra neoplasie benigne e maligne a partire da biopsie.
- *Categorizzazione Testuale*: smistamento automatico di documenti e notizie in categorie tematiche.

1.3.2 Raggruppamento (Clustering)

Il clustering consiste nel ripartire un insieme di oggetti non etichettati $\mathcal{D} = \{x_1, x_2, \dots, x_N\}$ in un numero k di gruppi o partizioni disgiunte $\mathcal{C} = \{C_1, C_2, \dots, C_k\}$ tali che:

1. **Distanza intra-cluster minimizzata**: Gli oggetti appartenenti allo stesso cluster C_i presentano un'elevata somiglianza reciproca.
2. **Distanza inter-cluster massimizzata**: Gli oggetti collocati in cluster distinti C_i e C_j ($i \neq j$) sono tra loro eterogenei o geometricamente distanti nello spazio delle metriche.



Figura 1.5: Rappresentazione concettuale del clustering: omogeneità interna e separazione esterna.

1.3.3 Estrazione di Regole di Associazione (Association Rules)

L'estrazione di regole associative individua dipendenze tra insiemi di elementi presenti all'interno di un database transazionale. Sia $\mathcal{I} = \{i_1, i_2, \dots, i_m\}$ l'insieme degli item e $\mathcal{T} = \{t_1, t_2, \dots, t_n\}$ l'insieme delle transazioni, dove ogni transazione $t_j \subseteq \mathcal{I}$.

Una **regola di associazione** è un'espressione logica del tipo:

$$X \implies Y \quad \text{con } X, Y \subset \mathcal{I} \text{ e } X \cap Y = \emptyset \quad (1.3)$$

Il significato formale indica che, nei record in cui compare l'insieme di elementi X (antecedente), si osserva sistematicamente anche la presenza dell'insieme Y (conseguente).

TID	Items Acquistati
1	Pane, Coca-Cola, Latte
2	Birra, Pane
3	Birra, Coca-Cola, Pannolini, Latte
4	Birra, Pane, Pannolini, Latte
5	Coca-Cola, Pannolini, Latte

Tabella 1.2: Esempio di database transazionale per Market Basket Analysis.

Dall'analisi delle co-occorrenze si estraggono regole come:

$$\{\text{Latte}\} \implies \{\text{Coca-Cola}\}, \quad \{\text{Pannolini, Latte}\} \implies \{\text{Birra}\} \quad (1.4)$$

1.3.4 Rilevamento delle Anomalie (Anomaly Detection)

L'identificazione di anomalie consiste nell'individuare oggetti, pattern o sequenze temporali che si discostano marcatamente dalla distribuzione o dal comportamento tipico del resto del dataset. I campi applicativi includono la rilevazione di intrusioni su reti di calcolatori (*Network Intrusion Detection*), il blocco di frodi su carte di credito, l'individuazione di avarie nei sensori industriali e il monitoraggio del disboscamento tramite serie temporali satellitari.

1.4 Sfide Aperte del Data Mining Moderno

L'impiego dei metodi tradizionali di statistica e machine learning su dataset complessi incontra vincoli sistemici:

1. **Scalabilità (Scalability):** Molti algoritmi classici hanno una complessità computazionale non lineare ($\mathcal{O}(N^2)$ o $\mathcal{O}(N^3)$ rispetto al numero di campioni N), rendendoli impraticabili su insiemi di miliardi di record senza parallelizzazione o approssimazioni.

2. **Alta Dimensionalità (High Dimensionality):** L'incremento del numero di attributi p genera problemi geometrici legati alla densità dello spazio (la cosiddetta *maledizione della dimensionalità*), che rende le distanze uniformi e disperde i dati nello spazio.
3. **Eterogeneità e Complessità del Dato:** I dati aziendali e scientifici non sono composti unicamente da tabelle piatte, ma includono grafi, serie temporali, testi liberi, sequenze biologiche, dati georeferenziati e flussi continui in streaming (*data streams*).
4. **Distribuzione e Proprietà dei Dati:** I dati sono spesso distribuiti su nodi remoti appartenenti a organizzazioni diverse, con vincoli legali di privacy, segreto industriale e disponibilità limitata di banda.
5. **Analisi Non Tradizionali:** Esigenza di gestire distribuzioni sbilanciate, derive dei concetti nel tempo (*concept drift*) e flussi informativi asincroni ad altissima frequenza.

Capitolo 2

Data Understanding I: Tipologie di Dati, Attributi e Statistica Descrittiva

2.1 Conoscere i Dati e Tassonomia dei Data-set

Il **Data Understanding** è la fase in cui l'analista esamina a fondo i dati a disposizione per determinare la qualità delle misurazioni, comprendere il significato applicativo delle feature e individuare preliminarmente la presenza di rumore, outlier o valori mancanti.

Obiettivi Fondamentali del Data Understanding

- Quali tipologie di attributi compongono il dataset?
- Qual è la qualità generale del dato e quali errori sintattici/semantici sono presenti?
- Sono presenti outlier o misurazioni anomale univariata e multivariata?
- Esistono correlazioni e dipendenze tra coppie di attributi?
- Come si distribuiscono i valori mancanti e quale meccanismo li genera?
- È necessario trasformare o ingegnerizzare nuove feature prima del mining?

2.1.1 Struttura Fondamentale: Oggetti e Attributi

Un dataset è una collezione formale di **oggetti di dati** (noti anche come *record*, *punti*, *campioni*, *entità*, *istanze o casi*) descritti da un insieme di **attributi** (noti anche come *variabili*, *feature*, *campi*, *caratteristiche o dimensioni*).

- Un **oggetto** rappresenta una singola entità del mondo reale (un cliente, una transazione, una lettura di un sensore).
- Un **attributo** denota una proprietà o caratteristica misurabile di tale oggetto (l'altezza, il prezzo, la temperatura, la categoria).

2.1.2 Classificazione delle Strutture Dati

I dataset si differenziano per la loro conformazione strutturale:




Figura 2.1: Tassonomia strutturale delle macro-tipologie di dataset.

1. Dati di tipo Record

- **Matrice Dati (*Data Matrix*):** Se tutti gli m oggetti sono descritti dallo stesso insieme fisso di n attributi numerici continui, il dataset si modella come una matrice di dimensione $m \times n$:

$$D = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1n} \\ x_{21} & x_{22} & \cdots & x_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ x_{m1} & x_{m2} & \cdots & x_{mn} \end{bmatrix} \in \mathbb{R}^{m \times n} \quad (2.1)$$

Ogni riga i corrisponde a un punto immerso nello spazio vettoriale continuo $\mathbb{R}^n$, dove ogni colonna rappresenta un asse coordinato.

- **Dati di tipo Documento (*Document-Term Matrix*):** Ogni testo viene rappresentato con il modello vettoriale *Bag-of-Words*. Le colonne corrispondono al vocabolario dei termini distinti e i valori registrano la frequenza:

Documento	team	coach	play	ball	score	game	win	lost	timeout	season
Doc 1	3	0	5	0	2	6	0	2	0	2
Doc 2	0	7	0	2	1	0	0	3	0	0
Doc 3	0	1	0	0	1	2	2	0	3	0

Tabella 2.1: Rappresentazione Document-Term Matrix per testi non strutturati.

- **Dati Transazionali (*Transaction Data*):** Ogni riga è identificata da un TID ed è formata da un insieme a cardinalità variabile di item discreti (articoli del carrello della spesa).

2. Dati a Grafo (*Graph Data*)

Modellano esplicitamente le relazioni tra entità: la topologia del Web (nodi = pagine, archi = collegamenti ipertestuali), molecole chimiche (es. benzene C_6H_6 con atomi e legami covalenti) e grafi di citazione bibliografica.

3. Dati Ordinati (*Ordered Data*)

Le relazioni di ordinamento determinano il significato del dato:

- **Serie Storiche:** Misurazioni indicizzate dal tempo con forte autocorrelazione.
- **Dati Sequenziali:** Sequenze ordinate di eventi (es. carrelli temporali: $(A, B) \rightarrow (D) \rightarrow (C, E)$).
- **Sequenze Genomiche:** Catene di basi nucleotidiche ('A', 'C', 'G', 'T').
- **Dati Spazio-Temporali:** Misurazioni indicizzate congiuntamente da coordinate geografiche e tempo (es. mappe globali delle temperature marine e terrestri).

2.2 Tipologie di Attributi e Proprietà di Scala

Le proprietà matematiche di un attributo dipendono dalle operazioni formali lecite sui valori del suo dominio:

- **Distinzione** ($=$ o $\neq$): Confronto di uguaglianza/disuguaglianza tra valori.
- **Ordinamento** ($<$ o $>$): Relazione d'ordine naturale totale o parziale.
- **Differenza** ($+$ o $-$): Intervalli quantificabili con metrica costante.
- **Rapporto** ($*$ o $/$): Zero assoluto naturale (totale assenza della quantità misurata).

Scala	Dist.	Ord.	Diff.	Rapp.	Operatori Statistici Ammessi
Nominale	✓	–	–	–	Moda, entropia, test χ^2
Ordinale	✓	✓	–	–	Mediana, quantili, Spearman ρ
Intervallo	✓	✓	✓	–	Media, dev.std, correlazione Pearson
Rapporto	✓	✓	✓	✓	Media geometrica, coeff. variazione

Tabella 2.2: Gerarchia e proprietà formali delle scale di misurazione statistica.

2.2.1 Attributi Categorici (Qualitativi)

1. **Nominali:** Permettono solo il test di uguaglianza ($=, \neq$). Esempi: colore degli occhi, CAP, codice fiscale, ID.
2. **Binari:** Casi particolari di attributi nominali con esattamente due stati $\{0, 1\}$.
 - *Binari Simmetrici:* Entrambi gli esiti hanno pari importanza (es. genere Maschio/Femmina).
 - *Binari Asimmetrici:* Uno dei due esiti è raro o di interesse primario ($1 =$ positivo a malattia rara, $0 =$ negativo).
3. **Ordinali:** Possiedono un ordinamento intrinseco ($<, >$), ma l'intervallo tra valori contigui non è costante numericamente. Esempi: scala di durezza di Mohs, giudizi {scarso, medio, buono}, voti in lettere $\{A, B, C, D, F\}$.

2.2.2 Attributi Numerici (Quantitativi)

1. **A Intervallo (*Interval-Scaled*):** La differenza tra due valori è costante, ma la scala **non possiede uno zero assoluto**. Esempi: temperatura in gradi Celsius o Fahrenheit (20°C non è “il doppio” di 10°C , poiché in Kelvin $293.15\text{ K} \neq 2 \cdot 283.15\text{ K}$); date di calendario.
2. **A Rapporto (*Ratio-Scaled*):** Possiedono uno **zero assoluto naturale** indicante l'assenza della grandezza. Esempi: lunghezza, peso, età, temperatura in Kelvin (0 K assenza di energia termica), importi monetari, tempo trascorso. Ha senso affermare che una partita durata 3 ore è il 50% più lunga di una durata 2 ore ($3/2 = 1.5$).

2.2.3 Variabili Discrete vs Continue

- **Attributo Discreto:** Possiede un insieme finito o numerabile di valori possibili, tipicamente rappresentato da numeri interi (CAP, conteggi di frequenza, parole).
- **Attributo Continuo:** Possiede un dominio coincidente con i numeri reali $\mathbb{R}$, rappresentato in virgola mobile.

2.3 Problemi di Qualità del Dato

L'impiego di dati degradati inficia qualunque algoritmo analitico (principio *Garbage In, Garbage Out*). Studi industriali (Redman, 2004) evidenziano che la scarsa qualità incide per il 10% ÷ 20% del fatturato aziendale complessivo.



Figura 2.2: Dimensioni fondamentali della qualità dei dati.

2.4 Ispezione delle Distribuzioni Monovariate

2.4.1 Asimmetria e Multimodalità

La forma della densità di frequenza di un attributo continuo rivela le proprietà intrinseche del fenomeno indagato:




Figura 2.3: Forme caratteristiche delle distribuzioni univariata: simmetria, asimmetria e multimodalità.

- **Distribuzione Simmetrica:** Densità speculare attorno al centro. Coincidono Media = Mediana = Moda.
- **Asimmetrica Positiva (*Right-Skewed*):** Coda allungata verso valori alti (es. reddito pro capite). Pochi valori elevati spostano la media:

$$\text{Moda} < \text{Mediana} < \text{Media} \quad (2.2)$$

- **Asimmetrica Negativa (*Left-Skewed*):** Coda allungata verso valori bassi:

$$\text{Media} < \text{Mediana} < \text{Moda} \quad (2.3)$$

- **Bimodale o Multimodale:** Segnala la sovrapposizione di sottopopolazioni disgiunte non ancora separate da variabili latenti (es. peso corporeo aggregato senza distinzione di genere).

2.4.2 Strumenti Visuali: Bar Chart vs Istogrammi

- **Grafico a Barre (*Bar Chart*):** Utilizzato per variabili **categoriche/discrete**. Le barre sono visivamente separate per evidenziare l'assenza di continuità metrica sull'asse orizzontale.
- **Istogramma (*Histogram*):** Utilizzato per variabili **continue**. Il dominio viene partizionato in intervalli contigui (*bin*) e l'area di ciascun rettangolo è proporzionale al numero di osservazioni.

Scelta del Numero di Bin e Regola di Sturges: Un numero insufficiente di bin appiattisce la distribuzione nascondendo la bimodalità; un numero eccessivo introduce oscillazioni casuali. Per distribuzioni approssimativamente normali si adotta la **Regola di Sturges**:

$$k = \lceil \log_2(n) + 1 \rceil \quad (2.4)$$

dove n è la dimensione campionaria e $\lceil \cdot \rceil$ è l'arrotondamento all'intero superiore.

2.5 Misure di Tendenza Centrale e Dispersione

2.5.1 Misure di Tendenza Centrale

- **Media Aritmetica Campionaria:**

$$\bar{x} = \frac{1}{m} \sum_{i=1}^m x_i \quad (2.5)$$

È estremamente sensibile agli outlier: una singola osservazione estrema falsa il valore medio.

- **Mediana:** Valore che occupa la posizione centrale nel campione ordinato:

$$\text{mediana} = \begin{cases} x_{(\frac{m+1}{2})} & \text{se } m \text{ è dispari} \\ \frac{x_{(\frac{m}{2})} + x_{(\frac{m}{2}+1)}}{2} & \text{se } m \text{ è pari} \end{cases} \quad (2.6)$$

È una misura **robusta**, invariante rispetto all'entità numerica dei valori estremi.

- **Moda:** Il valore a frequenza empirica massima. È l'unica misura applicabile anche ad attributi nominali.
- **Media Troncata (*Trimmed Mean*):** Calcolata escludendo una percentuale α di campioni minimi e massimi per combinare efficienza e robustezza.

2.5.2 Misure di Dispersione dei Dati

- **Range (Campo di Variazione):** $\text{Range} = x_{\max} - x_{\min}$.
- **Varianza Campionaria (s^2):**

$$s^2 = \frac{1}{m-1} \sum_{i=1}^m (x_i - \bar{x})^2 \quad (2.7)$$

con correzione di Bessel a denominatore $(m-1)$ per garantire uno stimatore non distorto.

- **Deviazione Standard Campionaria (s):** $s = \sqrt{s^2}$, espressa nella medesima unità di misura della variabile originaria.

Misure di Dispersione Robuste:

- **Deviazione Assoluta Media (*Absolute Average Deviation - AAD*):**

$$AAD(x) = \frac{1}{m} \sum_{i=1}^m |x_i - \bar{x}| \quad (2.8)$$

- **Mediana degli Scostamenti Assoluti (*Median Absolute Deviation - MAD*):**

$$MAD(x) = \text{mediana} \left(\left\{ |x_i - \text{mediana}(x)| \right\}_{i=1}^m \right) \quad (2.9)$$

2.6 Five-Number Summary, Quartili e Box Plot

2.6.1 Il Five-Number Summary

Il **Five-Number Summary** sintetizza la distribuzione statistica tramite cinque parametri posizionali:

$$\left\{ x_{\min}, Q_1, \text{Mediana} (Q_2), Q_3, x_{\max} \right\} \quad (2.10)$$

- Q_1 (Primo Quartile): 25% delle osservazioni sono inferiori o uguali a esso.
- Q_2 (Mediana): 50% delle osservazioni.
- Q_3 (Terzo Quartile): 75% delle osservazioni.
- **Range Interquartilico (IQR):** $IQR = Q_3 - Q_1$.

2.6.2 Anatomia del Box Plot

Il **Box Plot** traduce visivamente la sintesi a cinque numeri:




Figura 2.4: Anatomia formale del Box Plot con recinzioni di Tukey per l'identificazione degli outlier.




Figura 2.5: Box Plot condizionale calcolato sui dati reali del dataset Iris: distribuzione empirica della lunghezza del petalo (*Petal Length*) stratificata sulle tre specie, con evidenza della mediana, dei quartili e dei singoli campioni osservati.

Limiti del Box Plot rispetto agli Istogrammi: Sebbene il box plot sintetizzi efficacemente posizione e dispersione, **non permette di identificare la multimodalità**. Due distribuzioni, una marcatamente bimodale e una unimodale simmetrica, possono presentare lo stesso Five-Number Summary ($x_{\min}, Q_1, Q_2, Q_3, x_{\max}$) generando lo stesso identico box plot; solo l'istogramma consente di visualizzare la presenza di una concavità o di picchi multipli tra i quartili.

Capitolo 3

Data Understanding II – Analisi Multivariata, Correlazione e Rilevamento Outliers

L'analisi multivariata studia le relazioni simultanee tra due o più attributi del dataset, superando i limiti delle descrizioni univariate isolate. In questo capitolo si approfondiscono le tecniche di visualizzazione per dati a più dimensioni, gli indici formali di associazione e correlazione lineare e non lineare, i criteri metodologici per la diagnosi degli outlier e una checklist operativa conclusiva per completare la fase di Data Understanding.

Il caso di studio impiegato come riferimento applicativo è il benchmark **Iris** (introdotto dal botanico Edgar Anderson e reso celebre da Ronald Fisher nel 1936), composto da 150 osservazioni distribuite in modo bilanciato su 3 classi da 50 campioni ciascuna (*Iris setosa*, *Iris versicolor*, *Iris virginica*) e descritto da 4 feature continue espresse in centimetri:

- Lunghezza del sepalo (*Sepal Length*)
- Larghezza del sepalo (*Sepal Width*)
- Lunghezza del petalo (*Petal Length*)
- Larghezza del petalo (*Petal Width*)

3.1 Tecniche di Visualizzazione Multidimensionale

Quando l'analisi si estende a configurazioni bivariate e multivariate, la rappresentazione grafica deve consentire la percezione immediata della separabilità

geometrica tra classi, dell'addensamento in cluster naturali e della presenza di anomalie strutturali.

3.1.1 Scatter Plot e Scatter Matrix

Lo **Scatter Plot (Grafico a Dispersione)** traccia ogni coppia di attributi continui (X, Y) proiettando le osservazioni come punti con coordinate cartesiane $(x_i, y_i) \in \mathbb{R}^2$.

- **Caratteristiche:** Permette di evidenziare visivamente cluster, tendenze di correlazione diretta o inversa e la presenza di outlier bivariati che risultano invisibili dall'analisi dei singoli istogrammi.
- **Codifica cromatico-categoriale:** Assegnando a ciascun punto un colore o un simbolo corrispondente alla classe di appartenenza, l'analista può valutare la separabilità geometrica indotta dalla coppia di feature.
- **Evidenza sul dataset Iris:** Incrociando *Petal Length* e *Petal Width*, le classi mostrano un elevato grado di separabilità: la classe *Setosa* forma un cluster compatto e isolato, mentre *Versicolor* e *Virginica* presentano solo una ridotta sovrapposizione marginale (Figura 3.1). Al contrario, il piano formato da *Sepal Length* e *Sepal Width* mostra una forte sovrapposizione tra *Versicolor* e *Virginica*.

Quando il numero di attributi numerici p è moderato ($3 \leq p \leq 10$), si ricorre alla **Scatter Matrix (Scatter Plot Matrix - SPLOM)**: una griglia simmetrica di dimensione $p \times p$ contenente tutti i $\frac{p(p-1)}{2}$ grafici a dispersione a coppie distinte. Sulla diagonale principale vengono tipicamente inseriti gli istogrammi univariati o le stime di densità (KDE) della singola variabile, consentendo una diagnosi simultanea di forma e correlazione (Figura 3.2).

Lo **Scatter Plot Tridimensionale (3D)** estende la proiezione a tre coordinate cartesiane simultanee (X_1, X_2, X_3) . Consente di identificare outlier tridimensionali non rilevabili nelle proiezioni bidimensionali marginali, sebbene la fruizione su supporto bidimensionale risenta delle occlusioni e dell'angolazione di visuale.

3.1.2 Visualizzazione di Spazi ad Alta Dimensionalità

Negli spazi a dimensione elevata ($p > 3$), la geometria euclidea cartesiana classica non consente proiezioni dirette esaustive. Si adottano schemi grafici alternativi basati su geometrie coordinate non ortogonali.




Figura 3.1: Scatter plot bivariati sul dataset Iris: confronto tra la separabilità generata da sepalo e petalo.

Coordinate Parallele (Parallel Coordinates)

Nelle coordinate parallele gli assi non sono mutuamente perpendicolari, ma disposti come p rette verticali equi-spaziate e parallele, ciascuna tarata sull'intervallo di valori dell'attributo corrispondente.

- **Mappatura geometrica:** Un'osservazione p -dimensionale $\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{ip}) \in \mathbb{R}^p$ viene rappresentata non come un punto, ma come una **polilinea (linea spezzata)** che attraversa tutti gli assi, intersecando l'asse j -esimo esattamente alla quota x_{ij} .
- **Proprietà diagnostiche:** I record appartenenti alla stessa classe formano fasci compatti con andamento coerente. Una polilinea isolata con traiettoria discordante segnala un potenziale outlier multivariato.
- **Rilevanza dell'ordinamento degli assi:** La percezione dei legami statistici dipende dall'ordinamento orizzontale degli assi. Collocando attributi fortemente correlati su assi contigui, fasci di segmenti paralleli indicano correlazione positiva, mentre fasci che si incrociano a X indicano correlazione negativa (Figura 3.3).




Figura 3.2: Scatter Plot Matrix (SPLOM) completa per le quattro feature del dataset Iris.




Figura 3.3: Coordinate parallele per il dataset Iris con curve differenziate per classe.

Radar Plot (Grafico Radar o Diagramma a Stella)

Il **Radar Plot** condivide il principio delle coordinate parallele, con la variante che gli assi dimensionali non sono disposti linearmente, ma **irraggiano a raggiera da un polo centrale comune**, distanziati da angoli equi-spaziati:

$$\theta_j = \frac{2\pi(j-1)}{p}, \quad j = 1, \dots, p \quad (3.1)$$

Per ciascun record, il valore assunto dalla variabile definisce la distanza del vertice dal centro lungo il corrispondente raggio; congiungendo i vertici si genera un poligono chiuso. Quando il radar plot viene replicato in piccoli riquadri separati per ciascuna osservazione, prende il nome di **Star Plot**, agevolando il confronto visivo di profili complessi (Figura 3.4).




Figura 3.4: Profili medi delle classi del dataset Iris visualizzati tramite Radar Plot.

3.2 Analisi di Dipendenza Bivariata: Covarianza e Correlazione

L'analisi quantitativa della dipendenza studia l'intensità e la direzione con cui due variabili casuali variano congiuntamente.

3.2.1 Da Varianza a Covarianza

Mentre la varianza misura la dispersione di una singola variabile rispetto al proprio baricentro, la **Covarianza Campionaria** quantifica la tendenza di due variabili numeriche X e Y a manifestare scarti concordi o discordi rispetto alle rispettive medie:

$$\text{Cov}(X, Y) = s_{xy} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \quad (3.2)$$

Nel caso speciale $X = Y$, la covarianza coincide con la varianza campionaria:

$$\text{Cov}(X, X) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = s_x^2 \quad (3.3)$$

Matrici di Covarianza

Per un insieme di p attributi continui, la struttura complessiva di variabilità congiunta è sintetizzata dalla **Matrice di Covarianza** $V \in \mathbb{R}^{p \times p}$:

$$V = \begin{bmatrix} \text{Cov}(X_1, X_1) & \text{Cov}(X_1, X_2) & \cdots & \text{Cov}(X_1, X_p) \\ \text{Cov}(X_2, X_1) & \text{Cov}(X_2, X_2) & \cdots & \text{Cov}(X_2, X_p) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(X_p, X_1) & \text{Cov}(X_p, X_2) & \cdots & \text{Cov}(X_p, X_p) \end{bmatrix} \quad (3.4)$$

- Gli elementi diagonali $V_{jj} = \text{Var}(X_j) = s_j^2$ rappresentano le varianze marginali.
- Gli elementi extra-diagonali $V_{jk} = \text{Cov}(X_j, X_k)$ rappresentano le covarianze a coppie.
- Poiché $\text{Cov}(X_j, X_k) = \text{Cov}(X_k, X_j)$, la matrice V è **simmetrica** ($V = V^T$) e semi-definita positiva ($V \succeq 0$).

Interpretazione Geometrica dei Prodotti degli Scarti

Il segno della covarianza dipende dalla posizione delle osservazioni rispetto al baricentro $(\bar{x}, \bar{y})$ nel piano cartesiano, che divide lo spazio in quattro quadranti:




Figura 3.5: Scomposizione geometrica degli scarti in quattro quadranti centrati sul baricentro $(\bar{x}, \bar{y})$.

- Punti nei quadranti I e III apportano contributi positivi: le deviazioni sono concordi $\implies \text{Cov}(X, Y) > 0$.
- Punti nei quadranti II e IV apportano contributi negativi: le deviazioni sono discordi $\implies \text{Cov}(X, Y) < 0$.
- Se le osservazioni si disperdono uniformemente nei quattro quadranti, i termini positivi e negativi si bilanciano, portando a $\text{Cov}(X, Y) \approx 0$.

Limite Strutturale: Dipendenza dall'Unità di Misura

La covarianza non è invariante per trasformazioni di scala. Se la variabile X esprime un reddito in euro e viene convertita in migliaia di euro ($X' = X/1000$), la covarianza si riduce di un fattore 1000, nonostante la correlazione statistica rimanga immutata. Essa non consente quindi di confrontare coppie di attributi aventi ordini di grandezza o unità differenti.

3.2.2 Coefficiente di Correlazione Lineare di Pearson

Il **Coefficiente di Correlazione Lineare di Pearson** (r_{xy}) normalizza la covarianza dividendola per il prodotto delle deviazioni standard campionarie:

$$r_{xy} = \frac{\text{Cov}(X, Y)}{s_x s_y} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} \quad (3.5)$$

Proprietà Matematiche del Coefficiente r_{xy}

1. **Limitazione dell'intervallo:** Per la disuguaglianza di Cauchy-Schwarz nello spazio dei vettori centrati, il coefficiente è rigorosamente limitato nell'intervallo:

$$-1 \leq r_{xy} \leq +1 \quad (3.6)$$

2. **Invarianza di scala:** È un indice adimensionale, invariante rispetto a qualunque trasformazione lineare affine positiva ($X' = aX + b, Y' = cY + d$ con $a, c > 0$).

3. **Correlazione lineare perfetta:**

- $r_{xy} = +1$: indica una perfetta relazione lineare positiva crescente; tutti i punti giacciono su una retta a pendenza positiva ($y = ax + b$, con $a > 0$).
- $r_{xy} = -1$: indica una perfetta relazione lineare negativa decrescente ($a < 0$).

4. **Assenza di relazione lineare:** Un valore $r_{xy} \approx 0$ denota **assenza di associazione lineare**, ma non implica l'indipendenza stocastica. Relazioni funzionali non lineari deterministiche (es. $Y = X^2$ con X distribuita simmetricamente attorno all'origine) generano $r_{xy} = 0$, pur in presenza di una totale dipendenza.




Figura 3.6: Configurazioni tipiche di dispersione bivariata e corrispondenti coefficienti r di Pearson.

3.2.3 Fallacia Causale e Variabili Concomitanti

Un principio fondante dell'analisi dati stabilisce che **la correlazione statistica non implica causalità** (*correlation does not imply causation*). Un valore elevato di $|r_{xy}|$ può originare da tre dinamiche:




Figura 3.7: Heatmap di correlazione per il dataset Iris complessivo e disaggregato per singola specie.

1. X è causa diretta di Y .
2. Y è causa diretta di X .
3. X e Y sono entrambe causate da una terza variabile non osservata o latente, definita **variabile di confondimento (confounding factor)**.

Esempio Classico: Vendita di Gelati e Annegamenti

Durante i mesi estivi si registra una forte correlazione lineare positiva ($r > 0.85$) tra le vendite di gelati (X) e il numero di decessi per annegamento (Y). Dedurre che l'assunzione di gelati aumenti il rischio di annegamento costituisce una fallacia causale: entrambe le grandezze sono influenzate da un fattore di confondimento esogeno, la temperatura ambientale (*hot weather*), che incentiva simultaneamente il consumo di gelati e l'afflusso di bagnanti in mare e nei fiumi.

3.2.4 Coefficiente di Correlazione per Ranghi di Spearman

Quando i dati violano l'ipotesi di normalità bivariata o presentano relazioni non lineari ma strettamente monotone, si impiega il **Coefficiente di Correlazione per Ranghi di Spearman** (ρ).

La procedura converte ciascun valore continuo x_i e y_i nella rispettiva posizione d'ordine o rango ordinale $r(x_i), r(y_i) \in \{1, \dots, n\}$. In assenza di

valori paritari (*ties*), la formulazione algebrica esplicita risulta:

$$\rho = 1 - \frac{6 \sum_{i=1}^n (r(x_i) - r(y_i))^2}{n(n^2 - 1)} \quad (3.7)$$

- $\rho = +1$: indica una perfetta relazione monotona crescente (al crescere di X , Y cresce strettamente, anche secondo andamenti esponenziali o sigmoidei).
- $\rho = -1$: indica una perfetta relazione monotona decrescente.
- **Robustezza**: Essendo basato sui ranghi ordinali anziché sui valori metrici effettivi, Spearman è molto meno sensibile a valori anomali isolati situati nelle code.

3.3 Tassonomia e Rilevamento degli Outlier

Un **outlier** (valore anomalo) è definito come un'istanza che devia marcatamente dalla distribuzione della maggior parte delle osservazioni, suggerendo che sia stata generata da un meccanismo generatore differente o affetta da distorsioni di misura.

3.3.1 Ruolo degli Outlier: Rumore vs Target di Analisi

- **Outlier come Rumore (Noise)**: L'anomalia è conseguenza di un errore materiale di digitazione, di un malfunzionamento momentaneo della sensoristica o di un'alterazione spuria. In questa veste, l'outlier degrada gli stimatori e deve essere isolato, corretto o rimosso in fase di pre-processing.
- **Outlier come Obiettivo Primario (Analysis Goal)**: L'indagine analitica è finalizzata precisamente all'identificazione di eventi eccezionali, che veicolano il massimo valore informativo.
 - Rilevamento di intrusioni informatiche (*Intrusion Detection*).
 - Identificazione di frodi finanziarie o transazioni bancarie illecite.
 - Manutenzione predittiva su macchinari industriali tramite rilievo di micro-vibrazioni anomale.

3.3.2 Metodologie di Identificazione degli Outlier

La tassonomia degli approcci di identificazione distingue tra indagini su singola feature e indagini congiunte multidimensionali:




Figura 3.8: Tassonomia delle metodologie di rilevamento delle anomalie.

- **Attributi Categorici:** Un'osservazione anomala presenta una categoria associata a una frequenza empirica prossima allo zero ($< 0.1\%$).
- **Attributi Numerici Univariati:**
 - *Regola di Tukey:* Valori esterni all'intervallo $[Q_1 - 1.5 \text{ IQR}, Q_3 + 1.5 \text{ IQR}]$.
 - *Criterio Z-Score:* Valori con scostamento standardizzato $|z| > 3.29$ (code estreme della normale).
- **Spazi Multidimensionali:**
 - *Scatter Plot bivariati:* Identificazione ottica di punti lontani dal corpo centrale della nube.
 - *Proiezioni PCA:* Punti che presentano valori anomali lungo le componenti principali secondarie.
 - *Clustering e Local Outlier Factor (LOF):* Riconoscimento di punti isolati a bassa densità locale rispetto al vicinato di k elementi.

3.4 Gestione dei Valori Mancanti

Un record manifesta **valori mancanti (Missing Values)** quando per una o più feature non è presente alcuna informazione registrata (formalmente denotata con simboli nulli come NaN, NULL, ? o mediante valori convenzionali impliciti come 999 o 0).

3.4.1 Cause di Insorgenza

1. **Omissione volontaria per riservatezza:** L'intervistato si rifiuta di comunicare attributi sensibili (es. reddito personale, orientamento politico o religioso, abitudini sanitarie).
2. **Inapplicabilità logica del campo:** La variabile non è definita per una specifica sottopopolazione (es. il numero di gravidanze per individui di sesso maschile, o l'anzianità lavorativa per minori in età scolare).
3. **Avarie strumentali o caduta di connettività:** Malfunzionamento di sensori di telemetria che generano valori nulli o trasmettono serie fittizie costanti (es. sensore anemometrico bloccato che registra sistematicamente velocità del vento pari a 0 m/s).

3.4.2 Checklist Operativa per il Data Understanding

A completamento della fase di esplorazione preliminare, l'analista deve verificare sistematicamente la seguente checklist:

Ambito di Controllo	Verifica Diagnostica da Eseguire
Coerenza Sintattica	Verificare i tipi di dato, la codifica di formati numerici/stringa e i vincoli di dominio.
Valori Anomali (Outlier)	Ispezionare la presenza di valori estremi mediante Boxplot univariati e Scatter Plot bivariati.
Valori Mancanti (Missing)	Rilevare incidenza percentuale dei campi nulli e identificare valori sentinella impliciti (0, -1, 999).
Associazioni e Ridondanze	Calcolare le correlazioni di Pearson e Spearman per isolare coppie di attributi collineari o ridondanti.
Assunzioni Distributive	Verificare simmetria, normalità e omoschedasticità prima di impostare la fase di preparazione e pulizia.

Tabella 3.1: Checklist diagnostica operativa per la chiusura della fase di Data Understanding.

Capitolo 4

Data Preparation & Cleaning – Riduzione, Discretizzazione e Trasformazione

Mentre la fase di Data Understanding si concentra sulla diagnosi delle anomalie e sulla comprensione delle strutture latenti del dataset, la **Data Preparation** costituisce la componente operativa e trasformativa del ciclo KDD. In questa fase i dati grezzi vengono bonificati, compressi, riscaldati e ricodificati per soddisfare i requisiti algebrici e computazionali degli algoritmi di data mining.

4.1 Differenze tra Data Understanding e Data Preparation

La transizione tra la fase diagnostica e la fase trasformativa è sintetizzata dal passaggio dalle evidenze empiriche alle azioni di pulizia:




Figura 4.1: Relazione sequenziale tra Data Understanding (diagnosi) e Data Preparation (intervento).

4.2 Aggregazione e Campionamento

La riduzione del volume dei dati si persegue mediante la combinazione di osservazioni o attraverso la selezione statistica di sottoinsiemi rappresentativi.

4.2.1 Aggregazione dei Dati

L'aggregazione sintetizza due o più record o attributi in una singola misura aggregata.

- **Obiettivi primari:**
 1. *Riduzione dimensionale*: Riduce il numero complessivo di record o attributi, alleggerendo il carico computazionale.
 2. *Riconfigurazione di scala e granularità*: Adatta l'analisi al livello concettuale idoneo (ad esempio, aggregare le transazioni orarie in totali settimanali o i singoli punti vendita a livello regionale).
 3. *Stabilizzazione della varianza*: Le grandezze aggregate mediano il rumore casuale, producendo indicatori a varianza inferiore e relazioni più stabili.
- **Caso Studio: Precipitazioni in Australia (1982–1993)**: Nelle serie storiche pluviometriche australiane, la deviazione standard delle precipitazioni medie mensili evidenzia un'elevata variabilità con code fino a 15 cm. Al contrario, aggregando i dati su base annua, la deviazione standard si concentra su valori bassi con dispersione contenuta

(Figura 4.2). Per l'analisi dei cicli stagionali è necessaria la scala mensile disaggregata, mentre per la comparazione dei regimi climatici regionali la scala annua aggregata risulta più robusta e priva del rumore a breve termine.




Figura 4.2: Confronto di dispersione tra precipitazioni medie mensili e precipitazioni medie annue aggregate in Australia.

4.2.2 Tecniche di Campionamento (Sampling)

Il campionamento estrae un sottoinsieme rappresentativo di dimensione n da una popolazione complessiva di cardinalità N ($n \ll N$). Un campione è **rappresentativo** se riflette fedelmente le medesime proprietà distributive e statistiche della popolazione sorgente.



Figura 4.3: Albero delle strategie di campionamento nel data mining.

1. **Campionamento Casuale Semplice (Simple Random Sampling):** Ciascuna istanza possiede la medesima probabilità a priori di selezione:

$$P(x_i) = \frac{1}{N} \quad (4.1)$$

- *Senza reinserimento (without replacement):* L'elemento estratto viene rimosso dal pool e non può essere risSelectedzionato.
 - *Con reinserimento (with replacement):* L'elemento estratto rimane disponibile per successive estrazioni (stesso record estratto > 1 volta).
2. **Campionamento Stratificato (Stratified Sampling):** La popolazione viene suddivisa in strati omogenei disgiunti (ad esempio per etichetta di classe o per percentili). Da ciascun strato viene estratto un campione proporzionale alla sua cardinalità relativa, garantendo che le classi rare non vengano omesse dal campione estratto.

La scelta della dimensione campionaria ottimale impone un compromesso tra costo computazionale e accuratezza statistica, come illustrato nella curva di trade-off di Figura 4.4.




Figura 4.4: Trade-off tra dimensione campionaria e accuratezza empirica di stima.

4.3 Riduzione della Dimensionalità

La presenza di un numero elevato di feature determina rilevanti criticità computazionali e geometriche.

4.3.1 La Maledizione della Dimensionalità (*Curse of Dimensionality*)

All'aumentare della dimensionalità p , il volume dello spazio $\mathbb{R}^p$ cresce esponenzialmente rispetto al numero di osservazioni disponibili. Questo fenomeno causa:

1. **Sparsità estrema:** Le osservazioni si disperdono nello spazio multidimensionale; la densità locale tende a zero e lo spazio diventa prevalentemente vuoto.
2. **Concentrazione delle distanze:** All'aumentare di p , il contrasto relativo tra la distanza minima e la distanza massima rispetto a qualsiasi punto di riferimento tende a vanificarsi:

$$\lim_{p \rightarrow \infty} \frac{\text{dist}_{\max} - \text{dist}_{\min}}{\text{dist}_{\min}} \rightarrow 0 \quad (4.2)$$

Ciò compromette le prestazioni degli algoritmi metrica-dipendenti (k -NN, clustering K-Means).

3. **Instabilità delle stime:** La stima della matrice di covarianza $p \times p$ richiede una numerosità campionaria che scala esponenzialmente con p per scongiurare singularità numeriche.




Figura 4.5: Illustrazione della dispersione geometrica dei campioni all'aumentare delle dimensioni (Curse of Dimensionality).

4.3.2 Selezione delle Feature (Feature Selection)

La **Feature Selection** seleziona un sottoinsieme ottimale di feature originali, eliminando gli attributi irrilevanti (non informativi) e ridondanti (duplicati di informazione già presente). I metodi si suddividono in tre categorie:

Paradigma	Meccanismo Operativo	Vantaggi / Limiti
Filter	Valutano la significatività statistica (t -test, ANOVA, correlazione di Pearson, χ^2) a priori, indipendentemente dal modello.	Computazionalmente velocissimi; non considerano l'interazione tra feature.
Wrapper	Utilizzano il modello predittivo come oracolo di valutazione iterativo (Forward Selection, Backward Elimination).	Ottimizzano l'accuratezza finale; computazionalmente gravosi (2^p combinazioni teoriche).
Embedded	La selezione è integrata nel processo di addestramento dell'algoritmo (es. alberi decisionali, regolarizzazione Lasso L_1).	Eccellente compromesso tra accuratezza e tempi computazionali.

Tabella 4.1: Confronto sinottico tra approcci Filter, Wrapper ed Embedded per la Feature Selection.

4.3.3 Creazione e Proiezione di Feature

- **Costruzione di Feature (*Feature Construction*)**: Generazione di nuove variabili combinando attributi esistenti tramite conoscenza del dominio (ad esempio, calcolo della densità come massa/volume o dell'efficienza come ore effettive/ore previste).
- **Proiezione di Feature (*Feature Projection*)**: Mappatura lineare o non lineare dello spazio originario $\mathbb{R}^p$ in un sottospazio ridotto $\mathbb{R}^k$ ($k \ll p$), massimizzando la varianza conservata o la separabilità tra classi (PCA, SVD, Linear Discriminant Analysis - LDA, Autoencoder).

4.4 Analisi delle Componenti Principali (PCA)

L'**Analisi delle Componenti Principali (PCA)** è una tecnica lineare non supervisionata che trasforma un insieme di p variabili originarie correlate in un nuovo insieme di p variabili ortogonali (scorrelate), ordinate in modo decrescente rispetto alla quota di varianza spiegata.




Figura 4.6: Allineamento delle componenti principali ortogonali lungo le direzioni di massima varianza dei dati.

4.4.1 Procedura Dettagliata per il Calcolo della PCA

La procedura analitica per il calcolo della PCA si articola in cinque passi formali:

Passo 1: Centrazione e Standardizzazione della Matrice Dati

Data la matrice iniziale $D \in \mathbb{R}^{n \times p}$, si calcola la media campionaria per ciascuna colonna:

$$\bar{x}_j = \frac{1}{n} \sum_{i=1}^n D_{ij} \quad (4.3)$$

Si genera la **matrice centrata** $C \in \mathbb{R}^{n \times p}$ sottraendo il vettore delle medie da ciascuna riga:

$$C_{ij} = D_{ij} - \bar{x}_j \quad (4.4)$$

Qualora le variabili presentino unità o scale eterogenee, si calcola la **matrice standardizzata** $Z \in \mathbb{R}^{n \times p}$ dividendo ciascuno scarto per la deviazione standard campionaria s_j :

$$Z_{ij} = \frac{D_{ij} - \bar{x}_j}{s_j} \quad (4.5)$$

Passo 2: Calcolo della Matrice di Covarianza

Si determina la matrice di covarianza empirica $V \in \mathbb{R}^{p \times p}$ mediante il prodotto matriciale:

$$V = \frac{1}{n-1} C^T C \quad (4.6)$$

Passo 3: Decomposizione Spettrale (Autovalori e Autovettori)

Si risolve il problema agli autovalori per la matrice reale simmetrica V :

$$V\mathbf{e}_j = \lambda_j\mathbf{e}_j, \quad j = 1, \dots, p \quad (4.7)$$

- Ogni **autovettore** normalizzato ad ampiezza unitaria $\|\mathbf{e}_j\|_2 = 1$ identifica la direzione del j -esimo asse principale. Poiché V è simmetrica, autovettori relativi ad autovalori distinti sono mutuamente ortogonali ($\mathbf{e}_j^T \mathbf{e}_k = 0$ per $j \neq k$).
- Il corrispondente **autovalore** $\lambda_j \geq 0$ quantifica la varianza spiegata lungo la direzione dell'asse principale $\mathbf{e}_j$.

Passo 4: Ordinamento e Selezione delle Componenti

Si ordinano autovalori e autovettori in senso decrescente rispetto alla magnitudo di λ :

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0 \quad (4.8)$$

La percentuale di varianza spiegata dalla singola componente j è calcolata come:

$$\text{Varianza Spiegata (\%)} = \frac{\lambda_j}{\sum_{m=1}^p \lambda_m} \times 100 \quad (4.9)$$

Si selezionano le prime k componenti ($k < p$) che garantiscono una soglia cumulativa desiderata (es. 85% o 95%), scartando le restanti componenti a bassa varianza (Figura 4.7). Si assembla la matrice di trasformazione $F \in \mathbb{R}^{p \times k}$:

$$F = [\mathbf{e}_1 \quad \mathbf{e}_2 \quad \dots \quad \mathbf{e}_k] \quad (4.10)$$

Passo 5: Proiezione nel Nuovo Sottospazio

La matrice finale proiettata $Z \in \mathbb{R}^{n \times k}$ nello spazio ridotto k -dimensionale si calcola mediante moltiplicazione matriciale:

$$Z = CF \quad (4.11)$$

In Figura 4.8 è visualizzata la proiezione dei campioni del dataset Iris sul piano bidimensionale definito dalle prime due componenti principali (PC1 e PC2), che catturano oltre il 95% della varianza originaria complessiva.




Figura 4.7: Scree plot degli autovalori e curva di varianza cumulativa spiegata.




Figura 4.8: Proiezione bidimensionale dei campioni Iris lungo le prime due componenti principali.

4.5 Gestione dei Valori Mancanti

Le strategie operative per il trattamento dei record incompleti comprendono:

1. **Eliminazione Completa del Record (Listwise Deletion):** Rimozione integrale di tutte le righe con almeno un campo nullo. Applicabile in sicurezza solo quando l'incidenza dei missing è trascurabile ($< 3-5\%$) e i dati mancano in modo puramente casuale (*Missing Completely at Random - MCAR*); altrimenti introduce gravi distorsioni selettive.
2. **Sostituzione con Indici di Tendenza Centrale:**
 - *Media*: Per variabili numeriche simmetriche prive di outlier.
 - *Mediana*: Per variabili numeriche asimmetriche o in presenza di code pesanti.
 - *Moda*: Per attributi categorici qualitativi.
 - *Criticità*: Riduce artificialmente la varianza della feature e attenua l'intensità delle correlazioni con gli altri attributi.
3. **Imputazione Condizionale tramite Segmentazione:** Ripartizione dei campioni in cluster o classi omogenee sulla base delle feature complete e imputazione del valore mancante impiegando la media o mediana calcolata esclusivamente all'interno del rispettivo cluster.
4. **Imputazione Predittiva Basata su Modelli:** Addestramento di un modello supervisionato (regressione lineare, k -NN, Random Forest) dove la variabile da stimare funge da target e gli attributi completi fungono da predittori.

4.6 Tecniche di Discretizzazione e Binarizzazione

La **discretizzazione** trasforma una variabile quantitativa continua in un attributo ordinale discreto, suddividendo il dominio continuo in un insieme finito di intervalli contigui (detti *bin* o *classi*).

4.6.1 Discretizzazione Non Supervisionata

1. Natural Binning (Equal-Width Binning)

Suddivide l'intervallo $[x_{\min}, x_{\max}]$ in k classi aventi la medesima **ampiezza costante**:

$$\delta = \frac{x_{\max} - x_{\min}}{k} \quad (4.12)$$

L' i -esimo intervallo ($i = 0, \dots, k-1$) è delimitato da:

$$I_i = [x_{\min} + i\delta, x_{\min} + (i+1)\delta) \quad (4.13)$$

Esempio Numerico: Prezzo di 12 Birre

Dato l'insieme di $N = 12$ prezzi compresi tra $x_{\min} = 100$ e $x_{\max} = 160$, impostando $k = 4$ classi otteniamo ampiezza $\delta = \frac{160-100}{4} = 15$. Gli intervalli risultano:

- Classe 1: $[100, 115) \rightarrow \{100, 110, 110\}$ (Conteggio: 3)
- Classe 2: $[115, 130) \rightarrow \{120, 120, 125\}$ (Conteggio: 3)
- Classe 3: $[130, 145) \rightarrow \{130, 130, 135, 140\}$ (Conteggio: 4)
- Classe 4: $[145, 160] \rightarrow \{150, 160\}$ (Conteggio: 2)

2. Equal-Frequency Binning (Equal-Depth Binning)

Ordina i campioni in senso crescente e assegna a ciascun intervallo lo **stesso numero di osservazioni**:

$$f = \frac{N}{k} \quad (4.14)$$

Sugli stessi 12 prezzi ordinati $\{100, 110, 110, 120, 120, 125, 130, 130, 135, 140, 150, 160\}$ con $k = 4$, la frequenza per classe è $f = 12/4 = 3$:

- Classe 1: $\{100, 110, 110\}$
- Classe 2: $\{120, 120, 125\}$
- Classe 3: $\{130, 130, 135\}$
- Classe 4: $\{140, 150, 160\}$

Questo approccio uniforma la densità e mitiga l'impatto degli outlier, sebbene possa collocare valori contigui identici in classi distinte qualora cadano a cavallo della soglia.

Formule per il Numero e l'Ampiezza Ottimale dei Bin

Oltre alla Regola di Sturges, si utilizza la formulazione logaritmica decimale:

$$C = 1 + \frac{10}{3} \log_{10}(N) \quad (4.15)$$

Per ottimizzare direttamente l'ampiezza h combinando variabilità e numerosità campionaria, si applica la **Regola di Scott (1979)**:

$$h = \frac{3.5 \times s}{\sqrt[3]{N}} \quad (4.16)$$

dove s è la deviazione standard campionaria e N la numerosità del dataset.

4.6.2 Discretizzazione Supervisionata Basata sull'Entropia

Quando è disponibile una variabile di classe target $Y \in \{c_1, \dots, c_m\}$, le soglie di taglio vengono ottimizzate per massimizzare la purezza informativa. L'entropia di un insieme di campioni S è data da:

$$\text{Entropy}(S) = - \sum_{j=1}^m p_j \log_2(p_j) \quad (4.17)$$

dove p_j è la proporzione di istanze in S appartenenti alla classe c_j . Se un punto di split T partiziona S nei sottoinsiemi S_1 ed S_2 , l'entropia combinata pesata è:

$$E(S, T) = \frac{|S_1|}{|S|} \text{Entropy}(S_1) + \frac{|S_2|}{|S|} \text{Entropy}(S_2) \quad (4.18)$$

Il punto di split ottimale T^* massimizza il guadagno informativo $\text{Gain}(S, T) = \text{Entropy}(S) - E(S, T)$.

4.6.3 Binarizzazione (Encoding)

Converte variabili qualitative con m modalità in attributi binari $\{0, 1\}$:

- **Codifica One-Hot (Asymmetric Binary Encoding)**: Alloca un indicatore binario dedicato per ciascuna modalità. Genera m variabili asimmetriche ed evita di introdurre relazioni d'ordine artificiali.
- **Codifica Binaria Compatta**: Mappa ciascuna modalità nella sua rappresentazione binaria posizionale numerica, richiedendo $n = \lceil \log_2(m) \rceil$ bit. *Criticità*: Induce correlazioni fittizie tra i singoli bit privi di riscontro empirico nel fenomeno reale.

Valore Categorico	Codice Intero	x_1	x_2	x_3	x_4	x_5
awful	0	1	0	0	0	0
poor	1	0	1	0	0	0
OK	2	0	0	1	0	0
good	3	0	0	0	1	0
great	4	0	0	0	0	1

Tabella 4.2: Esempio di codifica One-Hot per un attributo a 5 livelli qualitativi.

Valore Categorico	Codice Intero	x_1	x_2	x_3
awful	0	0	0	0
poor	1	0	0	1
OK	2	0	1	0
good	3	0	1	1
great	4	1	0	0

Tabella 4.3: Codifica binaria compatta su 3 bit per 5 livelli categorici.

4.7 Trasformazioni Funzionali di Attributi e Stabilizzazione della Varianza

Una **trasformazione funzionale** applica una funzione T continua e strettamente monotona a ciascun valore di un attributo X : $Y = T(X)$.

- **Stabilizzazione della varianza:** Rende omogenea la dispersione lungo tutto il dominio (*omoschedasticità*).
- **Normalizzazione della forma:** Riconduce code pesanti o asimmetrie a distribuzioni approssimativamente normali.
- **Linearizzazione delle relazioni:** Rende lineari dipendenze polinomiali o esponenziali.

4.7.1 Famiglia delle Trasformazioni Esponenziali e Logaritmiche

La trasformazione parametrica generale è definita come:

$$T_p(x) = \begin{cases} ax^p + b & \text{se } p \neq 0 \\ c \log(x) + d & \text{se } p = 0 \end{cases} \quad (4.19)$$

con $x > 0$.

- **Trasformazione Lineare** ($p = 1$): Modifica unicamente origine e scala (es. euro in lire con $a = 1936.27, b = 0$; gradi Fahrenheit in Celsius con $a = 5/9, b = -160/9$).
- **Trasformazione Logaritmica** ($p = 0$): $T(x) = c \log(x) + d$. Comprime i valori elevati ed espande la scala dei valori piccoli, contrastando l'asimmetria positiva destra.

Bar	Birra	Gain Originario (X)	Gain Trasformato $\log_{10}(X)$
A	Bud	20	1.3010
A	Becks	10000	4.0000
C	Bud	300	2.4771
D	Bud	400	2.6021
D	Becks	5	0.6990
E	Becks	120	2.0792
E	Bud	120	2.0792
F	Bud	11000	4.0414
G	Bud	1300	3.1139
H	Bud	3200	3.5051
H	Becks	1000	3.0000
I	Bud	135	2.1303

Tabella 4.4: Campione di 12 osservazioni di profitto (Gain) prima e dopo trasformazione logaritmica.

Nella scala originaria la deviazione standard (4079.02) eccede abbondantemente la media (2481.82), trascinata dai picchi a 10000 e 11000. Dopo la conversione in $\log_{10}$, media (2.5956) e mediana (2.6021) coincidono quasi perfettamente, ripristinando la simmetria.

4.7.2 Altre Trasformazioni di Stabilizzazione

- **Radice Quadrata** ($p = 1/2$): $T(x) = \sqrt{x}$. Stabilizza la varianza nei dati di conteggio poissoniani ($\sigma^2 = \mu$).
- **Reciproca** ($p = -1$): $T(x) = 1/x$. Utilizzata quando la varianza cresce in modo quadratico o superlineare rispetto alla media.

Parametro Statistico	Scala Originaria (X)	Scala Logaritmica ($Y = \log_{10} X$)
Media Aritmetica	2481.82	2.5956
Deviazione Standard	4079.02	1.0651
Minimo	5	0.6990
1° Quartile (Q_1)	120	2.0792
Mediana (Q_2)	400	2.6021
3° Quartile (Q_3)	2250	3.3095
Massimo	11000	4.0414

Tabella 4.5: Indicatori statistici descrittivi prima e dopo la trasformazione logaritmica.

4.8 Algoritmi di Normalizzazione

La normalizzazione riconduce attributi misurati su scale numeriche disomogenee all'interno di intervalli standard comparabili, scongiurando il dominio distorto di feature con valori numerici elevati negli algoritmi basati sulle distanze metriche (k -NN, K-Means, SVM, reti neurali).

4.8.1 Normalizzazione Min-Max

Mappa linearmente l'intervallo originario $[\min_A, \max_A]$ nell'intervallo target $[\text{new_min}_A, \text{new_max}_A]$ (frequentemente $[0, 1]$):

$$v' = \frac{v - \min_A}{\max_A - \min_A} (\text{new_max}_A - \text{new_min}_A) + \text{new_min}_A \quad (4.20)$$

Preserva esattamente le relazioni lineari originarie, ma risulta sensibile a outlier estremi che possono comprimere i valori ordinari in un sottointervallo minuscolo.

4.8.2 Standardizzazione Z-Score

Riconduce la variabile ad avere **media nulla e varianza unitaria**:

$$v' = \frac{v - \bar{x}_A}{s_A} \quad (4.21)$$

dove $\bar{x}_A$ è la media campionaria e s_A la deviazione standard campionaria. È l'approccio raccomandato per distribuzioni approssimativamente normali e resiste meglio alla presenza di valori sparsi nelle code.

4.8.3 Normalizzazione per Scalamento Decimale (Decimal Scaling)

Sposta la virgola decimale dividendo per una potenza di 10:

$$v' = \frac{v}{10^j} \quad (4.22)$$

dove j è il minimo intero positivo tale che:

$$\max(|v'|) < 1 \iff 10^{j-1} \leq \max(|v|) < 10^j \quad (4.23)$$

Esempio Numerico di Decimal Scaling

Dato il vettore $V = \{-10, 201, 301, -401, 501, 601, 701\}$:

1. Il massimo in valore assoluto è $m = \max(|v|) = 701$.
2. Il minimo intero j tale che $10^j > 701$ è $j = 3$ ($10^3 = 1000$).
3. Dividendo per 1000 si ottiene:

$$V' = \{-0.01, 0.201, 0.301, -0.401, 0.501, 0.601, 0.701\} \quad (4.24)$$

Tutti i valori trasformati appartengono rigidamente all'intervallo aperto $(-1, +1)$.

4.9 Trattamento Univariato degli Outlier

L'intervento operativo sui valori anomali isolati segue criteri codificati a seconda del modello statistico di riferimento:

4.9.1 Criterio Basato sul Range Interquartilico (Tukey)

1. Si calcola l'ampiezza interquartilica $IQR = Q_3 - Q_1$.
2. Si definiscono le recinzioni (*fences*) di ammissibilità:

$$L = Q_1 - 1.5 \times IQR, \quad U = Q_3 + 1.5 \times IQR \quad (4.25)$$




Figura 4.9: Quadro decisionale per l'identificazione e la sostituzione univariata degli outlier.

3. Un'osservazione x è formalmente anomala se $x < L \vee x > U$.

4. **Risoluzione:**

- *Winsorizzazione (Sostituzione al bordo):* Si assegna L se $x < L$, e U se $x > U$. Preserva la monotonicità ordinale annullando la magnitudo distorsiva del picco.
- *Imputazione con la Mediana:* Si sostituisce il valore estremo con la mediana calcolata sul sottoinsieme dei dati regolari.

4.9.2 Criterio Basato sullo Z-Score

In una distribuzione teorica normale, il 95% dei campioni ricade entro $|z| \leq 1.96$, il 99% entro $|z| \leq 2.58$, e il 99.9% entro $|z| \leq 3.29$. Si etichetta come outlier qualunque valore eccedente la soglia:

$$|z| > 3.29 \iff x < \bar{x} - 3.29 s \quad \vee \quad x > \bar{x} + 3.29 s \quad (4.26)$$

Strategie di Sostituzione

1. **Troncamento a 3σ :** Il valore estremo viene convertito nel valore corrispondente al punto di soglia $z = \pm 3.0$ ($x' = \bar{x} \pm 3.0 s$). Questa scelta riconduce il record entro un intervallo plausibile senza cancellare l'informazione che l'osservazione apparteneva all'estremo della coda.

2. **Imputazione con la Media Campionaria:** Il valore anomalo viene rimpiazzato con il baricentro $z = 0$, corrispondente alla media campionaria originaria $\bar{x}$.

Capitolo 5

Laboratorio Python: Data Understanding e Data Preparation

In questo capitolo viene presentata la trasposizione computazionale delle metodologie teoriche di Data Understanding (DU) e Data Preparation (DP), facendo riferimento all'attività di laboratorio svolta con lo stack scientifico di Python (`numpy`, `pandas`, `scipy`, `matplotlib`, `seaborn` e `scikit-learn`).

Il laboratorio impiega il dataset **Tips** (arricchito con la tabella **Tips_Age**), relativo alle abitudini di spesa e di mancia dei clienti di un ristorante, per illustrare l'intero flusso operativo: dall'ingestione e integrazione dei dati, alla diagnosi e imputazione dei valori mancanti, fino all'ingegnerizzazione delle feature, normalizzazione e riduzione dimensionale con PCA e *t*-SNE.

Ambiente Interattivo e Riproducibilità del Laboratorio

Tutti gli esempi, le pipeline di trasformazione e i grafici presentati in questo capitolo sono riproducibili ed eseguibili interattivamente tramite i notebook Jupyter inclusi nella cartella `Data-Mining/notebooks/`.

Avvio rapido con Docker:

- Da terminale (nella radice del progetto): `docker compose up jupyter`
- Oppure con doppio clic su Windows: `scripts/start-jupyter.cmd`
- Interfaccia web: <http://localhost:8888/lab> (senza password né token).

Per eseguire direttamente gli script senza interfaccia grafica da riga di comando:

- `docker compose run -rm app python3 Data-Mining/notebooks/generate_dispensa_figures.py`

5.1 Ambiente di Lavoro, Ingestione e Data Integration

Nota 5.1.1 (Riferimento al Notebook Interattivo). Il codice delle sezioni 5.1, 5.2 e 5.3 corrisponde al notebook Jupyter interattivo **Notebook 1 (Data Understanding)** (file `1_basics_and_understanding.ipynb`).

Lo stack software fondamentale per l'analisi esplorativa dei dati in Python comprende le seguenti librerie:

```
1 import numpy as np
2 import pandas as pd
3 import scipy.stats as stats
4 import matplotlib.pyplot as plt
5 import seaborn as sns
6 from sklearn.impute import SimpleImputer, KNNImputer
7 from sklearn.preprocessing import StandardScaler,
   MinMaxScaler, KBinsDiscretizer, OneHotEncoder,
   TargetEncoder
8 from sklearn.decomposition import PCA
9 from sklearn.manifold import TSNE
```

5.1.1 Caricamento e Ispezione Strutturale

Il dataset principale viene acquisito tramite file delimitato da tabulazione (`tsv`) impostando l'indice sulla prima colonna:

```
1 tips = pd.read_csv('tips.csv', sep='\t', index_col=0)
2 print(tips.head())
3 tips.info()
```

Il dataset contiene inizialmente 244 osservazioni e 7 colonne: `total_bill` (importo totale del conto), `tip` (mancia), `sex` (genere del pagante), `smoker` (presenza di fumatori al tavolo), `day` (giorno della settimana), `time` (pranzo o cena), `size` (numero di coperti al tavolo).

5.1.2 Data Integration e Join Relazionale

Nel laboratorio, l'età dei clienti è memorizzata in una sorgente secondaria (`tips_age.csv`). L'integrazione delle due tabelle avviene tramite una join sull'identificativo primario ID:

```
1 tips_age = pd.read_csv('tips_age.csv', sep='\t',
2                        index_col=0)
3 df = tips.join(tips_age, on='ID')
4 # Rimozione di eventuali colonne ridondanti generate
5   dalla sorgente
6 df = df.drop(columns=['gender'], errors='ignore')
```

5.1.3 Rilevamento e Rimozione di Record Duplicati

L'ispezione delle righe duplicate richiede la verifica dell'uguaglianza tra tutti gli attributi del record:

```
1 # Visualizzazione di tutti i duplicati (tutte le copie)
2 duplicated_rows = df[df.duplicated(keep=False)]
3 print(f"Righe duplicate rilevate: {len(duplicated_rows)}")
4
5 # Rimozione mantenendo la prima occorrenza
6 df = df.drop_duplicates()
```

5.1.4 Bonifica di Valori Non Validi e Cast di Tipo

Spesso i dati contengono errori di trascrizione o stringhe non valide inserite al posto di campi numerici (ad esempio il valore fittizio `'aaaaa'` nella colonna

`total_bill`). Ciò costringe Pandas a tipizzare la colonna come generico tipo `object`. La bonifica avviene mediante sostituzione puntuale e conversione esplicita di tipo:

```
1 # Sostituzione della stringa anomala con zero o NaN
2 df["total_bill"] = df["total_bill"].replace("aaaaa", np.
      nan)
3
4 # Cast esplicito a float numerico
5 df["total_bill"] = pd.to_numeric(df["total_bill"])
```

5.2 Diagnosi e Imputazione dei Valori Mancanti

5.2.1 Audit dei Missing Values

Il conteggio dei valori mancanti (NaN) per ciascun attributo si ottiene combinando `isnull()` e `sum()`:

```
1 # Riepilogo dei valori nulli per colonna
2 null_counts = df.isnull().sum()
3 print(null_counts[null_counts > 0])
4
5 # Selezione dei soli record incompleti
6 incomplete_records = df[df.isnull().any(axis=1)]
```

5.2.2 Strategie di Rimozione vs Imputazione Statistica

- **Listwise Deletion:** Eliminazione integrale di tutti i record con almeno un valore nullo:

```
1 df_cleaned = df.dropna()
```

- **Imputazione con la Mediana Condizionale:** Quando l'attributo `age` presenta valori mancanti o codificati con la convenzione sentinella 0, l'imputazione mediante la mediana calcolata sull'intero dataset potrebbe appiattire la variabilità tra fasce orarie distinte (*Lunch* vs *Dinner*). Si esegue pertanto un'imputazione stratificata:

```
1 df['age'] = df['age'].replace(0, np.nan)
2 # Imputa con la mediana di gruppo calcolata sulla
   fascia oraria (time)
```

```

3 df['age'] = df['age'].fillna(df.groupby('time')['age']
    ].transform('median'))

```

5.2.3 Imputazione Avanzata con Scikit-Learn

Il modulo `sklearn.impute` mette a disposizione trasformatori integrabili nelle pipeline di machine learning:

```

1 # 1. SimpleImputer per feature numeriche (media o
    mediana)
2 imp_mean = SimpleImputer(strategy='mean')
3 df['tip'] = imp_mean.fit_transform(df[['tip']])
4
5 # 2. SimpleImputer per feature categoriche (moda/
    frequenza massima)
6 imp_mode = SimpleImputer(strategy='most_frequent')
7 df['smoker'] = imp_mode.fit_transform(df[['smoker']]).
    ravel()
8
9 # 3. KNNImputer (imputazione multivariata basata su k-
    Nearest Neighbors)
10 knn_imp = KNNImputer(n_neighbors=2, weights='distance')
11 num_cols = ['total_bill', 'tip', 'size', 'age']
12 df[num_cols] = knn_imp.fit_transform(df[num_cols])

```

5.3 Esplorazione Multivariata e Analisi di Correlazione

5.3.1 Tabelle di Contingenza e Distribuzioni Condizionate

Per studiare le associazioni tra variabili categoriche si utilizzano tabelle di contingenza normalizzate (*cross-tabulation*):

```

1 # Tabella di frequenza congiunta tra genere e abitudine
    al fumo
2 smoker_xt = pd.crosstab(df['smoker'], df['sex'])
3
4 # Normalizzazione per riga (proporzioni percentuali)
5 smoker_pct = smoker_xt.div(smoker_xt.sum(1).astype(float)
    ), axis=0)

```

```

6 smoker_pct.plot(kind='bar', stacked=False, title='Genere
   per Categoria Fumatore')
7 plt.ylabel('Frequenza Relativa')
8 plt.show()

```

5.3.2 Matrici di Correlazione e Heatmap

Pandas consente di stimare simultaneamente i coefficienti di correlazione lineare (Pearson) e di rango (Spearman, Kendall) sui soli attributi numerici:

```

1 # Calcolo della matrice di correlazione di Pearson
2 corr_pearson = df.corr(numeric_only=True, method='
   pearson')
3
4 # Calcolo con il coefficiente di Spearman (monotonia
   robusta)
5 corr_spearman = df.corr(numeric_only=True, method='
   spearman')
6
7 # Visualizzazione grafica tramite heatmap con
   annotazioni numeriche
8 plt.figure(figsize=(8, 6))
9 sns.heatmap(corr_pearson, annot=True, cmap='coolwarm',
   fmt='.2f', vmin=-1, vmax=1)
10 plt.title('Matrice di Correlazione di Pearson (Dataset
   Tips)')
11 plt.show()

```

5.3.3 Scatter Matrix e Pairplot

L'ispezione visiva incrociata delle relazioni bivariate si realizza tramite `scatter_matrix` o Seaborn `pairplot`:

```

1 # Scatter Matrix di Pandas
2 pd.plotting.scatter_matrix(df[['total_bill', 'tip', '
   size', 'age']], figsize=(9, 9), diagonal='kde')
3 plt.show()
4
5 # Pairplot con codice colore basato sul momento del
   pasto (time)
6 sns.pairplot(df, vars=['total_bill', 'tip', 'size'], hue
   ='time', palette='Dark2')
7 plt.show()

```

5.3.4 Feature Engineering: Costruzione di Indicatori di Dominio

La conoscenza del dominio consente di combinare variabili grezze per sintetizzare nuovi attributi ad alto valore interpretativo:

```
1 # 1. Percentuale effettiva di mancia rispetto al conto
2 df['tip_ratio'] = df['tip'] / df['total_bill']
3
4 # 2. Spesa media per persona (Bill Per Person - BPP)
5 df['bpp'] = df['total_bill'] / df['size']
6
7 # Ispezione con Boxplot condizionato per genere
8 df.boxplot(column=['bpp'], by='sex')
9 plt.title('Spesa Media per Persona per Genere')
10 plt.suptitle('')
11 plt.show()
```

5.4 Feature Transformation, Discretizzazione e Encoding

Nota 5.4.1 (Riferimento al Notebook Interattivo). Il codice delle sezioni 5.4 e 5.5 corrisponde al notebook Jupyter interattivo [Notebook 2 \(Feature Engineering\)](#):

[2_feature_engineering_and_data_representation.ipynb](#)

5.4.1 Discretizzazione con KBinsDiscretizer

La libreria Scikit-Learn fornisce KBinsDiscretizer per convertire variabili continue in classi ordinali discrete secondo tre strategie:

```
1 # Discretizzazione a 4 intervalli con strategie diverse
2 disc_uniform = KBinsDiscretizer(n_bins=4, encode='
   ordinal', strategy='uniform')      # Equal-Width
3 disc_quantile = KBinsDiscretizer(n_bins=4, encode='
   ordinal', strategy='quantile')     # Equal-Frequency
4 disc_kmeans = KBinsDiscretizer(n_bins=4, encode='ordinal
   ', strategy='kmeans')              # Basata su Cluster
5
6 df['total_bill_bins'] = disc_uniform.fit_transform(df[['
   total_bill']])
```

```
7 print(df['total_bill_bins'].value_counts())
```

5.4.2 Normalizzazione dei Dati: StandardScaler vs MinMaxScaler

- **StandardScaler**: Trasforma la feature per avere media zero e deviazione standard unitaria ($\mu = 0, \sigma = 1$).
- **MinMaxScaler**: Riscalda linearmente l'intervallo originario entro $[0, 1]$.

```
1 num_cols = ['total_bill', 'tip', 'age']
2
3 # Standardizzazione Z-Score
4 scaler_std = StandardScaler()
5 df_standardized = df.copy()
6 df_standardized[num_cols] = scaler_std.fit_transform(df[
    num_cols])
7
8 # Normalizzazione Min-Max
9 scaler_minmax = MinMaxScaler()
10 df_normalized = df.copy()
11 df_normalized[num_cols] = scaler_minmax.fit_transform(df[
    num_cols])
12
13 # Ripristino dei valori originali tramite trasformazione
    inversa
14 df_recovered = scaler_minmax.inverse_transform(
    df_normalized[num_cols])
```

5.4.3 Codifica di Variabili Categorie: One-Hot vs Target Encoding

```
1 # 1. One-Hot Encoding (evita di creare ordinalita
    fittizia)
2 ohe = OneHotEncoder(handle_unknown='ignore',
    sparse_output=False)
3 encoded_days = ohe.fit_transform(df[['day']])
4 encoded_df = pd.DataFrame(encoded_days, columns=ohe.
    get_feature_names_out(['day']))
5
```

```

6 # 2. Target Encoding (sostituisce la categoria con la
   media della target)
7 target_enc = TargetEncoder(smooth='auto')
8 # Codifica 'day' in base all'importo medio della mancia
   'tip'
9 df['day_target_encoded'] = target_enc.fit_transform(df[['
   'day']], df['tip'])

```

5.5 Riduzione Dimensionale: PCA e *t*-SNE

5.5.1 Principal Component Analysis (PCA)

Prima di applicare la PCA è indispensabile standardizzare le feature continue affinché attributi con varianze ampie non dominino la decomposizione spettrale:

```

1 # Selezione attributi quantitativi
2 X = df[['total_bill', 'tip', 'size', 'age', 'tip_ratio',
   'bpp']].dropna()
3 X_scaled = StandardScaler().fit_transform(X)
4
5 # Esecuzione della PCA
6 pca = PCA()
7 X_pca = pca.fit_transform(X_scaled)
8
9 # Autovalori (quota di varianza spiegata per componente)
10 eigenvalues = pca.explained_variance_
11 # Percentuale di varianza spiegata
12 explained_var_ratio = pca.explained_variance_ratio_
13 # Varianza cumulata
14 cumulative_var = np.cumsum(explained_var_ratio)

```

Costruzione dello Scree Plot

Lo Scree Plot consente di individuare visivamente il "gomito" (*elbow*) oltre il quale le componenti spiegano quote trascurabili di varianza:

```

1 plt.figure(figsize=(8, 4))
2 plt.plot(range(1, len(eigenvalues) + 1), eigenvalues, 'o
   -', color='navy', label='Autovalori singoli')
3 plt.title('Scree Plot degli Autovalori (PCA)')
4 plt.xlabel('Numero Componente Principale')

```

```

5 plt.ylabel('Autovalore (Varianza spiegata)')
6 plt.grid(True, linestyle='--', alpha=0.5)
7 plt.legend()
8 plt.show()

```

5.5.2 Proiezione Non Lineare con *t*-SNE

Il *t*-Distributed Stochastic Neighbor Embedding (*t*-SNE) è una tecnica non supervisionata non lineare specificamente progettata per preservare le strutture di vicinato locale nei dati ad alta dimensionalità:

```

1 tsne = TSNE(
2     n_components=2,
3     perplexity=30,      # Equilibrio tra granularita
4                          locale e globale (tipicamente 5-50)
5     learning_rate=200,  # Passo di ottimizzazione della
6                          discesa del gradiente
7     max_iter=1000,      # Iterazioni di minimizzazione
8                          della divergenza KL
9     random_state=42
10 )
11 X_tsne = tsne.fit_transform(X_scaled)

```

5.5.3 Confronto Metodologico tra PCA e *t*-SNE

```

1 # Visualizzazione comparata delle due proiezioni
2   bidimensionali
3
4 fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(14, 5))
5
6 # Scatter PCA
7 ax1.scatter(X_pca[:, 0], X_pca[:, 1], c='navy', alpha
8             =0.7, edgecolors='k')
9 ax1.set_title('Proiezione Lineare PCA (PC1 vs PC2)')
10 ax1.set_xlabel('Prima Componente Principale')
11 ax1.set_ylabel('Seconda Componente Principale')
12 ax1.grid(True, linestyle='--', alpha=0.5)
13
14 # Scatter t-SNE
15 ax2.scatter(X_tsne[:, 0], X_tsne[:, 1], c='crimson',
16            alpha=0.7, edgecolors='k')
17 ax2.set_title('Proiezione Non Lineare t-SNE')
18 ax2.set_xlabel('Dimensione t-SNE 1')

```

Caratteristica	PCA (Principal Component Analysis)	t -SNE (t -Distributed SNE)
Tipologia	Lineare, globale, deterministica.	Non lineare, locale, probabilistica/stocastica.
Funzione Obiettivo	Massimizza la varianza globale proiettata (decomposizione agli autovalori).	Minimizza la divergenza di Kullback-Leibler tra distribuzioni di probabilità di vicinato.
Interpretabilità	Gli assi rappresentano combinazioni lineari degli attributi (pesi/loading noti).	Gli assi non hanno significato fisico; contano solo le distanze relative tra punti.
Distanze Lontane	Preserva fedelmente le distanze euclidee su larga scala.	Non preserva le distanze globali tra cluster distanti (la grandezza dei cluster non riflette la densità originaria).
Uso Tipico	Riduzione preliminare di feature per modelli predittivi, compressione, eliminazione di collinearità.	Visualizzazione esplorativa avanzata e separazione visiva di cluster complessi (2D/3D).

Tabella 5.1: Confronto metodologico tra PCA e t -SNE nell'analisi dei dati.

```
15 ax2.set_ylabel('Dimensione t-SNE 2')
16 ax2.grid(True, linestyle='--', alpha=0.5)
17
18 plt.tight_layout()
19 plt.show()
```

Capitolo 6

Misure di Prossimità, Teoria dell'Informazione e Cluster Analysis

In questo capitolo vengono presentati i fondamenti matematici e concettuali su cui poggiano le discipline di apprendimento non supervisionato e basato su istanze nel Data Mining:

1. La quantificazione analitica della **vicinanza, distanza e similarità** tra oggetti descritti da attributi eterogenei e continui;
2. Gli strumenti formali della **Teoria dell'Informazione di Shannon** (entropia ed informazione mutua) per valutare l'incertezza e la dipendenza non lineare;
3. I principi generali, le tassonomie e le formulazioni geometriche della **Cluster Analysis**.

6.1 Fondamenti di Similarità, Dissimilarità e Prossimità

Nelle discipline di Data Mining, Machine Learning e Information Retrieval, il confronto tra coppie di entità informative costituisce il nucleo operativo di molteplici paradigmi analitici: dalla classificazione supervisionata mediante istanze vicine (*k*-Nearest Neighbors), all'estrazione di cluster naturali, fino alla stima di densità e anomalie.

Definizione 6.1.1 (Misura di Similarità). Una **misura di similarità** è una funzione reale $s : \mathcal{D} \times \mathcal{D} \rightarrow \mathbb{R}$ che quantifica il grado di affinità tra due oggetti $\mathbf{x}$ e $\mathbf{y}$. Tale valore è monotonicamente crescente all'aumentare



Figura 6.1: Quadro concettuale delle misure di prossimità nello spazio dei dati.

della vicinanza tra gli oggetti: assume il suo valore massimo quando i due oggetti sono identici e decresce man mano che divergono. Nella maggior parte dei domini, la funzione è normalizzata nell'intervallo $[0, 1]$, in cui 1 denota coincidenza assoluta e 0 disgiunzione totale.

Definizione 6.1.2 (Misura di Dissimilarità). Una **misura di dissimilarità** è una funzione reale $d : \mathcal{D} \times \mathcal{D} \rightarrow \mathbb{R}$ che quantifica la differenza o discrepanza tra due oggetti $\mathbf{x}$ e $\mathbf{y}$. Assume valori più bassi quando gli oggetti sono tra loro affini o identici, e cresce monotonicamente all'aumentare della loro diversità. Il limite inferiore è convenzionalmente fissato a $d(\mathbf{x}, \mathbf{y}) = 0$ quando $\mathbf{x} = \mathbf{y}$, mentre il limite superiore può essere limitato (1) oppure illimitato ($+\infty$).

Il termine ombrello **prossimità** (*proximity*) è impiegato nella letteratura per riferirsi indistintamente a una funzione di similarità o di dissimilarità.

6.2 Prossimità Unidimensionali per Singolo Attributo

Dati due oggetti $\mathbf{x}$ e $\mathbf{y}$, sia p il valore assunto da $\mathbf{x}$ su un dato attributo e q il valore assunto da $\mathbf{y}$ sul medesimo attributo. Il calcolo della dissimilarità elementare $d(p, q)$ e della duale similarità $s(p, q)$ dipende dalla scala di misurazione dell'attributo.

6.2.1 Attributi Nominali

Poiché gli attributi qualitativi nominali (es. colore, tipologia di conto bancario) non presentano relazioni di ordinamento o metrica intrinseca, le uniche

Scala Attributo	Dissimilarità $d(p, q)$	Similarità Duale $s(p, q)$
Nominale	$d = 0$ se $p = q$; $d = 1$ se $p \neq q$	$s = 1$ se $p = q$; $s = 0$ se $p \neq q$
Ordinale	$d = \frac{ p - q }{n - 1}$ (con stati mappati in $\{0, \dots, n - 1\}$)	$s = 1 - d = 1 - \frac{ p - q }{n - 1}$
Intervallo o Rapporto	$d = p - q $	$s = -d, \quad s = \frac{1}{1 + d},$ oppure $s = 1 - \frac{d - d_{\min}}{d_{\max} - d_{\min}}$

Tabella 6.1: Regole di calcolo della prossimità elementare per singoli attributi.

operazioni lecite sono il test di identità e diversità:

$$d(p, q) = \begin{cases} 0 & \text{se } p = q \\ 1 & \text{se } p \neq q \end{cases}, \quad s(p, q) = \begin{cases} 1 & \text{se } p = q \\ 0 & \text{se } p \neq q \end{cases} \quad (6.1)$$

6.2.2 Attributi Ordinali

Gli attributi ordinali presentano un ordinamento intrinseco composto da n livelli discreti. Per calcolare distanze coerenti, si esegue preliminarmente la **mappatura posizionale** degli stati discreti nell'insieme degli interi $\{0, 1, \dots, n - 1\}$.

La differenza assoluta $|p - q|$ varia da 0 a un massimo di $n - 1$. Normalizzando sullo scarto massimo ammissibile, si ottiene:

$$d(p, q) = \frac{|p - q|}{n - 1}, \quad s(p, q) = 1 - d(p, q) = 1 - \frac{|p - q|}{n - 1} \quad (6.2)$$

Esempio 6.2.1 (Similarità tra Giudizi Ordinali). Si consideri una scala di valutazione a $n = 5$ livelli:

$$\{\text{insufficiente} = 0, \text{sufficiente} = 1, \text{buono} = 2, \text{distinto} = 3, \text{ottimo} = 4\} \quad (6.3)$$

Dati due individui con valutazioni $p = 1$ (*sufficiente*) e $q = 4$ (*ottimo*):

$$d(1, 4) = \frac{|1 - 4|}{5 - 1} = \frac{3}{4} = 0.75 \implies s(1, 4) = 1 - 0.75 = 0.25 \quad (6.4)$$

6.2.3 Attributi ad Intervallo e a Rapporto

Per gli attributi numerici continui o discreti, la metrica elementare coincide con lo scarto assoluto lineare $d(p, q) = |p - q|$. La riconduzione a una misura di similarità normalizzata può seguire tre approcci:

1. **Opposto Aritmetico** (illimitato superiormente): $s(p, q) = -|p - q|$;
2. **Inversione Asintotica**: $s(p, q) = \frac{1}{1 + |p - q|}$, con $s \rightarrow 1$ quando $d \rightarrow 0$, e $s \rightarrow 0$ quando $d \rightarrow \infty$;
3. **Normalizzazione Min-Max Lineare**: $s(p, q) = 1 - \frac{d(p, q) - d_{\min}}{d_{\max} - d_{\min}}$, in cui $d_{\min} = 0$ e $d_{\max}$ denota la massima estensione osservata.

6.3 Distanze Vettoriali e Metriche di Minkowski

Quando gli oggetti sono descritti da vettori multidimensionali $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$, la dissimilarità viene calcolata aggregando gli scarti dimensionali lungo le n coordinate ortogonali.

Definizione 6.3.1 (Distanza di Minkowski (Norma L_r)). Dati due vettori $\mathbf{x} = (x_1, \dots, x_n)$ e $\mathbf{y} = (y_1, \dots, y_n)$ in $\mathbb{R}^n$, la **distanza di Minkowski** con parametro $r \geq 1$ è definita come:

$$d(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_r = \left(\sum_{k=1}^n |x_k - y_k|^r \right)^{1/r} \quad (6.5)$$

1. **Distanza di Manhattan** ($r = 1$, Norma L_1 , City Block):

$$d_{L_1}(\mathbf{x}, \mathbf{y}) = \sum_{k=1}^n |x_k - y_k| \quad (6.6)$$

Modella il tragitto percorso lungo percorsi ortogonali. Su vettori binari coincide rigorosamente con la **distanza di Hamming**.

2. **Distanza Euclidea** ($r = 2$, Norma L_2):

$$d_{L_2}(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_{k=1}^n (x_k - y_k)^2} \quad (6.7)$$




Figura 6.2: Struttura della famiglia delle metriche di Minkowski al variare del parametro r .

Corrisponde alla lunghezza del segmento retto nello spazio euclideo. Se le variabili presentano ordini di grandezza eterogenei, è essenziale standardizzarle preventivamente con z -score per evitare la dominanza delle feature ad alta varianza.

3. **Distanza del Supremo ($r \rightarrow \infty$, Norma L_∞ , Distanza di Chebyshev):**

$$d_{L_\infty}(\mathbf{x}, \mathbf{y}) = \lim_{r \rightarrow \infty} \left(\sum_{k=1}^n |x_k - y_k|^r \right)^{1/r} = \max_{1 \leq k \leq n} |x_k - y_k| \quad (6.8)$$

Estrae la massima deviazione osservata lungo una singola componente.

6.4 Esempio di Calcolo delle Matrici di Distanza

Si consideri l'insieme di 4 punti bidimensionali analizzato didatticamente:

$$\mathbf{p}_1 = (0, 2), \quad \mathbf{p}_2 = (2, 0), \quad \mathbf{p}_3 = (3, 1), \quad \mathbf{p}_4 = (5, 1) \quad (6.9)$$

Il calcolo delle distanze analitiche per tutte le coppie distinte genera i seguenti valori:

- $(\mathbf{p}_1, \mathbf{p}_2)$: $\Delta x = 2, \Delta y = 2 \implies L_1 = 4, L_2 = \sqrt{8} \approx 2.828, L_\infty = 2$;
- $(\mathbf{p}_1, \mathbf{p}_3)$: $\Delta x = 3, \Delta y = 1 \implies L_1 = 4, L_2 = \sqrt{10} \approx 3.162, L_\infty = 3$;




Figura 6.3: Disposizione geometrica dei quattro punti campione nel piano cartesiano.

- $(\mathbf{p}_1, \mathbf{p}_4)$: $\Delta x = 5, \Delta y = 1 \implies L_1 = 6, L_2 = \sqrt{26} \approx 5.099, L_\infty = 5$;
- $(\mathbf{p}_2, \mathbf{p}_3)$: $\Delta x = 1, \Delta y = 1 \implies L_1 = 2, L_2 = \sqrt{2} \approx 1.414, L_\infty = 1$;
- $(\mathbf{p}_2, \mathbf{p}_4)$: $\Delta x = 3, \Delta y = 1 \implies L_1 = 4, L_2 = \sqrt{10} \approx 3.162, L_\infty = 3$;
- $(\mathbf{p}_3, \mathbf{p}_4)$: $\Delta x = 2, \Delta y = 0 \implies L_1 = 2, L_2 = \sqrt{4} = 2.000, L_\infty = 2$.

Poiché ogni metrica soddisfa riflessività ($d(\mathbf{p}_i, \mathbf{p}_i) = 0$) e simmetria ($d(\mathbf{p}_i, \mathbf{p}_j) = d(\mathbf{p}_j, \mathbf{p}_i)$), le matrici risultanti assumono forma simmetrica a diagonale principale nulla:

$$\mathbf{D}_{L_1} = \begin{bmatrix} 0 & 4 & 4 & 6 \\ 4 & 0 & 2 & 4 \\ 4 & 2 & 0 & 2 \\ 6 & 4 & 2 & 0 \end{bmatrix}, \quad \mathbf{D}_{L_\infty} = \begin{bmatrix} 0 & 2 & 3 & 5 \\ 2 & 0 & 1 & 3 \\ 3 & 1 & 0 & 2 \\ 5 & 3 & 2 & 0 \end{bmatrix}, \quad (6.10)$$

$$\mathbf{D}_{L_2} = \begin{bmatrix} 0 & 2.828 & 3.162 & 5.099 \\ 2.828 & 0 & 1.414 & 3.162 \\ 3.162 & 1.414 & 0 & 2.000 \\ 5.099 & 3.162 & 2.000 & 0 \end{bmatrix} \quad (6.11)$$

6.5 Proprietà Matematiche di Metriche e Similitudine

Definizione 6.5.1 (Assiomi di una Metrica di Distanza). Una funzione di dissimilarità $d : \mathcal{D} \times \mathcal{D} \rightarrow \mathbb{R}$ è qualificata formalmente come **metrica** se e solo se soddisfa tre assiomi per ogni terna di punti $\mathbf{x}, \mathbf{y}, \mathbf{z} \in \mathcal{D}$:

1. **Definitezza Positiva**:

$$d(\mathbf{x}, \mathbf{y}) \geq 0 \quad \forall \mathbf{x}, \mathbf{y}; \quad d(\mathbf{x}, \mathbf{y}) = 0 \iff \mathbf{x} = \mathbf{y} \quad (6.12)$$

2. **Simmetria:**

$$d(\mathbf{x}, \mathbf{y}) = d(\mathbf{y}, \mathbf{x}) \quad \forall \mathbf{x}, \mathbf{y} \quad (6.13)$$

3. **Disuguaglianza Triangolare:**

$$d(\mathbf{x}, \mathbf{z}) \leq d(\mathbf{x}, \mathbf{y}) + d(\mathbf{y}, \mathbf{z}) \quad \forall \mathbf{x}, \mathbf{y}, \mathbf{z} \quad (6.14)$$

Tutte le metriche di Minkowski ($r \geq 1$) soddisfano rigorosamente i tre assiomi (la disuguaglianza triangolare discende direttamente dalla disuguaglianza di Minkowski per integrali e sommatorie).

Analogamente, una funzione di similarità $s : \mathcal{D} \times \mathcal{D} \rightarrow \mathbb{R}$ soddisfa:

1. **Identità del Massimo:** $s(\mathbf{x}, \mathbf{y}) = 1$ (o valore massimo ammesso) se e solo se $\mathbf{x} = \mathbf{y}$;
2. **Simmetria:** $s(\mathbf{x}, \mathbf{y}) = s(\mathbf{y}, \mathbf{x})$ per ogni coppia $\mathbf{x}, \mathbf{y}$.

6.6 Prossimità tra Vettori Binari: SMC vs Indice di Jaccard

Negli spazi descritti da vettori binari asimmetrici (come le transazioni di acquisto o la presenza di vocaboli in documenti), la quantificazione della concordanza richiede la distinzione tra la presenza (1) e l'assenza (0) di attributi.

Dati due vettori binari $\mathbf{p}$ e $\mathbf{q}$, le frequenze congiunte delle configurazioni di bit definiscono la tabella di contingenza 2×2 :

		Oggetto $\mathbf{q}$	
		1	0
Oggetto $\mathbf{p}$	1	M_{11} (presenza congiunta)	M_{10} (presente solo in $\mathbf{p}$)
	0	M_{01} (presente solo in $\mathbf{q}$)	M_{00} (assenza congiunta)

Tabella 6.2: Tabella di contingenza per vettori di attributi binari.

Il numero totale di attributi binari considerati coincide con la cardinalità:

$$n = M_{11} + M_{10} + M_{01} + M_{00} \quad (6.15)$$

6.6.1 Definizione dei Coefficienti

1. Simple Matching Coefficient (SMC):

$$\text{SMC} = \frac{M_{11} + M_{00}}{M_{01} + M_{10} + M_{11} + M_{00}} \quad (6.16)$$

Assegna pari dignità informativa alle concordanze positive (M_{11}) e a quelle negative (M_{00}). È appropriato per attributi simmetrici (ad es. sesso biologico o risposte binarie bilanciate).

2. Coefficiente di Jaccard (J):

$$J = \frac{M_{11}}{M_{01} + M_{10} + M_{11}} \quad (6.17)$$

Tratta l'attributo come asimmetrico: ignora deliberatamente le concordanze negative (M_{00}).

Perché l'Indice di Jaccard è Indispensabile nei Dati Sparsi

Nei problemi ad elevata dimensionalità e forte sparsità (come l'analisi dei carrelli della spesa o il recupero testuale), due transazioni condividono l'assenza di decine di migliaia di articoli o vocaboli. Se si impiegasse il coefficiente SMC, il termine M_{00} dominerebbe numericamente la frazione, portando a stimare una similarità artificiosamente elevata ($\text{SMC} \rightarrow 1$) per il solo fatto che i due profili non presentano la quasi totalità degli item. L'indice di Jaccard evita questa distorsione vincolando l'analisi agli attributi effettivamente attivi.

Esempio 6.6.1 (Confronto SMC vs Jaccard su Vettori Sparsi). Siano dati due vettori binari con $n = 10$ attributi:

$$\mathbf{p} = [1, 0, 0, 0, 0, 0, 0, 0, 0, 0] \quad (6.18)$$

$$\mathbf{q} = [0, 0, 0, 0, 0, 0, 1, 0, 0, 1] \quad (6.19)$$

Dall'ispezione delle posizioni si ottiene:

$$M_{11} = 0, \quad M_{10} = 1, \quad M_{01} = 2, \quad M_{00} = 7 \quad (6.20)$$

I coefficienti risultano rispettivamente:

$$\text{SMC} = \frac{0 + 7}{2 + 1 + 0 + 7} = \frac{7}{10} = 0.70, \quad J = \frac{0}{2 + 1 + 0} = \frac{0}{3} = 0.00 \quad (6.21)$$

L'SMC riporta un'elevata affinità (70%) dovuta alla sola condivisione di zeri, mentre Jaccard certifica l'assoluta assenza di elementi comuni ($J = 0$).

6.7 Similarità Coseno per Dati Documentali

Nel modello a spazio vettoriale (*Vector Space Model*) tipico dell'Information Retrieval, i documenti vengono rappresentati come vettori multidimensionali di conteggio o pesi TF-IDF nello spazio lessicale dei termini.

In tale scenario, testi di lunghezze eterogenee che affrontano il medesimo tema risulterebbero distanti se valutati con la metrica Euclidea, a causa della diversa norma dei vettori. La **Similarità Coseno** isola l'orientamento angolare reciproco, prescindendo dalla magnitudine:

$$\cos(\mathbf{d}_1, \mathbf{d}_2) = \frac{\mathbf{d}_1 \cdot \mathbf{d}_2}{\|\mathbf{d}_1\|_2 \|\mathbf{d}_2\|_2} = \frac{\sum_{k=1}^n d_{1,k} d_{2,k}}{\sqrt{\sum_{k=1}^n d_{1,k}^2} \sqrt{\sum_{k=1}^n d_{2,k}^2}} \quad (6.22)$$

Esempio 6.7.1 (Calcolo Guidato su Vettori Documentali). Siano dati i vettori dei termini:

$$\mathbf{d}_1 = [3, 2, 0, 5, 0, 0, 0, 2, 0, 0] \quad (6.23)$$

$$\mathbf{d}_2 = [1, 0, 0, 0, 0, 0, 0, 1, 0, 2] \quad (6.24)$$

1. Prodotto Scalare:

$$\mathbf{d}_1 \cdot \mathbf{d}_2 = (3 \times 1) + (2 \times 0) + (5 \times 0) + (2 \times 1) + (0 \times 2) = 3 + 2 = 5 \quad (6.25)$$

2. Norme Euclidee:

$$\|\mathbf{d}_1\|_2 = \sqrt{3^2 + 2^2 + 5^2 + 2^2} = \sqrt{9 + 4 + 25 + 4} = \sqrt{42} \approx 6.4807 \quad (6.26)$$

$$\|\mathbf{d}_2\|_2 = \sqrt{1^2 + 1^2 + 2^2} = \sqrt{1 + 1 + 4} = \sqrt{6} \approx 2.4495 \quad (6.27)$$

3. Similarità Coseno:

$$\cos(\mathbf{d}_1, \mathbf{d}_2) = \frac{5}{\sqrt{42} \times \sqrt{6}} = \frac{5}{\sqrt{252}} = \frac{5}{15.8745} \approx 0.3150 \quad (6.28)$$

I documenti condividono il 31.5% di orientamento tematico congiunto.

6.8 Ponderazione, Dati Mancanti e Correlazione tra Oggetti

6.8.1 Similarità Ponderata con Gestione di Dati Mancanti

Qualora le feature posseggano rilevanze differenziate o contengano valori nulli, si introduce un vettore di pesi non negativi $\{\omega_k\}_{k=1}^n$ e una variabile indicatrice

binaria $\delta_k \in \{0, 1\}$ che vale 1 se e solo se la coordinata k -esima è definita sia per $\mathbf{x}$ sia per $\mathbf{y}$:

$$\text{similarity}(\mathbf{x}, \mathbf{y}) = \frac{\sum_{k=1}^n \omega_k \delta_k s_k(\mathbf{x}, \mathbf{y})}{\sum_{k=1}^n \omega_k \delta_k} \quad (6.29)$$

In modo analogo, la **distanza di Minkowski ponderata** è espressa da:

$$d(\mathbf{x}, \mathbf{y}) = \left(\sum_{k=1}^n \omega_k |x_k - y_k|^r \right)^{1/r} \quad (6.30)$$

6.8.2 Coefficiente di Correlazione tra Oggetti

Il coefficiente di Pearson può essere applicato trasversalmente per quantificare la prossimità tra coppie di vettori profilo $\mathbf{p}$ e $\mathbf{q}$:

$$\text{corr}(\mathbf{p}, \mathbf{q}) = \frac{\sum_{k=1}^n (p_k - \bar{p})(q_k - \bar{q})}{\sqrt{\sum_{k=1}^n (p_k - \bar{p})^2} \sqrt{\sum_{k=1}^n (q_k - \bar{q})^2}} = \mathbf{p}^* \cdot \mathbf{q}^* \quad (6.31)$$

dove $\mathbf{p}^*$ e $\mathbf{q}^*$ sono i profili standardizzati (a media nulla e varianza unitaria lungo le coordinate).

6.9 Teoria dell'Informazione: Entropia e Informazione Mutua

La teoria dell'informazione formalizzata da Claude Shannon (1948) offre gli strumenti analitici per quantificare l'incertezza, il disordine e la dipendenza non lineare tra variabili discrete o categoriche.

6.9.1 Informazione Propria ed Entropia di Shannon

L'informazione associata a un evento aleatorio x_i con probabilità $p_i = P(X = x_i)$ corrisponde alla sorpresa legata al suo verificarsi:

$$I(x_i) = \log_2 \left(\frac{1}{p_i} \right) = -\log_2(p_i) \quad (6.32)$$

L'**Entropia di Shannon** $H(X)$ rappresenta il valore atteso dell'informazione propria:

$$H(X) = \mathbb{E}[I(X)] = -\sum_{i=1}^n p_i \log_2(p_i) \quad (6.33)$$




Figura 6.4: Curva dell'entropia di Shannon per una variabile di Bernoulli in funzione della probabilità di successo p .

con la convenzione di continuità $\lim_{p \rightarrow 0^+} p \log_2(p) = 0$.

L'entropia è limitata: $0 \leq H(X) \leq \log_2(n)$. Si annulla se e solo se la variabile è puramente deterministica ($p_k = 1$), mentre raggiunge il massimo teorico $\log_2(n)$ in presenza di distribuzione uniforme ($p_i = 1/n$).

6.9.2 Informazione Mutua (Mutual Information)

L'**Informazione Mutua** $I(X; Y)$ quantifica la quota di incertezza condivisa tra due variabili aleatorie (ossia la riduzione dell'incertezza su X derivante dalla conoscenza esatta di Y):

$$I(X; Y) = H(X) + H(Y) - H(X, Y) \quad (6.34)$$

in cui $H(X, Y)$ rappresenta l'entropia congiunta definita sulle probabilità congiunte $p_{ij} = P(X = x_i, Y = y_j)$:

$$H(X, Y) = - \sum_{i=1}^{n_X} \sum_{j=1}^{n_Y} p_{ij} \log_2(p_{ij}) \quad (6.35)$$

Proprietà fondamentali:

1. $I(X; Y) \geq 0$ e $I(X; Y) = I(Y; X)$ (non negatività e simmetria);
2. $I(X; Y) = 0 \iff P(X, Y) = P(X)P(Y)$ (annullamento sotto indipendenza statistica);
3. $I(X; Y) \leq \min(H(X), H(Y)) \leq \log_2(\min(n_X, n_Y))$.

6.9.3 Esempio Numerico di Calcolo dell'Informazione Mutua

Si consideri il campione di $m = 100$ studenti universitari analizzato didatticamente, in cui si confronta lo **Status Accademico** ($X \in \{\text{Undergrad}, \text{Grad}\}$) con il **Voto** conseguito ($Y \in \{A, B, C\}$).

Status (X)	Voto A	Voto B	Voto C	Totale (X)
Undergrad	5 (0.05)	30 (0.30)	10 (0.10)	45 (0.45)
Grad	30 (0.30)	20 (0.20)	5 (0.05)	55 (0.55)
Totale (Y)	35 (0.35)	50 (0.50)	15 (0.15)	100 (1.00)

Tabella 6.3: Distribuzione di frequenza congiunta e marginale per lo status e i voti accademici.

1. **Entropia Marginale di X :**

$$H(X) = -0.45 \log_2(0.45) - 0.55 \log_2(0.55) \approx 0.9928 \text{ bit} \quad (6.36)$$

2. **Entropia Marginale di Y :**

$$\begin{aligned} H(Y) &= -0.35 \log_2(0.35) - 0.50 \log_2(0.50) - 0.15 \log_2(0.15) \\ &\approx 0.5301 + 0.5000 + 0.4105 = 1.4406 \text{ bit} \end{aligned} \quad (6.37)$$

3. **Entropia Congiunta $H(X, Y)$:**

$$\begin{aligned} H(X, Y) &= - \sum_{i=1}^2 \sum_{j=1}^3 p_{ij} \log_2(p_{ij}) \\ &\approx 2(0.2161) + 2(0.5211) + 0.3322 + 0.4644 = 2.2710 \text{ bit} \end{aligned} \quad (6.38)$$

4. **Informazione Mutua:**

$$\begin{aligned} I(X; Y) &= H(X) + H(Y) - H(X, Y) \\ &= 0.9928 + 1.4406 - 2.2710 = 0.1624 \text{ bit} \end{aligned} \quad (6.39)$$

La conoscenza dello status dello studente apporta una riduzione netta dell'incertezza sulla votazione pari a 0.1624 bit (l'11.27% dell'entropia originaria della variabile voto).

6.10 Principi Fondamentali della Cluster Analysis

La **Cluster Analysis** (o analisi dei gruppi) è il processo computazionale non supervisionato preposto alla partizione di un dataset $\mathcal{D} = \{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ in sottoinsiemi omogenei (detti **cluster**) in base a due principi cardine:

1. **Massimizzazione dell'Omogeneità Intra-Cluster:** Gli oggetti allocati nel medesimo raggruppamento devono presentare elevata coesione interna e prossimità reciproca;
2. **Massimizzazione della Separazione Inter-Cluster:** Oggetti afferenti a cluster distinti devono presentare massima dissimilarità e separazione metrica.




Figura 6.5: Dicotomia geometrica tra coesione interna e separazione esterna nella cluster analysis.

A differenza dei modelli supervisionati, il clustering non fa affidamento su alcuna variabile target Y prestabilita; l'architettura relazionale emerge autonomamente dalla geometria dello spazio campionario.

6.10.1 Ambiti Applicativi: Comprensione vs Sintesi

Le motivazioni applicative del clustering si distinguono in due polarità:

1. **Comprensione dei Dati (*Understanding*):** Scoperta di strutture e tassonomie latenti:
 - *Information Retrieval*: Organizzazione tematica automatica di collezioni testuali;
 - *Bioinformatica*: Raggruppamento di geni con profili di co-espressione funzionale affini;

- *Finanza e Mercati*: Identificazione di cluster azionari con rendimenti covarianti (es. comparti tecnologici, finanziari o energetici).
2. **Sintesi dei Dati (*Summarization*)**: Compressione dimensionale quantitativa in cui milioni di misurazioni locali vengono rappresentate per mezzo dei rispettivi prototipi (centroidi o medoidi), preservando le proprietà statistiche complessive.

6.10.2 Cosa NON è la Cluster Analysis

Per evitare ambiguità epistemologiche, è cruciale distinguere il clustering da altri task:

- **Segmentazione Manuale**: La suddivisione di record imposta dall'esterno su criteri deterministici arbitrari (es. ripartizione alfabetica per cognome $A - L$ ed $M - Z$) non riflette pattern naturali;
- **Query su Database**: Clausole SQL dichiarative (es. `WHERE Age > 30`) filtrano sottoinsiemi vincolati a regole rigide specificate dall'utente anziché derivate dalla topologia dei dati;
- **Classificazione**: Minimizza l'errore empirico su etichette supervisionate $y \in \mathcal{Y}$ assegnate a priori;
- **Pattern Mining**: L'estrazione di regole di associazione ricerca correlazioni locali o regole implicative tra insiemi di item, mentre il clustering modella la struttura globale dell'intero spazio geometrico.

6.11 Tassonomie dei Metodi e Strutture di Raggruppamento

6.11.1 Clustering Partizionale vs Gerarchico

1. **Clustering Partizionale**: Suddivide lo spazio in k partizioni mutuamente disgiunte $\mathcal{C} = \{C_1, \dots, C_k\}$ che ricoprono integralmente il dataset:

$$\bigcup_{i=1}^k C_i = \mathcal{D}, \quad C_i \cap C_j = \emptyset \quad \forall i \neq j \quad (6.40)$$

Ogni oggetto appartiene a una e una sola partizione. Il numero di gruppi k deve generalmente essere specificato a priori (es. *K-Means*).

2. **Clustering Gerarchico:** Costruisce una famiglia annidata di partizioni rappresentabile visivamente come un albero metrico denominato **dendrogramma**, eliminando il vincolo di dover fissare a monte il valore scalare di k .




Figura 6.6: Confronto strutturale tra clustering partizionale e clustering gerarchico.

6.11.2 Ulteriori Dimensioni Tassonomiche

- **Esclusivo vs Non-Esclusivo (Overlapping):** Nel clustering non-esclusivo un punto può appartenere simultaneamente a più raggruppamenti (utile per punti di frontiera o domini multi-argomento).
- **Fuzzy (Soft) vs Non-Fuzzy (Hard):** Nel clustering fuzzy ogni punto $\mathbf{x}_i$ è associato al cluster C_k mediante un coefficiente di appartenenza continuo $w_{ik} \in [0, 1]$, soggetto al vincolo di conservazione $\sum_{k=1}^K w_{ik} = 1$.
- **Parziale vs Completo:** Gli algoritmi parziali isolano i nuclei ad alta coesione e scartano le osservazioni anomale come rumore o outlier.
- **Omogeneo vs Eterogeneo:** Gli algoritmi omogenei assumono a priori volumi e forme sferoidali confrontabili, mentre i metodi eterogenei ammettono forme arbitrarie e densità fortemente dissimili.

6.12 Tipologie di Cluster e Formulazione Matematica

La nozione semantica di “cluster” assume connotazioni analitiche profondamente distinte a seconda della proprietà geometrica prescelta:




Figura 6.7: Quadro sintetico delle definizioni formali di cluster.

1. **Cluster Ben Separati (*Well-Separated*)**: Ogni punto interno al cluster è più vicino a tutti i membri del proprio gruppo rispetto a qualunque punto esterno:

$$\forall \mathbf{x}, \mathbf{y} \in C_i, \forall \mathbf{z} \notin C_i \implies d(\mathbf{x}, \mathbf{y}) < d(\mathbf{x}, \mathbf{z}) \quad (6.41)$$

2. **Cluster Basati sul Centro (*Center-Based*)**: Ciascun oggetto appartiene al cluster il cui punto centrale è più vicino:

$$\mathbf{x} \in C_i \iff d(\mathbf{x}, \mathbf{c}_i) < d(\mathbf{x}, \mathbf{c}_j) \quad \forall j \neq i \quad (6.42)$$

Il centro può essere il **centroide** (media aritmetica continua $\mathbf{c}_i = \frac{1}{|C_i|} \sum_{\mathbf{x} \in C_i} \mathbf{x}$) o il **medoide** (l'istanza reale più centrale $\mathbf{m}_i = \arg \min_{\mathbf{y} \in C_i} \sum_{\mathbf{x} \in C_i} d(\mathbf{x}, \mathbf{y})$).

3. **Cluster Basati sulla Contiguità (*Contiguity-Based o Graph-Based*)**: Un punto appartiene al cluster se è più vicino ad almeno un elemento del cluster rispetto a qualsiasi punto esterno:

$$\forall \mathbf{x} \in C_i, \exists \mathbf{y} \in C_i \setminus \{\mathbf{x}\} \quad \text{t.c.} \quad d(\mathbf{x}, \mathbf{y}) < \min_{\mathbf{z} \notin C_i} d(\mathbf{x}, \mathbf{z}) \quad (6.43)$$

Consente di modellare geometrie arbitrarie non convesse, ma soffre del grave fenomeno dell'**effetto catena** (*chaining effect*), in cui pochi punti di rumore fanno da ponte fondendo impropriamente cluster separati.

4. **Cluster Basati sulla Densità (*Density-Based*):** Regioni dense di punti delimitate e separate da aree a bassa densità campionaria (es. DBSCAN). Sono naturalmente resistenti al rumore e non vincolati alla forma sferoidale.
5. **Cluster Definiti da una Funzione Obiettivo:** Formulati come problemi di ottimizzazione matematica. L'individuazione della partizione globale ottima su N punti in k gruppi richiederebbe di testare tutti i numeri di Stirling di seconda specie:

$$S(N, k) = \frac{1}{k!} \sum_{j=0}^k (-1)^{k-j} \binom{k}{j} j^N \approx \frac{k^N}{k!} \quad (6.44)$$

Poiché il problema è intrinsecamente **NP-Hard**, si impiegano euristiche iterative di discesa come in K -Means per minimizzare la somma degli errori quadratici (SSE):

$$\text{SSE} = \sum_{i=1}^k \sum_{\mathbf{x} \in C_i} \|\mathbf{x} - \mathbf{c}_i\|_2^2 \quad (6.45)$$

6.13 Caratteristiche dei Dati di Input e Famiglie Algoritmiche

La stabilità e l'efficacia di un processo di clustering dipendono dalle caratteristiche dello spazio di input:

- **Maledizione della Dimensionalità:** Negli spazi $\mathbb{R}^n$ con n elevato, le distanze tra coppie di punti tendono a concentrarsi e ad uniformarsi, degradando il contrasto tra vicini e lontani nella metrica euclidea;
- **Sparsità ed Eterogeneità:** Vettori sparsi richiedono metriche asimmetriche (Jaccard, Coseno); attributi misti necessitano di metriche ibride (Gower);
- **Rumore e Outlier:** Alterano il calcolo dei baricentri nei metodi center-based e innescano fusioni anomale nei metodi contigui.

I tre paradigmi algoritmici fondamentali che derivano da tali premesse sono riassunti come segue:

1. **K -Means e Varianti:** Metodo partizionale, esclusivo e completo. Ottimizza iterativamente la funzione SSE su cluster sferoidali compatti a densità equivalente;

2. **Clustering Gerarchico Agglomerativo:** Metodo gerarchico e nestato. Fonde iterativamente le coppie di gruppi più vicine secondo i criteri di linkage (Single, Complete, Average, Ward), producendo un dendrogramma interpretabile;
3. **Clustering Density-Based (DBSCAN):** Metodo basato su densità locale, parziale e non parametrico rispetto a k . Isola naturalmente i punti di rumore e identifica cluster di forma geometrica arbitraria.

Capitolo 7

Cluster Analysis: Algoritmi K-Means e Clustering Gerarchico

In questo capitolo vengono presentati i fondamenti teorici, le formulazioni algebriche e le dinamiche operative dei due paradigmi cardine dell'apprendimento non supervisionato basato su partizionamento e gerarchizzazione:

1. L'**algoritmo K-Means**: formulazione analitica, dinamica di Lloyd, minimizzazione dell'errore quadratico (SSE), dimostrazione formale di convergenza tramite discesa di coordinate, euristiche di inizializzazione (K-Means++, Bisecting K-Means) e limiti strutturali;
2. Il **Clustering Gerarchico**: approcci agglomerativi e divisivi, interpretazione dei dendrogrammi, criteri di collegamento (*linkage*: MIN, MAX, Group Average, Metodo di Ward con derivazione analitica), ricorrenza universale di Lance-Williams ed equivalenza con il Minimum Spanning Tree (MST).

7.1 Introduzione alla Cluster Analysis Partizionale e Gerarchica

La **Cluster Analysis** (o raggruppamento non supervisionato) costituisce una delle discipline fondanti dell'apprendimento automatico non supervisionato (*unsupervised machine learning*). A differenza dell'apprendimento supervisionato, in cui ogni istanza $\mathbf{x}_i$ è corredata da un'etichetta di classe nota a priori $y_i \in \mathcal{Y}$ (*ground truth*), nel clustering l'obiettivo primario consiste

nello scoprire strutture latenti, regolarità geometriche o aggregazioni naturali all'interno di un insieme di dati multidimensionali non etichettati.




Figura 7.1: Tassonomia dei due principali paradigmi di clustering trattati nel capitolo.

Dato un insieme di n osservazioni $\mathcal{D} = \{\mathbf{x}_1, \dots, \mathbf{x}_n\}$ con $\mathbf{x}_i \in \mathbb{R}^d$, il problema generale del clustering richiede di ripartire $\mathcal{D}$ in sottoinsiemi $C = \{C_1, \dots, C_K\}$ massimizzando congiuntamente due proprietà complementari:

1. **Massima omogeneità interna (*high intra-cluster cohesion*)**: le osservazioni assegnate al medesimo raggruppamento devono risultare il più vicine e simili possibile secondo una metrica stabilita.
2. **Massima eterogeneità esterna (*high inter-cluster separation*)**: elementi appartenenti a gruppi distinti devono esibire una marcata distanza o dissimilarità reciproca.

I due paradigmi affrontano tale sfida con filosofie strutturali differenti: il paradigma partizionale fissa a priori il numero di raggruppamenti K e persegue una tassellazione poligonale ottima dello spazio mediante prototipi; il paradigma gerarchico genera una sequenza continua di partizioni nidificate, delegando la determinazione di K a un'analisi a posteriori del dendrogramma.

7.2 K-Means: Algoritmo di Lloyd e Geometria di Voronoi

L'algoritmo **K-Means** rappresenta il capostipite dei metodi partizionali basati su centroide o prototipo. Introdotto storicamente da Hugo Steinhaus nel 1956, formalizzato da Stuart Lloyd (1957/1982) nei contesti di quantizzazione dei segnali, e denominato da James MacQueen (1967), il metodo realizza un partizionamento rigido (*hard clustering*) in cui ogni punto è assegnato univocamente a un solo cluster.

Definizione 7.2.1 (Partizione Hard e Centroide). Data una collezione di n punti $\mathcal{D} \subset \mathbb{R}^d$ e un intero positivo fissato $K \in \mathbb{N}^+$, una partizione rigida è una famiglia di insiemi $\{C_1, \dots, C_K\}$ tale che:

$$\bigcup_{i=1}^K C_i = \mathcal{D}, \quad C_i \cap C_j = \emptyset \quad (\forall i \neq j), \quad C_i \neq \emptyset \quad (\forall i \in \{1, \dots, K\}) \quad (7.1)$$

A ciascun cluster C_i è associato un vettore prototipo denominato **centroide** $\mathbf{m}_i \in \mathbb{R}^d$, che per la distanza euclidea coincide con il baricentro aritmetico dei punti assegnati:

$$\mathbf{m}_i = \frac{1}{|C_i|} \sum_{\mathbf{x} \in C_i} \mathbf{x} \quad (7.2)$$

dove $|C_i|$ denota la cardinalità del cluster C_i .

7.2.1 Pseudocodice dell'Algoritmo di Lloyd

L'algoritmo di base opera alternando ricorsivamente due fasi deterministiche fino a convergenza, come illustrato nell'Algoritmo 1.

7.2.2 Interpretazione Geometrica: Diagramma di Voronoi

La fase di assegnazione partiziona lo spazio euclideo continuo $\mathbb{R}^d$ in K regioni convesse delimitate da iperpiani bisettori, note come **tassellazione di Voronoi** generata dai prototipi $\{\mathbf{m}_1, \dots, \mathbf{m}_K\}$:

$$V(C_i) = \{\mathbf{x} \in \mathbb{R}^d : \|\mathbf{x} - \mathbf{m}_i\|_2 \leq \|\mathbf{x} - \mathbf{m}_j\|_2 \quad \forall j \neq i\} \quad (7.3)$$

Ciascun iperpiano di separazione tra il cluster C_i e il cluster C_j è ortogonale al segmento congiungente $\mathbf{m}_i$ e $\mathbf{m}_j$ e passa per il loro punto medio. Ne consegue che ogni cluster individuato da K-Means è un poliedro convesso: punti appartenenti a regioni non convesse o concave non possono essere raggruppati correttamente senza frammentare la tassellazione.

Algorithm 1: Algoritmo standard di K-Means (Lloyd).

Dati: Dataset $\mathcal{D} = \{\mathbf{x}_1, \dots, \mathbf{x}_n\} \subset \mathbb{R}^d$, numero di cluster K , tolleranza $\epsilon \geq 0$.

Risultato: Partizione finale $\{C_1, \dots, C_K\}$ e centroidi $\{\mathbf{m}_1, \dots, \mathbf{m}_K\}$.

```
1 Inizializza  $K$  centroidi iniziali  $\{\mathbf{m}_1^{(0)}, \dots, \mathbf{m}_K^{(0)}\}$  mediante estrazione casuale da  $\mathcal{D}$ 
2  $t \leftarrow 0$ 
3 repeat
4    $t \leftarrow t + 1$ 
5   // Fase 1: Assegnazione alle celle di Voronoi
6   Inizializza  $C_i^{(t)} \leftarrow \emptyset$  per ogni  $i \in \{1, \dots, K\}$ 
7   foreach  $\mathbf{x} \in \mathcal{D}$  do
8     Determina l'indice del centroide più vicino:
9      $k^* = \arg \min_{j \in \{1, \dots, K\}} \|\mathbf{x} - \mathbf{m}_j^{(t-1)}\|^2$ 
10    Assegna  $\mathbf{x}$  al cluster corrispondente:  $C_{k^*}^{(t)} \leftarrow C_{k^*}^{(t)} \cup \{\mathbf{x}\}$ 
11  end
12  // Fase 2: Ricalcolo dei centroidi (baricentri)
13  foreach  $i \in \{1, \dots, K\}$  do
14    if  $|C_i^{(t)}| > 0$  then
15       $\mathbf{m}_i^{(t)} \leftarrow \frac{1}{|C_i^{(t)}|} \sum_{\mathbf{x} \in C_i^{(t)}} \mathbf{x}$ 
16    end
17    else
18      Gestisci cluster vuoto riallocando un centroide orfano
19    end
20  end
21 until  $i$  centroidi non variano significativamente:
22    $\sum_{i=1}^K \|\mathbf{m}_i^{(t+1)} - \mathbf{m}_i^{(t)}\|^2 \leq \epsilon$ 
```




Figura 7.2: Ciclo iterativo di aggiornamento a due fasi dell’algoritmo K-Means.

7.2.3 Dinamica Temporale delle Iterazioni

Studiando l’evoluzione dei centroidi lungo l’asse delle iterazioni $t = 1, 2, \dots$:

- **Iterazioni 1–3:** Si osserva la migrazione macroscopica più rilevante. I centroidi iniziali si allontanano rapidamente dalle configurazioni spurie e migrano verso i baricentri delle macro-regioni a maggiore densità.
- **Iterazioni 4–6 e successive:** Si entra nella fase di raffinamento fine. Pochi punti di confine vengono riassegnati lungo le superfici di Voronoi finché la variazione dei centroidi si annulla o scende sotto la soglia numerica prefissata ϵ .

7.2.4 Generalizzazione ad Altre Metriche di Prossimità

Sebbene K-Means sia formalizzato per la distanza euclidea, la struttura a due fasi può essere generalizzata ad altre misure di prossimità, a patto di ridefinire coerentemente la nozione di prototipo:

- **Distanza Euclidea (L_2):** Prototipo = **Media** (baricentro). Minimizza l’errore quadratico (SSE).
- **Distanza di Manhattan (L_1):** Prototipo = **Mediana** per componente (algoritmo **K-Medians**). Minimizza la somma degli errori assoluti ($\text{SAE} = \sum_i \sum_{\mathbf{x} \in C_i} \|\mathbf{x} - \mathbf{m}_i\|_1$).

- **Similarità Coseno:** Prototipo = **Media normalizzata** a norma unitaria ($\mathbf{m}_i / \|\mathbf{m}_i\|_2$). Massimizza la similarità coseno cumulativa (impiegato nel text mining).
- **Correlazione di Pearson:** Prototipo = **Vettore standardizzato** (media zero, varianza unitaria).

7.2.5 Analisi della Complessità Computazionale

L'algoritmo di Lloyd vanta un'eccellente scalabilità computazionale:

- **Complessità Temporale:** Ad ogni iterazione, la fase di assegnazione confronta ciascuno degli n punti con tutti i K centroidi in dimensione d , richiedendo $\mathcal{O}(n \cdot K \cdot d)$ operazioni. Il ricalcolo dei baricentri richiede la somma dei vettori, con costo $\mathcal{O}(n \cdot d)$. Indicando con I il numero totale di iterazioni fino a convergenza, la complessità asintotica totale è:

$$\mathcal{T}_{\text{K-Means}} = \mathcal{O}(n \cdot K \cdot I \cdot d) \quad (7.4)$$

Poiché sperimentalmente $K \ll n$, $d \ll n$ e $I \ll n$ (spesso $I \leq 50$), il tempo cresce linearmente con la dimensione del dataset n .

- **Complessità Spaziale:** È sufficiente memorizzare la matrice dei dati $n \times d$ e i K vettori centroidi di dimensione d , oltre al vettore degli indici di appartenenza $n \times 1$:

$$\mathcal{S}_{\text{K-Means}} = \mathcal{O}((n + K) \cdot d) \quad (7.5)$$

rendendo l'algoritmo applicabile a contesti di Big Data in cui l'intero dataset risiede in memoria principale.

7.3 Funzione Obiettivo SSE e Dimostrazione di Convergenza

L'efficacia e la stabilità analitica del K-Means derivano dall'esistenza di una funzione obiettivo scalare rigorosamente minimizzata dall'alternanza delle due fasi di Lloyd.

Definizione 7.3.1 (Sum of Squared Errors (SSE)). Data una partizione $\{C_1, \dots, C_K\}$ e i rispettivi centroidi $\{\mathbf{m}_1, \dots, \mathbf{m}_K\}$, la **somma degli errori quadratici** (SSE, o inerzia interna del clustering) è definita come:

$$\text{SSE} = \sum_{i=1}^K \sum_{\mathbf{x} \in C_i} \|\mathbf{x} - \mathbf{m}_i\|_2^2 = \sum_{i=1}^K \sum_{\mathbf{x} \in C_i} \sum_{j=1}^d (x_j - m_{ij})^2 \quad (7.6)$$

7.3.1 Dimostrazione: Il Baricentro Minimizza Rigorosamente l'SSE

Teorema 7.3.1 (Ottimalità del Baricentro). *Dato un cluster C_k contenente $|C_k|$ punti in $\mathbb{R}^d$, il prototipo $\mathbf{m}_k \in \mathbb{R}^d$ che minimizza la somma delle distanze euclidee al quadrato dei punti di C_k è univocamente il baricentro aritmetico dei punti stessi.*

Dimostrazione. L'errore quadratico associato al singolo cluster C_k può essere scomposto come somma indipendente sulle d dimensioni ortogonali:

$$\text{SSE}_k = \sum_{\mathbf{x} \in C_k} \sum_{j=1}^d (x_j - m_{kj})^2 = \sum_{j=1}^d \left(\sum_{\mathbf{x} \in C_k} (x_j - m_{kj})^2 \right) \quad (7.7)$$

Per trovare il punto di minimo rispetto a ciascuna componente scalare m_{kj} del centroide $\mathbf{m}_k$, calcoliamo la derivata parziale prima e la poniamo uguale a zero:

$$\begin{aligned} \frac{\partial \text{SSE}_k}{\partial m_{kj}} &= \frac{\partial}{\partial m_{kj}} \sum_{\mathbf{x} \in C_k} (x_j - m_{kj})^2 \\ &= \sum_{\mathbf{x} \in C_k} 2(x_j - m_{kj}) \cdot (-1) \\ &= -2 \sum_{\mathbf{x} \in C_k} x_j + 2 \sum_{\mathbf{x} \in C_k} m_{kj} = 0 \end{aligned} \quad (7.8)$$

Poiché m_{kj} è una costante scalare rispetto all'indice di sommatoria $\mathbf{x} \in C_k$, la seconda sommatoria restituisce $|C_k| \cdot m_{kj}$:

$$2|C_k| m_{kj} = 2 \sum_{\mathbf{x} \in C_k} x_j \implies m_{kj} = \frac{1}{|C_k|} \sum_{\mathbf{x} \in C_k} x_j \quad (7.9)$$

Verifichiamo la condizione di minimo calcolando la derivata seconda:

$$\frac{\partial^2 \text{SSE}_k}{\partial m_{kj}^2} = 2|C_k| > 0 \quad (7.10)$$

La matrice Hessiana associata è una matrice diagonale scalare definita positiva:

$$\nabla^2 \text{SSE}_k = 2|C_k| \mathbf{I}_d \succ 0 \quad (7.11)$$

Pertanto, il baricentro $\mathbf{m}_k = \frac{1}{|C_k|} \sum_{\mathbf{x} \in C_k} \mathbf{x}$ è l'unico minimizzatore globale stretto di SSE_k . $\square$

7.3.2 Formulazione come Discesa di Coordinate e Convergenza

L'algoritmo di Lloyd può essere formalizzato matematicamente come un'ottimizzazione per **discesa di coordinate** (*Coordinate Descent*) su una funzione bivariata.

Definiamo la matrice di appartenenza binaria $\mathbf{W} \in \{0, 1\}^{n \times K}$, dove $w_{ik} = 1$ se l'istanza $\mathbf{x}_i$ appartiene al cluster k e $w_{ik} = 0$ altrimenti, con il vincolo $\sum_{k=1}^K w_{ik} = 1$ per ogni $i \in \{1, \dots, n\}$. Sia inoltre $\mathbf{S} = (\mathbf{m}_1, \dots, \mathbf{m}_K) \in \mathbb{R}^{d \times K}$ l'insieme dei centroidi. La funzione obiettivo globale è:

$$G(\mathbf{W}, \mathbf{S}) = \sum_{i=1}^n \sum_{k=1}^K w_{ik} \|\mathbf{x}_i - \mathbf{m}_k\|_2^2 \quad (7.12)$$

Teorema 7.3.2 (Convergenza Monotona a un Minimo Locale). *L'algoritmo K-Means riduce monotonamente la funzione obiettivo $G(\mathbf{W}, \mathbf{S})$ ad ogni semi-passo e converge in un numero finito di iterazioni a un minimo locale o punto stazionario.*

Dimostrazione. L'esecuzione si articola in due passi di minimizzazione alternata:

1. **Passo 1 (Assegnazione):** Fissata la matrice dei centroidi $\mathbf{S}^{(t-1)}$, si minimizza $G(\mathbf{W}, \mathbf{S}^{(t-1)})$ rispetto a $\mathbf{W}$. Poiché ogni termine per l'osservazione $\mathbf{x}_i$ è indipendente, la funzione è minimizzata ponendo:

$$w_{ik}^{(t)} = \begin{cases} 1 & \text{se } k = \arg \min_j \|\mathbf{x}_i - \mathbf{m}_j^{(t-1)}\|_2^2 \\ 0 & \text{altrimenti} \end{cases} \quad (7.13)$$

Ne consegue che:

$$G(\mathbf{W}^{(t)}, \mathbf{S}^{(t-1)}) \leq G(\mathbf{W}^{(t-1)}, \mathbf{S}^{(t-1)}) \quad (7.14)$$

2. **Passo 2 (Aggiornamento):** Fissata la nuova matrice di appartenenza $\mathbf{W}^{(t)}$, si minimizza $G(\mathbf{W}^{(t)}, \mathbf{S})$ rispetto a $\mathbf{S}$. Dal teorema precedente sull'ottimalità del baricentro, la scelta ottima per ogni $\mathbf{m}_k$ è:

$$\mathbf{m}_k^{(t)} = \frac{\sum_{i=1}^n w_{ik}^{(t)} \mathbf{x}_i}{\sum_{i=1}^n w_{ik}^{(t)}} = \frac{1}{|C_k^{(t)}|} \sum_{\mathbf{x} \in C_k^{(t)}} \mathbf{x} \quad (7.15)$$

Ne consegue che:

$$G(\mathbf{W}^{(t)}, \mathbf{S}^{(t)}) \leq G(\mathbf{W}^{(t)}, \mathbf{S}^{(t-1)}) \quad (7.16)$$

Combinando le due disuguaglianze, la successione dei valori assunti dalla funzione obiettivo è monotona non crescente:

$$G(\mathbf{W}^{(t)}, \mathbf{S}^{(t)}) \leq G(\mathbf{W}^{(t-1)}, \mathbf{S}^{(t-1)}) \quad (7.17)$$

Poiché $G(\mathbf{W}, \mathbf{S}) \geq 0$ è limitata inferiormente da zero, e il numero di possibili matrici di assegnazione discrete $\mathbf{W}$ è finito (pari al numero di partizioni di n elementi in K gruppi non vuoti, quantificato dai numeri di Stirling di seconda specie $S(n, K)$), l'algoritmo non può entrare in cicli infiniti e deve necessariamente convergere in un numero finito di passi a una configurazione stazionaria (minimo locale). $\square$

7.4 Scelta del Parametro K, Minimi Locali e Inizializzazione

Nonostante la convergenza garantita, la superficie di errore dell'ottimizzazione K-Means è altamente non convessa e costellata da innumerevoli minimi locali sub-ottimali. Infatti, la determinazione della partizione che minimizza globalmente l'SSE è un problema **NP-hard** anche per soli $K = 2$ cluster in dimensione arbitraria, o per dimensione $d = 2$ con K arbitrario.

7.4.1 Determinazione del Numero di Cluster: Il Metodo a Gomito

Poiché all'aumentare di K la funzione $SSE(K)$ decresce monotonicamente (fino ad annullarsi banalmente per $K = n$), non è possibile minimizzare l'SSE direttamente rispetto a K .

Si ricorre all'**Elbow Method** (Metodo a Gomito):

1. Si esegue K-Means per una sequenza crescente di valori candidati $K \in \{1, 2, \dots, K_{\max}\}$;
2. Si traccia la curva di SSE in funzione di K ;
3. Si individua il punto di flesso ("gomito") in cui il decremento marginale di errore subisce un drastico rallentamento.

Matematicamente, il gomito corrisponde al valore di K che massimizza la derivata seconda discreta dell'SSE:

$$\Delta^2 SSE(K) = SSE(K + 1) - 2 SSE(K) + SSE(K - 1) \quad (7.18)$$

Oltre tale soglia, l'introduzione di ulteriori cluster frammenta aggregazioni naturali senza apportare reale guadagno informativo.

7.4.2 Sensibilità ai Centroidi Iniziali e Dimostrazione Combinatoria

La qualità della partizione finale di K-Means dipende criticamente dal posizionamento dei centroidi iniziali $\mathbf{m}_1^{(0)}, \dots, \mathbf{m}_K^{(0)}$. Se due centroidi cadono all'interno dello stesso addensamento naturale, uno dei cluster vicini rimarrà orfano, intrappolando l'algoritmo in un minimo locale sub-ottimale.

Teorema 7.4.1 (Probabilità Combinatoria di Inizializzazione Perfetta). *Si consideri un dataset ideale composto da K cluster naturali ben separati, ciascuno avente la medesima cardinalità N/K . Scegliendo K centroidi iniziali mediante campionamento casuale uniforme indipendente con reinserimento, la probabilità $P(K)$ che ciascun centroide iniziale appartenga a un cluster distinto è:*

$$P(K) = \frac{K!}{K^K} \quad (7.19)$$

Dimostrazione. Calcoliamo la probabilità come prodotto delle probabilità condizionate passo per passo:

1. Il primo centroide può cadere in uno qualsiasi dei K cluster: $P_1 = \frac{K}{K} = 1$.
2. Affinché il secondo centroide cada in un cluster distinto dal primo, deve essere estratto da uno dei restanti $K - 1$ cluster non ancora occupati. Poiché tutti i cluster hanno cardinalità uguale, la frazione di punti ammissibili è $P_2 = \frac{K-1}{K}$.
3. Il terzo centroide deve cadere in uno dei restanti $K - 2$ cluster: $P_3 = \frac{K-2}{K}$.
4. Iterando fino al K -esimo centroide, la frazione residua è $P_K = \frac{1}{K}$.

Moltiplicando le probabilità degli eventi indipendenti:

$$P(K) = \prod_{j=1}^K \frac{K - j + 1}{K} = \frac{K \cdot (K - 1) \cdot (K - 2) \cdots 1}{K^K} = \frac{K!}{K^K} \quad (7.20)$$

□

Valutando la formula (7.19) per diversi valori di K :

- $K = 2 \implies P(2) = \frac{2}{4} = 0.50$ (50%);
- $K = 3 \implies P(3) = \frac{6}{27} \approx 0.222$ (22.2%);
- $K = 5 \implies P(5) = \frac{120}{3125} \approx 0.0384$ (3.84%);
- $K = 10 \implies P(10) = \frac{3628800}{10^{10}} \approx 0.00036$ (appena lo **0.036%**).

Applicando l'approssimazione asintotica di Stirling $K! \approx \sqrt{2\pi K} \left(\frac{K}{e}\right)^K$, otteniamo:

$$P(K) \approx \frac{\sqrt{2\pi K} \left(\frac{K}{e}\right)^K}{K^K} = \sqrt{2\pi K} \cdot e^{-K} \quad (7.21)$$

La probabilità di successo dell'inizializzazione casuale pura decade in modo **esponenzialmente veloce** verso zero al crescere di K . Con $K \geq 10$, l'inizializzazione uniforme non garantisce quasi mai la corretta convergenza.

7.5 Euristiche di Inizializzazione e Varianti di K-Means

Per superare la fragilità dell'inizializzazione casuale, la letteratura ha sviluppato potenti strategie correttive ed euristiche algoritmiche avanzate.

7.5.1 Tecniche Euristiche di Inizializzazione

1. **Restart Casuali Multipli (*Random Restarts*)**: Si esegue l'algoritmo R volte (es. $R = 50$) con semi casuali differenti, selezionando la soluzione che restituisce il valore minimo di SSE. Efficace per valori modesti di K , ma computazionalmente oneroso e inefficace per K elevato.
2. **Campionamento con Pre-clustering Gerarchico**: Si estrae un campione casuale ridotto del dataset ($\approx 1\% - 5\%$) e si applica un algoritmo gerarchico agglomerativo con Metodo di Ward per determinare K raggruppamenti stabili, i cui baricentri vengono usati come semi per K-Means.
3. **K-Means++ (D^2 -Weighting)**: Introdotto da Arthur e Vassilvitskii (2007), sceglie il primo centroide a caso, e ciascun centroide successivo con probabilità proporzionale al quadrato della distanza minima dai centroidi già allocati:

$$p(\mathbf{x}) = \frac{D(\mathbf{x})^2}{\sum_{\mathbf{y} \in \mathcal{D}} D(\mathbf{y})^2}, \quad D(\mathbf{x}) = \min_{j \in \{1, \dots, m\}} \|\mathbf{x} - \mathbf{m}_j\|_2 \quad (7.22)$$

Garanzia teorica: K-Means++ garantisce che il valore atteso dell'SSE finale sia entro un fattore logaritmico rispetto all'ottimo globale:

$$\mathbb{E}[\text{SSE}] \leq 8(\ln K + 2) \cdot \text{SSE}_{\text{opt}} = \mathcal{O}(\log K) \cdot \text{SSE}_{\text{opt}} \quad (7.23)$$

4. **Bisecting K-Means:** Algoritmo partizionale ibrido che opera ricorsivamente con bisezioni binarie ($K = 2$):

- Inizia considerando l'intero dataset come un unico macro-cluster;
- A ogni iterazione, seleziona il cluster con il più alto SSE interno (o con cardinalità massima);
- Applica il K-Means standard con $K = 2$ su tale cluster per scinderlo in due sotto-gruppi;
- Ripete il processo finché non si ottengono esattamente K cluster.

Bisecting K-Means è nettamente meno sensibile all'inizializzazione rispetto a Lloyd e produce naturalmente una gerarchia parziale dei cluster.

7.5.2 Aggiornamento Incrementale (Online K-Means)

Nella variante di MacQueen (1967), i centroidi vengono aggiornati *immediatamente* dopo la riassegnazione di ogni singolo punto, invece di attendere la fine dell'epoca (*batch*):

Proprietà 7.5.1 (Formule di Aggiornamento Incrementale di MacQueen).
Se il punto $\mathbf{x}$ viene rimosso dal cluster C_j e assegnato al cluster C_i :

$$\mathbf{m}_j \leftarrow \mathbf{m}_j - \frac{\mathbf{x} - \mathbf{m}_j}{|C_j| - 1} \quad (7.24)$$

$$\mathbf{m}_i \leftarrow \mathbf{m}_i + \frac{\mathbf{x} - \mathbf{m}_i}{|C_i| + 1} \quad (7.25)$$

L'approccio incrementale garantisce che l'SSE decresca strettamente ad ogni singolo spostamento, azzerando la possibilità che si generino cluster vuoti, ma introduce una dipendenza dall'ordine di presentazione dei punti.

7.5.3 Gestione dei Cluster Vuoti (*Empty Clusters*)

Nell'algoritmo batch di Lloyd, può accadere che durante la fase di assegnazione nessun punto dati sia più vicino al centroide $\mathbf{m}_k$ rispetto agli altri $K - 1$ centroidi, portando a $|C_k| = 0$ (centroide orfano). Strategie di ripristino per mantenere inalterato K :

1. **Selezione a Massimo Errore Residuo:** Identificare il punto $\mathbf{x}^* \in \mathcal{D}$ che massimizza la distanza quadratica dal proprio centroide assegnato $\|\mathbf{x}^* - \mathbf{m}_{c(\mathbf{x}^*)}\|^2$ e promuoverlo a nuovo centroide isolato del cluster vuoto. Questa strategia produce la massima riduzione marginale istantanea dell'SSE.

2. **Scissione del Cluster a Massimo SSE:** Identificare il cluster che esibisce il più elevato SSE cumulativo ed estrarre il suo punto più periferico per popolare il cluster orfano.

7.6 Limitazioni Strutturali di K-Means e Tecniche di Adattamento

K-Means presuppone implicitamente che i cluster siano sferici, compatti, ben separati e dotati di volumi e densità omogenee. In presenza di configurazioni geometriche complesse, l'algoritmo fallisce sistematicamente.

1. Dimensioni Eterogenee

I centroidi dividono equamente lo spazio; il cluster più piccolo attrae e ingloba punti periferici del cluster più grande.

2. Densità Eterogenee

I cluster sparsi a bassa densità vengono spezzati, mentre cluster compatti ad alta densità vicini vengono fusi.

3. Forme Non Globulari

Geometrie concave o intrecciate (*two moons*, anelli) vengono tagliate linearmente dagli iperpiani di Voronoi.

4. Sensibilità agli Outlier

La metrica quadratica $\|\mathbf{x} - \mathbf{m}\|^2$ devia gravemente i centroidi verso le anomalie isolate.

Figura 7.3: Quattro scenari critici di fallimento strutturale dell'algoritmo standard K-Means.

7.6.1 Analisi delle Tre Limitazioni Geometriche

1. **Dimensioni Differenti:** Poiché l'SSE penalizza gli scarti quadratici senza considerare il volume intrinseco, il centroide assegnato al cluster compatto attrae punti del cluster disperso per minimizzare l'errore globale, determinando confini incoerenti.
2. **Densità Differenti:** Iperpiani posizionati equidistantemente tra centroidi non tengono conto del gradiente di densità. Un cluster a bassissima densità richiederà più centroidi per essere coperto, causando l'unione impropria di cluster ad alta densità vicini.
3. **Forme Non Globulari (es. *Two Moons*):** Le celle di Voronoi sono poliedri convessi. Se i dati seguono varietà curvilinee non convesse

(due semicerchi intrecciati), un iperpiano lineare secante taglia inevitabilmente a metà entrambi i corpi continui, fallendo completamente la separazione.

Strategia di Risoluzione: Over-Clustering

Per modellare varietà curvilinee o densità eterogenee, si esegue K-Means con un numero elevato di micro-cluster ($K' \gg K$). Tanti piccoli centroidi formano un'approssimazione poligonale a pezzi (*piecewise linear approximation*) che segue il profilo della curva continua. Successivamente, algoritmi basati su grafi o collegamenti ricompongono i micro-cluster nelle forme non lineari desiderate.

7.6.2 Pre-processing e Post-processing: Il Paradigma ISODATA

Per mitigare questi limiti nell'analisi partizionale, si adottano routine di pre- e post-elaborazione formalizzate storicamente nell'algoritmo **ISODATA** (*Iterative Self-Organizing Data Analysis Technique*):

- **Pre-processing:**
 - Normalizzazione o standardizzazione delle feature (z-score) per impedire che dimensioni con scale numeriche elevate dominino il calcolo della distanza euclidea;
 - Identificazione e rimozione preliminare degli outlier prima dell'inizializzazione dei centroidi.
- **Post-processing (Dinamica ISODATA):**
 - **Split (Scissione):** Se la deviazione standard o l'SSE di un cluster supera una soglia massima θ_{split} , e la cardinalità è sufficiente ($|C_i| \geq 2\theta_{\text{min}}$), il cluster viene diviso in due lungo la coordinata di massima varianza.
 - **Merge (Fusione):** Se la distanza euclidea tra due centroidi $\|\mathbf{m}_i - \mathbf{m}_j\|_2$ è inferiore a una soglia minima θ_{merge} , i due cluster vengono fusi in un unico raggruppamento baricentrico.
 - **Eliminazione:** Se $|C_i| < \theta_{\text{min}}$, il cluster viene soppresso e i suoi punti redistribuiti.

7.7 Fondamenti del Clustering Gerarchico

Il **Clustering Gerarchico** supera la rigidità della partizione piatta generando una tassonomia continua di partizioni nidificate (*nested clusters*).

Definizione 7.7.1 (Dendrogramma). Il **dendrogramma** è una rappresentazione grafica ad albero binario radicato in cui:

- Le **foglie** al livello $h = 0$ rappresentano i singoli punti dati isolati (cluster singleton);
- I **nodì interni** rappresentano le unioni successive di coppie di cluster;
- L'**altezza** h a cui due rami si collegano corrisponde formalmente alla distanza o dissimilarità inter-cluster al momento della loro fusione.




Figura 7.4: Struttura di un dendrogramma: le altezze delle giunzioni indicano la distanza di unione. Un taglio orizzontale induce una partizione piatta con $K = 3$ cluster.

7.7.1 Vantaggi Distintivi del Paradigma Gerarchico

- **Nessun vincolo a priori su K :** Non è richiesto specificare anticipatamente il numero di cluster. L'analista ottiene una visualizzazione completa dell'architettura dei dati ed estrae K a posteriori tracciando un taglio orizzontale alla quota desiderata h^* .
- **Modellazione di gerarchie biologiche e tassonomiche:** Strutture evolutive, tassonomie filogenetiche e relazioni semantiche possiedono una natura intrinsecamente gerarchica perfettamente rispecchiata dal dendrogramma.
- **Determinismo:** A differenza del K-Means, gli algoritmi gerarchici standard sono completamente deterministici (non dipendono da semi di inizializzazione casuali).

7.7.2 Tassonomia degli Algoritmi Gerarchici

- **Agglomerativi (*Bottom-up*)**: Iniziano considerando ogni punto come un cluster singleton (n cluster iniziali) e, a ciascun passo, fondono iterativamente la coppia di cluster più vicina fino a formare un unico grande raggruppamento radice in $n - 1$ passi.
- **Divisivi (*Top-down*)**: Iniziano considerando l'intero dataset come un unico mega-cluster e, ad ogni iterazione, partizionano ricorsivamente i gruppi in sotto-gruppi fino a ricondursi a n singleton.

7.8 Algoritmo Agglomerativo e Criteri di Collegamento (Linkage)

L'approccio agglomerativo standard richiede la definizione di una matrice di prossimità inter-cluster $\mathbf{D} \in \mathbb{R}^{N \times N}$ e segue il ciclo descritto nell'Algoritmo 2.

Algorithm 2: Algoritmo gerarchico agglomerativo standard.

Dati: Dataset $\mathcal{D} = \{\mathbf{x}_1, \dots, \mathbf{x}_n\}$, metrica di distanza tra punti $d(\cdot, \cdot)$.

Risultato: Dendrogramma completo delle fusioni gerarchiche.

- 1 Inizializza n cluster singleton: $C_i = \{\mathbf{x}_i\}$ per ogni $i \in \{1, \dots, n\}$
 - 2 Costruisci la matrice di prossimità iniziale $\mathbf{D}^{(0)} \in \mathbb{R}^{n \times n}$ con
$$D_{ij} = d(\mathbf{x}_i, \mathbf{x}_j)$$
 - 3 **for** $t = 1$ **to** $n - 1$ **do**
 - 4 Trova la coppia di cluster (A, B) a minima distanza nella matrice:
$$(A, B) = \arg \min_{i \neq j} D_{ij}^{(t-1)}$$
 - 5 Fondi i cluster A e B creando il nuovo cluster $A \cup B$ a quota
$$h_t = D_{AB}^{(t-1)}$$
 - 6 Elimina le righe e colonne corrispondenti ad A e B dalla matrice di prossimità
 - 7 Calcola la distanza tra il nuovo cluster $A \cup B$ e ogni altro cluster residuo Q secondo il criterio di collegamento prescelto
 - 8 Aggiorna la matrice di prossimità $\mathbf{D}^{(t)}$ inserendo la nuova riga/colonna associata ad $A \cup B$
 - 9 **end**
-

7.8.1 I Quattro Criteri di Collegamento (*Linkage*)

La definizione della distanza $D(A, B)$ tra due insiemi di punti A e B determina interamente la forma e le proprietà della gerarchia risultante.

1. MIN (Single Link)

La distanza tra due cluster coincide con la minima distanza tra qualsiasi coppia di punti:

$$D_{\text{MIN}}(A, B) = \min_{\mathbf{x} \in A, \mathbf{y} \in B} d(\mathbf{x}, \mathbf{y}) \quad (7.26)$$

- **Punti di forza:** Capace di catturare forme arbitrarie non convesse, filiformi o ad anello (è isomorfo alla costruzione del Minimum Spanning Tree).
- **Debolezze (*Chaining Effect*):** Estremamente sensibile al rumore e agli outlier. Anche un singolo punto spurio situato tra due cluster compatti distinti funge da "ponte", inducendo la fusione prematura dei due macro-gruppi in un'unica lunga catena.

2. MAX (Complete Link)

La distanza tra due cluster coincide con la massima distanza tra le loro coppie di punti:

$$D_{\text{MAX}}(A, B) = \max_{\mathbf{x} \in A, \mathbf{y} \in B} d(\mathbf{x}, \mathbf{y}) \quad (7.27)$$

- **Punti di forza:** Robusto rispetto al rumore e immune al chaining effect; tende a produrre cluster iper-compatti e globulari limitando formalmente il diametro massimo del cluster combinato: $\text{diam}(A \cup B) \leq h$.
- **Debolezze:** Tende a frammentare ingiustificatamente grandi cluster allungati e soffre la presenza di outlier periferici estremi.

3. Group Average (Average Link / UPGMA)

La distanza tra due cluster è la media aritmetica di tutte le distanze a coppie:

$$D_{\text{AVG}}(A, B) = \frac{1}{|A| \cdot |B|} \sum_{\mathbf{x} \in A} \sum_{\mathbf{y} \in B} d(\mathbf{x}, \mathbf{y}) \quad (7.28)$$

Costituisce un compromesso matematicamente bilanciato tra la permissività di MIN e la severità di MAX. È relativamente robusto al rumore poiché l'effetto di singoli outlier viene mediato sull'intera cardinalità del gruppo.

4. Metodo di Ward (Minimizzazione della Varianza)

Introdotta da Joe H. Ward Jr. (1963), la prossimità tra due cluster è misurata tramite l'**incremento dell'errore quadratico totale** (ΔSSE) che deriverebbe dalla loro eventuale fusione:

$$\Delta\text{SSE}_{AB} = \text{SSE}_{A \cup B} - (\text{SSE}_A + \text{SSE}_B) \quad (7.29)$$

Teorema 7.8.1 (Formulazione Chiusa del Metodo di Ward). *L'incremento dell'errore quadratico ΔSSE_{AB} dovuto alla fusione dei cluster A e B equivale alla distanza euclidea al quadrato tra i loro rispettivi centroidi, scalata dal prodotto armonico delle loro masse:*

$$\Delta\text{SSE}_{AB} = \frac{|A| \cdot |B|}{|A| + |B|} \|\mathbf{m}_A - \mathbf{m}_B\|_2^2 \quad (7.30)$$

Dimostrazione. Siano A e B due cluster disgiunti con cardinalità $|A|, |B|$ e centroidi $\mathbf{m}_A, \mathbf{m}_B$. Il centroide del cluster fuso $A \cup B$ è la media pesata dei baricentri:

$$\mathbf{m}_{A \cup B} = \frac{|A|\mathbf{m}_A + |B|\mathbf{m}_B}{|A| + |B|} \quad (7.31)$$

Calcoliamo lo scarto vettoriale tra il baricentro combinato e il baricentro originale $\mathbf{m}_A$:

$$\mathbf{m}_{A \cup B} - \mathbf{m}_A = \frac{|A|\mathbf{m}_A + |B|\mathbf{m}_B - (|A| + |B|)\mathbf{m}_A}{|A| + |B|} = \frac{|B|(\mathbf{m}_B - \mathbf{m}_A)}{|A| + |B|} \quad (7.32)$$

Simmetricamente per il cluster B :

$$\mathbf{m}_{A \cup B} - \mathbf{m}_B = \frac{|A|(\mathbf{m}_A - \mathbf{m}_B)}{|A| + |B|} \quad (7.33)$$

L'errore quadratico totale del cluster unificato è:

$$\text{SSE}_{A \cup B} = \sum_{\mathbf{x} \in A} \|\mathbf{x} - \mathbf{m}_{A \cup B}\|^2 + \sum_{\mathbf{y} \in B} \|\mathbf{y} - \mathbf{m}_{A \cup B}\|^2 \quad (7.34)$$

Sviluppiamo il primo termine inserendo e sottraendo il baricentro originale $\mathbf{m}_A$:

$$\begin{aligned} \sum_{\mathbf{x} \in A} \|\mathbf{x} - \mathbf{m}_{A \cup B}\|^2 &= \sum_{\mathbf{x} \in A} \|(\mathbf{x} - \mathbf{m}_A) - (\mathbf{m}_{A \cup B} - \mathbf{m}_A)\|^2 \\ &= \sum_{\mathbf{x} \in A} \|\mathbf{x} - \mathbf{m}_A\|^2 + \sum_{\mathbf{x} \in A} \|\mathbf{m}_{A \cup B} - \mathbf{m}_A\|^2 \\ &\quad - 2 \left(\sum_{\mathbf{x} \in A} (\mathbf{x} - \mathbf{m}_A) \right) \cdot (\mathbf{m}_{A \cup B} - \mathbf{m}_A) \end{aligned} \quad (7.35)$$

Poiché per definizione di centroide $\sum_{\mathbf{x} \in A} (\mathbf{x} - \mathbf{m}_A) = \mathbf{0}$, il doppio prodotto svanisce identicamente:

$$\sum_{\mathbf{x} \in A} \|\mathbf{x} - \mathbf{m}_{A \cup B}\|^2 = \text{SSE}_A + |A| \cdot \|\mathbf{m}_{A \cup B} - \mathbf{m}_A\|^2 \quad (7.36)$$

Sostituendo l'espressione precedentemente ricavata per $(\mathbf{m}_{A \cup B} - \mathbf{m}_A)$:

$$\begin{aligned} \sum_{\mathbf{x} \in A} \|\mathbf{x} - \mathbf{m}_{A \cup B}\|^2 &= \text{SSE}_A + |A| \left\| \frac{|B|(\mathbf{m}_B - \mathbf{m}_A)}{|A| + |B|} \right\|^2 \\ &= \text{SSE}_A + \frac{|A| \cdot |B|^2}{(|A| + |B|)^2} \|\mathbf{m}_A - \mathbf{m}_B\|^2 \end{aligned} \quad (7.37)$$

Ripetendo lo stesso sviluppo per il secondo termine relativo a B :

$$\sum_{\mathbf{y} \in B} \|\mathbf{y} - \mathbf{m}_{A \cup B}\|^2 = \text{SSE}_B + \frac{|A|^2 \cdot |B|}{(|A| + |B|)^2} \|\mathbf{m}_A - \mathbf{m}_B\|^2 \quad (7.38)$$

Sommando i due termini per ottenere $\text{SSE}_{A \cup B}$:

$$\begin{aligned} \text{SSE}_{A \cup B} &= \text{SSE}_A + \text{SSE}_B + \left[\frac{|A| \cdot |B|^2 + |A|^2 \cdot |B|}{(|A| + |B|)^2} \right] \|\mathbf{m}_A - \mathbf{m}_B\|^2 \\ &= \text{SSE}_A + \text{SSE}_B + \left[\frac{|A| \cdot |B|(|B| + |A|)}{(|A| + |B|)^2} \right] \|\mathbf{m}_A - \mathbf{m}_B\|^2 \\ &= \text{SSE}_A + \text{SSE}_B + \frac{|A| \cdot |B|}{(|A| + |B|)} \|\mathbf{m}_A - \mathbf{m}_B\|^2 \end{aligned} \quad (7.39)$$

Sottraendo $(\text{SSE}_A + \text{SSE}_B)$, si ottiene la tesi:

$$\Delta \text{SSE}_{AB} = \text{SSE}_{A \cup B} - (\text{SSE}_A + \text{SSE}_B) = \frac{|A| \cdot |B|}{|A| + |B|} \|\mathbf{m}_A - \mathbf{m}_B\|^2 \quad (7.40)$$

□

Il Metodo di Ward è l'analogo gerarchico esatto del criterio di costo del K-Means: genera cluster regolari, sferici e ben bilanciati, risultando straordinariamente robusto rispetto al rumore.

7.8.2 Esempio Pratico Guidato su 6 Punti: MIN vs MAX

Consideriamo un dataset di 6 punti bidimensionali $\{p_1, \dots, p_6\}$ con matrice di distanza iniziale:

$$\mathbf{D} = \begin{pmatrix} & p_1 & p_2 & p_3 & p_4 & p_5 & p_6 \\ p_1 & 0.00 & 0.24 & 0.22 & 0.37 & 0.34 & 0.23 \\ p_2 & 0.24 & 0.00 & 0.15 & 0.20 & 0.14 & 0.25 \\ p_3 & 0.22 & 0.15 & 0.00 & 0.15 & 0.28 & 0.11 \\ p_4 & 0.37 & 0.20 & 0.15 & 0.00 & 0.29 & 0.22 \\ p_5 & 0.34 & 0.14 & 0.28 & 0.29 & 0.00 & 0.39 \\ p_6 & 0.23 & 0.25 & 0.11 & 0.22 & 0.39 & 0.00 \end{pmatrix} \quad (7.41)$$

Risoluzione con MIN (Single Link)

1. Minimo assoluto globale: $d(p_3, p_6) = 0.11 \implies$ Unione di $\{p_3, p_6\}$ a quota $h = 0.11$.
2. Minimo successivo: $d(p_2, p_5) = 0.14 \implies$ Unione di $\{p_2, p_5\}$ a quota $h = 0.14$.
3. Distanza tra $\{p_3, p_6\}$ e p_4 : $\min(d(p_3, p_4), d(p_6, p_4)) = 0.15 \implies$ Fusione di $\{p_3, p_6\}$ con p_4 a quota $h = 0.15$.
4. Distanza tra $\{p_3, p_6, p_4\}$ e $\{p_2, p_5\}$:

$$\begin{aligned} \min_{\mathbf{x} \in \{3,6,4\}, \mathbf{y} \in \{2,5\}} d(\mathbf{x}, \mathbf{y}) &= \min(0.15, 0.25, 0.20, 0.28, 0.39, 0.29) \\ &= d(p_3, p_2) = 0.15 \end{aligned} \quad (7.42)$$

I due blocchi si fondono istantaneamente a quota $h = 0.15$ sfruttando il ponte ravvicinato p_3-p_2 .

5. Distanza da p_1 : $\min(d(p_1, p_j)) = d(p_1, p_3) = 0.22 \implies$ Fusione finale a quota $h = 0.22$.

Risoluzione con MAX (Complete Link)

1. Primi due passi identici: fusione $\{p_3, p_6\}$ a $h = 0.11$, e $\{p_2, p_5\}$ a $h = 0.14$.
2. Distanza MAX tra $\{p_3, p_6\}$ e p_4 : $\max(d(p_3, p_4), d(p_6, p_4)) = 0.22$.

3. Distanza MAX tra $\{p_3, p_6\}$ e $\{p_2, p_5\}$:

$$\begin{aligned} \max_{\mathbf{x} \in \{3,6\}, \mathbf{y} \in \{2,5\}} d(\mathbf{x}, \mathbf{y}) &= \max(0.15, 0.25, 0.28, 0.39) \\ &= d(p_6, p_5) = 0.39 \end{aligned} \quad (7.43)$$

Poiché $0.22 < 0.39$, l'unione preferita a questo passo è $\{p_3, p_6\}$ con p_4 a quota $h = 0.22$.

4. La distanza tra $\{p_3, p_6, p_4\}$ e $\{p_2, p_5\}$ rimane elevata (0.39). Invece, la distanza da p_1 a $\{p_2, p_5\}$ è $\max(0.24, 0.34) = 0.34$. Pertanto, MAX ritarda la fusione tra i due gruppi principali ed evita fusioni precoci indotte da collegamenti isolati.

7.8.3 Formula di Ricorrenza di Lance-Williams

La formula di ricorrenza proposta da Lance e Williams (1967) fornisce un quadro analitico unificato per aggiornare la matrice di prossimità ad ogni fusione senza dover riesaminare i singoli punti dati originari.

Teorema 7.8.2 (Formula di Lance-Williams). *Dati due cluster A e B fusi nel nuovo cluster $A \cup B$, la distanza tra $A \cup B$ e un terzo cluster Q è determinata da:*

$$D(A \cup B, Q) = \alpha_A D(A, Q) + \alpha_B D(B, Q) + \beta D(A, B) + \gamma |D(A, Q) - D(B, Q)| \quad (7.44)$$

dove i parametri $(\alpha_A, \alpha_B, \beta, \gamma)$ dipendono univocamente dal criterio prescelto.

Criterio di Linkage	α_A	α_B	β	γ
MIN (Single Link)	1/2	1/2	0	-1/2
MAX (Complete Link)	1/2	1/2	0	+1/2
Group Average	$\frac{ A }{ A + B }$	$\frac{ B }{ A + B }$	0	0
Centroid Linkage	$\frac{ A }{ A + B }$	$\frac{ B }{ A + B }$	$-\frac{ A B }{(A + B)^2}$	0
Metodo di Ward	$\frac{ A + Q }{ A + B + Q }$	$\frac{ B + Q }{ A + B + Q }$	$-\frac{ Q }{ A + B + Q }$	0

Tabella 7.1: Parametri della formula di ricorrenza di Lance-Williams per i principali metodi gerarchici.

Dimostrazione di Consistenza per Group Average. Verifichiamo che la sostituzione dei parametri nella formula di Lance-Williams riproduca esattamente la definizione originaria della media:

$$\begin{aligned} \sum_{\mathbf{x} \in A \cup B} \sum_{\mathbf{z} \in Q} d(\mathbf{x}, \mathbf{z}) &= \sum_{\mathbf{x} \in A} \sum_{\mathbf{z} \in Q} d(\mathbf{x}, \mathbf{z}) + \sum_{\mathbf{y} \in B} \sum_{\mathbf{z} \in Q} d(\mathbf{y}, \mathbf{z}) \\ &= |A| \cdot |Q| \cdot D_{\text{AVG}}(A, Q) + |B| \cdot |Q| \cdot D_{\text{AVG}}(B, Q) \end{aligned} \quad (7.45)$$

Dividendo per $|A \cup B| \cdot |Q| = (|A| + |B|) \cdot |Q|$ e semplificando $|Q| > 0$:

$$D_{\text{AVG}}(A \cup B, Q) = \frac{|A|}{|A| + |B|} D_{\text{AVG}}(A, Q) + \frac{|B|}{|A| + |B|} D_{\text{AVG}}(B, Q) \quad (7.46)$$

che coincide esattamente con la riga di Group Average in Tabella 7.1. $\square$

7.8.4 Tabella Sinottica Comparativa dei Criteri di Collegamento

Criterio	Obiettivo	Geometria	Outlier	Proprietà
MIN (Single)	$\min_{\mathbf{x}, \mathbf{y}} d(\mathbf{x}, \mathbf{y})$	Arbitraria, concatenata	Altissima (<i>chaining</i>)	Isomorfo all'MST
MAX (Complete)	$\max_{\mathbf{x}, \mathbf{y}} d(\mathbf{x}, \mathbf{y})$	Sferica, compatta	Bassa al centro	Diametro $\leq h$
Group Average	Media $\frac{\sum \sum d}{ A B }$	Globulare tollerante	Moderata	Bilanciato
Metodo di Ward	ΔSSE_{AB}	Sferica bilanciata	Molto bassa	Analogo K-Means

Tabella 7.2: Confronto analitico tra i quattro criteri di collegamento nel clustering gerarchico.

7.9 Clustering Gerarchico Divisivo basato su Minimum Spanning Tree (MST)

Mentre gli algoritmi divisivi generici risultano computazionalmente proibitivi (considerare tutte le possibili bisezioni di un insieme di n punti comporta $2^{n-1} - 1$ configurazioni), l'approccio basato su teoria dei grafi fornisce una soluzione elegante ed efficiente tramite il **Minimum Spanning Tree** (MST).

Definizione 7.9.1 (Minimum Spanning Tree dei Dati). Dato il grafo completo $G = (V, E)$ in cui i vertici V rappresentano gli n punti dati e ogni arco $(u, v) \in E$ ha peso $w(u, v) = d(\mathbf{x}_u, \mathbf{x}_v)$, un MST è un albero ricoprente privo di cicli di peso complessivo minimo:

$$w(\text{MST}) = \sum_{e \in \text{MST}} w(e) \rightarrow \min \quad (7.47)$$

7.9.1 Algoritmo Divisivo basato su Taglio di Archi

Algorithm 3: Clustering divisivo basato su Minimum Spanning Tree.

Dati: Dataset $\mathcal{D} = \{\mathbf{x}_1, \dots, \mathbf{x}_n\}$, numero di cluster desiderato K .

Risultato: Partizione $\{C_1, \dots, C_K\}$.

- 1 Costruisci il grafo completo pesato sui dati $G = (V, E)$
 - 2 Estrai il Minimum Spanning Tree $\mathcal{T}_{\text{MST}}$ mediante l'algoritmo di Prim o Kruskal
 - 3 Ordina gli $n - 1$ archi dell'albero per peso decrescente:
 $w(e_1) \geq w(e_2) \geq \dots \geq w(e_{n-1})$
 - 4 **for** $k = 1$ **to** $K - 1$ **do**
 - 5 Rimuovi dall'albero l'arco di peso massimo residuo e_k
 - 6 L'albero si scinde in due componenti connesse disgiunte
 - 7 **end**
 - 8 Identifica le K componenti connesse risultanti come i K cluster della partizione
-

Proprietà 7.9.1 (Equivalenza Teorica con il Single Link). *La partizione ottenuta rimuovendo i $K - 1$ archi a peso massimo dal Minimum Spanning Tree è **identica** alla partizione ottenuta arrestando l'algoritmo agglomerativo con Single Link a K cluster. Ne consegue che la costruzione dell'MST (realizzabile in $\mathcal{O}(n^2)$ con Prim) fornisce una via computazionalmente diretta per ricavare la gerarchia del Single Link.*

7.10 Complessità, Limiti e Confronto Sinottico

7.10.1 Analisi della Complessità Asintotica del Clustering Gerarchico

- **Complessità Spaziale:** L'algoritmo deve memorizzare l'intera matrice di prossimità triangolare $n \times n$:

$$\mathcal{S}_{\text{Gerarchico}} = \mathcal{O}(n^2) \quad (7.48)$$

Ciò costituisce un limite severo nei contesti di Big Data. Ad esempio, per $n = 100\,000$ punti a precisione standard (8 byte per float), la matrice richiede circa 40 GB di memoria RAM, rendendo il metodo inapplicabile senza partizionamenti preliminari.

- **Complessità Temporale Naive:** Il ciclo compie $n - 1$ iterazioni. A ogni iterazione, la ricerca lineare del minimo nella matrice di dimensione residua richiede $\mathcal{O}(n^2)$ confronti, portando a:

$$\mathcal{T}_{\text{Naive}} = \sum_{t=1}^{n-1} \mathcal{O}((n-t)^2) = \mathcal{O}(n^3) \quad (7.49)$$

- **Ottimizzazione tramite Code con Priorità (Heap):** Mantenendo le distanze per ciascun cluster in una coda con priorità (*min-heap*), l'estrazione del minimo e l'aggiornamento richiedono $\mathcal{O}(n \log n)$ per iterazione, riducendo la complessità totale a:

$$\mathcal{T}_{\text{Heap}} = \mathcal{O}(n^2 \log n) \quad (7.50)$$

(Per criteri specifici come Single Link e Complete Link, algoritmi ottimizzati come SLINK e CLINK operano in $\mathcal{O}(n^2)$ tempo e $\mathcal{O}(n)$ spazio ausiliario).

7.10.2 Limiti Strutturali del Clustering Gerarchico

1. **Irreversibilità delle Decisioni (*Greedy Nature*):** Le decisioni di fusione o scissione sono permanenti e prive di backtracking. Se due punti vengono uniti al passo t per via del rumore locale o di un criterio inadeguato, non potranno mai essere separati nei passi successivi.
2. **Mancanza di una Funzione Obiettivo Globale:** A eccezione del Metodo di Ward (che minimizza l'incremento locale di varianza), i criteri di linkage non ottimizzano una funzione di costo globale scalare sull'intero dataset.

7.10.3 Schema Comparativo Finale: K-Means vs Clustering Gerarchico

A completamento della trattazione dei due paradigmi, la Tabella 7.3 sintetizza le divergenze architetturali, algebriche e operative essenziali che guidano la scelta del modello in contesti ingegneristici e scientifici reali.

Caratteristica Operativa	K-Means Clustering	Clustering Gerarchico
Tipo di Struttura	Partizionale piatta (<i>hard clustering</i>)	Tassonomica ad albero nidificato (Dendrogramma)
Parametro K	Obbligatorio a priori	Derivabile a posteriori tracciando un taglio
Funzione Obiettivo	Minimizzazione di SSE globale	Scelte miopi locali (<i>greedy</i>) senza costo globale
Complessità Temporale	$\mathcal{O}(n \cdot K \cdot I \cdot d)$ (Lineare con n)	$\mathcal{O}(n^2 \log n)$ fino a $\mathcal{O}(n^3)$ (Sovra-quadratica)
Complessità Spaziale	$\mathcal{O}((n + K) \cdot d)$ (Lineare con n)	$\mathcal{O}(n^2)$ (Quadratica, memoria critica)
Scalabilità sui Dati	Estremamente elevata (milioni di record)	Molto bassa ($n \leq 20\,000$ in RAM standard)
Sensibilità Inizializzazione	Elevatissima (intrappolamento in minimi locali)	Deterministico (nessun seme o partizione iniziale)
Flessibilità di Forma	Solo sferica/globulare (iperpiani Voronoi)	Arbitraria con Single Link; sferica con Ward
Reversibilità Decisioni	Sì (i punti migrano ad ogni iterazione)	No (fusioni e tagli permanenti senza riassegnazione)

Tabella 7.3: Confronto sinottico globale tra K-Means e Clustering Gerarchico.

Bibliografia